

Universidade Federal do Paraná - Departamento de Estatística

CE310 - Modelos de Regressão Linear

Prof. Cesar Augusto Taconeli

Lista de exercícios

1. Defina o modelo de regressão linear simples. Especifique cada um de seus componentes e as suposições assumidas para os erros.
2. Qual o princípio da estimação por mínimos quadrados? Quais as principais propriedades dos estimadores de mínimos quadrados dos parâmetros de um modelo de regressão linear?
3. Qual o princípio da estimação por máxima verossimilhança? Qual a relação dos estimadores de mínimos quadrados e de máxima verossimilhança dos parâmetros do modelo de regressão linear se assumirmos que os erros são normalmente distribuídos?
4. Considere o modelo de regressão linear simples com $\beta_0 = 10$, $\beta_1 = 5$ e $\sigma = 4$. Assuma distribuição normal para os erros.
 - a) Apresente gráficos da distribuição de y condicional a (i) $x = 3$; (ii) $x = 5$ e (iii) $x = 10$;
 - b) Descreva o significado de β_0 e β_1 . Suponha que $x = 0$ pertença ao escopo do modelo;
 - c) Calcule $P(20 < y < 30)$ para: (i) $x = 3$; $x = 5$.
5. Considere o modelo de regressão linear simples com $\beta_0 = 10$; $\beta_1 = 0.5$ e $\sigma = 1$. Assuma que os erros sejam normalmente distribuídos.
 - a) Simule uma amostra de $n = 10$ observações para y locadas em $x = -2, -1, 0, 1$ e 2 (duas observações para cada valor de x);
 - b) Ajuste um modelo de regressão linear simples aos dados simulados no item *a*. Extraia as estimativas de β_0 e β_1 .
 - c) Repita os itens *a* e *c* 5000 vezes. Armazene as estimativas obtidas numa matriz com duas colunas (uma referente a cada parâmetro);
 - d) Construa histogramas e calcule média e variância das estimativas produzidas para cada parâmetro. Compare os resultados obtidos na simulação aos apresentados no item *b*;
 - e) Para cada uma das 5000 simulações, obtenha os intervalos de confiança 95% para β_0 e β_1 . Qual proporção dos intervalos contém os valores fixados para os respectivos parâmetros?
6. Considere o modelo de regressão linear simples sem intercepto:

$$y = \beta x + \epsilon,$$

com as suposições usuais para os erros para o modelo de regressão linear.

- a) Mencione uma situação prática em que o modelo de regressão linear passando pela origem possa ser considerado;
- b) Determine o estimador de mínimos quadrados de β ;
- c) Obtenha esperança e variância para o estimador deduzido no item b.

7. Neste exercício consideramos transformações lineares de x e y . Em todos os itens, considere o modelo de regressão linear simples conforme especificado em sala de aula. Sejam β_0 , β_1 , SQE e r os parâmetros do modelo, a soma de quadrados dos erros e o coeficiente de correlação, respectivamente.

- a) Suponha que cada valor de x seja transformado usando $x' = x - 10$ e a regressão linear simples de y em x' . Como ficam β'_0 , β'_1 , SQ'_{Res} e r' ? O que acontece com essas quantidades quando $x' = 10x$? E quando $x' = 10(x - 1) = 10x - 10$?
- b) Agora, suponha que os valores da variável resposta sejam transformados para $y' = y + 10$ e considere a regressão de y' em x . Como ficam β'_0 , β'_1 , SQ'_{Res} e r' ? O que acontece com essas quantidades quando $y' = 5y$? E quando $y' = 5(y + 2) = 5y + 10$?
- c) Em geral, como os resultados da regressão linear simples ficam afetados por transformações lineares em x e em y ?

8. Solicitado a especificar o modelo de regressão linear simples, um aluno escreveu o seguinte:

$$E(y|x) = \beta_0 + \beta_1 x + \epsilon.$$

Você concorda com essa especificação? Justifique.

9. Qual o impacto da ausência de normalidade dos erros nas propriedades dos estimadores de mínimos quadrados do modelo de regressão linear?

10. Mostre que:

- a) $\sum_{i=1}^n y_i = \sum_{i=1}^n \hat{y}_i$;
- b) $\sum_{i=1}^n r_i = 0$;
- c) Para $x = \bar{x}$ tem-se $\hat{y} = \bar{y}$;
- d) $\sum_{i=1}^n (x_i - \bar{x}) = 0$;
- e) $\sum_{i=1}^n (x_i - \bar{x})y_i = \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$;
- f) $\sum_{i=1}^n (x_i - \bar{x})^2 = \sum_{i=1}^n x_i^2 - n\bar{x}^2$;
- g) $\sum_{i=1}^n x_i r_i = 0$;

h) $\sum_{i=1}^n \hat{y}_i r_i = 0$.

11. Um estudo foi conduzido para avaliar o efeito da temperatura na produção química de um processo. Os seguintes dados foram coletados:

Temp.	-5	-4	-3	-2	-1	0	1	2	3	4	5
Prod.	1	5	4	7	10	8	9	13	14	13	18

Vamos proceder a análise dos dados usando o modelo de regressão linear simples.

- Determine as estimativas de mínimos quadrados de β_0 e β_1 e apresente a equação do modelo ajustado.
- Apresente um intervalo de confiança (95%) para β_1 ;
- Teste a hipótese $H_0 : \beta_1 = 0$ ao nível de significância de 5%;
- Apresente os limites de confiança (95%) para a resposta média quando a temperatura é igual a 3;
- Apresente limites de confiança (95%) para a diferença nas resposta média quando a temperatura é igual a 3 em relação à resposta média sob temperatura -2;
- Sob qual temperatura se estima produção igual a 12?

12. A base de dados **Prestige** do pacote **car** apresenta dados referentes à percepção da população canadense quanto a 102 diferentes profissões. Vamos considerar, para ajuste de um modelo de regressão linear simples, as seguintes variáveis:

- education**: Educação média dos profissionais (em anos de estudo);
- prestige**: Escore de prestígio da profissão segundo a resposta dos entrevistados.

Considere o prestígio da profissão como a resposta e a escolaridade média como a variável explicativa.

- Ajuste o modelo de regressão linear simples aos dados apresentados e apresente a equação do modelo ajustado;
- Construa o diagrama de dispersão e adicione a reta de regressão ajustada. A reta obtida parece se ajustar bem aos dados?
- Qual a predição para o escore de prestígio para uma profissão com escolaridade média de 12.5 anos?
- Qual o valor ajustado pelo modelo para o prestígio dos administradores públicos (primeira linha da base)? Qual o correspondente resíduo?
- Em quanto se estima a variação esperada no escore de prestígio para um ano a mais de escolaridade média entre os profissionais? E para três anos a mais?
- O intercepto tem alguma interpretação prática nesta análise?
- Apresente uma estimativa para σ^2 ;
- Teste a hipótese $H_0 : \beta_1 = 0$ vs $H_1 : \beta_1 \neq 0$ ao nível de significância de 5% e apresente suas conclusões;
- Teste a hipótese $H_0 : \beta_1 = 6$ vs $H_1 : \beta_1 \neq 6$ ao nível de significância de 5% e apresente suas conclusões;
- Apresente intervalos de confiança (95%) para os parâmetros do modelo;
- Apresente intervalos de confiança para a média e de predição considerando (i) $x = 9$; (ii) $x = 15$; (iii) $x = \bar{x}$;

- l) Adicione ao diagrama de dispersão as bandas de confiança e de predição (95%);
- m) Apresente o quadro de análise de variância e o teste F. Compare o p-valor desse teste ao teste da hipótese $H_0 : \beta_1 = 0$;
- n) Calcule o valor de R^2 e interprete-o.

13. Neste exercício vamos analisar os dados de velocidade (x , em milhas por horas) e consumo de combustível (y , em milhas por galão) para $n = 28$ automóveis de certa marca. Os dados estão disponíveis na página da disciplina no Moodle. O objetivo é ajustar um modelo de regressão linear simples para explicar o consumo de combustível em função da velocidade sem usar a função `lm` e suas dependências.

Dados:

$$\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) = -1184.39; \quad \sum_{i=1}^n (x_i - \bar{x})^2 = 7316.96; \quad \sum_{i=1}^n (y_i - \hat{y}_i)^2 = 11.20 \quad \bar{x} = 75.54; \quad \bar{y} = 12.89$$

- a) Usando o R, faça o gráfico de dispersão;
- b) Calcule as estimativas de mínimos quadrados para β_0 e β_1 . Interprete-as.
- c) Qual a variação estimada no consumo de combustível para 15mph a mais de velocidade?
- d) Escreva a expressão do modelo ajustado. Calcule o consumo de combustível estimado sob velocidade $x = 75mph$;
- e) Calcule os erros padrões de $\hat{\beta}_0$ e $\hat{\beta}_1$;
- f) Estime as variâncias para (i) o consumo médio sob velocidade $x = 75mph$; (ii) o consumo predito para um particular automóvel sob velocidade $x = 75mph$. Compare os resultados;
- g) Idêntico ao item anterior, mas para velocidade $x = 50mph$. Compare com os resultados do item anterior;
- h) Apresente intervalos de confiança 95% para β_0 e para β_1 ;
- i) Apresente intervalos de confiança 95% para o consumo médio e o consumo predito para um novo automóvel sob velocidades: (i) $x = 75mph$; (ii) $x = 50mph$;
- j) Teste a significância do modelo de regressão, ou seja, teste a hipótese $H_0 : \beta_1 = 0$ vs $H_1 : \beta_1 \neq 0$;
- k) Um especialista afirma que o consumo de combustível altera, em média, em $-0.18mpg$ para cada unidade a mais de velocidade (em mph). Teste essa hipótese.

Nota: Para as questões envolvendo testes de hipóteses, o seguinte procedimento deve ser aplicado:

- (I) Formulação das hipóteses nula e alternativa;
- (II) Apresentação e cálculo da estatística teste;
- (III) Definição da regra de decisão para os níveis de significância de 5% e 1%;
- (IV) Conclusão do problema baseada nas regras de decisão descritas no passo anterior;
- (V) Cálculo do nível descritivo (p -valor) do teste.

14. Sejam y_1 e y_2 variáveis aleatórias com distribuição conjunta normal bivariada, conforme definido na sequência:

$$\begin{pmatrix} y_1 \\ y_2 \end{pmatrix} \sim \text{Normal} \left(\boldsymbol{\mu} = \begin{bmatrix} 6 \\ 2 \end{bmatrix}, \quad \Sigma = \begin{bmatrix} 1 & 0.4 \\ 0.4 & 0.5 \end{bmatrix} \right) \quad (1)$$

- a) Quais as distribuições marginais de y_1 e y_2 ;
- $y_1 \sim N(6, 1)$ e $y_2 \sim N(2, 0.5)$
- b) Usando o R, faça gráficos das distribuições (funções densidade de probabilidade) de y_1 , y_2 e da conjunta de y_1 e y_2 ;
- c) Qual a distribuição de probabilidades de:
- i) $z_1 = y_1 + y_2$;
 - ii) $z_2 = \frac{y_1 + y_2}{2}$;
 - iii) $z_3 = y_1 - y_2$;
 - iv) $z_4 = 0.875y_1 - 2.278y_2$?
15. Sejam y_1, y_2, \dots, y_{30} variáveis aleatórias independentes com distribuição $y_i \sim N(i, i^2)$, $i = 1, 2, \dots, 30$. Qual a distribuição de $z = y_1 + y_2 + \dots + y_{30}$?