

# CE310 - Modelos de Regressão Linear

## Regressão polinomial

Cesar Augusto Taconeli

09 de junho, 2025

# Introdução

- Principais métodos para a modelagem de relação não lineares entre variáveis:

- Principais métodos para a modelagem de relação não lineares entre variáveis:
  - Transformação nas variáveis;

- Principais métodos para a modelagem de relação não lineares entre variáveis:
  - Transformação nas variáveis;
  - Regressão polinomial;

- Principais métodos para a modelagem de relação não lineares entre variáveis:
  - Transformação nas variáveis;
  - Regressão polinomial;
  - Regressão segmentada;

- Principais métodos para a modelagem de relação não lineares entre variáveis:
  - Transformação nas variáveis;
  - Regressão polinomial;
  - Regressão segmentada;
  - Regressão não paramétrica (ou semi paramétrica);

- Principais métodos para a modelagem de relação não lineares entre variáveis:
  - Transformação nas variáveis;
  - Regressão polinomial;
  - Regressão segmentada;
  - Regressão não paramétrica (ou semi paramétrica);
  - Regressão não linear.



- Principais métodos para a modelagem de relação não lineares entre variáveis:
  - Transformação nas variáveis;
  - Regressão polinomial;
  - Regressão segmentada;
  - Regressão não paramétrica (ou semi paramétrica);
  - Regressão não linear.
- Neste módulo vamos estudar as estratégias para modelagem de relações não lineares no campo da regressão linear, considerando transformação nas variáveis, regressão polinomial e regressão segmentada.

# Regressão polinomial

- Num modelo de regressão polinomial, uma mesma variável quantitativa é inserida por meio de dois ou mais termos (potências) no modelo.

- Num modelo de regressão polinomial, uma mesma variável quantitativa é inserida por meio de dois ou mais termos (potências) no modelo.
- Como exemplo, uma variável  $x$  pode ser inserida na forma linear ( $x$ ), quadrática ( $x^2$ ), cúbica ( $x^3$ ), ou ainda por meio de termos multiplicativos envolvendo outras variáveis ( $xy$ ,  $xz$ ).

# Regressão polinomial em uma variável

- O modelo de regressão polinomial de ordem  $k$  em uma variável fica especificado por:

$$y_i = \beta_0 + \beta_1 x_i + \beta_2 x_i^2 + \dots + \beta_k x_i^k + \epsilon_i.$$

# Regressão polinomial em uma variável

- O modelo de regressão polinomial de ordem  $k$  em uma variável fica especificado por:

$$y_i = \beta_0 + \beta_1 x_i + \beta_2 x_i^2 + \dots + \beta_k x_i^k + \epsilon_i.$$

- Particularmente, o modelo polinomial de ordem 2 (quadrático) é definido por:

$$y_i = \beta_0 + \beta_1 x_i + \beta_2 x_i^2 + \epsilon_i.$$

# Regressão polinomial em uma variável

- O modelo de regressão polinomial de ordem  $k$  em uma variável fica especificado por:

$$y_i = \beta_0 + \beta_1 x_i + \beta_2 x_i^2 + \dots + \beta_k x_i^k + \epsilon_i.$$

- Particularmente, o modelo polinomial de ordem 2 (quadrático) é definido por:

$$y_i = \beta_0 + \beta_1 x_i + \beta_2 x_i^2 + \epsilon_i.$$

- Assumindo que os erros têm média zero, a média de  $y$ , condicional a  $x$ , fica definida por uma função quadrática de  $x$ :

$$E(y|x) = \beta_0 + \beta_1 x + \beta_2 x^2.$$

# Regressão polinomial em uma variável

- A aplicação de modelo de regressão polinomial pode ser motivada, por exemplo:



# Regressão polinomial em uma variável

- A aplicação de modelo de regressão polinomial pode ser motivada, por exemplo:
- ① O analista pode saber, com base na teoria da área, que um modelo polinomial com uma particular ordem descreve a relação entre as variáveis;

# Regressão polinomial em uma variável

- A aplicação de modelo de regressão polinomial pode ser motivada, por exemplo:
  - 1 O analista pode saber, com base na teoria da área, que um modelo polinomial com uma particular ordem descreve a relação entre as variáveis;
  - 2 A relação entre as variáveis pode apresentar um ponto ótimo (mínimo ou máximo), o que pode motivar a investigação de um modelo quadrático;

# Regressão polinomial em uma variável

- A aplicação de modelo de regressão polinomial pode ser motivada, por exemplo:
  - 1 O analista pode saber, com base na teoria da área, que um modelo polinomial com uma particular ordem descreve a relação entre as variáveis;
  - 2 A relação entre as variáveis pode apresentar um ponto ótimo (mínimo ou máximo), o que pode motivar a investigação de um modelo quadrático;
  - 3 Em boa parte dos casos, tem-se uma relação desconhecida e não linear entre as variáveis, de maneira que polinômios de diferentes ordens podem ser testados buscando um ajuste satisfatório.

# Regressão polinomial em uma variável - ordem do modelo

- Caso não se disponha, de antemão, de um particular polinômio a ser aplicado, a ordem do polinômio deve ser escolhida de maneira criteriosa.

# Regressão polinomial em uma variável - ordem do modelo

- Caso não se disponha, de antemão, de um particular polinômio a ser aplicado, a ordem do polinômio deve ser escolhida de maneira criteriosa.
- Quanto maior a ordem do polinômio especificado, melhor o ajuste aos dados, mas menor a precisão das estimativas (*tradeoff bias-variance*).

# Regressão polinomial em uma variável - ordem do modelo

- Caso não se disponha, de antemão, de um particular polinômio a ser aplicado, a ordem do polinômio deve ser escolhida de maneira criteriosa.
- Quanto maior a ordem do polinômio especificado, melhor o ajuste aos dados, mas menor a precisão das estimativas (*tradeoff bias-variance*).
- A menos que se tenha uma justificativa adequada, polinômios de ordem superior a 3 devem ser evitados.

# Regressão polinomial em uma variável - ordem do modelo




Figura 1: Ajustes de modelos polinomiais de diferentes ordens.

# Regressão polinomial em uma variável - ordem do modelo

- A escolha da ordem do polinômio pode ser feita usando estratégias do tipo **forward** ou **backward**.



# Regressão polinomial em uma variável - ordem do modelo

- A escolha da ordem do polinômio pode ser feita usando estratégias do tipo **forward** ou **backward**.
- Na estratégia **forward** deve-se começar pelo ajuste sem a variável investigada e incluir, a cada passo, o termo linear ( $x$ ), depois o quadrático ( $x^2$ ), o cúbico ( $x^3$ )...

# Regressão polinomial em uma variável - ordem do modelo

- A escolha da ordem do polinômio pode ser feita usando estratégias do tipo **forward** ou **backward**.
- Na estratégia **forward** deve-se começar pelo ajuste sem a variável investigada e incluir, a cada passo, o termo linear ( $x$ ), depois o quadrático ( $x^2$ ), o cúbico ( $x^3$ )...
- O processo se encerra quando a adição de um termo de ordem  $t + 1$  não for significativa. O modelo escolhido é o de ordem  $t$ .

# Regressão polinomial em uma variável - ordem do modelo

- Na estratégia **backward** deve-se começar pelo ajuste do modelo polinomial de maior ordem a ser investigado (digamos  $k$ ) e, a cada passo, excluir o termo de maior ordem (primeiro  $x^k$ , depois  $x^{k-1}, \dots$ ), desde que o termo não tenha efeito significativo.

# Regressão polinomial em uma variável - ordem do modelo

- Na estratégia **backward** deve-se começar pelo ajuste do modelo polinomial de maior ordem a ser investigado (digamos  $k$ ) e, a cada passo, excluir o termo de maior ordem (primeiro  $x^k$ , depois  $x^{k-1}, \dots$ ), desde que o termo não tenha efeito significativo.
- O processo se encerra quando o termo de maior ordem (digamos  $t$ ) tiver efeito significativo. O modelo escolhido é o de ordem  $t$ .

- Extrapolar (ou seja, prever  $y$  fora do intervalo observado para  $x$ ) em geral não é apropriado para modelos polinomiais, podendo produzir resultados incorretos e inconsistentes.

- Extrapolar (ou seja, predizer  $y$  fora do intervalo observado para  $x$ ) em geral não é apropriado para modelos polinomiais, podendo produzir resultados incorretos e inconsistentes.
- Uma situação em que a extrapolação pode ser aplicada com maior segurança é quando o modelo de regressão baseia-se em algum modelo teórico da área que descreva adequadamente o fenômeno.

# Regressão polinomial - extrapolação




Figura 2: Modelos polinomiais - o problema da extrapolação

# Regressão polinomial - multicolinearidade

- Em regressão polinomial, a matriz do modelo é composta por colunas que são potências de uma mesma variável.



# Regressão polinomial - multicolinearidade

- Em regressão polinomial, a matriz do modelo é composta por colunas que são potências de uma mesma variável.
- Essa construção implica no mau condicionamento da matriz, ou seja, na correlação entre as colunas da matriz.

# Regressão polinomial - multicolinearidade

- Em regressão polinomial, a matriz do modelo é composta por colunas que são potências de uma mesma variável.
- Essa construção implica no mau condicionamento da matriz, ou seja, na correlação entre as colunas da matriz.
- Uma medida corretiva consiste em usar os dados centrados (ou seja, substituir  $x$  por  $x^* = x - \bar{x}$ ).

# Regressão polinomial - multicolinearidade

- Em regressão polinomial, a matriz do modelo é composta por colunas que são potências de uma mesma variável.
- Essa construção implica no mau condicionamento da matriz, ou seja, na correlação entre as colunas da matriz.
- Uma medida corretiva consiste em usar os dados centrados (ou seja, substituir  $x$  por  $x^* = x - \bar{x}$ ).
- Uma alternativa mais eficiente é usar **polinômios ortogonais**.

## Exemplo- Valores de imóveis em Boston

## Exemplo- Valores de imóveis em Boston

- Nesta aplicação vamos considerar os dados disponíveis na base de dados `Boston` da biblioteca `MASS` do R.

## Exemplo- Valores de imóveis em Boston

- Nesta aplicação vamos considerar os dados disponíveis na base de dados **Boston** da biblioteca **MASS** do **R**.
- Os dados referem-se aos valores dos imóveis residenciais em 506 subúrbios de Boston.

## Exemplo- Valores de imóveis em Boston

- Nesta aplicação vamos considerar os dados disponíveis na base de dados **Boston** da biblioteca **MASS** do **R**.
- Os dados referem-se aos valores dos imóveis residenciais em 506 subúrbios de Boston.
- As variáveis que vamos analisar são as seguintes:

## Exemplo- Valores de imóveis em Boston

- Nesta aplicação vamos considerar os dados disponíveis na base de dados **Boston** da biblioteca **MASS** do R.
- Os dados referem-se aos valores dos imóveis residenciais em 506 subúrbios de Boston.
- As variáveis que vamos analisar são as seguintes:
  - **medv**: preço mediano dos imóveis ocupados no subúrbio (em \$1000s);



# Exemplo- Valores de imóveis em Boston

- Nesta aplicação vamos considerar os dados disponíveis na base de dados **Boston** da biblioteca **MASS** do **R**.
- Os dados referem-se aos valores dos imóveis residenciais em 506 subúrbios de Boston.
- As variáveis que vamos analisar são as seguintes:
  - **medv**: preço mediano dos imóveis ocupados no subúrbio (em \$1000s);
  - **lstat**: percentual da população do subúrbio na menor faixa de renda.

## Exemplo- Valores de imóveis em Boston




Figura 3: Valores de imóveis e população de menor renda

## Exemplo- Valores de imóveis em Boston

- Vamos ajustar modelos polinomiais de primeira a sexta ordem, conforme descrito na sequência:

## Exemplo- Valores de imóveis em Boston

- Vamos ajustar modelos polinomiais de primeira a sexta ordem, conforme descrito na sequência:
- ❶ Modelo de regressão polinomial de primeira ordem:

$$\text{medv} = \beta_0 + \beta_1 \text{lstat} + \epsilon$$

# Exemplo- Valores de imóveis em Boston

- Vamos ajustar modelos polinomiais de primeira a sexta ordem, conforme descrito na sequência:
- ❶ Modelo de regressão polinomial de primeira ordem:

$$\text{medv} = \beta_0 + \beta_1 \text{lstat} + \epsilon$$

2. Modelo de regressão polinomial de segunda ordem:

$$\text{medv} = \beta_0 + \beta_1 \text{lstat} + \beta_2 \text{lstat}^2 + \epsilon$$

# Exemplo- Valores de imóveis em Boston

- Vamos ajustar modelos polinomiais de primeira a sexta ordem, conforme descrito na sequência:
- 1 Modelo de regressão polinomial de primeira ordem:

$$\text{medv} = \beta_0 + \beta_1 \text{lstat} + \epsilon$$

2. Modelo de regressão polinomial de segunda ordem:

$$\text{medv} = \beta_0 + \beta_1 \text{lstat} + \beta_2 \text{lstat}^2 + \epsilon$$

3. Modelo de regressão polinomial de terceira ordem:

$$\text{medv} = \beta_0 + \beta_1 \text{lstat} + \beta_2 \text{lstat}^2 + \beta_3 \text{lstat}^3 + \epsilon$$

# Exemplo- Valores de imóveis em Boston

- ④ Modelo de regressão polinomial de quarta ordem:

$$\text{medv} = \beta_0 + \beta_1 \text{lstat} + \beta_2 \text{lstat}^2 + \beta_3 \text{lstat}^3 + \beta_4 \text{lstat}^4 + \epsilon$$

# Exemplo- Valores de imóveis em Boston

- ④ Modelo de regressão polinomial de quarta ordem:

$$\text{medv} = \beta_0 + \beta_1 \text{lstat} + \beta_2 \text{lstat}^2 + \beta_3 \text{lstat}^3 + \beta_4 \text{lstat}^4 + \epsilon$$

- ⑤ Modelo de regressão polinomial de quinta ordem:

$$\text{medv} = \beta_0 + \beta_1 \text{lstat} + \beta_2 \text{lstat}^2 + \beta_3 \text{lstat}^3 + \beta_4 \text{lstat}^4 + \beta_5 \text{lstat}^5 + \epsilon$$



## Exemplo- Valores de imóveis em Boston

- ④ Modelo de regressão polinomial de quarta ordem:

$$\text{medv} = \beta_0 + \beta_1 \text{lstat} + \beta_2 \text{lstat}^2 + \beta_3 \text{lstat}^3 + \beta_4 \text{lstat}^4 + \epsilon$$

- ⑤ Modelo de regressão polinomial de quinta ordem:

$$\text{medv} = \beta_0 + \beta_1 \text{lstat} + \beta_2 \text{lstat}^2 + \beta_3 \text{lstat}^3 + \beta_4 \text{lstat}^4 + \beta_5 \text{lstat}^5 + \epsilon$$

- ⑥ Modelo de regressão polinomial de sexta ordem:

$$\text{medv} = \beta_0 + \beta_1 \text{lstat} + \beta_2 \text{lstat}^2 + \beta_3 \text{lstat}^3 + \beta_4 \text{lstat}^4 + \beta_5 \text{lstat}^5 + \beta_6 \text{lstat}^6 + \epsilon$$

## Exemplo- Valores de imóveis em Boston

- ④ Modelo de regressão polinomial de quarta ordem:

$$\text{medv} = \beta_0 + \beta_1 \text{lstat} + \beta_2 \text{lstat}^2 + \beta_3 \text{lstat}^3 + \beta_4 \text{lstat}^4 + \epsilon$$

- ⑤ Modelo de regressão polinomial de quinta ordem:

$$\text{medv} = \beta_0 + \beta_1 \text{lstat} + \beta_2 \text{lstat}^2 + \beta_3 \text{lstat}^3 + \beta_4 \text{lstat}^4 + \beta_5 \text{lstat}^5 + \epsilon$$

- ⑥ Modelo de regressão polinomial de sexta ordem:

$$\text{medv} = \beta_0 + \beta_1 \text{lstat} + \beta_2 \text{lstat}^2 + \beta_3 \text{lstat}^3 + \beta_4 \text{lstat}^4 + \beta_5 \text{lstat}^5 + \beta_6 \text{lstat}^6 + \epsilon$$

- Em todos os casos os erros são independentes e identicamente distribuídos  $\epsilon \sim N(0, \sigma^2)$ .

# Exemplo- Valores de imóveis em Boston

- Os modelos ajustados são os seguintes:

# Exemplo- Valores de imóveis em Boston

- Os modelos ajustados são os seguintes:
- ① Modelo de primeira ordem:

$$\widehat{\text{medv}} = 34.55 - 0.95 \times \text{lstat}$$

# Exemplo- Valores de imóveis em Boston

- Os modelos ajustados são os seguintes:

- 1 Modelo de primeira ordem:

$$\widehat{\text{medv}} = 34.55 - 0.95 \times \text{lstat}$$

2. Modelo de segunda ordem:

$$\widehat{\text{medv}} = 42.86 - 2.33 \times \text{lstat} + 0.043 \times \text{lstat}^2$$

# Exemplo- Valores de imóveis em Boston

- Os modelos ajustados são os seguintes:

- Modelo de primeira ordem:

$$\widehat{\text{medv}} = 34.55 - 0.95 \times \text{lstat}$$

- Modelo de segunda ordem:

$$\widehat{\text{medv}} = 42.86 - 2.33 \times \text{lstat} + 0.043 \times \text{lstat}^2$$

- Modelo de terceira ordem:

$$\widehat{\text{medv}} = 48.64 - 3.87 \times \text{lstat} + 0.15 \times \text{lstat}^2 - 0.002 \times \text{lstat}^3$$

# Exemplo- Valores de imóveis em Boston

- ④ Modelo de quarta ordem:

$$\widehat{\text{medv}} = 57.30 - 7.03 \times \text{lstat} + 0.50 \times \text{lstat}^2 - 0.016 \times \text{lstat}^3 + 0.0002 \times \text{lstat}^4$$

# Exemplo- Valores de imóveis em Boston

- ❶ Modelo de quarta ordem:

$$\widehat{\text{medv}} = 57.30 - 7.03 \times \text{lstat} + 0.50 \times \text{lstat}^2 - 0.016 \times \text{lstat}^3 + 0.0002 \times \text{lstat}^4$$

- ❷ Modelo de quinta ordem:

$$\widehat{\text{medv}} = 67.70 - 11.99 \times \text{lstat} + 1.27 \times \text{lstat}^2 - 0.068 \times \text{lstat}^3 + 0.0017 \times \text{lstat}^4 - 0.000016 \times \text{lstat}^5$$



# Exemplo- Valores de imóveis em Boston

- ❶ Modelo de quarta ordem:

$$\widehat{\text{medv}} = 57.30 - 7.03 \times \text{lstat} + 0.50 \times \text{lstat}^2 - 0.016 \times \text{lstat}^3 + 0.0002 \times \text{lstat}^4$$

- ❷ Modelo de quinta ordem:

$$\widehat{\text{medv}} = 67.70 - 11.99 \times \text{lstat} + 1.27 \times \text{lstat}^2 - 0.068 \times \text{lstat}^3 + 0.0017 \times \text{lstat}^4 - 0.000016 \times \text{lstat}^5$$

- ❸ Modelo de sexta ordem:

$$\widehat{\text{medv}} = 73.04 - 15.17 \times \text{lstat} + 1.93 \times \text{lstat}^2 - 0.131 \times \text{lstat}^3 + 0.0046 \times \text{lstat}^4 - 0.000084 \times \text{lstat}^5 + 0.00000059 \times \text{lstat}^6$$

# Exemplo- Valores de imóveis em Boston

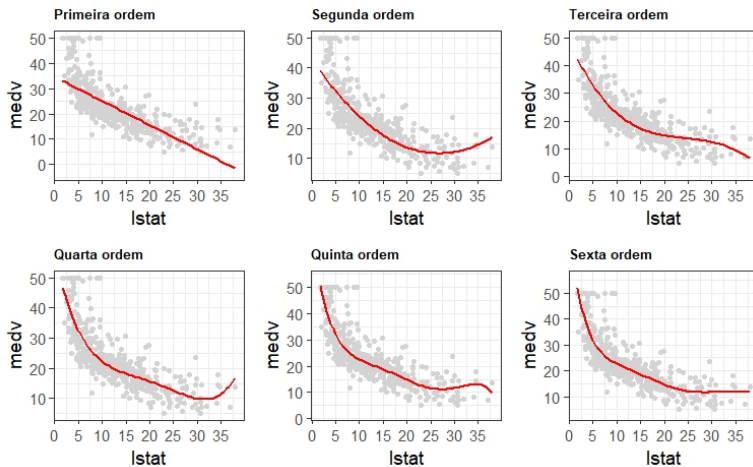


Figura 4: Modelos de regressão polinomial de diferentes ordens ajustados aos dados de valores de imóveis em Boston

## Exemplo- Valores de imóveis em Boston

Tabela 1: Tabela de análise de variância para os modelos de regressão polinomial ajustados aos dados de valores de imóveis em Boston

Order	Res.Df	RSS	Df	Sum of Sq	F	Pr(>F)
1	504	19472.38				
2	503	15347.24	1	4125.14	151.86	0.0000
3	502	14615.48	1	731.76	26.94	0.0000
4	501	13967.69	1	647.79	23.85	0.0000
5	500	13597.04	1	370.66	13.65	0.0002
6	499	13554.67	1	42.36	1.56	0.2123

## Exemplo- Valores de imóveis em Boston

- A soma de quadrados de resíduos reduz de 19472.38 para 15347.24 do modelo linear para o quadrático. Essa redução de 4125.14 é significativa ( $p < 0.0001$ ), de forma que o modelo quadrático é preferível.

## Exemplo- Valores de imóveis em Boston

- A soma de quadrados de resíduos reduz de 19472.38 para 15347.24 do modelo linear para o quadrático. Essa redução de 4125.14 é significativa ( $p < 0.0001$ ), de forma que o modelo quadrático é preferível.
- A soma de quadrados de resíduos reduz de 15347.24 para 14615.48 do modelo quadrático para o cúbico. Essa redução de 731.76 é significativa ( $p < 0.0001$ ), de forma que o modelo cúbico é preferível.

## Exemplo- Valores de imóveis em Boston

- A soma de quadrados de resíduos reduz de 19472.38 para 15347.24 do modelo linear para o quadrático. Essa redução de 4125.14 é significativa ( $p < 0.0001$ ), de forma que o modelo quadrático é preferível.
- A soma de quadrados de resíduos reduz de 15347.24 para 14615.48 do modelo quadrático para o cúbico. Essa redução de 731.76 é significativa ( $p < 0.0001$ ), de forma que o modelo cúbico é preferível.
- A soma de quadrados de resíduos reduz de 14615.48 para 13967.69 do modelo cúbico para o de quarta ordem. Essa redução de 647.79 é significativa ( $p < 0.0001$ ), de forma que o modelo de ordem quatro é preferível.

## Exemplo- Valores de imóveis em Boston

- A soma de quadrados de resíduos reduz de 13967.69 para 13597.04 do modelo de quarta para o de quinta ordem. Essa redução de 370.66 é significativa ( $p=0.0002$ ), de forma que o modelo de ordem cinco é preferível.

## Exemplo- Valores de imóveis em Boston

- A soma de quadrados de resíduos reduz de 13967.69 para 13597.04 do modelo de quarta para o de quinta ordem. Essa redução de 370.66 é significativa ( $p=0.0002$ ), de forma que o modelo de ordem cinco é preferível.
- A soma de quadrados de resíduos reduz de 13597.04 para 13554.67 do modelo de quinta para o de sexta ordem. Essa redução de 42.36 não é significativa ( $p=0.2123$ ), de forma que o modelo de ordem cinco é preferível.



## Exemplo- Valores de imóveis em Boston

- A soma de quadrados de resíduos reduz de 13967.69 para 13597.04 do modelo de quarta para o de quinta ordem. Essa redução de 370.66 é significativa ( $p=0.0002$ ), de forma que o modelo de ordem cinco é preferível.
- A soma de quadrados de resíduos reduz de 13597.04 para 13554.67 do modelo de quinta para o de sexta ordem. Essa redução de 42.36 não é significativa ( $p=0.2123$ ), de forma que o modelo de ordem cinco é preferível.
- Desta forma, com base nessa bateria de avaliações de modelos de regressão polinomial de diferentes ordens, o modelo polinomial de ordem cinco deve ser escolhido.

## Exemplo- Valores de imóveis em Boston

- **Nota:** Embora nesta aplicação um polinômio de ordem elevada (ordem cinco) tenha sido selecionado, vale reforçar o risco de *overfitting* associado a tais polinômios.

## Exemplo- Valores de imóveis em Boston

- **Nota:** Embora nesta aplicação um polinômio de ordem elevada (ordem cinco) tenha sido selecionado, vale reforçar o risco de *overfitting* associado a tais polinômios.
- Se a relação não linear entre a resposta e a explicativa não for facilmente descrita por um polinômio mais simples, soluções alternativas como regressão não paramétrica são preferíveis.

## Exemplo- Valores de imóveis em Boston

- Para fins de ilustração, vamos calcular alguns valores preditos (ajustados) pelo modelo.

## Exemplo- Valores de imóveis em Boston

- Para fins de ilustração, vamos calcular alguns valores preditos (ajustados) pelo modelo.
  - Para `lstat=10`:

$$\widehat{\text{medv}} = 67.70 - 11.99 \times 10 + 1.27 \times 10^2 - 0.068 \times 10^3 + 0.0017 \times 10^4 - 0.000016 \times 10^5 = 22.2$$

## Exemplo- Valores de imóveis em Boston

- Para fins de ilustração, vamos calcular alguns valores preditos (ajustados) pelo modelo.
  - Para `lstat=10`:

$$\widehat{\text{medv}} = 67.70 - 11.99 \times 10 + 1.27 \times 10^2 - 0.068 \times 10^3 + 0.0017 \times 10^4 - 0.000016 \times 10^5 = 22.2$$

\* Para `lstat=22`:

$$\widehat{\text{medv}} = 67.70 - 11.99 \times 22 + 1.27 \times 22^2 - 0.068 \times 22^3 + 0.0017 \times 22^4 - 0.000016 \times 22^5 = 10.3$$

# Polinômios ortogonais

# Polinômios ortogonais

- Polinômios ortogonais são uma estratégia eficiente para lidar com o mau condicionamento dos termos em regressão polinomial.



# Polinômios ortogonais

- Polinômios ortogonais são uma estratégia eficiente para lidar com o mau condicionamento dos termos em regressão polinomial.
- O modelo de regressão polinomial ortogonal, para uma variável independente  $x$ , é representado por:

$$y = \beta_0 P_0(x) + \beta_1 P_1(x) + \beta_2 P_2(x) + \dots + \beta_k P_k(x) + \epsilon, \quad \epsilon \sim N(0, \sigma^2),$$

# Polinômios ortogonais

- Polinômios ortogonais são uma estratégia eficiente para lidar com o mau condicionamento dos termos em regressão polinomial.
- O modelo de regressão polinomial ortogonal, para uma variável independente  $x$ , é representado por:

$$y = \beta_0 P_0(x) + \beta_1 P_1(x) + \beta_2 P_2(x) + \dots + \beta_k P_k(x) + \epsilon, \quad \epsilon \sim N(0, \sigma^2),$$

onde  $P_0(x), P_1(x), P_2(x), \dots, P_k(x)$  são polinômios ortogonais de ordem  $j = 0, 1, 2, \dots, k$ , ou seja:

$$\sum_{i=1}^n P_r(x_i) P_s(x_i) = 0, \quad r \neq s, \quad r, s = 0, 1, 2, \dots, k$$

$$P_0(x_i) = 1$$

- Desta forma, a matriz do modelo de regressão linear polinomial ortogonal fica dada por:

$$\mathbf{X} = \begin{bmatrix} P_0(x_1) & P_1(x_1) & P_2(x_1) & \dots & P_k(x_1) \\ P_0(x_2) & P_1(x_2) & P_2(x_2) & \dots & P_k(x_2) \\ P_0(x_3) & P_1(x_3) & P_2(x_3) & \dots & P_k(x_3) \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ P_0(x_n) & P_1(x_n) & P_2(x_n) & \dots & P_k(x_n) \end{bmatrix}$$

- Como a matriz  $\mathbf{X}$  tem colunas ortogonais, segue que:

$$\mathbf{X}'\mathbf{X} = \begin{bmatrix} \sum_{i=1}^n P_0^2(x_i) & 0 & 0 & \dots & 0 \\ 0 & \sum_{i=1}^n P_1^2(x_i) & 0 & \dots & 0 \\ 0 & 0 & \sum_{i=1}^n P_2^2(x_i) & \dots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \dots & \sum_{i=1}^n P_k^2(x_i) \end{bmatrix}$$

# Polinômios ortogonais

- Como a matriz  $\mathbf{X}$  tem colunas ortogonais, segue que:

$$\mathbf{X}'\mathbf{X} = \begin{bmatrix} \sum_{i=1}^n P_0^2(x_i) & 0 & 0 & \dots & 0 \\ 0 & \sum_{i=1}^n P_1^2(x_i) & 0 & \dots & 0 \\ 0 & 0 & \sum_{i=1}^n P_2^2(x_i) & \dots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \dots & \sum_{i=1}^n P_k^2(x_i) \end{bmatrix}$$

- Desta forma, os estimadores de mínimos quadrados para os  $\beta'$ s ficam dados por:

$$\hat{\beta}_j = \frac{\sum_{i=1}^n P_j(x_i)y_i}{\sum_{i=1}^n P_j^2(x_i)}, \quad j = 0, 1, 2, \dots, k$$

# Polinômios ortogonais

- No caso onde os níveis (valores amostrados) de  $x$  são igualmente espaçados e  $P_0(x_i)$  é fixado em 1,  $i = 1, 2, \dots, n$ , os primeiros cinco polinômios ortogonais são:

$$P_0(x_1) = 1$$

$$P_1(x_i) = \lambda_1 \left[ \frac{x_i - \bar{x}}{d} \right]$$

$$P_2(x_i) = \lambda_2 \left[ \left( \frac{x_i - \bar{x}}{d} \right)^2 - \left( \frac{n^2 - 1}{12} \right) \right]$$

$$P_3(x_i) = \lambda_3 \left[ \left( \frac{x_i - \bar{x}}{d} \right)^3 - \left( \frac{x_i - \bar{x}}{d} \right) \left( \frac{3n^2 - 7}{20} \right) \right]$$

$$P_4(x_i) = \lambda_4 \left[ \left( \frac{x_i - \bar{x}}{d} \right)^4 - \left( \frac{x_i - \bar{x}}{d} \right) \left( \frac{3n^2 - 13}{14} \right) + \frac{3(n^2 - 1)(n^2 - 9)}{560} \right]$$

onde  $d$  é a diferença entre os valores sucessivos de  $x$  e os  $\lambda$ s são constantes para garantir que os polinômios tenham valores inteiros.

## Exemplo- Inventário de estoque



## Exemplo- Inventário de estoque

- Nesta ilustração, vamos analisar dados de um inventário realizado no estoque de uma empresa.

# Exemplo- Inventário de estoque

- Nesta ilustração, vamos analisar dados de um inventário realizado no estoque de uma empresa.
- As variáveis são as seguintes:

# Exemplo- Inventário de estoque

- Nesta ilustração, vamos analisar dados de um inventário realizado no estoque de uma empresa.
- As variáveis são as seguintes:
  - **Quantidade:** Número de itens reabastecidos;

# Exemplo- Inventário de estoque

- Nesta ilustração, vamos analisar dados de um inventário realizado no estoque de uma empresa.
- As variáveis são as seguintes:
  - **Quantidade:** Número de itens reabastecidos;
  - **Custo:** Custo médio anual de estocagem (resposta).

# Exemplo- Inventário de estoque

- Nesta ilustração, vamos analisar dados de um inventário realizado no estoque de uma empresa.
- As variáveis são as seguintes:
  - **Quantidade:** Número de itens reabastecidos;
  - **Custo:** Custo médio anual de estocagem (resposta).
- Os dados apresentados na sequência exibem uma relação claramente quadrática entre o custo médio de estocagem e a quantidade de itens reabastecidos.

# Exemplo- Inventário de estoque

Tabela 2: Dados de inventário

Quantidade (x)	Custo (y)
50	335
75	326
100	316
125	313
150	311
175	314
200	318
225	328
250	337
275	345

## Exemplo- Inventário de estoque

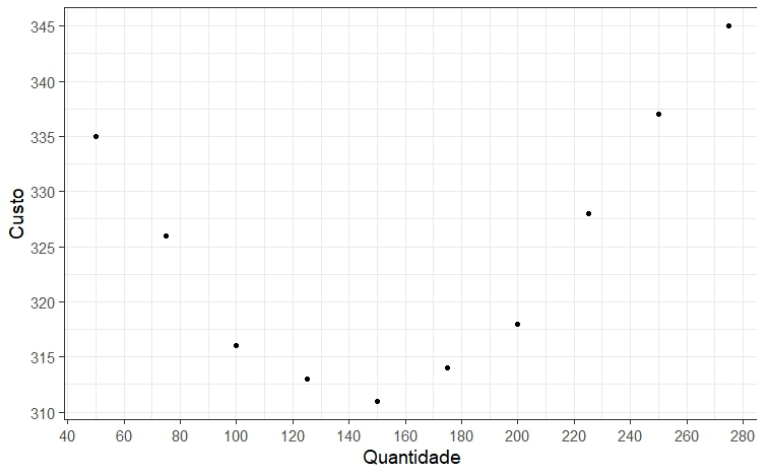


Figura 5: Custo médio de estocagem versus quantidade de itens reabastecidos

## Exemplo- Inventário de estoque

- Vamos ajustar um modelo de regressão polinomial de segunda ordem (inicialmente, não ortogonal), definido por:



## Exemplo- Inventário de estoque

- Vamos ajustar um modelo de regressão polinomial de segunda ordem (inicialmente, não ortogonal), definido por:

$$\text{Custo} = \beta_0 + \beta_1 \text{Quant} + \beta_2 \text{Quant}^2 + \epsilon, \quad \epsilon \sim N(0, \sigma^2)$$

## Exemplo- Inventário de estoque

- Vamos ajustar um modelo de regressão polinomial de segunda ordem (inicialmente, não ortogonal), definido por:

$$\text{Custo} = \beta_0 + \beta_1 \text{Quant} + \beta_2 \text{Quant}^2 + \epsilon, \quad \epsilon \sim N(0, \sigma^2)$$

- Ou, de maneira equivalente:

## Exemplo- Inventário de estoque

- Vamos ajustar um modelo de regressão polinomial de segunda ordem (inicialmente, não ortogonal), definido por:

$$\text{Custo} = \beta_0 + \beta_1 \text{Quant} + \beta_2 \text{Quant}^2 + \epsilon, \quad \epsilon \sim N(0, \sigma^2)$$

- Ou, de maneira equivalente:

$$\text{Custo} | \text{Quant} \sim N(\mu_{\text{Quant}}, \sigma^2)$$

$$\mu_{\text{Quant}} = \beta_0 + \beta_1 \text{Quant} + \beta_2 \text{Quant}^2$$

# Exemplo- Inventário de estoque

- Matriz do modelo:

# Exemplo- Inventário de estoque

- Matriz do modelo:

$$\mathbf{X} = \begin{bmatrix} 1 & 50 & 50^2 = 2500 \\ 1 & 75 & 75^2 = 5625 \\ 1 & 100 & 100^2 = 10000 \\ 1 & 125 & 125^2 = 15625 \\ 1 & 150 & 150^2 = 22500 \\ 1 & 175 & 175^2 = 30625 \\ 1 & 200 & 200^2 = 40000 \\ 1 & 225 & 225^2 = 50625 \\ 1 & 250 & 250^2 = 62500 \\ 1 & 275 & 275^2 = 75625 \end{bmatrix}$$

## Exemplo- Inventário de estoque

- A correlação linear entre Quantidade e Quantidade<sup>2</sup> é igual a 0.98.

## Exemplo- Inventário de estoque

- A correlação linear entre Quantidade e Quantidade<sup>2</sup> é igual a 0.98.
- No ajuste do modelo polinomial, o VIF para Quantidade e Quantidade<sup>2</sup> é de 27.41.

## Exemplo- Inventário de estoque

- A correlação linear entre `Quantidade` e `Quantidade2` é igual a 0.98.
- No ajuste do modelo polinomial, o VIF para `Quantidade` e `Quantidade2` é de 27.41.
- Desta forma, o modelo ajustado está fortemente suscetível aos problemas da multicolinearidade.



## Exemplo- Inventário de estoque

- O modelo de regressão polinomial (não ortogonal) de segunda ordem, ajustado pelo método de mínimos quadrados, é o seguinte:

## Exemplo- Inventário de estoque

- O modelo de regressão polinomial (não ortogonal) de segunda ordem, ajustado pelo método de mínimos quadrados, é o seguinte:

$$\widehat{\text{Custo}} = 362.17 - 0.67 \times \text{Quant} + 0.0022 \times \text{Quant}^2$$

## Exemplo- Inventário de estoque

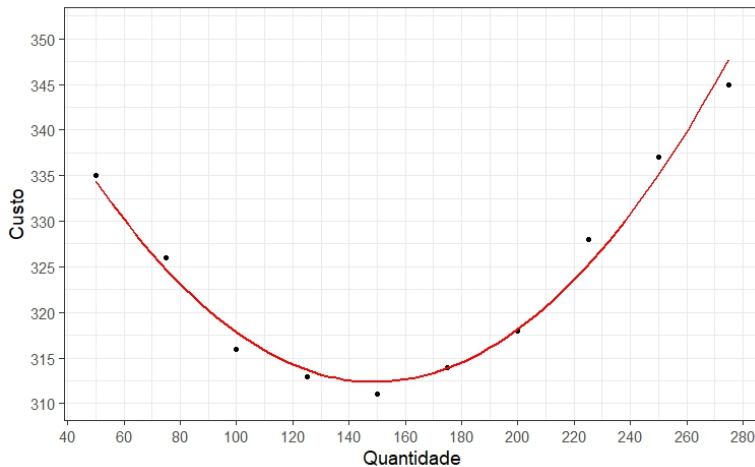


Figura 6: Custo médio de estocagem versus quantidade de itens reabastecidos com regressão polinomial ajustada

## Exemplo- Inventário de estoque

- Vamos agora considerar o modelo de regressão polinomial ortogonal de segunda ordem:

- Vamos agora considerar o modelo de regressão polinomial ortogonal de segunda ordem:

$$\text{Custo} = \beta_0 P_0(\text{Quant}) + \beta_1 P_1(\text{Quant}) + \beta_2 P_2(\text{Quant}) + \epsilon, \quad \epsilon \sim N(0, \sigma^2)$$

# Exemplo- Inventário de estoque

Tabela 3: Coeficientes dos polinômios ortogonais para os dados do inventário

$i$	$P_0(x_i)$	$P_1(x_i)$	$P_2(x_i)$
1	1	-9	6
2	1	-7	2
3	1	-5	-1
4	1	-3	-3
5	1	-1	-4
6	1	1	-4
7	1	3	-3
8	1	5	-1
9	1	7	2
10	1	9	6
<hr/>			
$\sum_{i=1}^{10} P_0^2(x_i) = 10$			
$\sum_{i=1}^{10} P_1^2(x_i) = 330$			
$\lambda_1 = 2$			
$\sum_{i=1}^{10} P_2^2(x_i) = 132$			
$\lambda_2 = 1/2$			

# Exemplo- Inventário de estoque

- Neste caso,

$$\mathbf{X}'\mathbf{X} = \begin{bmatrix} \sum_{i=1}^{10} P_0^2(x_i) & 0 & 0 \\ 0 & \sum_{i=1}^{10} P_1^2(x_i) & 0 \\ 0 & 0 & \sum_{i=1}^{10} P_2^2(x_i) \end{bmatrix} = \begin{bmatrix} 10 & 0 & 0 \\ 0 & 330 & 0 \\ 0 & 0 & 132 \end{bmatrix}$$

## Exemplo- Inventário de estoque

- Neste caso,

$$\mathbf{X}'\mathbf{X} = \begin{bmatrix} \sum_{i=1}^{10} P_0^2(x_i) & 0 & 0 \\ 0 & \sum_{i=1}^{10} P_1^2(x_i) & 0 \\ 0 & 0 & \sum_{i=1}^{10} P_2^2(x_i) \end{bmatrix} = \begin{bmatrix} 10 & 0 & 0 \\ 0 & 330 & 0 \\ 0 & 0 & 132 \end{bmatrix}$$

$$\mathbf{X}'\mathbf{y} = \begin{bmatrix} \sum_{i=1}^n P_0(x_i)y_i \\ \sum_{i=1}^n P_1(x_i)y_i \\ \sum_{i=1}^n P_2(x_i)y_i \end{bmatrix} = \begin{bmatrix} 3243 \\ 245 \\ 369 \end{bmatrix}$$



## Exemplo- Inventário de estoque

$$\hat{\beta} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y} = \begin{bmatrix} \frac{1}{10} & 0 & 0 \\ 0 & \frac{1}{330} & 0 \\ 0 & 0 & \frac{1}{132} \end{bmatrix} \times \begin{bmatrix} 3243 \\ 245 \\ 369 \end{bmatrix} = \begin{bmatrix} 324.30 \\ 0.74 \\ 2.79 \end{bmatrix}$$

## Exemplo- Inventário de estoque

$$\hat{\beta} = (X'X)^{-1}X'y = \begin{bmatrix} \frac{1}{10} & 0 & 0 \\ 0 & \frac{1}{330} & 0 \\ 0 & 0 & \frac{1}{132} \end{bmatrix} \times \begin{bmatrix} 3243 \\ 245 \\ 369 \end{bmatrix} = \begin{bmatrix} 324.30 \\ 0.74 \\ 2.79 \end{bmatrix}$$

- Logo, o modelo ajustado fica dado por:

$$\widehat{\text{Custo}} = 324.30 + 0.7424 \times P_1(\text{Quant}) + 2.7955 \times P_2(\text{Quant})$$

## Modelos polinomiais em duas ou mais variáveis

# Modelos polinomiais em duas ou mais variáveis

- Modelos polinomiais podem ser estendidos para o caso de duas ou mais variáveis explicativas.

# Modelos polinomiais em duas ou mais variáveis

- Modelos polinomiais podem ser estendidos para o caso de duas ou mais variáveis explicativas.
- Por exemplo, um modelo polinomial de segunda ordem definido em duas variáveis é dado por:

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_1^2 + \beta_4 x_2^2 + \beta_5 x_1 x_2 + \epsilon,$$

com  $\epsilon \sim N(0, \sigma^2)$ .

# Modelos polinomiais em duas ou mais variáveis

- Modelos polinomiais podem ser estendidos para o caso de duas ou mais variáveis explicativas.
- Por exemplo, um modelo polinomial de segunda ordem definido em duas variáveis é dado por:

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_1^2 + \beta_4 x_2^2 + \beta_5 x_1 x_2 + \epsilon,$$

com  $\epsilon \sim N(0, \sigma^2)$ .

- Neste caso, é comum chamar a representação gráfica de  $E(y|\mathbf{x})$  de **superfície de resposta**:

$$E(y|\mathbf{x}) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_1^2 + \beta_4 x_2^2 + \beta_5 x_1 x_2$$

## Exemplo- Gastos em educação e desempenho escolar

## Exemplo- Gastos em educação e desempenho escolar

- Nesta aplicação vamos considerar a base de dados `sat` disponível na biblioteca `faraway` do R.



## Exemplo- Gastos em educação e desempenho escolar

- Nesta aplicação vamos considerar a base de dados `sat` disponível na biblioteca `faraway` do R.
- O objetivo é ilustrar uma análise de regressão polinomial envolvendo duas variáveis explicativas.

## Exemplo- Gastos em educação e desempenho escolar

- Nesta aplicação vamos considerar a base de dados `sat` disponível na biblioteca `faraway` do R.
- O objetivo é ilustrar uma análise de regressão polinomial envolvendo duas variáveis explicativas.
- Os dados referem-se a indicadores de gastos com educação pública e resultados de testes estudantis nos 50 estados norte-americanos no período 1994-95.

## Exemplo- Gastos em educação e desempenho escolar

- As variáveis consideradas na análise são as seguintes:

## Exemplo- Gastos em educação e desempenho escolar

- As variáveis consideradas na análise são as seguintes:
  - **total**: Escore médio dos estudantes no SAT (*Scholastic Aptitude Test*);

# Exemplo- Gastos em educação e desempenho escolar

- As variáveis consideradas na análise são as seguintes:
  - **total**: Escore médio dos estudantes no SAT (*Scholastic Aptitude Test*);
  - **takers**: Porcentagem de estudantes elegíveis que realizaram o SAT;


# Exemplo- Gastos em educação e desempenho escolar

- As variáveis consideradas na análise são as seguintes:
  - **total**: Escore médio dos estudantes no SAT (*Scholastic Aptitude Test*);
  - **takers**: Porcentagem de estudantes elegíveis que realizaram o SAT;
  - **salary**: Salário médio estimado dos professores do ensino básico.

# Exemplo- Gastos em educação e desempenho escolar

- As variáveis consideradas na análise são as seguintes:
  - **total**: Escore médio dos estudantes no SAT (*Scholastic Aptitude Test*);
  - **takers**: Porcentagem de estudantes elegíveis que realizaram o SAT;
  - **salary**: Salário médio estimado dos professores do ensino básico.
- O objetivo é ajustar um modelo de regressão que explique o desempenho dos estudantes (**total**) em função das outras duas variáveis (**takers** e **salary**).

# Exemplo- Gastos em educação e desempenho escolar





## Exemplo- Gastos em educação e desempenho escolar

- Diferentes modelos de regressão linear serão ajustados, considerando (ou não):

## Exemplo- Gastos em educação e desempenho escolar

- Diferentes modelos de regressão linear serão ajustados, considerando (ou não):
  - Efeito quadrático de `takers`;

## Exemplo- Gastos em educação e desempenho escolar

- Diferentes modelos de regressão linear serão ajustados, considerando (ou não):
  - Efeito quadrático de `takers`;
  - Efeito quadrático de `salary`;

## Exemplo- Gastos em educação e desempenho escolar

- Diferentes modelos de regressão linear serão ajustados, considerando (ou não):
  - Efeito quadrático de `takers`;
  - Efeito quadrático de `salary`;
  - Efeito de interação entre `takers` e `salary`.

## Exemplo- Gastos em educação e desempenho escolar

- Diferentes modelos de regressão linear serão ajustados, considerando (ou não):
  - Efeito quadrático de `takers`;
  - Efeito quadrático de `salary`;
  - Efeito de interação entre `takers` e `salary`.
- ❶ Modelo com efeitos quadráticos de `takers` e `salary` e com efeito de interação:

# Exemplo- Gastos em educação e desempenho escolar

- Diferentes modelos de regressão linear serão ajustados, considerando (ou não):
  - Efeito quadrático de `takers`;
  - Efeito quadrático de `salary`;
  - Efeito de interação entre `takers` e `salary`.
- ❶ Modelo com efeitos quadráticos de `takers` e `salary` e com efeito de interação:

$$\text{total} = \beta_0 + \beta_1 \text{takers} + \beta_2 \text{salary} + \beta_3 \text{takers}^2 + \beta_4 \text{salary}^2 + \beta_5 \text{takers} \times \text{salary} + \epsilon$$

# Exemplo- Gastos em educação e desempenho escolar

- ② Modelo com efeitos quadráticos de **takers** e **salary**:

# Exemplo- Gastos em educação e desempenho escolar

- ② Modelo com efeitos quadráticos de `takers` e `salary`:

$$\text{total} = \beta_0 + \beta_1 \text{takers} + \beta_2 \text{salary} + \beta_3 \text{takers}^2 + \beta_4 \text{salary}^2 + \epsilon$$



## Exemplo- Gastos em educação e desempenho escolar

- ② Modelo com efeitos quadráticos de `takers` e `salary`:

$$\text{total} = \beta_0 + \beta_1 \text{takers} + \beta_2 \text{salary} + \beta_3 \text{takers}^2 + \beta_4 \text{salary}^2 + \epsilon$$

- ③ Modelo com efeito quadrático de `takers`:

## Exemplo- Gastos em educação e desempenho escolar

- ② Modelo com efeitos quadráticos de `takers` e `salary`:

$$\text{total} = \beta_0 + \beta_1 \text{takers} + \beta_2 \text{salary} + \beta_3 \text{takers}^2 + \beta_4 \text{salary}^2 + \epsilon$$

- ③ Modelo com efeito quadrático de `takers`:

$$\text{total} = \beta_0 + \beta_1 \text{takers} + \beta_2 \text{salary} + \beta_3 \text{takers}^2 + \epsilon$$

# Exemplo- Gastos em educação e desempenho escolar

- ④ Modelo com efeitos lineares de `takers` e `salary`:

# Exemplo- Gastos em educação e desempenho escolar

- ④ Modelo com efeitos lineares de `takers` e `salary`:

$$\text{total} = \beta_0 + \beta_1 \text{takers} + \beta_2 \text{salary} + \epsilon$$

# Exemplo- Gastos em educação e desempenho escolar

- ④ Modelo com efeitos lineares de `takers` e `salary`:

$$\text{total} = \beta_0 + \beta_1 \text{takers} + \beta_2 \text{salary} + \epsilon$$

- ⑤ Modelo com efeitos lineares de `takers` e `salary` e com efeito de interação:

# Exemplo- Gastos em educação e desempenho escolar

- ④ Modelo com efeitos lineares de `takers` e `salary`:

$$\text{total} = \beta_0 + \beta_1 \text{takers} + \beta_2 \text{salary} + \epsilon$$

- ⑤ Modelo com efeitos lineares de `takers` e `salary` e com efeito de interação:

$$\text{total} = \beta_0 + \beta_1 \text{takers} + \beta_2 \text{salary} + \beta_3 \text{takers} \times \text{salary} + \epsilon$$

# Exemplo- Gastos em educação e desempenho escolar

- ④ Modelo com efeitos lineares de `takers` e `salary`:

$$\text{total} = \beta_0 + \beta_1 \text{takers} + \beta_2 \text{salary} + \epsilon$$

- ⑤ Modelo com efeitos lineares de `takers` e `salary` e com efeito de interação:

$$\text{total} = \beta_0 + \beta_1 \text{takers} + \beta_2 \text{salary} + \beta_3 \text{takers} \times \text{salary} + \epsilon$$

- Em todos os casos os erros são independentes e identicamente distribuídos  $\epsilon \sim N(0, \sigma^2)$ .

# Exemplo- Gastos em educação e desempenho escolar

- ❶ Modelo com efeitos lineares de `takers` e `salary`:

$$\text{total} = \beta_0 + \beta_1 \text{takers} + \beta_2 \text{salary} + \epsilon$$

- ❷ Modelo com efeitos lineares de `takers` e `salary` e com efeito de interação:

$$\text{total} = \beta_0 + \beta_1 \text{takers} + \beta_2 \text{salary} + \beta_3 \text{takers} \times \text{salary} + \epsilon$$

- Em todos os casos os erros são independentes e identicamente distribuídos  $\epsilon \sim N(0, \sigma^2)$ .
- Na sequência são apresentados os modelos ajustados.



# Exemplo- Gastos em educação e desempenho escolar

- ① Modelo com efeitos quadráticos de `takers` e `salary` e com efeito de interação:

$$\widehat{\text{total}} = 909.66 - 6.612 \times \text{takers} + 8.678 \times \text{salary} + 0.058 \times \text{takers}^2 - 0.082 \times \text{salary}^2 - 0.018 \times \text{takers} \times \text{salary}$$

## Exemplo- Gastos em educação e desempenho escolar





Figura 8: Superfície de resposta para o modelo com efeitos quadráticos de takers e salary e com

## Exemplo- Gastos em educação e desempenho escolar

- ② Modelo com efeitos quadráticos de `takers` e `salary`:

$$\widehat{\text{total}} = 875.72 - 7.081 \times \text{takers} + 11.114 \times \text{salary} + 0.056 \times \text{takers}^2 - 0.125 \times \text{salary}^2$$

# Exemplo- Gastos em educação e desempenho escolar



## Exemplo- Gastos em educação e desempenho escolar

- ③ Modelo com efeito quadrático de `takers`:

$$\widehat{\text{total}} = 1039 - 6.646 \times \text{takers} + 1.803 \times \text{salary} + 0.051 \times \text{takers}^2$$

## Exemplo- Gastos em educação e desempenho escolar





Figura 10: Superfície de resposta para o modelo com efeito quadrático de **takers**

# Exemplo- Gastos em educação e desempenho escolar

- ④ Modelo com efeitos lineares de `takers` e `salary`:

$$\widehat{\text{total}} = 987.9 - 2.778 \times \text{takers} + 2.180 \times \text{salary}$$

# Exemplo- Gastos em educação e desempenho escolar





## Exemplo- Gastos em educação e desempenho escolar

- 5 Modelo com efeitos lineares de `takers` e `salary` e com efeito de interação:

$$\widehat{\text{total}} = 1082 - 5.026 \times \text{takers} - 0.719 \times \text{salary} + 0.064 \times \text{takers} \times \text{salary}$$

# Exemplo- Gastos em educação e desempenho escolar




Figura 12: Superfície de resposta para o modelo com efeitos lineares de takers e salary e com

## Exemplo- Gastos em educação e desempenho escolar

Tabela 4: Resumo do modelo ajustado com os efeitos quadráticos de **takers** e **salary** e com efeito de interação

	Estimate	Std. Error	t value	Pr(> t )
(Intercept)	909.6693	161.5353	5.63	0.0000
<b>takers</b>	-6.6127	1.4411	-4.59	0.0000
<b>salary</b>	8.6787	9.8935	0.88	0.3851
<b>takers</b> <sup>2</sup>	0.0583	0.0115	5.06	0.0000
<b>salary</b> <sup>2</sup>	-0.0820	0.1513	-0.54	0.5907
<b>takers</b> × <b>salary</b>	-0.0182	0.0467	-0.39	0.6991

## Exemplo- Gastos em educação e desempenho escolar

- Com base no resumo do modelo ajustado com efeitos quadráticos de `takers` e `salary` e efeito de interação, concluímos que:

## Exemplo- Gastos em educação e desempenho escolar

- Com base no resumo do modelo ajustado com efeitos quadráticos de `takers` e `salary` e efeito de interação, concluímos que:
- ① O termo de interação não é estatisticamente significativo ( $p = 0.6991$ ), de forma que pode ser removido do modelo;

## Exemplo- Gastos em educação e desempenho escolar

- Com base no resumo do modelo ajustado com efeitos quadráticos de **takers** e **salary** e efeito de interação, concluímos que:
  - 1 O termo de interação não é estatisticamente significativo ( $p = 0.6991$ ), de forma que pode ser removido do modelo;
  - 2 O efeito quadrático de **salary** também não é significativo ( $p = 0.5907$ ), ao contrário do efeito quadrático de **takers** ( $p < 0.0001$ );

## Exemplo- Gastos em educação e desempenho escolar

- Com base no resumo do modelo ajustado com efeitos quadráticos de **takers** e **salary** e efeito de interação, concluímos que:
  - 1 O termo de interação não é estatisticamente significativo ( $p = 0.6991$ ), de forma que pode ser removido do modelo;
  - 2 O efeito quadrático de **salary** também não é significativo ( $p = 0.5907$ ), ao contrário do efeito quadrático de **takers** ( $p < 0.0001$ );
  - 3 Desta forma, baseado nos resultados apresentados, o modelo poderia apenas conter o efeito quadrático de **takers**. Adicionalmente, poderia se avaliar a remoção do efeito de **salary** (exercício).