

CE310 - Modelos de Regressão Linear

Seleção de variáveis

Cesar Augusto Taconeli

26 de maio, 2025

Introdução

Princípio da navalha de Occam

Dentre as várias explicações possíveis para um fenômeno, a mais simples é a melhor

Princípio da navalha de Occam

Dentre as várias explicações possíveis para um fenômeno, a mais simples é a melhor

Fuechsel, técnico da IBM

Garbage in, garbage out

- Neste módulo vamos tratar da seleção de variáveis explicativas para o ajuste de modelos de regressão linear.

- Neste módulo vamos tratar da seleção de variáveis explicativas para o ajuste de modelos de regressão linear.
- O objetivo é identificar um modelo parcimonioso, capaz de proporcionar bom ajuste com a menor quantidade possível de parâmetros.

- Neste módulo vamos tratar da seleção de variáveis explicativas para o ajuste de modelos de regressão linear.
- O objetivo é identificar um modelo parcimonioso, capaz de proporcionar bom ajuste com a menor quantidade possível de parâmetros.
- Diferentes métodos podem ser aplicados na seleção de um subconjunto “ótimo” de variáveis.

- Neste módulo vamos tratar da seleção de variáveis explicativas para o ajuste de modelos de regressão linear.
- O objetivo é identificar um modelo parcimonioso, capaz de proporcionar bom ajuste com a menor quantidade possível de parâmetros.
- Diferentes métodos podem ser aplicados na seleção de um subconjunto “ótimo” de variáveis.
- Importante ter em mente que diferentes métodos de seleção podem produzir diferentes modelos (lembre-se: “*All models are wrong but some are useful*”).

- Por que não incluir todas as variáveis no modelo?

- Por que não incluir todas as variáveis no modelo?
- ① Um dos objetivos principais da análise de regressão é explicar a relação entre as variáveis de maneira simples e interpretável;

- Por que não incluir todas as variáveis no modelo?
- ① Um dos objetivos principais da análise de regressão é explicar a relação entre as variáveis de maneira simples e interpretável;
- ② Quanto maior o número de parâmetros no modelo, menos graus de liberdade para os resíduos, menor precisão para as inferências;

- Por que não incluir todas as variáveis no modelo?
- ① Um dos objetivos principais da análise de regressão é explicar a relação entre as variáveis de maneira simples e interpretável;
- ② Quanto maior o número de parâmetros no modelo, menos graus de liberdade para os resíduos, menor precisão para as inferências;
- ③ Quanto maior o número de variáveis incluídas no modelo, maior a possibilidade de multicolinearidade;

- Por que não incluir todas as variáveis no modelo?
- 1 Um dos objetivos principais da análise de regressão é explicar a relação entre as variáveis de maneira simples e interpretável;
 - 2 Quanto maior o número de parâmetros no modelo, menos graus de liberdade para os resíduos, menor precisão para as inferências;
 - 3 Quanto maior o número de variáveis incluídas no modelo, maior a possibilidade de multicolinearidade;
 - 4 Quanto mais complexo (parametrizado) o modelo, melhor o ajuste da amostra, mas menor seu poder de generalização (e menor o poder preditivo).

Como proceder a seleção do modelo?

Como proceder a seleção do modelo?

- Antes de aplicar qualquer método analítico para seleção de variáveis, é recomendável fazer uma pré-triagem de variáveis, buscando eliminar variáveis que:

Como proceder a seleção do modelo?

- Antes de aplicar qualquer método analítico para seleção de variáveis, é recomendável fazer uma pré-triagem de variáveis, buscando eliminar variáveis que:
 - Sejam redundantes;

Como proceder a seleção do modelo?

- Antes de aplicar qualquer método analítico para seleção de variáveis, é recomendável fazer uma pré-triagem de variáveis, buscando eliminar variáveis que:
 - Sejam redundantes;
 - Apresentem inconsistências;

Como proceder a seleção do modelo?

- Antes de aplicar qualquer método analítico para seleção de variáveis, é recomendável fazer uma pré-triagem de variáveis, buscando eliminar variáveis que:
 - Sejam redundantes;
 - Apresentem inconsistências;
 - Estejam fora do contexto do estudo;

Como proceder a seleção do modelo?

- Antes de aplicar qualquer método analítico para seleção de variáveis, é recomendável fazer uma pré-triagem de variáveis, buscando eliminar variáveis que:
 - Sejam redundantes;
 - Apresentem inconsistências;
 - Estejam fora do contexto do estudo;
 - Apresentem elevada taxa de dados perdidos (*missing data*)...

- Certos modelos apresentam alguma hierarquia natural quanto às variáveis que os compõem.

Seleção de variáveis - princípio hierárquico

- Certos modelos apresentam alguma hierarquia natural quanto às variáveis que os compõem.
- Nesses casos, a seleção das variáveis a compor o modelo deve respeitar essa hierarquia.

- Certos modelos apresentam alguma hierarquia natural quanto às variáveis que os compõem.
- Nesses casos, a seleção das variáveis a compor o modelo deve respeitar essa hierarquia.
- Um dos casos mais típicos é o **modelo polinomial**.

- Considere o modelo polinomial de segunda ordem:

$$y = \beta_0 + \beta_1 x + \beta_2 x^2 + \epsilon.$$

- Considere o modelo polinomial de segunda ordem:

$$y = \beta_0 + \beta_1 x + \beta_2 x^2 + \epsilon.$$

- Em modelos polinomiais, a remoção das variáveis sempre deve iniciar pelos termos de maior ordem.

- Considere o modelo polinomial de segunda ordem:

$$y = \beta_0 + \beta_1 x + \beta_2 x^2 + \epsilon.$$

- Em modelos polinomiais, a remoção das variáveis sempre deve iniciar pelos termos de maior ordem.
- Para fins de ilustração, considere o modelo quadrático com a remoção do termo linear:

$$y = \beta_0 + \beta_2 x^2 + \epsilon.$$

- Suponha que seja feita uma mudança de escala, trocando x por $x + c$. O modelo ficaria dado por:

$$y = \beta_0 + \beta_2 c^2 + 2\beta_2 c x + \beta_2 x^2 + \epsilon.$$

- Suponha que seja feita uma mudança de escala, trocando x por $x + c$. O modelo ficaria dado por:

$$y = \beta_0 + \beta_2 c^2 + 2\beta_2 c x + \beta_2 x^2 + \epsilon.$$

- Observe que o termo linear reaparece mediante simples mudança de escala.

- Suponha que seja feita uma mudança de escala, trocando x por $x + c$. O modelo ficaria dado por:

$$y = \beta_0 + \beta_2 c^2 + 2\beta_2 c x + \beta_2 x^2 + \epsilon.$$

- Observe que o termo linear reaparece mediante simples mudança de escala.
- Em geral, é indesejado que a estrutura do modelo (e as interpretações) sejam alteradas devido à simples mudança de escala dos dados.

Seleção de variáveis - Modelos hierárquicos

- Da mesma forma o princípio hierárquico se aplica a modelos com termos de interação entre variáveis.

Seleção de variáveis - Modelos hierárquicos

- Da mesma forma o princípio hierárquico se aplica a modelos com termos de interação entre variáveis.
- Considere o modelo de regressão com interação de segunda ordem:

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_1^2 + \beta_4 x_2^2 + \beta_5 x_1 x_2 + \epsilon.$$

Seleção de variáveis - Modelos hierárquicos

- Da mesma forma o princípio hierárquico se aplica a modelos com termos de interação entre variáveis.
- Considere o modelo de regressão com interação de segunda ordem:

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_1^2 + \beta_4 x_2^2 + \beta_5 x_1 x_2 + \epsilon.$$

- Neste caso, não é recomendável remover o termo de interação ($x_1 x_2$) sem a remoção dos demais termos quadráticos (x_1^2, x_2^2);

Seleção de variáveis - Modelos hierárquicos

- Da mesma forma o princípio hierárquico se aplica a modelos com termos de interação entre variáveis.
- Considere o modelo de regressão com interação de segunda ordem:

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_1^2 + \beta_4 x_2^2 + \beta_5 x_1 x_2 + \epsilon.$$

- Neste caso, não é recomendável remover o termo de interação ($x_1 x_2$) sem a remoção dos demais termos quadráticos (x_1^2 , x_2^2);
- A remoção conjunta de $x_1 x_2$, x_1^2 e x_2^2 é válida, e tem por objetivo comparar os ajustes linear e quadrático.

Critérios para comparação de modelos

Critérios para comparação de modelos

- No processo de seleção de covariáveis, diferentes critérios podem ser usados para comparar os modelos produzidos. Alguns deles são descritos na sequência.

Critérios para comparação de modelos

- No processo de seleção de covariáveis, diferentes critérios podem ser usados para comparar os modelos produzidos. Alguns deles são descritos na sequência.
- **Coeficiente de determinação** - O coeficiente de determinação de um modelo é definido como:

$$R^2 = \frac{SQ_{\text{Total}} - SQ_{\text{Res}}}{SQ_{\text{Total}}} = 1 - \frac{SQ_{\text{Res}}}{SQ_{\text{Total}}},$$

em que

$$SQ_{\text{Total}} = \sum_{i=1}^n (y_i - \bar{y})^2 \quad \text{e} \quad SQ_{\text{Res}} = \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

são as somas de quadrados total e atribuída aos resíduos, respectivamente.

Critérios para comparação de modelos

- O coeficiente de determinação expressa a proporção da variabilidade total explicada pelo modelo ajustado.

Critérios para comparação de modelos

- O coeficiente de determinação expressa a proporção da variabilidade total explicada pelo modelo ajustado.
- O valor de R^2 nunca decresce à medida que novas covariáveis são incluídas no modelo.

Critérios para comparação de modelos

- O coeficiente de determinação expressa a proporção da variabilidade total explicada pelo modelo ajustado.
- O valor de R^2 nunca decresce à medida que novas covariáveis são incluídas no modelo.
- Assim, o modelo que produz maior valor de R^2 incluirá, necessariamente, todas as variáveis disponíveis.

- **Coeficiente de determinação ajustado** - O coeficiente de determinação ajustado (ou simplesmente R^2 ajustado) é definido por:

$$R_{Aj}^2 = 1 - \left(\frac{n-1}{n-p} \right) (1 - R^2),$$

em que n e p são o número de observações e o número de parâmetros do modelo.

- **Coeficiente de determinação ajustado** - O coeficiente de determinação ajustado (ou simplesmente R^2 ajustado) é definido por:

$$R_{Aj}^2 = 1 - \left(\frac{n-1}{n-p} \right) (1 - R^2),$$

em que n e p são o número de observações e o número de parâmetros do modelo.

- Diferentemente do que ocorre para R^2 , o valor de R_{Aj}^2 pode não aumentar mediante inclusão de novas variáveis ao modelo. Neste caso, deve-se optar por modelos com maiores valores de R_{Aj}^2 .

- **Quadrado médio de resíduos**, definido por:

$$\text{QM}_{\text{Res}} = \frac{\text{SQ}_{\text{Res}}}{n - p} = \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{n - p}.$$

também pode ser usado para comparação e seleção de modelos de regressão.

Critérios para comparação de modelos

- **Quadrado médio de resíduos**, definido por:

$$QM_{\text{Res}} = \frac{SQ_{\text{Res}}}{n - p} = \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{n - p}.$$

também pode ser usado para comparação e seleção de modelos de regressão.

- Deve-se optar por modelos com menores valores para QM_{Res} .

Critérios para comparação de modelos

- **Quadrado médio de resíduos**, definido por:

$$QM_{\text{Res}} = \frac{SQ_{\text{Res}}}{n - p} = \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{n - p}.$$

também pode ser usado para comparação e seleção de modelos de regressão.

- Deve-se optar por modelos com menores valores para QM_{Res} .
- Pode-se mostrar que minimizar QM_{Res} é equivalente a maximizar R_{Aj}^2 , de forma que os dois critérios conduzem à seleção do mesmo conjunto de variáveis.

Critérios para comparação de modelos

- A **estatística PRESS** permite avaliar a qualidade preditiva dos modelos de regressão, sendo definida por:

$$\text{PRESS} = \sum_{i=1}^n \left[y_i - \hat{y}_{(i)} \right]^2 = \sum_{i=1}^n \left(\frac{r_i}{1 - h_{ii}} \right)^2,$$

em que $\hat{y}_{(i)}$ é obtido com base no modelo ajustado apenas excluindo a i -ésima observação, ou seja, com as demais $n - 1$ observações ($i = 1, 2, \dots, n$).

Critérios para comparação de modelos

- A **estatística PRESS** permite avaliar a qualidade preditiva dos modelos de regressão, sendo definida por:

$$\text{PRESS} = \sum_{i=1}^n \left[y_i - \hat{y}_{(i)} \right]^2 = \sum_{i=1}^n \left(\frac{r_i}{1 - h_{ii}} \right)^2,$$

em que $\hat{y}_{(i)}$ é obtido com base no modelo ajustado apenas excluindo a i -ésima observação, ou seja, com as demais $n - 1$ observações ($i = 1, 2, \dots, n$).

- Menores valores da estatística PRESS indicam modelos com melhor poder preditivo.

Critérios para comparação de modelos

- O critério de informação de Akaike (*Akaike Information Criterion*), ou simplesmente AIC, é definido por:

$$\text{AIC} = -2l(\hat{\theta}) + 2p,$$

em que $l(\hat{\theta})$ é a log-verossimilhança maximizada do modelo (calculada com base nos estimadores de máxima verossimilhança dos parâmetros) e p o número de parâmetros do modelo.

Critérios para comparação de modelos

- O critério de informação de Akaike (*Akaike Information Criterion*), ou simplesmente AIC, é definido por:

$$\text{AIC} = -2l(\hat{\theta}) + 2p,$$

em que $l(\hat{\theta})$ é a log-verossimilhança maximizada do modelo (calculada com base nos estimadores de máxima verossimilhança dos parâmetros) e p o número de parâmetros do modelo.

- No caso de um modelo de regressão linear temos:

$$\text{AIC} = -n \ln(\text{SQ}_{\text{Res}}/n) + 2p.$$

Critérios para comparação de modelos

- O componente $2p$, na expressão do AIC, atua como *termo de penalização* associado à complexidade (número de parâmetros) do modelo.

Critérios para comparação de modelos

- O componente $2p$, na expressão do AIC, atua como *termo de penalização* associado à complexidade (número de parâmetros) do modelo.
- Um critério alternativo ao AIC é o Critério de Informação Bayesiano (BIC), definido, para um modelo de regressão linear, por:

$$\text{BIC} = -n \ln(\text{SQ}_{\text{Res}}/n) + \ln(n)p.$$

Critérios para comparação de modelos

- O componente $2p$, na expressão do AIC, atua como *termo de penalização* associado à complexidade (número de parâmetros) do modelo.
- Um critério alternativo ao AIC é o Critério de Informação Bayesiano (BIC), definido, para um modelo de regressão linear, por:

$$\text{BIC} = -n \ln(\text{SQ}_{\text{Res}}/n) + \ln(n)p.$$

- O BIC penaliza mais fortemente a complexidade do modelo que o AIC ao substituir p por $\ln(n)$ como fator de penalização.

Critérios para comparação de modelos

- O componente $2p$, na expressão do AIC, atua como *termo de penalização* associado à complexidade (número de parâmetros) do modelo.
- Um critério alternativo ao AIC é o Critério de Informação Bayesiano (BIC), definido, para um modelo de regressão linear, por:

$$\text{BIC} = -n \ln(\text{SQ}_{\text{Res}}/n) + \ln(n)p.$$

- O BIC penaliza mais fortemente a complexidade do modelo que o AIC ao substituir p por $\ln(n)$ como fator de penalização.
- Devemos selecionar modelos com menores valores de AIC (ou BIC).

Algoritmos de seleção de variáveis

Algoritmos de seleção de variáveis

- Um primeiro algoritmo de seleção de modelos, baseados em critérios de qualidade de ajuste, é o método **todas as regressões possíveis**.

Algoritmos de seleção de variáveis

- Um primeiro algoritmo de seleção de modelos, baseados em critérios de qualidade de ajuste, é o método **todas as regressões possíveis**.
- Suponha uma análise de regressão com k variáveis.

Algoritmos de seleção de variáveis

- Um primeiro algoritmo de seleção de modelos, baseados em critérios de qualidade de ajuste, é o método **todas as regressões possíveis**.
- Suponha uma análise de regressão com k variáveis.
- Neste caso, devemos ajustar todos os possíveis modelos de regressão com $j \leq k$ variáveis explicativas, para $j = 0, 1, 2, \dots, k$;

Algoritmos de seleção de variáveis

- Um primeiro algoritmo de seleção de modelos, baseados em critérios de qualidade de ajuste, é o método **todas as regressões possíveis**.
- Suponha uma análise de regressão com k variáveis.
- Neste caso, devemos ajustar todos os possíveis modelos de regressão com $j \leq k$ variáveis explicativas, para $j = 0, 1, 2, \dots, k$;
- Para cada modelo de regressão ajustado calcula-se o valor do critério de seleção escolhido (AIC, BIC ou $R^2_{Aj} \dots$).

Algoritmos de seleção de variáveis

- Um primeiro algoritmo de seleção de modelos, baseados em critérios de qualidade de ajuste, é o método **todas as regressões possíveis**.
- Suponha uma análise de regressão com k variáveis.
- Neste caso, devemos ajustar todos os possíveis modelos de regressão com $j \leq k$ variáveis explicativas, para $j = 0, 1, 2, \dots, k$;
- Para cada modelo de regressão ajustado calcula-se o valor do critério de seleção escolhido (AIC, BIC ou $R_{Aj}^2 \dots$).
- O modelo selecionado será aquele que apresentar o valor ótimo para o critério adotado (maior R_{Aj}^2 , menor AIC, \dots).

Todas as regressões possíveis

- O método baseado em todas as regressões possíveis torna-se inviável mesmo para um número moderado de variáveis.

Todas as regressões possíveis

- O método baseado em todas as regressões possíveis torna-se inviável mesmo para um número moderado de variáveis.
- Para k variáveis o número de regressões possíveis é 2^k . Para $k = 30$, por exemplo, teríamos 1.073.741.824 modelos possíveis!

Todas as regressões possíveis

- O método baseado em todas as regressões possíveis torna-se inviável mesmo para um número moderado de variáveis.
- Para k variáveis o número de regressões possíveis é 2^k . Para $k = 30$, por exemplo, teríamos 1.073.741.824 modelos possíveis!
- Como alternativa ao método de todas as regressões possíveis podemos usar os algoritmos backward, forward ou stepwise.

Todas as regressões possíveis

- O método baseado em todas as regressões possíveis torna-se inviável mesmo para um número moderado de variáveis.
- Para k variáveis o número de regressões possíveis é 2^k . Para $k = 30$, por exemplo, teríamos 1.073.741.824 modelos possíveis!
- Como alternativa ao método de todas as regressões possíveis podemos usar os algoritmos backward, forward ou stepwise.
- Esses algoritmos visam determinar um modelo subótimo, obtido mediante um número consideravelmente menor de modelos ajustados e comparados.

Seleção de variáveis - Método backward

- 1 Ajuste o modelo de regressão com todas as k covariáveis disponíveis;

Seleção de variáveis - Método backward

- 1 Ajuste o modelo de regressão com todas as k covariáveis disponíveis;
- 2 Remova as variáveis do modelo uma por vez e calcule o valor do critério de qualidade de ajuste adotado (digamos o AIC, para ilustração) para cada modelo;

Seleção de variáveis - Método backward

- 1 Ajuste o modelo de regressão com todas as k covariáveis disponíveis;
- 2 Remova as variáveis do modelo uma por vez e calcule o valor do critério de qualidade de ajuste adotado (digamos o AIC, para ilustração) para cada modelo;
- 3 Remova do modelo (em definitivo) a variável cuja exclusão resultar em menor AIC;

Seleção de variáveis - Método backward

- 1 Ajuste o modelo de regressão com todas as k covariáveis disponíveis;
- 2 Remova as variáveis do modelo uma por vez e calcule o valor do critério de qualidade de ajuste adotado (digamos o AIC, para ilustração) para cada modelo;
- 3 Remova do modelo (em definitivo) a variável cuja exclusão resultar em menor AIC;
- 4 Os passos 1 a 3 são repetidos para o novo modelo (com a remoção da variável) e o processo continua até o momento em que nenhuma remoção produzir um ajuste com menor AIC que o modelo do passo anterior.

Seleção de variáveis - Método forward

- 1 Ajuste o modelo nulo (sem variáveis explicativas);

Seleção de variáveis - Método forward

- 1 Ajuste o modelo nulo (sem variáveis explicativas);
- 2 Adicione as variáveis ao modelo uma de cada vez e calcule o valor do critério de qualidade de ajuste adotado (digamos o AIC, para ilustração) para cada modelo;

Seleção de variáveis - Método forward

- 1 Ajuste o modelo nulo (sem variáveis explicativas);
- 2 Adicione as variáveis ao modelo uma de cada vez e calcule o valor do critério de qualidade de ajuste adotado (digamos o AIC, para ilustração) para cada modelo;
- 3 Inclua no modelo (em definitivo) a variável cuja exclusão resultar em menor AIC;

Seleção de variáveis - Método forward

- 1 Ajuste o modelo nulo (sem variáveis explicativas);
- 2 Adicione as variáveis ao modelo uma de cada vez e calcule o valor do critério de qualidade de ajuste adotado (digamos o AIC, para ilustração) para cada modelo;
- 3 Inclua no modelo (em definitivo) a variável cuja exclusão resultar em menor AIC;
- 4 Os passos 1 a 3 são repetidos para o novo modelo (com a inclusão da variável) e o processo continua até o momento em que nenhuma inclusão produzir um ajuste com menor AIC que o modelo do passo anterior.

Seleção de variáveis - Método combinado

- 1 Ajuste o modelo de regressão com todas as k covariáveis disponíveis. Proceda como descrito no algoritmo backward, mas...

Seleção de variáveis - Método combinado

- 1 Ajuste o modelo de regressão com todas as k covariáveis disponíveis. Proceda como descrito no algoritmo backward, mas...
- 2 A cada passo do algoritmo, avalie tanto a inclusão variáveis não inseridas quanto a exclusão das variáveis que compõem o modelo.

Seleção de variáveis - Método combinado

- 1 Ajuste o modelo de regressão com todas as k covariáveis disponíveis. Proceda como descrito no algoritmo backward, mas...
- 2 A cada passo do algoritmo, avalie tanto a inclusão variáveis não inseridas quanto a exclusão das variáveis que compõem o modelo.
- 3 Inclua (exclua) no modelo a variável cuja inclusão (exclusão) resultar em menor AIC;

Seleção de variáveis - Método combinado

- 1 Ajuste o modelo de regressão com todas as k covariáveis disponíveis. Proceda como descrito no algoritmo backward, mas...
- 2 A cada passo do algoritmo, avalie tanto a inclusão variáveis não inseridas quanto a exclusão das variáveis que compõem o modelo.
- 3 Inclua (exclua) no modelo a variável cuja inclusão (exclusão) resultar em menor AIC;
- 4 Os passos 1 a 3 são repetidos para o novo modelo (com a inclusão (exclusão) da variável) e o processo continua até o momento em que nenhuma inclusão (ou exclusão) produzir um ajuste com menor AIC que o modelo do passo anterior.

Exemplo- Desempenho de atletas de remo

Exemplo- Desempenho de atletas de remo

- Nesta aplicação vamos analisar dados de 90 atletas de remo, com idades entre 18 e 24 anos.

Exemplo- Desempenho de atletas de remo

- Nesta aplicação vamos analisar dados de 90 atletas de remo, com idades entre 18 e 24 anos.
- A variável resposta é **racetime**, o tempo gasto numa prova de 2km realizada num simulador.

Exemplo- Desempenho de atletas de remo

- Nesta aplicação vamos analisar dados de 90 atletas de remo, com idades entre 18 e 24 anos.
- A variável resposta é **racetime**, o tempo gasto numa prova de 2km realizada num simulador.
- As variáveis explicativas são as seguintes:

Exemplo- Desempenho de atletas de remo

- Nesta aplicação vamos analisar dados de 90 atletas de remo, com idades entre 18 e 24 anos.
- A variável resposta é **racetime**, o tempo gasto numa prova de 2km realizada num simulador.
- As variáveis explicativas são as seguintes:
 - **tall**- altura (cm)

Exemplo- Desempenho de atletas de remo

- Nesta aplicação vamos analisar dados de 90 atletas de remo, com idades entre 18 e 24 anos.
- A variável resposta é **racetime**, o tempo gasto numa prova de 2km realizada num simulador.
- As variáveis explicativas são as seguintes:
 - **tall**- altura (cm)
 - **Weight**- peso (kg)

Exemplo- Desempenho de atletas de remo

- Nesta aplicação vamos analisar dados de 90 atletas de remo, com idades entre 18 e 24 anos.
- A variável resposta é **racetime**, o tempo gasto numa prova de 2km realizada num simulador.
- As variáveis explicativas são as seguintes:
 - **tall**- altura (cm)
 - **Weight**- peso (kg)
 - **arm_span**- envergadura (cm)

Exemplo- Desempenho de atletas de remo

- Nesta aplicação vamos analisar dados de 90 atletas de remo, com idades entre 18 e 24 anos.
- A variável resposta é **racetime**, o tempo gasto numa prova de 2km realizada num simulador.
- As variáveis explicativas são as seguintes:
 - **tall**- altura (cm)
 - **Weight**- peso (kg)
 - **arm_span**- envergadura (cm)
 - **flex_arm**- circunferência do braço (cm)

Exemplo- Desempenho de atletas de remo

- Nesta aplicação vamos analisar dados de 90 atletas de remo, com idades entre 18 e 24 anos.
- A variável resposta é **racetime**, o tempo gasto numa prova de 2km realizada num simulador.
- As variáveis explicativas são as seguintes:
 - **tall**- altura (cm)
 - **Weight**- peso (kg)
 - **arm_span**- envergadura (cm)
 - **flex_arm**- circunferência do braço (cm)
 - **thigh_ci**- circunferência da coxa (cm)

Exemplo- Desempenho de atletas de remo

- Relação de variáveis explicativas (continuação)

Exemplo- Desempenho de atletas de remo

- Relação de variáveis explicativas (continuação)
 - `calf_ci`- circunferência da panturrilha (cm)

Exemplo- Desempenho de atletas de remo

- Relação de variáveis explicativas (continuação)
 - `calf_ci`- circunferência da panturrilha (cm)
 - `tricep`- prega do triceps (mm)

Exemplo- Desempenho de atletas de remo

- Relação de variáveis explicativas (continuação)
 - `calf_ci`- circunferência da panturrilha (cm)
 - `tricep`- prega do triceps (mm)
 - `biceps`- prega do biceps (mm)

Exemplo- Desempenho de atletas de remo

- Relação de variáveis explicativas (continuação)
 - calf_ci- circunferência da panturrilha (cm)
 - tricep- prega do triceps (mm)
 - biceps- prega do biceps (mm)
 - thigh- prega da coxa

Exemplo- Desempenho de atletas de remo

- Relação de variáveis explicativas (continuação)
 - calf_ci- circunferência da panturrilha (cm)
 - tricep- prega do triceps (mm)
 - biceps- prega do biceps (mm)
 - thigh- prega da coxa
 - est_ffm- massa livre de gordura estimada (kg)

Exemplo- Desempenho de atletas de remo

- Relação de variáveis explicativas (continuação)
 - calf_ci- circunferência da panturrilha (cm)
 - tricep- prega do triceps (mm)
 - biceps- prega do biceps (mm)
 - thigh- prega da coxa
 - est_ffm- massa livre de gordura estimada (kg)
 - est_fm- massa gorda estimada (kg)

Exemplo- Desempenho de atletas de remo

- Relação de variáveis explicativas (continuação)
 - calf_ci- circunferência da panturrilha (cm)
 - tricep- prega do triceps (mm)
 - biceps- prega do biceps (mm)
 - thigh- prega da coxa
 - est_ffm- massa livre de gordura estimada (kg)
 - est_fm- massa gorda estimada (kg)
 - best_snr- teste de alcance sentada (cm)

Exemplo- Desempenho de atletas de remo

- Relação de variáveis explicativas (continuação)
 - calf_ci- circunferência da panturrilha (cm)
 - tricep- prega do triceps (mm)
 - biceps- prega do biceps (mm)
 - thigh- prega da coxa
 - est_ffm- massa livre de gordura estimada (kg)
 - est_fm- massa gorda estimada (kg)
 - best_snr- teste de alcance sentada (cm)
 - best_vj- teste de salto vertical (cm)

Exemplo- Desempenho de atletas de remo

- Relação de variáveis explicativas (continuação)
 - calf_ci- circunferência da panturrilha (cm)
 - tricep- prega do triceps (mm)
 - biceps- prega do biceps (mm)
 - thigh- prega da coxa
 - est_ffm- massa livre de gordura estimada (kg)
 - est_fm- massa gorda estimada (kg)
 - best_snr- teste de alcance sentada (cm)
 - best_vj- teste de salto vertical (cm)
 - leg_powe- teste de pernas (kpm/min)

Exemplo- Desempenho de atletas de remo

- Relação de variáveis explicativas (continuação)
 - calf_ci- circunferência da panturrilha (cm)
 - tricep- prega do triceps (mm)
 - biceps- prega do biceps (mm)
 - thigh- prega da coxa
 - est_ffm- massa livre de gordura estimada (kg)
 - est_fm- massa gorda estimada (kg)
 - best_snr- teste de alcance sentada (cm)
 - best_vj- teste de salto vertical (cm)
 - leg_powe- teste de pernas (kpm/min)
 - endo- endomorfia

Exemplo- Desempenho de atletas de remo

- Relação de variáveis explicativas (continuação)
 - calf_ci- circunferência da panturrilha (cm)
 - tricep- prega do triceps (mm)
 - biceps- prega do biceps (mm)
 - thigh- prega da coxa
 - est_ffm- massa livre de gordura estimada (kg)
 - est_fm- massa gorda estimada (kg)
 - best_snr- teste de alcance sentada (cm)
 - best_vj- teste de salto vertical (cm)
 - leg_powe- teste de pernas (kpm/min)
 - endo- endomorfia
 - meso- mesomorfia

Exemplo- Desempenho de atletas de remo

- Relação de variáveis explicativas (continuação)
 - calf_ci- circunferência da panturrilha (cm)
 - tricep- prega do triceps (mm)
 - biceps- prega do biceps (mm)
 - thigh- prega da coxa
 - est_ffm- massa livre de gordura estimada (kg)
 - est_fm- massa gorda estimada (kg)
 - best_snr- teste de alcance sentada (cm)
 - best_vj- teste de salto vertical (cm)
 - leg_powe- teste de pernas (kpm/min)
 - endo- endomorfia
 - meso- mesomorfia
 - ecto- ectomorfia

Exemplo- Ergonomia de motoristas

Exemplo- Ergonomia de motoristas

- Nesta aplicação vamos analisar dados de ergonomia de motorista, apresentados na base de dados `seatpos` da biblioteca `faraway` do R.

Exemplo- Ergonomia de motoristas

- Nesta aplicação vamos analisar dados de ergonomia de motorista, apresentados na base de dados `seatpos` da biblioteca `faraway` do R.
- A variável resposta é `hipcenter`, a distância do ponto médio dos quadris a um ponto fixo no carro (em mm).

Exemplo- Ergonomia de motoristas

- Nesta aplicação vamos analisar dados de ergonomia de motorista, apresentados na base de dados `seatpos` da biblioteca `faraway` do R.
- A variável resposta é `hipcenter`, a distância do ponto médio dos quadris a um ponto fixo no carro (em mm).
- As variáveis explicativas são as seguintes:

Exemplo- Ergonomia de motoristas

- Nesta aplicação vamos analisar dados de ergonomia de motorista, apresentados na base de dados `seatpos` da biblioteca `faraway` do R.
- A variável resposta é `hipcenter`, a distância do ponto médio dos quadris a um ponto fixo no carro (em mm).
- As variáveis explicativas são as seguintes:
 - `Age`- idade (anos)

Exemplo- Ergonomia de motoristas

- Nesta aplicação vamos analisar dados de ergonomia de motorista, apresentados na base de dados `seatpos` da biblioteca `faraway` do R.
- A variável resposta é `hipcenter`, a distância do ponto médio dos quadris a um ponto fixo no carro (em mm).
- As variáveis explicativas são as seguintes:
 - `Age`- idade (anos)
 - `Weight`- peso (libras)

Exemplo- Ergonomia de motoristas

- Nesta aplicação vamos analisar dados de ergonomia de motorista, apresentados na base de dados `seatpos` da biblioteca `faraway` do R.
- A variável resposta é `hipcenter`, a distância do ponto médio dos quadris a um ponto fixo no carro (em mm).
- As variáveis explicativas são as seguintes:
 - `Age`- idade (anos)
 - `Weight`- peso (libras)
 - `HtShoes`- altura calçado (cm)

Exemplo- Ergonomia de motoristas

- Nesta aplicação vamos analisar dados de ergonomia de motorista, apresentados na base de dados `seatpos` da biblioteca `faraway` do R.
- A variável resposta é `hipcenter`, a distância do ponto médio dos quadris a um ponto fixo no carro (em mm).
- As variáveis explicativas são as seguintes:
 - `Age`- idade (anos)
 - `Weight`- peso (libras)
 - `HtShoes`- altura calçado (cm)
 - `Ht`- altura descalço (cm)

Exemplo- Ergonomia de motoristas

- Nesta aplicação vamos analisar dados de ergonomia de motorista, apresentados na base de dados `seatpos` da biblioteca `faraway` do R.
- A variável resposta é `hipcenter`, a distância do ponto médio dos quadris a um ponto fixo no carro (em mm).
- As variáveis explicativas são as seguintes:
 - `Age`- idade (anos)
 - `Weight`- peso (libras)
 - `HtShoes`- altura calçado (cm)
 - `Ht`- altura descalço (cm)
 - `Seated`- altura sentado (cm)

Exemplo- Ergonomia de motoristas

- Nesta aplicação vamos analisar dados de ergonomia de motorista, apresentados na base de dados `seatpos` da biblioteca `faraway` do R.
- A variável resposta é `hipcenter`, a distância do ponto médio dos quadris a um ponto fixo no carro (em mm).
- As variáveis explicativas são as seguintes:
 - `Age`- idade (anos)
 - `Weight`- peso (libras)
 - `HtShoes`- altura calçado (cm)
 - `Ht`- altura descalço (cm)
 - `Seated`- altura sentado (cm)
 - `Arm`- comprimento do antebraço (cm)

Exemplo- Ergonomia de motoristas

- Nesta aplicação vamos analisar dados de ergonomia de motorista, apresentados na base de dados `seatpos` da biblioteca `faraway` do R.
- A variável resposta é `hipcenter`, a distância do ponto médio dos quadris a um ponto fixo no carro (em mm).
- As variáveis explicativas são as seguintes:
 - `Age`- idade (anos)
 - `Weight`- peso (libras)
 - `HtShoes`- altura calçado (cm)
 - `Ht`- altura descalço (cm)
 - `Seated`- altura sentado (cm)
 - `Arm`- comprimento do antebraço (cm)
 - `Thigh`- comprimento da coxa (cm)

Exemplo- Ergonomia de motoristas

- Nesta aplicação vamos analisar dados de ergonomia de motorista, apresentados na base de dados `seatpos` da biblioteca `faraway` do R.
- A variável resposta é `hipcenter`, a distância do ponto médio dos quadris a um ponto fixo no carro (em mm).
- As variáveis explicativas são as seguintes:
 - `Age`- idade (anos)
 - `Weight`- peso (libras)
 - `HtShoes`- altura calçado (cm)
 - `Ht`- altura descalço (cm)
 - `Seated`- altura sentado (cm)
 - `Arm`- comprimento do antebraço (cm)
 - `Thigh`- comprimento da coxa (cm)
 - `Leg`- comprimento da panturrilha (cm)

Exercícios

- Resolva os exercícios da lista de exercícios relativa a este módulo, disponibilizada na página da disciplina.