

# ANOVA

- Para o modelo de efeitos (ANOVA):

$$y_{ij} = \mu + \tau_i + \varepsilon_{ij}, \quad i = 1, 2, \dots, a; \quad j = 1, 2, \dots, n \quad (1)$$

em que  $\mu$  é a média geral,  $\tau_i$  é a média ou efeito dos tratamentos e  $\varepsilon_{ij}$  componente de erro aleatório.

- As hipóteses de interesse são definidas por:

$$\begin{cases} H_0 : \tau_1 = \tau_2 = \dots = \tau_a = 0, & (\text{O efeito de tratamento é nulo}) \\ H_1 : \exists \tau_i \neq 0 \end{cases}$$

- Ou de forma equivalente:

$$\begin{cases} H_0 : \mu_1 = \mu_2 = \dots = \mu_a \\ H_1 : \exists \mu_i \neq \mu_j, \quad i \neq j, \end{cases}$$

em que  $\mu_i = \mu + \tau_i$ .

# ANOVA

- Só é possível realizar a análise de variância se certas condições, ou seja, certas exigências do modelo matemático forem satisfeitas:
  - Os erros devem ter distribuição normal;
  - Os erros devem ser independentes;
  - Os erros deve ter a mesma variância, ou seja, deve existir homocedasticidade.
- Pode-se representar essas condições por:

$$\varepsilon_{ij} \sim N(0, \sigma^2). \quad (2)$$

# ANOVA

$$E(QM_{Res}) = E\left(\frac{SQ_{Res}}{N - a}\right) = \frac{1}{N - a} E\left[\sum_{i=1}^a \sum_{j=1}^n (y_{ij} - \bar{y}_{i.})^2\right] = \sigma^2$$

e

$$E(QM_{Trat}) = \sigma^2 + \frac{n \sum_{i=1}^a \tau_i^2}{a - 1}$$

- Ou seja,  $QM_{Res} = SQ_{Res}/(N - a)$  estima  $\sigma^2$ ;
- E  $QM_{Trat} = SQ_{Trat}/(a - 1)$  também estima  $\sigma^2$ , caso não há diferença entre as médias dos tratamentos (o que implica em  $\tau_i = 0$ ).

# ANOVA

- Como os graus de liberdade de  $SQ_{Trat}$  e  $SQ_{Res}$  somam  $N - 1$ , que é o número de graus de liberdade da  $SQ_T$ , o Teorema de Cochran estabelece que  $SQ_{Trat}/\sigma^2$  e  $SQ_{Res}/\sigma^2$  são variáveis aleatórias independentes.
- Portanto, se a hipótese nula de nenhuma diferença nas médias de tratamento for verdadeira, a razão

$$F_0 = \frac{SQ_{Trat}/(a - 1)}{SQ_{Res}/(N - a)} = \frac{QM_{Trat}}{QM_{Res}}, \quad (3)$$

segue distribuição  $F$  com  $a - 1$  e  $N - a$  graus de liberdade.

- A equação (3) é a estatística do teste para a hipótese de não haver diferenças nas médias de tratamento.

# ANOVA

- A partir da esperança dos quadrados médios, verifica-se que, em geral,  $QM_{Res}$  é um estimador imparcial de  $\sigma^2$ ;
- Além disso, sob a hipótese nula ser verdadeira,  $QM_{Trat}$  também é um estimador imparcial de  $\sigma^2$ ;
- No entanto, se a hipótese nula for falsa, o valor esperado de  $QM_{Trat}$  é maior que  $\sigma^2$ ;
- Portanto, sob a hipótese alternativa, o valor esperado do numerador da estatística de teste (3) é maior que o valor esperado do denominador, e deve-se rejeitar  $H_0$  para valores da estatística do teste que são muito grandes;
- Portanto, deve-se rejeitar  $H_0$  e concluir que existem diferenças nas médias de tratamento se  $F_0 > F_{\alpha, (a-1), (N-a)}$ .

# ANOVA

TABLE: Tabela de Análise de Variância

| Fonte de Variação | SQ          | g.l.    | QM          | F                    |
|-------------------|-------------|---------|-------------|----------------------|
| Tratamentos       | $SQ_{Trat}$ | $a - 1$ | $QM_{Trat}$ | $QM_{Trat}/QM_{Res}$ |
| Resíduo           | $SQ_{Res}$  | $N - a$ | $QM_{Res}$  |                      |
| Total             | $SQ_T$      | $N - 1$ |             |                      |

em que  $N = an$ .

# DIAGNÓSTICO

- É fundamental verificar a adequabilidade do modelo antes de tirar conclusões sobre o processo inferencial.
- Verificar as características do modelo.
- Para avaliar a adequabilidade do modelo serão usados:
  - Métodos gráficos
  - Testes estatísticos

# ESTIMAÇÃO DOS PARÂMETROS DO MODELO

- Após verificar a qualidade de ajuste do modelo, o próximo passo é estimar os parâmetros do modelo;
- Ao considerar o modelo de efeitos:

$$y_{ij} = \mu + \tau_i + \varepsilon_{ij}, \quad i = 1, 2, \dots, a; \quad j = 1, 2, \dots, n$$

em que  $\mu$  é a média geral,  $\tau_i$  é a média ou efeito dos tratamentos e  $\varepsilon_{ij}$  componente de erro aleatório.

- Os parâmetros a serem estimados são:  $\mu$  e  $\tau_i$ ;
- O método de estimação de Mínimos Quadrados será utilizado.



# ESTIMAÇÃO DOS PARÂMETROS DO MODELO

- Para encontrar os estimadores de mínimos quadrados de  $\mu$  e  $\tau_i$ , é necessário escrever a soma dos quadrados dos erros:

$$L = \sum_{i=1}^a \sum_{j=1}^n \varepsilon_{ij}^2 = \sum_{i=1}^a \sum_{j=1}^n (y_{ij} - \mu - \tau_i)^2 \quad (4)$$

e os valores de  $\mu$  e  $\tau_i$  que minimizam a equação (4) são os estimadores de mínimos quadrados,  $\hat{\mu}$  e  $\hat{\tau}_i$ .

- Os valores apropriados seriam as soluções para as  $a + 1$  equações simultâneas:

$$\frac{\partial L}{\partial \mu} \Big|_{\hat{\mu}, \hat{\tau}_i} = 0$$

e

$$\frac{\partial L}{\partial \tau_i} \Big|_{\hat{\mu}, \hat{\tau}_i} = 0 \quad i = 1, 2, \dots, a.$$

# ESTIMAÇÃO DOS PARÂMETROS DO MODELO

- Derivando a equação (4) em relação a  $\mu$  e  $\tau_i$  e igualando a zero, tem-se que:

$$-2 \sum_{i=1}^a \sum_{j=1}^n (y_{ij} - \hat{\mu} - \hat{\tau}_i) = 0$$

e

$$-2 \sum_{j=1}^n (y_{ij} + \hat{\mu} - \hat{\tau}_i) = 0 \quad i = 1, 2, \dots, a.$$

- Ao aplicar a restrição:  $\sum_{i=1}^a \hat{\tau}_i = 0$ , tem-se a seguinte solução para o sistema de equações normais:

$$\hat{\mu} = \bar{y}_{..}$$

e

$$\hat{\tau}_i = \bar{y}_{i.} - \bar{y}_{..}$$

# ESTIMAÇÃO DOS PARÂMETROS DO MODELO

- Um intervalo de confiança para a média do  $i$ -ésimo tratamento pode ser facilmente determinada;
- A média do  $i$ -ésimo tratamento é

$$\mu_i = \mu + \tau_i$$

- Então, um estimador pontual para  $\mu_i$  é dado por:

$$\hat{\mu}_i = \hat{\mu} + \hat{\tau}_i = \bar{y}_i.$$

- Ao assumir que a distribuição dos erro é normal, a média de cada tratamento,  $\bar{y}_i$ , tem distribuição  $N(\mu_i, \sigma^2/n)$ ;
- Se  $\sigma^2$  fosse conhecido, a distribuição normal seria usada para construir o intervalo de confiança;

# ESTIMAÇÃO DOS PARÂMETROS DO MODELO

- Ao usar o  $QM_{Res}$  como estimador de  $\sigma^2$ , deve-se usar a distribuição t-Student para obter o intervalo de confiança;
- Sendo assim, o intervalo  $100(1 - \alpha)\%$  para a  $i$ -ésima média de tratamento,  $\mu_i$ , é definido por:

$$\bar{y}_i. - t_{\alpha/2, N-a} \sqrt{\frac{QM_{Res}}{n}} \leq \mu_i \leq \bar{y}_i. + t_{\alpha/2, N-a} \sqrt{\frac{QM_{Res}}{n}} \quad (5)$$

- Quando o pesquisador quer construir o intervalo de confiança para várias médias de tratamento, deve-se fazer uma correção no nível de confiança usando o método de Bonferroni;
- Nesse caso deve-se usar  $\alpha/(2r)$  na equação (5), em que  $r$  é a quantidade de intervalos de confiança simultâneos.

# COEFICIENTE DE DETERMINAÇÃO

- A medida  $R^2$  é chamada de **Coeficiente de Determinação** e representa a proporção da variação total explicada pelo modelo ANOVA e é definida por:.

$$R^2 = \frac{SQ_{Modelo}}{SQ_{Total}}$$

- Desde de que  $0 \leq SQ_{Modelo} \leq SQ_{Total}$ , segue que

$$0 \leq R^2 \leq 1$$

- Valores grandes de  $R^2$  indicam que a variação total é mais reduzida/explicada pelo efeito de tratamento.

# COMPARAÇÕES DE MÉDIAS

- Ao rejeitar a hipótese nula:  $H_0 : \tau_1 = \tau_2 = \dots = \tau_a = 0$  ou  $H_0 : \mu_1 = \mu_2 = \dots = \mu_a$
- A pergunta a ser feita é: Qual(is) efeito(s) de tratamento é(são) diferente(s) de zero?

# CONTRASTES

Dada uma função linear da forma

$$y = f(x) = a_1x_1 + a_2x_2 + \dots + a_nx_n$$

e se

$$\sum_{i=1}^n a_i = a_1 + a_2 + \dots + a_n = 0$$

Diz-se então, que  $y$  é um contraste na variável  $x$ . Se  $x$  for uma média, tem-se um contraste de médias.

# CONTRASTES

Exemplos:

$$\hat{y}_1 = \hat{\mu}_1 - \hat{\mu}_2$$

$$\hat{y}_2 = (\hat{\mu}_1 + \hat{\mu}_2) - (\hat{\mu}_3 + \hat{\mu}_4)$$

$\hat{y}_1$  e  $\hat{y}_2$  são estimativas de contrastes

Em geral, um contraste é uma combinação linear de parâmetros na forma

$$\Gamma = \sum_{i=1}^a c_i \mu_i$$

em que  $\sum_{i=1}^a c_i = c_1 + c_2 + \dots + c_a = 0$



# VARIÂNCIA DE UM CONTRASTES

A variância de um contraste é estimada por

$$Var(\hat{y}) = \frac{\sigma^2}{n} \sum_{i=1}^a c_i^2$$

em que  $n$  é o número de repetições e  $\sigma^2$  é estimada para  $QM_{Res}$ .

# CONTRASTES ORTOGONAIS

- Dois contrastes são ditos ortogonais se a variação de um contraste é independente da variação do outro, ou seja,  $Cov(\hat{y}_1, \hat{y}_2) = 0$ .
- Condição 1: Três ou mais contrastes são ortogonais entre si se eles forem ortogonais dois a dois.
- Condição 2: em um experimento, existem  $a - 1$  contrastes possíveis entre os  $a$  tratamentos

# CONTRASTES ORTOGONAIS

- Dois contrastes são ortogonais entre si quando a soma algébrica dos produtos dos coeficientes das médias correspondentes é nula.

$$C_1 = c_1\mu_1 + c_2\mu_2 + \dots + c_a\mu_a \quad \sum_{i=1}^a c_i = 0$$

$$C_2 = d_1\mu_1 + d_2\mu_2 + \dots + d_a\mu_a \quad \sum_{i=1}^a d_i = 0$$

- $C_1$  e  $C_2$  são ortogonais entre si se:

$$\sum_{i=1}^a c_i d_i = 0$$

# CONTRASTES ORTOGONAIS

Sejam  $\mu_1$ ,  $\mu_2$  e  $\mu_3$  médias de três tratamentos. Verifique que os contrastes

$$C_1 = \mu_1 - \mu_2$$

$$C_2 = \mu_1 + \mu_2 - 2\mu_3$$

são ortogonais entre si.

- Três ou mais contrastes são ortogonais entre si ou mutuamente ortogonais se eles forem ortogonais dois a dois.

# COMPARAÇÕES DE MÉDIAS

Alguns teste podem ser utilizados para tal objetivo. São eles:

- Teste de Fisher;
- Teste de Tukey;
- Teste de Duncan;
- Teste de Scheffé.

# TESTE DE TUKEY

- Suponha que, após rejeitar a hipótese nula de igualdade de tratamento na ANOVA, deseja-se testar todas as comparações de médias:

$$H_0 : \mu_i = \mu_j$$

$$H_1 : \mu_i \neq \mu_j$$

para todo  $i \neq j$ .

- O procedimento de Tukey controla o erro experimental no nível selecionado. Este é um excelente procedimento de espionagem de dados quando o interesse está em pares de médias (não permite comparar grupos entre si);

# TESTE DE TUKEY

- O teste de Tukey considera a seguinte estatística de intervalo estudentizado:

$$q = \frac{\bar{y}_{max} - \bar{y}_{min}}{\sqrt{QM_{Res}/n}},$$

em que  $\bar{y}_{max}$  e  $\bar{y}_{min}$  são a maior e menor média, respectivamente, para o grupo de  $p$  amostras de médias.

- O valor de  $q$  deve ser comparado com valores de  $q(p, f)$ , em que:
- $q()$  é o percentil da estatística de intervalo estudentizado (valor tabelado);
- e  $f$  é o número de graus de liberdade associados ao  $QM_{Res}$ ;

# TESTE DE TUKEY

- Para amostras de mesmo tamanho, o teste de Tukey declara duas médias significativamente diferentes se o valor absoluto de suas diferenças amostrais excedem:

$$\Delta_{\alpha} = q_{\alpha}(a, f) \sqrt{\frac{QM_{Res}}{n}}. \quad (6)$$

$\Delta$  Diferença Mínima Significativa (DMS)

- De forma equivalente, pode-se construir um conjunto de  $100(1 - \alpha)\%$  intervalos de confiança para todos os pares de médias, ou seja:

$$\bar{y}_{i.} - \bar{y}_{j.} - q_{\alpha}(a, f) \sqrt{\frac{QM_{Res}}{n}} \leq \mu_i - \mu_j \leq \bar{y}_{i.} - \bar{y}_{j.} + q_{\alpha}(a, f) \sqrt{\frac{QM_{Res}}{n}}$$



# EXEMPLO - TESTE DE TUKEY

Uma engenheira está interessada em investigar a relação entre a configuração de potência de rádio frequência (RF) e a taxa de gravação para esta ferramenta. O objetivo de um experimento como este é modelar a relação entre a taxa de gravação e a potência de RF e especificar a configuração de potência que dará uma taxa de gravação desejada.

## EXEMPLO - TESTE DE TUKEY

Ela está interessada em um determinado gás ( $C_2F_6$ ) e uma abertura de 0,80cm para testar quatro níveis de potência de RF: 160, 180, 200 e 220 W. Ela decidiu testar cinco placas em cada nível de potência de RF.

Suponha que a engenheira execute o experimento de forma aleatória.

## EXEMPLO - TESTE DE TUKEY

As observações que ela obteve sobre a taxa de gravação são mostradas na Tabela 1.

**TABELA 1** : Dados de taxa de gravação (em A/min) do experimento de gravação com plasma

| Potência | Observações |     |     |     |     | Total |
|----------|-------------|-----|-----|-----|-----|-------|
|          | 1           | 2   | 3   | 4   | 5   |       |
| 160      | 575         | 542 | 530 | 539 | 570 | 2756  |
| 180      | 565         | 593 | 590 | 579 | 610 | 2937  |
| 200      | 600         | 651 | 610 | 637 | 629 | 3127  |
| 220      | 725         | 700 | 715 | 685 | 710 | 3535  |

## EXEMPLO - TESTE DE TUKEY

- Considere o experimento da gravação de plasma. Como a hipótese nula foi rejeitada, sabemos que algumas configurações de energia produzem taxas de gravação diferentes das outras, mas quais realmente causam essa diferença?
- Podemos suspeitar no início do experimento que 200W e 220W produzem a mesma taxa de gravação, o que implica que gostaríamos de testar a hipótese:

$$H_0 : \mu_3 = \mu_4$$

$$H_1 : \mu_3 \neq \mu_4$$

ou equivalentemente:

$$H_0 : \mu_3 - \mu_4 = 0$$

$$H_1 : \mu_3 - \mu_4 \neq 0$$

# EXEMPLO - TESTE DE TUKEY

No exemplo temos:

```
>summary(anovap)
```

|           | Df | Sum Sq | Mean Sq | F value | Pr(>F)       |
|-----------|----|--------|---------|---------|--------------|
| potencia  | 3  | 66871  | 22290   | 66.8    | 2.88e-09 *** |
| Residuals | 16 | 5339   | 334     |         |              |

```
>mediatrat
```

```
160 180 200 220
```

```
551.2 587.4 625.4 707.0
```

$$\Delta(5\%) = 4,05\sqrt{\frac{334}{5}} = 33,10$$

Se o contraste for maior do que  $\Delta$  então as médias diferem ao nível  $\alpha$  de significância.

# EXEMPLO - TESTE DE TUKEY

- Como o teste de Tukey é de certa forma independente do teste F, é possível que, mesmo sendo significativo o valor de  $F_{calculado}$ , não se encontre diferenças significativas entre contrastes de médias.
- Utilizaremos o método das letras para exemplificar o uso do teste.
- Inicialmente ordena-se as médias de forma crescente ou decrescente para facilitar as comparações. Coloca-se uma letra do alfabeto na primeira média e em seguida compara-se a diferença, com as médias seguintes. Se a diferença, for superior ao valor de  $\Delta$  a diferença entre duas médias será considerada significativa. Médias sem a mesma letra diferem

## EXEMPLO - TESTE DE TUKEY

|     |       |   |
|-----|-------|---|
| 160 | 551,2 | a |
| 180 | 587,4 | b |
| 200 | 625,4 | c |
| 220 | 707,0 | d |