UNIVERSIDADE FEDERAL DO PARANÁ

Eduardo Demetrio da Silva

ANÁLISE COMPARATIVA DE MÉTODOS DE AGRUPAMENTO: SUPPORT VECTOR CLUSTERING (SVC) E K-MEANS

1. Introdução

Neste trabalho foi feita uma comparação entre dois métodos de agrupamento: o K-means e o Support Vector Clustering (SVC). A ideia foi aplicar os dois métodos em uma mesma base de dados e observar como cada um deles se comporta na formação dos grupos.

O K-means é um dos métodos de agrupamento mais conhecidos e funciona a partir da ideia de centroides. Ou seja, ele tenta separar os dados em grupos de forma que os elementos dentro de cada grupo fiquem mais próximos entre si. Apesar de ser simples e bastante utilizado, o K-means depende da definição prévia do número de clusters e pode ter dificuldade quando os grupos não são bem separados.

Já o SVC é um método baseado na ideia de Support Vector Machine, mas aplicado ao problema de clusterização. Ele utiliza funções kernel para projetar os dados em um espaço de maior dimensão e, a partir disso, tentar encontrar regiões que representem os agrupamentos. Em teoria, esse método pode ser mais flexível que o K-means, principalmente quando os grupos possuem formatos mais complexos. Porém, ele também depende bastante da escolha dos parâmetros.

2. Metodologia

A base escolhida foi a base Iris, que possui 150 observações de flores divididas em três espécies: Setosa, Versicolor e Virginica. A base possui quatro variáveis numéricas relacionadas ao comprimento e largura das sépalas e pétalas.

Antes de aplicar os métodos, os dados foram padronizados usando a transformação Z-score. Essa etapa foi importante porque tanto o K-means quanto o SVC utilizam medidas relacionadas à distância ou similaridade entre os pontos. Se os dados não fossem padronizados, alguma variável com escala maior poderia influenciar mais o resultado.

O primeiro método aplicado foi o K-means, utilizando três clusters, pois a base Iris possui três espécies conhecidas. É importante destacar que as espécies reais não foram usadas para treinar o algoritmo, apenas para comparar os resultados depois.

Depois foi aplicado o Support Vector Clustering utilizando o pacote SVclust. Foi utilizado o kernel gaussiano e foram testados diferentes valores para o parâmetro gamma. Esse teste foi feito porque, durante a aplicação inicial, o SVC agrupou todas as observações em apenas um cluster, mostrando que o método é sensível à escolha dos parâmetros.

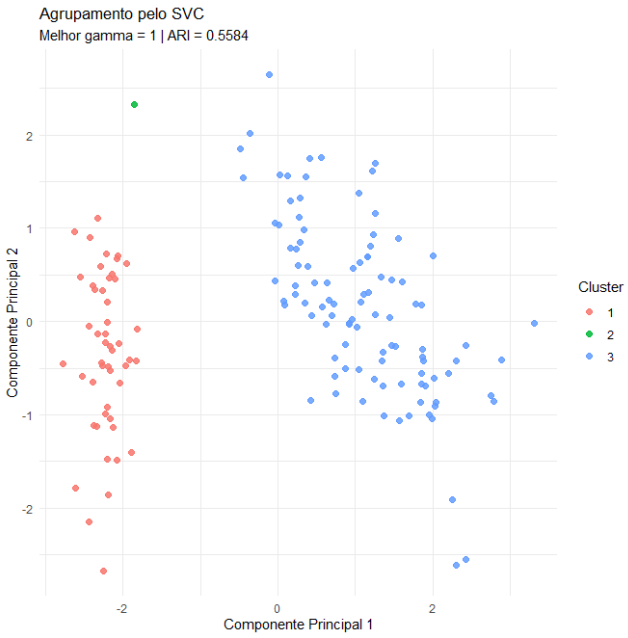
A avaliação dos resultados foi feita por meio de tabelas comparando os clusters obtidos com as espécies reais. Também foi utilizado o Adjusted Rand Index (ARI), que mede o

quanto a partição encontrada pelo algoritmo se aproxima da classificação real da base. Além disso, foram gerados gráficos para visualizar os agrupamentos.

3. Resultados e discussão

Na aplicação do K-means, o método apresentou um resultado relativamente bom para a base Iris. A espécie Setosa foi separada com bastante clareza, o que já era esperado, pois ela possui características bem diferentes das outras espécies. A maior dificuldade apareceu na separação entre Versicolor e Virginica, que são espécies mais parecidas e possuem uma região de sobreposição.

No caso do Support Vector Clustering, foram testados diferentes valores para o parâmetro gamma, pois o método mostrou bastante sensibilidade a esse ajuste. O melhor resultado encontrado foi com gamma igual a 1, obtendo um Adjusted Rand Index (ARI) de 0,5584. Esse valor indica que o agrupamento encontrado tem uma relação moderada com as espécies reais da base, mas ainda não representa uma separação perfeita.



Observa-se que o método conseguiu formar um grupo mais separado à esquerda, que provavelmente está relacionado à espécie Setosa. Porém, na parte direita do gráfico, grande parte das observações ficou concentrada em um mesmo cluster, indicando dificuldade em separar melhor Versicolor e Virginica. Além disso, o algoritmo criou um pequeno cluster com apenas uma observação, o que pode indicar sensibilidade do método a pontos mais isolados.

Esse resultado mostra uma diferença importante entre o SVC e o K-means. O K-means é mais simples e exige a definição prévia do número de clusters, mas apresentou uma solução mais direta e fácil de interpretar. Já o SVC não exige diretamente a definição do número de grupos, porém depende bastante da escolha dos parâmetros,

principalmente do gamma. Uma pequena mudança nesse parâmetro pode alterar bastante a quantidade de clusters encontrados e a forma da separação.

Portanto, o SVC apresentou um resultado interessante, mas não necessariamente melhor que o K-means para essa base. O principal ponto observado foi que o método tem potencial para encontrar agrupamentos com formas diferentes, mas precisa de mais cuidado na calibração dos parâmetros. Para a base Iris, o resultado com gamma igual a 1 foi o melhor entre os testes realizados, mas ainda manteve confusão entre as espécies mais próximas.

4. Recomendações para o pacote SVclust

Durante o desenvolvimento do script e a utilização prática do pacote SVclust, deu para notar alguns pontos de usabilidade e funcionalidade que poderiam ser melhorados em futuras atualizações da ferramenta. O primeiro ponto é em relação à documentação oficial dos parâmetros. Dado que o comportamento do SVC varia drasticamente de acordo com o valor escolhido para o gamma, seria de grande ajuda se o help do pacote trouxesse exemplos práticos e visuais mostrando o impacto direto que essa mudança causa na formação dos agrupamentos.

Outra melhoria que ajudaria bastante seria o desenvolvimento de alguma função nativa de busca (como um grid search integrado) para testar de forma automática vários valores do parâmetro. Isso facilitaria muito a vida do usuário para identificar qual faixa de valores gera uma quantidade de clusters que faça sentido para o problema. O pacote poderia, por exemplo, retornar um sumário simples em formato de tabela contendo o valor testado do gamma, o número de clusters gerados e alguma métrica de validação interna, como a silhueta média.

Também vale pontuar a necessidade de melhorar as mensagens de erro geradas no console. Em alguns momentos do código, ao errar a sintaxe ou passar um argumento não reconhecido, a mensagem de retorno do pacote é muito genérica e não ajuda o usuário a entender exatamente onde está o erro para corrigi-lo rápido. Para quem está iniciando na programação estatística, mensagens mais descritivas poupam muito tempo.

Por fim, como uma sugestão de padronização, seria interessante se o pacote aceitasse a string "rbf" como um sinônimo ou alternativa para chamar o kernel gaussiano. Esse termo (Radial Basis Function) é o padrão de mercado adotado em quase todas as grandes bibliotecas de machine learning, como o scikit-learn do Python ou o pacote caret do R, e incluí-lo evitaria pequenas confusões de sintaxe.

5. Conclusão

Neste trabalho foi feita uma comparação entre o K-means e o Support Vector Clustering usando a base Iris. O K-means apresentou um resultado mais simples de interpretar, separando bem a espécie Setosa, mas ainda confundindo parte das espécies Versicolor e Virginica.

O SVC apresentou seu melhor resultado com gamma igual a 1, atingindo ARI de 0,5584. Esse resultado mostra que o método conseguiu capturar parte da estrutura dos dados, mas ainda teve dificuldade em separar completamente os grupos. Além disso, foi

possível perceber que o SVC é bastante sensível aos parâmetros, já que diferentes valores de gamma geraram resultados diferentes.

Assim, para essa base, o K-means acabou sendo mais direto e estável, enquanto o SVC mostrou ser um método mais flexível, mas que exige maior cuidado na escolha dos parâmetros. Como recomendação, seria interessante que o pacote SVclust tivesse uma documentação mais detalhada sobre o efeito do gamma e alguma função auxiliar para testar automaticamente diferentes configurações.