UNIVERSIDADE FEDERAL DO PARANÁ

EDUARDO DEMETRIO DA SILVA

REDUÇÃO DE DIMENSIONALIDADE

Análise Comparativa de Métodos de Redução de Dimensionalidade.

CURITIBA

2026

1. Introdução

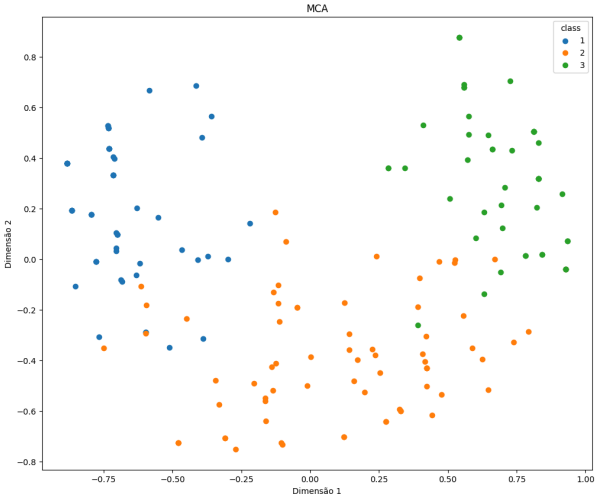
A redução de dimensionalidade é um dos temas importantes dentro de aprendizado não supervisionado, pois é a técnica que permite representar um dataset com muitas variáveis em um espaço com menor dimensão. O objetivo é preservar uma parte significativa de todas as variáveis, mas sempre contendo uma perda de informação no processo.
Conforme apresentado na disciplina a redução de dimensionalidade é melhor utilizada para visualização, análise exploratória e de redução de informações redundantes, mantendo os padrões mais relevantes dos dados.
No hands-on foram aplicados diferentes métodos de redução de dimensionalidade na base de dados fornecida **Wine.** A variável **class** foi utilizada como referência para avaliar graficamente a qualidade das projeções geradas pelos métodos.
O objetivo deste trabalho é avaliar como os métodos **MCA com binarização pela média, PCA, MDS com diferentes distâncias, SNE, t-SNE e Kernel PCA** se comportam em relação à separação das classes presentes no dataset. A partir dos gráficos gerados, buscou-se identificar quais técnicas apresentaram melhor separação dos grupos e quais apresentaram maior sobreposição entre as classes.

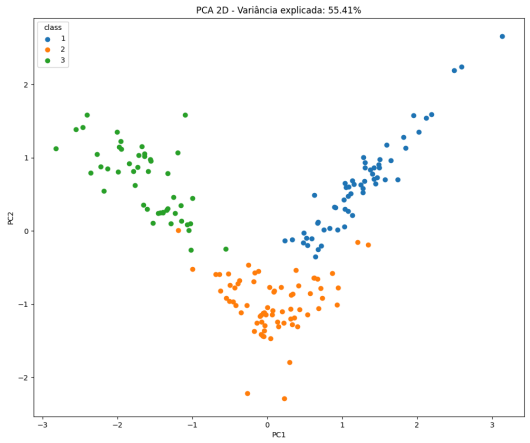
2. Metodologia

Com base na variáveis disponíveis, foi identificado a diferença de escalas, assim foi aplicado a padronização dos dados utilizando StandardScaler, essa etapa é importante, principalmente em métodos baseados em distância ou variâncias como PCA, MDS, SNE, t-SNE e Kernel PCA, evitando que variáveis com maior escala tenham maior influência.
O primeiro método desenvolvido foi o **MCA**, que obrigatoriamente necessita de dados categóricos, como a base **Wine** é composta apenas por dados contínuos, foi indicado a ser feito a binarização pela média, dessa forma cada variável foi transformada em binária, indicando se a observação é maior ou menor que a média. Com os dados já transformados foi possível a utilização do método.
Em seguida, foi aplicado o **PCA**, buscando reter a maior variância possível dos dados a partir da criação de novos eixos, chamados componentes principais.
Também foi aplicado o **MDS,** que busca representar os dados em baixa dimensão preservando principalmente as distâncias entre as observações, foi utilizado no método duas distâncias métricas, distância euclidiana e distância de Manhattan. Essa comparação é relevante, pois o resultado do MDS depende diretamente da forma como a dissimilaridade entre os objetos é medida.
Além disso, foram utilizados os métodos **SNE** e **t-SNE,** ambos não lineares e com objetivo de preservação das vizinhanças das observações. A principal diferença entre eles está na distribuição aplicada para modelar as probabilidades de vizinhança em espaço reduzido, sendo que SNE utiliza distribuição gaussiana e y-SNE a distribuição t de Student.
Por fim, foi aplicado o **Kernel PCA,** uma extensão não linear do PCA clássico, o método projeta os dados em um espaço de maior dimensão por meio de uma função kernel, permitindo capturar estrutura não linear, que por sua vez o **PCA** tradicional não pode representar. Foi utilizado o kernel RBF e polinomial.

3. Resultados e Discussões

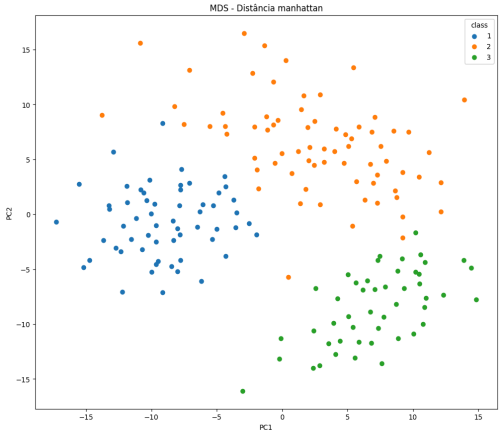
O método MCA com binarização pela média obteve uma separação parcial entre as classes, obtivemos uma organização dos grupos, porém com bastante sobreposição dos dados, principalmente envolvendo a classe 2, explicado especialmente pela limitação dos dados oferecidos ao método.

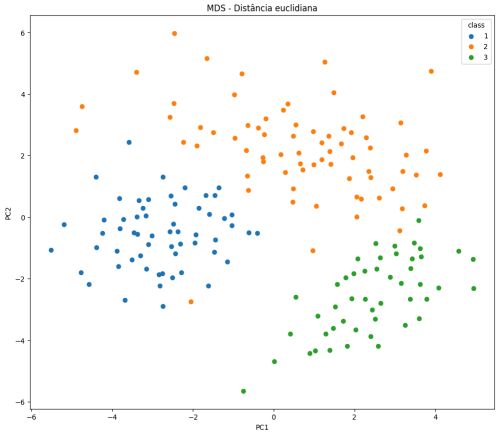




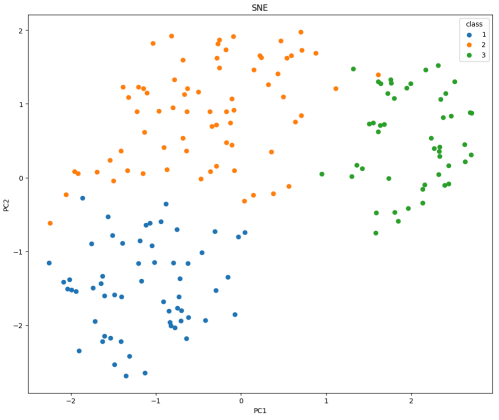
No caso do **PCA** foi possível uma visualização mais clara entre as classes. As classes 1 e 3 estão em regiões opostas, enquanto a 2 está em uma região intermediária. Os dois primeiros componentes explicaram aproximadamente **55,41% da variância total**, o que indica que uma parte relevante da estrutura dos dados foi preservada em duas dimensões. Apesar disso, ainda há pontos de sobreposição, principalmente nas regiões de fronteira entre as classes. Como o PCA é um método linear ele consegue representar bem padrões baseados em combinações lineares das variáveis, mas pode ter limitações quando a separação entre os grupos envolve relações não lineares.

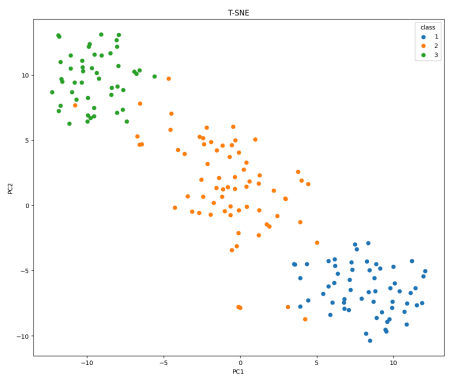
O **MDS com distância euclidiana** apresentou boa separação entre as classes, indicando que as distâncias entre as observações ajudam a representar os grupos de vinhos. Porém, ainda houve certa aproximação entre pontos de classes diferentes. Já o **MDS com distância Manhattan** mostrou uma separação visual mais clara, com os grupos mais afastados. Isso indica que a escolha da métrica influencia diretamente o resultado da redução, sendo a distância Manhattan mais eficiente para esta base.





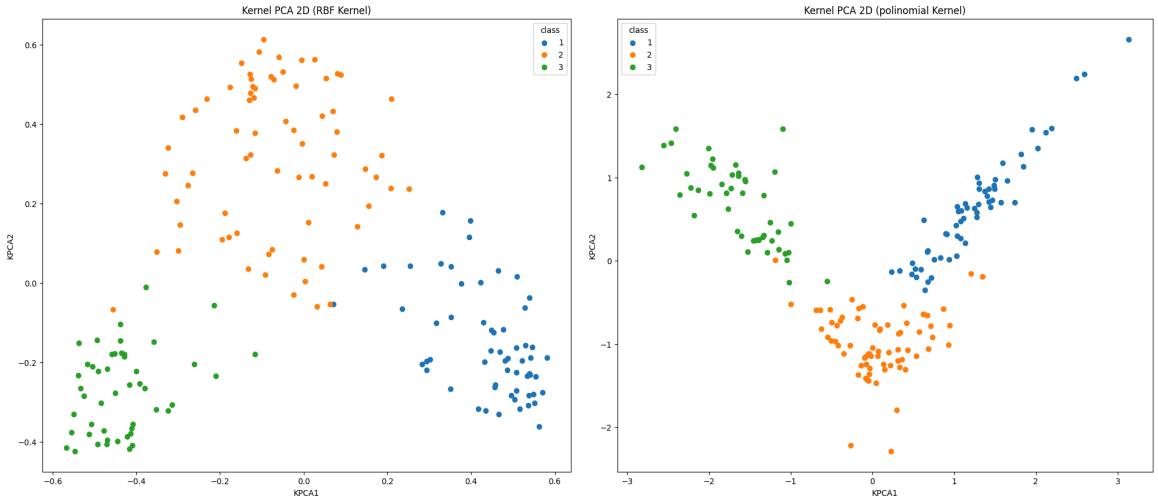
O **SNE** apresentou uma boa organização das classes ao preservar relações de vizinhança entre as observações. Pontos da mesma classe ficam relativamente próximos, indicando que o método capturou parte da estrutura local dos dados. Porém, ainda houve alguma sobreposição, principalmente quando comparado ao t-SNE.





O **t-SNE** apresentou uma separação mais nítida entre as classes. Os grupos ficaram mais definidos no plano, com menor sobreposição entre as observações. Esse resultado indica que o método conseguiu preservar melhor as vizinhanças locais, sendo um dos mais adequados para visualizar os agrupamentos da base Wine.

No **Kernel PCA com kernel RBF**, também foi observada uma separação bastante satisfatória entre as classes. O kernel RBF permitiu capturar relações não lineares entre os atributos químicos, resultando em uma projeção mais clara que a do PCA tradicional. Já o **Kernel PCA com kernel polinomial** apresentou comportamento mais parecido com o PCA linear, com boa separação geral, mas menos evidente que a obtida pelo kernel RBF. Isso reforça que a escolha do kernel tem impacto direto na qualidade da redução.



4. Conclusão

Entre os métodos avaliados, o **t-SNE** apresentou a melhor separação visual entre as classes, formando agrupamentos bem definidos e com pouca sobreposição. O **Kernel PCA com kernel RBF** também teve desempenho muito satisfatório, indicando que existem relações não lineares nos dados que podem ser melhor capturadas por métodos baseados em kernel. O **MDS com distância Manhattan** apresentou resultado superior ao MDS euclidiano, mostrando que a escolha da métrica de distância interfere diretamente na qualidade da projeção.

O **PCA** apresentou bom resultado, principalmente por ser um método mais simples e linear, mas teve maior sobreposição entre algumas classes. A **MCA**, por sua vez, foi o método com menor separação visual, provavelmente devido à perda de informação causada pela binarização das variáveis contínuas pela média.

Portanto, considerando a qualidade gráfica das reduções, os métodos mais adequados para visualizar a separação das classes nesta base foram **t-SNE**, **Kernel PCA com RBF** e **MDS com distância Manhattan**. Esses métodos conseguiram representar melhor a estrutura dos dados em duas dimensões e facilitaram a interpretação exploratória dos grupos de vinhos.

5. Referência

ARA, Anderson. **Aprendizado não supervisionado: slides da disciplina**. Curitiba: Universidade Federal do Paraná, 2026.

DEMETRIO, Eduardo. Projeto prático de redução de dimensionalidade em Python, 2026