UNIVERSIDADE FEDERAL DO PARANÁ

EDUARDO DEMETRIO DA SILVA

Análise de comparação de técnicas de clusterização

Conjunto de dados seeds

CURITIBA

2026

1. Introdução

A análise de agrupamento, ou clusterização, é uma técnica de aprendizado não supervisionado bastante utilizada para encontrar padrões ou estruturas em conjuntos de dados que não possuem uma variável resposta. Diferente dos métodos supervisionados, onde já existe uma classe definida para treinar o modelo, a clusterização funciona agrupando as observações com base na semelhança entre elas.

O objetivo deste trabalho é comparar o desempenho de quatro algoritmos de agrupamento: **K-médias**, **agrupamento hierárquico (com ligação de Ward)**, **DBSCAN** e **Mistura de Gaussianas**. Para o teste, foi utilizado o conjunto de dados *Seeds*, avaliando a capacidade de cada método em identificar corretamente as variedades de sementes da base de dados.

A avaliação dos resultados foi dividida em duas partes:

- **Validação interna:** foca na qualidade dos grupos olhando apenas para a estrutura dos dados, utilizando as métricas *Silhouette*, *Calinski-Harabasz* e *Davies-Bouldin*.
- **Validação externa:** compara os grupos formados pelos algoritmos com as classes reais das sementes, usando os índices *Rand Index* e *Adjusted Rand Index* (ARI).

Além disso, foi aplicada a Análise de Componentes Principais (PCA) para reduzir a dimensionalidade dos dados, permitindo plotar e visualizar os agrupamentos em duas dimensões, o que facilita a interpretação dos resultados.

2. Base de Dados e Pré-Processamento

Para este trabalho, foi utilizado o Seeds Dataset, que traz dados morfológicos de 210 grãos de trigo. A base é bem balanceada, dividida igualmente com 70 observações para cada uma das três variedades: Kama, Rosa e Canadian.
O dataset conta com **sete variáveis** numéricas que descrevem as características geométricas das sementes: **área, perímetro, compacidade, comprimento, largura, coeficiente de assimetria e comprimento do sulco do grão.** A base também possui uma coluna com a classe real de cada semente, mas ela foi guardada para ser usada só na validação externa, sem interferir no treino dos modelos de clusterização.
Como as variáveis originais estão em escalas bem diferentes, foi preciso aplicar uma padronização por z-score antes de rodar os algoritmos. Essa etapa é indispensável porque algoritmos baseados em distância (como K-médias, hierárquico e DBSCAN) sofrem muita influência de atributos com valores mais altos. Com a padronização, todas as variáveis ficaram na mesma escala, com média zero e desvio padrão igual a um.

Para fechar o pré-processamento e ajudar na visualização, foi feita uma Análise de Componentes Principais (PCA). Os dois primeiros componentes conseguiram resumir cerca de 88,98% da variância total dos dados (71,87% no PC1 e 17,11% no PC2). Ao plotar o gráfico com as classes reais, deu para notar que as variedades Rosa e Canadian ficam bem separadas, enquanto a classe Kama é mais confusa e acaba se sobrepondo com as outras no centro do gráfico.

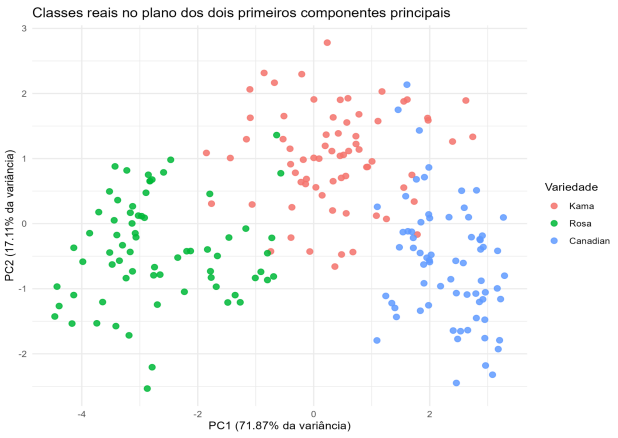


Figura - 1 Classes reais no plano PCA

3. Técnicas de Clusterização Utilizadas

3.1 K-médias

O K-médias é um algoritmo particional clássico que divide o conjunto de dados em uma quantidade de grupos que a gente precisa definir antes de rodar o código. No caso deste projeto, fixamos **K = 3**, já que sabemos que a base possui três tipos de sementes. A lógica do algoritmo é basicamente minimizar a distância de cada ponto até o centroide do seu respectivo grupo.

De forma geral, os resultados do K-médias foram bem satisfatórios. Conseguimos um índice **Silhouette de 0,4007, ARI de 0,7733 e Rand Index de 0,8997**, métricas que mostram que o algoritmo conseguiu recuperar bem a estrutura real dos dados. Olhando o gráfico gerado com os dois primeiros componentes principais (PCA), dá para ver que ele separou muito bem as variedades Rosa e Canadian. No entanto, o modelo sofreu um pouco na zona de transição onde fica a variedade Kama.

Essa dificuldade já era prevista. O K-médias assume que os grupos são aproximadamente esféricos e têm tamanhos parecidos. Como a base Seeds tem uma sobreposição natural entre algumas variedades na região central, o algoritmo acabou confundindo e trocando algumas sementes de grupo nessa fronteira.

3.2 Agrupamento Hierárquico com ligação de Ward

O agrupamento hierárquico foi testado utilizando o método de ligação de Ward, que tem como lógica unir os grupos tentando minimizar o aumento da variância de cada *cluster*. A grande diferença desse método para o K-médias é que ele cria uma estrutura em árvore, o dendrograma, mostrando o passo a passo de como os dados vão se agrupando.

Para conseguir comparar os resultados com as três variedades reais de trigo, cortamos o dendrograma na altura que gerasse exatamente três grupos. Com essa configuração, o método de Ward entregou um índice ***Silhouette* de 0,3926, ARI de 0,7970 e *Rand Index* de 0,9102**. O interessante aqui é que, mesmo com uma *Silhouette* um pouquinho menor que a do K-médias, o ARI foi mais alto, o que significa que este modelo bateu mais com a separação real das sementes

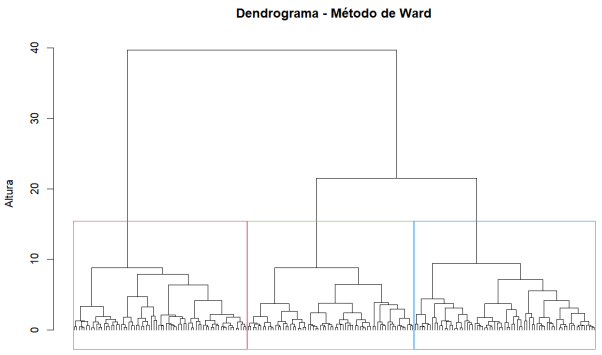
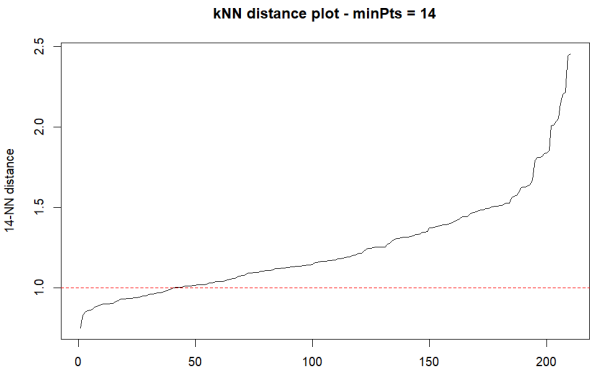


Figura - 2 - Dendrograma do método Ward

Olhando o gráfico do PCA, deu para ver que o método de Ward conseguiu organizar bem os três blocos principais de dados. Mesmo assim, ele repetiu o comportamento do K-médias e acabou confundindo alguns pontos nas áreas onde as características das sementes são muito parecidas. No balanço geral, olhando para a validação externa, o método de Ward acabou se saindo um pouco mais consistente que o K-médias.

3.3 DBSCAN

O DBSCAN funciona de um jeito diferente: ele é um método baseado em densidade. A grande vantagem teórica dele sobre o K-médias e o hierárquico é que ele não pede para definir o número de grupos logo de cara. O algoritmo basicamente vai procurando regiões onde os dados estão mais concentrados para formar os *clusters*, e o que fica muito isolado ele joga para escanteio, classificando como ruído.



Para rodar o modelo, definimos os parâmetros com **eps = 1** e **minPts = 14**. Para chegar nesses valores, usamos como apoio o gráfico, tentando achar aquele ponto de inflexão na curva para o ***eps***. O problema é que, com essa configuração, o DBSCAN só encontrou 2 grupos e acabou deixando 72 observações de fora, marcadas como ruído.

Por conta disso, os resultados na validação externa ficaram bem abaixo dos outros modelos, com um **ARI de 0,2584 e *Rand Index* de 0,6579. A *Silhouette* geral ficou em 0,1685**, mas se a gente calcular a *Silhouette* tirando os ruídos da conta, ela sobe para 0,5412. Isso prova que os pontos que ele realmente conseguiu agrupar ficaram bem separados entre si; o que quebrou o desempenho do modelo foi a quantidade enorme de dados que ele simplesmente descartou como ruído, não conseguindo capturar as três variedades reais.

No gráfico do PCA, deu para ver que o DBSCAN não casou bem com a estrutura real da base. Isso acontece porque o ***Seeds Dataset*** tem grupos que ficam muito perto uns dos outros, com bastante sobreposição. Como o DBSCAN é muito sensível à densidade, qualquer mudançazinha no **eps** ou no **minPts** muda o resultado todo, tornando bem difícil achar um equilíbrio para bases com esse perfil.

3.4 Mistura de Gaussianas

O modelo de Mistura de Gaussianas (GMM) segue uma linha probabilística para fazer a clusterização. A grande sacada dele em relação ao K-médias é que, em vez de cravar que um ponto pertence a apenas um único grupo de forma rígida (*hard clustering*), o GMM assume que os dados vêm de uma combinação de várias distribuições gaussianas. Com isso, cada observação ganha uma probabilidade de pertencer a cada um dos grupos.

No projeto, o GMM foi ajustado para encontrar três componentes, batendo com a quantidade real de variedades de sementes. No fim das contas, esse método entregou o melhor desempenho geral entre todos os modelos testados, alcançando um **ARI de 0,8905 e um *Rand Index* de 0,9516. A *Silhouette* ficou em 0,3794** que é um valor ligeiramente menor que o do K-médias, mas o resultado da validação externa foi bem superior.

Esse desempenho mostra que o GMM foi o que melhor conseguiu recuperar a separação real das classes. A principal explicação para isso é que os modelos de misturas gaussianas são bem mais flexíveis que o K-médias, já que aceitam *clusters* em formatos elipsoidais e

com diferentes estruturas de variância. Como as variedades de trigo na base *Seeds* não formam grupos perfeitamente redondos e têm regiões com certa sobreposição, essa flexibilidade jogou a favor do GMM.

4. Comparação dos Resultados

A tabela resume as métricas de validação interna e externa que coletamos para cada um dos quatro métodos de clusterização testados.

Metodo	Clusters	Ruidos	Silhouette	Silhouette_sem_ruido	Calinski_Harabasz	Davies_Bouldin	ARI	Rand
K-médias	3	0	0.4007	0.4007	249.7842	0.9279	0.7733	0.8997
Hierárquico Ward	3	0	0.3926	0.3926	238.3612	0.9445	0.7970	0.9102
DBSCAN	2	72	0.1685	0.5412	196.6494	0.5725	0.2584	0.6579
GMM	3	0	0.3794	0.3794	231.8643	0.9487	0.8905	0.9516

Analisando os resultados, dá para ver que o K-médias liderou na Silhouette geral, o que indica que ele conseguiu uma boa separação interna nos grupos que criou. Só que, quando a gente olha para o que realmente importa que é a comparação com as classes reais, o GMM foi o grande destaque, entregando os maiores valores tanto de ARI quanto de Rand Index.

O agrupamento hierárquico pelo método de Ward também mandou muito bem, ficando um passo à frente do K-médias na validação externa. Isso mostra que a lógica de tentar minimizar a variância de cada grupo casou direitinho com o comportamento da base Seeds.

Na contramão dos outros modelos, o DBSCAN acabou sendo a pior escolha para esse cenário. Mesmo que a Silhouette dele fique alta quando a gente limpa os ruídos, o algoritmo acabou isolando observações demais e falhou na missão de recuperar as três variedades originais. No fim das contas, para o perfil desse conjunto de dados, os algoritmos baseados em centroides, variância e distribuição de probabilidade funcionaram bem melhor do que a estratégia focada em densidade local.

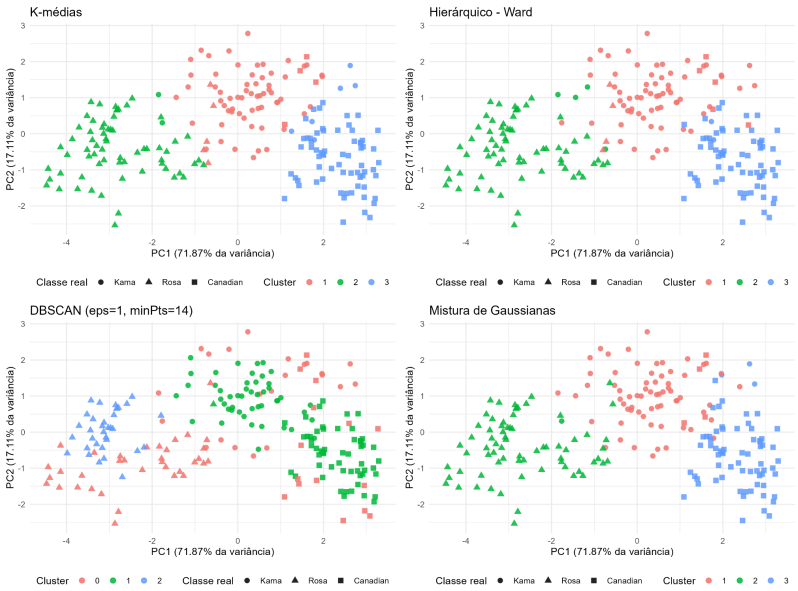


Figura - 4 - Comparação dos quatros métodos no PCA

5. Conclusão

Este trabalho trouxe uma análise comparativa de quatro técnicas de clusterização K-médias, agrupamento hierárquico (Ward), DBSCAN e Mistura de Gaussianas aplicadas ao *Seeds Dataset*. Para avaliar os modelos, usamos tanto métricas de validação interna e externa quanto a visualização dos grupos gerados no plano do PCA.

No geral, os resultados indicam que a base de dados tem sim uma estrutura dividida em três grupos principais, mas que conta com uma sobreposição natural entre as variedades, principalmente com a classe Kama. Essa confusão na região central explica o motivo de nenhum dos algoritmos ter conseguido uma separação 100% perfeita em relação às classes reais de trigo.

Dentre os métodos testados, a Mistura de Gaussianas (GMM) foi a que entregou o melhor desempenho, com resultados como **ARI de 0,8905 e *Rand Index* de 0,9516**. Isso mostra que o GMM foi o algoritmo que chegou mais perto de reconstruir a divisão real das sementes, muito por conta da sua flexibilidade para trabalhar com grupos elipsoidais e com diferentes variâncias.

O método hierárquico de Ward também teve um comportamento bem sólido, superando o K-médias no cruzamento com os rótulos reais. O K-médias, apesar de dar uma boa resposta na separação interna, acabou sofrendo mais nas fronteiras onde as sementes se misturam. Já o DBSCAN se mostrou inviável para esse problema específico, já que só enxergou dois grupos e isolou uma parte enorme dos dados como ruído.

No fim das contas, deu para concluir que para o perfil do conjunto *Seeds*, as abordagens do GMM, Ward e K-médias são as mais recomendadas, com um destaque claro para a Mistura de Gaussianas. A análise visual via PCA ajudou a carimbar esses resultados, provando que os modelos configurados para três grupos conseguiram capturar e traduzir muito melhor a real estrutura das variedades de sementes.

6. Referências

CHARYTANOWICZ, M.; NIEWCZAS, J.; KULCZYCKI, P.; KOWALSKI, P.; ŁUKASIK, S.; ŻAK, S. **Seeds**. Irvine: UCI Machine Learning Repository, 2010. DOI: 10.24432/C5H30K.

ESTER, M.; KRIEGEL, H.-P.; SANDER, J.; XU, X. **A density-based algorithm for discovering clusters in large spatial databases with noise**. In: *Proceedings of the Second International Conference on Knowledge Discovery and Data Mining*. Portland: AAAI Press, 1996. p. 226-231.

FRALEY, C.; RAFTERY, A. E. **Model-based clustering, discriminant analysis, and density estimation**. *Journal of the American Statistical Association*, v. 97, n. 458, p. 611-631, 2002.

ROUSSEEUW, P. J. **Silhouettes: a graphical aid to the interpretation and validation of cluster analysis**. *Journal of Computational and Applied Mathematics*, v. 20, p. 53-65, 1987.