Support Vector Clustering (SVC)

Lucas Scheffer
Orientador: Prof. Anderson Ara

Agrupamento por Vetores de Suporte



Departamento de Estatística - UFPR

O que é o Support Vector Clustering?

- O SVC é um algoritmo de **clustering** baseado na teoria do SVM, proposta por Vapnik.
- **Ideia Principal:** Proposta por **Ben-Hur et al. [2]**, consiste em mapear os dados para um espaço de alta dimensão (RKHS) e encontrar a *Esfera Mínima Envolvente* (Minimal Enclosing Sphere).
- **Vantagem:** Não assume uma forma geométrica fixa para os clusters (como o K-means que assume esferas).

Formulação do Problema: Primal

Seja $\{\mathbf{x}\} \in \mathbb{R}^p$ um conjunto de pontos. Queremos encontrar a esfera de raio R e centro a que contenha *quase* todos os pontos:

$$\min R^2 + C \sum_i \xi_i \tag{1}$$

Sujeito a:

$$\|\Phi(\mathbf{x}_i) - a\|^2 \leq R^2 + \xi_i, \quad \xi_i \geq 0 \tag{2}$$

- C é uma constante de penalização (trata outliers).
- Φ é o mapeamento para o espaço de características.

Formulação do Problema: Dual

Utilizando multiplicadores de Lagrange β_i, chegamos ao problema dual de maximização:

$$W = \sum_i \beta_i K(\mathbf{x}_i, \mathbf{x}_i) - \sum_{i,j} \beta_i \beta_j K(\mathbf{x}_i, \mathbf{x}_j) \tag{3}$$

Sujeito a:

$$0 \leq \beta_i \leq C \quad \text{e} \quad \sum_i \beta_i = 1 \tag{4}$$

Vetor de Suporte (SV): Pontos com $0 < \beta_i < C$ que ficam exatamente na fronteira da esfera.

Função de Distância e Atribuição

A distância de um ponto x ao centro da esfera no espaço de características é:

$$R^2(x) = K(\mathbf{x}, \mathbf{x}) - 2\sum_i \beta_i K(\mathbf{x}_i, \mathbf{x}) + \sum_{i,j} \beta_i \beta_j K(\mathbf{x}_i, \mathbf{x}_j)$$

Adjacência entre pontos

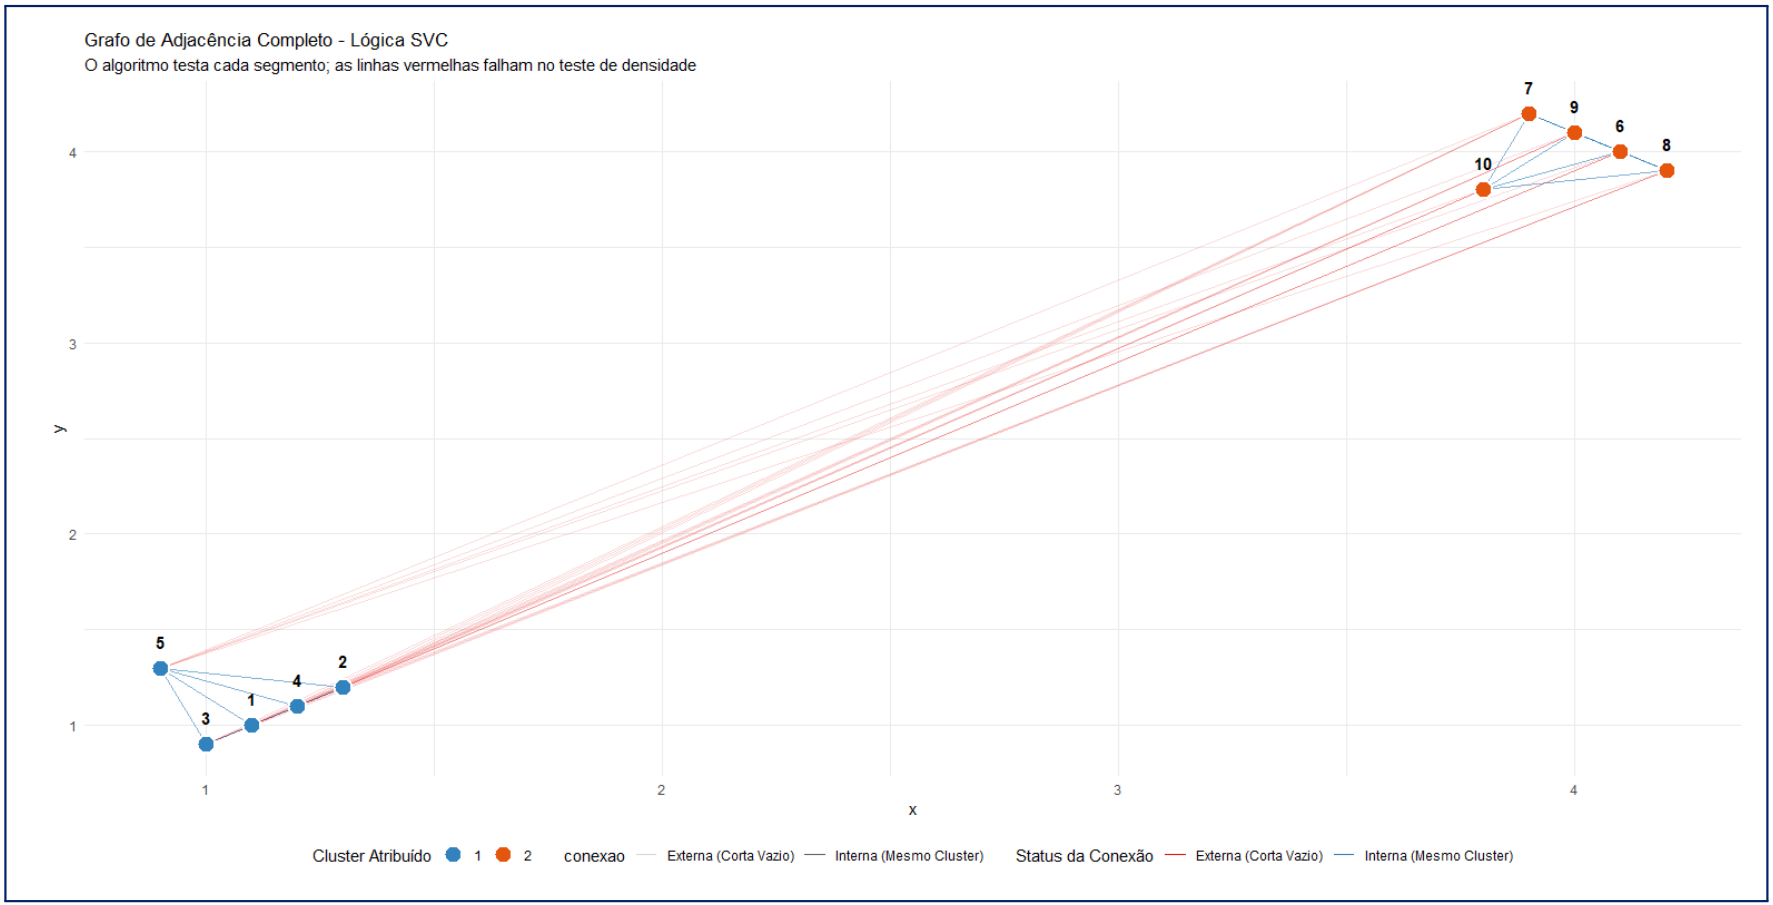
Dois pontos pertencem ao mesmo cluster se a linha que os une no espaço de características não sai da esfera. Matematicamente:

$$||\Phi(tX_i + (1-t)X_j) - a||^2 \leq R^2, \forall t \in (0,1), \tag{5}$$

com t sendo a posição ao longo do segmento. Originalmente, deveríamos observar todos os possíveis valores para t, mas isso é impossível, portanto, seleciona-se uma amostra de n t's para fazer a validação.

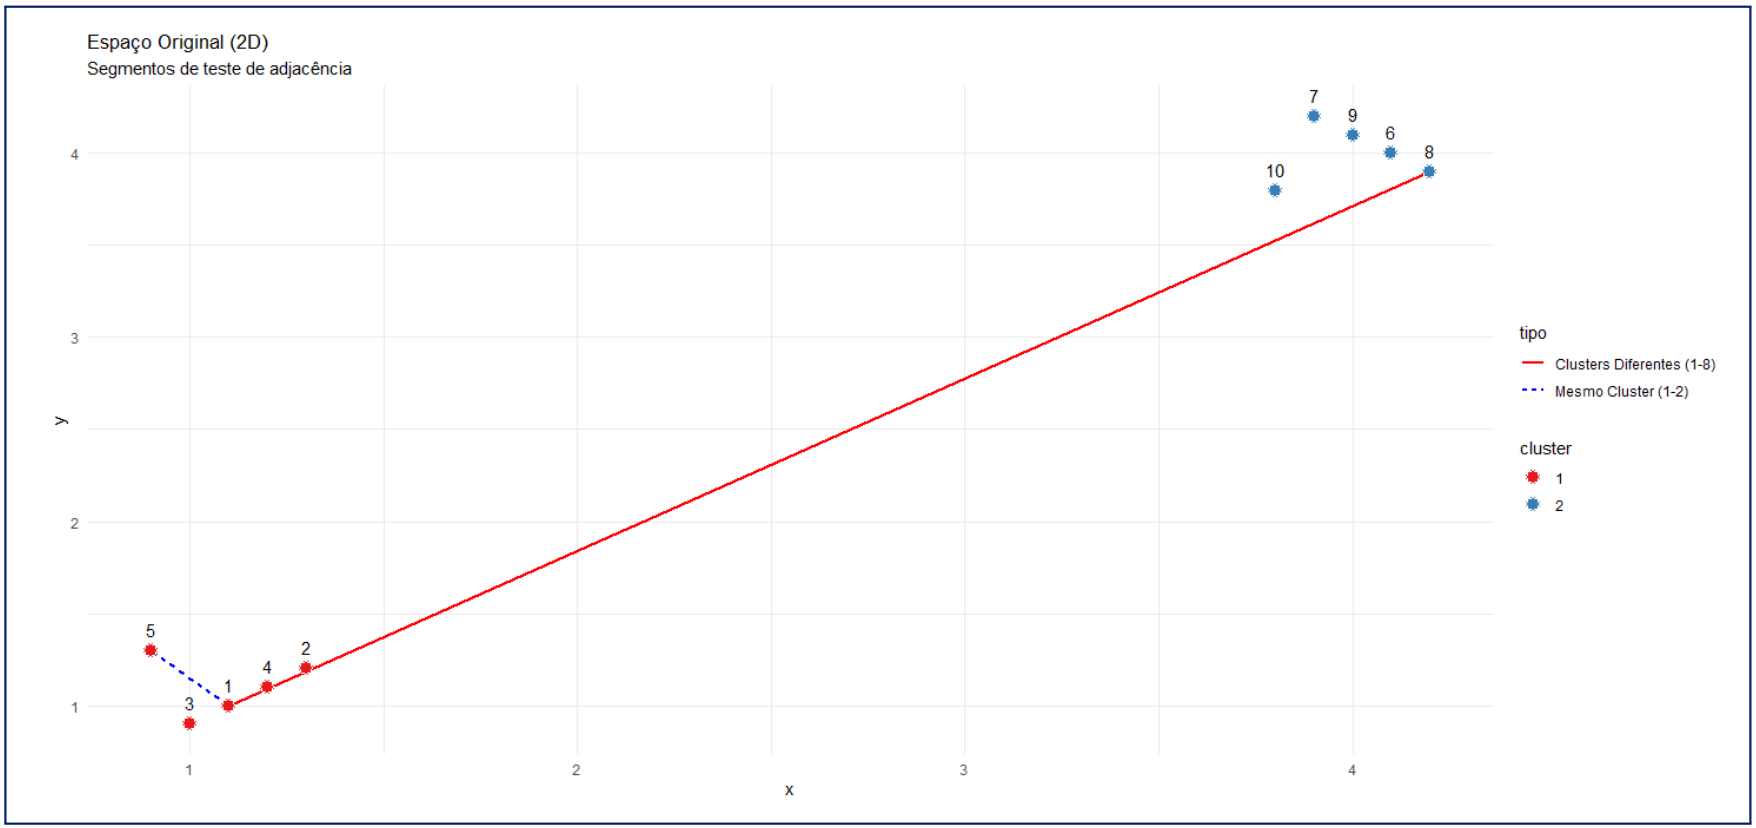
Função de Distância e Atribuição

Visualizando tudo isso:



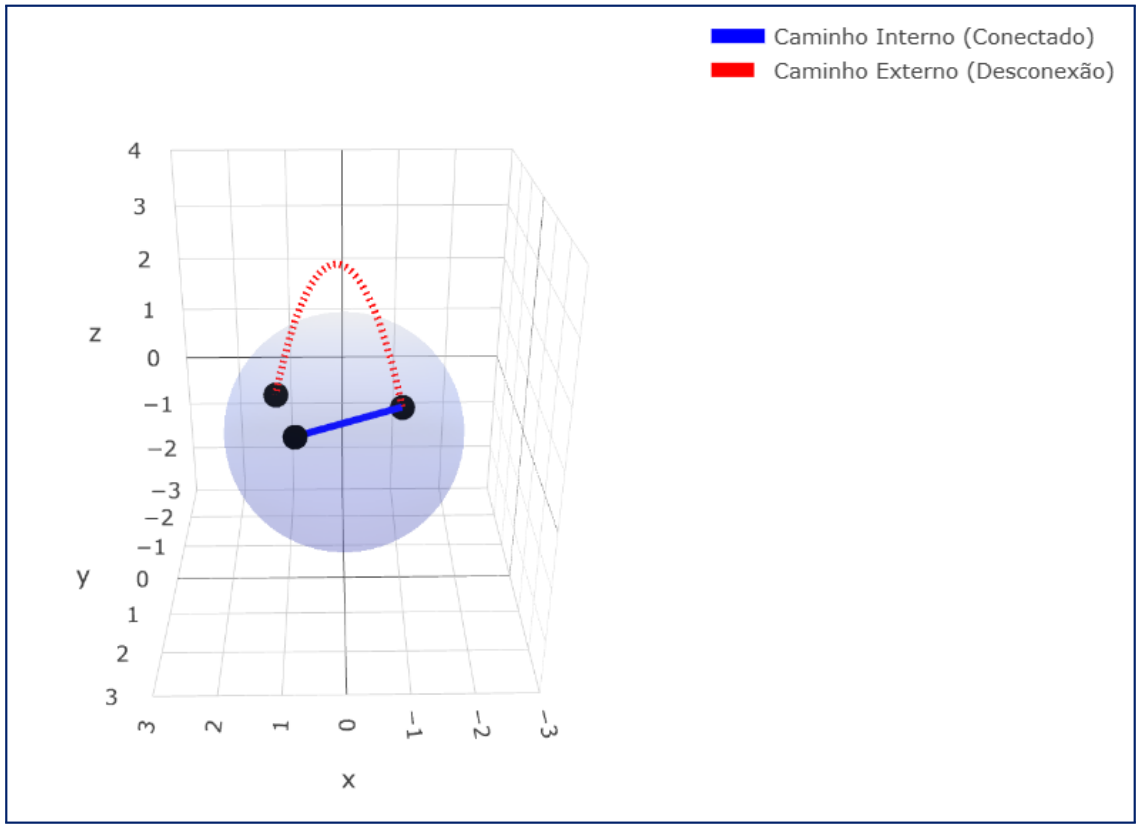
Todos os segmentos são traçados

Função de Distância e Atribuição



Segmentos 1-5 e 1-8.

Função de Distância e Atribuição



Segmentos 1-5 e 1-8 no espaço kernelizado.

Matriz de adjacência

Ao final, teremos uma matriz de adjacência contendo 0's e 1's, sendo:

- 0: os 2 pontos **não estão** no mesmo cluster;
- 1: os 2 pontos **estão** no mesmo cluster.

Matriz de adjacência

A_{ij}

- 0: os 2 pontos **não estão** no mesmo cluster;
- 1: os 2 pontos **estão** no mesmo cluster.

$A_{ij} =$

i \ j	1	2	3	4	5	6	7	8	9	10
1	1	1	1	1	1	0	0	0	0	0
2	1	1	1	1	1	0	0	0	0	0
3	1	1	1	1	1	0	0	0	0	0
4	1	1	1	1	1	0	0	0	0	0
5	1	1	1	1	1	0	0	0	0	0
6	0	0	0	0	0	1	1	1	1	1
7	0	0	0	0	0	1	1	1	1	1
8	0	0	0	0	0	1	1	1	1	1
9	0	0	0	0	0	1	1	1	1	1
10	0	0	0	0	0	1	1	1	1	1

Efeito do Parâmetro de Kernel (γ)

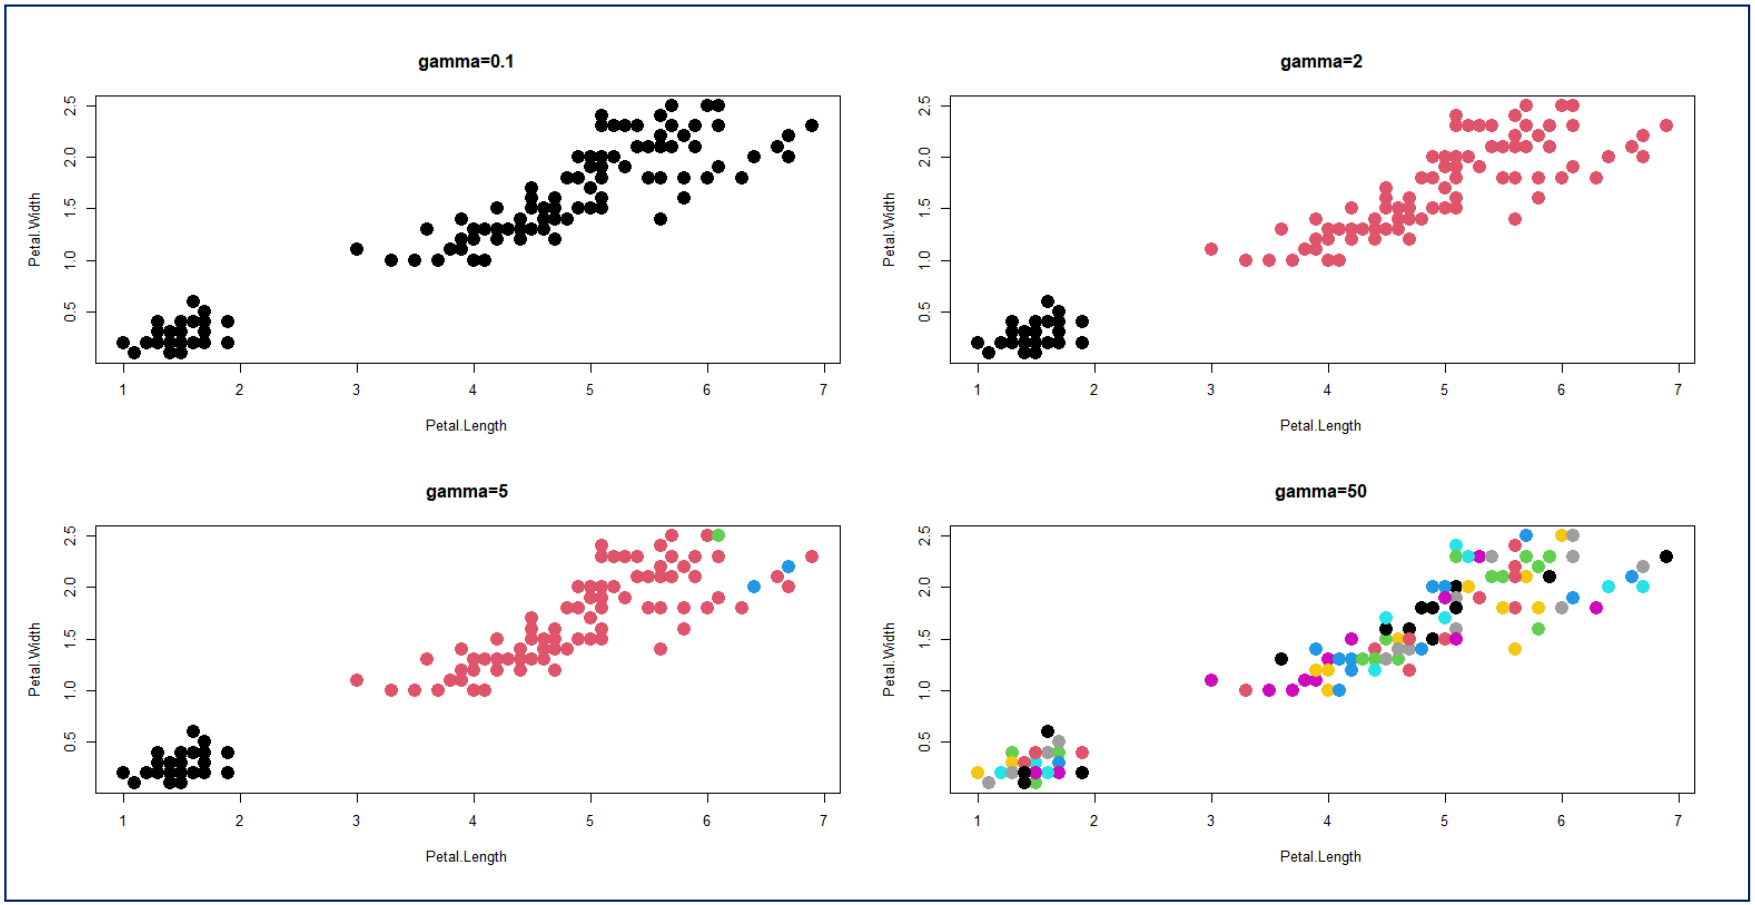
Kernel Gaussiano

A flexibilidade do contorno depende do parâmetro do kernel γ:

$$K(x_i, x_j) = e^{-\gamma \|x_i - x_j\|^2}$$

- γ **pequeno:** O modelo é simples, resultando em poucos clusters grandes.
- γ **grande:** O modelo torna-se complexo, podendo separar os dados em muitos clusters pequenos ou até isolar pontos.

Efeito do Parâmetro de Kernel (γ)



Visualização da fronteira de decisão variando γ.

- $\gamma = 0.1$: 1 cluster
- $\gamma = 5$: 4 clusters
- $\gamma = 2$: 2 clusters
- $\gamma = 50$: 105 clusters

Função no R

- Sem implementação no R e nem no Python.
- SVclust: Criada por Lucas Scheffer e Anderson Ara, em constante evolução (Mestrado PPGMNE).
- A teoria original possui um algoritmo intensivo demais, estamos estudando técnicas para reduzir essa complexidade.
- Em processo de análise e envio para o CRAN.

Estimação do Parâmetro γ

A escolha de γ define a escala do kernel e a flexibilidade da fronteira. Na ausência de um valor definido pelo usuário, o `SVclust` utiliza uma heurística baseada na distribuição das distâncias:

Heurística de Mediana (**Caputo et al. [4]**)

Embora inspirada na lógica da função `sigest()` do pacote `kernlab`, desenvolvemos uma implementação nativa:

1. Calculamos o quadrado da distância Euclidiana entre todos os pares de observações do subconjunto: $d_{ij}^2 = \|\mathbf{x}_i - \mathbf{x}_j\|^2$.
2. Filtramos as distâncias nulas ($d_{ij}^2 > 0$) para evitar problemas.
3. Definimos γ como o inverso da mediana (quantil 0.5) desses valores:

$$\gamma = \frac{1}{\text{mediana}(\{d_{ij}^2 : d_{ij}^2 > 0\})} \tag{6}$$

Instalação e Uso do SVclust

```
if (!require("devtools")) install.packages("devtools")
devtools::install_github("Scheffer2001/SVclust")

library(SVclust)
library(ggplot2)

# Abrir documentacao
?SVC
```

Instalação e Uso do SVclust

```
results <- SVC(
    data = iris[,1:4],
    gamma = 2,
    scan_n = 10,
    kernel = "gaussian",
    nobs = 75)
```

Definições dos Parâmetros:

data: Dados para agrupamento (matriz ou data frame).

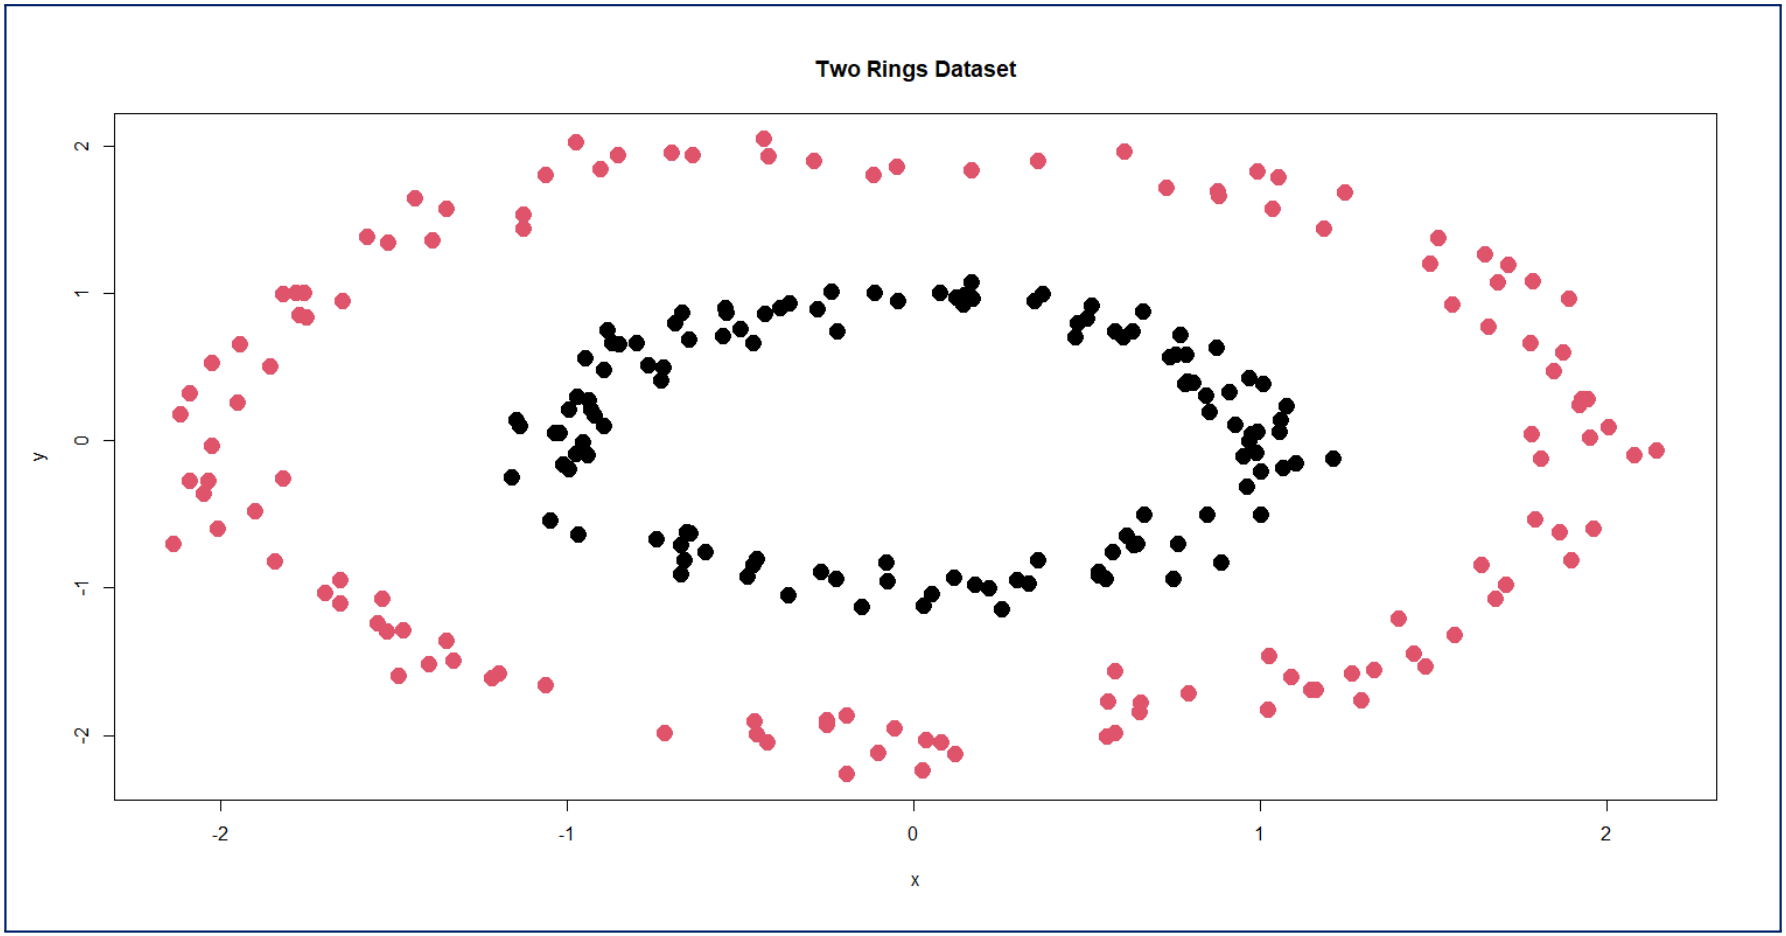
gamma: Parâmetro do kernel gaussiano.

scan_n: Amostragem para cálculo de adjacência.

kernel: Kernel utilizado nos cálculos.

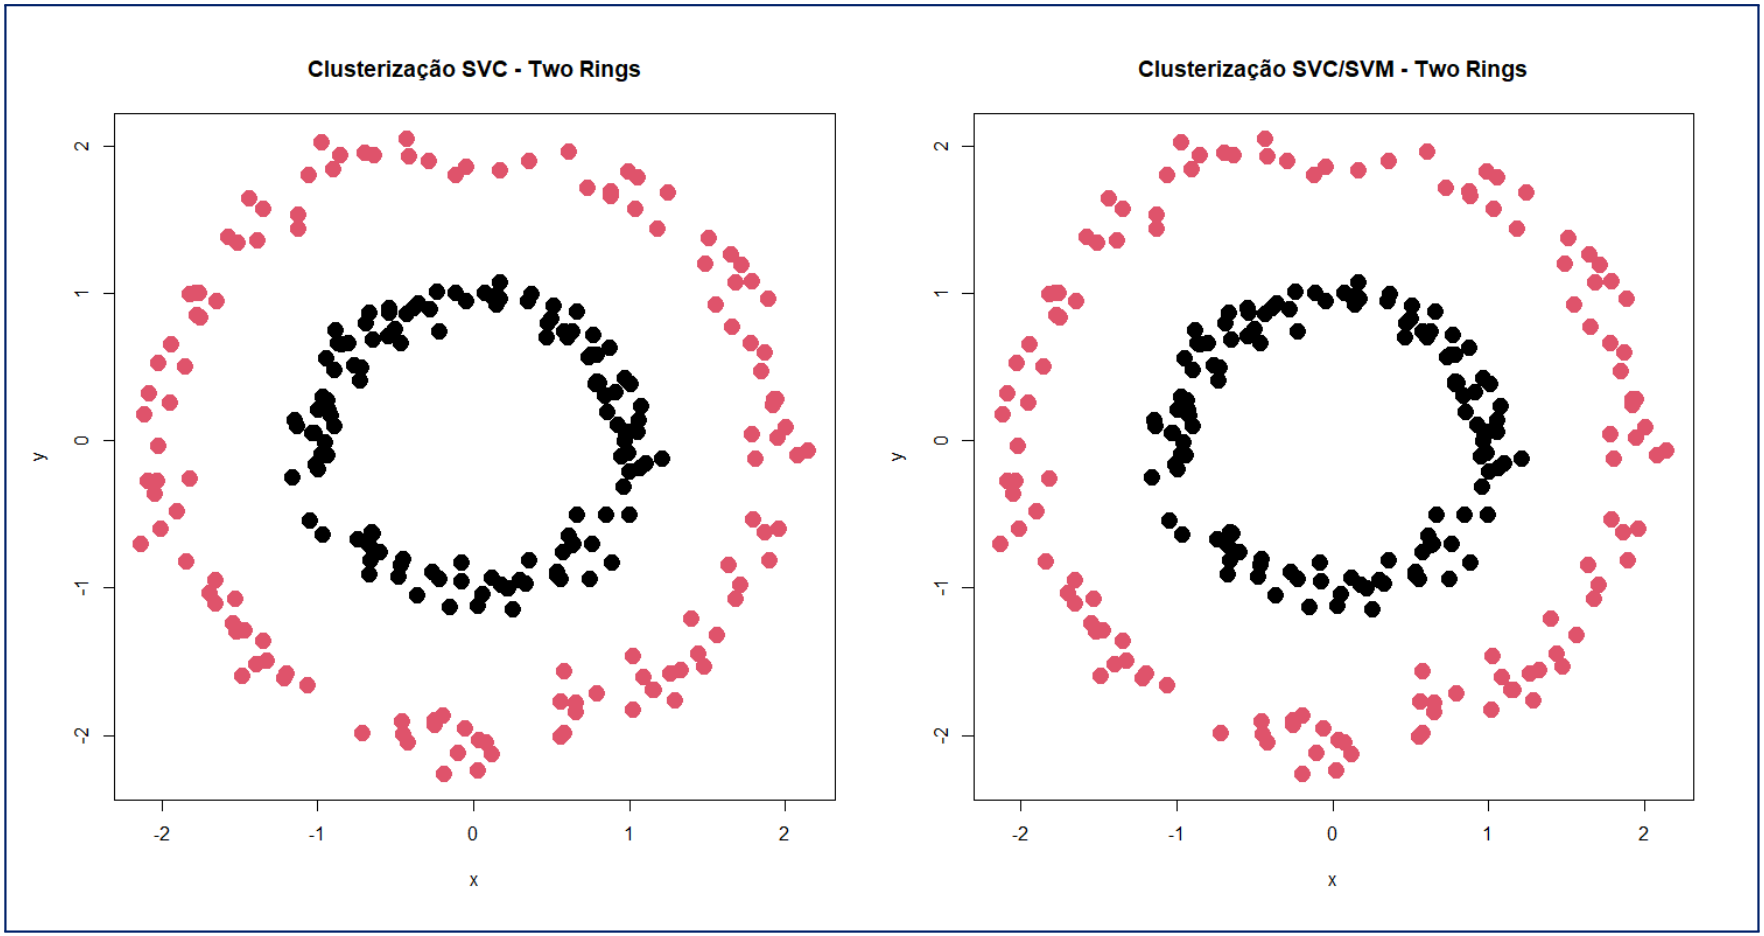
n_obs: Clusteriza `n_obs` observações e classifica via SVM o restante $n - n_{obs}$.

Aplicação: dataset two rings



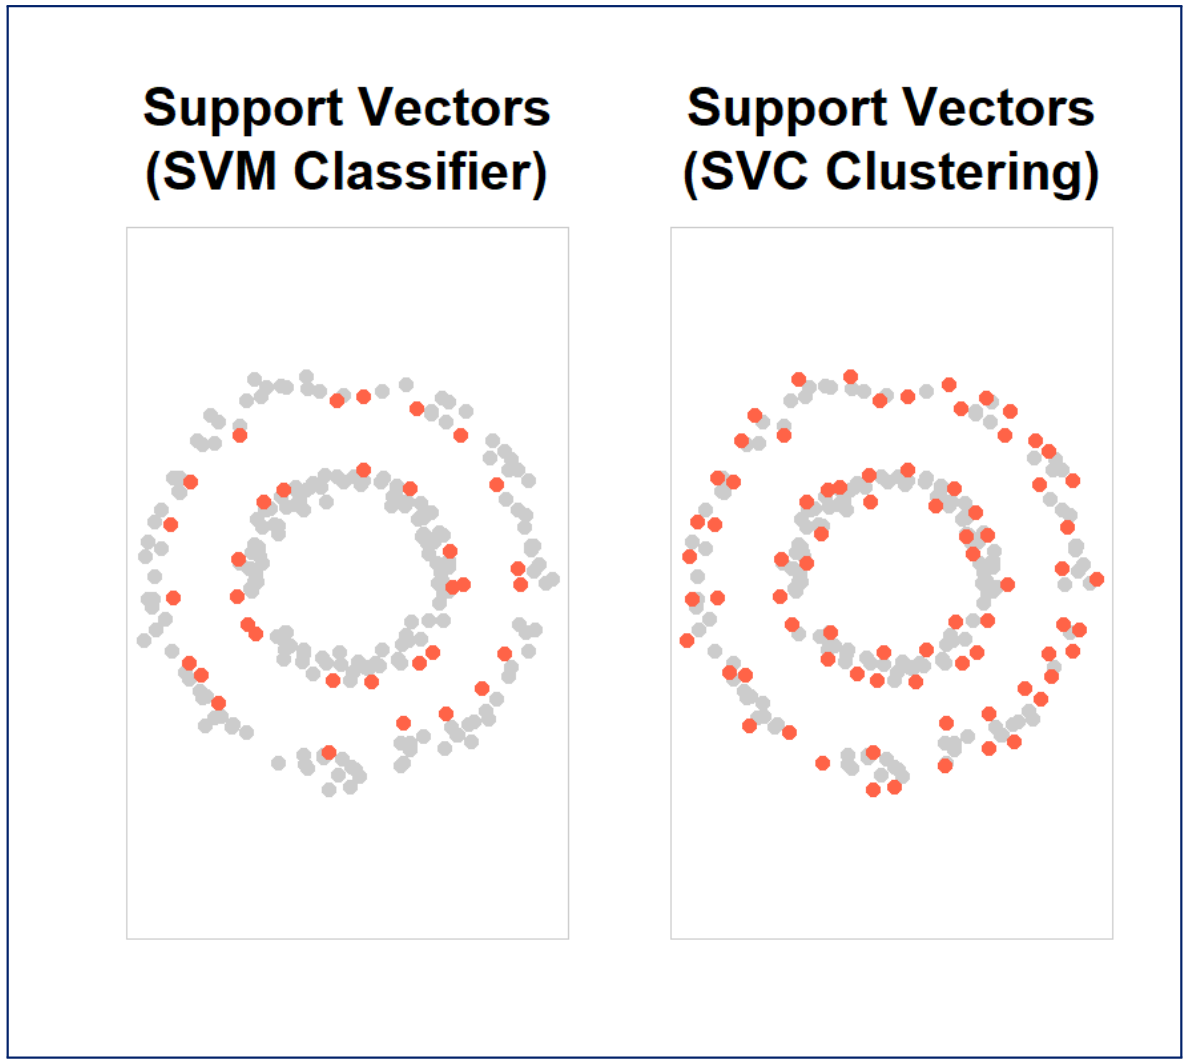
Dataset two rings.

Aplicação: `dataset two rings` - SVC/SVM



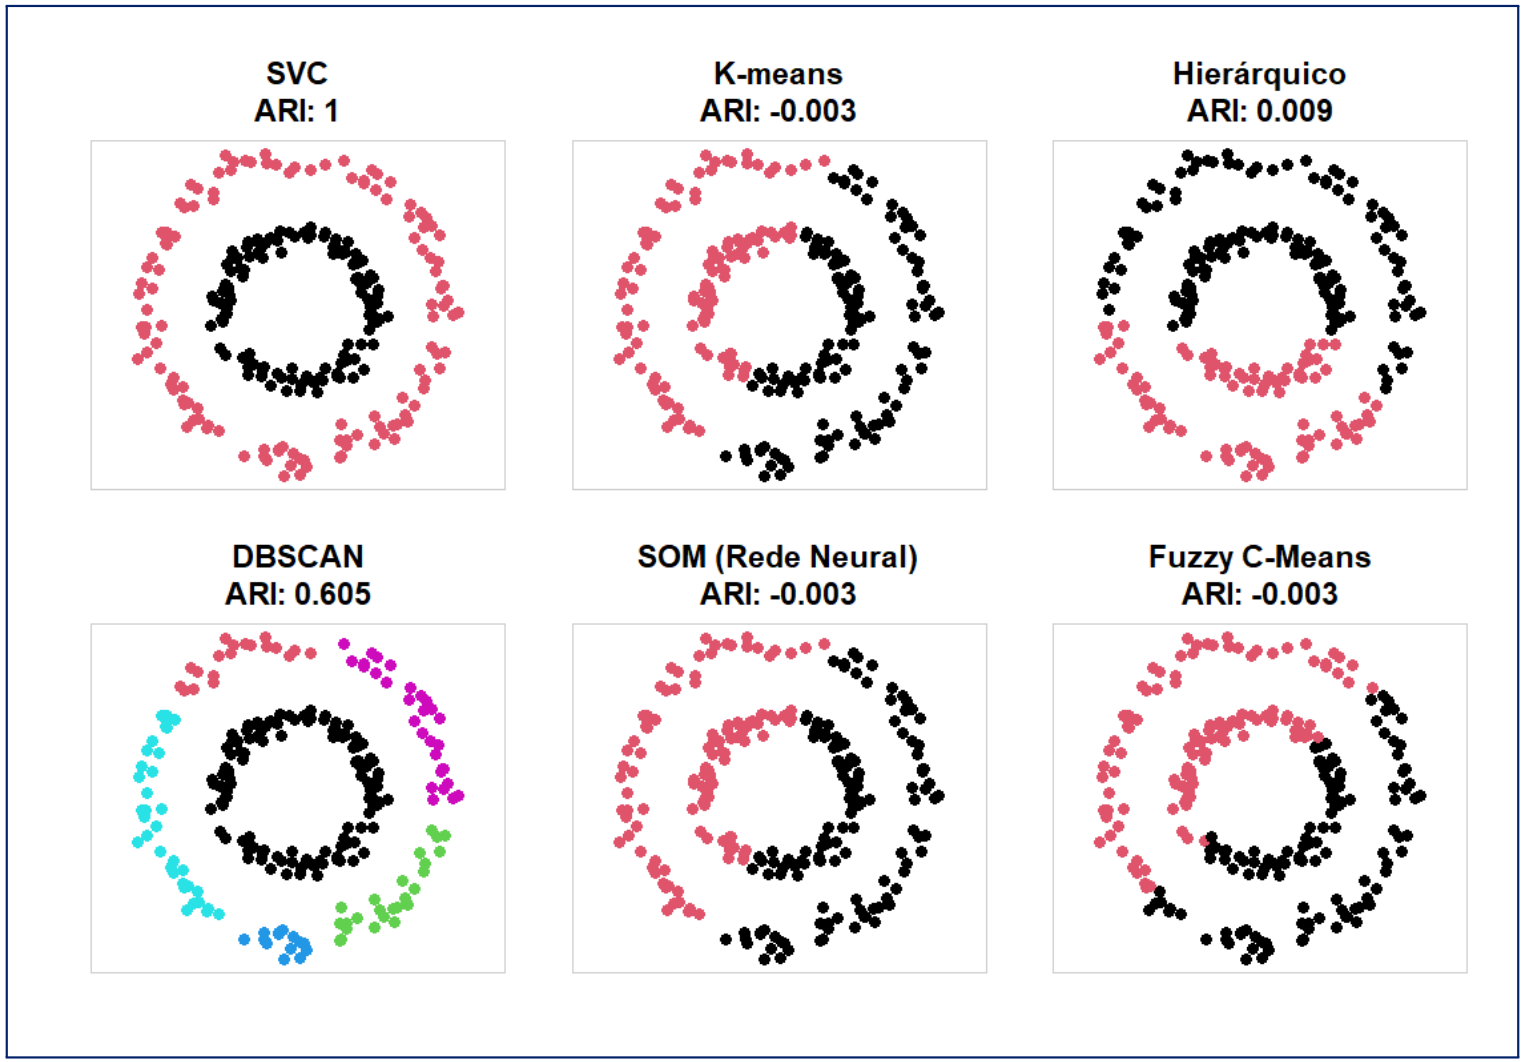
Clusterizações do SVC e SVM no Dataset two rings.

Aplicação: `dataset two rings` - SVC/SVM



Vetores de suporte do SVC e SVM no Dataset two rings.

Aplicação: `dataset two rings` - diversas clusterizações



*Clusterizações no Dataset two rings. ARI (**Rand [3]**) = concordância com a partição-resposta.*

Discussão e Considerações Finais

- Excelente desempenho em conjuntos de dados com fronteiras não lineares e topologias complexas (ex: *Two Rings*).
- A formulação original é $O(n^2)$ para a matriz de adjacência. O desenvolvimento do `SVclust` foca em reduzir esse gargalo via amostragem e otimização de matrizes.
- Sem a penalização C ativa, o SVC comporta-se de forma análoga ao DBSCAN, mas com a vantagem da projeção em RKHS.
- **Trabalhos em Curso:**
  - Maximização da distância do segmento de reta em RKHS até a.
  - Clusterizar somente os vetores de suporte, e posteriormente, aplicar SVM com esses SV's para o resto da base.

Referências Principais


VAPNIK, Vladimir.
The Nature of Statistical Learning Theory.
Springer, 1995.


BEN-HUR, A. et al.
Support Vector Clustering.
Journal of Machine Learning Research, 2001.


RAND, William M.
Objective criteria for the evaluation of clustering methods.
Journal of the American Statistical Association, 1971.


CAPUTO, B. et al.
Appearance-based object recognition using SVMs: a comparative study.
VBCS, 2002 (Heurística de γ).

Conclusões e Contatos

Obrigado pela atenção!

Lucas Scheffer
lucas.scheffer@ufpr.br

Anderson Ara
ara@ufpr.br

