APRENDIZADO NÃO SUPERVISIONADO



Prof. Dr. Anderson Ara

Slide 02

Estimação de Densidade

ESTATÍSTICA NÃO PARAMÉTRICA

A estatística não paramétrica refere-se a uma coleção de métodos estatísticos nos quais os dados não são assumidos como provenientes de modelos prescritos, determinados por um número de parâmetros.

Alguns exemplos de métodos paramétricos: o modelo de distribuição normal e o modelo de regressão linear.

ESTIMAÇÃO DE DENSIDADE

Dado um conjunto de dados

$$x_1, x_2, \ldots, x_n$$

queremos estimar a distribuição de probabilidade subjacente

$$f(x)$$

Sem assumir necessariamente um modelo paramétrico.

POR QUE ESTIMAR DENSIDADE?

Em suma, a estimação de densidade permite:

- entender a forma da distribuição
- identificar modos e multimodalidade
- detectar outliers
- construir modelos generativos

Aplicações:

- clustering
- anomaly detection
- visualização exploratória

ESTIMAÇÃO DE DENSIDADE

Considere uma variável aleatória X com função densidade de probabilidade $f_X(x)$. A probabilidade de $X \in [-h/2, h/2]$ é:

$$P(X \in [-h/2, h/2]) = \int_{-h/2}^{h/2} f_X(x)dx.$$

Uma estimativa da densidade f pode ser pensada como contar o número de observações que pertencem a cada intervalo e dividi-lo pelo número total de observações.

Estimação de Densidades

- Em outras palavras, dado um conjunto de observações, $x_1, \ldots, x_n$, temos:

$$P(X \in [-h/2, h/2]) \approx \frac{1}{n} \#\{x_i \in [-h/2, h/2]\}.$$

Ou seja,

$$P(X \in [-h/2, h/2]) = \int_{-h/2}^{h/2} f_X(x)dx \approx f(\xi)h,$$

com $\xi \in [-h/2, h/2]$. Assim, uma estimativa para f seria:

$$\hat{f}_h(x) = \frac{1}{nh} \#\{x_i \in [-h/2, h/2]\},$$

para todo $x \in x_i \in [-h/2, h/2]$.

Estimação de Densidades

- Formalmente, suponha uma amostra aleatória $X_1, \ldots, X_n$ da variável aleatória X com f desconhecida e observamos $x_1, \ldots, x_n$.
- Seja k o número de intervalos de comprimento h e defina C_j por:

$$C_j = [x_0 + (j-1)h, x_0 + jh], \; j = 1, 2, \ldots, k.$$

- Seja $n_j = \sum_{i=1}^{n} I(x_i \in C_j)$, tal que $n = \sum_{j=1}^{k} n_j$.
- Então, $\hat{f}_h(x) = \frac{1}{nh} \sum_{j=1}^{k} n_j I(x \in C_j)$.

Estimação de Densidades

Observações:

1 - É fácil ver que a estimativa de $\hat{f}_h(x)$ depende fortemente da escolha de h (consequentemente, de k).

2 - h é chamado de parâmetro de suavização.

```
hist(x, nclass=, prob=T)
```

Generalização

A ideia e motivação do histograma sugere, naturalmente, uma generalização considerando funções do tipo:

$$K(x) = \begin{cases} \frac{1}{2}, & \text{se } |x| < 1 \\ \\ 0, & \text{caso contrário.} \end{cases}$$

- Estimação pelo método Kernel ou funções de kernel
- KDE: kernel density estimation

Método Kernel

- Consequentemente, pode-se sugerir uma nova estimativa para f como sendo:

$$\hat{f}(x) = \frac{1}{nh} \sum_{i=1}^{n} K\left(\frac{x - x_i}{h}\right).$$

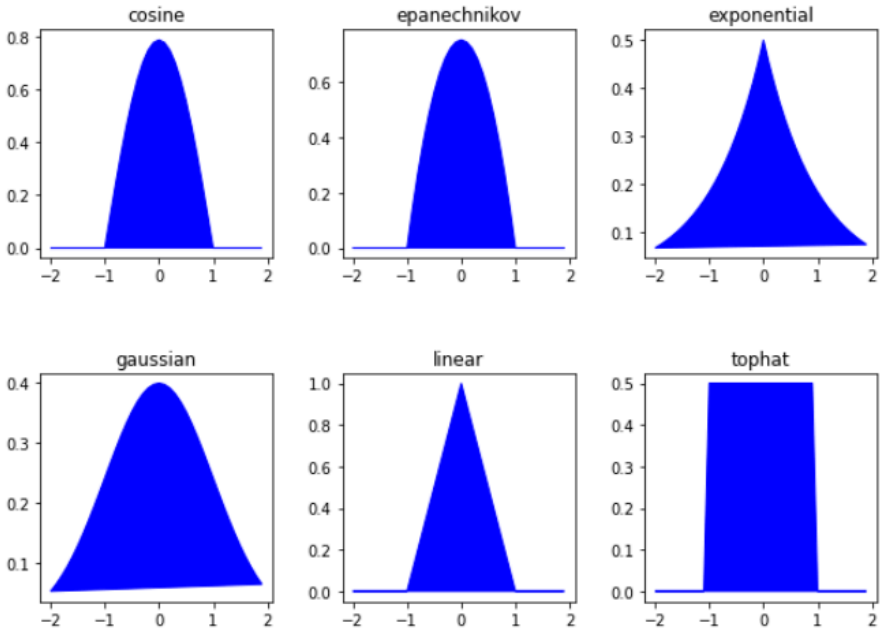
- Esta nova estimativa generaliza aquela baseada no Histograma.
- Este estimador 'ingênuo' tem a característica de não suavidade.
- Para superar o fato de não suavidade, faz-se suposições bastantes razoáveis sobre a função kernel K. Por exemplo K pode ser uma Gaussiana.

Método Kernel

Alguns exemplos de função kernel:

Tipos	Funções
Retangular	$\begin{cases} \frac{1}{2}, & \lvert x\rvert < 1 \\ 0, & \text{caso contrário} \end{cases}$
Triangular	$\begin{cases} 1 - \lvert x\rvert, & \lvert x\rvert < 1 \\ 0, & \text{caso contrário} \end{cases}$
Gaussiano	$\frac{1}{\sqrt{2\pi}} e^{-x^2/2}$

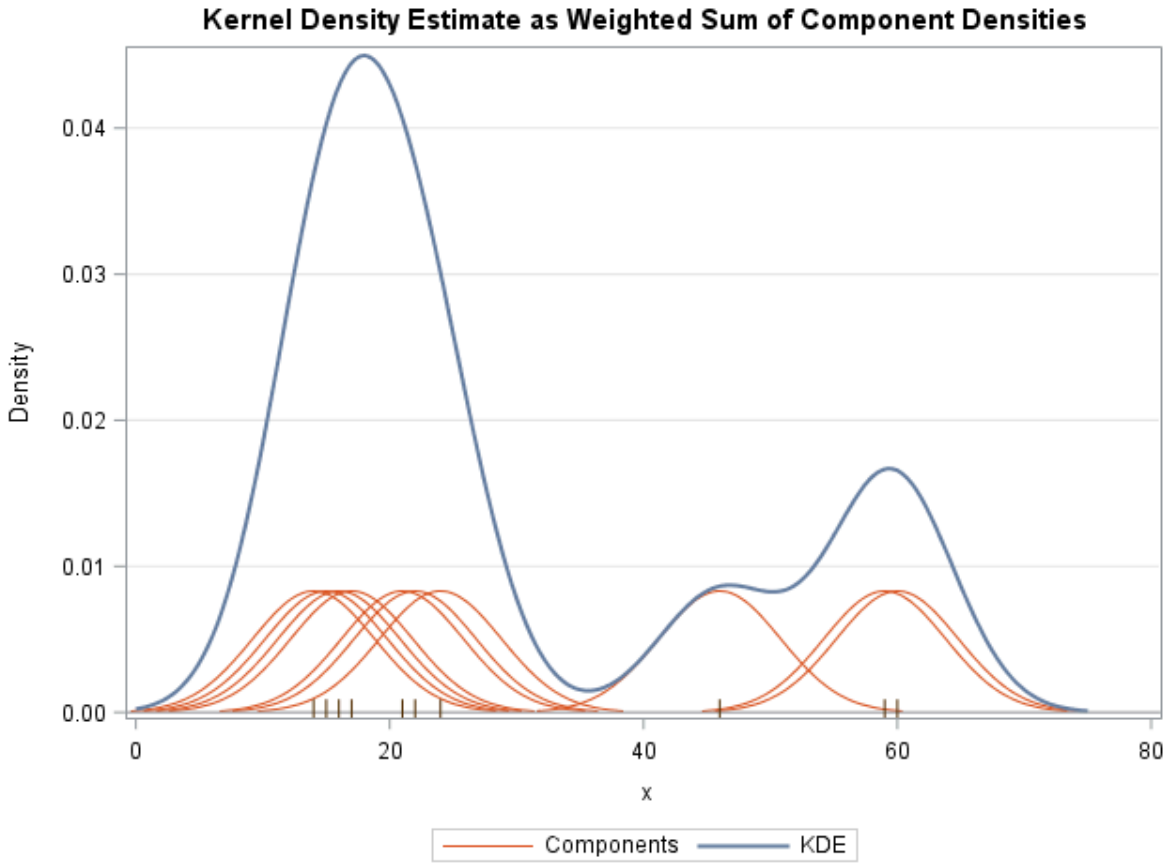
Método Kernel



https://scikit-learn.org/

Cuidado com o termo kernel. Sua tradução literal é *núcleo* e ele pode estar presente em diversos contextos. Alguns kernels acima não satifazem a condição de ser uma função de kernels positiva definida (Teorema de Mercer) e não são utilizados em outras na teoria de SVM.

Método Kernel



Método Kernel

- A estimativa é fortemente influenciada pela escolha de h.
- Quanto menor for o tamanho de h menos suave será a estimativa (mais ruído).
- De maneira oposta, quanto maior for o h mais suave será a estimativa final.

Método Kernel

Parâmetro de Suavização

A Escolha do Parâmetro de Suavização

a. Existem várias maneiras para se fazer uma boa escolha de h.

b. As comumente utilizadas são:

- A regra prática de Silverman (1986).
- Validação cruzada por máxima verossimilhança.

Método Kernel

Parâmetro de Suavização

Para a regra prática de Silverman:

$$\hat{h} = 1,06 \min\left(\hat{\sigma}, \frac{Q_3 - Q_1}{\Phi(3/4) - \Phi(1/4)}\right)$$

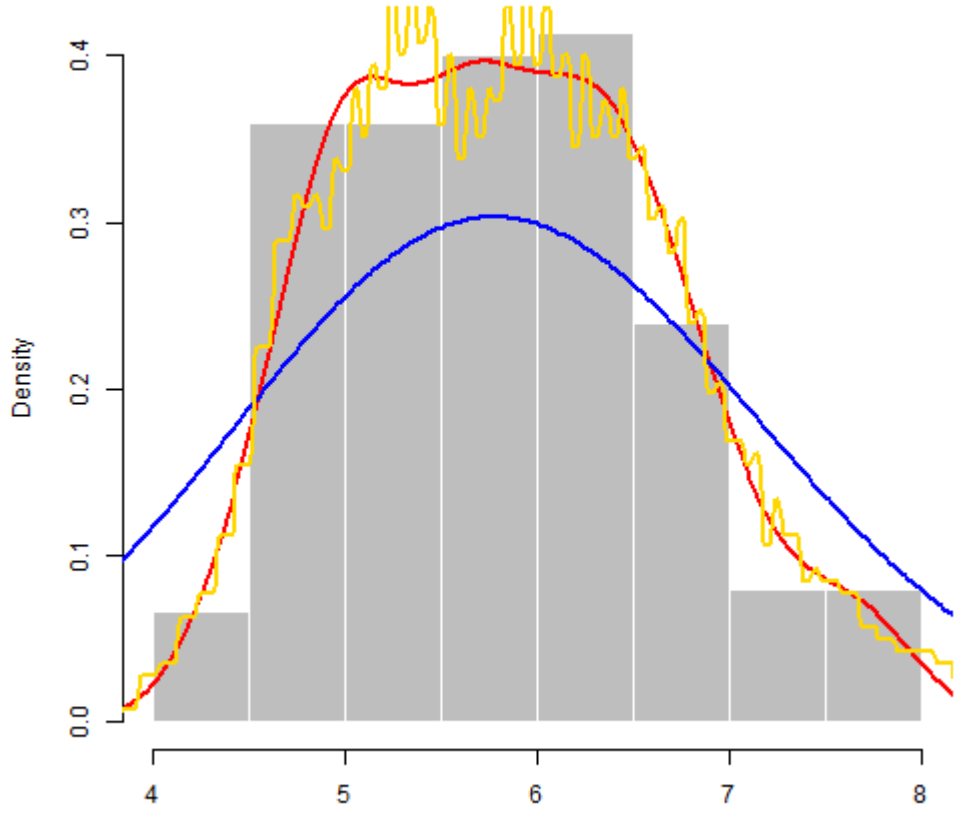
$$= 1,06 \min\left(\hat{\sigma}, \frac{Q_3 - Q_1}{1,349}\right)$$

em que Φ é a densidade de uma normal padrão.

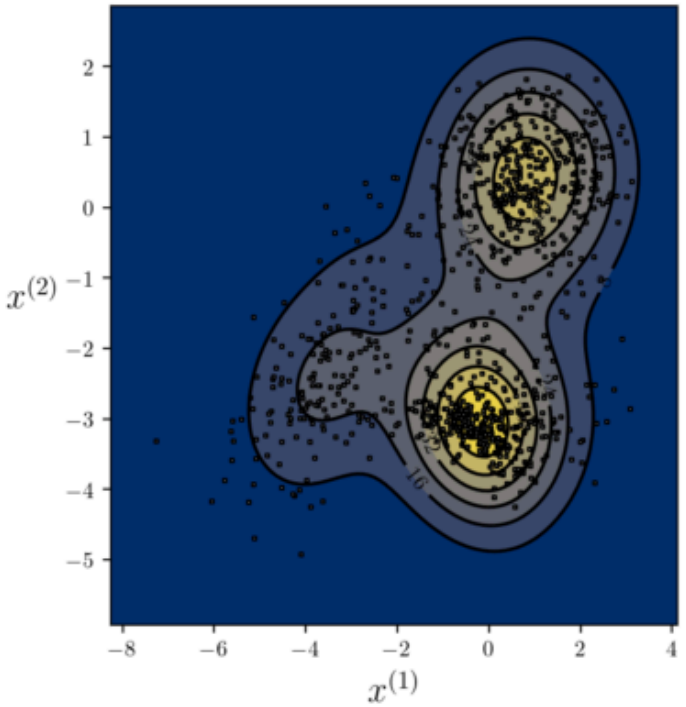
Método Kernel

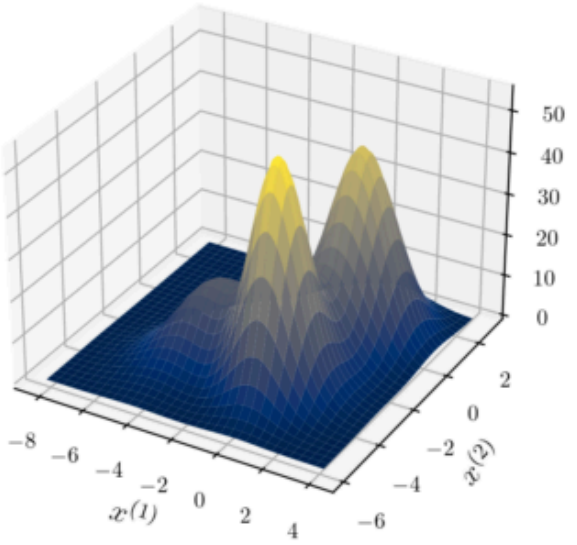
```
x=iris$Sepal.Length
hist(x,prob=T,col="gray",main="",border="white")
lines(density(x), col = "red", lwd = "2")
lines(density(x,bw=1), col = "blue", lwd = 2)
lines(density(x,kernel="rectangular"), col = "gold", lwd = 2)
```

Método Kernel



Método Kernel Multivariado





https://towardsdatascience.com/

Kernel Density Estimation Multivariado

Quando os dados têm várias variáveis:

$$x = (x_1, x_2, \ldots, x_d)$$

queremos estimar:

$$f(x_1, x_2, \ldots, x_d)$$

A ideia do KDE continua a mesma:

- cada observação contribui com uma pequena densidade
- a densidade final é a soma das contribuições

Agora isso ocorre em d dimensões.

KDE Multivariado

A estimativa de densidade é:

$$\hat{f}(x) = \frac{1}{nh^d} \sum_{i=1}^{n} K\left(\frac{x - x_i}{h}\right)$$

onde:

- $x \in \mathbb{R}^d$
- K é o kernel multivariado
- h é o bandwidth

Kernel Gaussiano (muito usado):

$$K(u) = \frac{1}{(2\pi)^{d/2}} e^{-\frac{1}{2}u^T u}$$

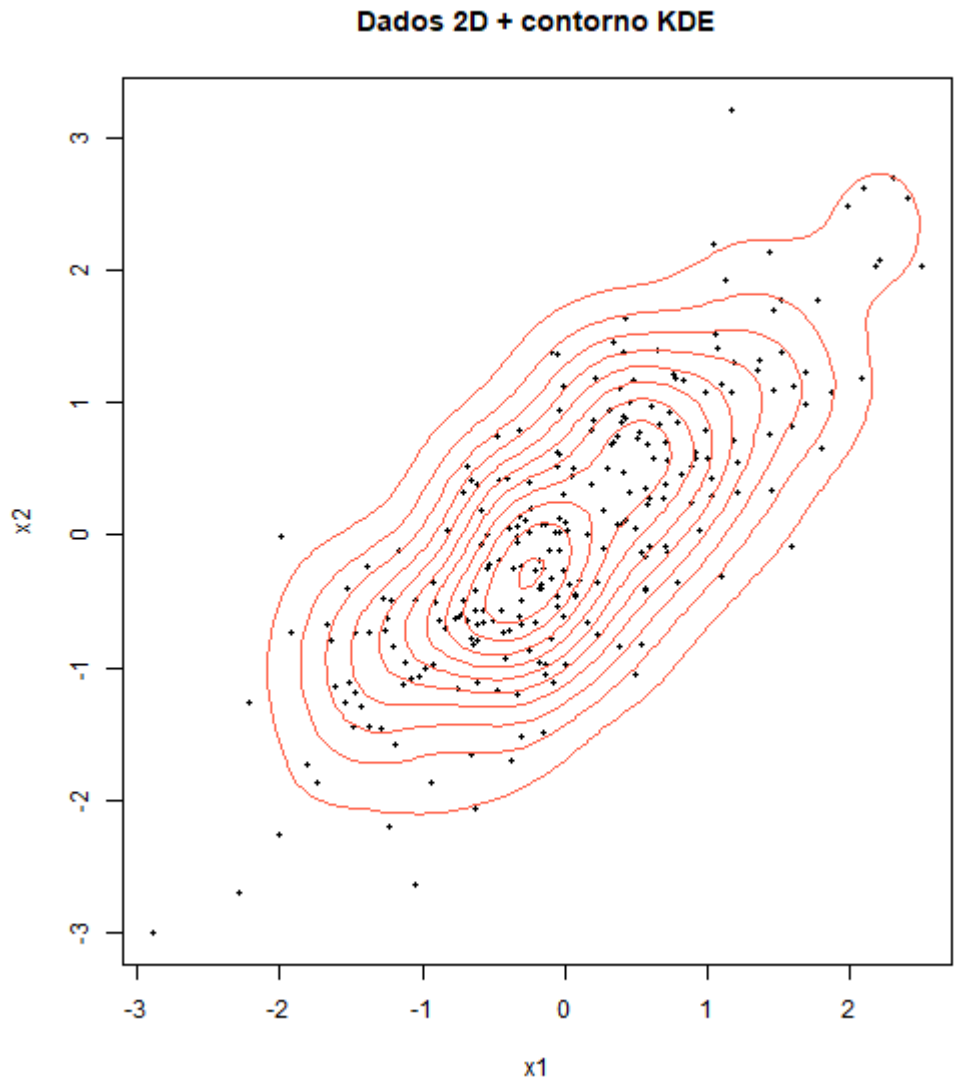
Visualização em 2D

```
require(MASS)
set.seed(1)
x1 <- rnorm(250)
x2 <- 0.8*x1 + rnorm(250, sd = 0.6)

kd <- kde2d(x1, x2, n = 70)

plot(x1, x2, pch = 16, cex = 0.5,
     main = "Dados 2D + contorno KDE",
     xlab = "x1", ylab = "x2")
contour(kd, add = TRUE, drawlabels = FALSE, col="tomato")
```

Interpretação: regiões com contornos mais "fechados" e densos indicam maior concentração de pontos.


Dados 2D + contorno KDE
x2
x1
3
2
1
0
-1
-2
-3
-3
-2
-1
0
1
2

Desafios em alta dimensão

KDE sofre com a maldição da dimensionalidade.

Quando d cresce:

- os dados ficam esparsos
- a estimativa fica instável
- é necessário muito mais dados para o mesmo nível de precisão

Práticas comuns:

- reduzir dimensão antes de estimar densidade
- usar modelos paramétricos / semi-paramétricos
- usar densidade como *score* (não necessariamente como objeto final)

Conexão com métodos de agrupamento

Gaussian Mixture Models (GMM)

- Em vez de KDE, modela a densidade como mistura:

$$f(x) = \sum_{k=1}^{K} \pi_k \mathcal{N}(x \mid \mu_k, \Sigma_k)$$

- Clustering surge por atribuição (soft/hard) aos componentes via EM.
- KDE = não paramétrico; GMM = paramétrico (mais compacto, mas assume forma).

Conexão com métodos de agrupamento

DBSCAN (densidade local)

- Não estima $f(x)$ explicitamente.
- Define clusters por densidade local: pontos com muitos vizinhos $(\varepsilon, \mathit{minPts})$.
- Muito útil quando clusters têm forma irregular e há ruído/outliers.

Mensagem-chave: KDE fornece uma noção de densidade; diferentes métodos exploram essa noção de maneiras diferentes:

- modos (Mean Shift),
- modelos gerativos (GMM),
- conectividade por densidade local (DBSCAN).

Conexão com métodos de agrupamento

Mean Shift Clustering

- Interpreta clustering como busca por modas (picos) da densidade.
- Usa o KDE (ou uma ideia equivalente) para mover cada ponto na direção do gradiente da densidade (*hill climbing*).
- Cada moda encontrado define um cluster.