APRENDIZADO NÃO SUPERVISIONADO

Prof. Bruno Melo e Prof. Anderson Ara

SVD & Análise de Correspondência

SVD & Análise de Correspondência

O que veremos hoje

- Parte 1 — SVD
  Intuição geométrica · Definição matemática · Compressão de imagem · Variância explicada
- Parte 2 — CA
  Da tabela ao mapa · Qui-quadrado · Inércia · Biplot · Exemplo com dados reais

Por que decompor uma matriz?

Imagine um dataset com centenas de variáveis.

A informação relevante raramente está distribuída igualmente em todas as dimensões, ela tende a estar concentrada em poucas direções privilegiadas.

Problema: Dada uma matriz $\mathbf{A}$, como encontrar as direções que capturam o máximo de sua estrutura, com o mínimo de componentes?

Resposta: Decomposição em Valores Singulares (SVD).

💡 O SVD é a decomposição mais fundamental da álgebra linear aplicada: existe para qualquer matriz, não precisa ser quadrada nem simétrica.

SVD: Intuição Geométrica

Toda matriz $\mathbf{A}$ é uma transformação linear.
Ela pode fazer três coisas com um vetor:

- Rotacionar — $\mathbf{V}^T$ alinha os vetores de entrada
- Escalar — $\mathbf{\Sigma}$ estica ou encolhe cada direção
- Rotacionar — $\mathbf{U}$ reposiciona no espaço de saída

$$\mathbf{A} = \mathbf{U}\,\mathbf{\Sigma}\,\mathbf{V}^T$$

Toda transformação linear é apenas duas rotações + um escalonamento.

Analogia: um fotógrafo que distorce uma foto. O SVD encontra o ângulo certo de observação ($\mathbf{V}^T$), identifica o quanto cada dimensão foi ampliada ($\mathbf{\Sigma}$) e reorienta o resultado ($\mathbf{U}$).

SVD: Definição Formal

Teorema. Toda matriz real $\mathbf{A} \in \mathbb{R}^{m \times n}$ de posto r pode ser escrita como:

$$\mathbf{A} = \mathbf{U}\,\Sigma\,\mathbf{V}^T$$

onde:

Matriz	Dimensão	Propriedade	Significado
$\mathbf{U}$	$m \times m$	$\mathbf{U}^T\mathbf{U} = \mathbf{I}$	Vetores singulares à esquerda
Σ	$m \times n$	Diagonal, $\sigma_1 \geq \cdots \geq \sigma_r > 0$	Valores singulares
$\mathbf{V}$	$n \times n$	$\mathbf{V}^T\mathbf{V} = \mathbf{I}$	Vetores singulares à direita

Os valores singulares σ_i , $i = 1, \ldots, r$ são as raízes quadradas dos autovalores de $\mathbf{A}^T\mathbf{A}$.
Eles medem a "importância" de cada direção: maior $\sigma_i \rightarrow$ mais estrutura capturada da matriz.

SVD: Conexão com Autovalores

Se $\mathbf{A} = \mathbf{U}\Sigma\mathbf{V}^T$, então:

$$\mathbf{A}^T\mathbf{A} = \mathbf{V}\Sigma^2\mathbf{V}^T \quad \Rightarrow \quad \mathbf{A}^T\mathbf{A}\,\mathbf{V} = \mathbf{V}\Sigma^2$$

Isso é exatamente a decomposição em autovetores de $\mathbf{A}^T\mathbf{A}$.

Colunas de $\mathbf{V}$ = autovetores de $\mathbf{A}^T\mathbf{A}$

Colunas de $\mathbf{U}$ = autovetores de $\mathbf{A}\mathbf{A}^T$

$\boldsymbol{\sigma_i^2}$ = autovalores de $\mathbf{A}^T\mathbf{A}$

SVD como Soma de Matrizes de Posto 1

O SVD pode ser escrito como:

$$\mathbf{A} = \sum_{i=1}^{r} \sigma_i \, \mathbf{u}_i \mathbf{v}_i^T$$

Cada termo $\sigma_i \mathbf{u}_i \mathbf{v}_i^T$ é uma matriz de posto 1 — o "padrão i" da matriz.

Ideia-chave: truncar a soma nos k maiores σ_i dá a melhor aproximação de posto k para $\mathbf{A}$ (Teorema de Eckart-Young, 1936):

$$\mathbf{A}_k = \sum_{i=1}^{k} \sigma_i \, \mathbf{u}_i \mathbf{v}_i^T \quad \text{minimiza} \quad \|\mathbf{A} - \mathbf{B}\|_F \text{ sobre todo } \mathbf{B} \text{ de posto } k$$

Esse é o fundamento matemático da compressão de imagem, do PCA e da Análise de Correspondência.

Imagem RGB → Tons de Cinza

Para aplicar o SVD a uma imagem colorida, precisamos de uma única matriz.

Uma imagem RGB tem 3 canais, convertemos para cinza com pesos baseados na sensibilidade visual humana:

$$\text{Cinza} = 0.2989 \cdot R + 0.5870 \cdot G + 0.1140 \cdot B$$

Canal	Peso	Motivo
Vermelho (R)	0.2989	Menor sensibilidade do olho humano
Verde (G)	0.5870	Maior sensibilidade — o olho é mais sensível ao verde
Azul (B)	0.1140	Menor contribuição à luminosidade percebida

Com isso: RGB (3 matrizes) → Cinza (1 matriz) → SVD aplicado diretamente.
O resultado: compressão sem perda perceptível de qualidade.

Compressão de Imagem com SVD

```r
# Criar as matrizes de cada canal RGB
R <- matrix(c(200, 120, 80, 90), nrow=2, byrow=TRUE)
G <- matrix(c(50, 200, 100, 30), nrow=2, byrow=TRUE)
B <- matrix(c(30, 150, 255, 200), nrow=2, byrow=TRUE)
```

Compressão de Imagem com SVD

```
A = matrix(c(92.55,170.37,111.68,67.31), nrow = 2, byrow = T)
A
```

```
##          [,1]   [,2]
## [1,]  92.55 170.37
## [2,] 111.68  67.31
```

Compressão de Imagem com SVD

Passo	Operação	Resultado / Status
1	Calcular a matriz de covariância AA^T	
2	$\det(AA^T - \lambda I) = 0$ (Bhaskara)	
3	Valores Singulares $\sigma_i = \sqrt{\lambda_i}$	
4	$(AA^T - \lambda_i I)\mathbf{u} = 0$ + normalização	
5	$\mathbf{v}_i = A^T\mathbf{u}_i \,/\, \sigma_i$	
6	Montar Decomposição $A = U\Sigma V^T$	
7	Aproximação Posto 1: $A_1 = \sigma_1 \mathbf{u}_1 \mathbf{v}_1^T$	

O que significa k?

k é o número de componentes singulares mantidos na reconstrução.

k	Qualidade	Tamanho
10	Baixa — silhuetas visíveis	Muito pequeno
50	Boa — detalhes moderados	Médio
100	Alta — quase indistinguível	Grande
$\min(m, n)$	Original	Original

O número máximo de componentes é $k_{\max} = \min(m, n)$, posto da matriz.

Variância explicada pelos primeiros k componentes:

$$\text{VE}(k) = \frac{\sum_{i=1}^{k} \sigma_i^2}{\sum_{i=1}^{r} \sigma_i^2}$$

Na prática, $k = 50$ costuma capturar > 90% da variância de uma imagem típica.

Vamos para o R



Parte 2

Análise de Correspondência (CA)

Do qui-quadrado ao mapa geométrico

A pergunta que a CA responde

Imagine que você aplicou um questionário com perguntas categóricas — faixa etária, preferência de produto, região — e quer entender como essas categorias se relacionam.

O que o qui-quadrado faz:

- ✓ Diz se há associação
- ✓ Dá um valor-p
- ✗ Não diz onde está a associação
- ✗ Não diz quais categorias se atraem
- ✗ Não funciona com tabelas grandes

O que a CA faz:

- ✓ Transforma a tabela em um mapa
- ✓ Categorias próximas → perfis semelhantes
- ✓ Categorias afastadas → perfis contrastantes
- ✓ Mede quanto cada dimensão explica

Tabela de Contingência: Base da CA

Uma tabela de contingência registra as frequências conjuntas entre categorias de duas variáveis:

	C_1	C_2	$\dots$	C_j	Total
R_1	n_{11}	n_{12}	$\dots$	n_{1j}	T_1
R_2	n_{21}	n_{22}	$\dots$	n_{2j}	T_2
$\vdots$	$\vdots$	$\vdots$	$\ddots$	$\vdots$	$\vdots$
Total	T'_1	T'_2	$\dots$	T'_j	N

Pergunta: as frequências observadas O_{ij} diferem das esperadas sob independência?

$$E_{ij} = \frac{T_i \cdot T'_j}{N}$$

Se diferem sistematicamente → há associação → a CA vai mapear essa estrutura.

Qui-Quadrado: Revisão Rápida

$$\chi^2 = \sum_{i,j} \frac{(O_{ij} - E_{ij})^2}{E_{ij}}$$

- H_0: variáveis independentes — $f_{ij} = f_{i\cdot} f_{\cdot j}$
- H_1: existe associação
- Se $p < \alpha$: rejeitamos $H_0 \rightarrow$ há associação

O qui-quadrado para por aqui. A CA vai além.

V de Cramer —> intensidade da associação (0 a 1):

$$V = \sqrt{\frac{\chi^2}{N \times (\min(r, c) - 1)}}$$

O qui-quadrado + V de Cramer dizem se e o quanto.
O mapa da CA diz como as categorias se organizam.

Da Tabela ao Mapa: A Matemática da CA

Passo 1. Construir a matriz de desvios da independência, ponderados pelos marginais:

$$S = D_r^{-1/2} \underbrace{(P - rc^T)}_{\text{desvios da independência}} D_c^{-1/2}$$

onde $P = [n_{ij}/N]$, r (linhas) e c (colunas) são os vetores de proporções marginais,
e D_r, D_c são matrizes diagonais dessas proporções.

Passo 2. Aplicar o SVD sobre S:

$$S = U\Sigma V^T$$

Passo 3. Usar os vetores singulares como coordenadas do mapa.

A CA é o SVD aplicado sobre os desvios da independência.
Não é um método separado; é o mesmo instrumento em outro contexto.

Vamos para o quadro

Tabela

Tabela de contingência Feijão × Carne (16 consumidores):

	Carne: Não	Carne: Sim	Total
Feijão: Não	0	6	6
Feijão: Sim	7	3	10
Total	7	9	16

Construindo S: Passo a Passo no Exemplo

Com a tabela Feijão × Carne ($N = 16$):

① Frequências relativas

$$P = \frac{n}{16} = \begin{bmatrix} 0 & 0.375 \\ 0.4375 & 0.1875 \end{bmatrix}$$

② Marginais

$$r = \begin{bmatrix} 0.375 \\ 0.625 \end{bmatrix} \quad c = \begin{bmatrix} 0.4375 \\ 0.5625 \end{bmatrix}$$

③ Modelo de independência

$$rc^T = \begin{bmatrix} 0.164 & 0.211 \\ 0.273 & 0.352 \end{bmatrix}$$

④ Desvios *(cada linha e coluna somam zero)*

$$P - rc^T = \begin{bmatrix} -0.164 & 0.164 \\ 0.164 & -0.164 \end{bmatrix}$$

⑤ Ponderação $D_r^{-1/2} = \mathrm{diag}(1.633,\ 1.265)$, $D_c^{-1/2} = \mathrm{diag}(1.512,\ 1.333)$

⑥ Resultado

$$S = \begin{bmatrix} -0.405 & 0.357 \\ 0.314 & -0.277 \end{bmatrix}$$

Construindo S: Passo a Passo no Exemplo

SVD de S: $\sigma_1 = 0.683, \sigma_2 = 0 \rightarrow$ Inércia total $= 0.683^2 = 0.467 = \chi^2/16$ ✓
O cálculo completo fica no roteiro do quadro.

Inércia: A Variância da CA

A inércia total é a variância dos dados categóricos, análoga à variância total do PCA:

$$\text{Inércia total} = \sum_i \sum_j \frac{(p_{ij} - r_i c_j)^2}{r_i c_j} = \sum_k \lambda_k^2 = \frac{\chi^2}{N}$$

Onde $\lambda_k = \sigma_k$ são os valores singulares de S.

Inércia da dimensão k: λ_k^2
→ fração da associação total explicada pelo eixo k

Inércia acumulada (2D): $(\lambda_1^2 + \lambda_2^2)/\text{total}$
→ qualidade do mapa bidimensional

Analogia direta com o PCA:

PCA	CA
Variância total	Inércia total
Autovalores	λ_k^2
% variância explicada	% inércia explicada
Scree plot	Scree de inércias

Exemplo CA: Dados de Consumo

Dados de 16 consumidores com 4 variáveis binárias (Sim/Não):
Arroz, Feijão, Carne, Cerveja.

```
library(FactoMineR); library(factoextra); library(DescTools)

dados_marketing <- data.frame(
  consumidor = c('A','B','C','D','E','F','G','H',
                 'I','J','K','L','M','N','O','P'),
  Arroz    = c('Sim','Nao','Sim','Sim','Nao','Sim','Nao','Sim',
               'Nao','Sim','Sim','Nao','Sim','Nao','Sim','Sim'),
  Feijao   = c('Nao','Sim','Sim','Nao','Sim','Nao','Sim','Sim',
               'Sim','Sim','Nao','Sim','Nao','Sim','Sim','Nao'),
  Carne    = c('Sim','Sim','Nao','Sim','Nao','Sim','Sim','Nao',
               'Nao','Nao','Sim','Sim','Sim','Nao','Nao','Sim'),
  Cerveja = c('Nao','Nao','Sim','Sim','Sim','Nao','Nao','Sim',
               'Nao','Nao','Sim','Sim','Sim','Nao','Nao','Sim')
)
```

Tabela de Contingência: Feijão × Carne

```
tab <- table(dados_marketing$Feijao, dados_marketing$Carne)
colnames(tab) <- c("Carne: Não", "Carne: Sim")
rownames(tab) <- c("Feijão: Não", "Feijão: Sim")
tab
```

```
##
##                Carne: Não Carne: Sim
##   Feijão: Não           0          6
##   Feijão: Sim           7          3
```

	Carne: Não	Carne: Sim	Total
Feijão: Não	0	6	6
Feijão: Sim	7	3	10
Total	7	9	16

Há 0 casos de Feijão Não + Carne Não, padrão de substituição claro.

Observado vs. Esperado

$$E_{ij} = \frac{\text{Total linha}_i \times \text{Total coluna}_j}{N}$$

$$E_{11} = \frac{6 \times 7}{16} = 2{,}625 \qquad E_{12} = \frac{6 \times 9}{16} = 3{,}375 \qquad E_{21} = \frac{10 \times 7}{16} = 4{,}375 \qquad E_{22} = \frac{10 \times 9}{16} = 5{,}625$$

	Carne: Não	Carne: Sim
Feijão: Não	0 *(esp. 2,6)*	6 *(esp. 3,4)*
Feijão: Sim	7 *(esp. 4,4)*	3 *(esp. 5,6)*

Olhar para a célula Feijão:Não + Carne:Não, observamos 0, esperaríamos 2,6.
E Feijão:Não + Carne:Sim, observamos 6, esperaríamos apenas 3,4.
O padrão de substituição já aparece antes de qualquer cálculo.

Qui-Quadrado: Contribuição de Cada Célula

$$\chi^2 = \sum_{i,j} \frac{(O_{ij} - E_{ij})^2}{E_{ij}}$$

Célula	O	E	$(O-E)^2/E$
Feijão:Não × Carne:Não	0	2,625	$(0-2{,}625)^2/2{,}625 = \mathbf{2{,}625}$
Feijão:Não × Carne:Sim	6	3,375	$(6-3{,}375)^2/3{,}375 = \mathbf{2{,}042}$
Feijão:Sim × Carne:Não	7	4,375	$(7-4{,}375)^2/4{,}375 = \mathbf{1{,}575}$
Feijão:Sim × Carne:Sim	3	5,625	$(3-5{,}625)^2/5{,}625 = \mathbf{1{,}225}$
Total			$\chi^2 = \mathbf{7{,}47}$

A maior contribuição vem da célula Feijão:Não + Carne:Não, nenhum consumidor abre mão das duas ao mesmo tempo.

Decisão, V de Cramér e Interpretação

Decisão do teste ($df = 1, \alpha = 0{,}05$):

χ^2 calculado	7,47
χ^2 crítico	3,84
p-valor	0,006

$7{,}47 > 3{,}84 \rightarrow$ rejeitamos H_0

Decisão, V de Cramér e Interpretação

Interpretação:

✓ Há associação significativa entre Feijão e Carne ($p = 0{,}006$)

✓ A associação é forte ($V = 0{,}68$)

→ Quem não compra feijão tende a comprar carne (6 de 6)

→ Quem compra feijão tende a não comprar carne (7 de 10)

Conclusão: feijão e carne competem e existe um padrão de substituição.

V de Cramér

intensidade:

$$V = \sqrt{\frac{\chi^2}{N \times \min(r-1, c-1)}} = \sqrt{\frac{7{,}47}{16}} = \mathbf{0{,}68}$$

V	Associação
< 0,10	Negligenciável
0,10–0,30	Fraca
0,30–0,50	Moderada
> 0,50	Forte ✓

Correção de Yates: Por que o R avisa?

Ao rodar `chisq.test()` sem argumentos, o R aplica automaticamente a correção de Yates:

$$\chi^2_{\text{Yates}} = \sum_{i,j} \frac{\left(|O_{ij} - E_{ij}| - 0{,}5\right)^2}{E_{ij}}$$

Motivação: o qui-quadrado usa distribuição contínua para aproximar dados discretos.
Em amostras pequenas, isso superestima χ^2 → mais falsos positivos.

Regra prática:

- $N < 40$ ou alguma $E_{ij} < 5$ → use a correção
- $N \geq 40$ e todas $E_{ij} \geq 5$ → correção é desnecessária

No nosso exemplo: $N = 16 < 40$ → correção seria recomendada.
Desativamos (`correct = FALSE`) apenas para que os cálculos manuais e o R coincidam.

O Lugar da CA no Aprendizado Não Supervisionado

A CA não é um método à parte, é a mesma operação do SVD, aplicada a dados categóricos.

Pergunta	Dados	Matriz decomposta	Método
Estrutura de variação	Numéricos	Covariância $\mathbf{X}^T\mathbf{X}$	PCA
Associação entre categorias	Categóricos	Desvios da independência S	CA / MCA
Estrutura não linear	Numéricos	Kernel $K(\mathbf{x}_i, \mathbf{x}_j)$	Kernel PCA

Instrumento: SVD, em todos os casos.
O que muda: a matriz que decompomos e a pergunta que fazemos.

CA → Clustering: os escores da CA podem ser usados como input direto para K-means ou agrupamento hierárquico, exatamente como os escores do PCA.

Resumo Final

O que Vimos Hoje

SVD

- $\mathbf{A} = \mathbf{U}\Sigma\mathbf{V}^T$ — duas rotações + escalonamento
- Teorema de Eckart-Young — melhor aproximação de posto k
- Variância explicada — como escolher k
- Compressão de imagem como aplicação concreta

CA

- CA = SVD sobre $S = D_r^{-1/2}(P - rc^T)D_c^{-1/2}$
- Inércia = variância dos dados categóricos = χ^2/N
- MCA estende para múltiplas variáveis
- CA é o PCA do mundo categórico

A mensagem central: SVD, PCA, CA, MCA, Kernel PCA, são todos instâncias do mesmo princípio: encontrar as direções privilegiadas de variação de uma matriz.

Referências

- Eckart & Young (1936). The approximation of one matrix by another of lower rank. *Psychometrika*.
- Benzécri (1973). *L'Analyse des Données*. Dunod, Paris.
- Greenacre (2007). *Correspondence Analysis in Practice*. Chapman & Hall/CRC.
- Husson, Lê & Pagès (2017). *Exploratory Multivariate Analysis by Example Using R*. CRC Press.
- Hastie, Tibshirani & Friedman (2009). *The Elements of Statistical Learning*. Springer.
- Ara & Melo (2026). *Aprendizado Não Supervisionado*. UFPR — ebook da disciplina CE318.

Pacotes R utilizados: `FactoMineR`, `factoextra`, `DescTools`, `jpeg`, `xaringanthemer`