APRENDIZADO NÃO SUPERVISIONADO



Profa. Tatiane F. Ribeiro | Prof. Bruno Melo | Prof. Anderson Ara

Slide 05

Revisão: Autovalores, Autovetores e SVD

Autovalores e Autovetores

Definição (Johnson & Wichern, 2013, Cap. 2):

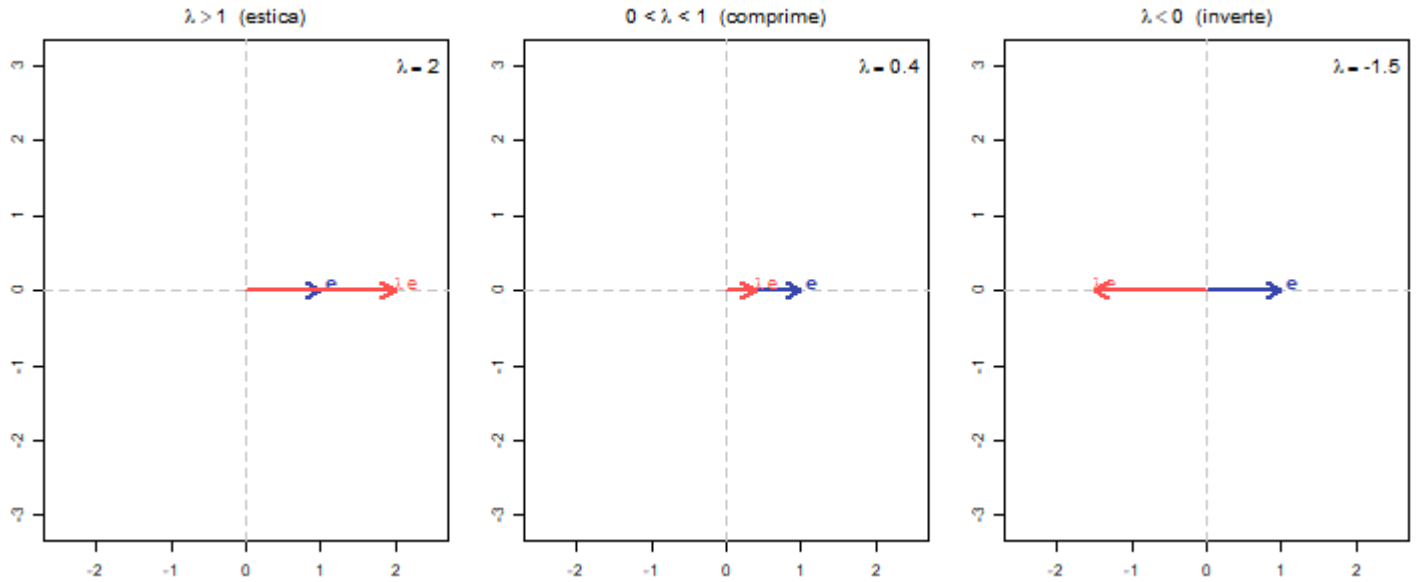
Seja $\mathbf{A}$ uma matriz quadrada $p \times p$. Um escalar λ e um vetor não-nulo $\mathbf{e}$ são chamados, respectivamente, de autovalor e autovetor de $\mathbf{A}$ se:

$$\mathbf{A}\,\mathbf{e} = \lambda\,\mathbf{e}$$

Interpretação geométrica:

- $\mathbf{e}$ aponta uma direção invariante: a transformação $\mathbf{A}$ apenas escala o vetor, sem mudar sua direção.
- λ é o fator de escala:
  - $\lambda > 1$: o vetor é esticado
  - $0 < \lambda < 1$: o vetor é comprimido
  - $\lambda < 0$: o vetor tem seu sentido invertido

Visualizando o efeito de λ



> O autovetor $\mathbf{e}$ (azul) e o vetor transformado $\lambda\mathbf{e}$ (vermelho) sempre apontam na mesma reta, independentemente do valor de λ.

Por que usamos $\det(\mathbf{A} - \lambda\mathbf{I}) = 0$?

A equação $\mathbf{Ae} = \boldsymbol{\lambda}\mathbf{e}$ pode ser reescrita como um sistema homogêneo:

$$(\mathbf{A} - \lambda\mathbf{I})\,\mathbf{e} = \mathbf{0}$$

Quando esse sistema tem solução não trivial ($\mathbf{e} \neq \mathbf{0}$)?

Um resultado fundamental de Álgebra Linear diz que o sistema $\mathbf{Mx} = \mathbf{0}$ tem solução $\mathbf{x} \neq \mathbf{0}$ se, e somente se, $\mathbf{M}$ é singular.

O que significa ser singular? Uma matriz é singular quando:

- não tem inversa
- suas linhas (ou colunas) são linearmente dependentes
- e, principalmente: seu determinante é zero

Portanto, λ é autovalor de $\mathbf{A}$ se, e somente se, subtrair λ da diagonal de $\mathbf{A}$ torna essa matriz singular: $\det(\mathbf{A} - \lambda\,\mathbf{I}) = 0 \qquad (\text{equação característica})$

Calculando autovalores: exemplo numérico

(Johnson & Wichern, 2013, p. 100) Seja $\mathbf{A} = \begin{bmatrix} 2{,}2 & 0{,}4 \\ 0{,}4 & 2{,}8 \end{bmatrix}$

Passo 1. Montar $(\mathbf{A} - \lambda\mathbf{I})$ e igualar seu determinante a zero:

$$\det \begin{bmatrix} 2{,}2 - \lambda & 0{,}4 \\ 0{,}4 & 2{,}8 - \lambda \end{bmatrix} = 0$$

$$\Rightarrow (2{,}2 - \lambda)(2{,}8 - \lambda) - (0{,}4)^2 = 0$$

$$\Rightarrow \lambda^2 - 5\lambda + 6{,}16 - 0{,}16 = (\lambda - 3)(\lambda - 2) = 0$$

Passo 2. Resolver: $\lambda_1 = 3$ e $\lambda_2 = 2$.

Calculando autovetores: exemplo numérico (cont.)

Passo 3. Para cada λ_i, resolver $(\mathbf{A} - \lambda_i \mathbf{I})\,\mathbf{e}_i = \mathbf{0}$:

Para $\lambda_1 = 3$:

$$(\mathbf{A} - 3\mathbf{I})\,\mathbf{e}_1 = \begin{bmatrix} -0{,}8 & 0{,}4 \\ 0{,}4 & -0{,}2 \end{bmatrix} \mathbf{e}_1 = \mathbf{0}$$

A 1ª linha fornece: $-0{,}8\,e_{11} + 0{,}4\,e_{12} = 0 \;\Rightarrow\; e_{12} = 2\,e_{11}$

Escolhendo $e_{11} = 1$, temos $\mathbf{e}_1 \propto (1,\, 2)'$. Normalizando:

$$\mathbf{e}_1 = \frac{1}{\sqrt{5}} \begin{bmatrix} 1 \\ 2 \end{bmatrix} \approx \begin{bmatrix} 0{,}447 \\ 0{,}894 \end{bmatrix}$$

Calculando autovetores: exemplo numérico (cont.)

Para $\lambda_2 = 2$:

$$(\mathbf{A} - 2\mathbf{I})\,\mathbf{e}_2 = \begin{bmatrix} 0{,}2 & 0{,}4 \\ 0{,}4 & 0{,}8 \end{bmatrix} \mathbf{e}_2 = \mathbf{0}$$

A 1ª linha fornece: $0{,}2\,e_{21} + 0{,}4\,e_{22} = 0 \;\Rightarrow\; e_{22} = -\frac{1}{2}\,e_{21}$

Escolhendo $e_{21} = 2$, temos $\mathbf{e}_2 \propto (2,\, -1)'$. Normalizando:

$$\mathbf{e}_2 = \frac{1}{\sqrt{5}} \begin{bmatrix} 2 \\ -1 \end{bmatrix} \approx \begin{bmatrix} 0{,}894 \\ -0{,}447 \end{bmatrix}$$

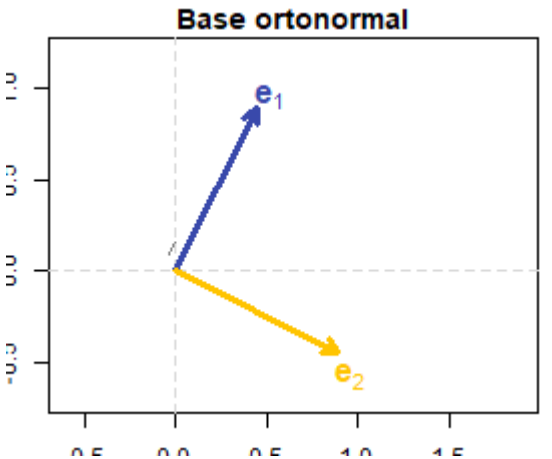
Verifique: $\mathbf{e}_1'\mathbf{e}_2 = \frac{1}{5}(1 \cdot 2 + 2 \cdot (-1)) = 0$; os autovetores são ortogonais.

Base Ortonormal e Propriedades para Matrizes Simétricas

Para matrizes simétricas como $\boldsymbol{\Sigma}$ e $\mathbf{S}$ (Johnson & Wichern, 2013):

1. Autovalores são números reais.
2. Autovetores de autovalores distintos são ortogonais: $\mathbf{e}_i'\mathbf{e}_k = 0$.
3. Matrizes positivas semidefinidas têm $\lambda_i \geq 0$.

Base ortonormal: cada vetor tem norma 1 e são perpendiculares entre si. Formam os eixos dos componentes principais.



Decomposição Espectral

Resultado 2A.14 (Johnson & Wichern, 2013, p. 100): Seja $\mathbf{A}$ uma matriz simétrica $p \times p$ com pares autovalor-autovetor $(\lambda_i, \mathbf{e}_i)$. Então:

$$\mathbf{A} = \sum_{i=1}^{p} \lambda_i \, \mathbf{e}_i \mathbf{e}_i' = \mathbf{E} \, \mathbf{\Lambda} \, \mathbf{E}'$$

onde $\mathbf{E} = [\mathbf{e}_1, \ldots, \mathbf{e}_p]$ é ortogonal e $\mathbf{\Lambda} = \mathbf{diag}(\lambda_1, \ldots, \lambda_p)$.

Conexão com PCA:

- Decompor $\mathbf{\Sigma} = \mathbf{E\Lambda E}'$ equivale a encontrar as direções de máxima variância (autovetores) e as variâncias associadas (autovalores).
- Cada coluna de $\mathbf{E}$ define um componente principal.

Decomposição em Valores Singulares (SVD)

Resultado 2A.15 (Johnson & Wichern, 2013, p. 100-101): Seja $\mathbf{A}$ uma matriz $m \times k$ de números reais. Então existem matrizes ortogonais $\mathbf{U}_{(m\times m)}$ e $\mathbf{V}_{(k\times k)}$ tais que:

$$\mathbf{A} = \mathbf{U}\ \mathbf{\Lambda}\ \mathbf{V}'$$

onde $\mathbf{\Lambda}_{(m\times k)}$ tem entradas $\lambda_i \geq 0$ (chamadas valores singulares) na diagonal.

- $\mathbf{U}$: autovetores de $\mathbf{A}\mathbf{A}'$; direções no espaço das observações
- $\mathbf{V}$: autovetores de $\mathbf{A}'\mathbf{A}$; direções no espaço das variáveis
- $\lambda_i = \sqrt{\gamma_i}$, onde γ_i são os autovalores de $\mathbf{A}'\mathbf{A}$

SVD e sua Conexão com PCA

Seja $\mathbf{X}_c$ a matriz de dados centrada ($n \times p$). Pela SVD: $\mathbf{X}_c = \mathbf{U}\,\mathbf{D}\,\mathbf{V}'$

A matriz de covariância amostral é:

$$\mathbf{S} = \frac{1}{n-1}\mathbf{X}_c'\mathbf{X}_c = \frac{1}{n-1}\,\mathbf{V}\,\mathbf{D}^2\,\mathbf{V}'$$

Objeto	Interpretação	Origem na SVD
Loadings	autovetores de $\mathbf{S}$	colunas de $\mathbf{V}$
Escores	coordenadas das obs. nos PCs	$\mathbf{UD}$
Autovalores de $\mathbf{S}$	variância de cada PC	$d_i^2/(n-1)$

Em R, `prcomp()` usa SVD internamente ; numericamente mais estável do que decompor $\mathbf{S}$ diretamente.

De onde viemos... e para onde vamos

Com a base construída na aula anterior:

- Autovalores e autovetores identificam as direções que mais importam em uma transformação linear.
- A decomposição espectral de $\boldsymbol{\Sigma}$ revela essas direções e a variância carregada em cada uma.
- A SVD generaliza essa ideia para qualquer matriz retangular de dados.

Nessa aula, aplicamos tudo isso em um método muito utilizado no aprendizado não supervisionado:

> Análise de Componentes Principais (PCA)

A PCA usa a decomposição espectral de $\boldsymbol{\Sigma}$ para encontrar um novo sistema de coordenadas que resume os dados com o menor número possível de dimensões, preservando o máximo de variância.

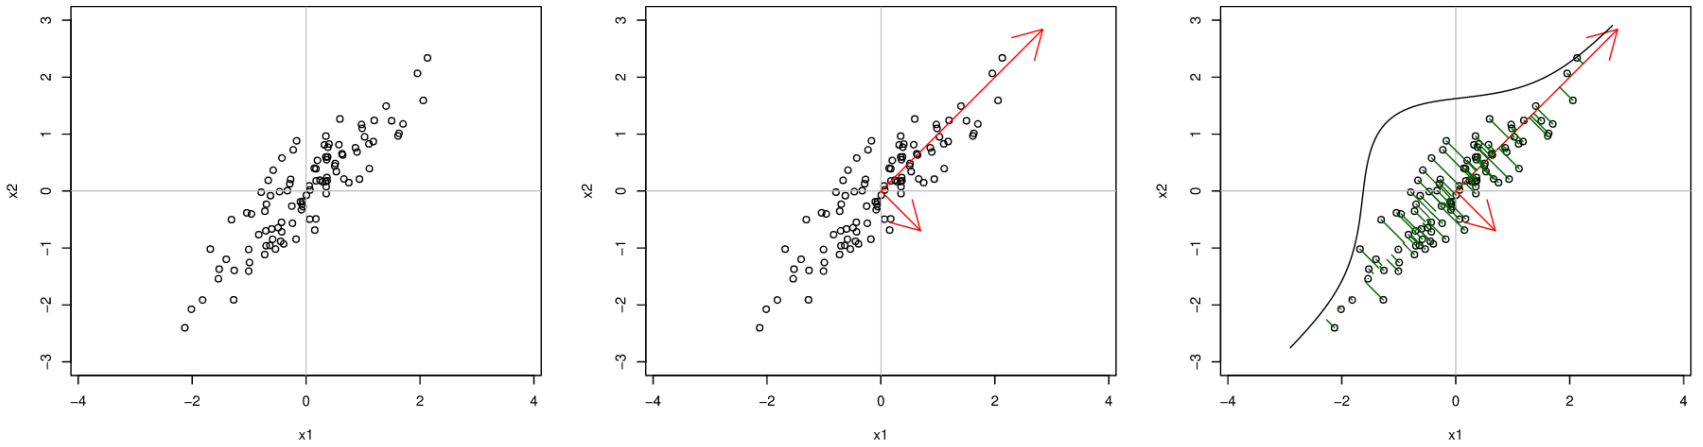
Análise de Componentes Principais (PCA)

PCA

- O PCA é uma ferramenta tradicional da estatística multivariada.
- Inventado em 1901 por Karl Pearson.
- Popularizado por Harold Hotelling em 1933.
- Técnica estatística que busca explicar a estrutura de variância e covariância de um conjunto de variáveis por meio de um pequeno número de combinações lineares dessas variáveis (Johnson & Wichern, 2013).
- Seus objetivos gerais são:

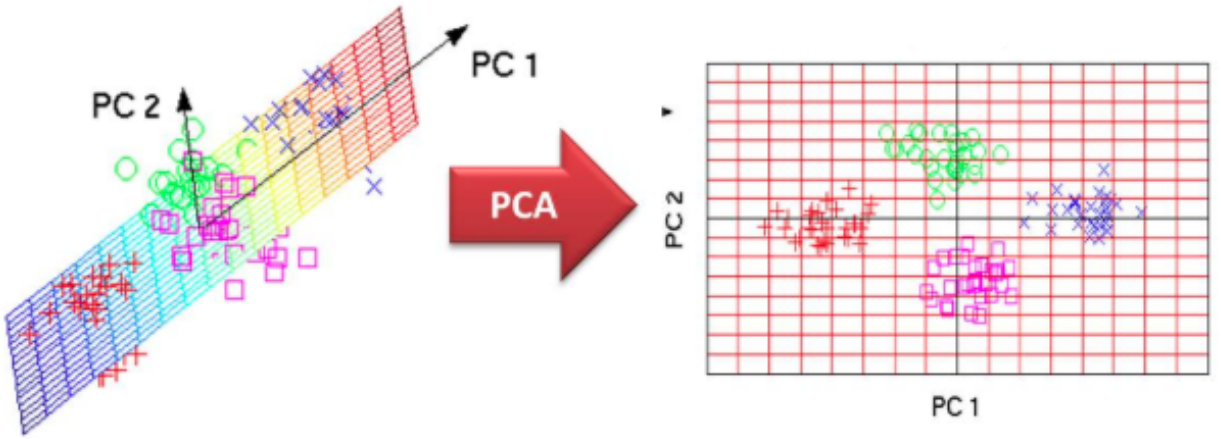
    1. redução de dimensionalidade e
    2. interpretação.

PCA



Fonte: A autora.

PCA



PCA

Fonte: Google images.

Análise de Componentes Principais

- Ideia: representar os dados em um novo sistema de coordenadas, formado por combinações lineares não correlacionadas das variáveis originais;
  - cada nova variável é chamada de componente principal;
  - reduzir a dimensionalidade, mantendo o máximo possível da variância total dos dados;
  - identificar direções principais (componentes) ao longo das quais as observações mais variam.

Intuição geométrica

- Cada componente principal é uma direção ortogonal no espaço dos dados;
- O primeiro componente é a direção de maior variância;
- O segundo componente é ortogonal ao primeiro e explica a maior variância remanescente;
- E assim por diante, até o i-ésimo componente.
- Assim, os dados são projetados em um subespaço de menor dimensão que preserva a estrutura essencial.

> Aplicações: compressão de dados, visualização em 2D/3D, pré-processamento para aprendizado de máquina.

Os componentes principais

Os componentes principais dependem unicamente da matriz de covariância Σ (ou da matriz de correlação ρ) das variáveis $X_1, X_2, \ldots, X_p$.

É necessário supor normalidade dos dados?

- O desenvolvimento não exige normalidade multivariada.
- Se a população for normal multivariada:
  - Os componentes principais têm interpretações úteis em termos de elipsóides de densidade constante.
  - Também permitem inferências baseadas nos componentes amostrais (ver Johnson & Wichern (2013), Seção 8.5).

Os componentes principais

Seja o vetor aleatório:

$$X' = [\, X_1, \ldots, X_p \,]$$

com matriz de covariância Σ.

- A matriz Σ possui autovalores:

$$\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_p \geq 0.$$

- Por que?
  - Σ é positiva semidefinida $(w'\Sigma w \geq 0 \quad \textbf{para todo } w \in \mathbb{R}^p)$.

Os componentes principais

Considere as combinações lineares:

$$\begin{aligned} Y_1 = \mathbf{a}_1'\mathbf{X} &= a_{11}X_1 + a_{12}X_2 + \cdots + a_{1p}X_p \\ &\vdots \\ Y_p = \mathbf{a}_p'\mathbf{X} &= a_{p1}X_1 + a_{p2}X_2 + \cdots + a_{pp}X_p \end{aligned} \tag{1}$$

Então, temos que:

$$\mathrm{Var}(Y_i) = \mathbf{a}_i' \, \mathbf{\Sigma} \, \mathbf{a}_i, \qquad i = 1, 2, \ldots, p \tag{2}$$

$$\mathrm{Cov}(Y_i, \, Y_k) = \mathbf{a}_i' \, \mathbf{\Sigma} \, \mathbf{a}_k, \qquad i, k = 1, 2, \ldots, p \tag{3}$$

As componentes principais são as combinações lineares $Y_1, \ldots, Y_p$ não correlacionadas, e possuem variância (2) o maior possível.

Procedimento

- O primeiro componente principal é definido como a combinação linear das variáveis $\mathbf{X}$ que maximiza a variância dos dados projetados, sujeita à restrição de que o vetor de pesos tenha norma unitária.
- Primeiro PC: é a combinação linear $\mathbf{a}_1'\mathbf{X}$ que maximiza

$$\mathrm{Var}(\mathbf{a}_1'\mathbf{X}) = \mathbf{a}_1'\Sigma\mathbf{a}_1$$

sujeita à restrição

$$\mathbf{a}_1'\mathbf{a}_1 = 1.$$

- Segundo PC: é a combinação linear $\mathbf{a}_2'\mathbf{X}$ que maximiza

$$\mathrm{Var}(\mathbf{a}_2'\mathbf{X}) = \mathbf{a}_2'\Sigma\mathbf{a}_2$$

sujeita a

$$\mathbf{a}_2'\mathbf{a}_2 = 1, \quad \mathrm{Cov}(\mathbf{a}_1'\mathbf{X}, \mathbf{a}_2'\mathbf{X}) = \mathbf{a}_1'\Sigma\mathbf{a}_2 = 0.$$

- i-ésimo PC: é a combinação linear $\mathbf{a}_i'\mathbf{X}$ que maximiza

Definimos $\mathbf{a}_i$ como o vetor que maximiza

$$\mathrm{Var}(\mathbf{a}_i'\mathbf{X}) = \mathbf{a}_i'\Sigma\mathbf{a}_i$$

sujeito a

$$\mathbf{a}_i'\mathbf{a}_i = 1, \quad \mathbf{a}_i'\Sigma\mathbf{a}_k = 0 \ \text{ para } k < i.$$

Como obter os PC?

Como obter os PC?

- A solução do problema de otimização pode ser obtida usando multiplicadores de Lagrange.
- Aplicando o método dos multiplicadores de Lagrange:

$$L(\mathbf{a}, \lambda) = \mathbf{a}^\top \Sigma \mathbf{a} - \lambda(\mathbf{a}^\top \mathbf{a} - 1)$$

Condição de otimalidade:

$$\frac{\partial L}{\partial \mathbf{a}} = 2\Sigma\mathbf{a} - 2\lambda\mathbf{a} = \mathbf{0}$$

Logo:

$$\Sigma\mathbf{a} = \lambda\mathbf{a}$$

- Ou seja, $\mathbf{a}$ é um autovetor de $\mathbf{\Sigma}$ e λ é o autovalor correspondente.

Resultados: autovalores e autovetores de Σ

> Proposição 1: Sejam os pares dos autovalores–autovetores $(\lambda_1, \mathbf{e}_1), (\lambda_2, \mathbf{e}_2), \ldots, (\lambda_p, \mathbf{e}_p)$ de Σ, onde
>
> $$\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_p \geq 0.$$
>
> Então, o i-ésimo PC é dada por:
>
> $$Y_i = \mathbf{e}_i'\mathbf{X} = e_{i1}X_1 + \cdots + e_{ip}X_p, \quad i = 1, 2, \ldots, p.$$

> Com essa definição, temos:
>
> $$\mathrm{Var}(Y_i) = \mathbf{e}_i'\Sigma\mathbf{e}_i = \lambda_i, \quad j = 1, \ldots, p, \quad \text{e} \quad \mathrm{Cov}(Y_i, Y_k) = \mathbf{e}_i'\Sigma\mathbf{e}_k = 0, \quad \forall\, j \neq k.$$
>
> Se alguns λ_i forem iguais, as escolhas dos vetores de coeficientes correspondentes, $\mathbf{e}_i$, e, portanto, de Y_i, não são únicas.

Ou seja os PC são não correlacionados e têm variâncias iguais aos autovalores de Σ.

Resultados: autovalores e autovetores de Σ

- Decomposição espectral de $\boldsymbol{\Sigma}$:

$$\Sigma = E\Lambda E',$$

onde $E = [\mathbf{e}_1, \ldots, \mathbf{e}_p]$ é a matriz cujas colunas são os autovetores de Σ e $\Lambda = \mathbf{diag}(\lambda_1, \ldots, \lambda_p)$ é a matriz diagonal cujos elementos são os autovalores de Σ.

- Seja $\mathbf{A}$ uma matriz quadrada e simétrica de dimensão $p \times p$.
  Então, existem:
  - uma matriz ortogonal $\mathbf{Q}$, cujas colunas são os autovetores de $\mathbf{A}$;
  - e uma matriz diagonal $\mathbf{\Lambda}$, contendo os autovalores $\lambda_1, \ldots, \lambda_p$;

    tais que:

$$\mathbf{A} = \mathbf{Q}\mathbf{\Lambda}\mathbf{Q}^\top$$

- Cada autovetor $\mathbf{q}_i$ define uma direção principal, e seu autovalor λ_i indica a variância associada a essa direção.

- Na PCA, essa decomposição é aplicada à matriz de covariância dos dados, fornecendo os eixos que maximizam a variância.

Resultados: autovalores e autovetores de Σ

Proposição 2: Seja $\mathbf{X}' = [X_1, X_2, \ldots, X_p]$ com matriz de covariância Σ e pares autovalor–autovetor $(\lambda_1, \mathbf{e}_1), \ldots, (\lambda_p, \mathbf{e}_p)$, onde

$$\lambda_1 \geq \cdots \geq \lambda_p \geq 0.$$

Sejam $Y_1 = \mathbf{e}_1'\mathbf{X}, \quad \ldots, \quad Y_p = \mathbf{e}_p'\mathbf{X}$ os componentes principais.
Então:

$$\sigma_{11} + \sigma_{22} + \cdots + \sigma_{pp} = \sum_{i=1}^{p} \mathrm{Var}(X_i) = \lambda_1 + \lambda_2 + \cdots + \lambda_p = \sum_{i=1}^{p} \mathrm{Var}(Y_i).$$

Proporção da variância total explicada

A variância total (populacional) é

$$\sigma_{11} + \sigma_{22} + \cdots + \sigma_{pp} = \lambda_1 + \lambda_2 + \cdots + \lambda_p$$

Assim, a proporção da variância total explicada pelo i-ésimo PC é

$$\frac{\lambda_i}{\lambda_1 + \lambda_2 + \cdots + \lambda_p}, \quad i = 1, 2, \ldots, p.$$

Interpretação

- Muitas vezes, poucos componentes (por exemplo, 1 a 3) já explicam 80% a 90% da variância total.
- Isso permite redução de dimensionalidade, substituindo as p variáveis originais por um número bem menor de componentes sem perda considerável de informação.
- Os coeficientes e_{ij} são chamados de cargas (loadings):
  - i : índice da variável original X_i
  - j : índice da componente principal Y_j
- A magnitude de e_{ij} (o i-ésimo elemento do autovetor $\mathbf{e}_j$) indica a importância da variável X_i na j-ésima componente principal.
- Em particular, e_{ij} é proporcional à correlação entre X_i e Y_j.

Escala das variáveis

- A matriz de covariâncias e os correspondentes autovalores não são invariantes a mudanças de escala nas variáveis.
- É difícil interpretar os componentes principais quando as variáveis estão em escalas diferentes.
- Uma solução possível é padronizar as variáveis antes de aplicar a PCA.
- Pode-se considerar a transformação z-score, dada por:

$$Z_{ij} = \frac{X_{ij} - \bar{X}_i}{S_i},$$

onde $\bar{X}_i$ e S_i representam média e o desvio padrão da variável X_i.

Quantos componentes principais escolher?

Critérios usuais (com dados padronizados):

- Kaiser: manter PCs com autovalor > 1 (na matriz de correlações).
- Scree plot (cotovelo): ponto onde os autovalores "esticam" → ganho marginal pequeno.
- Variância acumulada: escolher o menor (q) com ≥ 70–90% da variância explicada.

Redução 2D → 1D com PCA

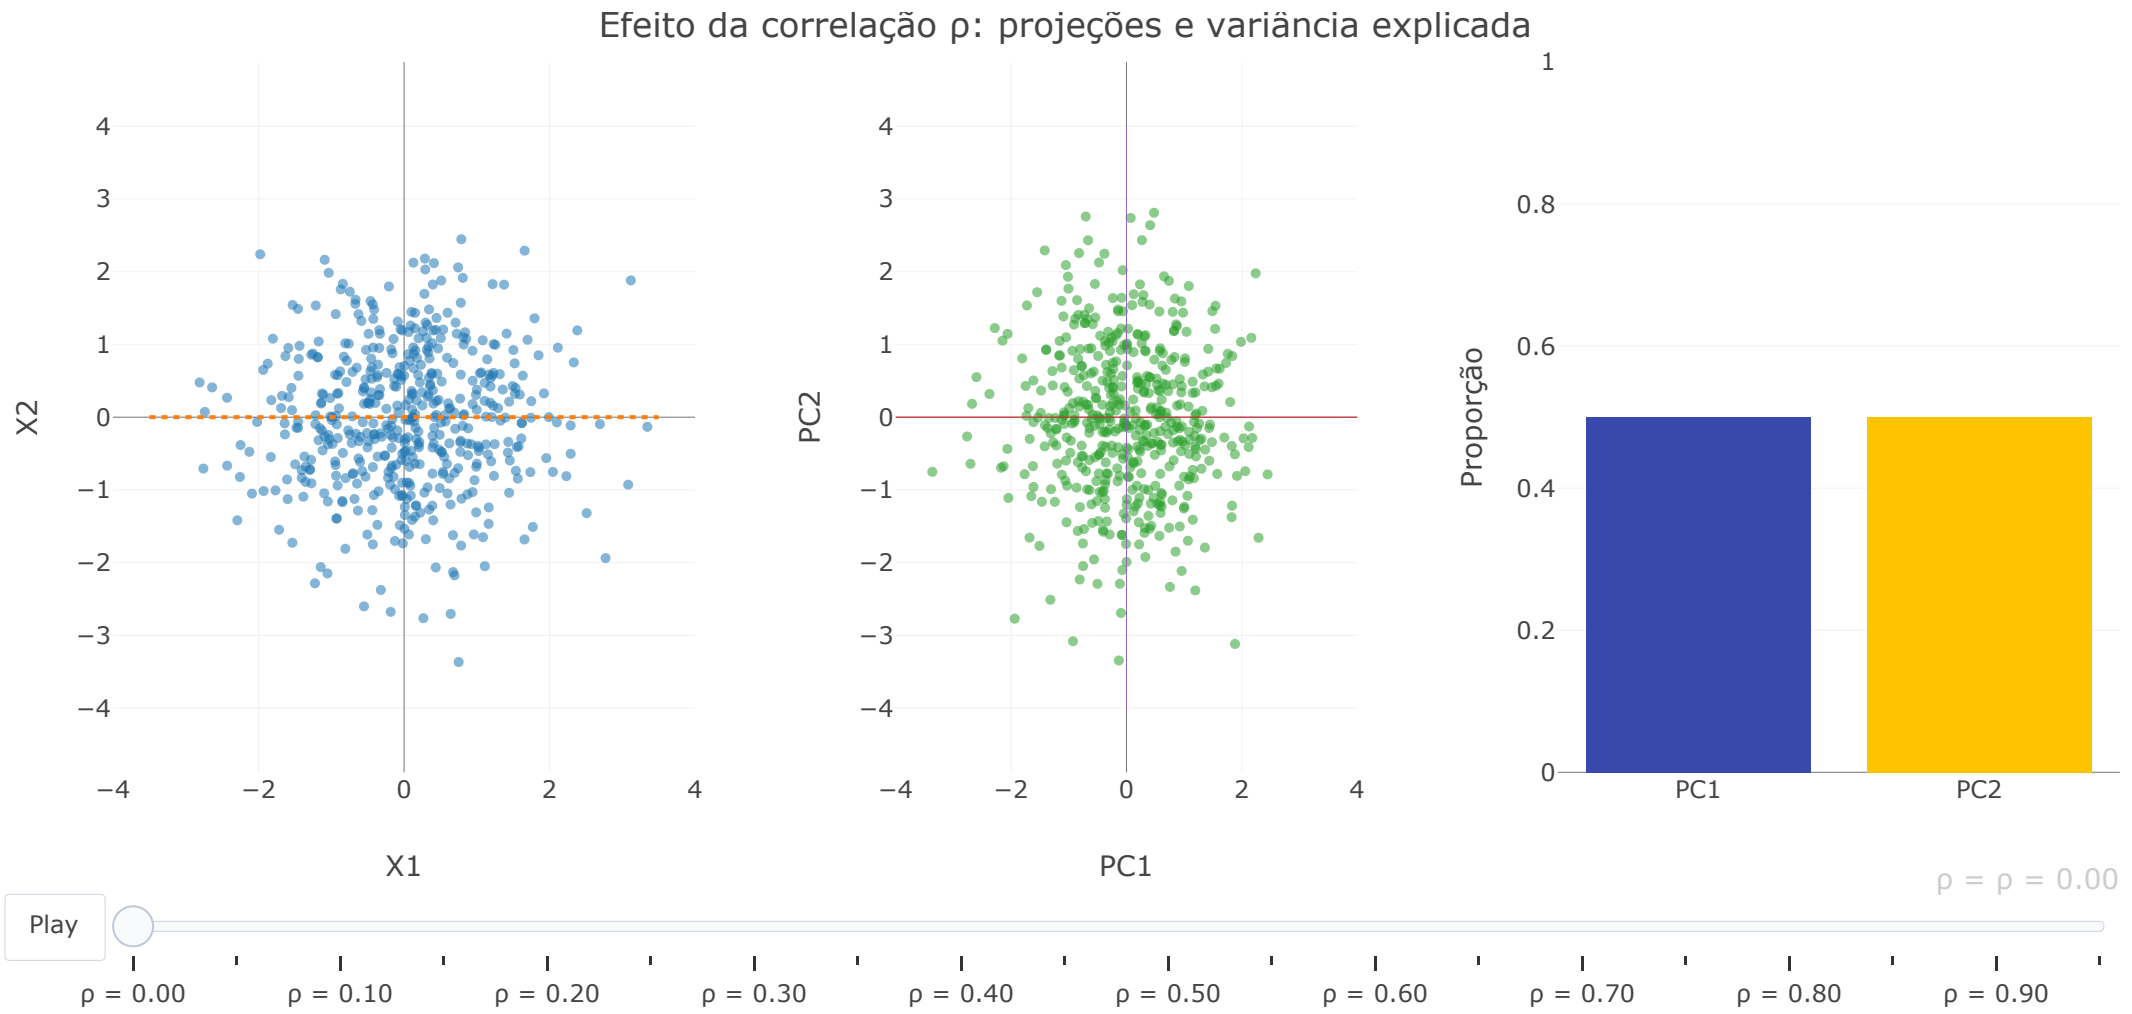
Considere duas variáveis quantitativas X_1 e X_2 com média zero e matriz de covariâncias

$$\Sigma = \begin{bmatrix} 1 & \rho \\ \rho & 1 \end{bmatrix}.$$

Como $\mathbf{Var}(X_1) = \mathbf{Var}(X_2) = 1$, o termo fora da diagonal coincide com a correlação: $\mathbf{Corr}(X_1, X_2) = \rho$.

Atribuiremos diferentes valores para $\rho \in [0, 0.9]$ para representar o grau de associação entre X_1 e X_2.

A seguir, mostramos um gráfico que ilustra a redução de 2D para 1D via PCA: projetamos (X_1, X_2) em PC1. A proporção de variância explicada por PC1 é $\frac{1+\rho}{2}$, e a variância descartada ao eliminar PC2 é $1 - \rho$.


Efeito da correlação ρ: projeções e variância explicada
X2
X1
PC2
PC1
Proporção
PC1
PC2
Play
ρ = ρ = 0.00
ρ = 0.00
ρ = 0.10
ρ = 0.20
ρ = 0.30
ρ = 0.40
ρ = 0.50
ρ = 0.60
ρ = 0.70
ρ = 0.80
ρ = 0.90

Variância explicada por PC1

O objetivo é mostrar que, para o nosso caso, a proporção da variância total explicada pelo primeiro componente principal (PC1) é $\frac{1+\rho}{2}$.

A variância de cada componente principal é dada pelo autovalor correspondente da matriz de covariâncias Σ. Portanto, nosso primeiro passo é encontrar os autovalores de Σ.

1. Ponto de Partida: A Matriz de Covariâncias

Nossa matriz de covariâncias é:

$$\Sigma = \begin{bmatrix} 1 & \rho \\ \rho & 1 \end{bmatrix}.$$

Variância explicada por PC1

2. A Equação Característica

Para encontrar os autovalores (λ), precisamos resolver a equação característica, que é $\det(\Sigma - \lambda I) = 0$, onde I é a matriz identidade.

Primeiro, montamos a matriz $(\Sigma - \lambda I)$:

$$\Sigma - \lambda I = \begin{bmatrix} 1 & \rho \\ \rho & 1 \end{bmatrix} - \lambda \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} = \begin{bmatrix} 1-\lambda & \rho \\ \rho & 1-\lambda \end{bmatrix}$$

Variância explicada por PC1

3. Cálculo do Determinante

Agora, calculamos o determinante desta nova matriz e o igualamos a zero:

$$\det \begin{bmatrix} 1-\lambda & \rho \\ \rho & 1-\lambda \end{bmatrix} = 0$$

$$(1-\lambda)(1-\lambda) - (\rho)(\rho) = 0$$

$$(1-\lambda)^2 - \rho^2 = 0$$

Variância explicada por PC1

4. Resolvendo para λ

Rearranjando a equação, temos uma diferença de quadrados:

$$(1 - \lambda)^2 = \rho^2$$

Tirando a raiz quadrada de ambos os lados, obtemos duas soluções:

$$1 - \lambda = \pm\rho$$

Isso nos dá os dois autovalores:

- Para $+\rho$: $1 - \lambda_2 = \rho \implies \lambda_2 = 1 - \rho$
- Para $-\rho$: $1 - \lambda_1 = -\rho \implies \lambda_1 = 1 + \rho$
    - λ_1 é o maior autovalor e corresponde à PC1.

Variância explicada por PC1

5. Calculando a Proporção da Variância

A variância total no sistema é a soma de todos os autovalores:

$$\textbf{Variância Total} = \lambda_1 + \lambda_2 = (1+\rho) + (1-\rho) = 2$$

A proporção de variância explicada pela PC1 é o seu autovalor dividido pela variância total:

$$\text{PVE(PC1)} = \frac{\lambda_1}{\textbf{Variância Total}} = \frac{1+\rho}{2}$$

Isso completa a dedução. Mostramos que a proporção da variância capturada pelo primeiro componente principal é igual a $\frac{1+\rho}{2}$.

PCA em R: passo a passo

```r
# 1) Dados numéricos e padronização (recomendado)
head(iris, n=2)
```

```
##   Sepal.Length Sepal.Width Petal.Length Petal.Width Species
## 1          5.1         3.5          1.4         0.2  setosa
## 2          4.9         3.0          1.4         0.2  setosa
```

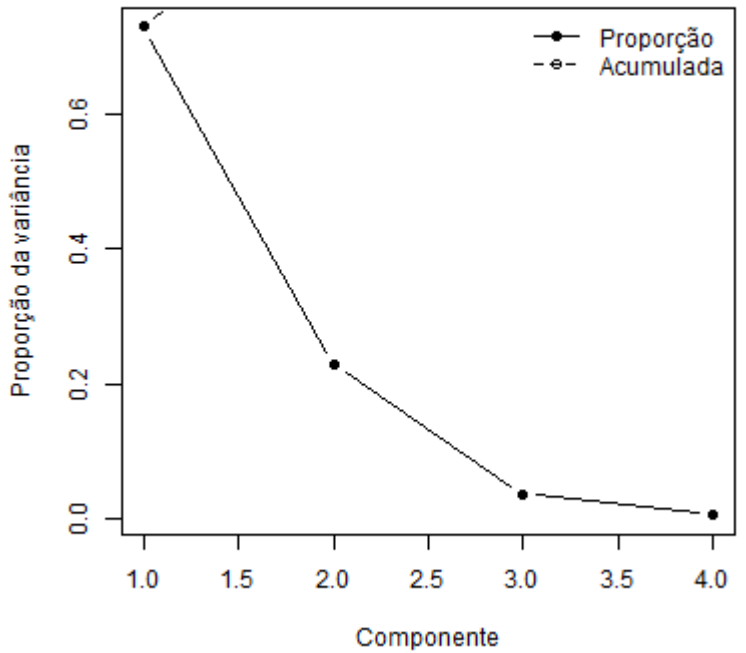
```r
X <- scale(iris[, 1:4], center = TRUE, scale = TRUE)

# 2) Ajuste do PCA (já padronizado; por isso center/scale desativados aqui)
pca <- prcomp(X, center = FALSE, scale. = FALSE)

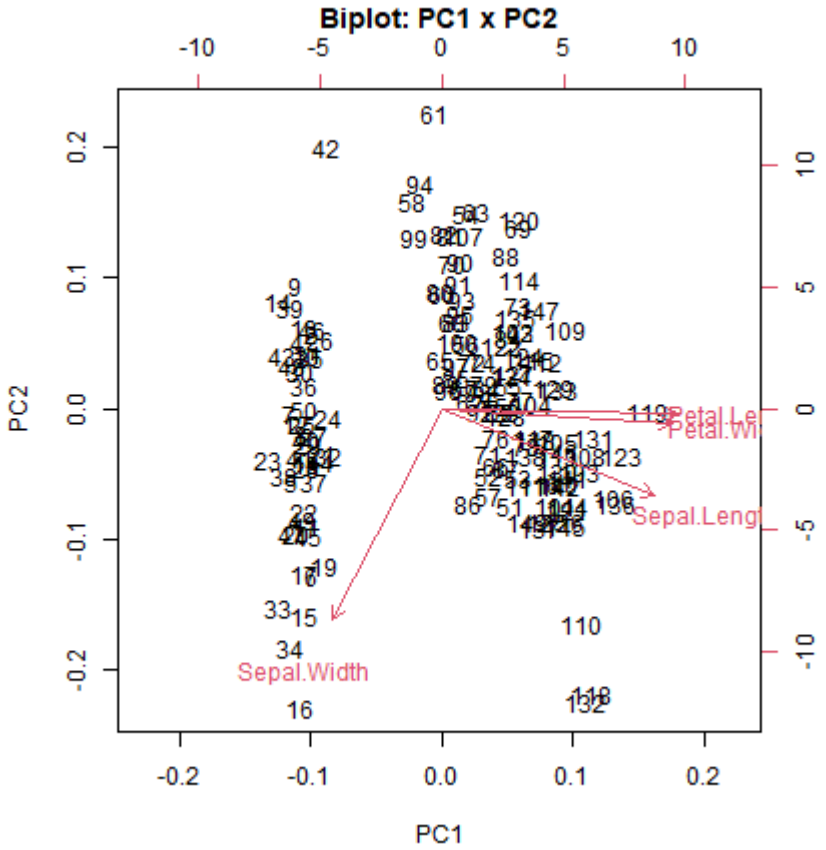
# 3) Variância explicada
vari  <- pca$sdev^2
prop  <- vari / sum(vari)
cum   <- cumsum(prop)
round(cbind(prop, cum), 3)
```

```
##       prop   cum
## [1,] 0.730 0.730
## [2,] 0.229 0.958
## [3,] 0.037 0.995
## [4,] 0.005 1.000
```

```r
# 4) Scree plot (proporção da variância explicada)
plot(prop, type = "b", pch = 19, xlab = "Componente",
     ylab = "Proporção da variância", main = " ")
lines(cum, type = "b", pch = 1, lty = 2)
legend("topright", c("Proporção", "Acumulada"), pch = c(19, 1), lty = c(1, 2), bty = "n")
```



```r
# 5) Biplot (PC1 x PC2)
biplot(pca, main = "Biplot: PC1 x PC2")
```



```r
# 6) Escores (coord. das observações nos PCs) e loadings (pesos das variáveis)
scores   <- pca$x          # n x p
loadings <- pca$rotation   # p x p
head(scores, 3); round(loadings, 3)
```

```
##             PC1        PC2        PC3        PC4
## [1,] -2.257141 -0.4784238  0.1272796 0.02408751
## [2,] -2.074013  0.6718827  0.2338255 0.10266284
## [3,] -2.356335  0.3407664 -0.0440539 0.02828231
```

```
##                PC1    PC2    PC3    PC4
## Sepal.Length  0.521 -0.377  0.720  0.261
## Sepal.Width  -0.269 -0.923 -0.244 -0.124
## Petal.Length  0.580 -0.024 -0.142 -0.801
## Petal.Width   0.565 -0.067 -0.634  0.524
```

Exemplo: PCA aplicada a Dados de Felicidade Mundial

1. Conjunto de dados

O Relatório Mundial da Felicidade é uma publicação anual que classifica os países com base no bem-estar e na satisfação com a vida de seus cidadãos.

- A edição de 2025, lançada em março, colocou a Finlândia como o país mais feliz do mundo pelo oitavo ano consecutivo
- O Brasil subiu oito posições para a 36ª, ficando atrás do Uruguai na América do Sul.
- O conjunto `happiness`, disponível no pacote zenplots, contém indicadores do *World Happiness Report* (WHR) para diversos países e anos.

1. Conjunto de dados

Os dados são contém várias variáveis que representam dimensões econômicas e sociais associadas ao bem-estar. As variáveis selecionadas para esta análise foram:

Variável	Interpretação
PIB per capita	Indicador econômico
Apoio social (família)	Rede de apoio percebida
Saúde (expectativa de vida)	Indicador de saúde e longevidade
Liberdade de escolha	Autonomia pessoal
Generosidade	Ações pró-sociais
Percepção de corrupção	Integridade institucional

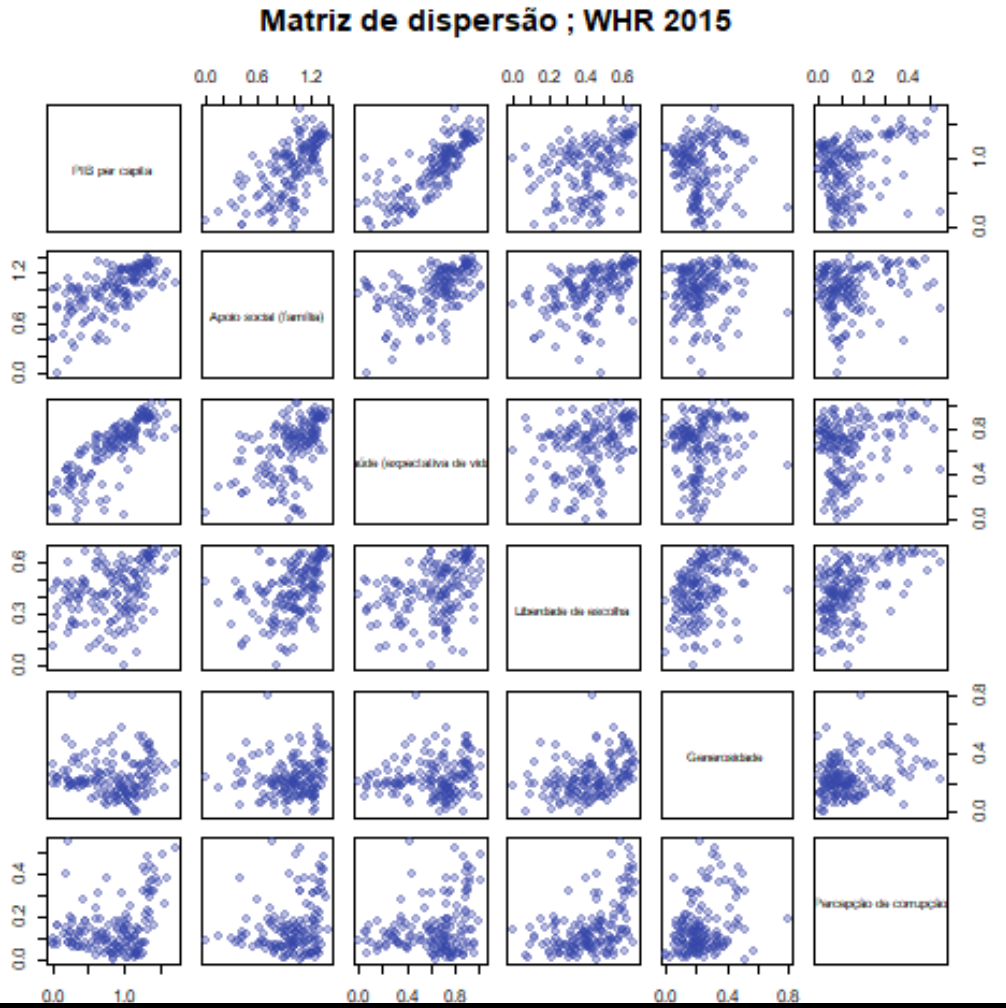
As observações correspondem a países, e os dados foram filtrados para o ano de 2015, que apresenta o maior número de casos completos, totalizando 158 países com observações válidas nas seis variáveis.

2. Análise exploratória - Estatísticas descritivas das variáveis

- Abaixo segue um resumo estatístico das variáveis selecionadas:

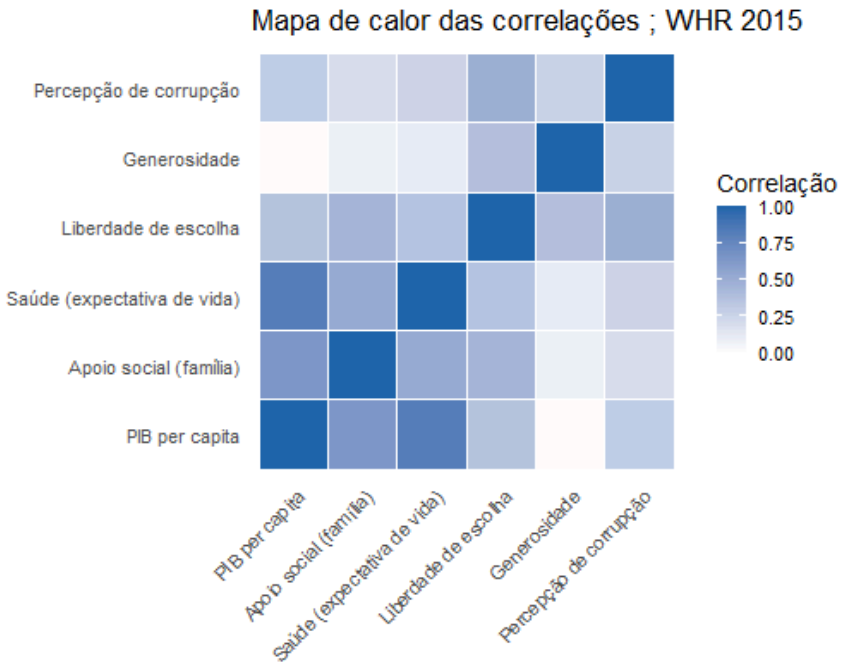
```
##  PIB per capita   Apoio social (família) Saúde (expectativa de vida)
##  Min.   :0.0000   Min.   :0.0000         Min.   :0.0000
##  1st Qu.:0.5458   1st Qu.:0.8568         1st Qu.:0.4392
##  Median :0.9102   Median :1.0295         Median :0.6967
##  Mean   :0.8461   Mean   :0.9910         Mean   :0.6303
##  3rd Qu.:1.1584   3rd Qu.:1.2144         3rd Qu.:0.8110
##  Max.   :1.6904   Max.   :1.4022         Max.   :1.0252
##  Liberdade de escolha  Generosidade    Percepção de corrupção
##  Min.   :0.0000       Min.   :0.0000   Min.   :0.00000
##  1st Qu.:0.3283       1st Qu.:0.1506   1st Qu.:0.06168
##  Median :0.4355       Median :0.2161   Median :0.10722
##  Mean   :0.4286       Mean   :0.2373   Mean   :0.14342
##  3rd Qu.:0.5491       3rd Qu.:0.3099   3rd Qu.:0.18025
##  Max.   :0.6697       Max.   :0.7959   Max.   :0.55191
```

2. Análise exploratória - Matriz de dispersão



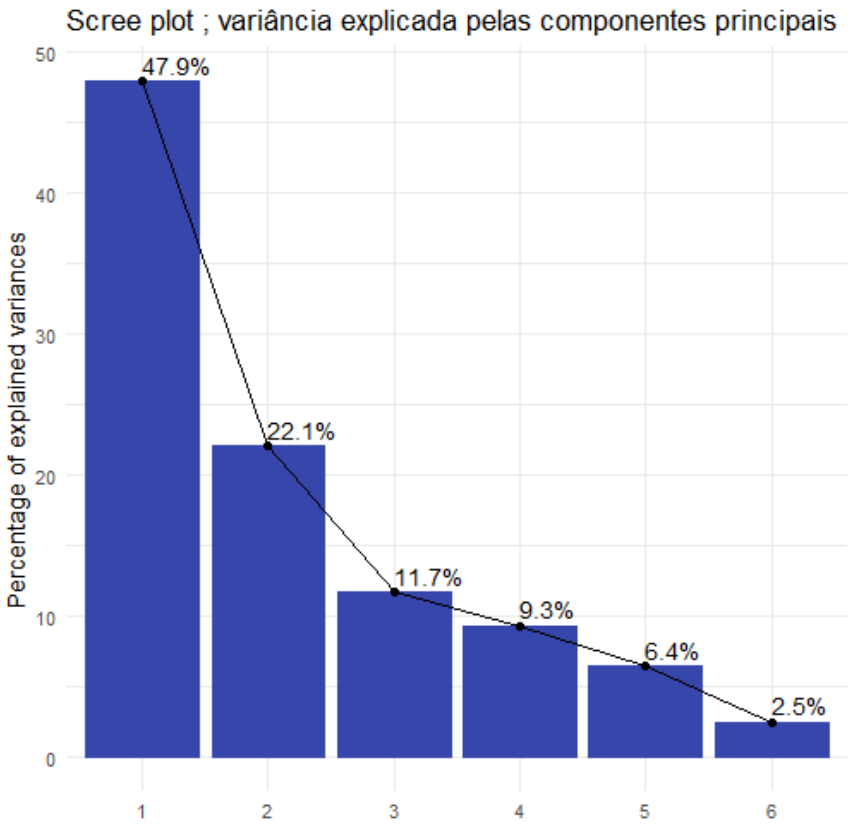
2. Análise exploratória - Matriz de correlação

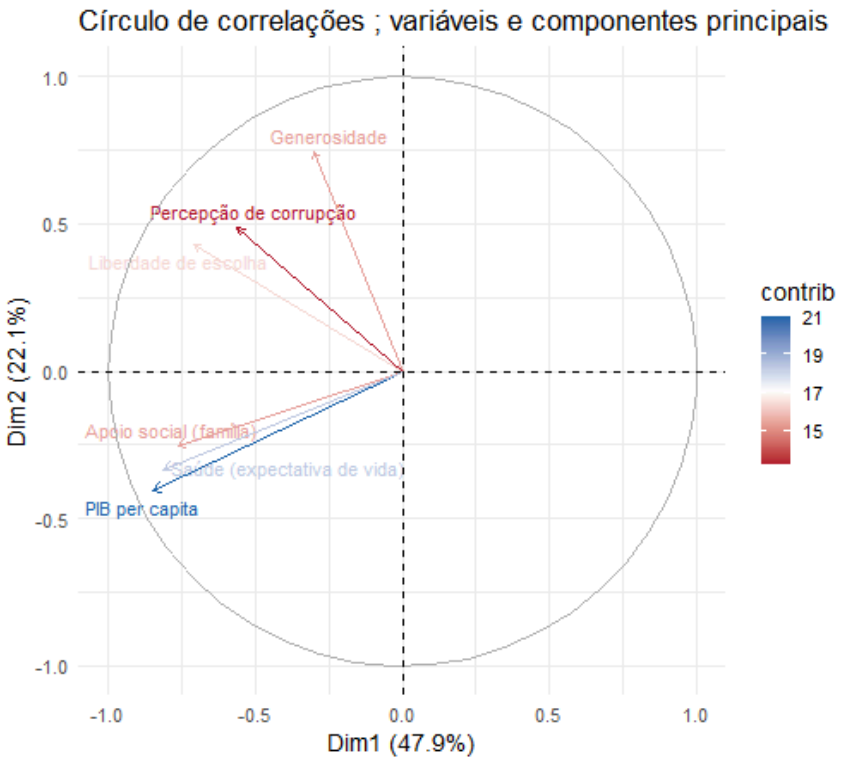
- Matriz de correlações entre as variáveis: associações positivas de intensidade moderada a forte.
- Cenário adequado para a aplicação da PCA.



3. Aplicando PCA

- PCA aplicada aos dados padronizados (média zero e variância unitária).
- Scree plot mostra a proporção da variância explicada por cada componente principal.

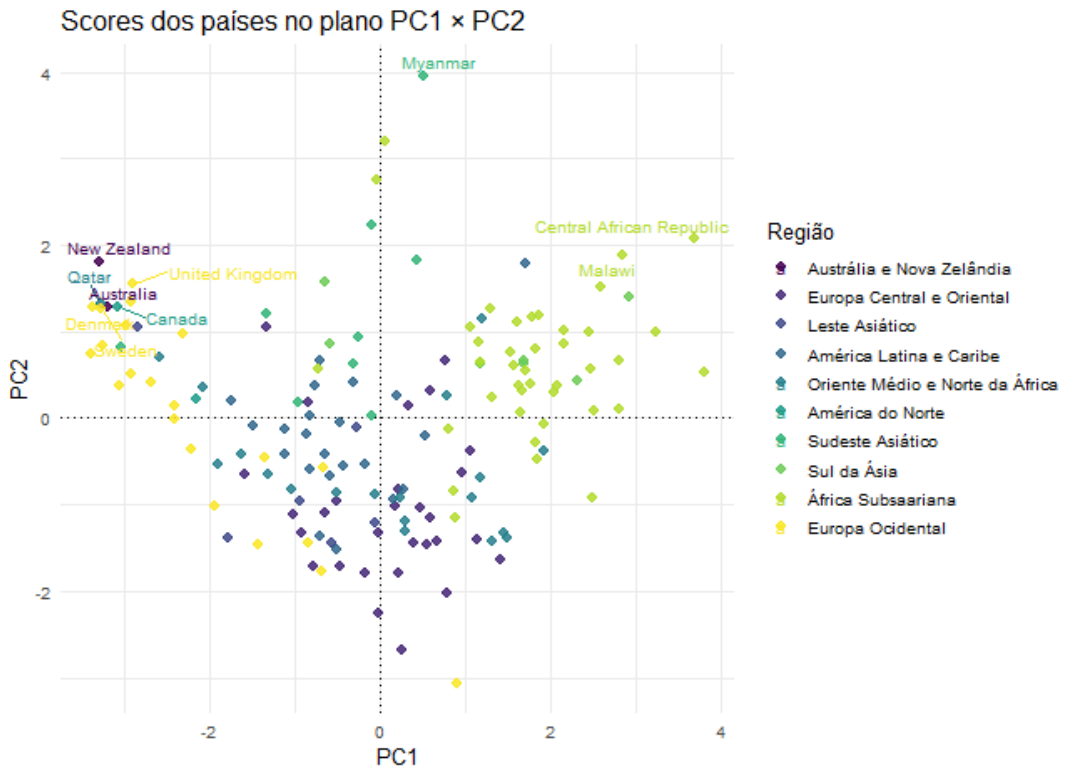




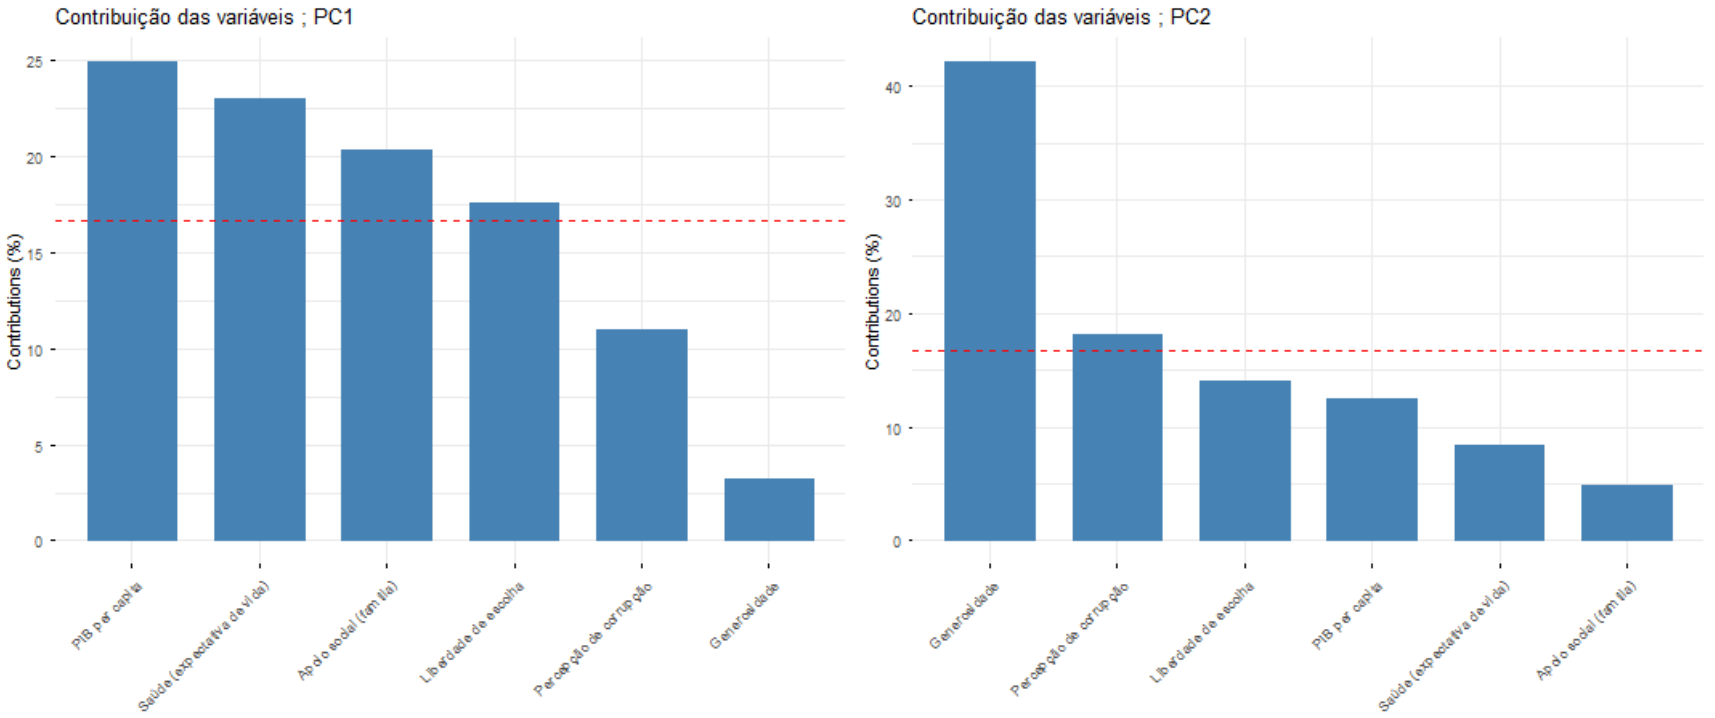
1. PC1 está fortemente associada a PIB per capita, Saúde e Apoio social, representando um eixo de bem-estar e desenvolvimento socioeconômico.
2. PC2 é mais relacionada a Generosidade e Percepção de corrupção, configurando um eixo moral e pró-social.

4. Representação dos países no plano PC1 × PC2

- Cada país recebe um score (coordenada) em cada componente.
- Nesta análise específica, os países com valores baixos (negativos) em PC1 são aqueles com maior bem-estar.
- Enquanto valores altos (positivos) indicam condições socioeconômicas menos favoráveis.



1. Países da Europa Ocidental, América do Norte e Oceania concentram-se no quadrante superior esquerdo, caracterizando alto bem-estar e desenvolvimento socioeconômico.
2. Países da África Subsaariana e Sul da Ásia aparecem em posições opostas, no lado direito do gráfico, indicando menor desempenho nos principais indicadores de bem-estar.



1. PC1 (Eixo do Desenvolvimento): É o principal componente e representa o desenvolvimento socioeconômico, sendo definido pelas variáveis de Riqueza (PIB), Saúde, Apoio Social e Liberdade.
2. PC2 (Eixo dos Valores Sociais): É um componente secundário que reflete valores cívicos, sendo dominado pelas variáveis de Generosidade e Percepção de Corrupção.

5. Considerações sobre a análise

A aplicação da PCA mostrou que a variação no bem-estar entre os países pode ser explicada principalmente por duas dimensões:

1. Um "Eixo de Desenvolvimento Socioeconômico" (PC1), que separa claramente as nações desenvolvidas das nações em desenvolvimento.

2. Um "Eixo de Valores Sociais" (PC2), que captura nuances relacionadas à generosidade e percepção de corrupção.

Portanto, a técnica não apenas simplificou a visualização dos dados, mas também mostrou a estrutura dos fatores que definem o bem-estar global.

Limitação do PCA Clássico

- O PCA clássico baseia-se em combinações lineares das variáveis originais, sendo, portanto, adequado apenas quando as relações entre os dados são essencialmente lineares.
- Como consequência, o método não é capaz de capturar estruturas não lineares ou padrões mais complexos presentes em muitos conjuntos de dados reais.
- Essa limitação restringe sua aplicabilidade em contextos onde a variabilidade dos dados se distribui de forma não linear no espaço de observações.
- Para superar essa limitação, técnicas como Kernel PCA e Autoencoders são usadas para capturar relações não-lineares.

Visualização interativa de PCA

Explore como os dados se distribuem em espaços reduzidos:

👉 https://projector.tensorflow.org/

Ferramenta do TensorFlow para visualizar PCA em dados de alta dimensão.

Pense sobre:

1. Prove as Proposições 1 e 2, explicando detalhadamente cada passo da demonstração.

- Dica: use a decomposição espectral de Σ:

$$\Sigma = E\Lambda E',$$

onde $E = [\mathbf{e}_1, \mathbf{e}_2, \ldots, \mathbf{e}_p]$ é a matriz cujas colunas são os autovetores de Σ e $\Lambda = \mathbf{diag}(\lambda_1, \lambda_2, \ldots, \lambda_p)$ é a matriz diagonal cujos elementos são os autovalores de Σ.

Resumo da Aula

Revisão (aula anterior):

- Autovalores e autovetores: $\mathbf{Ae} = \lambda\mathbf{e}$
- Decomposição espectral: $\mathbf{\Sigma} = \mathbf{E\Lambda E}'$
- SVD: $\mathbf{A} = \mathbf{U\Lambda V}'$ (generalizacao para matrizes retangulares)

Esta aula - PCA:

- Os componentes principais são as combinações lineares dos dados cujos coeficientes são os autovetores de $\mathbf{\Sigma}$ (ou $\boldsymbol{S}$), ordenados de acordo com os autovalores decrescentes.
- A PCA maximiza a variância projetada e produz combinações lineares não correlacionadas
- A proporção de variância explicada pelo $\boldsymbol{i}$-ésimo PC é $\lambda_i / \sum_j \lambda_j$
- Critérios de seleção: Kaiser ($\lambda > 1$), scree plot, variância acumulada $\geq$ 70–90%
- Em R: `prcomp()` (SVD) e `princomp()` (decomposição espectral de $\mathbf{S}$)

Referências

- JOHNSON, Richard A.; WICHERN, Dean W. Applied Multivariate Statistical Analysis. 6th ed. Harlow: Pearson Education Limited, 2013.
- MORETTIN, Pedro Alberto; SINGER, Júlio M. Estatística e Ciência de Dados. São Paulo: Blucher, 2021.
- HELLIWELL, J. F., HUANG, H., & WANG, S. (2015). The geography of world happiness. World happiness report, 2015.
- KASSAMBARA, A., & MUNDT, F. factoextra: Extract and Visualize the Results of Multivariate Data Analyses. R package version 1.0.7. Disponível em: https://CRAN.R-project.org/package=factoextra, 2020.