APRENDIZADO NÃO SUPERVISIONADO



Prof. Dr. Anderson Ara

Slide 06

Análise de Correspondência e MCA

Análise de Correspondência

Usualmente, uma análise de correspondência inclui a "melhor" representação bidimensional dos dados, juntamente com as coordenadas dos pontos plotados e uma medida (chamada inércia) da quantidade de informação retida em cada dimensão.

Inércia

A inércia total é uma medida da variação nos dados de contagem (variância total) e é definida como a soma ponderada dos quadrados:

$$\text{tr}\left[\mathbf{D}_r^{-1/2}(\mathbf{P}-\mathbf{r}\mathbf{c}')\mathbf{D}_c^{-1/2}(\mathbf{D}_r^{-1/2}(\mathbf{P}-\mathbf{r}\mathbf{c}')\mathbf{D}_c^{-1/2})'\right] = \sum_i \sum_j \frac{(p_{ij}-r_i c_j)^2}{r_i c_j} = \sum_{k=1}^{J-1} \lambda_k^2$$

onde λ_k são os valores singulares obtidos a partir da decomposição em valores singulares de $\mathbf{D}_r^{-1/2}(\mathbf{P}-\mathbf{r}\mathbf{c}')\mathbf{D}_c^{-1/2}$.

A inércia associada à melhor aproximação reduzida de ordem $K < J$ da matriz centrada $\mathbf{P}-\mathbf{r}\mathbf{c}'$ (a solução K-dimensional) tem inércia

$$\sum_{k=1}^{K} \lambda_k^2.$$

Inércia

A inércia residual (variação residual) que não é explicada pela solução de posto K é igual à soma dos quadrados dos valores singulares restantes: $\lambda_{K+1}^2 + \lambda_{K+2}^2 + \cdots + \lambda_{J-1}^2$.

Para gráficos, a inércia associada à dimensão k, λ_k^2, é normalmente exibida ao longo do eixo de coordenadas k.

Inércia Total e Qui-Quadrado

A inércia total está relacionada à medida qui-quadrado de associação em uma tabela de contingência bidimensional,

$$\chi^2 = \sum_{i,j} \frac{(O_{ij} - E_{ij})^2}{E_{ij}}.$$

Aqui, $O_{ij} = x_{ij}$ é a frequência observada e E_{ij} é a frequência esperada para a célula ij. No nosso contexto, se a variável da linha for independente (ou não relacionada) à variável da coluna, temos $E_{ij} = nr_ic_j$, e

$$\text{Inércia total} = \frac{1}{n} \sum_{i,j} \frac{(p_{ij} - r_ic_j)^2}{r_ic_j} = \frac{\chi^2}{n}.$$

Coordenadas

As coordenadas são os valores numéricos que representam a posição de cada ponto (linha ou coluna) em um espaço de dimensões reduzidas.

- A escolha do número de dimensões é feita pelo usuário.
- Se escolhermos apenas uma dimensão, cada ponto terá um único valor de coordenada.
- A interpretação dessas coordenadas depende do tipo de padronização utilizada na análise.

Exemplo: Se estivermos analisando categorias de consumidores em relação às preferências de um produto, cada categoria terá uma coordenada indicando sua posição nesse espaço reduzido.

Massa

A massa representa o peso ou a importância relativa de cada linha (ou coluna) na tabela de contingência.

- No caso das linhas, a massa é simplesmente o total da linha na tabela de frequências relativas.
- Se escolhemos a padronização baseada nos perfis de linha, as coordenadas são calculadas a partir dessa matriz de perfis (ou seja, a matriz de probabilidades condicionais).

Analogia: Pense na massa como a importância relativa de cada grupo na análise. Se um grupo de clientes representa 50% do total de observações, ele terá mais influência nos resultados do que um grupo que representa apenas 5%.

Qualidade da Representação

A qualidade de um ponto indica o quão bem ele está representado no espaço de dimensões reduzidas escolhido.

- Se todas as dimensões forem usadas, a distância entre os pontos será exatamente preservada.
- Como normalmente usamos menos dimensões, parte da informação pode ser perdida.
- A qualidade é uma medida que indica quanto dessa informação foi mantida.

Exemplo:

- Se a qualidade de um ponto for 0.9 (ou 90%), significa que ele está muito bem representado na nova configuração.
- Se for 0.1 (ou 10%), significa que a posição desse ponto no espaço reduzido não explica bem sua relação com os demais pontos.

OBS: Se a qualidade for baixa, pode ser necessário aumentar o número de dimensões para obter uma melhor representação dos dados.

Inércia Relativa

A inércia total na Análise de Correspondência está relacionada ao estatístico qui-quadrado e representa a variabilidade dos dados.

A inércia relativa indica quanto um determinado ponto contribui para a inércia total, independentemente do número de dimensões escolhidas.

- Um ponto pode ter alta qualidade (ou seja, estar bem representado no espaço reduzido), mas contribuir pouco para a inércia total.
- Isso acontece quando um ponto tem um padrão de distribuição semelhante à média, ou seja, não se destaca na análise.

Exemplo:

- Se um grupo de consumidores tem preferências muito diferentes da média, ele terá uma inércia relativa alta.
- Se outro grupo tem um padrão muito parecido com a média, ele terá baixa inércia relativa, pois não contribui muito para a variabilidade dos dados.

Inércia Relativa por Dimensão

Cada ponto contribui de forma diferente para cada dimensão extraída na análise.

- A inércia relativa por dimensão indica quanto um ponto contribui para a variabilidade explicada por uma dimensão específica.
- Isso permite identificar quais pontos são mais relevantes para cada dimensão da análise.

Exemplo:

- Se estamos analisando perfis de clientes e temos duas dimensões:
  - Dimensão 1 pode representar uma separação entre "Jovens" e "Idosos".
  - Dimensão 2 pode representar uma separação entre "Clientes que gastam pouco" e "Clientes que gastam muito".
  - Cada grupo de clientes terá uma inércia relativa diferente em cada dimensão.

Coseno²

O Coseno² (ou qualidade por dimensão) indica a correlação de um ponto com cada dimensão da análise.

- Ele representa a fração da variação de um ponto explicada por cada dimensão.
- A soma dos valores do Coseno² em todas as dimensões é igual à qualidade total do ponto.

Interpretação geométrica:

- O Coseno² é o quadrado do cosseno do ângulo entre um ponto e uma dimensão específica.
- Quanto maior esse valor, mais forte é a relação entre o ponto e aquela dimensão.

Exemplo:

- Se um ponto tem um Coseno² alto na Dimensão 1, significa que essa dimensão explica bem sua variação.
- Se o Coseno² for baixo para todas as dimensões, significa que o ponto não está bem representado no espaço reduzido.

Medidas de Qualidade

Inércia

- Mede a variabilidade total dos dados
- Relacionada ao teste qui-quadrado
- Cada dimensão explica uma parte da inércia

Inércia relativa

- Mede quanto um ponto contribui para a inércia total
- Identifica pontos mais importantes na estrutura dos dados

Medidas de Qualidade

Contribuição por dimensão

- Indica quais pontos são mais relevantes em cada dimensão
- Ajuda na interpretação dos eixos

Qualidade da representação (Cos^2)

- Mede o quanto um ponto é bem representado no espaço reduzido
- Interpretação: proporção da variância explicada pelas dimensões
- Valores próximos de 1: boa representação
- Valores baixos: ponto mal representado

Análise de Correspondência Múltipla

Análise de Correspondência Múltipla

A Análise de Correspondência Múltipla (MCA) é considerada uma extensão da Análise de Correspondência Simples (CA), aplicada especificamente a tabelas que contêm indivíduos e suas respostas a variáveis categóricas.

A MCA utiliza os mesmos princípios matemáticos da CA.

Aplicada em dados que:

- As linhas representam indivíduos.
- As colunas representam variáveis categóricas.
- As células indicam a resposta do indivíduo.

Análise de Correspondência Múltipla

Na Análise de Correspondência Simples (CA), trabalhamos com uma tabela de contingência entre duas variáveis categóricas.

Na Análise de Correspondência Múltipla (MCA), queremos analisar várias variáveis categóricas ao mesmo tempo.

Para isso, uma ideia central é reorganizar os dados em uma estrutura chamada:

- matriz indicadora
- matriz de Burt

Matriz Indicadora

A matriz indicadora (ou *complete disjunctive table*) representa:

- linhas: indivíduos
- colunas: categorias das variáveis
- células: valor 1 se o indivíduo pertence à categoria, e 0 caso contrário

Em variáveis binárias, cada pergunta gera duas colunas:

- Sim
- Não

Assim, a MCA pode ser vista como uma extensão da CA aplicada a essa nova representação dos dados.

Matriz Indicadora

Considere três perguntas binárias para 4 indivíduos:

- P1: Pratica atividade física?
- P2: Consome frutas diariamente?
- P3: Dorme pelo menos 8 horas?

Suponha as seguintes respostas:

Indivíduo	P1	P2	P3
A	Sim	Sim	Não
B	Não	Sim	Não
C	Sim	Não	Sim
D	Não	Não	Sim

Matriz Indicadora

Cada pergunta binária gera duas categorias:

- P1_Sim, P1_Não
- P2_Sim, P2_Não
- P3_Sim, P3_Não

Logo, a matriz indicadora terá:

- 4 linhas (indivíduos)
- 6 colunas (duas categorias para cada uma das 3 perguntas)

Em cada bloco de pergunta, exatamente uma categoria recebe 1 e a outra recebe 0.

Matriz Indicadora

A matriz indicadora neste caso é:

$$\mathbf{Z} = \begin{bmatrix} 1 & 0 & 1 & 0 & 0 & 1 \\ 0 & 1 & 1 & 0 & 0 & 1 \\ 1 & 0 & 0 & 1 & 1 & 0 \\ 0 & 1 & 0 & 1 & 1 & 0 \end{bmatrix}$$

onde as colunas estão na ordem:

$$(\text{P1_Sim},\ \text{P1_Não},\ \text{P2_Sim},\ \text{P2_Não},\ \text{P3_Sim},\ \text{P3_Não})$$

Matriz Indicadora

Indivíduo	P1_Sim	P1_Não	P2_Sim	P2_Não	P3_Sim	P3_Não
A	1	0	1	0	0	1
B	0	1	1	0	0	1
C	1	0	0	1	1	0
D	0	1	0	1	1	0

Observe que:

- em cada pergunta, cada indivíduo marca apenas uma categoria
- a soma em cada bloco binário é sempre 1

Matriz de Burt

A Matriz de Burt é um tipo de matriz de contingência utilizada na Análise de Correspondência Múltipla (MCA).

É construída a partir de variáveis categóricas e contém todas as combinações possíveis entre categorias, organizadas de forma simétrica.

Considera conjuntamente a tabela de frequência de cada variável em sua diagonal e as tabelas de contigências 2x2 fora da diagonal e de forma simétrica.

Matriz de Burt

A matriz de Burt é obtida por

$$\mathbf{B} = \mathbf{Z}^\top \mathbf{Z}$$

onde:

- $\mathbf{Z}$ é a matriz indicadora
- $\mathbf{Z}^\top$ é sua transposta

Intuição:

- os elementos da diagonal contam frequências das categorias
- os blocos fora da diagonal contam coocorrências entre categorias de variáveis diferentes

Matriz de Burt

Matriz de Burt do exemplo

$$\mathbf{B} = \begin{bmatrix} 2 & 0 & 1 & 1 & 1 & 1 \\ 0 & 2 & 1 & 1 & 1 & 1 \\ 1 & 1 & 2 & 0 & 0 & 2 \\ 1 & 1 & 0 & 2 & 2 & 0 \\ 1 & 1 & 0 & 2 & 2 & 0 \\ 1 & 1 & 2 & 0 & 0 & 2 \end{bmatrix}$$

com a mesma ordem de categorias: [(\text{P1_Sim},\ \text{P1_Não},\ \text{P2_Sim},\ \text{P2_Não},\ \text{P3_Sim},\ \text{P3_Não})]

Matriz de Burt

Por exemplo:

- o valor 2 na diagonal de P1_Sim indica que 2 indivíduos responderam “Sim” para P1
- o valor 1 entre P1_Sim e P2_Sim indica que 1 indivíduo respondeu “Sim” para ambas
- o valor 2 entre P2_Não e P3_Sim indica que 2 indivíduos responderam “Não” em P2 e “Sim” em P3

A matriz de Burt é sempre:

- simétrica
- formada por blocos
- muito útil para entender a estrutura categórica do problema

Matriz de Burt

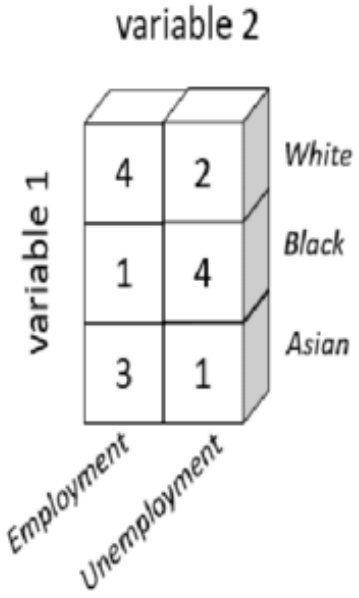
A matriz de Burt pode ser vista como uma matriz de contingência ampliada:

$$\mathbf{B} = \begin{bmatrix} \mathbf{B}_{11} & \mathbf{B}_{12} & \mathbf{B}_{13} \\ \mathbf{B}_{21} & \mathbf{B}_{22} & \mathbf{B}_{23} \\ \mathbf{B}_{31} & \mathbf{B}_{32} & \mathbf{B}_{33} \end{bmatrix}$$

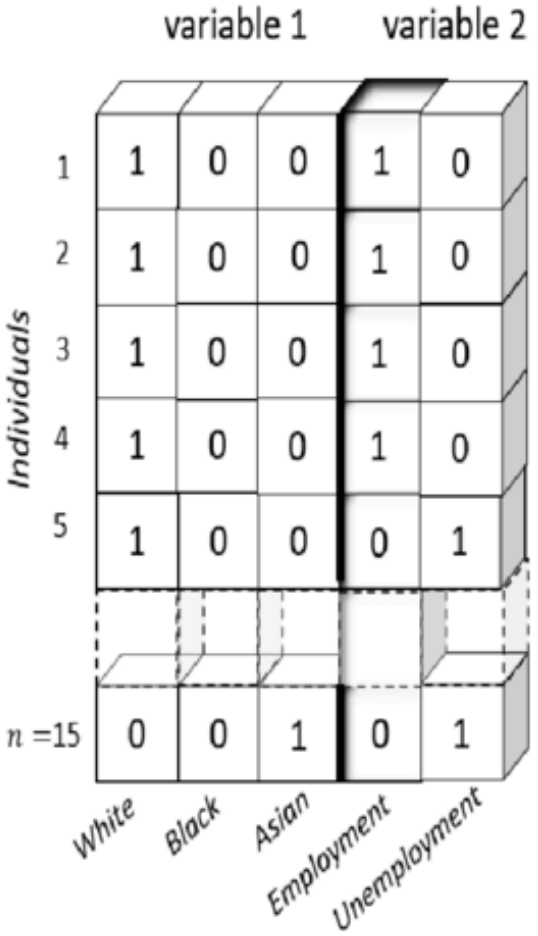
sendo:

- os blocos diagonais $\mathbf{B}_{jj}$ trazem frequências de cada variável
- os blocos fora da diagonal $\mathbf{B}_{jk}$ são tabelas de contingência entre duas variáveis

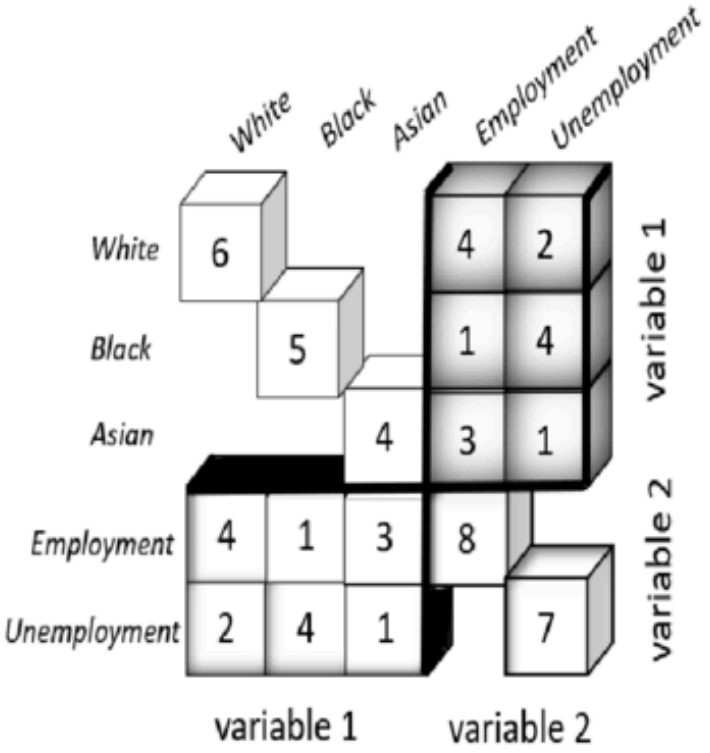
Simple contingency table



Indicator matrix



Burt matrix



Pasaribu, U. S., Lestari, K. E., Indratno, S. W., Garminia, H., & Sari, R. K. N. (2021). Some properties of the scaled Burt matrix on multiple correspondence analysis. Journal of Hunan University Natural Sciences, 48(5).

Análise de Correspondência Múltipla

MCA é uma extensão da CA

- CA: tabela de contingência
- MCA: indivíduos × variáveis categóricas

> MCA é CA aplicada a uma matriz indicadora (ou à matriz de Burt)

Quando usar MCA?

- Survey com múltiplas perguntas categóricas
- Perfil de clientes
- Respostas de questionário

Análise de Correspondência Múltipla

A MCA pode ser construída a partir de:

- matriz indicadora
- ou, equivalentemente, da matriz de Burt

A ideia central é a mesma da CA:

- representar categorias em um espaço de baixa dimensão
- estudar associações entre categorias
- explorar proximidade entre perfis de resposta dos indivíduos

Análise de Correspondência Múltipla

```r
# Dados
dados <- data.frame(
  P1 = c("S", "N", "S", "N"), P2 = c("S", "S", "N", "N"), P3 = c("N", "N", "S", "S"))

# Matriz indicadora
Z <- cbind(
  P1_S = as.integer(dados$P1 == "S"),
  P1_N = as.integer(dados$P1 == "N"),
  P2_S = as.integer(dados$P2 == "S"),
  P2_N = as.integer(dados$P2 == "N"),
  P3_S = as.integer(dados$P3 == "S"),
  P3_N = as.integer(dados$P3 == "N")
)

# Reordenando para ficar no padrão do slide
Z <- Z[, c("P1_S", "P1_N", "P2_S", "P2_N", "P3_S", "P3_N")]

# Matriz de Burt
B <- t(Z) %*% Z
```

Análise de Correspondência Múltipla

```
Z
```

```
##      P1_S P1_N P2_S P2_N P3_S P3_N
## [1,]    1    0    1    0    0    1
## [2,]    0    1    1    0    0    1
## [3,]    1    0    0    1    1    0
## [4,]    0    1    0    1    1    0
```

```
B
```

```
##      P1_S P1_N P2_S P2_N P3_S P3_N
## P1_S    2    0    1    1    1    1
## P1_N    0    2    1    1    1    1
## P2_S    1    1    2    0    0    2
## P2_N    1    1    0    2    2    0
## P3_S    1    1    0    2    2    0
## P3_N    1    1    2    0    0    2
```

Análise de Correspondência Múltipla

A MCA é amplamente utilizada para:

- Identificar padrões nas respostas dos entrevistados.
- Explorar relações entre diferentes variáveis categóricas.
- Representar visualmente as relações entre categorias e indivíduos.
- Reduzir a complexidade dos dados e facilitar a interpretação.

Pela matriz indicadora

A MCA pode ser vista como uma CA aplicada à matriz indicadora.

Partimos da matriz padronizada de desvios:

$$\mathbf{S} = \mathbf{D}_r^{-1/2} \left(\mathbf{P} - \mathbf{r}\mathbf{c}^\top \right) \mathbf{D}_c^{-1/2},$$

sendo $\mathbf{P} = \mathbf{Z}/n$.

Aplicando a SVD,

$$\mathbf{S} = \mathbf{U}\mathbf{\Delta}\mathbf{V}^\top,$$

obtemos os valores singulares e os eixos principais da MCA.

Pela matriz de Burt

Como

$$\mathbf{B} = \mathbf{Z}^\top \mathbf{Z},$$

a matriz de Burt resume as coocorrências entre categorias.

A MCA também pode ser obtida a partir de uma padronização de $\mathbf{B}$, cuja decomposição espectral é diretamente relacionada à SVD de $\mathbf{Z}$.

Ideia geral

- Matriz indicadora: representação indivíduos × categorias
- Matriz de Burt: representação categorias × categorias
- SVD: ferramenta que extrai a estrutura de baixa dimensão

> Assim, a MCA representa categorias e indivíduos em um espaço reduzido a partir da SVD da matriz indicadora, ou equivalentemente da decomposição da matriz de Burt.