APRENDIZADO NÃO SUPERVISIONADO



Prof. Dr. Anderson Ara

Slide 15

Algoritmo Apriori

Introdução

sistemas de recomendação e as regras de associação destacam-se por permitir que empresas entendam melhor os hábitos de consumo dos usuários, prevendo comportamentos e sugerindo ações automáticas com base em padrões históricos.

O que é um Sistema de Recomendação?

Sistemas de recomendação são algoritmos capazes de prever o que um usuário pode querer consumir a seguir. Eles analisam o histórico de interações dos usuários com produtos ou conteúdos e, com base nisso, realizam sugestões personalizadas. São amplamente utilizados por empresas como Netflix (para filmes), Spotify (para músicas), Amazon (para produtos), entre outras. O objetivo principal é aumentar o engajamento e as vendas.

Tipos de Sistemas de Recomendação

Há três abordagens principais:

- Baseado em conteúdo: recomenda itens semelhantes aos que o usuário já consumiu, com base em suas características.
- Filtragem colaborativa: recomenda itens que usuários semelhantes consumiram.
- Híbrido: combina ambas as abordagens, oferecendo resultados mais precisos. Cada abordagem tem vantagens e desvantagens, e a escolha depende do domínio e da quantidade de dados disponíveis.

Exemplo de Recomendação

Imagine um usuário da Netflix que assiste principalmente filmes de suspense psicológico. O sistema pode recomendar outros filmes desse gênero, ou mesmo de gêneros similares que agradaram a usuários com o mesmo padrão de consumo. Essas recomendações são ajustadas dinamicamente conforme o histórico do usuário cresce. Esse é um exemplo típico de sistema híbrido, combinando características do conteúdo com dados colaborativos.

Regras de Associação

As regras de associação permitem descobrir relações do tipo "se... então..." entre itens que ocorrem em conjunto dentro de uma base de dados transacional.

Por exemplo:

$$\{\text{leite, pão}\} \rightarrow \{\text{manteiga}\}$$

Significa que se um cliente compra leite e pão, há uma chance significativa de que ele também compre manteiga.

Essa análise é para recomendação de produtos.

Regras de Associação

Usos Práticos

- Varejo: promoções direcionadas, reposição de estoque, cross-selling
- E-commerce: recomendação em tempo real
- Saúde: associação entre sintomas e doenças
- Segurança: detecção de padrões anômalos As regras de associação têm aplicação em qualquer domínio onde padrões de coocorrência sejam relevantes.

Probabilidade Frequentista

A probabilidade frequentista interpreta a chance de um evento como a frequência com que ele ocorre em muitas observações.

Se {leite, pão} aparece em 300 de 1000 transações:

$$P(\text{leite, pão}) = \frac{300}{1000} = 0,3$$

Essa probabilidade representa o suporte do item `{leite, pão}` e é essencial para filtrar combinações comuns o suficiente para serem consideradas úteis.

Probabilidade Condicional e Confiança

A confiança de uma regra é uma probabilidade condicional: dado que X aconteceu, qual a chance de Y também acontecer?

$$P(Y \mid X) = \frac{P(X \cap Y)}{P(X)}$$

Por exemplo, se {leite, pão} aparece em 300 transações e {leite, pão, manteiga} aparece em 240:

$$\text{Confiança} = \frac{240}{300} = 0,8$$

Ou seja, 80% dos clientes que compram leite e pão também compram manteiga. A confiança ajuda a medir a força da implicação na regra.

class: left, top

Lift e Independência

O lift compara a confiança da regra com a frequência esperada de Y se X e Y fossem independentes:

$$\text{Lift}(X \to Y) = \frac{P(X \cap Y)}{P(X) \cdot P(Y)}$$

- Lift = 1: os itens são estatisticamente independentes;
- Lift > 1: há correlação positiva; Y ocorre mais com X do que por acaso;
- Lift < 1: correlação negativa; Y ocorre menos quando X ocorre.

Lift é útil para detectar dependências reais entre itens.

Market Basket Analysis

É a técnica de análise mais comum baseada em regras de associação. Avalia quais itens aparecem juntos em transações de compras (cestas de mercado).

Aplicações práticas:

- Criar promoções “compre X, leve Y”
- Reorganizar a posição de produtos nas prateleiras
- Personalizar vitrines online com produtos comprados juntos

O Algoritmo Apriori

O Apriori é o algoritmo mais tradicional para gerar regras de associação. Ele trabalha de forma incremental, explorando itemsets pequenos antes de tentar combinações maiores. Isso é possível graças à sua propriedade antimonótona que torna o processo computacionalmente viável mesmo em grandes bases.

O algoritmo Apriori gera conjuntos de itens frequentes, ou seja, conjuntos de itens que produzirão regras com suporte superior a um mínimo suporte definido juntando os conjuntos de itens frequentes da passagem anterior e podando os subconjuntos que possuem um suporte menor do que o mínimo pretendido (Agrawal & Srikan, 1994).

O Algoritmo Apriori

Item e itemset

Um item pode ser visto como um único teste do tipo atributo-valor, ou seja, é um complexo contendo uma única condição

Um itemset é uma conjunção de items, ou seja, os testes em um itemset estão ligados entre si pelo conectivo lógico

Princípio do Apriori

A chave do Apriori é: se um itemset não é frequente, nenhum de seus superconjuntos será.

$$X \subseteq Y \Rightarrow \text{Suporte}(X) \geq \text{Suporte}(Y)$$

Esse princípio evita a geração e avaliação de muitas combinações inúteis, reduzindo o tempo de execução drasticamente.

Itens Frequentes e Raros

- Itens frequentes: como pão, leite, fraldas – aparecem em muitas transações.
- Itens raros: como equipamentos caros – aparecem pouco, mas têm valor alto. Identificar ambos é importante: o primeiro para estratégias de volume e o segundo para recomendações valiosas e segmentadas.

Itemsets Máximos e Fechados

Para evitar redundância:

- Fechado: nenhum superconjunto tem o mesmo suporte.
- Máximo: nenhum superconjunto é frequente.

Esses conceitos permitem representar conjuntos relevantes com menos regras, facilitando a visualização e interpretação dos padrões.

Cuidado com Correlações Enganosas

Nem toda regra com alta confiança é relevante.

Exemplo:

80% dos clientes tomam café. Uma regra Chá → Café com 75% de confiança é menos interessante do que parece, já que a média geral de consumo de café é maior.

Use o lift para verificar se a relação é realmente mais forte que o esperado por acaso.

Medidas de Interesse

Critérios combinados são usados para filtrar as melhores regras:

- Suporte garante relevância estatística
- Confiança garante força de associação
- Lift garante dependência real

Além disso, pode-se usar métricas como chi-quadrado, ganho de informação, entre outras.

Em R

```r
require(arules)
data("Groceries")

# Regras com suporte ≥ 4% e confiança ≥ 20%
rules <- apriori(Groceries, parameter = list(supp = 0.03, conf = 0.2))
```

```
## Apriori
##
## Parameter specification:
##  confidence minval smax arem  aval originalSupport maxtime support minlen
##         0.2    0.1    1 none FALSE            TRUE       5    0.03      1
##  maxlen target  ext
##      10  rules TRUE
##
## Algorithmic control:
##  filter tree heap memopt load sort verbose
##     0.1 TRUE TRUE  FALSE TRUE    2    TRUE
##
## Absolute minimum support count: 295
```

Em R

```
# Regras com Lift > 2
strong_rules <- subset(rules, lift > 1.5)

# Visualização
inspect(strong_rules)
```

```
##      lhs                      rhs                support    confidence
## [1]  {whipped/sour cream} => {whole milk}       0.03223183 0.4496454
## [2]  {pip fruit}          => {whole milk}       0.03009659 0.3978495
## [3]  {sausage}            => {rolls/buns}       0.03060498 0.3257576
## [4]  {tropical fruit}     => {other vegetables} 0.03589222 0.3420543
## [5]  {tropical fruit}     => {whole milk}       0.04229792 0.4031008
## [6]  {root vegetables}    => {other vegetables} 0.04738180 0.4347015
## [7]  {other vegetables}   => {root vegetables}  0.04738180 0.2448765
## [8]  {root vegetables}    => {whole milk}       0.04890696 0.4486940
## [9]  {yogurt}             => {other vegetables} 0.04341637 0.3112245
## [10] {other vegetables}   => {yogurt}           0.04341637 0.2243826
## [11] {yogurt}             => {whole milk}       0.05602440 0.4016035
## [12] {whole milk}         => {yogurt}           0.05602440 0.2192598
```

Em R

No grafo cada nó representa um item e as arestas representam regras com pesos proporcionais à confiança.

```
require(arulesViz)
plot(strong_rules, method = "graph", control = list(type = "items"))
```

```
## Available control parameters (with default values):
## layout      =  stress
## circular      =  FALSE
## ggraphdots      =  NULL
## edges     =  <environment>
## nodes     =  <environment>
## nodetext      =  <environment>
## colors      =  c("#EE0000FF", "#EEEEEEFF")
## engine      =  ggplot2
## max     =  100
## verbose      =  FALSE
```


root vegetables
tropical fruit
pip fruit
whole milk
other vegetables
whipped/sour cream
rolls/buns
sausage
yogurt
lift
2.1
1.9
1.7
support
0.04
0.05
0.06
0.07