APRENDIZADO NÃO SUPERVISIONADO



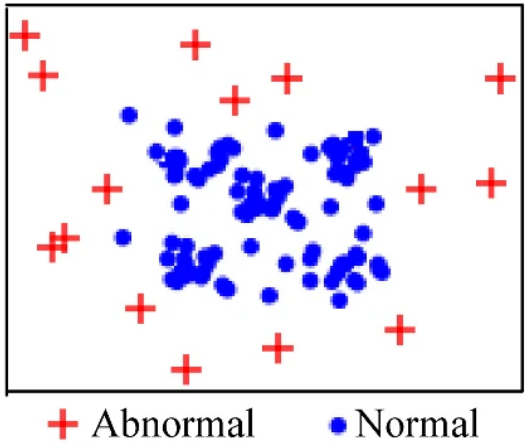
Prof. Dr. Anderson Ara

Slide 16

Detecção de Anomalias

O que é uma anomalia?

Uma anomalia é uma observação cujo comportamento difere significativamente do padrão predominante dos dados. Em muitos problemas reais, essas observações representam eventos raros, inesperados ou potencialmente importantes. A identificação dessas ocorrências permite detectar falhas, fraudes, comportamentos suspeitos ou mudanças de regime antes que produzam consequências mais graves.



Motivação

A detecção de anomalias está presente em diversos contextos. Instituições financeiras procuram identificar transações fraudulentas, hospitais monitoram exames em busca de padrões incomuns e indústrias acompanham sensores para detectar falhas em equipamentos. Em todos esses cenários, o interesse está em encontrar rapidamente observações raras que merecem investigação.

Tipos de Anomalias

Anomalias podem aparecer de diferentes formas. Uma observação isolada pode ser claramente distinta das demais, caracterizando uma anomalia pontual. Em outros casos, uma observação é anômala apenas dentro de determinado contexto, como uma temperatura de 25°C durante o inverno em uma região muito fria. Também existem anomalias coletivas, em que um conjunto de observações é incomum apenas quando analisado conjuntamente.

Aprendizado Não Supervisionado

Em muitos problemas não existem rótulos indicando quais observações são anômalas. Nesses casos, os algoritmos precisam identificar padrões diretamente a partir dos dados. A detecção de anomalias é uma das aplicações mais importantes do aprendizado não supervisionado, pois frequentemente lidamos com conjuntos de dados em que exemplos de eventos raros são escassos ou inexistentes.

Métodos tradicionais

Historicamente, diversas abordagens foram propostas para detectar anomalias. Algumas utilizam distâncias entre observações, outras estimam densidades probabilísticas ou constroem modelos capazes de representar o comportamento normal dos dados. Apesar de eficazes em muitos cenários, essas abordagens podem apresentar dificuldades quando o número de variáveis cresce ou quando a distribuição dos dados é desconhecida.

Métodos baseados em distância

Uma ideia simples consiste em medir a distância entre observações. Pontos muito afastados de seus vizinhos tendem a ser considerados suspeitos. Essa estratégia é intuitiva e fácil de compreender, porém sofre com a maldição da dimensionalidade, pois em espaços de alta dimensão as distâncias tornam-se menos informativas.

Métodos baseados em densidade

Outra estratégia consiste em analisar a densidade local dos dados. Regiões muito povoadas são consideradas normais, enquanto regiões esparsas podem indicar a presença de anomalias. Métodos como o Local Outlier Factor (LOF) seguem essa filosofia e avaliam a densidade relativa de cada observação em comparação com seus vizinhos.

Nova perspectiva baseada em árvore

Em 2008 foi proposto o algoritmo Isolation Forest. A principal inovação desse método é que ele não tenta modelar explicitamente os dados normais.

Em vez disso, procura identificar quão facilmente uma observação pode ser isolada do restante da amostra.

Ideia Fundamental

A hipótese central do Isolation Forest é extremamente simples: observações anômalas são mais fáceis de isolar do que observações normais. Como geralmente estão afastadas dos agrupamentos principais, poucas divisões aleatórias são suficientes para separá-las do restante dos dados.

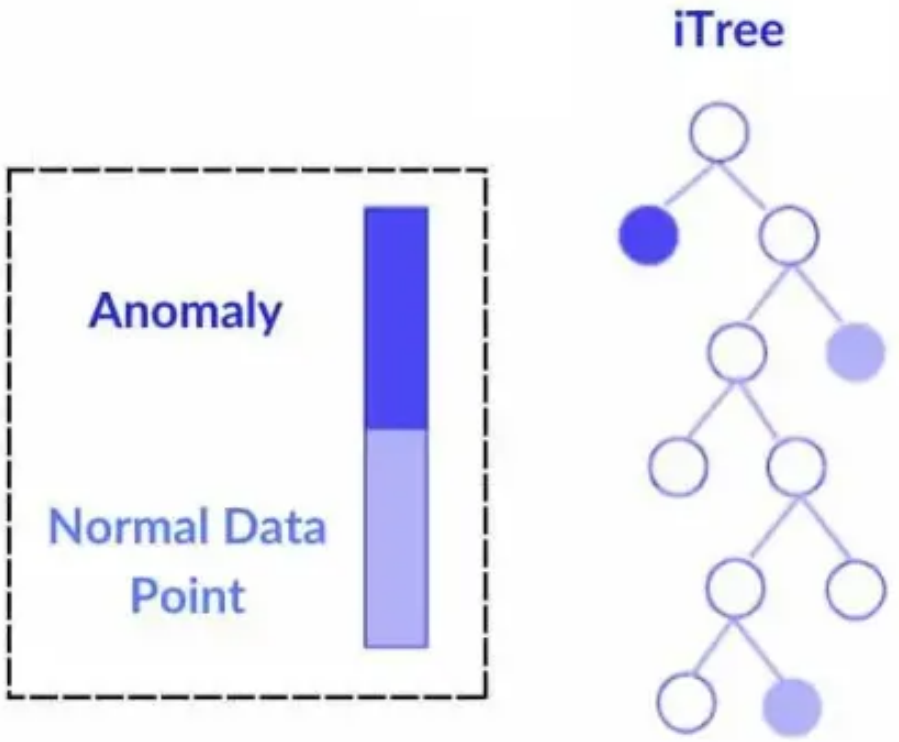
O Conceito de Isolamento

Imagine um conjunto de pontos concentrados em uma mesma região do espaço. Para separar um ponto localizado no centro desse grupo serão necessárias diversas divisões sucessivas. Já um ponto distante dos demais pode ser isolado rapidamente. Essa diferença será utilizada para medir o grau de anomalia.

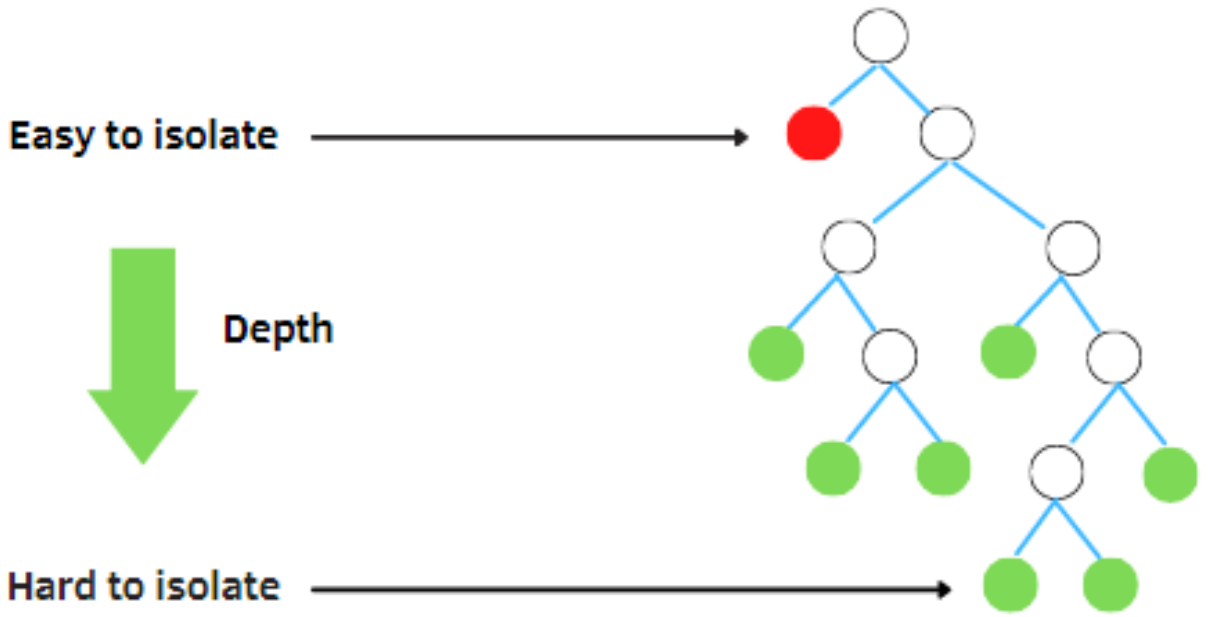
Isolation Tree

A estrutura básica do método é chamada de Isolation Tree. Trata-se de uma árvore binária construída por divisões completamente aleatórias. Diferentemente das árvores de classificação tradicionais, não existe variável resposta nem critério de impureza a ser otimizado.

Isolation Tree



Isolation Tree



Construção da Árvore

O processo inicia com todas as observações na raiz. Em seguida, uma variável é escolhida aleatoriamente. Depois, seleciona-se aleatoriamente um ponto de corte dentro do intervalo observado para essa variável. As observações são divididas em dois grupos e o procedimento é repetido recursivamente.

Escolha aleatória das variáveis

Em cada nó, qualquer variável pode ser selecionada. Essa aleatoriedade é uma característica essencial do método. O objetivo não é encontrar a melhor divisão possível, mas produzir múltiplos particionamentos capazes de revelar observações facilmente isoláveis.

Escolha Aleatória dos Cortes

Após escolher uma variável, o algoritmo sorteia um valor entre o mínimo e o máximo observados. Esse valor define a divisão do nó. Como os cortes são aleatórios, árvores diferentes produzirão estruturas diferentes mesmo utilizando os mesmos dados.

Quando a Árvore Para?

O crescimento continua até que uma observação fique sozinha em um nó ou até que seja atingida uma profundidade máxima. Nesse momento considera-se que a observação foi isolada.

Comprimento do Caminho

Para cada observação podemos contar quantos nós foram percorridos desde a raiz até o momento em que ela foi isolada. Essa quantidade recebe o nome de comprimento do caminho (path length). Trata-se da principal medida utilizada pelo algoritmo.

Interpretação do Caminho

Se uma observação é isolada após poucas divisões, o comprimento do caminho será pequeno. Isso sugere que ela possui características incomuns em relação ao restante dos dados. Por outro lado, observações normais tendem a apresentar caminhos mais longos.

Exemplo Conceitual

Considere uma nuvem de pontos concentrada próxima ao centro do espaço e um único ponto muito distante. Em diversas árvores aleatórias, esse ponto distante será separado rapidamente, enquanto os demais exigirão várias divisões adicionais para serem isolados.

Limitações de uma única árvore

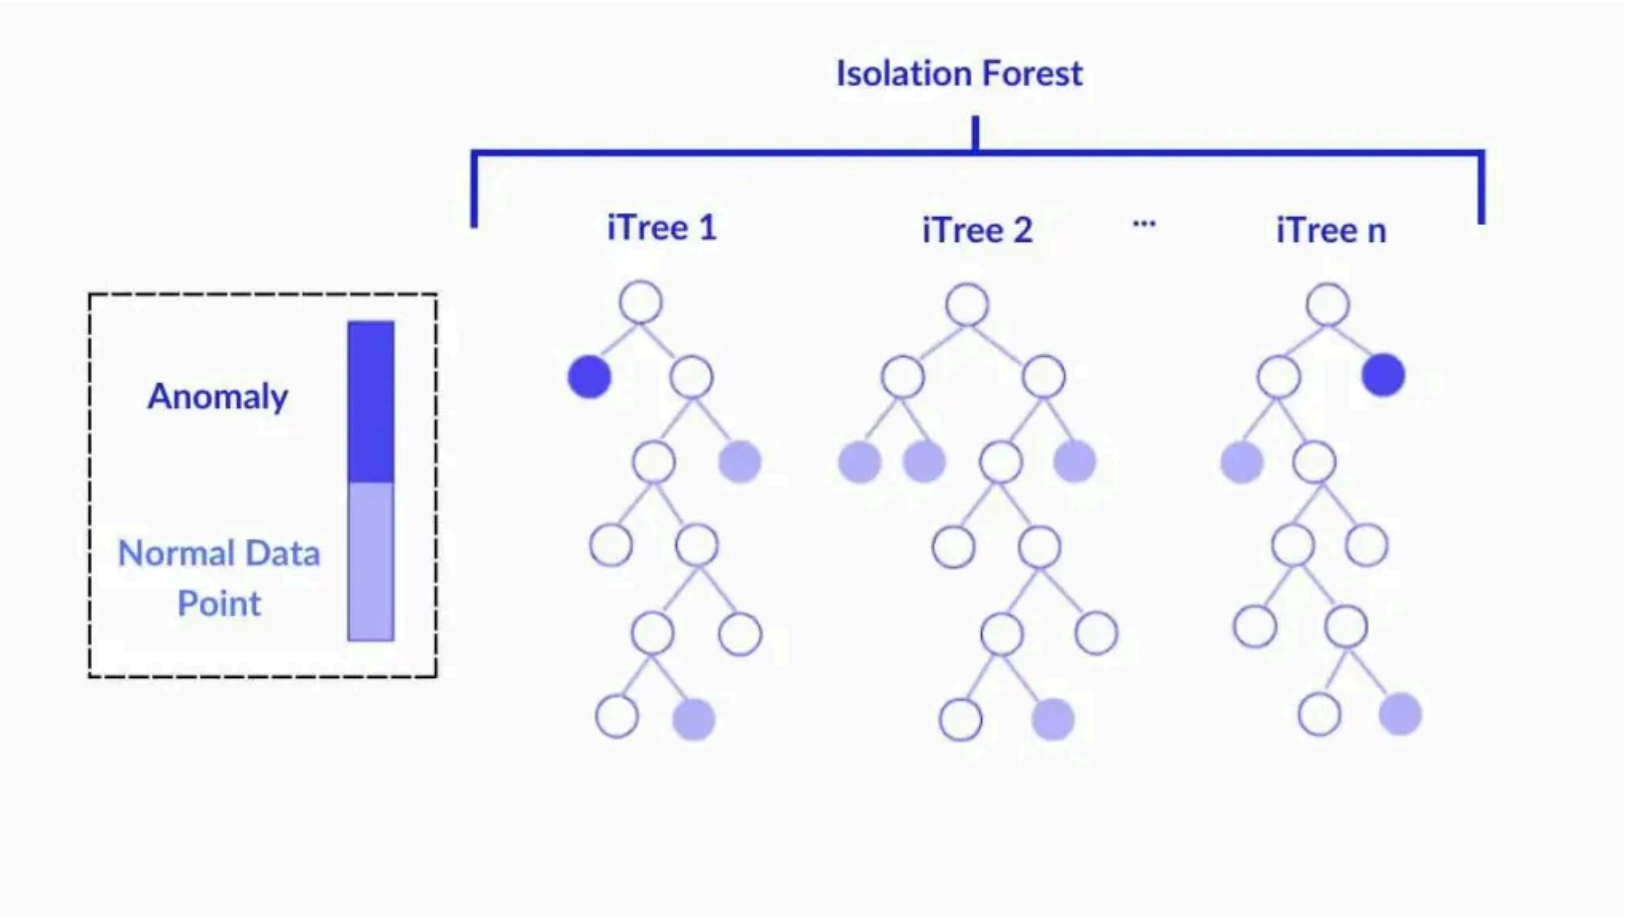
Uma única árvore pode ser bastante instável, pois depende fortemente das escolhas aleatórias realizadas durante sua construção. Pequenas mudanças nas divisões podem alterar significativamente os comprimentos dos caminhos observados.

Isolation Forest

Isolation Forest

Para reduzir essa variabilidade, utilizamos um conjunto de árvores. A coleção de várias Isolation Trees é chamada de Isolation Forest. O resultado final é obtido combinando as informações produzidas por todas as árvores da floresta.

Isolation Forest



Construção da Floresta

Cada árvore é construída utilizando uma subamostra aleatória dos dados. Esse procedimento aumenta a diversidade entre as árvores e reduz o custo computacional, tornando o algoritmo adequado para bases de dados muito grandes.

Profundidade Média

Após construir a floresta, calcula-se o comprimento do caminho de cada observação em todas as árvores. Em seguida, obtém-se a média desses comprimentos. Essa média resume o quão facilmente a observação foi isolada ao longo da floresta.

Score de anomalia

O comprimento médio do caminho é convertido em um score de anomalia. Observações isoladas rapidamente recebem valores altos de anomalia. Observações que exigem muitas divisões recebem scores menores, indicando comportamento compatível com o padrão predominante.

Score de anomalia

Para uma observação $\mathbf{x}$, calculamos inicialmente o comprimento médio do caminho:

$$E[h(\mathbf{x})] = \frac{1}{T}\sum_{t=1}^{T} h_t(\mathbf{x}),$$

em que:

- T é o número de árvores da floresta;
- $h_t(\mathbf{x})$ é a profundidade da observação na árvore t.

Score de anomalia

Para normalizar esse valor utiliza-se

$$c(n) = 2H(n-1) - \frac{2(n-1)}{n},$$

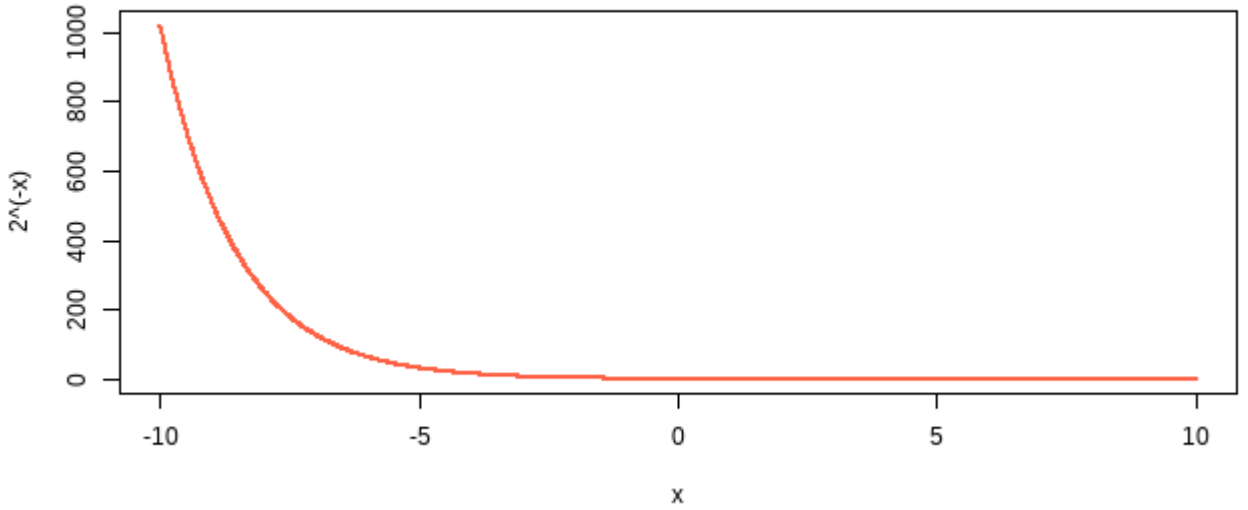
onde $H(i)$ é o número harmônico

$$H(i) = \sum_{k=1}^{i} \frac{1}{k} \approx \ln(i) + 0.5772.$$

O score de anomalia é então definido por

$$s(\mathbf{x}, n) = 2^{-\frac{E[h(\mathbf{x})]}{c(n)}}.$$

Score de anomalia



Quanto menor o comprimento médio do caminho, maior será o score de anomalia. Como observações anômalas são isoladas rapidamente, elas tendem a apresentar profundidades pequenas e, consequentemente, valores de score próximos de 1.

Interpretação do Score

Assim,

- $s(\mathbf{x}, n) \approx 1$: forte evidência de anomalia;
- $s(\mathbf{x}, n) \approx 0.5$: observação intermediária;
- $s(\mathbf{x}, n) \approx 0$: observação normal.

Dessa forma, é possível construir rankings de suspeição.

Complexidade computacional

Uma das maiores vantagens do Isolation Forest é sua eficiência computacional.

O algoritmo possui complexidade aproximadamente linear em relação ao número de observações analisadas, permitindo aplicações em conjuntos de dados com milhões de registros.

Vantagens

O método não exige hipóteses fortes sobre a distribuição dos dados, funciona bem em ambientes não supervisionados, apresenta alta escalabilidade e possui implementação relativamente simples. Essas características explicam sua ampla popularidade.

Limitações

Embora seja bastante eficiente, o método pode enfrentar dificuldades quando existem muitas variáveis irrelevantes ou quando as anomalias formam agrupamentos densos semelhantes aos grupos normais. Nessas situações, outras abordagens podem complementar a análise.

Aplicações práticas

O algoritmo é amplamente utilizado em detecção de fraudes financeiras, monitoramento de redes de computadores, manutenção preditiva, controle de qualidade industrial, análise de sensores e monitoramento de equipamentos críticos.

Exemplo em R

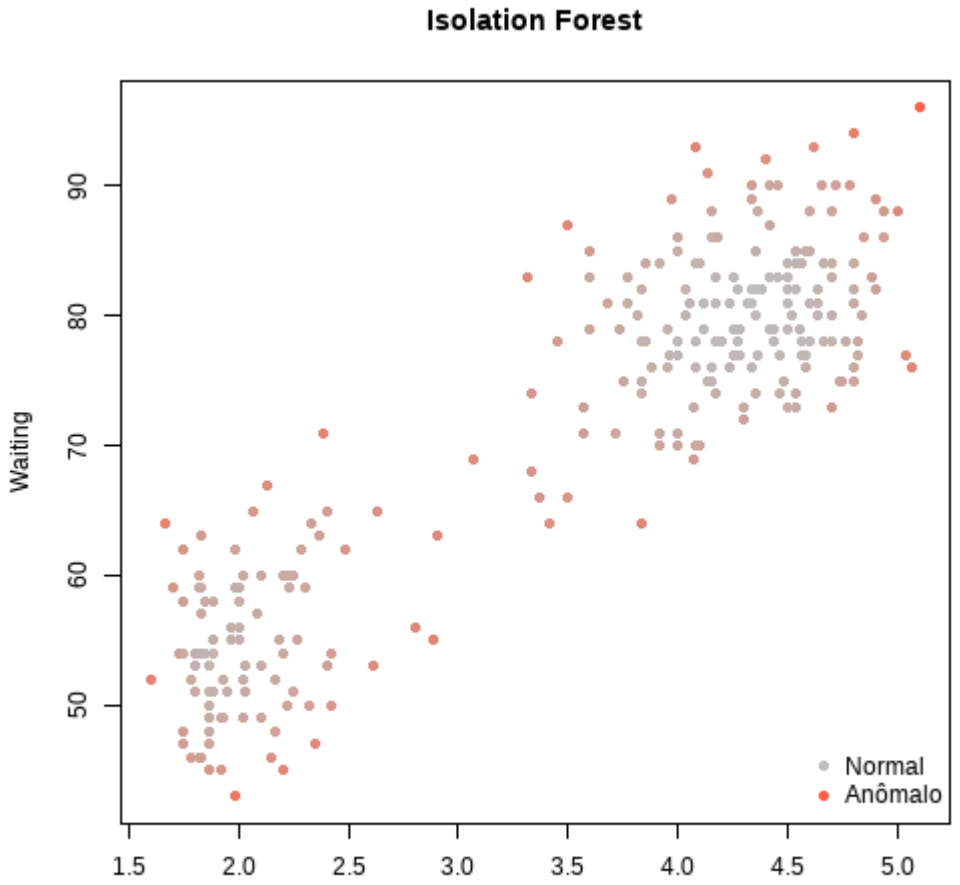
O pacote isotree fornece implementações eficientes do Isolation Forest.

```
require(isotree)
data(faithful)
modelo <- isolation.forest(faithful,
                           ntrees = 1000)

score <- predict(modelo, faithful,
                 type = "score")
```

Os scores obtidos podem ser utilizados para identificar observações suspeitas.

Exemplo em R


Isolation Forest
Waiting
50
60
70
80
90
1.5
2.0
2.5
3.0
3.5
4.0
4.5
5.0
Normal
Anômalo