UNIVERSIDADE FEDERAL DO PARANÁ

Setor de Ciências Exatas

Departamento de Estatística

Eduardo Demetrio da Silva

REGRA DE ASSOCIAÇÃO E ALGORITMO APRIORI

Análise e proposta de reformulação didática do capítulo 13

CURITIBA

2026

1.Indicação e motivação

Neste relatório vou realizar a avaliação do capítulo 13 (Regras de associação e algoritmo Apriori) da apostila de referência.

A motivação da escolha desse capítulo, decorre do meu interesse acadêmico e profissional pelo tema e por ser um tema que no futuro quero fazer pesquisas mais intensiva na metodologia e projetos relacionados. É um tema voltado a um sistema de recomendação com aplicação prática, o capítulo aborda conceitos, interpretações e exemplos aplicados que facilitam a compreensão do método.

2. Análise

O capítulo 13 apresenta de forma clara os principais conceitos relacionados às regras de associação e ao algoritmo Apriori. O texto possui boa progressão conceitual e utiliza exemplos aplicados, o que favorece a compreensão do tema por estudantes de graduação. No entanto, alguns pontos podem ser reformulados para melhorar a precisão conceitual, a organização didática e a interpretação dos resultados apresentados.

O primeiro ponto de melhoria está na página 473. O texto afirma que o capítulo busca identificar “padrões de coocorrência entre as colunas, os itens ou eventos”. Embora a ideia geral esteja correta, a expressão “entre as colunas” pode gerar ambiguidade para o leitor, pois regras de associação não são aplicadas necessariamente a colunas de uma base tabular tradicional, mas sim a itens ou eventos que aparecem conjuntamente em transações.

Frase atual:

“Ambos operam sobre as linhas de uma tabela de dados, as observações. Este capítulo aborda uma pergunta diferente: existem padrões de coocorrência entre as colunas, os itens ou eventos, que se repetem com frequência acima do esperado?”

Proposta de reformulação:

“Enquanto os métodos anteriores analisam principalmente as observações de uma tabela de dados, este capítulo investiga padrões de coocorrência entre itens ou eventos. Em outras palavras, busca-se identificar combinações que aparecem juntas com frequência maior do que seria esperado ao acaso.”

Essa reformulação torna o trecho mais acessível para estudantes de graduação, pois aproxima a definição do funcionamento prático das regras de associação.

Na página 476, há uma oportunidade de melhoria didática na explicação sobre filtragem colaborativa. O texto apresenta corretamente a ideia geral de que a recomendação pode ser baseada no comportamento de usuários semelhantes. No entanto, para uma visão mais completa, seria interessante diferenciar filtragem colaborativa baseada em usuários e filtragem colaborativa baseada em itens.

Frase atual:

“A filtragem colaborativa recomenda o que usuários semelhantes consumiram, ‘usuários como você também assistiram X’, sem depender das características dos itens.”

Proposta de acréscimo:

“Na filtragem colaborativa user-based, a recomendação parte da identificação de usuários com comportamentos semelhantes. Já na filtragem colaborativa item-based, a recomendação parte da similaridade entre itens consumidos, avaliados ou escolhidos de forma parecida.”

Essa inclusão ajuda o graduando a perceber que a filtragem colaborativa não é uma abordagem única, mas pode ser estruturada a partir da semelhança entre usuários ou entre itens.

Na página 481, a história do mini-projeto apresenta a seguinte pergunta:

“Existem padrões que diferenciam regiões ou classes de renda?”

Entretanto, no código apresentado em seguida, não são criadas variáveis de região ou classe de renda. Dessa forma, a pergunta proposta não pode ser respondida diretamente com os dados simulados utilizados no mini-projeto. Esse ponto pode gerar divergência entre a expectativa inicial do problema e a análise efetivamente realizada.

Uma alternativa seria reformular a pergunta para adequá-la aos dados disponíveis:

“Existem padrões de coocorrência entre grupos alimentares?”

Outra possibilidade seria manter a pergunta original, mas acrescentar variáveis como região e classe de renda na base simulada. Esse ajuste também poderia ser usado como ponto didático, mostrando ao leitor que um analista ou cientista de dados precisa alinhar as perguntas de pesquisa com as variáveis disponíveis na base.

Na página 482, o código cria um grupo de itens chamado “regionais”, incluindo alimentos como Cuscuz, Tapioca, Açaí, Pão de queijo e Churrasco. Apesar de o termo “regionais” ser compreensível, ele pode sugerir que há uma variável geográfica associada aos dados, como Nordeste, Norte, Sul ou Sudeste, o que não ocorre no exemplo. Para evitar essa interpretação, seria mais adequado utilizar uma nomenclatura como “alimentos típicos” ou “itens típicos”.

Trecho atual:

“regionais <- c(‘Cuscuz’, ‘Tapioca’, ‘Açaí’, ‘Pão_de_queijo’, ‘Churrasco’)”

Proposta de reformulação:

“tipicos <- c(‘Cuscuz’, ‘Tapioca’, ‘Açaí’, ‘Pão_de_queijo’, ‘Churrasco’)”

Essa alteração torna a descrição mais coerente com o objetivo do código, pois os itens representam alimentos culturalmente associados a diferentes regiões, mas não há uma variável regional propriamente dita.

Na interpretação dos resultados, na página 486, o capítulo afirma que Cuscuz e Tapioca aparecem com lift alto e que isso seria reflexo do padrão alimentar nordestino. No entanto, essa associação foi introduzida no próprio mecanismo de simulação, pois o código aumenta a probabilidade de Tapioca aparecer quando Cuscuz está presente. Portanto, a interpretação deveria deixar claro que, no conjunto simulado, a associação aparece porque foi programada, e não porque foi descoberta em dados reais.

Proposta de reformulação:

“No conjunto simulado, Cuscuz e Tapioca aparecem associados porque o mecanismo de geração dos dados aumentou a probabilidade de ocorrência conjunta desses itens. Em uma base real, essa associação poderia ser investigada como hipótese relacionada a padrões regionais de consumo, mas não deve ser interpretada como evidência empírica a partir da simulação.”

Também na página 486, o texto afirma que Refrigerante e Biscoito coocorrem com lift alto. Porém, as regras apresentadas anteriormente destacam principalmente associações envolvendo Tapioca e Cuscuz. Para sustentar a conclusão sobre Refrigerante e Biscoito, seria necessário apresentar uma tabela filtrada com regras envolvendo esses itens. Caso contrário, a afirmação deveria ser removida ou apresentada como uma sugestão de análise adicional.

Proposta de reformulação:

“Para investigar padrões associados ao consumo de alimentos processados, seria necessário filtrar e apresentar regras específicas envolvendo itens como Refrigerante, Biscoito e Embutido. Sem essa etapa, a conclusão sobre a coocorrência entre Refrigerante e Biscoito não fica diretamente sustentada pelos resultados exibidos.”

De modo geral, os pontos levantados não comprometem a relevância do capítulo, mas indicam oportunidades de melhoria para torná-lo mais preciso, didático e coerente com os dados utilizados. As principais reformulações sugeridas envolvem o alinhamento entre pergunta de pesquisa e variáveis disponíveis, o cuidado na interpretação de dados simulados e o aprofundamento de conceitos importantes para estudantes de graduação, como a diferença entre filtragem colaborativa baseada em usuários e baseada em itens.

4. Conclusão

De modo geral, o capítulo 13 cumpre muito bem o objetivo, apresenta conceitos claros e fundamentais de regras de associação e do algoritmo Apriori.
As propostas de reformulação não reduzem a qualidade do capítulo, mas buscam fortalecer sua precisão conceitual, sua coerência metodológica e sua utilidade para o público de graduação. Com esses ajustes, o capítulo tende a oferecer uma experiência de leitura mais clara, crítica e alinhada à prática de análise de dados.