Universidade Federal do Paraná - Departamento de Estatística

CE319- Estatística Multivariada

Prof. Cesar Augusto Taconeli

Lista de exercícios- Análise de componentes principais

1. Determine os componentes principais Z_1 e Z_2 com base na matriz de covariâncias:

$$\mathbf{\Sigma} = \begin{pmatrix} 5 & 2 \\ 2 & 2 \end{pmatrix}$$

Adicionalmente, calcule a proporção da variância total explicada por cada um dos componemtes.

2. Converta a matriz de covariâncias apresentada no exercício anterior em uma matriz de correlações. Com base nela:

a) Determine os componentes principais Z_1 e Z_2 e calcule a proporção da variância total explicada por cada um deles;

b) Compare os componentes obtidos a partir da matriz de correlações àqueles extraídos da matriz de covariâncias. São iguais? Deveriam ser?

c) Apresente as correlações $\text{Cor}(Y_1, Z_1)$,$\text{Cor}(Y_2, Z_1)$, $\text{Cor}(Y_1, Z_2)$ e $\text{Cor}(Y_2, Z_2)$, considerando os componentes obtidos a partir de cada uma das duas matrizes.

3. Na sequência são apresentados o vetor de médias e a matriz de covariâncias para as variáveis y_1 : vendas (em bilhões) e y_2 : lucros (também em bilhões) para 10 grandes empresas multinacionais:

$$\bar{\mathbf{y}} = \begin{bmatrix} 155.60 \\ 14.70 \end{bmatrix}, \quad S = \begin{bmatrix} 7476.45 & 303.62 \\ 303.62 & 26.19 \end{bmatrix}$$

a) Determine os componentes principais amostrais e suas variâncias. Interprete os resultados;

b) Determine a proporção da variância total explicada pelo primeiro componente;

c) Calcule a correlação entre o primeiro componente e cada uma das variáveis;

d) Considere os dados de duas dessas empresas: (i) HSBC ($y_1 = 62.97$; $y_2 = 9.52$ e (ii) General Eletric ($y_1 = 152.36$; $y_2 = 16.59$). Calcule os escores dessas duas empresas para cada componente;

e) Refaça os itens anteriores considerando a matriz de correlações amostral.

4. Vinte jovens engenheiros e 20 pilotos foram avaliados por uma bateria de testes. As variáveis resultantes correspondem às notas nos seguintes testes:
   - y_1: inteligência;
   - y_2: relações pessoais;
   - y_3: dinamômetro;
   - y_4: pontilhamento;

- y_5: coordenação motora sensorial;
- y_6: preservação.

A base de dados pode ser encontrada na página da disciplina. Além dessas seis variáveis, há uma primeira (`categoria`) que serve apenas para identificar os participantes como engenheiros (`categoria=1`) ou pilotos (`categoria=2`).

a) Com base na matriz de covariâncias ponderadas;

b) Com base na matriz de covariâncias ignorando a estrutura de grupos, calculada com base nas 40 observações.

Compare os resultados obtidos.

5. Para cada uma das bases de dados relacionadas na sequência você deverá realizar uma análise completa, baseada em ACP. Isso inclui a realização de:

- Gráficos e medidas descritivas;
- Identificação de outliers e assimetria, verificação de possíveis medidas corretivas;
- Obtenção e visualização das matrizes de covariâncias e correlações;
- Determinação dos componentes principais;
- Avaliação do número de componentes a serem considerados na análise;
- Apresentação dos componentes como combinações lineares das variáveis originais;
- Cálculo dos escores para ao menos duas observações em dois componentes;
- Análise dos componentes principais com base em suas cargas e nas correlações com as variáveis originais;
- Comparação dos resultados baseados nas matrizes de covariâncias e de correlações;
- Apresentação de gráficos baseados nos resultados da ACP.

a) Os dados 'retorno de ações' referem-se às taxas semanais de retorno para os preços de ações de 5 companhias: J.P. Morgan, Citibank, Wells Fargo, Royal Dutch Shell e Exxon Mobil.

b) Os dados do arquivo hematologia, contendo as variáveis:

- y_1 : hemoglobin concentration;
- y_2 : packed cell volume;
- y_3 : white blood cell count;
- y_4 : lymphocyte count;
- y_5 : neutrophil count;
- y_6 : serum lead concentration.

c) As variáveis *mpg*, *disp*, *hp*, *drat*, *wt*, *qsec*, *gear* da base *mtcars*, do R.

d) Os dados da base *decathlon*, pacote *FactoMineR* do R.