Universidade Federal do Paraná - Departamento de Estatística

CE319- Estatística Multivariada

Prof. Cesar Augusto Taconeli

Lista de exercícios (UD02)

1. Os dados apresentados no arquivo 'Futebol', disponível na página da disciplina, são informações de 335 atletas da liga profissional de futebol americano. As variáveis são as seguintes:

- Atleta - nome do atleta;
- Universidade - nome da universidade;
- Posição - posição em que joga;
- Pontuação - escore;
- Altura - em polegadas;
- Envergadura - em polegadas;
- Peso - em libras;
- Comp.mao - comprimento da mão em polegadas;
- Tempo.40 - tempo para percorrer 40 jardas (segundos);
- Força - resultado do teste de força;
- Pulo.vert - distância vertical do salto;
- Pulo.hor - distância horizontal do salto;
- Corrida - tempo (em segundos);
- Corrida2 - tempo (em segundos).

Faça uma análise descritiva dos dados. Utilize gráficos, obtenha as medidas descritivas vistas em aula. Converta as variáveis para unidades de medida adotadas no Brasil.

2. Considere a matriz de dados:

$$\boldsymbol{X} = \begin{pmatrix} -1 & 3 & -2 \\ 2 & 4 & 2 \\ 5 & 2 & 3 \end{pmatrix}$$

a) Calcule a matriz de desvios (resíduos) $\boldsymbol{x} - \mathbf{1}\bar{\boldsymbol{x}}'$. Essa matriz tem rank completo? Justifique.

b) Determine $\boldsymbol{S}$ e calcule a variância generalizada.

c) Usando os resultados do ítem anterior, calcule a variância total.

3. Os dados do arquivo 'Radioterapia', disponível na página da disciplina, referem-se a escores atribuídos a pacientes com câncer, tratados com radioterapia, segundo as seguintes variáveis:

- x1: escore relativo ao número de sintomas;

- x2: escore referente às atividades (numa escala de 1-5);
- x3: escore de sono (1-5);
- x4: escore de alimentação (1-3);
- x5: escore de apetite (1-5);
- x6: escore de reações na pele (0-3).

Faça uma análise descritiva desses dados, usando gráficos, médias, variâncias e covariâncias, correlações...

4. Os dados contidos no arquivo `Ossos`, disponível na página da disciplina, referem-se ao tamanho (cm) de determinado osso em crianças. Cada criança teve o osso medido semestralmente a partir dos oito anos de idade, de tal forma que y_1 se refere à medida aos 8 anos de idade, y_2 aos oito e meio, y_3 aos nove e y_4 aos nove e meio.

a) Usando o R, obtenha o vetor de médias, a matriz de covariâncias e a matriz de correlações amostrais;

b) Obtenha a variância generalizada e a variância total;

c) Usando a função xyplot da biblioteca lattice, faça um gráfico com o tamanho do osso no eixo vertical, a idade da criança no eixo horizontal e cada criança representada por uma linha, que une os quatro pontos correspondentes às suas quatro medidas. Adicione ao gráfico a linha média.

d) Faça um correlograma. Analise os resultados obtidos.

5. Os dados presentes no arquivo 'Glicose', disponível na página da disciplina, referem-se a seis medidas de glicose no sangue, tomadas em 50 mulheres. Os y's representam os níveis de glicose registrados nas três ocasiões; os x's são as medidas de glicose tomadas uma hora após a ingestão de açúcar.

a) Obtenha o vetor de médias, a matriz de covariâncias e a matriz de correlações amostrais para todas as seis variáveis;

b) Considerando a partição das variáveis originais em $(\boldsymbol{x}; \boldsymbol{y})$, re-apresente os resultados do item anterior, destacando, no vetor e nas matrizes, os vetores de média e as matrizes de covariâncias originadas pela partição;

c) Construa gráficos 3d para $\boldsymbol{x}$ e para $\boldsymbol{y}$. Experimente diferentes ângulos para a visualização dos resultados.

6. Considere as duas matrizes de covariâncias:

$$\boldsymbol{\Sigma_1} = \begin{pmatrix} 14 & 8 & 3 \\ 8 & 5 & 2 \\ 3 & 2 & 1 \end{pmatrix} \qquad \boldsymbol{\Sigma_2} = \begin{pmatrix} 6 & 6 & 1 \\ 6 & 8 & 2 \\ 1 & 2 & 1 \end{pmatrix}$$

Mostre que a variância generalizada da população 2 é maior do que a da população 1, embora a variância total seja maior para a população 1. Comente com relação a esse fato, baseado nas covariâncias e nas correlações.

7. Considere os dois seguintes vetores de dados:

$$\boldsymbol{y_1} = \begin{pmatrix} 10 \\ 8 \\ 2 \end{pmatrix} \qquad \boldsymbol{y_2} = \begin{pmatrix} 6 \\ 5 \\ 4 \end{pmatrix}$$

Para esse par de observações, calcule as seguintes medidas de distância sem usar as funções específicas do R:

a) Distância Euclideana;

b) Distância de Manhattan;

c) Distância de Chebyshev;

d) Distância de Canberra;

e) Distância de Minkowski.

8. Sejam dois vetores de dados binários conforme a seguir:

$$\boldsymbol{y_1} = \begin{pmatrix} 0 \\ 0 \\ 1 \\ 0 \\ 1 \\ 1 \\ 1 \\ 1 \end{pmatrix} \qquad \boldsymbol{y_2} = \begin{pmatrix} 0 \\ 1 \\ 1 \\ 0 \\ 0 \\ 1 \\ 0 \\ 1 \end{pmatrix}$$

Para esse par de observações, calcule as seguintes medidas de similaridades sem usar as funções específicas do R:

a) Índice de empates simples;

b) Índice de Jaccard;

c) Índice de Dice-Sorensen;

d) Índice de Oshiai.

9. Considere a base de dados `USArrests`. Usando as funções específicas do R, obtenha matrizes de distância usando as medidas estudadas em sala de aula. Produza visualizações das matrizes de distâncias usando mapas de calor. Compare os resultados.