Universidade Federal do Paraná - Departamento de Estatística
CE319- Estatística Multivariada
Prof. Cesar Augusto Taconeli
Lista de exercícios (UD04)

1. Considere os dados:

$$\boldsymbol{X} = \begin{pmatrix} 2 & 12 \\ 8 & 9 \\ 6 & 9 \\ 8 & 10 \end{pmatrix}$$

1. Calcule a estatística T^2 para testar $H_0 : \boldsymbol{\mu' = (7.11)}$;
2. Especifique a distribuição de T^2 sob H_0;
3. Com base nos itens anteriores, teste H_0 ao nível de significância de 5%. Qual a sua conclusão?

2. Um antropologista realizou a análise mineral de nove fósseis humanos localizados no Peru. Os resultados de Cromo (y_1) e Estrôncio (y_2), em partes por milhão (ppm) são apresentados na sequência:

Fóssil	1	2	3	4	5	6	7	8	9
y_1	0.48	40.53	2.19	0.55	0.74	0.66	0.93	0.37	0.22
y_2	12.57	73.68	11.13	20.03	20.29	0.78	4.64	0.43	1.08

Sabe-se que baixos níveis (menores ou iguais a 0.100 *ppm*) de Cromo sugerem a presença de diabetes, enquanto o Estrôncio é um indicador do consumo de proteína animal.

a) Usando o R, obtenha a elipse de 90% de confiança para o vetor de médias populacional $\boldsymbol{\mu'} = (\mu_1, \mu_2)$, assumindo que esses nove peruanos representem uma amostra aleatória de indivíduos de alguma comunidade que habitava o Peru à época;

b) Obtenha os intervalos de confiança simultâneos de 90% para μ_1 e μ_2 projetando a ellipse obtida no item anterior em cada eixo (o que corresponde aos intervalos de confiança simultâneos T^2). Há indicativos de que os membros dessa comunidade tivessem nível médio de Estrôncio igual a 10? $(0,30\ ;10)'$ é um resultado plausível para $\boldsymbol{\mu}$? Apresente seus argumentos;

c) Os dados disponíveis parecem ter sido produzidos por uma população normal bivariada? Fundamente sua discussão com base em gráficos do tipo quantil-quantil e de dispersão. Se os dados não remetem à distribuição normal bivariada, qual a implicação disso para os resultados apresentados no item *b*?

d) Repita as análises mediante exclusão do óbvio outlier presente na amostra. As inferências mudam? Comente.

3. Estações de tratamento de águas são fundamentais para monitorar a qualidade da água tratada que entra em rios e córregos. Para analisar a confiabilidade de um programa de auto-monitoramento, 11 amostras de água foram divididas em duas partes, sendo que uma parte foi enviada para análise para um laboratório público, enquanto a outra parte foi encaminhada para um laboratório privado. Duas variáveis foram medidas: a demanda bioquímica de oxigênio (DBO) e a quantidade de partículas suspensas (PS). Os dados obtidos estão disponíveis no arquivo `Dados_TH_Laboratorios.Rdata`:

a) Há diferença nos vetores de médias de DBO e PS entre laboratórios? Baseie sua conclusão em um nível de 5% de significância;

b) Construa a região de confiança para o vetor diferença média ($\boldsymbol{\delta}$). Note que o ponto $\boldsymbol{\delta} = \mathbf{0}$ encontra-se fora do contorno de 95%. Isso está de acordo com o resultado do teste realizado no item anterior?

c) Obtenha intervalos de confiança simultâneos para os elementos de $\boldsymbol{\delta}$ pelos métodos T^2 e Bonferroni. Compare e discuta os resultados;

d) Os dados correspondentes à amostra 8 são bastante discrepantes. Refaça a análise após exclusão dessa amostra. Compare os resultados obtidos aos originais. Qual o impacto (se há) do outlier na análise?

e) Refaça a análise após transformar os dados para $ln(DBO)$ e $ln(PS)$. Avalie a condição de normalidade bivariada para os dados transformados. Compare os resultados aos obtidos originalmente.

4. Na primeira fase de um estudo de transporte de leite das fazendas para os distribuidores, foram levantados os custos de transporte para uma amostra de 59 caminhões de empresas de transporte. Custos referentes a combustível (y_1), manutenção (y_2) e depreciação (y_3), todos tomados numa base por milha rodada, foram registrados para $n_1 = 36$ caminhões abastecidos com gasolina e $n_1 = 23$ caminhões à diesel. Os dados estão disponíveis na página da disciplina, com o nome `Dados_TH_Leite.Rdata`.

a) Teste a hipótese de igualdade dos vetores de custos médios. Considere $\alpha = 0,01$;

b) Construa intervalos de confiança simultâneos para os pares de componentes dos vetores de médias. Qual custo, se houver, parece apresentar maior diferença?

c) Comente sobre a validade dos resultados de sua análise. Em particular, verifique que as observações 9 e 21, para caminhões movidos a gasolina, configuram outliers multivariados. Repita o teste de hipóteses após excluir esses dois caminhões da análise. Comente os resultados.

5. Um cientista coletou dados de ursos de determinada espécie que habitavam uma reserva. As seguintes medidas foram registradas para 61 ursos: peso, em kg (X_1); tamanho do corpo, em cm (X_2); circunferência do pescoço, em cm (X_3); tamanho da mandíbula, em cm (X_4); e largura da cabeça, em cm (X_5). O vetor de médias e a matriz de covariâncias amostrais são:

$$\bar{\boldsymbol{x}} = \begin{pmatrix} 95.52 \\ 164.38 \\ 55.69 \\ 93.39 \\ 17.98 \end{pmatrix}$$

$$\boldsymbol{S} = \begin{pmatrix} 3266.46 & 1343.97 & 731.54 & 1175.50 & 162.68 & 238.37 \\ 1343.97 & 721.91 & 324.25 & 537.35 & 80.17 & 117.73 \\ 731.54 & 324.25 & 179.28 & 281.17 & 39.15 & 56.80 \\ 1175.50 & 537.35 & 281.17 & 474.98 & 63.73 & 94.85 \\ 162.68 & 80.17 & 39.15 & 63.73 & 9.95 & 13.88 \\ 238.37 & 117.73 & 56.80 & 94.85 & 13.88 & 21.26 \end{pmatrix}$$

a) Obtenha intervalos de confiança simultâneos (95%) para as médias populacionais das seis variáveis consideradas;

b) Obtenha a elipse de confiança (95%) para o peso e circunferência médias;

c) Obtenha os intervalos de confiança simultâneos de Bonferroni (95%) para as seis médias;

d) Referente ao item b, represente o retângulo gerado pelos intervalos de confiança de Bonferroni, usando $m = 6$, e a elipse de confiança obtida;

6. Um experimento inteiramente casualizado com 10 repetições foi realizado no período de seca para avaliar o efeito de 3 cultivares na altura (y_1) e no diâmetro à altura do peito (y_2) das plantas em uma área de recuperação às margens de um rio na região de Lavras, MG. Os resultados obtidos estão disponíveis na página da disciplina (com o nome `Dados_TH_Cultivar.Rdata`). Usando análise de variância multivariada, teste a hipótese de igualdade dos efeitos de transectos, utilizando os diferentes testes apresentados. Se a hipótese nula for rejeitada, conduza, na sequência, testes T^2 para identificar os cultivares responsáveis pela diferença, e intervalos de Bonferroni para verificar a(s) variável(eis) responsável(eis) pela rejeição.

7. Anacondas são algumas das maiores cobras do mundo. Jesus Ravis e sua equipe de pesquisadores capturaram diversas anacondas e mediram os comprimentos e os pesos de cada uma, além de registrar o sexo. Os dados estão disponíveis na página da disciplina, no arquivo `Dados_TH_Anaconda.Rdata`.

a) Teste a igualdade das matrizes covariâncias para machos e fêmeas. Qual sua conclusão ao nível de 5% de significância? (Vamos assumir normalidade multivariada para as medidas nos dois grupos).

b) Teste a igualdade dos vetores médias usando o teste aproximado para grandes amostras, considerando matrizes de variâncias e covariâncias diferentes;

c) Apresente intervalos de confiança simultâneos (95%) para as diferenças de médias quanto aos comprimentos e pesos das anacondas.