CE319 - Estatística multivariada

Análise de componentes principais

Cesar Augusto Taconeli

14 de abril, 2026

Análise de componentes principais

O que vamos estudar neste módulo

O que vamos estudar neste módulo

- Neste vamos estudar a técnica de análise de componentes principais.

O que vamos estudar neste módulo

- Neste vamos estudar a técnica de análise de componentes principais.

- Serão discutidos os principais objetivos e características da análise.

O que vamos estudar neste módulo

- Neste vamos estudar a técnica de análise de componentes principais.
- Serão discutidos os principais objetivos e características da análise.
- A aplicação da análise de componentes principais em bases de dados servirá como ilustração da técnica em diferentes contextos.

Análise de componentes principais

- A análise de componentes principais (ACP) é uma técnica multivariada que transforma um conjunto de p variáveis em novo conjunto de p **variáveis ortogonais** (não correlacionadas), preservando a informação contida no conjunto original.

Análise de componentes principais

- A análise de componentes principais (ACP) é uma técnica multivariada que transforma um conjunto de p variáveis em novo conjunto de p **variáveis ortogonais** (não correlacionadas), preservando a informação contida no conjunto original.

- Na ACP, um pequeno número dessas novas variáveis (componentes principais) deve ser capaz de explicar a maior parte possível da variação presente nos dados originais.

Análise de componentes principais

- A análise de componentes principais (ACP) é uma técnica multivariada que transforma um conjunto de p variáveis em novo conjunto de p **variáveis ortogonais** (não correlacionadas), preservando a informação contida no conjunto original.

- Na ACP, um pequeno número dessas novas variáveis (componentes principais) deve ser capaz de explicar a maior parte possível da variação presente nos dados originais.

- Os principais objetivos da ACP são:

Análise de componentes principais

- A análise de componentes principais (ACP) é uma técnica multivariada que transforma um conjunto de p variáveis em novo conjunto de p **variáveis ortogonais** (não correlacionadas), preservando a informação contida no conjunto original.

- Na ACP, um pequeno número dessas novas variáveis (componentes principais) deve ser capaz de explicar a maior parte possível da variação presente nos dados originais.

- Os principais objetivos da ACP são:
  - **Reduzir a dimensionalidade** dos dados;

Análise de componentes principais

- A análise de componentes principais (ACP) é uma técnica multivariada que transforma um conjunto de p variáveis em novo conjunto de p **variáveis ortogonais** (não correlacionadas), preservando a informação contida no conjunto original.

- Na ACP, um pequeno número dessas novas variáveis (componentes principais) deve ser capaz de explicar a maior parte possível da variação presente nos dados originais.

- Os principais objetivos da ACP são:
  - **Reduzir a dimensionalidade** dos dados;
  - **Criar índices** baseados em combinações das variáveis originais;

Análise de componentes principais

- A análise de componentes principais (ACP) é uma técnica multivariada que transforma um conjunto de p variáveis em novo conjunto de p **variáveis ortogonais** (não correlacionadas), preservando a informação contida no conjunto original.

- Na ACP, um pequeno número dessas novas variáveis (componentes principais) deve ser capaz de explicar a maior parte possível da variação presente nos dados originais.

- Os principais objetivos da ACP são:
  - **Reduzir a dimensionalidade** dos dados;
  - **Criar índices** baseados em combinações das variáveis originais;
  - **Produzir variáveis não correlacionadas** a partir de variáveis originalmente correlacionadas.

Análise de componentes principais

- A título de ilustração, suponha que num estudo clínico se disponha das seguintes informações avaliadas em pacientes:

Análise de componentes principais

- A título de ilustração, suponha que num estudo clínico se disponha das seguintes informações avaliadas em pacientes:
  - Pressão sistólica;

Análise de componentes principais

- A título de ilustração, suponha que num estudo clínico se disponha das seguintes informações avaliadas em pacientes:
  - Pressão sistólica;
  - Pressão diastólica;

Análise de componentes principais

- A título de ilustração, suponha que num estudo clínico se disponha das seguintes informações avaliadas em pacientes:
  - Pressão sistólica;
  - Pressão diastólica;
  - Colesterol total;

Análise de componentes principais

- A título de ilustração, suponha que num estudo clínico se disponha das seguintes informações avaliadas em pacientes:
  - Pressão sistólica;
  - Pressão diastólica;
  - Colesterol total;
  - LDL;

Análise de componentes principais

- A título de ilustração, suponha que num estudo clínico se disponha das seguintes informações avaliadas em pacientes:
  - Pressão sistólica;
  - Pressão diastólica;
  - Colesterol total;
  - LDL;
  - HDL;

Análise de componentes principais

- A título de ilustração, suponha que num estudo clínico se disponha das seguintes informações avaliadas em pacientes:
  - Pressão sistólica;
  - Pressão diastólica;
  - Colesterol total;
  - LDL;
  - HDL;
  - Triglicerídeos.

Análise de componentes principais

- A título de ilustração, suponha que num estudo clínico se disponha das seguintes informações avaliadas em pacientes:
  - Pressão sistólica;
  - Pressão diastólica;
  - Colesterol total;
  - LDL;
  - HDL;
  - Triglicerídeos.
- As variáveis apresentadas são potecialmente correlacionadas. Como resumir esse conjunto em poucos índices que capturem o "perfil cardiovascular" dos pacientes?

Análise de componentes principais

- A título de ilustração, suponha que num estudo clínico se disponha das seguintes informações avaliadas em pacientes:
  - Pressão sistólica;
  - Pressão diastólica;
  - Colesterol total;
  - LDL;
  - HDL;
  - Triglicerídeos.
- As variáveis apresentadas são potecialmente correlacionadas. Como resumir esse conjunto em poucos índices que capturem o "perfil cardiovascular" dos pacientes?
- Será que com poucas novas variáveis (uma? duas?) poderíamos resumir as seis variáveis originais com pouca perda de informação?

Análise de componentes principais

- A título de ilustração, suponha que num estudo clínico se disponha das seguintes informações avaliadas em pacientes:
  - Pressão sistólica;
  - Pressão diastólica;
  - Colesterol total;
  - LDL;
  - HDL;
  - Triglicerídeos.
- As variáveis apresentadas são potecialmente correlacionadas. Como resumir esse conjunto em poucos índices que capturem o "perfil cardiovascular" dos pacientes?
- Será que com poucas novas variáveis (uma? duas?) poderíamos resumir as seis variáveis originais com pouca perda de informação?
- A análise de componentes principais visa resolver esse tipo de problema.

Análise de componentes principais

- Os componentes principais são combinações lineares das variáveis originais.

Análise de componentes principais

- Os componentes principais são combinações lineares das variáveis originais.
  - O primeiro componente é aquele **capaz de explicar a maior parte possível da variação dos dados**;
  - O segundo componente é aquele que explica **a maior parte possível da variação não explicada pelo primeiro**, sendo **ortogonal ao primeiro componente**;
  - O terceiro componente é aquele que **explica a maior parte possível da variação não explicada pelos dois primeiros**, sendo **ortogonal aos dois primeiros**...

Análise de componentes principais

- Os componentes principais são combinações lineares das variáveis originais.
  - O primeiro componente é aquele **capaz de explicar a maior parte possível da variação dos dados**;
  - O segundo componente é aquele que explica **a maior parte possível da variação não explicada pelo primeiro**, sendo **ortogonal ao primeiro componente**;
  - O terceiro componente é aquele que **explica a maior parte possível da variação não explicada pelos dois primeiros**, sendo **ortogonal aos dois primeiros**...

- Geometricamente, as combinações lineares representam um novo sistema de coordenadas, obtido por meio da rotação dos eixos originais.

Análise de componentes principais

- Vamos motivar a análise de componentes principais por uma ilustração bastante simples, envolvendo apenas duas variáveis: peso (kg) e altura (m).

Análise de componentes principais

- Vamos motivar a análise de componentes principais por uma ilustração bastante simples, envolvendo apenas duas variáveis: peso (kg) e altura (m).
- Desta forma, o primeiro componente principal (PC1) é a combinação linear de peso e altura que tenha maior variação possível:

$$\text{PC}_1 = a_{11} \times \text{peso} + a_{12} \times \text{altura},$$

sendo a_{11} e a_{12} os coeficientes da combinação linear (cargas ou *loadings* de PC1).

Análise de componentes principais

- Vamos motivar a análise de componentes principais por uma ilustração bastante simples, envolvendo apenas duas variáveis: peso (kg) e altura (m).
- Desta forma, o primeiro componente principal (PC1) é a combinação linear de peso e altura que tenha maior variação possível:

$$\text{PC}_1 = a_{11} \times \text{peso} + a_{12} \times \text{altura},$$

sendo a_{11} e a_{12} os coeficientes da combinação linear (cargas ou *loadings* de PC1).

- Já o segundo componente principal (PC2) é a combinação linear de maior variação possível ortogonal a PC1:

$$\text{PC}_2 = a_{21} \times \text{peso} + a_{22} \times \text{altura}.$$

Análise de componentes principais

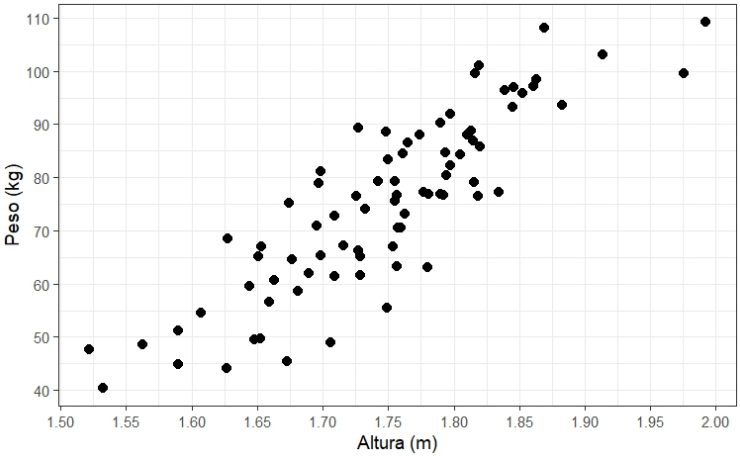


Figura 1: Dados de peso a altura

Análise de componentes principais

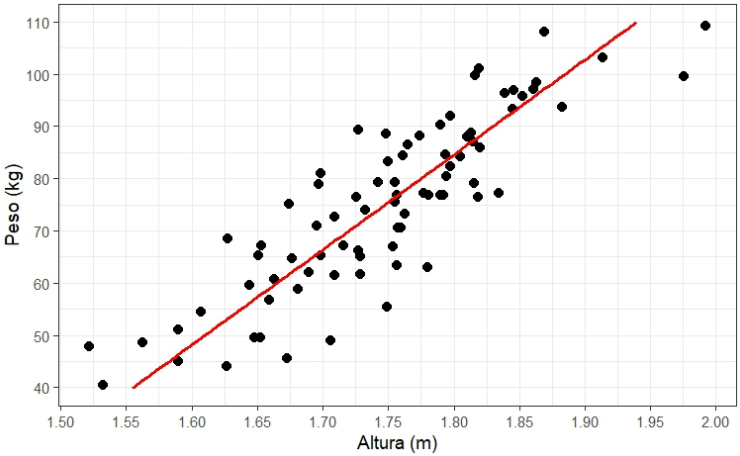


Figura 2: Representação do primeiro componente principal (PC1)

Análise de componentes principais

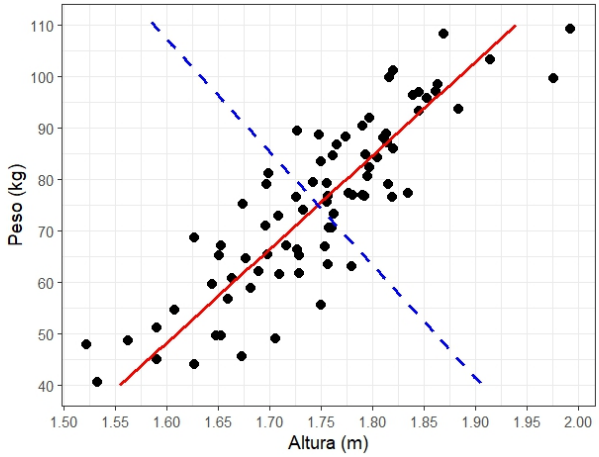


Figura 3: Representação dos dois componentes principais (PC1 em vermelho, PC2 em azul)

Análise de componentes principais

- Interpretação dos componentes principais:

Análise de componentes principais

- Interpretação dos componentes principais:
  - PC1 é um índice de tamanho geral (peso + altura);

Análise de componentes principais

- Interpretação dos componentes principais:
  - PC1 é um índice de tamanho geral (peso + altura);
  - PC2 é contraste entre peso e altura.

Análise de componentes principais

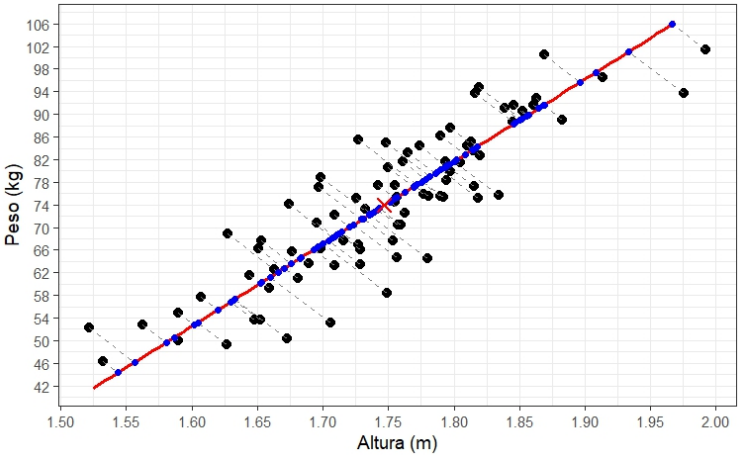


Figura 4: Escores das observações em PC1 (valores projetados em PC1)

Análise de componentes principais

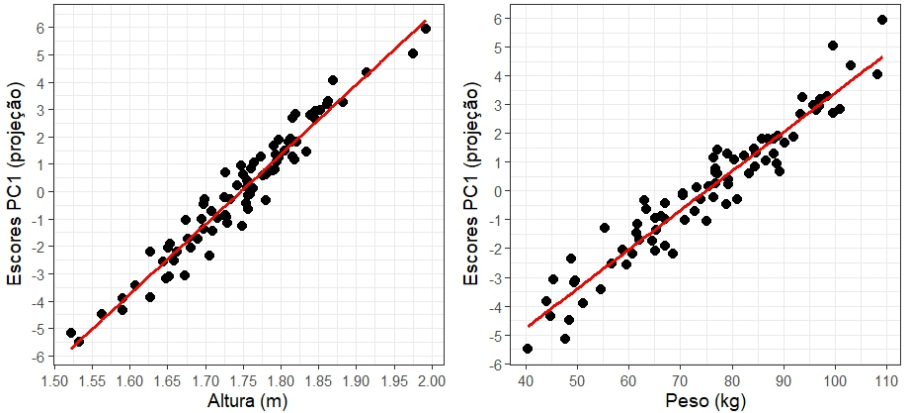


Figura 5: Correlação de PC1 com peso e altura

Análise de componentes principais

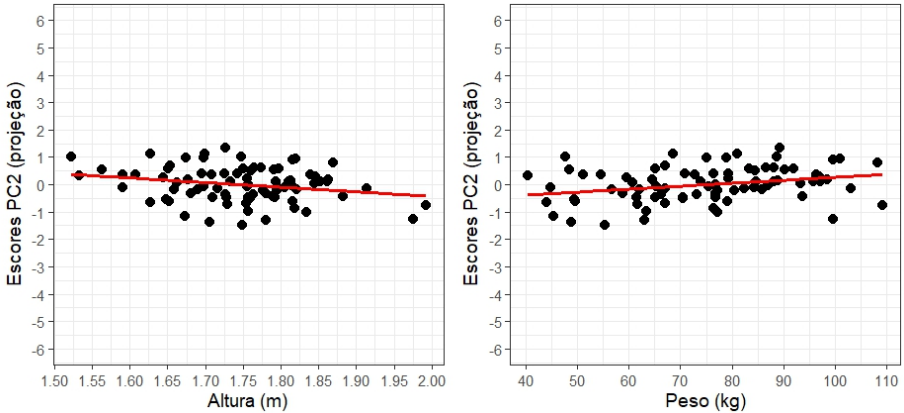


Figura 6: Correlação de PC2 com peso e altura

Análise de componentes principais

- As novas variáveis (componentes principais) definem um novo sistema de eixos.

Análise de componentes principais

- As novas variáveis (componentes principais) definem um novo sistema de eixos.

Análise de componentes principais

- As novas variáveis (componentes principais) definem um novo sistema de eixos.
- A primeira nova direção, definida pelo primeiro componente principal, é aquela onde os dados variam mais.

Análise de componentes principais

- As novas variáveis (componentes principais) definem um novo sistema de eixos.
- A primeira nova direção, definida pelo primeiro componente principal, é aquela onde os dados variam mais.
- A segunda nova direção é perpendicular à primeira capturando maior parte possível da variação não explicada...

Análise de componentes principais

- As novas variáveis (componentes principais) definem um novo sistema de eixos.
- A primeira nova direção, definida pelo primeiro componente principal, é aquela onde os dados variam mais.
- A segunda nova direção é perpendicular à primeira capturando maior parte possível da variação não explicada...
- O processo continua até a obtenção dos p componentes principais, sendo p o número de variáveis originais.

Obtenção das componentes principais

Obtenção dos componentes principais

- Considere o vetor aleatório $\boldsymbol{Y}' = (Y_1, Y_2, ..., Y_p)$ com matriz de covariâncias $\boldsymbol{\Sigma}$.

Obtenção dos componentes principais

- Considere o vetor aleatório $\boldsymbol{Y}' = (Y_1, Y_2, ..., Y_p)$ com matriz de covariâncias $\boldsymbol{\Sigma}$.
- Considere as combinações lineares:

Obtenção dos componentes principais

- Considere o vetor aleatório $\boldsymbol{Y}' = (Y_1, Y_2, ..., Y_p)$ com matriz de covariâncias $\boldsymbol{\Sigma}$.
- Considere as combinações lineares:

$$Z_1 = \boldsymbol{a_1'}\boldsymbol{Y} = a_{11}Y_1 + a_{12}Y_2 + ... + a_{1p}Y_p$$

Obtenção dos componentes principais

- Considere o vetor aleatório $\boldsymbol{Y}' = (Y_1, Y_2, ..., Y_p)$ com matriz de covariâncias $\boldsymbol{\Sigma}$.
- Considere as combinações lineares:

$$Z_1 = \boldsymbol{a_1'Y} = a_{11}Y_1 + a_{12}Y_2 + ... + a_{1p}Y_p$$

$$Z_2 = \boldsymbol{a_2'Y} = a_{21}Y_1 + a_{22}Y_2 + ... + a_{2p}Y_p$$

Obtenção dos componentes principais

- Considere o vetor aleatório $\boldsymbol{Y}' = (Y_1, Y_2, ..., Y_p)$ com matriz de covariâncias $\boldsymbol{\Sigma}$.
- Considere as combinações lineares:

$$Z_1 = \boldsymbol{a_1'Y} = a_{11}Y_1 + a_{12}Y_2 + ... + a_{1p}Y_p$$

$$Z_2 = \boldsymbol{a_2'Y} = a_{21}Y_1 + a_{22}Y_2 + ... + a_{2p}Y_p$$

$$\vdots$$

$$Z_p = \boldsymbol{a_p'Y} = a_{p1}Y_1 + a_{p2}Y_2 + ... + a_{pp}Y_p$$

Obtenção dos componentes principais

- Considere o vetor aleatório $\boldsymbol{Y}' = (Y_1, Y_2, ..., Y_p)$ com matriz de covariâncias $\boldsymbol{\Sigma}$.
- Considere as combinações lineares:

$$Z_1 = \boldsymbol{a_1'Y} = a_{11}Y_1 + a_{12}Y_2 + ... + a_{1p}Y_p$$

$$Z_2 = \boldsymbol{a_2'Y} = a_{21}Y_1 + a_{22}Y_2 + ... + a_{2p}Y_p$$

$$\vdots$$

$$Z_p = \boldsymbol{a_p'Y} = a_{p1}Y_1 + a_{p2}Y_2 + ... + a_{pp}Y_p$$

Obtenção dos componentes principais

- Sabemos que:

$$Var(Z_i) = \boldsymbol{a_i'\Sigma a_i}, \qquad i = 1, 2, ..., p$$

$$Cov(Z_i, Z_k) = \boldsymbol{a_i'\Sigma a_k}, \qquad i, k = 1, 2, ..., p$$

Obtenção dos componentes principais

- Sabemos que:

$$Var(Z_i) = \boldsymbol{a_i'\Sigma a_i}, \qquad i = 1, 2, ..., p$$
$$Cov(Z_i, Z_k) = \boldsymbol{a_i'\Sigma a_k}, \qquad i, k = 1, 2, ..., p$$

- Os componentes principais são as combinações lineares $(Z_1, Z_2, ..., Z_p)$ de $Y_1, Y_2, ..., Y_p$, **não correlacionadas** e tais que cada componente, sucessivamente, tenha **maior variância possível**.

Obtenção dos componentes principais

- Sabemos que:

$$Var(Z_i) = \boldsymbol{a_i'\Sigma a_i}, \quad i = 1, 2, ..., p$$
$$Cov(Z_i, Z_k) = \boldsymbol{a_i'\Sigma a_k}, \quad i, k = 1, 2, ..., p$$

- Os componentes principais são as combinações lineares $(Z_1, Z_2, ..., Z_p)$ de $Y_1, Y_2, ..., Y_p$, **não correlacionadas** e tais que cada componente, sucessivamente, tenha **maior variância possível**.

- No entanto, $Var(Z_i) = \boldsymbol{a_i'\Sigma a_i}$ pode crescer indefinidamente multiplicando $\boldsymbol{a_i}$ por alguma constante. Assim, aplicamos a restrição $\boldsymbol{a_i'a_i} = 1$.

Obtenção dos componentes principais

Passo 1- Primeiro componente principal: combinação linear $\boldsymbol{a}_1'\boldsymbol{Y}$ que maximiza Var($\boldsymbol{a}_1'\boldsymbol{Y}$) sujeita a $\boldsymbol{a}_1'\boldsymbol{a}_1 = 1$;

Obtenção dos componentes principais

Passo 1- Primeiro componente principal: combinação linear $\boldsymbol{a}_1'\boldsymbol{Y}$ que maximiza $\text{Var}(\boldsymbol{a}_1'\boldsymbol{Y})$ sujeita a $\boldsymbol{a}_1'\boldsymbol{a}_1 = 1$;

Passo 2- Segundo componente principal: combinação linear $\boldsymbol{a}_2'\boldsymbol{Y}$ que maximiza $\text{Var}(\boldsymbol{a}_2'\boldsymbol{Y})$ sujeita a $\boldsymbol{a}_2'\boldsymbol{a}_2 = 1$ e $\text{Cov}(\boldsymbol{a}_1'\boldsymbol{Y}, \boldsymbol{a}_2'\boldsymbol{Y}) = 0\ldots$

Obtenção dos componentes principais

Passo 1- Primeiro componente principal: combinação linear $\boldsymbol{a}_1'\boldsymbol{Y}$ que maximiza $\text{Var}(\boldsymbol{a}_1'\boldsymbol{Y})$ sujeita a $\boldsymbol{a}_1'\boldsymbol{a}_1 = 1$;

Passo 2- Segundo componente principal: combinação linear $\boldsymbol{a}_2'\boldsymbol{Y}$ que maximiza $\text{Var}(\boldsymbol{a}_2'\boldsymbol{Y})$ sujeita a $\boldsymbol{a}_2'\boldsymbol{a}_2 = 1$ e $\text{Cov}(\boldsymbol{a}_1'\boldsymbol{Y}, \boldsymbol{a}_2'\boldsymbol{Y}) = 0\ldots$

Passo k- k-ésimo componente principal: combinação linear $\boldsymbol{a}_k'\boldsymbol{Y}$ que maximiza $Var(\boldsymbol{a}_k'\boldsymbol{Y})$ sujeita a $\boldsymbol{a}_k'\boldsymbol{a}_k = 1$ e $Cov(\boldsymbol{a}_k'\boldsymbol{Y}, \boldsymbol{a}_j'\boldsymbol{Y}) = 0$, para todo $j < k,\ k = 3, ..., p$.

Obtenção dos componentes principais

- Seja $\boldsymbol{A}$ uma matriz quadrada $p \times p$ e λ uma constante. Então, o vetor $\boldsymbol{x}$ $(p \times 1)$, não nulo, que satisfaz:

$$\boldsymbol{A}\boldsymbol{x} = \lambda \boldsymbol{x}$$

é chamado **autovetor** e λ **autovalor** de $\boldsymbol{A}$.

Obtenção dos componentes principais

- Seja $\boldsymbol{A}$ uma matriz quadrada $p \times p$ e λ uma constante. Então, o vetor $\boldsymbol{x}$ $(p \times 1)$, não nulo, que satisfaz:

$$\boldsymbol{A}\boldsymbol{x} = \lambda \boldsymbol{x}$$

é chamado **autovetor** e λ **autovalor** de $\boldsymbol{A}$.

- Uma matriz quadrada $\boldsymbol{A}$ $p \times p$ é caracterizada por um conjunto de p autovalores e autovetores.

Obtenção dos componentes principais

- Autovalores e autovetores descrevem como uma transformação linear deforma o espaço.

Obtenção dos componentes principais

- Autovalores e autovetores descrevem como uma transformação linear deforma o espaço.

- Alguns vetores não mudam de direção (autovetores).

Obtenção dos componentes principais

- Autovalores e autovetores descrevem como uma transformação linear deforma o espaço.
- Alguns vetores não mudam de direção (autovetores).
- Os autovetores são apenas alongados (ou comprimidos) por um fator multiplicativo (autovalor).

Obtenção dos componentes principais

- Seja $\boldsymbol{A}$ uma matriz simétrica $p \times p$ com autovetores $\boldsymbol{x}_1, \boldsymbol{x}_2, ..., \boldsymbol{x}_p$ associados aos autovalores $\lambda_1, \lambda_2, ..., \lambda_p$.

Obtenção dos componentes principais

- Seja $\boldsymbol{A}$ uma matriz simétrica $p \times p$ com autovetores $\boldsymbol{x}_1, \boldsymbol{x}_2, ..., \boldsymbol{x}_p$ associados aos autovalores $\lambda_1, \lambda_2, ..., \lambda_p$.

- Considere $\boldsymbol{P}$ a matriz ortogonal com os p autovetores nas colunas, e $\boldsymbol{\Lambda}$ a matriz diagonal dos autovalores:

$$\boldsymbol{P} = \begin{bmatrix} x_{11} & x_{21} & \cdots & x_{p1} \\ x_{12} & x_{22} & \cdots & x_{p2} \\ \vdots & \vdots & \ddots & \vdots \\ x_{1p} & x_{2p} & \cdots & x_{pp} \end{bmatrix} \quad \boldsymbol{\Lambda} = \begin{bmatrix} \lambda_1 & 0 & \cdots & 0 \\ 0 & \lambda_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \lambda_p \end{bmatrix}$$

Obtenção dos componentes principais

- Neste caso, segundo o **teorema espectral**:

$$\boldsymbol{A} = \boldsymbol{P}\boldsymbol{\Lambda}\boldsymbol{P}' = \lambda_1 \boldsymbol{x}_1 \boldsymbol{x}_1' + \lambda_2 \boldsymbol{x}_2 \boldsymbol{x}_2' + ... + \lambda_p \boldsymbol{x}_p \boldsymbol{x}_p'$$

Obtenção dos componentes principais

- **Teorema- Maximização de formas quadráticas** Seja $\boldsymbol{A}$ uma matriz $p \times p$ simétrica com autovalores $\lambda_1 \geq \lambda_2 \geq ... \geq \lambda_p \geq 0$ e autovetores associados normalizados $\boldsymbol{e_1}, \boldsymbol{e_2}, ..., \boldsymbol{e_p}$. Então:

Obtenção dos componentes principais

- **Teorema- Maximização de formas quadráticas** Seja $\boldsymbol{A}$ uma matriz $p \times p$ simétrica com autovalores $\lambda_1 \geq \lambda_2 \geq ... \geq \lambda_p \geq 0$ e autovetores associados normalizados $\boldsymbol{e_1}, \boldsymbol{e_2}, ..., \boldsymbol{e_p}$. Então:

$$\max_{\boldsymbol{x} \neq \boldsymbol{0}} \frac{\boldsymbol{x'Ax}}{\boldsymbol{x'x}} = \lambda_1, \quad \text{obtido quando} \quad \boldsymbol{x} = \boldsymbol{e_1};$$

Obtenção dos componentes principais

- **Teorema- Maximização de formas quadráticas** Seja $\boldsymbol{A}$ uma matriz $p \times p$ simétrica com autovalores $\lambda_1 \geq \lambda_2 \geq ... \geq \lambda_p \geq 0$ e autovetores associados normalizados $\boldsymbol{e_1}, \boldsymbol{e_2}, ..., \boldsymbol{e_p}$. Então:

$$\max_{\boldsymbol{x} \neq \boldsymbol{0}} \frac{\boldsymbol{x'Ax}}{\boldsymbol{x'x}} = \lambda_1, \quad \text{obtido quando} \quad \boldsymbol{x} = \boldsymbol{e_1};$$

$$\min_{\boldsymbol{x} \neq \boldsymbol{0}} \frac{\boldsymbol{x'Ax}}{\boldsymbol{x'x}} = \lambda_p, \quad \text{obtido quando} \quad \boldsymbol{x} = \boldsymbol{e_p}.$$

Obtenção dos componentes principais

- **Teorema- Maximização de formas quadráticas** Seja $\boldsymbol{A}$ uma matriz $p \times p$ simétrica com autovalores $\lambda_1 \geq \lambda_2 \geq ... \geq \lambda_p \geq 0$ e autovetores associados normalizados $\boldsymbol{e_1}, \boldsymbol{e_2}, ..., \boldsymbol{e_p}$. Então:

$$\max_{\boldsymbol{x} \neq \boldsymbol{0}} \frac{\boldsymbol{x'Ax}}{\boldsymbol{x'x}} = \lambda_1, \quad \text{obtido quando} \quad \boldsymbol{x} = \boldsymbol{e_1};$$

$$\min_{\boldsymbol{x} \neq \boldsymbol{0}} \frac{\boldsymbol{x'Ax}}{\boldsymbol{x'x}} = \lambda_p, \quad \text{obtido quando} \quad \boldsymbol{x} = \boldsymbol{e_p}.$$

$$\max_{\boldsymbol{x} \perp \boldsymbol{e_1}, \boldsymbol{e_2}, ..., \boldsymbol{e_k}} \frac{\boldsymbol{x'Ax}}{\boldsymbol{x'x}} = \lambda_{k+1}, \quad \text{obtido quando} \quad \boldsymbol{x} = \boldsymbol{e_{k+1}}.$$

Obtenção dos componentes principais

- Assim, no contexto de componentes principais, seja $\boldsymbol{Y'} = (Y_1, Y_2, ..., Y_p)$ um vetor aleatório. Seja $\boldsymbol{\Sigma}$ a matriz de variâncias e covariâncias e $(\lambda_1, \boldsymbol{e_1}), (\lambda_2, \boldsymbol{e_2}), ..., (\lambda_p, \boldsymbol{e_p})$ seus autovalores e autovetores, tal que $\lambda_1 \geq \lambda_2 \geq ... \geq \lambda_p \geq 0$. Então:

Obtenção dos componentes principais

- Assim, no contexto de componentes principais, seja $\boldsymbol{Y'} = (Y_1, Y_2, ..., Y_p)$ um vetor aleatório. Seja $\boldsymbol{\Sigma}$ a matriz de variâncias e covariâncias e $(\lambda_1, \boldsymbol{e_1}), (\lambda_2, \boldsymbol{e_2}), ..., (\lambda_p, \boldsymbol{e_p})$ seus autovalores e autovetores, tal que $\lambda_1 \geq \lambda_2 \geq ... \geq \lambda_p \geq 0$. Então:

$$\max_{\boldsymbol{a} \neq \boldsymbol{0}} \frac{(\boldsymbol{a'\Sigma a})}{\boldsymbol{a'a}} = \max_{\boldsymbol{a} \neq \boldsymbol{0}} (\boldsymbol{a'\Sigma a}) = \lambda_1, \quad \text{obtido quando} \quad \boldsymbol{a = e_1};$$

Obtenção dos componentes principais

- Assim, no contexto de componentes principais, seja $\boldsymbol{Y'} = (Y_1, Y_2, ..., Y_p)$ um vetor aleatório. Seja $\boldsymbol{\Sigma}$ a matriz de variâncias e covariâncias e $(\lambda_1, \boldsymbol{e_1}), (\lambda_2, \boldsymbol{e_2}), ..., (\lambda_p, \boldsymbol{e_p})$ seus autovalores e autovetores, tal que $\lambda_1 \geq \lambda_2 \geq ... \geq \lambda_p \geq 0$. Então:

$$\max_{\boldsymbol{a} \neq \boldsymbol{0}} \frac{(\boldsymbol{a'\Sigma a})}{\boldsymbol{a'a}} = \max_{\boldsymbol{a} \neq \boldsymbol{0}} (\boldsymbol{a'\Sigma a}) = \lambda_1, \quad \text{obtido quando} \quad \boldsymbol{a = e_1};$$

$$\min_{\boldsymbol{a} \neq \boldsymbol{0}} \frac{(\boldsymbol{a'\Sigma a})}{\boldsymbol{a'a}} = \min_{\boldsymbol{a} \neq \boldsymbol{0}} (\boldsymbol{a'\Sigma a}) = \lambda_p, \quad \text{obtido quando} \quad \boldsymbol{a = e_p}.$$

Obtenção dos componentes principais

- Assim, no contexto de componentes principais, seja $\boldsymbol{Y'} = (Y_1, Y_2, ..., Y_p)$ um vetor aleatório. Seja $\boldsymbol{\Sigma}$ a matriz de variâncias e covariâncias e $(\lambda_1, \boldsymbol{e_1}), (\lambda_2, \boldsymbol{e_2}), ..., (\lambda_p, \boldsymbol{e_p})$ seus autovalores e autovetores, tal que $\lambda_1 \geq \lambda_2 \geq ... \geq \lambda_p \geq 0$. Então:

$$\max_{\boldsymbol{a} \neq \boldsymbol{0}} \frac{(\boldsymbol{a'\Sigma a})}{\boldsymbol{a'a}} = \max_{\boldsymbol{a} \neq \boldsymbol{0}} (\boldsymbol{a'\Sigma a}) = \lambda_1, \quad \text{obtido quando} \quad \boldsymbol{a = e_1};$$

$$\min_{\boldsymbol{a} \neq \boldsymbol{0}} \frac{(\boldsymbol{a'\Sigma a})}{\boldsymbol{a'a}} = \min_{\boldsymbol{a} \neq \boldsymbol{0}} (\boldsymbol{a'\Sigma a}) = \lambda_p, \quad \text{obtido quando} \quad \boldsymbol{a = e_p}.$$

Adicionalmente,

$$\max_{\boldsymbol{a} \perp \boldsymbol{e_1}, \boldsymbol{e_2}, ..., \boldsymbol{e_k}} \frac{(\boldsymbol{a'\Sigma a})}{\boldsymbol{a'a}} = \max_{\boldsymbol{a} \perp \boldsymbol{e_1}, \boldsymbol{e_2}, ..., \boldsymbol{e_k}} (\boldsymbol{a'\Sigma a}) = \lambda_{k+1}, \quad \text{obtido quando} \quad \boldsymbol{a = e_{k+1}}.$$

Obtenção dos componentes principais

- Em resumo, o *i*-ésimo componente principal é definido por uma combinação linear das p variáveis originais, em que **os coeficientes dessa combinação são os elementos do autovetor de Σ associados ao i-ésimo maior autovalor**.

Obtenção dos componentes principais

- Em resumo, o *i*-ésimo componente principal é definido por uma combinação linear das p variáveis originais, em que **os coeficientes dessa combinação são os elementos do autovetor de Σ associados ao i-ésimo maior autovalor**.

- O *i*-ésimo componente principal é definido por:

$$Z_i = \boldsymbol{e_i'Y} = e_{i1}Y_1 + e_{i2}Y_2 + ... + e_{ip}Y_p, \quad i = 1, 2, ..., p.$$

Análise de componentes principais

- Informalmente, um problema com dados multivariados:

Análise de componentes principais

- Informalmente, um problema com dados multivariados:
  - A matriz de covariâncias (Σ) define a forma da distribuição dos dados;

Análise de componentes principais

- Informalmente, um problema com dados multivariados:
  - A matriz de covariâncias (Σ) define a forma da distribuição dos dados;
  - Os autovetores de Σ indicam direções de máxima variação;

Análise de componentes principais

- Informalmente, um problema com dados multivariados:
  - A matriz de covariâncias (Σ) define a forma da distribuição dos dados;
  - Os autovetores de Σ indicam direções de máxima variação;
  - Os autovalores exprimem a magnitude da variação em cada direção.

Análise de componentes principais

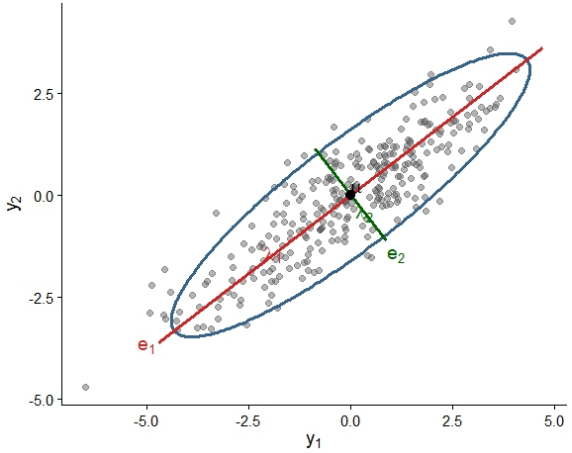


Figura 7: Ilustração dos componentes principais num problema em duas dimensões ($p = 2$)

Exemplo 1

Exemplo 1

- Uma amostra de tamanho $n = 100$ de um vetor aleatório $(X,\ Y)$ resultou na seguinte matriz de covariâncias:

$$\mathrm{S} = \begin{bmatrix} 1.06 & -0.78 \\ -0.78 & 0.93 \end{bmatrix}$$

Exemplo 1

- Uma amostra de tamanho $n = 100$ de um vetor aleatório $(X,\ Y)$ resultou na seguinte matriz de covariâncias:

$$\mathrm{S} = \begin{bmatrix} 1.06 & -0.78 \\ -0.78 & 0.93 \end{bmatrix}$$

- A figura seguinte ilustra os resultados.

Exemplo 1

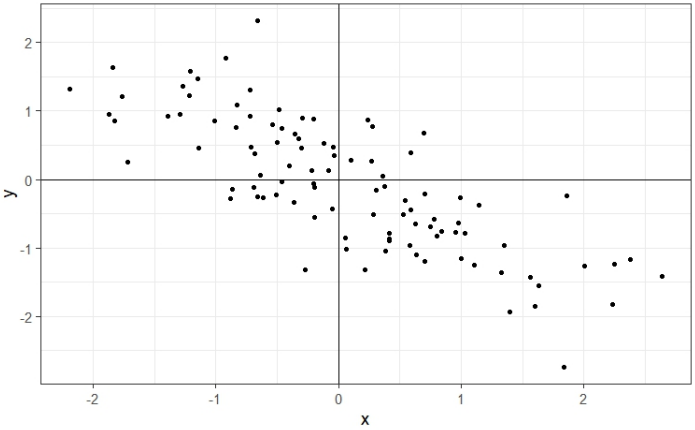


Figura 8: Gráfico de dispersão para os dados bivariados

Exemplo 1

- Os autovetores da matriz de covariâncias são:

Exemplo 1

- Os autovetores da matriz de covariâncias são:

$$\boldsymbol{e}_1 = \begin{bmatrix} -0.737 \\ +0.676 \end{bmatrix} \quad \boldsymbol{e}_2 = \begin{bmatrix} -0.676 \\ -0.737 \end{bmatrix}$$

Exemplo 1

- Os autovetores da matriz de covariâncias são:

$$\boldsymbol{e}_1 = \begin{bmatrix} -0.737 \\ +0.676 \end{bmatrix} \quad \boldsymbol{e}_2 = \begin{bmatrix} -0.676 \\ -0.737 \end{bmatrix}$$

- Desta forma, os dois componentes principais têm as seguintes expressões:

Exemplo 1

- Os autovetores da matriz de covariâncias são:

$$\boldsymbol{e}_1 = \begin{bmatrix} -0.737 \\ +0.676 \end{bmatrix} \quad \boldsymbol{e}_2 = \begin{bmatrix} -0.676 \\ -0.737 \end{bmatrix}$$

- Desta forma, os dois componentes principais têm as seguintes expressões:

$$\text{CP}_1 = -0.737x + 0.676y$$

Exemplo 1

- Os autovetores da matriz de covariâncias são:

$$\boldsymbol{e}_1 = \begin{bmatrix} -0.737 \\ +0.676 \end{bmatrix} \quad \boldsymbol{e}_2 = \begin{bmatrix} -0.676 \\ -0.737 \end{bmatrix}$$

- Desta forma, os dois componentes principais têm as seguintes expressões:

$$\text{CP}_1 = -0.737x + 0.676y$$

$$\text{CP}_2 = -0.676x - 0.737y$$

Exemplo 1

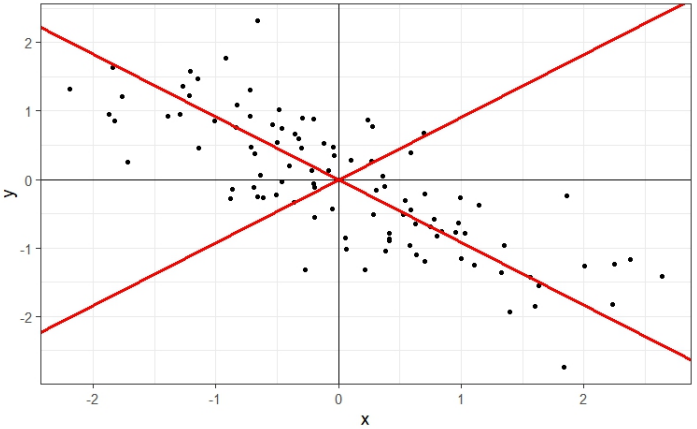


Figura 9: Gráfico de dispersão para os dados bivariados com componentes principais

Exemplo 1

- O primeiro componente principal reflete a correlação negativa entre as duas variáveis, tendo coeficientes (cargas) com sinais opostos para x e y.

Exemplo 1

- O primeiro componente principal reflete a correlação negativa entre as duas variáveis, tendo coeficientes (cargas) com sinais opostos para x e y.

- Claramente CP_1 é mais relevante, explicando mais de 89% da variação original dos dados.

Exemplo 1

- O primeiro componente principal reflete a correlação negativa entre as duas variáveis, tendo coeficientes (cargas) com sinais opostos para x e y.
- Claramente CP_1 é mais relevante, explicando mais de 89% da variação original dos dados.
- O segundo componente principal, ortogonal ao primeiro, explica aproximadamente 10% da variação.

Exemplo 1

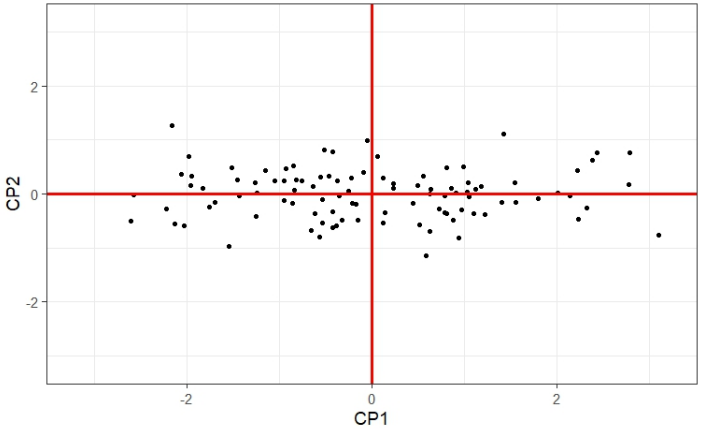


Figura 10: Representação dos componentes principais para os dados bivariados

Exemplo 1

- Os autovalores da matriz de covariâncias são $\lambda_1 = 1.77$ e $\lambda_2 = 0.21$.

Exemplo 1

- Os autovalores da matriz de covariâncias são $\lambda_1 = 1.77$ e $\lambda_2 = 0.21$.

- As porcentagens da variação total explicadas pelos dois componentes principais são:

Exemplo 1

- Os autovalores da matriz de covariâncias são $\lambda_1 = 1.77$ e $\lambda_2 = 0.21$.

- As porcentagens da variação total explicadas pelos dois componentes principais são:

$$\%\text{CP}_1 = 100\frac{\lambda_1}{\lambda_1 + \lambda_2} = 100\frac{1.77}{1.77 + 0.21} = 89.39\%$$

Exemplo 1

- Os autovalores da matriz de covariâncias são $\lambda_1 = 1.77$ e $\lambda_2 = 0.21$.

- As porcentagens da variação total explicadas pelos dois componentes principais são:

$$\%\text{CP}_1 = 100\frac{\lambda_1}{\lambda_1 + \lambda_2} = 100\frac{1.77}{1.77 + 0.21} = 89.39\%$$

$$\%\text{CP}_2 = 100\frac{\lambda_2}{\lambda_1 + \lambda_2} = 100\frac{0.21}{1.77 + 0.21} = 10.61\%$$

Propriedades das componentes principais

Propriedades dos componentes principais

- Os componentes principais têm variâncias iguais aos autovalores de Σ:

$$\text{Var}(Z_i) = \lambda_i, \quad i = 1, 2, ..., p.$$

Propriedades dos componentes principais

- Os componentes principais têm variâncias iguais aos autovalores de Σ:

$$\text{Var}(Z_i) = \lambda_i, \quad i = 1, 2, ..., p.$$

Prova:

Propriedades dos componentes principais

- Os componentes principais têm variâncias iguais aos autovalores de Σ:

$$\text{Var}(Z_i) = \lambda_i, \quad i = 1, 2, ..., p.$$

Prova:

$$\text{Var}(Z_i) = \text{Var}(\boldsymbol{e_i'Y}) = \boldsymbol{e_i'\Sigma e_i}$$

Propriedades dos componentes principais

- Pelas propriedades dos autovalores e autovetores $\boldsymbol{\Sigma e_i} = \lambda_i \boldsymbol{e_i}$, tal que:

Propriedades dos componentes principais

- Pelas propriedades dos autovalores e autovetores $\boldsymbol{\Sigma e_i} = \lambda_i \boldsymbol{e_i}$, tal que:

$$\text{Var}(Z_i) = \boldsymbol{e_i'} \lambda_i \boldsymbol{e_i} = \lambda_i \boldsymbol{e_i'} \boldsymbol{e_i} = \lambda_i \times 1 = \lambda_i, \quad i = 1, 2, ..., p$$

considerando que os autovetores sejam normalizados.

Propriedades dos componentes principais

- Os componentes principais são não correlacionados:

$$Cov(Z_i, Z_k) = 0, \quad i \neq k.$$

Propriedades dos componentes principais

- Os componentes principais são não correlacionados:

$$Cov(Z_i, Z_k) = 0, \quad i \neq k.$$

Prova:

$$\text{Cov}(Z_i, Z_k) = \text{Cov}(\boldsymbol{e_i'Y}, \boldsymbol{e_k'Y}) = \boldsymbol{e_i'}\text{Var}(\boldsymbol{Y})\boldsymbol{e_k} = \boldsymbol{e_i'}\Sigma\boldsymbol{e_k} =$$

$$\boldsymbol{e_i'}(\lambda_k \boldsymbol{e_k}) = \lambda_k e_i' e_k = \lambda_k \times 0 = 0,$$

considerando que os autovetores $\boldsymbol{e_i}$ e $\boldsymbol{e_k}$ são ortogonais.

Análise de componentes principais

- A variância total de $\boldsymbol{Y} = (Y_1, Y_2, ..., Y_p)$ é igual ao traço da matriz diagonal de autovalores (soma dos autovalores), ou seja:

$$\text{tr}(\Sigma) = \text{tr}(\Lambda) = \lambda_1 + \lambda_2 + ... + \lambda_p$$

Análise de componentes principais

- A variância total de $\boldsymbol{Y} = (Y_1, Y_2, ..., Y_p)$ é igual ao traço da matriz diagonal de autovalores (soma dos autovalores), ou seja:

$$\text{tr}(\Sigma) = \text{tr}(\Lambda) = \lambda_1 + \lambda_2 + ... + \lambda_p$$

Prova: Usando o fato que $\text{tr}(\mathbf{AB}) = \text{tr}(\mathbf{BA})$:

$$\text{tr}(\Sigma) = \text{tr}(\boldsymbol{P\Lambda P'}) = \text{tr}(\boldsymbol{\Lambda P' P}) = \text{tr}(\boldsymbol{\Lambda I}) = \text{tr}(\boldsymbol{\Lambda}) = \lambda_1 + \lambda_2 + ... + \lambda_p$$

Análise de componentes principais

- A porcentagem da variância total dos dados explicada pelo i-ésimo componente principal é igual a:

$$100 \times \frac{\lambda_i}{\lambda_1 + \lambda_2 + ... + \lambda_p}\%, \quad i = 1, 2, ..., p,$$

que pode ser expressa em porcentagem simplesmente multiplicada por 100.

Análise de componentes principais

- A correlação entre o i-ésimo componente (Z_i) e a k-ésima variável (Y_k) é dada por:

$$\text{Cor}(Z_i, Y_k) = \rho_{Z_i, Y_k} = \frac{e_{ik}\sqrt{\lambda_i}}{\sqrt{\sigma_k^2}}.$$

Análise de componentes principais

- A correlação entre o i-ésimo componente (Z_i) e a k-ésima variável (Y_k) é dada por:

$$\text{Cor}(Z_i, Y_k) = \rho_{Z_i, Y_k} = \frac{e_{ik}\sqrt{\lambda_i}}{\sqrt{\sigma_k^2}}.$$

Prova: A prova deste resultado baseia-se na seguinte propriedade geral das covariâncias de combinações lineares:

Análise de componentes principais

- A correlação entre o i-ésimo componente (Z_i) e a k-ésima variável (Y_k) é dada por:

$$\text{Cor}(Z_i, Y_k) = \rho_{Z_i, Y_k} = \frac{e_{ik}\sqrt{\lambda_i}}{\sqrt{\sigma_k^2}}.$$

Prova: A prova deste resultado baseia-se na seguinte propriedade geral das covariâncias de combinações lineares:

- Seja $\boldsymbol{Y}$ um vetor aleatório com matriz de covariâncias Σ e $\boldsymbol{a}$ e $\boldsymbol{b}$ vetores de constantes. Então:

$$\text{Cov}(\boldsymbol{a}'\boldsymbol{Y}, \boldsymbol{b}'\boldsymbol{Y}) = \boldsymbol{a}'\Sigma\boldsymbol{b}$$

Análise de componentes principais

- No contexto da análise de componentes principais, seja $Z_i = \boldsymbol{e}_i' \boldsymbol{Y}$ e $Y_k = \boldsymbol{l}_k' \boldsymbol{Y}$, em que $\boldsymbol{l}' = (0, ..., 0, 1, 0..., 0)$. Então:

Análise de componentes principais

- No contexto da análise de componentes principais, seja $Z_i = \boldsymbol{e}_i'\boldsymbol{Y}$ e $Y_k = \boldsymbol{l}_k'\boldsymbol{Y}$, em que $\boldsymbol{l}' = (0, ..., 0, 1, 0..., 0)$. Então:

$$\text{Cor}(Z_i, Y_k) = \frac{\text{Cov}(Y_k, Z_i)}{\sqrt{\text{Var}(Z_i)}\sqrt{\text{Var}(Y_k)}} = \frac{\text{Cov}(\boldsymbol{l}_k'\boldsymbol{Y}, \boldsymbol{e}_i'\boldsymbol{Y})}{\sqrt{\lambda_i}\sqrt{\sigma_k^2}} =$$

$$\frac{\boldsymbol{l}_k'\Sigma\boldsymbol{e}_i'}{\sqrt{\lambda_i}\sqrt{\sigma_k^2}} = \frac{\boldsymbol{l}_k'\lambda_i\boldsymbol{e}_i'}{\sqrt{\lambda_i}\sqrt{\sigma_k^2}} = \frac{\lambda_i e_{ik}}{\sqrt{\lambda_i}\sqrt{\sigma_k^2}} = \frac{e_{ik}\sqrt{\lambda_i}}{\sqrt{\sigma_k^2}}$$

Notas sobre análise de componentes principais

- Em geral, observamos as proporções explicadas pelos componentes principais e retemos um pequeno número de componentes capazes de explicar uma parcela expressiva da variação original dos dados.

Notas sobre análise de componentes principais

- Em geral, observamos as proporções explicadas pelos componentes principais e retemos um pequeno número de componentes capazes de explicar uma parcela expressiva da variação original dos dados.

- Os coeficientes (**cargas**, ou **loadings**) dos componentes principais (elementos dos autovetores), seus sinais e magnitudes, permitem interpretar os componentes e avaliar a importância das variáveis em sua constituição.

Notas sobre análise de componentes principais

- Em geral, observamos as proporções explicadas pelos componentes principais e retemos um pequeno número de componentes capazes de explicar uma parcela expressiva da variação original dos dados.

- Os coeficientes (**cargas**, ou **loadings**) dos componentes principais (elementos dos autovetores), seus sinais e magnitudes, permitem interpretar os componentes e avaliar a importância das variáveis em sua constituição.

- As correlações entre componentes principais e as variáveis originais são úteis para avaliar importância das variáveis na constituição dos componentes e produção de gráficos.

Notas sobre análise de componentes principais

- Chamamos **escores** os valores dos componentes principais (resultados das combinações lineares) calculados para cada particular indivíduo.

Notas sobre análise de componentes principais

- Chamamos **escores** os valores dos componentes principais (resultados das combinações lineares) calculados para cada particular indivíduo.

- Os escores podem ser usados como índices. para efeito de ranqueamento dos indivíduos, agrupamento, classificação...

Notas sobre análise de componentes principais

- Chamamos **escores** os valores dos componentes principais (resultados das combinações lineares) calculados para cada particular indivíduo.

- Os escores podem ser usados como índices. para efeito de ranqueamento dos indivíduos, agrupamento, classificação...

- Se $Y_1, Y_2, ..., Y_p$ forem variáveis aleatórias independentes, então cada um dos p componentes principais corresponderá a um dos $Y's$.

Análise de componentes principais usando a matriz de correlações

Análise de componentes principais usando a matriz de correlações

- Nas situações em que as variáveis originais têm escalas diferentes, é natural esperarmos que as variâncias, consequentemente, sejam diferentes.

Análise de componentes principais usando a matriz de correlações

- Nas situações em que as variáveis originais têm escalas diferentes, é natural esperarmos que as variâncias, consequentemente, sejam diferentes.

- Nestes casos, é comum os primeiros componentes principais serem definidos pelas variáveis cujas escalas apresentam maior variação.

Análise de componentes principais usando a matriz de correlações

- Nas situações em que as variáveis originais têm escalas diferentes, é natural esperarmos que as variâncias, consequentemente, sejam diferentes.

- Nestes casos, é comum os primeiros componentes principais serem definidos pelas variáveis cujas escalas apresentam maior variação.

- Para evitar esse tipo de distorção nos resultados, é recomendável considerar a análise de componentes principais com base nas variáveis padronizadas:

$$Y_1^* = \frac{Y_1 - \mu_1}{\sqrt{\sigma_{11}}}, \quad Y_2^* = \frac{Y_2 - \mu_2}{\sqrt{\sigma_{22}}}, ..., Y_p^* = \frac{Y_p - \mu_p}{\sqrt{\sigma_{pp}}}$$

Análise de componentes principais usando a matriz de correlações

- Os componentes principais para $Y_1^*, Y_2^*, ..., Y_p^*$ são determinados pela matriz de variâncias e covariâncias das variáveis padronizadas, o que equivale à matriz de correlações de $Y_1, Y_2, ..., Y_p$.

Análise de componentes principais usando a matriz de correlações

- Os componentes principais para $Y_1^*, Y_2^*, ..., Y_p^*$ são determinados pela matriz de variâncias e covariâncias das variáveis padronizadas, o que equivale à matriz de correlações de $Y_1, Y_2, ..., Y_p$.

- Assim, teremos $Z_i^* = \boldsymbol{e_i'} \boldsymbol{Y_i^*}, i = 1, 2, ..., p$, com:

$$\sum \text{Var} Z_i^* = \sum \text{Var} Y_i^* = p$$

Análise de componentes principais usando a matriz de correlações

- Os componentes principais para $Y_1^*, Y_2^*, ..., Y_p^*$ são determinados pela matriz de variâncias e covariâncias das variáveis padronizadas, o que equivale à matriz de correlações de $Y_1, Y_2, ..., Y_p$.

- Assim, teremos $Z_i^* = \boldsymbol{e_i'} \boldsymbol{Y_i^*}, i = 1, 2, ..., p$, com:

$$\sum \text{Var} Z_i^* = \sum \text{Var} Y_i^* = p$$

e

$$\text{Cor}(Y_i^*, Z_k^*) = \rho_{Y_i^*, Z_k^*} = e_{ik}\sqrt{\lambda_i}, \quad i, k = 1, 2, ..., p,$$

sendo $(\lambda_1, \boldsymbol{e_1}), (\lambda_2, \boldsymbol{e_2}), ..., (\lambda_p, \boldsymbol{e_p})$ os autovalores e autovetores da matriz de correlações.

Componentes principais amostrais

Componentes principais amostrais

- Na prática a ACP é conduzida com base em uma amostra $\boldsymbol{y_1}, \boldsymbol{y_2}, \ldots, \boldsymbol{y_n}$, com vetor de médias $\bar{\boldsymbol{y}}$ e matriz de covariâncias $\boldsymbol{S}$ e de correlações $\boldsymbol{R}$.

Componentes principais amostrais

- Na prática a ACP é conduzida com base em uma amostra $\boldsymbol{y_1}, \boldsymbol{y_2}, \ldots, \boldsymbol{y_n}$, com vetor de médias $\bar{\boldsymbol{y}}$ e matriz de covariâncias $\boldsymbol{S}$ e de correlações $\boldsymbol{R}$.

- Seja $\boldsymbol{S}$ a matriz de covariâncias amostral, com $(\hat{\lambda}_1, \hat{\boldsymbol{e}}_1), (\hat{\lambda}_2, \hat{\boldsymbol{e}}_2), \ldots, (\hat{\lambda}_p, \hat{\boldsymbol{e}}_p)$ os pares de autovalores e autovetores, tal que $\hat{\lambda}_1 \geq \hat{\lambda}_2 \geq \ldots \geq \hat{\lambda}_p \geq 0$.

Componentes principais amostrais

- Na prática a ACP é conduzida com base em uma amostra $\boldsymbol{y_1, y_2, ..., y_n}$, com vetor de médias $\bar{\boldsymbol{y}}$ e matriz de covariâncias $\boldsymbol{S}$ e de correlações $\boldsymbol{R}$.

- Seja $\boldsymbol{S}$ a matriz de covariâncias amostral, com $(\hat{\lambda}_1, \hat{\boldsymbol{e}}_1), (\hat{\lambda}_2, \hat{\boldsymbol{e}}_2), ..., (\hat{\lambda}_p, \hat{\boldsymbol{e}}_p)$ os pares de autovalores e autovetores, tal que $\hat{\lambda}_1 \geq \hat{\lambda}_2 \geq ... \geq \hat{\lambda}_p \geq 0$.

- O i-ésimo componente principal é dado por:

$$\hat{z}_i = \hat{\boldsymbol{e}}_i' \boldsymbol{y} = \hat{e}_{i1} y_1 + \hat{e}_{i2} y_2 + ... + \hat{e}_{ip} y_p, \qquad i = 1, 2, ..., p$$

Análise de componentes principais

- A variância amostral de $\hat{z}_i$ é igual a $\hat{\lambda}_i$, e a covariância amostral entre $\hat{z}_i$ e $\hat{z}_k$, $i \neq k$, é igual a zero.

Análise de componentes principais

- A variância amostral de $\hat{z}_i$ é igual a $\hat{\lambda}_i$, e a covariância amostral entre $\hat{z}_i$ e $\hat{z}_k$, $i \neq k$, é igual a zero.

- A variância amostral total fica dada por:

$$\sum_{i=1}^{n} s_{ii} = \hat{\lambda}_1 + \hat{\lambda}_2 + ... + \hat{\lambda}_p$$

Análise de componentes principais

- A variância amostral de $\hat{z}_i$ é igual a $\hat{\lambda}_i$, e a covariância amostral entre $\hat{z}_i$ e $\hat{z}_k$, $i \neq k$, é igual a zero.

- A variância amostral total fica dada por:

$$\sum_{i=1}^{n} s_{ii} = \hat{\lambda}_1 + \hat{\lambda}_2 + ... + \hat{\lambda}_p$$

- A correlação entre o i-ésimo componente e a k-ésima variável é dada por:

$$r_{\hat{z}_i, y_k} = \frac{\hat{e}_{ik}\sqrt{\hat{\lambda}_i}}{\sqrt{s_{kk}}}, \quad i, k = 1, 2, ..., p.$$

Análise de componentes principais

- Como dito anteriormente, um resultado fundamental da ACP é a produção dos escores, que correspondem a valores calculados para cada indivíduo nos componentes principais obtidos.

Análise de componentes principais

- Como dito anteriormente, um resultado fundamental da ACP é a produção dos escores, que correspondem a valores calculados para cada indivíduo nos componentes principais obtidos.

- Mesmo que a ACP seja realizada a partir das variáveis em sua escala original, é usual calcular os escores com base nas variáveis centradas nas respectivas médias. Por exemplo, para um indivíduo g, no *i-ésimo* componente:

$$\hat{z_{g\,i}} = \hat{\mathbf{e}}_{\boldsymbol{i}}'(\boldsymbol{y} - \bar{\boldsymbol{y}}) = e_{i1}(y_{g1} - \bar{y}_1) + e_{i2}(y_{g2} - \bar{y}_2) + ... + e_{ip}(y_{gp} - \bar{y}_p).$$

Análise de componentes principais

- Como dito anteriormente, um resultado fundamental da ACP é a produção dos escores, que correspondem a valores calculados para cada indivíduo nos componentes principais obtidos.

- Mesmo que a ACP seja realizada a partir das variáveis em sua escala original, é usual calcular os escores com base nas variáveis centradas nas respectivas médias. Por exemplo, para um indivíduo g, no *i-ésimo* componente:

$$\hat{z_{g\,i}} = \hat{\mathbf{e}}_i'(\boldsymbol{y} - \bar{\boldsymbol{y}}) = e_{i1}(y_{g1} - \bar{y}_1) + e_{i2}(y_{g2} - \bar{y}_2) + ... + e_{ip}(y_{gp} - \bar{y}_p).$$

- Como resultado, os componentes principais obtidos serão centrados em 0, sendo possível interpretar os respectivos sinais como associados a indivíduos com escore acima (positivo) ou abaixo (negativo) da média.

Análise de componentes principais

- Já no caso em que a análise é conduzida com base nas variáveis padronizadas (matriz de correlações), os escores são calculados como:

$$\hat{z_{g}}_{i} = e_{i1}\frac{y_{g1} - \bar{y}_1}{\sqrt{s_{11}}} + e_{i2}\frac{y_{g2} - \bar{y}_2}{\sqrt{s_{22}}} + ... + e_{ip}\frac{y_{gp} - \bar{y}_p}{\sqrt{s_{pp}}}.$$

Análise de componentes principais

- Um dos principais atrativos da ACP é a possibilidade de visualização dos resultados em gráficos de duas ou três dimensóes, como resultado da projeção. Algumas alternativas:

Análise de componentes principais

- Um dos principais atrativos da ACP é a possibilidade de visualização dos resultados em gráficos de duas ou três dimensóes, como resultado da projeção. Algumas alternativas:
  - Plotar os escores de cada indivíduo em cada componente, a fim de identificar grupos de indivíduos com escores (e características) semelhantes, identificar indivíduos extremos,...

Análise de componentes principais

- Um dos principais atrativos da ACP é a possibilidade de visualização dos resultados em gráficos de duas ou três dimensóes, como resultado da projeção. Algumas alternativas:
  - Plotar os escores de cada indivíduo em cada componente, a fim de identificar grupos de indivíduos com escores (e características) semelhantes, identificar indivíduos extremos,...
  - Plotar as correlações entre variáveis e componentes, a fim de visualizar as associações entre variáveis e componentes, as intercorrelações entre variáveis...

Análise de componentes principais

- Um dos principais atrativos da ACP é a possibilidade de visualização dos resultados em gráficos de duas ou três dimensóes, como resultado da projeção. Algumas alternativas:
  - Plotar os escores de cada indivíduo em cada componente, a fim de identificar grupos de indivíduos com escores (e características) semelhantes, identificar indivíduos extremos,...
  - Plotar as correlações entre variáveis e componentes, a fim de visualizar as associações entre variáveis e componentes, as intercorrelações entre variáveis...
  - Plotar conjuntamente dados e variáveis num mesmo gráfico, permitindo visualizar globalmente relações entre variáveis e indivíduos (gráfico biplot, veremos adiante).

Número de componentes principais

Número de componentes principais

- Uma das questões mais recorrentes em ACP é a definição do número de componentes a reter e explorar na análise.

Número de componentes principais

- Uma das questões mais recorrentes em ACP é a definição do número de componentes a reter e explorar na análise.

- Um dos aspectos a se levar em consideração é a interpretação prática dos componentes, possível justificativa à luz da teoria da área...

Número de componentes principais

- Uma das questões mais recorrentes em ACP é a definição do número de componentes a reter e explorar na análise.

- Um dos aspectos a se levar em consideração é a interpretação prática dos componentes, possível justificativa à luz da teoria da área...

- Aspectos referentes ao desempenho do método também devem ser considerados.

Número de componentes principais

- Alguns critérios que fundamentam a definição do número de componentes a serem "retidos":

Número de componentes principais

- Alguns critérios que fundamentam a definição do número de componentes a serem "retidos":
  - Reter o menor número k de componentes principais capaz de explicar uma porcentagem mínima desejável da variação dos dados (ex: 70 ou 80%);

Número de componentes principais

- Alguns critérios que fundamentam a definição do número de componentes a serem "retidos":
  - Reter o menor número k de componentes principais capaz de explicar uma porcentagem mínima desejável da variação dos dados (ex: 70 ou 80%);
  - Reter os componentes cujos autovalores são maiores que a média dos autovalores, $(\sum_{i=1}^{p} \lambda_i / p)$ (critério de Kaiser). Para a matriz de correlações esta média é igual a 1;

Número de componentes principais

- Alguns critérios que fundamentam a definição do número de componentes a serem "retidos":
  - Reter o menor número k de componentes principais capaz de explicar uma porcentagem mínima desejável da variação dos dados (ex: 70 ou 80%);
  - Reter os componentes cujos autovalores são maiores que a média dos autovalores, $(\sum_{i=1}^{p} \lambda_i / p)$ (critério de Kaiser). Para a matriz de correlações esta média é igual a 1;
  - Decidir o número de componentes com base na apreciação do *scree plot* para os autovalores;

Número de componentes principais

- Alguns critérios que fundamentam a definição do número de componentes a serem "retidos":
  - Reter o menor número k de componentes principais capaz de explicar uma porcentagem mínima desejável da variação dos dados (ex: 70 ou 80%);
  - Reter os componentes cujos autovalores são maiores que a média dos autovalores, $(\sum_{i=1}^{p} \lambda_i / p)$ (critério de Kaiser). Para a matriz de correlações esta média é igual a 1;
  - Decidir o número de componentes com base na apreciação do *scree plot* para os autovalores;
  - Usar simulação (análise paralela).

Análise paralela

- A análise paralela compara os autovalores obtidos da matriz de covariâncias (correlações) amostral com aqueles simulados do modelo nulo (com variáveis não correlacionadas) para amostras de mesmo tamanho.

Análise paralela

- A análise paralela compara os autovalores obtidos da matriz de covariâncias (correlações) amostral com aqueles simulados do modelo nulo (com variáveis não correlacionadas) para amostras de mesmo tamanho.

- Por usar simulação, a análise paralela incorpora a variação nos autovalores induzida pelo erro amostral, diferentemente do critério de Kaiser.

Análise paralela

- A análise paralela compara os autovalores obtidos da matriz de covariâncias (correlações) amostral com aqueles simulados do modelo nulo (com variáveis não correlacionadas) para amostras de mesmo tamanho.

- Por usar simulação, a análise paralela incorpora a variação nos autovalores induzida pelo erro amostral, diferentemente do critério de Kaiser.

- A idéia aqui é reter para a análise apenas os componentes principais cujos autovalores amostrais sejam maiores que os simulados do modelo nulo.

Número de componentes principais

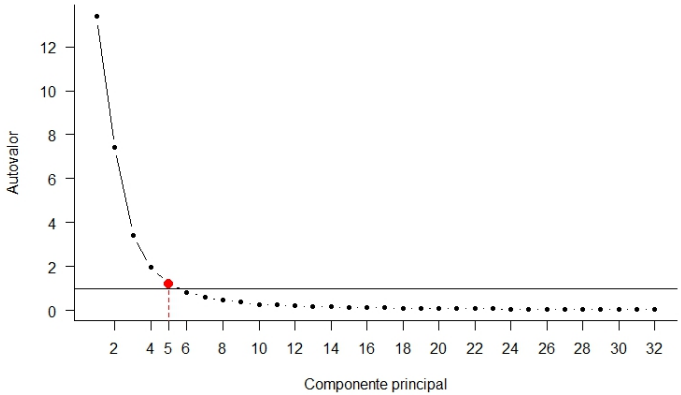


Figura 11: Determinação do número de componentes principais pelo critério de Kaiser

Número de componentes principais

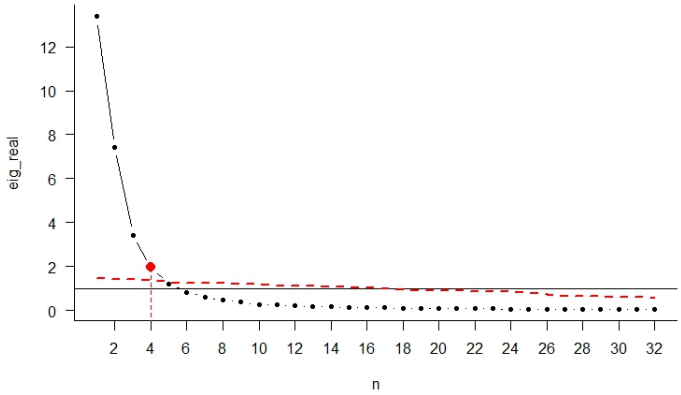


Figura 12: Determinação do número de componentes via análise paralela

Exemplo 2

Exemplo 2

- Neste exemplo vamos usar componentes principais numa análise de dados sensoriais.

Exemplo 2

- Neste exemplo vamos usar componentes principais numa análise de dados sensoriais.

- Dez avaliadores foram requisitados a dar notas para as seguintes características de quinze marcas de pizzas de mussarela pré-assadas congeladas: `sabor`, `aroma`, `consistência` e `quantidade` (de recheio).

Exemplo 2

- Neste exemplo vamos usar componentes principais numa análise de dados sensoriais.
- Dez avaliadores foram requisitados a dar notas para as seguintes características de quinze marcas de pizzas de mussarela pré-assadas congeladas: `sabor`, `aroma`, `consistência` e `quantidade` (de recheio).
- As notas médias atribuídas pelos jurados em cada quesito encontram-se tabeladas na sequência.

Exemplo 2

Tabela 1: Notas atribuidas pelos avaliadores às 15 marcas de pizza

Marca	Sabor	Aroma	Consistência	Quantidade
1	8.58	9.24	8.14	7.38
2	6.71	6.77	6.14	6.29
3	7.13	7.03	8.33	7.59
4	6.95	6.89	7.77	6.73
5	8.81	8.01	8.42	7.80
6	7.46	7.61	9.02	8.49
7	6.62	6.40	7.17	7.67
8	7.25	7.78	8.89	8.89
9	5.60	6.55	6.47	5.95
10	6.36	6.74	6.79	6.72
11	8.00	6.90	5.73	5.84
12	8.03	8.16	6.80	7.15
13	5.95	6.26	7.10	6.42
14	7.34	6.97	7.73	7.27
15	6.53	6.31	7.66	8.51

Exemplo 2

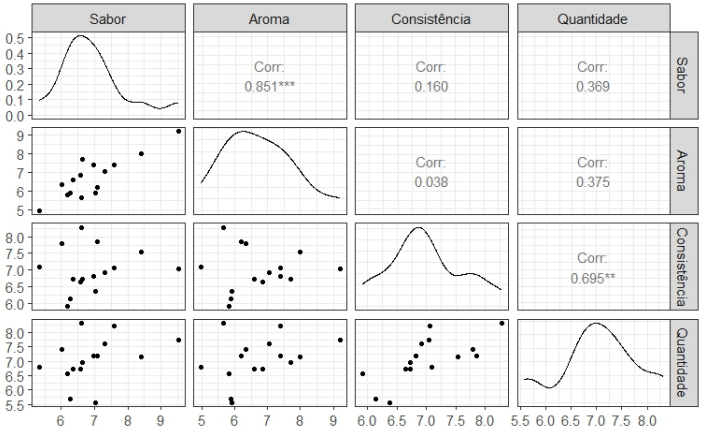


Figura 13: Correlações para as características sensoriais das marcas de pizza

Exemplo 2

- Matriz de covariâncias amostrais:

$$S = \begin{bmatrix} 0.84 & 0.62 & 0.30 & 0.23 \\ 0.62 & 0.69 & 0.36 & 0.24 \\ 0.30 & 0.36 & 0.98 & 0.78 \\ 0.23 & 0.24 & 0.78 & 0.88 \end{bmatrix}$$

Exemplo 2

- Autovalores da matriz de covariâncias: $\hat{\lambda}_1 = 2.145$; $\hat{\lambda}_2 = 0.693$; $\hat{\lambda}_3 = 0.172$; $\hat{\lambda}_4 = 0.104$.

Exemplo 2

- Autovalores da matriz de covariâncias: $\hat{\lambda}_1 = 2.145$; $\hat{\lambda}_2 = 0.693$; $\hat{\lambda}_3 = 0.172$; $\hat{\lambda}_4 = 0.104$.

- Autovetores da matriz de covariâncias:

Exemplo 2

- Autovalores da matriz de covariâncias: $\hat{\lambda}_1 = 2.145$; $\hat{\lambda}_2 = 0.693$; $\hat{\lambda}_3 = 0.172$; $\hat{\lambda}_4 = 0.104$.

- Autovetores da matriz de covariâncias:

$$\boldsymbol{e}_1 = \begin{bmatrix} +0.434 \\ +0.429 \\ +0.595 \\ +0.527 \end{bmatrix} \quad \boldsymbol{e}_2 = \begin{bmatrix} +0.628 \\ +0.486 \\ -0.395 \\ -0.463 \end{bmatrix} \quad \boldsymbol{e}_3 = \begin{bmatrix} +0.461 \\ -0.466 \\ -0.503 \\ +0.563 \end{bmatrix} \quad \boldsymbol{e}_4 = \begin{bmatrix} -0.454 \\ +0.605 \\ -0.487 \\ +0.437 \end{bmatrix}$$

Exemplo 2

- As porcentagens da variação total explicadas por cada componente são:

Exemplo 2

- As porcentagens da variação total explicadas por cada componente são:

$$\%\text{CP1} = 100 \times \frac{2.145}{2.145 + 0.963 + 0.172 + 0.104} = 63.38\%$$

Exemplo 2

- As porcentagens da variação total explicadas por cada componente são:

$$\%CP1 = 100 \times \frac{2.145}{2.145 + 0.963 + 0.172 + 0.104} = 63.38\%$$

$$\%CP2 = 100 \times \frac{0.963}{2.145 + 0.963 + 0.172 + 0.104} = 28.46\%$$

Exemplo 2

- As porcentagens da variação total explicadas por cada componente são:

$$\%CP1 = 100 \times \frac{2.145}{2.145 + 0.963 + 0.172 + 0.104} = 63.38\%$$

$$\%CP2 = 100 \times \frac{0.963}{2.145 + 0.963 + 0.172 + 0.104} = 28.46\%$$

$$\%CP3 = 100 \times \frac{0.172}{2.145 + 0.963 + 0.172 + 0.104} = 5.08\%$$

Exemplo 2

- As porcentagens da variação total explicadas por cada componente são:

$$\%CP1 = 100 \times \frac{2.145}{2.145 + 0.963 + 0.172 + 0.104} = 63.38\%$$

$$\%CP2 = 100 \times \frac{0.963}{2.145 + 0.963 + 0.172 + 0.104} = 28.46\%$$

$$\%CP3 = 100 \times \frac{0.172}{2.145 + 0.963 + 0.172 + 0.104} = 5.08\%$$

$$\%CP4 = 100 \times \frac{0.104}{2.145 + 0.963 + 0.172 + 0.104} = 3.07\%$$

Exemplo 2

- Os dois primeiros componentes principais explicam, juntos, $63.38 + 28.46 = 91.84\%$ da variação original dos dados. Vamos seguir a análise com eles.

Exemplo 2

- Os dois primeiros componentes principais explicam, juntos, $63.38 + 28.46 = 91.84\%$ da variação original dos dados. Vamos seguir a análise com eles.

- Componentes principais:

Exemplo 2

- Os dois primeiros componentes principais explicam, juntos, $63.38 + 28.46 = 91.84\%$ da variação original dos dados. Vamos seguir a análise com eles.

- Componentes principais:

$$\text{CP}_1 = 0.434 \times \texttt{sabor}^* + 0.429 \times \texttt{aroma}^* + 0.595 \times \texttt{consistência}^* + 0.527 \times \texttt{quantidade}^*$$

Exemplo 2

- Os dois primeiros componentes principais explicam, juntos, $63.38 + 28.46 = 91.84\%$ da variação original dos dados. Vamos seguir a análise com eles.

- Componentes principais:

$$\text{CP}_1 = 0.434 \times \texttt{sabor}^* + 0.429 \times \texttt{aroma}^* + 0.595 \times \texttt{consistência}^* + 0.527 \times \texttt{quantidade}^*$$

$$\text{CP}_2 = 0.627 \times \texttt{sabor}^* + 0.486 \times \texttt{aroma}^* - 0.394 \times \texttt{consistência}^* - 0.463 \times \texttt{quantidade}^*$$

Exemplo 2

- Os dois primeiros componentes principais explicam, juntos, $63.38 + 28.46 = 91.84\%$ da variação original dos dados. Vamos seguir a análise com eles.

- Componentes principais:

$$\text{CP}_1 = 0.434 \times \texttt{sabor}^* + 0.429 \times \texttt{aroma}^* + 0.595 \times \texttt{consistência}^* + 0.527 \times \texttt{quantidade}^*$$

$$\text{CP}_2 = 0.627 \times \texttt{sabor}^* + 0.486 \times \texttt{aroma}^* - 0.394 \times \texttt{consistência}^* - 0.463 \times \texttt{quantidade}^*$$

- **Nota:** $\texttt{sabor}^*$ indica que a variável `sabor` está centrada na média amostral (semelhante para as demais variáveis).

Exemplo 2

- O primeiro componente principal confere pesos próximos e de mesmo sinal aos quatro atributos. Ele pode ser interpretado como a *qualidade global* da pizza.

Exemplo 2

- O primeiro componente principal confere pesos próximos e de mesmo sinal aos quatro atributos. Ele pode ser interpretado como a *qualidade global* da pizza.

- Neste caso, quanto maior (mais positivo) o escore de CP1 para uma particular pizza, maior sua qualidade global. Pizzas com escores negativos em CP1, por outro lado, têm baixa qualidade global.

Exemplo 2

- O primeiro componente principal confere pesos próximos e de mesmo sinal aos quatro atributos. Ele pode ser interpretado como a *qualidade global* da pizza.
- Neste caso, quanto maior (mais positivo) o escore de CP1 para uma particular pizza, maior sua qualidade global. Pizzas com escores negativos em CP1, por outro lado, têm baixa qualidade global.
- O segundo componente principal contrasta aroma e sabor (com pesos positivos) versus consistência e quantidade (com pesos negativos).

Exemplo 2

- O primeiro componente principal confere pesos próximos e de mesmo sinal aos quatro atributos. Ele pode ser interpretado como a *qualidade global* da pizza.

- Neste caso, quanto maior (mais positivo) o escore de CP1 para uma particular pizza, maior sua qualidade global. Pizzas com escores negativos em CP1, por outro lado, têm baixa qualidade global.

- O segundo componente principal contrasta aroma e sabor (com pesos positivos) versus consistência e quantidade (com pesos negativos).

- Neste caso, quanto maior (mais positivo) o escore de CP2 para uma particular pizza, mais o aroma e o sabor superam consistência e quantidade. Pizzas com escores negativos em CP2, por outro lado, consistência e quantidade que superam qualidade e sabor. Finalmente, pizzas com CP2 próximo de zero são "equilibradas" no conjunto de atributos.

Exemplo 2

- Vamos calcular os escores de CP1 e CP2 para as duas primeiras marcas. As médias amostrais são apresentadas ao longo dos cálculos:

Exemplo 2

- Vamos calcular os escores de CP1 e CP2 para as duas primeiras marcas. As médias amostrais são apresentadas ao longo dos cálculos:

$$CP_{11} = 0.434 \times (8.57 - 7.16) + 0.429 \times (9.24 - 7.18) + 0.595 \times (8.14 - 7.48) + 0.527 \times (7.38 - 7.25) = 1.96$$

$$CP_{12} = 0.434 \times (6.71 - 7.16) + 0.429 \times (6.77 - 7.18) + 0.595 \times (6.14 - 7.48) + 0.527 \times (6.29 - 7.25) = 1.57$$

$$CP_{21} = 0.627 \times (8.57 - 7.16) + 0.486 \times (9.24 - 7.18) - 0.394 \times (8.14 - 7.48) - 0.463 \times (7.38 - 7.25) = -1.67$$

$$CP_{22} = 0.627 \times (6.71 - 7.16) + 0.486 \times (6.77 - 7.18) - 0.394 \times (6.14 - 7.48) - 0.463 \times (6.29 - 7.25) = 0.50$$

Exemplo 2

Tabela 2: Escores de CP1 e CP2 para as 15 marcas de pizza e respectivos rankings

Marca	CP1	CP2	Ranking (CP1)	Ranking (CP2)
1	1.96	1.57	2	2
2	-1.67	0.50	14	5
3	0.62	-0.58	5	10
4	-0.31	-0.15	9	7
5	1.93	0.81	3	4
6	1.89	-0.78	4	12
7	-0.52	-0.79	10	13
8	2.00	-0.96	1	14
9	-2.22	-0.28	15	9
10	-1.21	-0.19	11	8
11	-1.53	1.74	12	1
12	0.34	1.34	6	3
13	-1.57	-0.67	13	11
14	0.16	-0.09	7	6
15	0.14	-1.47	8	15

Exemplo 2

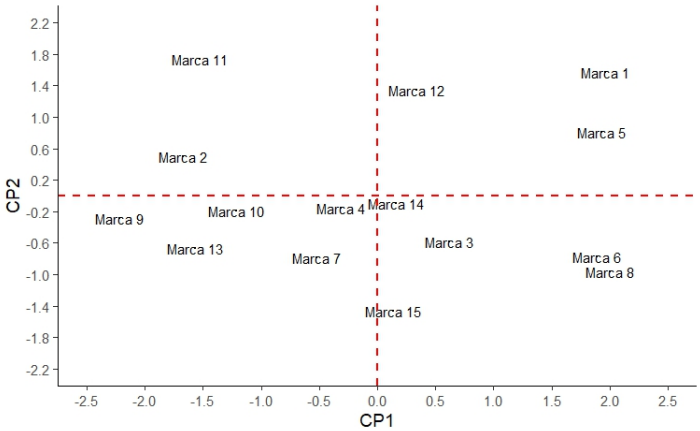


Figura 14: Gráfico para as duas componentes principais

Exemplo 2

- A pizza da marca 1 se destaca por elevados escores (positivos) de CP1 e CP2. Isso indica que ela tem elevada qualidade global, e que sabor e aroma são predominantes em relação a consistência e quantidade.

Exemplo 2

- A pizza da marca 1 se destaca por elevados escores (positivos) de CP1 e CP2. Isso indica que ela tem elevada qualidade global, e que sabor e aroma são predominantes em relação a consistência e quantidade.

- A pizza da marca 11 se destaca por elevados escores de CP1 (negativo) e CP2 (positivo). Isso indica que ela tem baixa qualidade global, e que consistência e quantidade são predominantes em relação a sabor e aroma.

Exemplo 2

- A pizza da marca 1 se destaca por elevados escores (positivos) de CP1 e CP2. Isso indica que ela tem elevada qualidade global, e que sabor e aroma são predominantes em relação a consistência e quantidade.

- A pizza da marca 11 se destaca por elevados escores de CP1 (negativo) e CP2 (positivo). Isso indica que ela tem baixa qualidade global, e que consistência e quantidade são predominantes em relação a sabor e aroma.

- A pizza da marca 4 tem escores intermediários para CP1 e CP2. Isso indica que ela tem qualidade global mediana, e que se trata de uma pizza equilibrada com relação às qualidades dos quatro atributos aferidos.

Exemplo 2

- A pizza da marca 1 se destaca por elevados escores (positivos) de CP1 e CP2. Isso indica que ela tem elevada qualidade global, e que sabor e aroma são predominantes em relação a consistência e quantidade.

- A pizza da marca 11 se destaca por elevados escores de CP1 (negativo) e CP2 (positivo). Isso indica que ela tem baixa qualidade global, e que consistência e quantidade são predominantes em relação a sabor e aroma.

- A pizza da marca 4 tem escores intermediários para CP1 e CP2. Isso indica que ela tem qualidade global mediana, e que se trata de uma pizza equilibrada com relação às qualidades dos quatro atributos aferidos.

- Conclusões semelhantes podem ser aferidas para as pizzas das demais marcas.

Exemplo 3

Exemplo 3

- Um estudo foi conduzido com o objetivo de investigar a associação entre as condições climáticas e o número de suicídios por enforcamento na cidade de São Paulo. Nesta aplicação, vamos considerar os dados das seguintes variáveis climáticas avaliadas diariamente no período de 01/08/2006 a 31/07/2007:

Exemplo 3

- Um estudo foi conduzido com o objetivo de investigar a associação entre as condições climáticas e o número de suicídios por enforcamento na cidade de São Paulo. Nesta aplicação, vamos considerar os dados das seguintes variáveis climáticas avaliadas diariamente no período de 01/08/2006 a 31/07/2007:
  - `tempmax`: temperatura máxima;

Exemplo 3

- Um estudo foi conduzido com o objetivo de investigar a associação entre as condições climáticas e o número de suicídios por enforcamento na cidade de São Paulo. Nesta aplicação, vamos considerar os dados das seguintes variáveis climáticas avaliadas diariamente no período de 01/08/2006 a 31/07/2007:
  - `tempmax`: temperatura máxima;
  - `tempmin`: temperatura mínima;

Exemplo 3

- Um estudo foi conduzido com o objetivo de investigar a associação entre as condições climáticas e o número de suicídios por enforcamento na cidade de São Paulo. Nesta aplicação, vamos considerar os dados das seguintes variáveis climáticas avaliadas diariamente no período de 01/08/2006 a 31/07/2007:
  - `tempmax`: temperatura máxima;
  - `tempmin`: temperatura mínima;
  - `tempmed`: temperatura média;

Exemplo 3

- Um estudo foi conduzido com o objetivo de investigar a associação entre as condições climáticas e o número de suicídios por enforcamento na cidade de São Paulo. Nesta aplicação, vamos considerar os dados das seguintes variáveis climáticas avaliadas diariamente no período de 01/08/2006 a 31/07/2007:
  - `tempmax`: temperatura máxima;
  - `tempmin`: temperatura mínima;
  - `tempmed`: temperatura média;
  - `precip`: precipitação;

Exemplo 3

- Um estudo foi conduzido com o objetivo de investigar a associação entre as condições climáticas e o número de suicídios por enforcamento na cidade de São Paulo. Nesta aplicação, vamos considerar os dados das seguintes variáveis climáticas avaliadas diariamente no período de 01/08/2006 a 31/07/2007:
  - `tempmax`: temperatura máxima;
  - `tempmin`: temperatura mínima;
  - `tempmed`: temperatura média;
  - `precip`: precipitação;
  - `nebul`: nebulosidade.

Exemplo 3

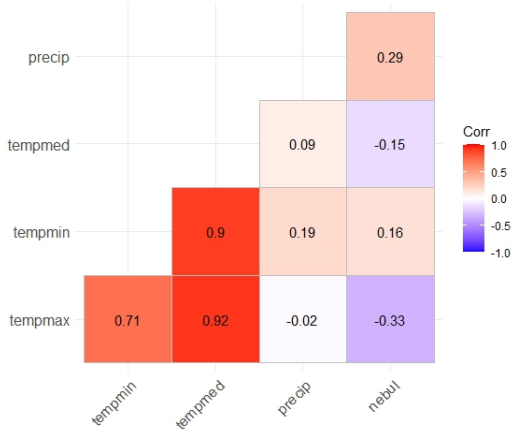


Figura 15: Correlograma para as variáveis climáticas

Exemplo 3

Tabela 3: Matriz de correlações

	tempmax	tempmin	tempmed	precip	nebul
tempmax	1.00	0.71	0.92	-0.02	-0.33
tempmin	0.71	1.00	0.90	0.19	0.16
tempmed	0.92	0.90	1.00	0.09	-0.15
precip	-0.02	0.19	0.09	1.00	0.29
nebul	-0.33	0.16	-0.15	0.29	1.00

Exemplo 3

$$\mathrm{R} = \boldsymbol{P\Lambda P'},$$

Exemplo 3

$$\mathrm{R} = \boldsymbol{P}\boldsymbol{\Lambda}\boldsymbol{P}',$$

onde

$$\boldsymbol{P} = \begin{bmatrix} 0.568 & -0.147 & -0.061 & -0.677 & 0.424 \\ 0.547 & 0.247 & 0.226 & 0.637 & 0.426 \\ 0.602 & -0.001 & 0.038 & 0.003 & -0.797 \\ 0.068 & 0.635 & -0.767 & 0.041 & 0.012 \\ -0.100 & 0.706 & 0.594 & -0.635 & -0.049 \end{bmatrix} \quad \text{e} \quad \boldsymbol{\Lambda} \begin{bmatrix} 2.719 & 0 & 0 & 0 & 0 \\ 0 & 1.402 & 0 & 0 & 0 \\ 0 & 0 & 0.713 & 0 & 0 \\ 0 & 0 & 0 & 0.145 & 0 \\ 0 & 0 & 0 & 0 & 0.019 \end{bmatrix}$$

Exemplo 3

- Autovalores da matriz de correlações: $\hat{\lambda}_1 = 2.719$; $\hat{\lambda}_2 = 1.402$; $\hat{\lambda}_3 = 0.713$; $\hat{\lambda}_4 = 0.145$; $\hat{\lambda}_5 = 0.019$.

Exemplo 3

- Autovalores da matriz de correlações: $\hat{\lambda}_1 = 2.719$; $\hat{\lambda}_2 = 1.402$; $\hat{\lambda}_3 = 0.713$; $\hat{\lambda}_4 = 0.145$; $\hat{\lambda}_5 = 0.019$.

- Autovetores da matriz de correlações:

$$\boldsymbol{e}_1 = \begin{bmatrix} +0.568 \\ +0.547 \\ +0.602 \\ +0.068 \\ -0.100 \end{bmatrix} \quad \boldsymbol{e}_2 = \begin{bmatrix} -0.187 \\ +0.247 \\ -0.001 \\ +0.635 \\ +0.706 \end{bmatrix} \quad \boldsymbol{e}_3 = \begin{bmatrix} -0.061 \\ +0.226 \\ +0.038 \\ -0.767 \\ +0.594 \end{bmatrix} \quad \boldsymbol{e}_4 = \begin{bmatrix} -0.677 \\ +0.637 \\ +0.003 \\ +0.041 \\ -0.635 \end{bmatrix} \quad \boldsymbol{e}_5 = \begin{bmatrix} +0.424 \\ +0.426 \\ -0.797 \\ +0.012 \\ -0.049 \end{bmatrix}$$

Exemplo 3

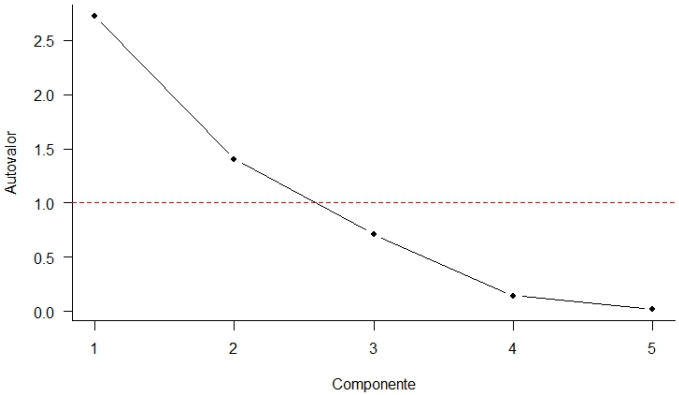


Figura 16: Screeplot

Exemplo 3

- O primeiro componente pricipal explica a seguinte porcentagem da variação total dos dados:

$$100 \times \frac{\hat{\lambda}_1}{\hat{\lambda}_1 + \hat{\lambda}_2 + \hat{\lambda}_3 + \hat{\lambda}_4 + \hat{\lambda}_5} = 100 \times \frac{2.719}{2.719 + 1.402 + 0.713 + 0.145 + 0.019} = 100 \times \frac{2.719}{5} = 54.4\%$$

Exemplo 3

- O primeiro componente pricipal explica a seguinte porcentagem da variação total dos dados:

$$100 \times \frac{\hat{\lambda}_1}{\hat{\lambda}_1 + \hat{\lambda}_2 + \hat{\lambda}_3 + \hat{\lambda}_4 + \hat{\lambda}_5} = 100 \times \frac{2.719}{2.719 + 1.402 + 0.713 + 0.145 + 0.019} = 100 \times \frac{2.719}{5} = 54.4\%$$

- O segundo componente pricipal explica a seguinte porcentagem da variação total dos dados:

$$100 \times \frac{\hat{\lambda}_2}{\hat{\lambda}_1 + \hat{\lambda}_2 + \hat{\lambda}_3 + \hat{\lambda}_4 + \hat{\lambda}_5} = 100 \times \frac{1.402}{2.719 + 1.402 + 0.713 + 0.145 + 0.019} = 100 \times \frac{1.402}{5} = 28.1\%,$$

de forma que, conjuntamente, os dois primeiros componentes principais explicam 54.4+28.1=82.5% da variação total.

Exemplo 3

- De maneira semelhante, os demais componentes explicam as seguintes parcelas da variação total: 14.3% (CP3); 2.9% (CP4); e 0.4% (CP5).

Exemplo 3

- De maneira semelhante, os demais componentes explicam as seguintes parcelas da variação total: 14.3% (CP3); 2.9% (CP4); e 0.4% (CP5).

- Com base nos resultados apresentados, a solução com dois componentes principais poderia ser escolhida, porque:

Exemplo 3

- De maneira semelhante, os demais componentes explicam as seguintes parcelas da variação total: 14.3% (CP3); 2.9% (CP4); e 0.4% (CP5).

- Com base nos resultados apresentados, a solução com dois componentes principais poderia ser escolhida, porque:
  - Apenas os dois primeiros componentes principais tem autovalor associado maior que 1 (critério de Kaiser);

Exemplo 3

- De maneira semelhante, os demais componentes explicam as seguintes parcelas da variação total: 14.3% (CP3); 2.9% (CP4); e 0.4% (CP5).

- Com base nos resultados apresentados, a solução com dois componentes principais poderia ser escolhida, porque:
  - Apenas os dois primeiros componentes principais tem autovalor associado maior que 1 (critério de Kaiser);
  - Os dois primeiros componentes principais explicam, conjuntamente, uma parcela basrante expressiva da variação total dos dados (82.5%);

Exemplo 3

- De maneira semelhante, os demais componentes explicam as seguintes parcelas da variação total: 14.3% (CP3); 2.9% (CP4); e 0.4% (CP5).

- Com base nos resultados apresentados, a solução com dois componentes principais poderia ser escolhida, porque:
  - Apenas os dois primeiros componentes principais tem autovalor associado maior que 1 (critério de Kaiser);
  - Os dois primeiros componentes principais explicam, conjuntamente, uma parcela basrante expressiva da variação total dos dados (82.5%);
  - O screeplot evidencia as explicações relativamente menores de CP3, CP4 e CP5.

Exemplo 3

- O primeiro componente principal tem a seguinte expressão:

$$\text{CP1} = 0.568 \times \texttt{tempmax} + 0.547 \times \texttt{tempmin} + 0.602 \times \texttt{tempmed} + 0.068 \times \texttt{precip} - 0.100 \times \texttt{nebul}$$

Exemplo 3

- O primeiro componente principal tem a seguinte expressão:

$$\text{CP1} = 0.568 \times \texttt{tempmax} + 0.547 \times \texttt{tempmin} + 0.602 \times \texttt{tempmed} + 0.068 \times \texttt{precip} - 0.100 \times \texttt{nebul}$$

- As variáveis com maiores cargas em CP1 são aquelas relacionadas às temperaturas (`tempmax`, `tempmin` e `tempmed`), que estão positivamente correlacionadas (têm mesmo sinal no componente).

Exemplo 3

- O primeiro componente principal tem a seguinte expressão:

$$\text{CP1} = 0.568 \times \texttt{tempmax} + 0.547 \times \texttt{tempmin} + 0.602 \times \texttt{tempmed} + 0.068 \times \texttt{precip} - 0.100 \times \texttt{nebul}$$

- As variáveis com maiores cargas em CP1 são aquelas relacionadas às temperaturas (`tempmax`, `tempmin` e `tempmed`), que estão positivamente correlacionadas (têm mesmo sinal no componente).

- Este componente poderia ser interpretado como a *percepção térmica*.

Exemplo 3

- O segundo componente principal tem a seguinte expressão:

$$\text{CP2} = -0.187 \times \texttt{tempmax} + 0.247 \times \texttt{tempmin} - 0.001 \times \texttt{tempmed} + 0.635 \times \texttt{precip} + 0.706 \times \texttt{nebul}$$

Exemplo 3

- O segundo componente principal tem a seguinte expressão:

$$\text{CP2} = -0.187 \times \texttt{tempmax} + 0.247 \times \texttt{tempmin} - 0.001 \times \texttt{tempmed} + 0.635 \times \texttt{precip} + 0.706 \times \texttt{nebul}$$

- As variáveis com maiores cargas em CP2 são aquelas relacionadas à precipitação e à nebulosidade (`precip` e `nebul`), que estão positivamente correlacionadas (têm mesmo sinal no componente).

Exemplo 3

- O segundo componente principal tem a seguinte expressão:

$$\text{CP2} = -0.187 \times \texttt{tempmax} + 0.247 \times \texttt{tempmin} - 0.001 \times \texttt{tempmed} + 0.635 \times \texttt{precip} + 0.706 \times \texttt{nebul}$$

- As variáveis com maiores cargas em CP2 são aquelas relacionadas à precipitação e à nebulosidade (`precip` e `nebul`), que estão positivamente correlacionadas (têm mesmo sinal no componente).

- Esse componente poderia ser interpretado como a *percepção de acinzentamento*. para um dia qualquer.

Exemplo 3

- Correlações entre as variáveis originais e o primeiro componente principal:

Exemplo 3

- Correlações entre as variáveis originais e o primeiro componente principal:

$$\text{Cor}(\texttt{tempmax}, \text{PC1}) = \hat{e}_{11} \times \sqrt{\hat{\lambda}_1} = 0.568 \times \sqrt{2.719} = 0.936$$

Exemplo 3

- Correlações entre as variáveis originais e o primeiro componente principal:

$$\text{Cor}(\texttt{tempmax}, \text{PC1}) = \hat{e}_{11} \times \sqrt{\hat{\lambda}_1} = 0.568 \times \sqrt{2.719} = 0.936$$

$$\text{Cor}(\texttt{tempmin}, \text{PC1}) = \hat{e}_{12} \times \sqrt{\hat{\lambda}_1} = 0.547 \times \sqrt{2.719} = 0.901$$

Exemplo 3

- Correlações entre as variáveis originais e o primeiro componente principal:

$$\text{Cor}(\texttt{tempmax}, \text{PC1}) = \hat{e}_{11} \times \sqrt{\hat{\lambda}_1} = 0.568 \times \sqrt{2.719} = 0.936$$

$$\text{Cor}(\texttt{tempmin}, \text{PC1}) = \hat{e}_{12} \times \sqrt{\hat{\lambda}_1} = 0.547 \times \sqrt{2.719} = 0.901$$

$$\text{Cor}(\texttt{tempmed}, \text{PC1}) = \hat{e}_{13} \times \sqrt{\hat{\lambda}_1} = 0.602 \times \sqrt{2.719} = 0.992$$

Exemplo 3

$$\text{Cor}(\texttt{precip}, \text{PC1}) = \hat{e}_{14} \times \sqrt{\hat{\lambda}_1} = 0.068 \times \sqrt{2.719} = 0.112$$

Exemplo 3

$$\text{Cor}(\texttt{precip}, \text{PC1}) = \hat{e}_{14} \times \sqrt{\hat{\lambda}_1} = 0.068 \times \sqrt{2.719} = 0.112$$

$$\text{Cor}(\texttt{nebul}, \text{PC1}) = \hat{e}_{15} \times \sqrt{\hat{\lambda}_1} = -0.100 \times \sqrt{2.719} = -0.165$$

Exemplo 3

- Correlações entre as variáveis originais e o segundo componente principal:

Exemplo 3

- Correlações entre as variáveis originais e o segundo componente principal:

$$\text{Cor}(\texttt{tempmax}, \text{PC2}) = \hat{e}_{21} \times \sqrt{\hat{\lambda}_2} = -0.187 \times \sqrt{1.402} = -0.221$$

Exemplo 3

- Correlações entre as variáveis originais e o segundo componente principal:

$$\text{Cor}(\texttt{tempmax}, \text{PC2}) = \hat{e}_{21} \times \sqrt{\hat{\lambda}_2} = -0.187 \times \sqrt{1.402} = -0.221$$

$$\text{Cor}(\texttt{tempmin}, \text{PC2}) = \hat{e}_{22} \times \sqrt{\hat{\lambda}_2} = 0.247 \times \sqrt{1.402} = 0.292$$

Exemplo 3

- Correlações entre as variáveis originais e o segundo componente principal:

$$\text{Cor}(\texttt{tempmax}, \text{PC2}) = \hat{e}_{21} \times \sqrt{\hat{\lambda}_2} = -0.187 \times \sqrt{1.402} = -0.221$$

$$\text{Cor}(\texttt{tempmin}, \text{PC2}) = \hat{e}_{22} \times \sqrt{\hat{\lambda}_2} = 0.247 \times \sqrt{1.402} = 0.292$$

$$\text{Cor}(\texttt{tempmed}, \text{PC2}) = \hat{e}_{23} \times \sqrt{\hat{\lambda}_2} = -0.001 \times \sqrt{1.402} = -0.001$$

Exemplo 3

$$\text{Cor}(\texttt{precip}, \text{PC2}) = \hat{e}_{24} \times \sqrt{\hat{\lambda}_2} = 0.635 \times \sqrt{1.402} = 0.752$$

Exemplo 3

$$\text{Cor}(\texttt{precip}, \text{PC2}) = \hat{e}_{24} \times \sqrt{\hat{\lambda}_2} = 0.635 \times \sqrt{1.402} = 0.752$$

$$\text{Cor}(\texttt{nebul}, \text{PC2}) = \hat{e}_{25} \times \sqrt{\hat{\lambda}_2} = 0.706 \times \sqrt{1.402} = 0.836$$

Exemplo 3

- Vamos calcular os escores de CP1 e CP2 para um dia com as seguintes características: `tempmax`=30, `tempmin`=18, `tempmed`=25, `precip`=2, `nebul`=2.

Exemplo 3

- Vamos calcular os escores de CP1 e CP2 para um dia com as seguintes características: `tempmax`=30, `tempmin`=18, `tempmed`=25, `precip`=2, `nebul`=2.

- Como a análise foi realizada com base na matriz de correlações, as observações devem ser escalonadas para o cálculo do escore:

$$\text{CP1} = 0.568 \times \frac{30 - 26.44}{4.28} + 0.547 \times \frac{18 - 16.61}{3.46} + 0.602 \times \frac{25 - 20.55}{3.56} + 0.068 \times \frac{2 - 4.878}{12} - 0.100 \times \frac{2 - 7.487}{2.60} = +1.639$$

Exemplo 3

- Vamos calcular os escores de CP1 e CP2 para um dia com as seguintes características: `tempmax`=30, `tempmin`=18, `tempmed`=25, `precip`=2, `nebul`=2.

- Como a análise foi realizada com base na matriz de correlações, as observações devem ser escalonadas para o cálculo do escore:

$$\text{CP1} = 0.568 \times \frac{30 - 26.44}{4.28} + 0.547 \times \frac{18 - 16.61}{3.46} + 0.602 \times \frac{25 - 20.55}{3.56} + 0.068 \times \frac{2 - 4.878}{12} - 0.100 \times \frac{2 - 7.487}{2.60} = +1.639$$

- O escore positivo para CP1 indica um dia com percepção de altas temperaturas.

Exemplo 3

$$\text{CP2} = -0.187 \times \frac{30 - 26.44}{4.28} + 0.247 \times \frac{18 - 16.61}{3.46} - 0.001 \times \frac{25 - 20.55}{3.56} + 0.635 \times \frac{2 - 4.878}{12} + 0.706 \times \frac{2 - 7.487}{2.60} = -1.700$$

Exemplo 3

$$\text{CP2} = -0.187 \times \frac{30 - 26.44}{4.28} + 0.247 \times \frac{18 - 16.61}{3.46} - 0.001 \times \frac{25 - 20.55}{3.56} + 0.635 \times \frac{2 - 4.878}{12} + 0.706 \times \frac{2 - 7.487}{2.60} = -1.700$$

- O escore negativo para CP2 indica um dia com baixa percepção de acinzamento.

Exemplo 3

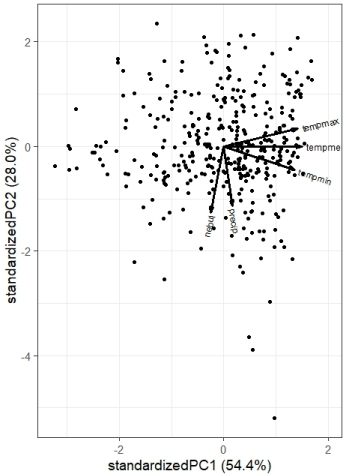


Figura 17: Biplot

Exemplo 3

- Como interpretar o biplot:

Exemplo 3

- Como interpretar o biplot:
  - Ângulo entre vetores (e entre vetores e componentes) é uma aproximação para as correlações entre as respectivas variáveis:

Exemplo 3

- Como interpretar o biplot:
  - Ângulo entre vetores (e entre vetores e componentes) é uma aproximação para as correlações entre as respectivas variáveis:
    - Ângulo próximo de zero indica elevada correlação positiva;

Exemplo 3

- Como interpretar o biplot:
  - Ângulo entre vetores (e entre vetores e componentes) é uma aproximação para as correlações entre as respectivas variáveis:
    - Ângulo próximo de zero indica elevada correlação positiva;
    - Ângulo próximo de 90 graus, correlação próxima de zero;

Exemplo 3

- Como interpretar o biplot:
  - Ângulo entre vetores (e entre vetores e componentes) é uma aproximação para as correlações entre as respectivas variáveis:
    - Ângulo próximo de zero indica elevada correlação positiva;
    - Ângulo próximo de 90 graus, correlação próxima de zero;
    - Ângulo próximo de 180 graus, elevada correlação negativa.

Exemplo 3

- Como interpretar o biplot:
  - Ângulo entre vetores (e entre vetores e componentes) é uma aproximação para as correlações entre as respectivas variáveis:
    - Ângulo próximo de zero indica elevada correlação positiva;
    - Ângulo próximo de 90 graus, correlação próxima de zero;
    - Ângulo próximo de 180 graus, elevada correlação negativa.
  - Quanto maior o comprimento do vetor, melhor a qualidade de representação da variável;

Exemplo 3

- Como interpretar o biplot:
  - Ângulo entre vetores (e entre vetores e componentes) é uma aproximação para as correlações entre as respectivas variáveis:
    - Ângulo próximo de zero indica elevada correlação positiva;
    - Ângulo próximo de 90 graus, correlação próxima de zero;
    - Ângulo próximo de 180 graus, elevada correlação negativa.
  - Quanto maior o comprimento do vetor, melhor a qualidade de representação da variável;
  - Projeção do ponto (observação) em vetor (ou componente) indica a contribuição do vetor (componente) naquela observação.

O que vamos estudar no próximo módulo

O que vamos estudar no próximo módulo

- No próximo módulo estudaremos outra técnica de redução de dimensão, denominada **análise fatorial**.

O que vamos estudar no próximo módulo

- No próximo módulo estudaremos outra técnica de redução de dimensão, denominada **análise fatorial**.

- Estudaremos as principais características da técnica e como ela se diferencia da análise de componentes principais.

O que vamos estudar no próximo módulo

- No próximo módulo estudaremos outra técnica de redução de dimensão, denominada **análise fatorial**.
- Estudaremos as principais características da técnica e como ela se diferencia da análise de componentes principais.
- Aplicações da análise de componentes principais em diferentes área serão usadas para discutir o uso da técnica.