CE319 - Estatística multivariada

Análise discriminante

Cesar Augusto Taconeli

02 de junho, 2026

O que vamos estudar neste módulo

O que vamos estudar neste módulo

- Neste módulo vamos abordar a técnica de análise discriminante.

O que vamos estudar neste módulo

- Neste módulo vamos abordar a técnica de análise discriminante.

- Serão discutidas duas de suas principais versões: as análises discriminante linear e quafrática.

O que vamos estudar neste módulo

- Neste módulo vamos abordar a técnica de análise discriminante.
- Serão discutidas duas de suas principais versões: as análises discriminante linear e quafrática.
- Problemas de classificação usando o fator de Bayes serão apresentados.

O que vamos estudar neste módulo

- Neste módulo vamos abordar a técnica de análise discriminante.
- Serão discutidas duas de suas principais versões: as análises discriminante linear e quafrática.
- Problemas de classificação usando o fator de Bayes serão apresentados.
- A aula finaliza com aplicações das técnicas usando o R.

Análise Discriminante

Análise Discriminante

- Considere um problema multivariado em que se dispõe de uma amostra $(\boldsymbol{y}_1, \boldsymbol{y}_2, ..., \boldsymbol{y}_n)$ de n indivíduos avaliados em p variáveis.

Análise Discriminante

- Considere um problema multivariado em que se dispõe de uma amostra $(\boldsymbol{y}_1, \boldsymbol{y}_2, ..., \boldsymbol{y}_n)$ de n indivíduos avaliados em p variáveis.

- Vamos admitir também que cada indivíduo pertença a um de k grupos (ou populações), previamente conhecidos.

Análise Discriminante

- Considere um problema multivariado em que se dispõe de uma amostra $(\boldsymbol{y}_1, \boldsymbol{y}_2, ..., \boldsymbol{y}_n)$ de n indivíduos avaliados em p variáveis.

- Vamos admitir também que cada indivíduo pertença a um de k grupos (ou populações), previamente conhecidos.

- Vamos motivar, inicialmente, o caso mais conhecido de análise discriminante, que é a **análise discriminante linear**.

Análise Discriminante linear

- Na análise discriminante linear, buscamos encontrar uma projeção linear:

$$z = \boldsymbol{a}'\boldsymbol{y}$$

tal que

Análise Discriminante linear

- Na análise discriminante linear, buscamos encontrar uma projeção linear:

$$z = \boldsymbol{a}'\boldsymbol{y}$$

tal que

1. os grupos fiquem o mais distantes (separados) possível;

Análise Discriminante linear

- Na análise discriminante linear, buscamos encontrar uma projeção linear:

$$z = \boldsymbol{a}'\boldsymbol{y}$$

tal que

(i) os grupos fiquem o mais distantes (separados) possível;
(ii) a variabilidade dentro dos grupos seja a menor possível.

Análise Discriminante linear

- Na análise discriminante linear, buscamos encontrar uma projeção linear:

$$z = \boldsymbol{a}'\boldsymbol{y}$$

tal que

(i) os grupos fiquem o mais distantes (separados) possível;
(ii) a variabilidade dentro dos grupos seja a menor possível.

- A análise discriminante linear procura a direção que maximiza separação entre grupos.

Análise Discriminante linear

- Na análise discriminante linear, buscamos encontrar uma projeção linear:

$$z = \boldsymbol{a}'\boldsymbol{y}$$

tal que

(i) os grupos fiquem o mais distantes (separados) possível;
(ii) a variabilidade dentro dos grupos seja a menor possível.

- A análise discriminante linear procura a direção que maximiza separação entre grupos.

- Antes de estudarmos a análise discriminante, vamos tratar de maneira mais geral sobre problemas de separação e classificação de dados.

O problema da separação e classificação

O problema da separação e classificação

- Dois tipos de problemas recorrentes em análise de dados e contemplados por técnicas multivariadas são **discriminação** e **classificação**.

O problema da separação e classificação

- Dois tipos de problemas recorrentes em análise de dados e contemplados por técnicas multivariadas são **discriminação** e **classificação**.

- Num problema de discriminação, o objetivo é investigar como p variáveis podem ser usadas na discriminação (separação) de k grupos (ou populações) **pré-definidos**.

O problema da separação e classificação

- Dois tipos de problemas recorrentes em análise de dados e contemplados por técnicas multivariadas são **discriminação** e **classificação**.

- Num problema de discriminação, o objetivo é investigar como p variáveis podem ser usadas na discriminação (separação) de k grupos (ou populações) **pré-definidos**.

- Num problema de classificação, o objetivo é construir uma regra, baseada em p variáveis, que permita classificar novos indivíduos em uma de k populações (grupos) **pré-definidos**.

Exemplos ilustrativos

- **Populações:** Empresas solventes e não solventes; **Variáveis:** Despesas com mão de obra, investimento em novas unidades, balanço no último período...

Exemplos ilustrativos

- **Populações:** Empresas solventes e não solventes; **Variáveis:** Despesas com mão de obra, investimento em novas unidades, balanço no último período...

- **Populações:** Times de futebol deficitários ou superavitários; **Variáveis:** Investimento em contratações, arrecadação com ingresso, desempenho no último campeonato,...

Exemplos ilustrativos

- **Populações:** Empresas solventes e não solventes; **Variáveis:** Despesas com mão de obra, investimento em novas unidades, balanço no último período...
- **Populações:** Times de futebol deficitários ou superavitários; **Variáveis:** Investimento em contratações, arrecadação com ingresso, desempenho no último campeonato,...
- **Populações:** Credores pagadores e não pagadores; **Variáveis:** Valor do crédito concedido, renda, quantia investida em aplicações,...

Exemplos de problemas de discriminação e classificação

- **Populações:** Insetos machos e fêmeas de determinada espécie; **Variáveis:** Medidas corporais como comprimento da asa, tamanho da cabeça, largura do fêmur,...

Exemplos de problemas de discriminação e classificação

- **Populações:** Insetos machos e fêmeas de determinada espécie; **Variáveis:** Medidas corporais como comprimento da asa, tamanho da cabeça, largura do fêmur,...
- **Populações:** Discursos de candidatos de partidos de esquerda, de direita e de centro; **Variáveis:** Número de palavras utilizadas, diversidade de palavras, frequência de uso de termos específicos,...

Exemplos de problemas de discriminação e classificação

- **Populações:** Insetos machos e fêmeas de determinada espécie; **Variáveis:** Medidas corporais como comprimento da asa, tamanho da cabeça, largura do fêmur,...
- **Populações:** Discursos de candidatos de partidos de esquerda, de direita e de centro; **Variáveis:** Número de palavras utilizadas, diversidade de palavras, frequência de uso de termos específicos,...
- **Populações:** Alunos aprovados em cursos de diferentes nas áreas de Exatas, Humanas e Biológicas; **Variáveis:** Notas obtidas nas diferentes provas que compõem o vestibular.

Classificador de Bayes

Classificador de Bayes (caso de duas populações)

- Considere que desejamos discriminar indivíduos de duas populações π_1 e π_2 com base em p variáveis avaliadas $\boldsymbol{y}' = (y_1, y_2, ..., y_p)$.

Classificador de Bayes (caso de duas populações)

- Considere que desejamos discriminar indivíduos de duas populações π_1 e π_2 com base em p variáveis avaliadas $\boldsymbol{y}' = (y_1, y_2, ..., y_p)$.

- Sejam $f_1(\boldsymbol{y})$ e $f_2(\boldsymbol{y})$ as funções (densidade) de probabilidade de $\boldsymbol{y}$ em π_1 e π_2.

Classificador de Bayes (caso de duas populações)

- Considere que desejamos discriminar indivíduos de duas populações π_1 e π_2 com base em p variáveis avaliadas $\boldsymbol{y}' = (y_1, y_2, ..., y_p)$.

- Sejam $f_1(\boldsymbol{y})$ e $f_2(\boldsymbol{y})$ as funções (densidade) de probabilidade de $\boldsymbol{y}$ em π_1 e π_2.

- Seja Ω o espaço amostral (conjunto de resultados possíveis para $\boldsymbol{y}$).

Classificador de Bayes (caso de duas populações)

- Vamos considerar uma partição de Ω em dois conjuntos R_1 e R_2 ($R_1 \bigcup R_2 = \Omega; R_1 \bigcap R_2 = \phi$), tal que:

Classificador de Bayes (caso de duas populações)

- Vamos considerar uma partição de Ω em dois conjuntos R_1 e R_2 ($R_1 \bigcup R_2 = \Omega; R_1 \bigcap R_2 = \phi$), tal que:
  - Todo indivíduo tal que $\boldsymbol{y} \in R_1$ seja classificado como pertencente a π_1;

Classificador de Bayes (caso de duas populações)

- Vamos considerar uma partição de Ω em dois conjuntos R_1 e R_2 ($R_1 \bigcup R_2 = \Omega; R_1 \bigcap R_2 = \phi$), tal que:
  - Todo indivíduo tal que $\boldsymbol{y} \in R_1$ seja classificado como pertencente a π_1;
  - Todo indivíduo tal que $\boldsymbol{y} \in \Omega - R_1 = R_2$ seja classificado como pertencente a π_2.

Classificador de Bayes (caso de duas populações)

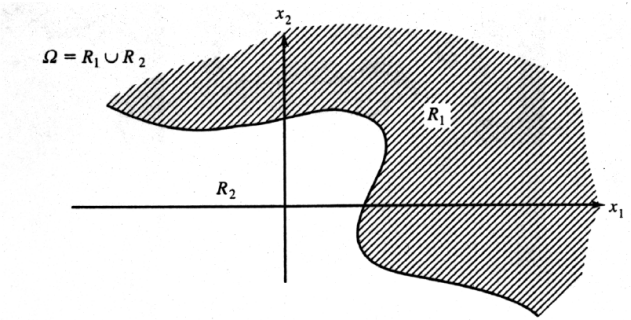


Figura 1: Classificação em duas populações

Classificador de Bayes (caso de duas populações)

- Com base no que foi apresentado, temos os seguintes riscos:

Classificador de Bayes (caso de duas populações)

- Com base no que foi apresentado, temos os seguintes riscos:

1. P(2|1): Probabilidade de classificar um indivíduo em π_2 dado que ele pertence a π_1:

$$P(2|1) = P(\boldsymbol{y} \in R_2|\pi_1) = \int_{R_2} f_1(\boldsymbol{y}) d\boldsymbol{y};$$

Classificador de Bayes (caso de duas populações)

- Com base no que foi apresentado, temos os seguintes riscos:

1. P(2|1): Probabilidade de classificar um indivíduo em π_2 dado que ele pertence a π_1:

$$P(2|1) = P(\boldsymbol{y} \in R_2|\pi_1) = \int_{R_2} f_1(\boldsymbol{y})d\boldsymbol{y};$$

1. P(1|2): Probabilidade de classificar um indivíduo em π_1 dado que ele pertence a π_2:

$$P(1|2) = P(\boldsymbol{y} \in R_1|\pi_2) = \int_{R_1} f_2(\boldsymbol{y})d\boldsymbol{y}.$$

Classificador de Bayes (caso de duas populações)

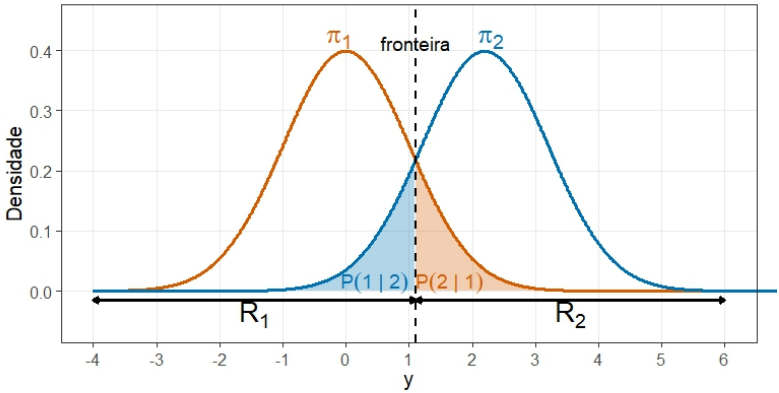


Figura 2: Problema de classificação (caso de duas populações)

Classificador de Bayes (caso de duas populações)

- Vamos assumir probabilidades a priori $p_1 = P(\pi_1)$ e $p_2 = P(\pi_2)$ de um indivíduo pertencer a π_1 e π_2, respectivamente ($p_1 + p_2 = 1$).

Classificador de Bayes (caso de duas populações)

- Vamos assumir probabilidades a priori $p_1 = P(\pi_1)$ e $p_2 = P(\pi_2)$ de um indivíduo pertencer a π_1 e π_2, respectivamente ($p_1 + p_2 = 1$).

- Desta forma, temos:

Classificador de Bayes (caso de duas populações)

- Vamos assumir probabilidades a priori $p_1 = P(\pi_1)$ e $p_2 = P(\pi_2)$ de um indivíduo pertencer a π_1 e π_2, respectivamente ($p_1 + p_2 = 1$).

- Desta forma, temos:

$$P(\pi_1|\boldsymbol{y}) = \frac{p_1 f_1(\boldsymbol{y})}{p_1 f_1(\boldsymbol{y}) + p_2 f_2(\boldsymbol{y})}$$

Classificador de Bayes (caso de duas populações)

- Vamos assumir probabilidades a priori $p_1 = P(\pi_1)$ e $p_2 = P(\pi_2)$ de um indivíduo pertencer a π_1 e π_2, respectivamente ($p_1 + p_2 = 1$).

- Desta forma, temos:

$$P(\pi_1|\boldsymbol{y}) = \frac{p_1 f_1(\boldsymbol{y})}{p_1 f_1(\boldsymbol{y}) + p_2 f_2(\boldsymbol{y})}$$

$$P(\pi_2|\boldsymbol{y}) = \frac{p_2 f_2(\boldsymbol{y})}{p_1 f_1(\boldsymbol{y}) + p_2 f_2(\boldsymbol{y})}$$

Classificador de Bayes (caso de duas populações)

- O classificador de Bayes classifica a observação $\boldsymbol{y}$ em π_i tal que $P(Y \in \pi_i | \boldsymbol{y})$ seja máxima, $i = 1, 2$.

Classificador de Bayes (caso de duas populações)

- O classificador de Bayes classifica a observação $\boldsymbol{y}$ em π_i tal que $P(Y \in \pi_i|\boldsymbol{y})$ seja máxima, $i = 1, 2$.

- De maneira equivalente, o classificador de Bayes classifica $\boldsymbol{y}$ em π_1 se:

$$\frac{f_1(\boldsymbol{y})}{f_2(\boldsymbol{y})} \geq \frac{p_2}{p_1}$$

Classificador de Bayes (caso de duas populações)

- O classificador de Bayes classifica a observação $\boldsymbol{y}$ em π_i tal que $P(Y \in \pi_i|\boldsymbol{y})$ seja máxima, $i = 1, 2$.

- De maneira equivalente, o classificador de Bayes classifica $\boldsymbol{y}$ em π_1 se:

$$\frac{f_1(\boldsymbol{y})}{f_2(\boldsymbol{y})} \geq \frac{p_2}{p_1}$$

e classifica em π_2 se:

$$\frac{f_1(\boldsymbol{y})}{f_2(\boldsymbol{y})} < \frac{p_2}{p_1}.$$

Exemplo 1- Classificador de Bayes (caso de duas populações)

Exemplo 1- Classificador de Bayes (caso de duas populações)

Suponha $f_1(y)$ a densidade de uma distribuição $N(0,1)$, e $f_2(y)$ a de uma distribuição $N(2,1)$. Determine o classificador de Bayes e os riscos de decisão se assumirmos como prioris $p_1 = p_2 = 0.5$.

$$\frac{f_1(y)}{f_2(y)} = \frac{1/\sqrt{2\pi}e^{-y^2/2}}{1/\sqrt{2\pi}e^{-(y-2)^2/2}} = e^{-2y+2}$$

Exemplo 1- Classificador de Bayes (caso de duas populações)

- Neste caso, devemos classificar y em π_1 se

$$e^{-2y+2} \geq \frac{0.5}{0.5} = 1$$

e em π_2, caso contrário.

Exemplo 1- Classificador de Bayes (caso de duas populações)

- Neste caso, devemos classificar y em π_1 se

$$e^{-2y+2} \geq \frac{0.5}{0.5} = 1$$

e em π_2, caso contrário.

- Repare que $e^{-2y+2} \geq 1$ apenas se $-2y + 2 \geq 0$, ou seja, se $y \leq 1$.

Exemplo 1- Classificador de Bayes (caso de duas populações)

- Neste caso, devemos classificar y em π_1 se

$$e^{-2y+2} \geq \frac{0.5}{0.5} = 1$$

e em π_2, caso contrário.

- Repare que $e^{-2y+2} \geq 1$ apenas se $-2y + 2 \geq 0$, ou seja, se $y \leq 1$.

- Então, usando o classificador de Bayes, toda observação $y \leq 1$ deverá ser classificada em π_1, e se $y > 1$ a observação deverá ser classificada em π_2.

Exemplo 1- Classificador de Bayes (caso de duas populações)

- Os riscos de classificação incorreta são dados por:

Exemplo 1- Classificador de Bayes (caso de duas populações)

- Os riscos de classificação incorreta são dados por:

$$P(2|1) = P(Y \geq 1|\pi_1) = 0.159$$

Exemplo 1- Classificador de Bayes (caso de duas populações)

- Os riscos de classificação incorreta são dados por:

$$P(2|1) = P(Y \geq 1|\pi_1) = 0.159$$

$$P(1|2) = P(Y < 1|\pi_2) = 0.159$$

Exemplo 1- Classificador de Bayes (caso de duas populações)

- Se as probabilidades estabelecidas a priori não fossem as mesmas para as duas populações, isso impactaria na regra de decisão.

Exemplo 1- Classificador de Bayes (caso de duas populações)

- Se as probabilidades estabelecidas a priori não fossem as mesmas para as duas populações, isso impactaria na regra de decisão.

- A título de ilustração, se tomarmos $p_1 = 0.25$ e $p_2 = 0.75$, então a observação y deverá ser classificada em π_1 se:

$$\frac{f_1(y)}{f_2(y)} = e^{-2y+2} \geq \frac{0.75}{0.25} = 3,$$

e em π_2, caso contrário.

Exemplo 1- Classificador de Bayes (caso de duas populações)

- Desta forma, para $y = 0.25$ temos $e^{-2\times 0.25+2} = 4.48 > 3$, e a observação seria classificada em π_1.

Exemplo 1- Classificador de Bayes (caso de duas populações)

- Desta forma, para $y = 0.25$ temos $e^{-2\times 0.25+2} = 4.48 > 3$, e a observação seria classificada em π_1.

- Por outro lado, para $y = 0.5$ temos $e^{-2\times 0.5+2} = 2.71 < 3$, e a observação seria classificada em π_2.

Custos de má-classificação

Custos de má-classificação

- Em algumas situações, os custos associados aos riscos de classificação incorreta não são os mesmos para as diferentes classes.

Custos de má-classificação

- Em algumas situações, os custos associados aos riscos de classificação incorreta não são os mesmos para as diferentes classes.
  - Seja $c(1|2)$ o custo de classificar um indivíduo pertencente a π_2 como vindo de π_1;

Custos de má-classificação

- Em algumas situações, os custos associados aos riscos de classificação incorreta não são os mesmos para as diferentes classes.
  - Seja $c(1|2)$ o custo de classificar um indivíduo pertencente a π_2 como vindo de π_1;
  - Seja $c(2|1)$ o custo de classificar um indivíduo pertencente a π_1 como vindo de π_2.

Custos de má-classificação

- Em algumas situações, os custos associados aos riscos de classificação incorreta não são os mesmos para as diferentes classes.
  - Seja $c(1|2)$ o custo de classificar um indivíduo pertencente a π_2 como vindo de π_1;
  - Seja $c(2|1)$ o custo de classificar um indivíduo pertencente a π_1 como vindo de π_2.

- Naturalmente $c(1|1) = c(2|2) = 0$.

Custos de má-classificação

- Para qualquer regra de classificação, o custo esperado de má-classificação (ECM) fica dado por:

$$\text{ECM} = c(2|1)P(2|1)p_1 + c(1|2)P(1|2)p_2$$

.

Custos de má-classificação

- Para qualquer regra de classificação, o custo esperado de má-classificação (ECM) fica dado por:

$$\text{ECM} = c(2|1)P(2|1)p_1 + c(1|2)P(1|2)p_2$$

.

- Neste caso, o classificador de Bayes consiste em minimizar ECM, classificando uma observação em π_1 se

$$c(2|1)P(2|1)p_1 \leq c(1|2)P(1|2)p_2,$$

Custos de má-classificação

- Para qualquer regra de classificação, o custo esperado de má-classificação (ECM) fica dado por:

$$\text{ECM} = c(2|1)P(2|1)p_1 + c(1|2)P(1|2)p_2$$

.

- Neste caso, o classificador de Bayes consiste em minimizar ECM, classificando uma observação em π_1 se

$$c(2|1)P(2|1)p_1 \leq c(1|2)P(1|2)p_2,$$

ou em π_2 se $c(2|1)P(2|1)p_1 > c(1|2)P(1|2)p_2$.

Custos de má-classificação

- Sejam $f_1(\boldsymbol{y})$ e $f_2(\boldsymbol{y})$ as funções densidade de probabilidades de $\boldsymbol{y} \in \pi_1$ e $\boldsymbol{y} \in \pi_2$, respectivamente.

Custos de má-classificação

- Sejam $f_1(\boldsymbol{y})$ e $f_2(\boldsymbol{y})$ as funções densidade de probabilidades de $\boldsymbol{y} \in \pi_1$ e $\boldsymbol{y} \in \pi_2$, respectivamente.

- Usando o classificador de Bayes, devemos classificar $\boldsymbol{y}$ em π_1 se:

$$\frac{f_1(\boldsymbol{y})}{f_2(\boldsymbol{y})} \geq \frac{c(1|2)}{c(2|1)} \times \frac{p_2}{p_1}$$

ou, de forma equivalente, se $p_1 c(2|1) f_1(\boldsymbol{y}) \geq p_2 c(1|2) f_2(\boldsymbol{y})$.

Custos de má-classificação

- Logo, $\boldsymbol{y}$ será classificada em π_2 se:

$$\frac{f_1(\boldsymbol{y})}{f_2(\boldsymbol{y})} < \frac{c(1|2)}{c(2|1)} \times \frac{p_2}{p_1},$$

ou, de forma equivalente, se $p_1 c(2|1) f_1(\boldsymbol{y}) < p_2 c(1|2) f_2(\boldsymbol{y})$.

Exemplo 2- Classificação em duas populações com custos desiguais de má-classificação

Exemplo 2- Classificação em duas populações com custos desiguais de má-classificação

- Considere π_1 e π_2 duas populações com respectivas funções densidade $f_1(\boldsymbol{y})$ e $f_2(\boldsymbol{y})$. Estabeleça a regra de decisão que minimiza ECM com base nas regras:

Exemplo 2- Classificação em duas populações com custos desiguais de má-classificação

- Considere π_1 e π_2 duas populações com respectivas funções densidade $f_1(\boldsymbol{y})$ e $f_2(\boldsymbol{y})$. Estabeleça a regra de decisão que minimiza ECM com base nas regras:

a. **Regra 1:** $p_1 = p_2$, $c(1|2) = c(2|1)$;

Exemplo 2- Classificação em duas populações com custos desiguais de má-classificação

- Considere π_1 e π_2 duas populações com respectivas funções densidade $f_1(\boldsymbol{y})$ e $f_2(\boldsymbol{y})$. Estabeleça a regra de decisão que minimiza ECM com base nas regras:

a. **Regra 1:** $p_1 = p_2$, $c(1|2) = c(2|1)$;

Devemos classificar $\boldsymbol{y}$ em π_1 se:

$$\frac{f_1(\boldsymbol{y})}{f_2(\boldsymbol{y})} \geq \frac{c(1|2)}{c(2|1)} \times \frac{p_2}{p_1} = 1,$$

e classificar em π_2, caso contrário.

Exemplo 2- Classificação em duas populações com custos desiguais de má-classificação

b. **Regra 2:** $p_1 = p_2$, $c(1|2) = 3 \times c(2|1)$;

Exemplo 2- Classificação em duas populações com custos desiguais de má-classificação

b. **Regra 2:** $p_1 = p_2$, $c(1|2) = 3 \times c(2|1)$;

Devemos classificar $\boldsymbol{y}$ em π_1 se:

$$\frac{f_1(\boldsymbol{y})}{f_2(\boldsymbol{y})} \geq \frac{c(1|2)}{c(2|1)} \times \frac{p_2}{p_1} = 3 \times 1 = 3,$$

e classificar em π_2, caso contrário.

Exemplo 2- Classificação em duas populações com custos desiguais de má-classificação

- **Regra 3:** $p_1 = 0.2$, $p_2 = 0.8$ e $c(1|2) = 3 \times c(2|1)$;

Exemplo 2- Classificação em duas populações com custos desiguais de má-classificação

- **Regra 3:** $p_1 = 0.2$, $p_2 = 0.8$ e $c(1|2) = 3 \times c(2|1)$;

Devemos classificar $\boldsymbol{y}$ em π_1 se:

$$\frac{f_1(\boldsymbol{y})}{f_2(\boldsymbol{y})} \geq \frac{c(1|2)}{c(2|1)} \times \frac{p_2}{p_1} = 3 \times 4 = 12,$$

e classificar em π_2, caso contrário.

Exemplo 2- Classificação em duas populações com custos desiguais de má-classificação

d. Suponha as seguintes distribuições:

$$\pi_1 : \boldsymbol{Y} \sim N\left(\begin{bmatrix}0\\0\end{bmatrix}, \begin{bmatrix}1 & 0.75\\0.75 & 1\end{bmatrix}\right)$$

$$\pi_2 : \boldsymbol{Y} \sim N\left(\begin{bmatrix}1\\1\end{bmatrix}, \begin{bmatrix}1.5 & 0.5\\0.5 & 1.5\end{bmatrix}\right)$$

Exemplo 2- Classificação em duas populações com custos desiguais de má-classificação

Como seriam classificados os seguintes indivíduos segundo cada uma das regras?

Exemplo 2- Classificação em duas populações com custos desiguais de má-classificação

Como seriam classificados os seguintes indivíduos segundo cada uma das regras?

1. $\boldsymbol{y}_0' = (0.2, 0.3)$;

Exemplo 2- Classificação em duas populações com custos desiguais de má-classificação

Como seriam classificados os seguintes indivíduos segundo cada uma das regras?

i. $\boldsymbol{y}_0' = (0.2, 0.3)$;
ii. $\boldsymbol{y}_0' = (0.2, 0.0)$;

Exemplo 2- Classificação em duas populações com custos desiguais de má-classificação

Como seriam classificados os seguintes indivíduos segundo cada uma das regras?

i. $\boldsymbol{y}_0' = (0.2, 0.3)$;
ii. $\boldsymbol{y}_0' = (0.2, 0.0)$;
iii. $\boldsymbol{y}_0' = (1.5, 0.8)$.

Exemplo 2- Classificação em duas populações com custos desiguais de má-classificação

Como seriam classificados os seguintes indivíduos segundo cada uma das regras?

i. $\boldsymbol{y}_0' = (0.2, 0.3)$;
ii. $\boldsymbol{y}_0' = (0.2, 0.0)$;
iii. $\boldsymbol{y}_0' = (1.5, 0.8)$.

A resolução deste exercício será feita usando o R.

Classificação em $k > 2$ populações

Classificação em $k > 2$ populações

- Sejam $f_1(\boldsymbol{y}), f_2(\boldsymbol{y}), ..., f_k(\boldsymbol{y})$ as distribuições do vetor aleatório $\boldsymbol{y}$ em cada uma de k populações, $\pi_1, \pi_2, ...\pi_k$.

Classificação em $k > 2$ populações

- Sejam $f_1(\boldsymbol{y}), f_2(\boldsymbol{y}), ..., f_k(\boldsymbol{y})$ as distribuições do vetor aleatório $\boldsymbol{y}$ em cada uma de k populações, $\pi_1, \pi_2, ...\pi_k$.

- Sejam $p_1, p_2, ..., p_k$ as probabilidades a priori e $c(i|j), i, j = 1, 2, ..., k$, os custos de má-classificação.

Classificação em $k > 2$ populações

- Sejam $f_1(\boldsymbol{y}), f_2(\boldsymbol{y}), ..., f_k(\boldsymbol{y})$ as distribuições do vetor aleatório $\boldsymbol{y}$ em cada uma de k populações, $\pi_1, \pi_2, ...\pi_k$.

- Sejam $p_1, p_2, ..., p_k$ as probabilidades a priori e $c(i|j), i, j = 1, 2, ..., k$, os custos de má-classificação.

- Seja R_i o conjunto dos $\boldsymbol{y's}$ classificados como π_i, $i = 1, 2, ..., k$, e

$$P(j|i) = \int_{R_j} f_i(\boldsymbol{y}) d\boldsymbol{y}, i, j = 1, 2, ..., k.$$

Classificação em $k > 2$ populações

- Custo esperado de má-classificação:

$$\text{ECM} = \text{ECM}(1) + \text{ECM}(2) + ... + \text{ECM}(k),$$

Classificação em $k > 2$ populações

- Custo esperado de má-classificação:

$$\text{ECM} = \text{ECM}(1) + \text{ECM}(2) + ... + \text{ECM}(k),$$

em que

$$\text{ECM}(i) = p_1 P(1|i)c(1|i) + p_2 P(2|i)c(2|i) + ... + p_k P(k|i)c(k|i), i = 1, 2, ..., k$$

Classificação em $k > 2$ populações

- Sejam $f_1(\cdot), f_2(\cdot), ..., f_k(\cdot)$ as funções densidade de probabilidades de $\boldsymbol{y}$ em $\pi_1, \pi_2, ...\pi_k$.

Classificação em $k > 2$ populações

- Sejam $f_1(\cdot), f_2(\cdot), ..., f_k(\cdot)$ as funções densidade de probabilidades de $\boldsymbol{y}$ em $\pi_1, \pi_2, ...\pi_k$.
- A regra de classificação **tal que ECM seja mínimo** consiste em classificar uma observação $\boldsymbol{y}$ no grupo j tal que:

$$\text{ECM}(i) = \sum_{\substack{i=1 \\ i \neq j}}^{k} p_i f_i(\boldsymbol{y}) c(j|i) \text{ seja mínimo.}$$

Classificação em $k > 2$ populações

- Sejam $f_1(\cdot), f_2(\cdot), ..., f_k(\cdot)$ as funções densidade de probabilidades de $\boldsymbol{y}$ em $\pi_1, \pi_2, ...\pi_k$.
- A regra de classificação **tal que ECM seja mínimo** consiste em classificar uma observação $\boldsymbol{y}$ no grupo j tal que:

$$\text{ECM}(i) = \sum_{\substack{i=1 \\ i \neq j}}^{k} p_i f_i(\boldsymbol{y}) c(j|i) \text{ seja mínimo.}$$

- Assim, deve-se classificar $\boldsymbol{y}$ em π_j caso a média dos custos de classificações incorretas nas demais populações seja mínima.

Classificação em $k > 2$ populações

- Sejam $f_1(\cdot), f_2(\cdot), ..., f_k(\cdot)$ as funções densidade de probabilidades de $\boldsymbol{y}$ em $\pi_1, \pi_2, ...\pi_k$.
- A regra de classificação **tal que ECM seja mínimo** consiste em classificar uma observação $\boldsymbol{y}$ no grupo j tal que:

$$\text{ECM}(i) = \sum_{\substack{i=1 \\ i \neq j}}^{k} p_i f_i(\boldsymbol{y}) c(j|i) \text{ seja mínimo.}$$

- Assim, deve-se classificar $\boldsymbol{y}$ em π_j caso a média dos custos de classificações incorretas nas demais populações seja mínima.
- Observe que para $k = 2$ populações, essa regra de classificação fica simplificada, sendo dada pela regra de classificação para duas populações apresentada anteriormente.

Exemplo 3- Classificação em $k > 2$ populações

Exemplo 3- Classificação em $k > 2$ populações

Considerando a seguinte configuração, qual seria a alocação de $\boldsymbol{y}_0$? E se os custos de má-classificação fossem todos iguais?

Tabela 1: Classificação em k populações

		Pop. Verd.		
		π_1	π_2	π_3
Classificado como	π_1	c(1|1)=0	c(1|2)=500	c(1|3)=100
	π_2	c(2|1)=10	c(2|2)=0	c(2|3)=50
	π_3	c(3|1)=50	c(3|2)=200	c(3|3)=0
Prioris		0.05	0.60	0.35
$f(\boldsymbol{y}_0)$		0.01	0.85	2

Exemplo 3- Classificação em $k > 2$ populações

- Vamos calcular ECM para cada possível classificação, inicialmente considerando os custos de má-classificação. Começando pela população 1 (π_1):

$$\text{ECM}(1) = p_2 \times f_2(y_0) \times c(1|2) + p_3 \times f_3(y_0) \times c(1|3) =$$

$$0.6 \times 0.85 \times 500 + 0.35 \times 2 \times 100 = 325$$

Exemplo 3- Classificação em $k > 2$ populações

- Para a população 2 (π_2):

$$\text{ECM}(2) = p_1 \times f_1(y_0) \times c(2|1) + p_3 \times f_3(y_0) \times c(2|3) =$$

$$0.05 \times 0.01 \times 10 + 0.35 \times 2 \times 50 = 35$$

Exemplo 3- Classificação em $k > 2$ populações

- Para a população 3 (π_3):

$$\text{ECM}(3) = p_1 \times f_1(y_0) \times c(3|1) + p_2 \times f_2(y_0) \times c(3|2) =$$

$$0.05 \times 0.01 \times 50 + 0.60 \times 0.85 \times 200 = 102$$

Exemplo 3- Classificação em $k > 2$ populações

- Para a população 3 (π_3):

$$\text{ECM}(3) = p_1 \times f_1(y_0) \times c(3|1) + p_2 \times f_2(y_0) \times c(3|2) =$$

$$0.05 \times 0.01 \times 50 + 0.60 \times 0.85 \times 200 = 102$$

- Neste caso, como ECM(2) é menor que ECM(1) e ECM(3), então $\boldsymbol{y}_0$ deve ser classificada em π_2.

Exemplo 3- Classificação em $k > 2$ populações

- Agora, considerando custos iguais de má-classificação. Começando pela população 1 (π_1):

Exemplo 3- Classificação em $k > 2$ populações

- Agora, considerando custos iguais de má-classificação. Começando pela população 1 (π_1):

$$\text{ECM}(1) = p_2 \times f_2(y_0) + p_3 \times f_3(y_0) =$$

$$0.6 \times 0.85 + 0.35 \times 2 = 1.21$$

Exemplo 3- Classificação em $k > 2$ populações

- Para a população 2 (π_2):

Exemplo 3- Classificação em $k > 2$ populações

- Para a população 2 (π_2):

$$\text{ECM}(2) = p_1 \times f_1(y_0) + p_3 \times f_3(y_0) =$$

$$0.05 \times 0.01 + 0.35 \times 2 = 0.70$$

Exemplo 3- Classificação em $k > 2$ populações

- Para a população 3 (π_3):

Exemplo 3- Classificação em $k > 2$ populações

- Para a população 3 (π_3):

$$\text{ECM}(3) = p_1 \times f_1(y_0) + p_2 \times f_2(y_0) =$$

$$0.05 \times 0.01 + 0.60 \times 0.85 = 0.51$$

Exemplo 3- Classificação em $k > 2$ populações

- Para a população 3 (π_3):

$$\text{ECM}(3) = p_1 \times f_1(y_0) + p_2 \times f_2(y_0) =$$

$$0.05 \times 0.01 + 0.60 \times 0.85 = 0.51$$

- Neste caso, como ECM(3) é menor que ECM(1) e ECM(2), então $\boldsymbol{y}_0$ deve ser classificada em π_3.

Análise discriminante linear (caso de duas populações)

Análise discriminante linear (caso de duas populações)

- Seja o vetor aleatório $\boldsymbol{y'} = (y_1, y_2, ..., y_p)$ com as seguintes propriedades:

Análise discriminante linear (caso de duas populações)

- Seja o vetor aleatório $\boldsymbol{y'} = (y_1, y_2, ..., y_p)$ com as seguintes propriedades:
  - População (ou grupo) 1 (π_1): $\mathrm{E}(\boldsymbol{y}) = \boldsymbol{\mu_1}$ e $\mathrm{Cov}(\boldsymbol{y}) = \Sigma$;

Análise discriminante linear (caso de duas populações)

- Seja o vetor aleatório $\boldsymbol{y'} = (y_1, y_2, ..., y_p)$ com as seguintes propriedades:
  - População (ou grupo) 1 (π_1): $\mathrm{E}(\boldsymbol{y}) = \boldsymbol{\mu_1}$ e $\mathrm{Cov}(\boldsymbol{y}) = \Sigma$;
  - População (ou grupo) 2 (π_2): $\mathrm{E}(\boldsymbol{y}) = \boldsymbol{\mu_2}$ e $\mathrm{Cov}(\boldsymbol{y}) = \Sigma$.

Análise discriminante linear (caso de duas populações)

- Seja o vetor aleatório $\boldsymbol{y'} = (y_1, y_2, ..., y_p)$ com as seguintes propriedades:
  - População (ou grupo) 1 (π_1): $\mathrm{E}(\boldsymbol{y}) = \boldsymbol{\mu_1}$ e $\mathrm{Cov}(\boldsymbol{y}) = \Sigma$;
  - População (ou grupo) 2 (π_2): $\mathrm{E}(\boldsymbol{y}) = \boldsymbol{\mu_2}$ e $\mathrm{Cov}(\boldsymbol{y}) = \Sigma$.

- O objetivo é determinar uma combinação linear (**vetor, função ou direção discriminante**)

$$Z = \boldsymbol{a'y} = a_1y_1 + a_2y_2 + ... + a_py_p$$

que separe os indivíduos de π_1 e π_2 da maneira mais eficiente possível.

Análise discriminante linear (caso de duas populações)

- Seja o vetor aleatório $\boldsymbol{y'} = (y_1, y_2, ..., y_p)$ com as seguintes propriedades:
  - População (ou grupo) 1 (π_1): $\mathrm{E}(\boldsymbol{y}) = \boldsymbol{\mu_1}$ e $\mathrm{Cov}(\boldsymbol{y}) = \Sigma$;
  - População (ou grupo) 2 (π_2): $\mathrm{E}(\boldsymbol{y}) = \boldsymbol{\mu_2}$ e $\mathrm{Cov}(\boldsymbol{y}) = \Sigma$.

- O objetivo é determinar uma combinação linear (**vetor, função ou direção discriminante**)

$$Z = \boldsymbol{a'y} = a_1y_1 + a_2y_2 + ... + a_py_p$$

que separe os indivíduos de π_1 e π_2 da maneira mais eficiente possível.

- Identificada a função discriminante, define-se um ponto de corte (*threshold* ou **fronteira**) ótimo que melhor separe as projeções das observações das duas populações.

Análise discriminante linear (caso de duas populações)

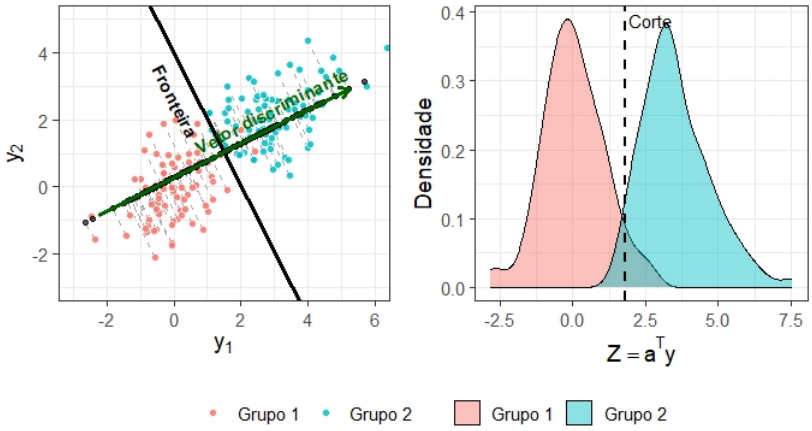


Figura 3: Representação da função discriminante linear e projeção discriminante resultante

Análise discriminante linear (caso de duas populações)

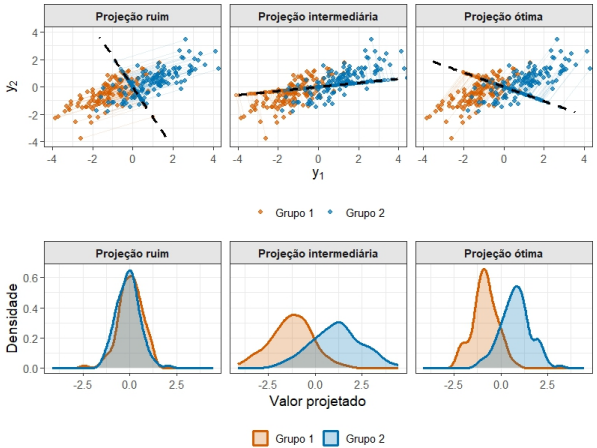


Figura 4: Diferentes projeções lineares num problema de análise discriminante

Análise discriminante linear (caso de duas populações)

- Como medida de separação de π_1 e π_2 produzida por $z = \boldsymbol{a}'\boldsymbol{y}$, consideramos:

$$\frac{(\mu_{1Z} - \mu_{2Z})^2}{\sigma_z^2} = \frac{(\boldsymbol{a}'\boldsymbol{\mu_1} - \boldsymbol{a}'\boldsymbol{\mu_2})^2}{\boldsymbol{a}'\boldsymbol{\Sigma}\boldsymbol{a}} =$$

$$\frac{\boldsymbol{a}'(\boldsymbol{\mu_1} - \boldsymbol{\mu_2})(\boldsymbol{\mu_1} - \boldsymbol{\mu_2})'\boldsymbol{a}}{\boldsymbol{a}'\boldsymbol{\Sigma}\boldsymbol{a}} = \frac{(\boldsymbol{a}'\boldsymbol{\delta})^2}{\boldsymbol{a}'\boldsymbol{\Sigma}\boldsymbol{a}},$$

em que $\boldsymbol{\delta} = \boldsymbol{\mu_1} - \boldsymbol{\mu_2}$.

Análise discriminante linear (caso de duas populações)

- Como medida de separação de π_1 e π_2 produzida por $z = \boldsymbol{a}'\boldsymbol{y}$, consideramos:

$$\frac{(\mu_{1Z} - \mu_{2Z})^2}{\sigma_z^2} = \frac{(\boldsymbol{a}'\boldsymbol{\mu_1} - \boldsymbol{a}'\boldsymbol{\mu_2})^2}{\boldsymbol{a}'\boldsymbol{\Sigma}\boldsymbol{a}} =$$

$$\frac{\boldsymbol{a}'(\boldsymbol{\mu_1} - \boldsymbol{\mu_2})(\boldsymbol{\mu_1} - \boldsymbol{\mu_2})'\boldsymbol{a}}{\boldsymbol{a}'\boldsymbol{\Sigma}\boldsymbol{a}} = \frac{(\boldsymbol{a}'\boldsymbol{\delta})^2}{\boldsymbol{a}'\boldsymbol{\Sigma}\boldsymbol{a}},$$

em que $\boldsymbol{\delta} = \boldsymbol{\mu_1} - \boldsymbol{\mu_2}$.

- Na medida de separação apresentada o numerador mede a **distância entre as médias projetadas** e o denominador mede a **variação dentro dos grupos**.

Análise discriminante linear (caso de duas populações)

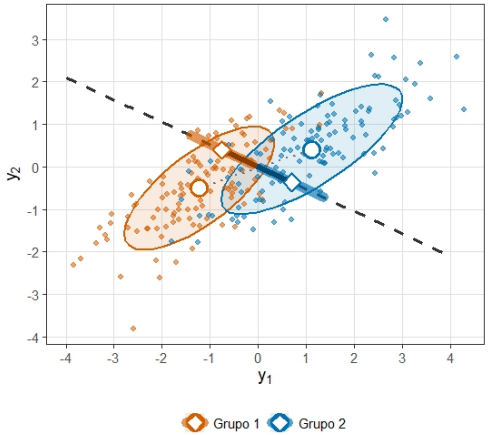


Figura 5: Análise discriminante linear (variação dentro dos grupos e distância das médias projetadas)

Análise discriminante linear (caso de duas populações)

- Com base na desigualdade de Cauchy-Schwarz, demonstra-se que a combinação linear responsável por maximizar a medida de separação apresentada é dada por:

$$\boldsymbol{z} = \boldsymbol{a}'\boldsymbol{y} = (\boldsymbol{\mu_1} - \boldsymbol{\mu_2})'\Sigma^{-1}\boldsymbol{y}$$

Análise discriminante linear (caso de duas populações)

- Com base na desigualdade de Cauchy-Schwarz, demonstra-se que a combinação linear responsável por maximizar a medida de separação apresentada é dada por:

$$\boldsymbol{z} = \boldsymbol{a}'\boldsymbol{y} = (\boldsymbol{\mu_1} - \boldsymbol{\mu_2})'\Sigma^{-1}\boldsymbol{y}$$

Análise discriminante linear (caso de duas populações)

- Com base na desigualdade de Cauchy-Schwarz, demonstra-se que a combinação linear responsável por maximizar a medida de separação apresentada é dada por:

$$z = a'y = (\mu_1 - \mu_2)'\Sigma^{-1}y$$

- Na função discriminante, Σ^{-1} penaliza direções de alta variabilidade, produzindo um novo espaço para as variáveis.

Análise discriminante linear (caso de duas populações)

- Com base na desigualdade de Cauchy-Schwarz, demonstra-se que a combinação linear responsável por maximizar a medida de separação apresentada é dada por:

$$z = a'y = (\mu_1 - \mu_2)'\Sigma^{-1}y$$

- Na função discriminante, Σ^{-1} penaliza direções de alta variabilidade, produzindo um novo espaço para as variáveis.

- Nesse espaço, os dados são reescalonados e decorrelacionados, de forma que a melhor direção discriminante passa a ser a reta entre médias dos dois grupos.

Análise discriminante linear (caso de duas populações)

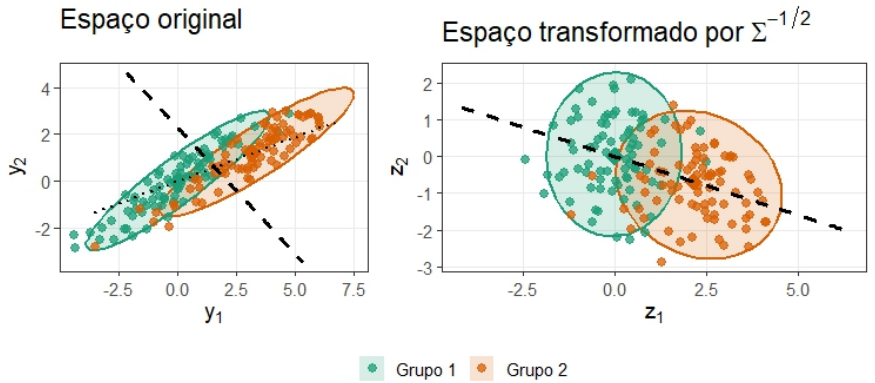


Figura 6: Separação entre grupos antes e após a transformação por Σ^{-1}

Análise discriminante linear (caso de duas populações)

- Seja m o ponto médio entre as médias de Z para as populações π_1 e π_2:

$$m = \frac{1}{2}(\mu_{1Z} + \mu_{2Z}) = \frac{1}{2}(\boldsymbol{\mu_1} - \boldsymbol{\mu_2})'\Sigma^{-1}(\boldsymbol{\mu_1} + \boldsymbol{\mu_2})$$

Análise discriminante linear (caso de duas populações)

- A regra de classificação para uma observação $\boldsymbol{y}_0$ baseada na função discriminante linear de Fisher é dada por:

Análise discriminante linear (caso de duas populações)

- A regra de classificação para uma observação $\boldsymbol{y}_0$ baseada na função discriminante linear de Fisher é dada por:
  - Classificar $\boldsymbol{y}_0$ em π_1 se $(\boldsymbol{\mu_1} - \boldsymbol{\mu_2})'\Sigma^{-1}\boldsymbol{y}_0 \geq m$ (ou, de maneira equivalente, se $z_0 - m \geq 0$);

Análise discriminante linear (caso de duas populações)

- A regra de classificação para uma observação $\boldsymbol{y}_0$ baseada na função discriminante linear de Fisher é dada por:
  - Classificar $\boldsymbol{y}_0$ em π_1 se $(\boldsymbol{\mu_1} - \boldsymbol{\mu_2})'\Sigma^{-1}\boldsymbol{y}_0 \geq m$ (ou, de maneira equivalente, se $z_0 - m \geq 0$);
  - Classificar $\boldsymbol{y}_0$ em π_2 se $(\boldsymbol{\mu_1} - \boldsymbol{\mu_2})'\Sigma^{-1}\boldsymbol{y}_0 < m$ (ou, de maneira equivalente, se $z_0 - m < 0$).

Análise discriminante linear (caso de duas populações)

- A regra de classificação para uma observação $\boldsymbol{y}_0$ baseada na função discriminante linear de Fisher é dada por:
  - Classificar $\boldsymbol{y}_0$ em π_1 se $(\boldsymbol{\mu_1} - \boldsymbol{\mu_2})'\Sigma^{-1}\boldsymbol{y}_0 \geq m$ (ou, de maneira equivalente, se $z_0 - m \geq 0$);
  - Classificar $\boldsymbol{y}_0$ em π_2 se $(\boldsymbol{\mu_1} - \boldsymbol{\mu_2})'\Sigma^{-1}\boldsymbol{y}_0 < m$ (ou, de maneira equivalente, se $z_0 - m < 0$).

- No contexto de análise discriminante, o ponto médio (m) é a fronteira, delimitando a classificação das observações.

Análise discriminante linear (caso de duas populações)

- A regra de classificação para uma observação $\boldsymbol{y}_0$ baseada na função discriminante linear de Fisher é dada por:
  - Classificar $\boldsymbol{y}_0$ em π_1 se $(\boldsymbol{\mu_1} - \boldsymbol{\mu_2})'\Sigma^{-1}\boldsymbol{y}_0 \geq m$ (ou, de maneira equivalente, se $z_0 - m \geq 0$);
  - Classificar $\boldsymbol{y}_0$ em π_2 se $(\boldsymbol{\mu_1} - \boldsymbol{\mu_2})'\Sigma^{-1}\boldsymbol{y}_0 < m$ (ou, de maneira equivalente, se $z_0 - m < 0$).

- No contexto de análise discriminante, o ponto médio (m) é a fronteira, delimitando a classificação das observações.

- **Nota** - A análise discriminante linear de Fisher requer a **igualdade das matrizes de covariâncias** de π_1 e π_2 (normalidade multivariada não é requerida).

Análise discriminante linear (caso de duas populações)

- Na prática, $\boldsymbol{\mu_1}$, $\boldsymbol{\mu_2}$ e Σ são desconhecidos, e devem ser estimados por:

Análise discriminante linear (caso de duas populações)

- Na prática, $\boldsymbol{\mu_1}$, $\boldsymbol{\mu_2}$ e Σ são desconhecidos, e devem ser estimados por:

$$\bar{\boldsymbol{y}}_1 = \frac{1}{n_1}\sum_{j=1}^{n_1} \boldsymbol{y}_{1j} \quad S_1 = \frac{1}{n_1 - 1}\sum_{j=1}^{n_1} (\boldsymbol{y}_{1j} - \bar{\boldsymbol{y}}_1)(\boldsymbol{y}_{1j} - \bar{\boldsymbol{y}}_1)'$$

Análise discriminante linear (caso de duas populações)

- Na prática, $\boldsymbol{\mu_1}$, $\boldsymbol{\mu_2}$ e Σ são desconhecidos, e devem ser estimados por:

$$\bar{\boldsymbol{y}}_1 = \frac{1}{n_1}\sum_{j=1}^{n_1} \boldsymbol{y}_{1j} \quad S_1 = \frac{1}{n_1 - 1}\sum_{j=1}^{n_1} (\boldsymbol{y}_{1j} - \bar{\boldsymbol{y}}_1)(\boldsymbol{y}_{1j} - \bar{\boldsymbol{y}}_1)'$$

$$\bar{\boldsymbol{y}}_2 = \frac{1}{n_2}\sum_{j=1}^{n_2} \boldsymbol{y}_{2j} \quad S_2 = \frac{1}{n_2 - 1}\sum_{j=1}^{n_2} (\boldsymbol{y}_{2j} - \bar{\boldsymbol{y}}_2)(\boldsymbol{y}_{2j} - \bar{\boldsymbol{y}}_2)'$$

Análise discriminante linear (caso de duas populações)

- Na prática, $\boldsymbol{\mu_1}$, $\boldsymbol{\mu_2}$ e Σ são desconhecidos, e devem ser estimados por:

$$\bar{\boldsymbol{y}}_1 = \frac{1}{n_1}\sum_{j=1}^{n_1} \boldsymbol{y}_{1j} \quad S_1 = \frac{1}{n_1 - 1}\sum_{j=1}^{n_1} (\boldsymbol{y}_{1j} - \bar{\boldsymbol{y}}_1)(\boldsymbol{y}_{1j} - \bar{\boldsymbol{y}}_1)'$$

$$\bar{\boldsymbol{y}}_2 = \frac{1}{n_2}\sum_{j=1}^{n_2} \boldsymbol{y}_{2j} \quad S_2 = \frac{1}{n_2 - 1}\sum_{j=1}^{n_2} (\boldsymbol{y}_{2j} - \bar{\boldsymbol{y}}_2)(\boldsymbol{y}_{2j} - \bar{\boldsymbol{y}}_2)'$$

$$\hat{\Sigma} = S_P = \frac{(n_1 - 1)S_1 + (n_2 - 1)S_2}{n_1 + n_2 - 2}$$

Análise discriminante linear (caso de duas populações)

- Assim função linear discriminante amostral fica dada por:

$$z = (\bar{\boldsymbol{y}}_{\mathbf{1}} - \bar{\boldsymbol{y}}_{\mathbf{2}}) S_P^{-1} \boldsymbol{y}$$

Análise discriminante linear (caso de duas populações)

- Assim função linear discriminante amostral fica dada por:

$$z = (\bar{\boldsymbol{y}}_{\mathbf{1}} - \bar{\boldsymbol{y}}_{\mathbf{2}})S_P^{-1}\boldsymbol{y}$$

- O ponto médio entre as duas médias amostrais é dado por:

$$\hat{m} = \frac{1}{2}(\bar{z}_1 + \bar{z}_2) = \frac{1}{2}(\bar{\boldsymbol{y}}_{\mathbf{1}} - \bar{\boldsymbol{y}}_{\mathbf{2}})' S_P^{-1}(\bar{\boldsymbol{y}}_{\mathbf{1}} + \bar{\boldsymbol{y}}_{\mathbf{2}})$$

Análise discriminante linear (caso de duas populações)

- Assim função linear discriminante amostral fica dada por:

$$z = (\bar{\boldsymbol{y}}_{\mathbf{1}} - \bar{\boldsymbol{y}}_{\mathbf{2}}) S_P^{-1} \boldsymbol{y}$$

- O ponto médio entre as duas médias amostrais é dado por:

$$\hat{m} = \frac{1}{2}(\bar{z}_1 + \bar{z}_2) = \frac{1}{2}(\bar{\boldsymbol{y}}_{\mathbf{1}} - \bar{\boldsymbol{y}}_{\mathbf{2}})' S_P^{-1} (\bar{\boldsymbol{y}}_{\mathbf{1}} + \bar{\boldsymbol{y}}_{\mathbf{2}})$$

- Finalmente, a regra de classificação baseada na função discriminante linear amostral é dada por:

Análise discriminante linear (caso de duas populações)

- Assim função linear discriminante amostral fica dada por:

$$z = (\bar{\boldsymbol{y}}_{\mathbf{1}} - \bar{\boldsymbol{y}}_{\mathbf{2}}) S_P^{-1} \boldsymbol{y}$$

- O ponto médio entre as duas médias amostrais é dado por:

$$\hat{m} = \frac{1}{2}(\bar{z}_1 + \bar{z}_2) = \frac{1}{2}(\bar{\boldsymbol{y}}_{\mathbf{1}} - \bar{\boldsymbol{y}}_{\mathbf{2}})' S_P^{-1} (\bar{\boldsymbol{y}}_{\mathbf{1}} + \bar{\boldsymbol{y}}_{\mathbf{2}})$$

- Finalmente, a regra de classificação baseada na função discriminante linear amostral é dada por:
  - Classificar $\boldsymbol{y}_0$ em π_1 se $(\bar{\boldsymbol{y}}_{\mathbf{1}} - \bar{\boldsymbol{y}}_{\mathbf{2}})' S_P^{-1} \boldsymbol{y}_0 \geq m$ (ou, de maneira equivalente, se $z_0 - m \geq 0$);

Análise discriminante linear (caso de duas populações)

- Assim função linear discriminante amostral fica dada por:

$$z = (\bar{\boldsymbol{y}}_{\mathbf{1}} - \bar{\boldsymbol{y}}_{\mathbf{2}}) S_P^{-1} \boldsymbol{y}$$

- O ponto médio entre as duas médias amostrais é dado por:

$$\hat{m} = \frac{1}{2}(\bar{z}_1 + \bar{z}_2) = \frac{1}{2}(\bar{\boldsymbol{y}}_{\mathbf{1}} - \bar{\boldsymbol{y}}_{\mathbf{2}})' S_P^{-1} (\bar{\boldsymbol{y}}_{\mathbf{1}} + \bar{\boldsymbol{y}}_{\mathbf{2}})$$

- Finalmente, a regra de classificação baseada na função discriminante linear amostral é dada por:
  - Classificar $\boldsymbol{y}_0$ em π_1 se $(\bar{\boldsymbol{y}}_{\mathbf{1}} - \bar{\boldsymbol{y}}_{\mathbf{2}})' S_P^{-1} \boldsymbol{y}_0 \geq m$ (ou, de maneira equivalente, se $z_0 - m \geq 0$);
  - Classificar $\boldsymbol{y}_0$ em π_2 se $(\bar{\boldsymbol{y}}_{\mathbf{1}} - \bar{\boldsymbol{y}}_{\mathbf{2}})' S_P^{-1} \boldsymbol{y}_0 < m$ (ou, de maneira equivalente, se $z_0 - m < 0$).

Análise discriminante linear (caso de duas populações)

- Assim como no caso do classificador de Bayes probabilidades a priori e custos de má-classificação podem ser incorporados.

Análise discriminante linear (caso de duas populações)

- Assim como no caso do classificador de Bayes probabilidades a priori e custos de má-classificação podem ser incorporados.

- Sejam p_1 e p_2 as probabilidades a priori de π_1 e π_2, e $c(1|2)$ e $c(2|1)$ os custos de má-classificação.

Análise discriminante linear (caso de duas populações)

- Assim como no caso do classificador de Bayes probabilidades a priori e custos de má-classificação podem ser incorporados.

- Sejam p_1 e p_2 as probabilidades a priori de π_1 e π_2, e $c(1|2)$ e $c(2|1)$ os custos de má-classificação.

Análise discriminante linear (caso de duas populações)

- Seja $\boldsymbol{y}_0$ um novo indivíduo. Assumindo que $\boldsymbol{y} \sim \mathrm{N}_p(\boldsymbol{\mu}_1, \Sigma)$ em π_1 e $\boldsymbol{y} \sim \mathrm{N}_p(\boldsymbol{\mu}_2, \Sigma)$ em π_2, a regra de classificação com menor custo esperado fica dada por:

Análise discriminante linear (caso de duas populações)

- Seja $\boldsymbol{y}_0$ um novo indivíduo. Assumindo que $\boldsymbol{y} \sim \mathrm{N}_p(\boldsymbol{\mu}_1, \Sigma)$ em π_1 e $\boldsymbol{y} \sim \mathrm{N}_p(\boldsymbol{\mu}_2, \Sigma)$ em π_2, a regra de classificação com menor custo esperado fica dada por:

1. Classificar $\boldsymbol{y}_0$ em π_1 se:

$$(\bar{\boldsymbol{y}}_1 - \bar{\boldsymbol{y}}_2) S_P^{-1} \boldsymbol{y}_0 - \frac{1}{2}(\bar{\boldsymbol{y}}_1 - \bar{\boldsymbol{y}}_2)' S_P^{-1} (\bar{\boldsymbol{y}}_1 + \bar{\boldsymbol{y}}_2) \geq \ln \left[\left(\frac{c(1|2)}{c(2|1)} \right) \left(\frac{p_2}{p_1} \right) \right]$$

Análise discriminante linear (caso de duas populações)

- Seja $\boldsymbol{y}_0$ um novo indivíduo. Assumindo que $\boldsymbol{y} \sim \mathrm{N}_p(\boldsymbol{\mu}_1, \Sigma)$ em π_1 e $\boldsymbol{y} \sim \mathrm{N}_p(\boldsymbol{\mu}_2, \Sigma)$ em π_2, a regra de classificação com menor custo esperado fica dada por:

1. Classificar $\boldsymbol{y}_0$ em π_1 se:

$$(\bar{\boldsymbol{y}}_1 - \bar{\boldsymbol{y}}_2) S_P^{-1} \boldsymbol{y}_0 - \frac{1}{2}(\bar{\boldsymbol{y}}_1 - \bar{\boldsymbol{y}}_2)' S_P^{-1} (\bar{\boldsymbol{y}}_1 + \bar{\boldsymbol{y}}_2) \geq \ln \left[\left(\frac{c(1|2)}{c(2|1)} \right) \left(\frac{p_2}{p_1} \right) \right]$$

2. Classificar $\boldsymbol{y}_0$ em π_2 se:

$$(\bar{\boldsymbol{y}}_1 - \bar{\boldsymbol{y}}_2) S_P^{-1} \boldsymbol{y}_0 - \frac{1}{2}(\bar{\boldsymbol{y}}_1 - \bar{\boldsymbol{y}}_2)' S_P^{-1} (\bar{\boldsymbol{y}}_1 + \bar{\boldsymbol{y}}_2) < \ln \left[\left(\frac{c(1|2)}{c(2|1)} \right) \left(\frac{p_2}{p_1} \right) \right]$$

Análise discriminante linear (caso de duas populações)

Notas:

1. O vetor de coeficientes discriminantes é único a menos de uma constante multiplicativa $c \neq 0$, ou seja, qualquer vetor do tipo $c \times \boldsymbol{a}$ configura uma solução (função discriminante) equivalente.

Análise discriminante linear (caso de duas populações)

Notas:

1. O vetor de coeficientes discriminantes é único a menos de uma constante multiplicativa $c \neq 0$, ou seja, qualquer vetor do tipo $c \times \boldsymbol{a}$ configura uma solução (função discriminante) equivalente.

2. A direção discriminante é paralela à reta que une os centróides (no caso esférico, se $\Sigma = \sigma^2 I$). A fronteira de decisão é perpendicular à direção discriminante.

Análise discriminante linear (caso de duas populações)

Notas:

1. O vetor de coeficientes discriminantes é único a menos de uma constante multiplicativa $c \neq 0$, ou seja, qualquer vetor do tipo $c \times \boldsymbol{a}$ configura uma solução (função discriminante) equivalente.

2. A direção discriminante é paralela à reta que une os centróides (no caso esférico, se $\Sigma = \sigma^2 I$). A fronteira de decisão é perpendicular à direção discriminante.

3. O classificador linear de Fisher é equivalente ao classificador de Bayes assumindo probabilidades a priori iguais para as duas populações.

Análise discriminante linear (caso de duas populações)

- Assumindo distribuição normal multivariada para o vetor $\boldsymbol{y}$, temos condições de calcular a probabilidade a posteriori de uma nova observação ($\boldsymbol{y}_0$) pertencer a cada uma das populações.

Análise discriminante linear (caso de duas populações)

- Assumindo distribuição normal multivariada para o vetor $\boldsymbol{y}$, temos condições de calcular a probabilidade a posteriori de uma nova observação ($\boldsymbol{y}_0$) pertencer a cada uma das populações.

- Neste caso, a probabilidade a posteriori de $\boldsymbol{y}_0$ pertencer a π_1 é:

$$P(\pi_1|\boldsymbol{y}_0) = \frac{p_1 \times f_{\pi_1}(\boldsymbol{y}_0)}{p_1 \times f_{\pi_1}(\boldsymbol{y}_0) + p_2 \times f_{\pi_2}(\boldsymbol{y}_0)},$$

em que p_1 e p_2 são as probabilidades a priori de π_1 e π_2, e $f_{\pi_1}(\cdot)$ e $f_{\pi_2}(\cdot)$ são as densidades normal multivariada em π_1 e π_2.

Análise discriminante linear (caso de duas populações)

- De maneira semelhante, a probabilidade a posteriori de $\boldsymbol{y}_0$ pertencer a π_2 é:

$$P(\pi_2|\boldsymbol{y}_0) = \frac{p_2 \times f_{\pi_2}(\boldsymbol{y}_0)}{p_1 \times f_{\pi_1}(\boldsymbol{y}_0) + p_2 \times f_{\pi_2}(\boldsymbol{y}_0)},$$

Análise discriminante linear (caso de duas populações)

- De maneira semelhante, a probabilidade a posteriori de $\boldsymbol{y}_0$ pertencer a π_2 é:

$$P(\pi_2|\boldsymbol{y}_0) = \frac{p_2 \times f_{\pi_2}(\boldsymbol{y}_0)}{p_1 \times f_{\pi_1}(\boldsymbol{y}_0) + p_2 \times f_{\pi_2}(\boldsymbol{y}_0)},$$

- Na prática, classificamos $\boldsymbol{y}_0$ na população em que a probabilidade a posteriori é máxima.

Exemplo 4- Indicadores econômico-financeiros de bancos

Exemplo 4- Indicadores econômico-financeiros de bancos

- Nesta aplicação vamos considerar dados referentes a indicadores econômico-financeiros de instituições financeiras usados para detectar possíveis problemas de liquidez.

Exemplo 4- Indicadores econômico-financeiros de bancos

- Nesta aplicação vamos considerar dados referentes a indicadores econômico-financeiros de instituições financeiras usados para detectar possíveis problemas de liquidez.

- O objetivo é utilizar esses indicadores para classificar as instituições em dois grupos: **com problemas de liquidez** ou **sem problemas de liquidez**.

Exemplo 4- Indicadores econômico-financeiros de bancos

- Nesta aplicação vamos considerar dados referentes a indicadores econômico-financeiros de instituições financeiras usados para detectar possíveis problemas de liquidez.

- O objetivo é utilizar esses indicadores para classificar as instituições em dois grupos: **com problemas de liquidez** ou **sem problemas de liquidez**.

- Para fins de ilustração, das variáveis relacionadas apenas duas (`y1` e `y2`) seráo usadas nesta aplicação.

Exemplo 4- Indicadores econômico-financeiros de bancos

- Nesta aplicação vamos considerar dados referentes a indicadores econômico-financeiros de instituições financeiras usados para detectar possíveis problemas de liquidez.

- O objetivo é utilizar esses indicadores para classificar as instituições em dois grupos: **com problemas de liquidez** ou **sem problemas de liquidez**.

- Para fins de ilustração, das variáveis relacionadas apenas duas (`y1` e `y2`) seráo usadas nesta aplicação.

- A análise completa, contemplando todas as variáveis, será discutida na aula prática com os códigos `R` disponibilizados na página da disciplina.

Exemplo 4- Indicadores econômico-financeiros de bancos

- A lista completa de variáveis é a seguinte:

Exemplo 4- Indicadores econômico-financeiros de bancos

- A lista completa de variáveis é a seguinte:
  - y1: liquidez imediata;

Exemplo 4- Indicadores econômico-financeiros de bancos

- A lista completa de variáveis é a seguinte:
  - y1: liquidez imediata;
  - y2: participação dos depósitos interfinanceiros no total operacional;

Exemplo 4- Indicadores econômico-financeiros de bancos

- A lista completa de variáveis é a seguinte:
  - y1: liquidez imediata;
  - y2: participação dos depósitos interfinanceiros no total operacional;
  - y3: participação das exigibilidades no ativo operacional;

Exemplo 4- Indicadores econômico-financeiros de bancos

- A lista completa de variáveis é a seguinte:
  - y1: liquidez imediata;
  - y2: participação dos depósitos interfinanceiros no total operacional;
  - y3: participação das exigibilidades no ativo operacional;
  - y4: participação das rendas de prestação de serviços em relação às despesas administrativas;

Exemplo 4- Indicadores econômico-financeiros de bancos

- A lista completa de variáveis é a seguinte:
  - `y1`: liquidez imediata;
  - `y2`: participação dos depósitos interfinanceiros no total operacional;
  - `y3`: participação das exigibilidades no ativo operacional;
  - `y4`: participação das rendas de prestação de serviços em relação às despesas administrativas;
  - `Condição`: banco com problemas ou banco sem problemas.

Exemplo 4- Indicadores econômico-financeiros de bancos

Tabela 2: Indicadores econômico-financeiros dos bancos

Banco	Condição	y1	y2	y3	y4
Banco Real	Sem problemas	0.8888	0.7391	1.0255	0.3938
Banco Garantia	Sem problemas	1.6655	0.7268	0.8780	0.0004
Citibank	Sem problemas	2.2111	0.9166	0.9492	0.3420
Chase Manhattan	Sem problemas	1.4351	0.9133	0.9577	0.2325
Unibanco	Sem problemas	2.1414	0.0020	1.0245	0.3966
Santander Noroeste	Sem problemas	1.1920	0.4972	1.0340	0.3095
Banco Itaú	Sem problemas	1.5895	0.2593	1.0453	0.5570
Francês e Brasileiro	Sem problemas	1.3272	0.4126	1.0448	0.3482
Banco Sogeral	Sem problemas	1.8847	0.3880	0.9864	0.0337
Banco Itamarati	Sem problemas	0.5229	0.9473	1.1244	0.1180
Banco Banorte	Com problemas	0.4922	0.3166	1.1127	0.1628
Banco Est. Alagoas	Com problemas	1.4427	0.0589	0.9019	0.1355
Banco Econômico	Com problemas	0.5438	0.5358	1.0300	0.1481
Banco Nacional	Com problemas	0.1904	0.7087	0.9917	0.2625
Banco Progresso	Com problemas	0.1102	0.7378	1.5280	0.0783
Banerj	Com problemas	2.0060	0.0414	1.0321	0.0816
Banco Rosa	Com problemas	0.2321	0.9234	0.9753	0.0045
Banco Open	Com problemas	0.9019	0.1634	1.1414	0.5485
Banespa	Com problemas	1.9757	0.3395	0.9997	0.0751
Banco Bamerindus	Com problemas	0.7276	0.3139	1.1077	0.2957

Exemplo 4- Indicadores econômico-financeiros de bancos

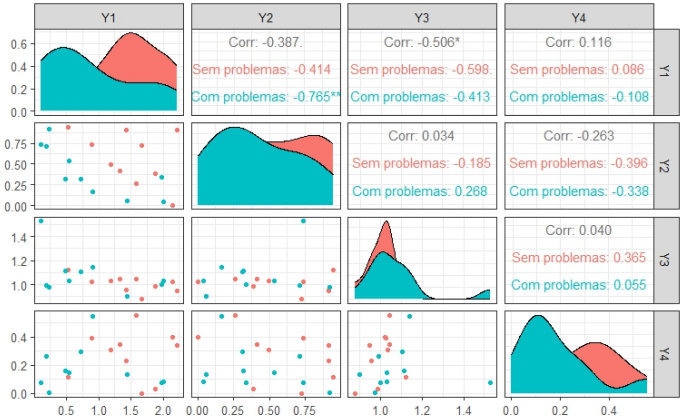


Figura 7: Indicadores econômico-financeiros de instituições bancárias

Exemplo 4- Indicadores econômico-financeiros de bancos

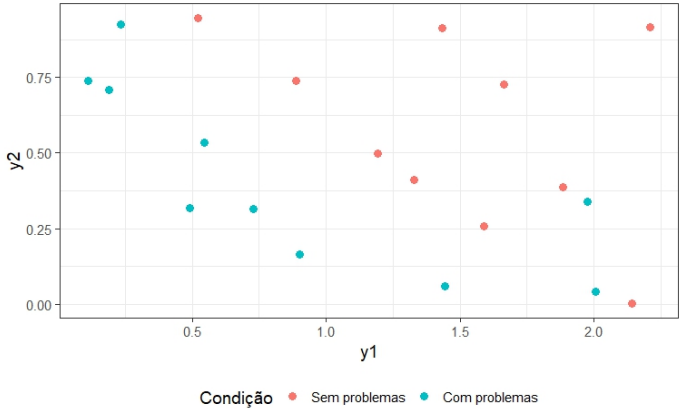


Figura 8: Indicadores econômico-financeiros de instituições bancárias (para y1 e y2)

Exemplo 4- Indicadores econômico-financeiros de bancos

- Os vetores de médias amostrais, as matrizes de covariâncias e a matriz de covariâncias ponderada são dados por:

$$\bar{\boldsymbol{y}}_{\text{SP}} = \begin{bmatrix} 1.486 \\ 0.580 \end{bmatrix} \qquad S_{\text{SP}} = \begin{bmatrix} 0.284 & -0.070 \\ -0.070 & 0.102 \end{bmatrix}$$

$$\bar{\boldsymbol{y}}_{\text{CP}} = \begin{bmatrix} 0.862 \\ 0.414 \end{bmatrix} \qquad S_{\text{CP}} = \begin{bmatrix} 0.506 & -0.164 \\ -0.164 & 0.091 \end{bmatrix}$$

$$S_p = \begin{bmatrix} 0.395 & -0.117 \\ -0.117 & 0.096 \end{bmatrix}$$

Exemplo 4- Indicadores econômico-financeiros de bancos

- Na sequência são calculados os componentes para a obtenção da função discriminante linear:

$$\bar{\boldsymbol{y}}_{\text{SP}} - \bar{\boldsymbol{y}}_{\text{CP}} = \begin{bmatrix} 0.624 \\ 0.166 \end{bmatrix} \qquad \bar{\boldsymbol{y}}_{\text{SP}} + \bar{\boldsymbol{y}}_{\text{CP}} = \begin{bmatrix} 2.348 \\ 0.994 \end{bmatrix}$$

$$S_p^{-1} = \begin{bmatrix} 3.9619 & 4.8285 \\ 4.8285 & 16.3014 \end{bmatrix}$$

Exemplo 4- Indicadores econômico-financeiros de bancos

- A função discriminante linear fica dada por:

$$z = (\bar{\boldsymbol{y}}_{\text{SP}} - \bar{\boldsymbol{y}}_{\text{CP}})S_P^{-1}\boldsymbol{y} = \begin{bmatrix} 0.624 \\ 0.166 \end{bmatrix}' \times \begin{bmatrix} 3.9619 & 4.8285 \\ 4.8285 & 16.3014 \end{bmatrix} \times \begin{bmatrix} y_1 \\ y_2 \end{bmatrix} = 3.27y_1 + 5.71y_2$$

- Já o valor de $\hat{m}$ é dado por:

$$\hat{m} = \frac{1}{2}(\bar{\boldsymbol{y}}_{\text{SP}} - \bar{\boldsymbol{y}}_{\text{CP}})' S_P^{-1}(\bar{\boldsymbol{y}}_{\text{SP}} + \bar{\boldsymbol{y}}_{\text{CP}}) =$$

$$\frac{1}{2}\begin{bmatrix} 0.624 \\ 0.166 \end{bmatrix}' \times \begin{bmatrix} 3.9619 & 4.8285 \\ 4.8285 & 16.3014 \end{bmatrix} \times \begin{bmatrix} 2.348 \\ 0.994 \end{bmatrix} = 6.68$$

Exemplo 4- Indicadores econômico-financeiros de bancos

- A regra de classificação baseada na função discriminante linear amostral fica dada por:

Exemplo 4- Indicadores econômico-financeiros de bancos

- A regra de classificação baseada na função discriminante linear amostral fica dada por:
  - Classificar $\boldsymbol{y}_0$ em π_1 (sem problemas) se $3.27y_1 + 5.71y_2 \geq 6.68$;

Exemplo 4- Indicadores econômico-financeiros de bancos

- A regra de classificação baseada na função discriminante linear amostral fica dada por:
  - Classificar $\boldsymbol{y}_0$ em π_1 (sem problemas) se $3.27y_1 + 5.71y_2 \geq 6.68$;
  - Classificar $\boldsymbol{y}_0$ em π_2 (com problemas) se $3.27y_1 + 5.71y_2 < 6.68$.

Exemplo 4- Indicadores econômico-financeiros de bancos

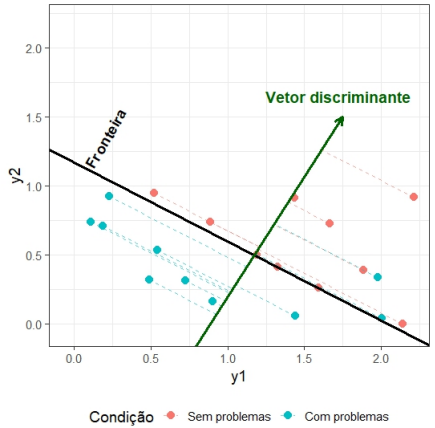


Figura 9: Resultado da análise discriminante linear para os dados das instituições financeiras

Exemplo 4- Indicadores econômico-financeiros de bancos

- Considere duas novas instituições, independente daquelas usadas no ajuste do modelo:

Exemplo 4- Indicadores econômico-financeiros de bancos

- Considere duas novas instituições, independente daquelas usadas no ajuste do modelo:
  - Instituição 1: $y_1 = 2.0$ e $y_2 = 0.7$;

Exemplo 4- Indicadores econômico-financeiros de bancos

- Considere duas novas instituições, independente daquelas usadas no ajuste do modelo:
  - Instituição 1: $y_1 = 2.0$ e $y_2 = 0.7$;
  - Instituição 2: $y_1 = 0.5$ e $y_2 = 0.3$.

Exemplo 4- Indicadores econômico-financeiros de bancos

- Considere duas novas instituições, independente daquelas usadas no ajuste do modelo:
  - Instituição 1: $y_1 = 2.0$ e $y_2 = 0.7$;
  - Instituição 2: $y_1 = 0.5$ e $y_2 = 0.3$.

- Vamos calcular o valor da função discriminante linear e classificar cada uma delas:

Exemplo 4- Indicadores econômico-financeiros de bancos

- Considere duas novas instituições, independente daquelas usadas no ajuste do modelo:
  - Instituição 1: $y_1 = 2.0$ e $y_2 = 0.7$;
  - Instituição 2: $y_1 = 0.5$ e $y_2 = 0.3$.

- Vamos calcular o valor da função discriminante linear e classificar cada uma delas:

$$\text{LD}_1 = 3.27 \times 2.0 + 5.71 \times 0.7 = 10.54 \geq 6.68 \quad \text{(Class. sem problemas)}$$

Exemplo 4- Indicadores econômico-financeiros de bancos

- Considere duas novas instituições, independente daquelas usadas no ajuste do modelo:
  - Instituição 1: $y_1 = 2.0$ e $y_2 = 0.7$;
  - Instituição 2: $y_1 = 0.5$ e $y_2 = 0.3$.

- Vamos calcular o valor da função discriminante linear e classificar cada uma delas:

$$\text{LD}_1 = 3.27 \times 2.0 + 5.71 \times 0.7 = 10.54 \geq 6.68 \quad \text{(Class. sem problemas)}$$

$$\text{LD}_2 = 3.27 \times 0.5 + 5.71 \times 0.3 = 3.35 < 6.68 \quad \text{(Class. com problemas)}$$

Análise discriminante linear (caso de k>2 populações)

Análise discriminante linear (caso de k>2 populações)

- Vamos considerar k populações com vetores de médias $\boldsymbol{\mu_1}, \boldsymbol{\mu_2}, ..., \boldsymbol{\mu_k}$ e matrizes de covariâncias $\Sigma_1, \Sigma_2, ..., \Sigma_k$.

Análise discriminante linear (caso de k>2 populações)

- Vamos considerar k populações com vetores de médias $\boldsymbol{\mu_1}, \boldsymbol{\mu_2}, ..., \boldsymbol{\mu_k}$ e matrizes de covariâncias $\Sigma_1, \Sigma_2, ..., \Sigma_k$.

- Como no caso da análise discriminante linear para duas populações, vamos considerar $\Sigma_1 = \Sigma_2 = ... = \Sigma_k = \Sigma$.

Análise discriminante linear (caso de k>2 populações)

- Vamos considerar k populações com vetores de médias $\boldsymbol{\mu_1}, \boldsymbol{\mu_2}, ..., \boldsymbol{\mu_k}$ e matrizes de covariâncias $\Sigma_1, \Sigma_2, ..., \Sigma_k$.

- Como no caso da análise discriminante linear para duas populações, vamos considerar $\Sigma_1 = \Sigma_2 = ... = \Sigma_k = \Sigma$.

- Seja $\boldsymbol{B}$ a soma de produtos cruzados dos vetores de médias das k populações centrados no vetor de médias geral ($\bar{\boldsymbol{\mu}} = (1/k) \sum_{i=1}^{k} \boldsymbol{\mu_i}$):

$$\boldsymbol{B} = \sum_{i=1}^{k} (\boldsymbol{\mu_i} - \bar{\boldsymbol{\mu}})(\boldsymbol{\mu_i} - \bar{\boldsymbol{\mu}})'$$

Análise discriminante linear (caso de k>2 populações)

- No caso de $k > 2$ populações, o objetivo também é obter combinações lineares que melhor disciminem as k populações, no sentido de maximizar:

$$\frac{\sum_{i=1}^{k}(\mu_{iZ} - \bar{\mu}_Z)}{\sigma_Z^2} = \frac{\sum_{i=1}^{k}(\boldsymbol{a'\mu_i} - \boldsymbol{a'\bar{\mu}})^2}{\boldsymbol{a'\Sigma a}} =$$

$$\frac{\boldsymbol{a'}\left[\sum_{i=1}^{k}(\boldsymbol{\mu_i} - \bar{\boldsymbol{\mu}})(\boldsymbol{\mu_i} - \bar{\boldsymbol{\mu}})'\right]\boldsymbol{a}}{\boldsymbol{a'\Sigma a}} = \frac{\boldsymbol{a'Ba}}{\boldsymbol{a'\Sigma a}}$$

Análise discriminante linear (caso de k>2 populações)

- Os coeficientes $\boldsymbol{a}_1'$ da primeira função discriminante $\boldsymbol{a}_1'\boldsymbol{y}$ são os elementos do autovetor normalizado de $\Sigma^{-1}\boldsymbol{B}$ associados ao maior autovalor desta matriz;

Análise discriminante linear (caso de k>2 populações)

- Os coeficientes $\boldsymbol{a}_1'$ da primeira função discriminante $\boldsymbol{a}_1'\boldsymbol{y}$ são os elementos do autovetor normalizado de $\Sigma^{-1}\boldsymbol{B}$ associados ao maior autovalor desta matriz;

- O vetor $\boldsymbol{a}_2'$ que maximiza a referida razão sujeito à restrição $\text{Cov}(\boldsymbol{a}_1'\boldsymbol{y}, \boldsymbol{a}_2'\boldsymbol{y}) = 0$ é o autovetor normalizado associado ao segundo maior autovalor de $\Sigma^{-1}\boldsymbol{B}$, produzindo a segunda função discriminante...

Análise discriminante linear (caso de k>2 populações)

- Os coeficientes $\boldsymbol{a}_1'$ da primeira função discriminante $\boldsymbol{a}_1'\boldsymbol{y}$ são os elementos do autovetor normalizado de $\Sigma^{-1}\boldsymbol{B}$ associados ao maior autovalor desta matriz;

- O vetor $\boldsymbol{a}_2'$ que maximiza a referida razão sujeito à restrição $\text{Cov}(\boldsymbol{a}_1'\boldsymbol{y}, \boldsymbol{a}_2'\boldsymbol{y}) = 0$ é o autovetor normalizado associado ao segundo maior autovalor de $\Sigma^{-1}\boldsymbol{B}$, produzindo a segunda função discriminante...

- O vetor $\boldsymbol{a}_q'$ que maximiza a referida razão sujeito à restrição $\text{Cov}(\boldsymbol{a}_q'\boldsymbol{y}, \boldsymbol{a}_i'\boldsymbol{y}) = 0$, $i < q$ é o autovetor normalizado associado ao $q-$ésimo maior autovalor de $\Sigma^{-1}\boldsymbol{B}$, produzindo a $q-$ésima função discriminante.

Análise discriminante linear (caso de k>2 populações)

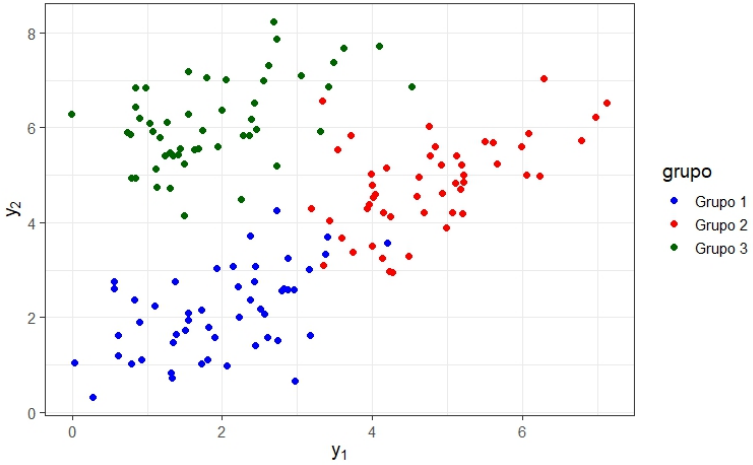


Figura 10: Dados de três populações para análise discriminante linear

Análise discriminante linear (caso de k>2 populações)

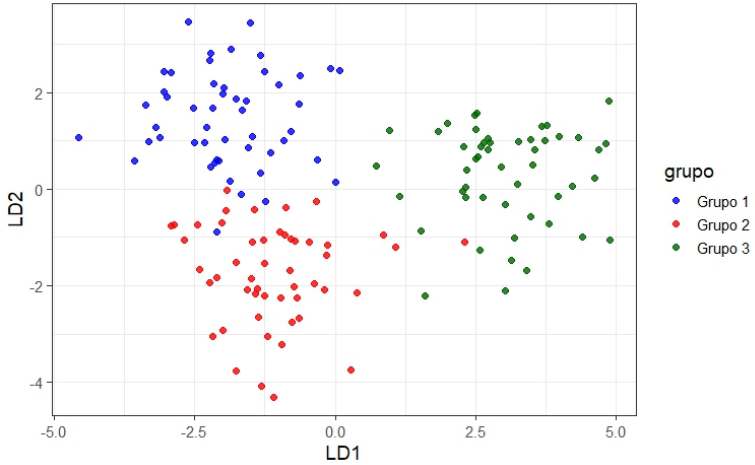


Figura 11: Projeção das três populações nas funções discriminantes

Análise discriminante linear (caso de k>2 populações)

- Na prática, Σ e os $\boldsymbol{\mu}_i$ são desconhecidos, e devem ser estimados usando dados amostrais.

Análise discriminante linear (caso de k>2 populações)

- Na prática, Σ e os $\boldsymbol{\mu}_i$ são desconhecidos, e devem ser estimados usando dados amostrais.

- Os vetores de médias populacionais $\boldsymbol{\mu}_1, \boldsymbol{\mu}_2, ..., \boldsymbol{\mu}_k$ devem ser estimadas pelos correspondentes vetores de médias amostrais $\boldsymbol{y}_1, \boldsymbol{y}_2, ..., \boldsymbol{y}_k$.

Análise discriminante linear (caso de k>2 populações)

- Na prática, Σ e os $\boldsymbol{\mu}_i$ são desconhecidos, e devem ser estimados usando dados amostrais.
- Os vetores de médias populacionais $\boldsymbol{\mu}_1, \boldsymbol{\mu}_2, ..., \boldsymbol{\mu}_k$ devem ser estimadas pelos correspondentes vetores de médias amostrais $\boldsymbol{y}_1, \boldsymbol{y}_2, ..., \boldsymbol{y}_k$.
- A matriz de covariâncias Σ é estimada pela ponderação das matrizes de covariâncias amostrais $(S_1^2, S_2^2, ..., S_k^2)$:

$$S_p = \frac{\sum_{i=1}^{k}(n_i - 1)S_i}{n_1 + n_2 + ... + n_k - k}$$

Análise discriminante linear (caso de k>2 populações)

- Usando as estatísticas amostrais apresentadas, as somas de quadrados entre e intra-grupos são estimadas por:

$$\hat{\mathbf{B}} = \sum_{i=1}^{k} n_i \left(\bar{\mathbf{x}}_i - \bar{\mathbf{x}}\right)\left(\bar{\mathbf{x}}_i - \bar{\mathbf{x}}\right)' \quad \hat{\mathbf{W}} = (n-k)\mathrm{S}_p,$$

de tal forma que as funções discriminantes são obtidas maximizando:

$$\frac{\mathbf{a}'\hat{\mathbf{B}}\mathbf{a}}{\mathbf{a}'\hat{\mathbf{W}}\mathbf{a}}.$$

Análise discriminante linear (caso de k>2 populações)

- O número de funções discriminantes é limitado ao menor valor entre:

Análise discriminante linear (caso de k>2 populações)

- O número de funções discriminantes é limitado ao menor valor entre:
  - p, o número de variáveis observadas e

Análise discriminante linear (caso de k>2 populações)

- O número de funções discriminantes é limitado ao menor valor entre:
  - p, o número de variáveis observadas e
  - $k - 1$, sendo k o número de populações.

Análise discriminante linear (caso de k>2 populações)

- O número de funções discriminantes é limitado ao menor valor entre:
  - p, o número de variáveis observadas e
  - $k-1$, sendo k o número de populações.

- Novamente, na classificação de uma nova observação $\boldsymbol{y}_0$, probabilidades a posteriori podem ser calculadas para cada população da seguinte forma:

$$P(\pi_j|\boldsymbol{y}_0) = \frac{p_j \times f_{\pi_j}(\boldsymbol{y}_0)}{p_1 \times f_{\pi_1}(\boldsymbol{y}_0) + p_2 \times f_{\pi_2}(\boldsymbol{y}_0) + ... + p_k \times f_{\pi_k}(\boldsymbol{y}_0)},$$

para $j = 1, 2, ..., k$.

Análise discriminante linear (caso de k>2 populações)

- Com base nas funções discriminantes r obtidas, devemos classificar $\boldsymbol{y}_0$ à população g tal que a distância de $\boldsymbol{y}_0$ a $\bar{\boldsymbol{y}}_g$:

$$d_g^2 = \sum_{j=1}^{r} \left[\mathbf{a}_j' \left(\mathbf{y}_0 - \bar{\mathbf{y}}_g \right) \right]^2$$

seja mínima, ou seja, menor que para qualquer outra população $i \neq g$.

Análise discriminante linear (caso de k>2 populações)

- Com base nas funções discriminantes r obtidas, devemos classificar $\boldsymbol{y}_0$ à população g tal que a distância de $\boldsymbol{y}_0$ a $\bar{\boldsymbol{y}}_g$:

$$d_g^2 = \sum_{j=1}^{r} \left[\mathbf{a}_j' \left(\mathbf{y}_0 - \bar{\mathbf{y}}_g \right) \right]^2$$

seja mínima, ou seja, menor que para qualquer outra população $i \neq g$.

- Novamente, probabilidades a priori e custos de má-classificação podem ser incorporados na definição da regra de classificação.

Análise discriminante linear (caso de k>2 populações)

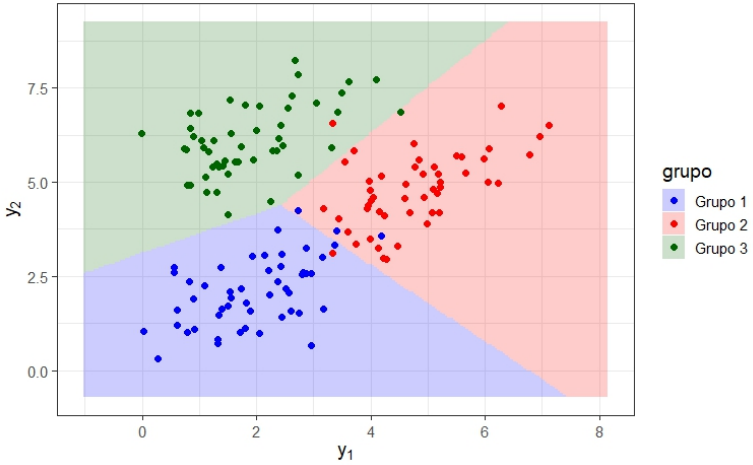


Figura 12: Partição produzida pela análise discriminante linear para fins de classificação

Exemplo 5- Produção de petróleo

Exemplo 5- Produção de petróleo

- Vamos analisar dados de amostras de petróleo bruto extraídas de arenito na reserva petrolífera de Elk Hills, Califórnia.

Exemplo 5- Produção de petróleo

- Vamos analisar dados de amostras de petróleo bruto extraídas de arenito na reserva petrolífera de Elk Hills, Califórnia.

- Esses óleos podem ser atribuídos a uma entre três unidades estratigráficas, tratadas aqui como populações:

π_1 : arenito Wilhelm, π_2 : arenito Sub-Mulinia, π_3 : arenito Upper.

Exemplo 5- Produção de petróleo

- Vamos analisar dados de amostras de petróleo bruto extraídas de arenito na reserva petrolífera de Elk Hills, Califórnia.

- Esses óleos podem ser atribuídos a uma entre três unidades estratigráficas, tratadas aqui como populações:

π_1 : arenito Wilhelm, π_2 : arenito Sub-Mulinia, π_3 : arenito Upper.

- Foram coletadas e classificadas 56 amostras, em que foi também registrado um conjunto de variáveis químicas.

Exemplo 5- Produção de petróleo

- Vamos conduzir uma análise discriminante linear baseada nas seguintes características químicas:

$$
\begin{aligned}
y_1 &= \text{vanádio, em porcentagem nas cinzas,} \\
y_2 &= \sqrt{\text{ferro, (em porcentagem nas cinzas)}}, \\
y_3 &= \sqrt{\text{berílio, (em porcentagem nas cinzas)}}, \\
y_4 &= \frac{1}{\text{hidrocarbonetos saturados, em porcentagem de área}}, \\
y_5 &= \text{hidrocarbonetos aromáticos, em porcentagem de área.}
\end{aligned}
$$

Exemplo 5- Produção de petróleo

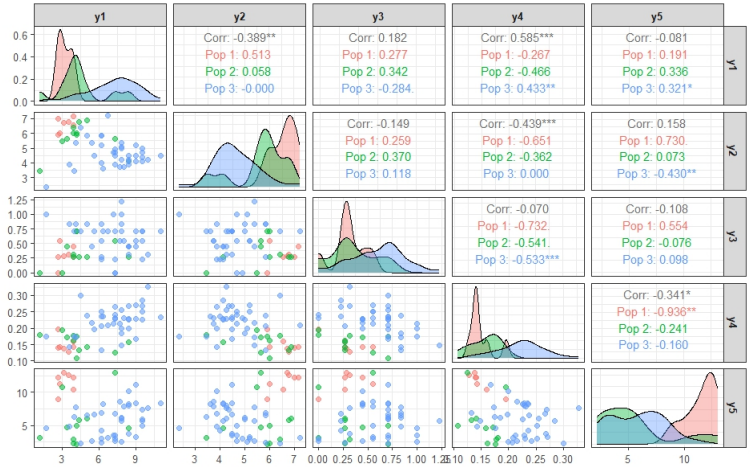


Figura 13: Dados químicos de amostras de petóleo

Exemplo 5- Produção de petróleo

- As médias calculadas para cada com base em cada amostra são as seguintes:

$$\bar{\mathbf{y}}_1 = \begin{bmatrix} 6.258 \\ 3.303 \\ 0.150 \\ 0.218 \\ 11.540 \end{bmatrix}, \qquad \bar{\mathbf{y}}_2 = \begin{bmatrix} 4.445 \\ 5.667 \\ 0.344 \\ 0.157 \\ 5.484 \end{bmatrix}, \qquad \bar{\mathbf{y}}_3 = \begin{bmatrix} 7.462 \\ 4.326 \\ 0.598 \\ 0.223 \\ 5.768 \end{bmatrix}$$

Exemplo 5- Produção de petróleo

- As médias calculadas para cada com base em cada amostra são as seguintes:

$$\bar{\mathbf{y}}_1 = \begin{bmatrix} 6.258 \\ 3.303 \\ 0.150 \\ 0.218 \\ 11.540 \end{bmatrix}, \qquad \bar{\mathbf{y}}_2 = \begin{bmatrix} 4.445 \\ 5.667 \\ 0.344 \\ 0.157 \\ 5.484 \end{bmatrix}, \qquad \bar{\mathbf{y}}_3 = \begin{bmatrix} 7.462 \\ 4.326 \\ 0.598 \\ 0.223 \\ 5.768 \end{bmatrix}$$

- A média global é

$$\bar{\mathbf{y}} = \begin{bmatrix} 6.180 \\ 5.081 \\ 0.511 \\ 0.201 \\ 6.434 \end{bmatrix}$$

Exemplo 5- Produção de petróleo

- A matriz de covariâncias amostral ponderada é dada por:

$$\mathbf{S}_{\text{pooled}} = \begin{bmatrix} 3.5392 & 0.0369 & -0.0761 & 0.0206 & 1.5032 \\ 0.0369 & 0.7885 & 0.0402 & -0.0027 & -0.5329 \\ -0.0761 & 0.0402 & 0.0675 & -0.0054 & 0.0483 \\ 0.0206 & -0.0027 & -0.0054 & 0.0015 & -0.0188 \\ 1.5032 & -0.5329 & 0.0483 & -0.0188 & 6.3778 \end{bmatrix}.$$

Exemplo 5- Produção de petróleo

- A matriz de covariâncias amostral ponderada é dada por:

$$\mathbf{S}_{\text{pooled}} = \begin{bmatrix} 3.5392 & 0.0369 & -0.0761 & 0.0206 & 1.5032 \\ 0.0369 & 0.7885 & 0.0402 & -0.0027 & -0.5329 \\ -0.0761 & 0.0402 & 0.0675 & -0.0054 & 0.0483 \\ 0.0206 & -0.0027 & -0.0054 & 0.0015 & -0.0188 \\ 1.5032 & -0.5329 & 0.0483 & -0.0188 & 6.3778 \end{bmatrix}.$$

- Como há $k = 3$ populações e $p = 5$ variáveis, o número máximo de funções discriminantes de Fisher não nulas é

$$s = \min(k - 1, p) = \min(2, 5) = 2$$

Exemplo 5- Produção de petróleo

- As matrizes de dispersão entre e intra-grupos são dadas por:

$$\hat{\mathbf{B}} = \begin{bmatrix} 53.93 & -12.18 & 5.03 & 0.42 & 92.70 \\ -12.18 & 51.29 & -4.28 & -0.50 & -117.86 \\ 5.03 & -4.28 & 1.88 & 0.06 & 8.54 \\ 0.42 & -0.50 & 0.06 & 0.03 & -1.69 \\ 92.70 & -117.86 & 8.54 & -1.69 & 780.77 \end{bmatrix}$$

e

$$\hat{\mathbf{W}} = \begin{bmatrix} 187.575 & 1.957 & -4.031 & 1.092 & 79.672 \\ 1.957 & 41.789 & 2.128 & -0.143 & -28.243 \\ -4.031 & 2.128 & 3.580 & -0.284 & 2.559 \\ 1.092 & -0.143 & -0.284 & 0.077 & -0.996 \\ 79.672 & -28.243 & 2.559 & -0.996 & 338.023 \end{bmatrix}$$

Exemplo 5- Produção de petróleo

- Os coeficientes das funções discriminantes são dados pelos dois primeiros autovetores de $\hat{\mathbf{W}}^{-1}\hat{\mathbf{B}}$, produzindo, na forma centrada:

$$z_1 = 0.312(y_1 - 6.180) - 0.710(y_2 - 5.081) + 2.764(y_3 - 0.511) + 11.809(y_4 - 0.201) - 0.235(y_5 - 6.434),$$

e

$$z_2 = 0.169(y_1 - 6.180) - 0.245(y_2 - 5.081) - 2.046(y_3 - 0.511) - 24.453(y_4 - 0.201) - 0.378(y_5 - 6.434).$$

Exemplo 5- Produção de petróleo

- Desta forma, cada observação original $\mathbf{y} = (y_1, y_2, y_3, y_4, y_5)'$ é projetada no plano definido pelas duas funções discriminantes.

Exemplo 5- Produção de petróleo

- Desta forma, cada observação original $\mathbf{y} = (y_1, y_2, y_3, y_4, y_5)'$ é projetada no plano definido pelas duas funções discriminantes.

- A representação gráfica das observações nesse sistema de coordenadas permite visualizar a separação entre os três grupos.

Exemplo 5- Produção de petróleo

- Desta forma, cada observação original $\mathbf{y} = (y_1, y_2, y_3, y_4, y_5)'$ é projetada no plano definido pelas duas funções discriminantes.

- A representação gráfica das observações nesse sistema de coordenadas permite visualizar a separação entre os três grupos.

- No exemplo, a separação entre os grupos é bastante satisfatória.

Exemplo 5- Produção de petróleo

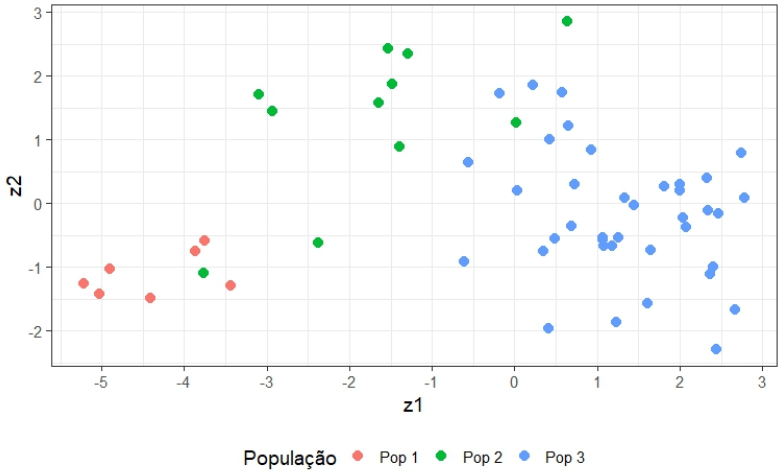


Figura 14: Representação dos escores para as duas funções discriminantes

Exemplo 6- Classificação de vinhos

Exemplo 6- Classificação de vinhos

- Nesta aplicação vamos considerar a base de dados `wine` disponível na biblioteca `rattle` do R.

Exemplo 6- Classificação de vinhos

- Nesta aplicação vamos considerar a base de dados `wine` disponível na biblioteca `rattle` do R.

- O objetivo é usar análise discriminante linear para classificação de 178 marcas de vinho italianas de três tipos (1, 2 e 3) segundo os resultados de 13 variáveis produzidas em análise química.

Exemplo 6- Classificação de vinhos

- Nesta aplicação vamos considerar a base de dados `wine` disponível na biblioteca `rattle` do R.

- O objetivo é usar análise discriminante linear para classificação de 178 marcas de vinho italianas de três tipos (1, 2 e 3) segundo os resultados de 13 variáveis produzidas em análise química.

- As variáveis utilizadas na análise discriminante linear são relacionadas na sequência.

Exemplo 6- Classificação de vinhos

- Type: tipo de vinho em uma de três classes (1, 2 ou 3);

Exemplo 6- Classificação de vinhos

- `Type`: tipo de vinho em uma de três classes (1, 2 ou 3);
- `Alcohol`: teor de álcool;

Exemplo 6- Classificação de vinhos

- `Type`: tipo de vinho em uma de três classes (1, 2 ou 3);
- `Alcohol`: teor de álcool;
- `Malic`: teor de ácido málico;

Exemplo 6- Classificação de vinhos

- `Type`: tipo de vinho em uma de três classes (1, 2 ou 3);
- `Alcohol`: teor de álcool;
- `Malic`: teor de ácido málico;
- `Ash`: teor de cinzas;

Exemplo 6- Classificação de vinhos

- `Type`: tipo de vinho em uma de três classes (1, 2 ou 3);
- `Alcohol`: teor de álcool;
- `Malic`: teor de ácido málico;
- `Ash`: teor de cinzas;
- `Alcalinity`: alcalinidade;

Exemplo 6- Classificação de vinhos

- `Type`: tipo de vinho em uma de três classes (1, 2 ou 3);
- `Alcohol`: teor de álcool;
- `Malic`: teor de ácido málico;
- `Ash`: teor de cinzas;
- `Alcalinity`: alcalinidade;
- `Magnesium`: teor de magnésio;

Exemplo 6- Classificação de vinhos

- `Type`: tipo de vinho em uma de três classes (1, 2 ou 3);
- `Alcohol`: teor de álcool;
- `Malic`: teor de ácido málico;
- `Ash`: teor de cinzas;
- `Alcalinity`: alcalinidade;
- `Magnesium`: teor de magnésio;
- `Phenols`: fenóis;

Exemplo 6- Classificação de vinhos

- `Type`: tipo de vinho em uma de três classes (1, 2 ou 3);
- `Alcohol`: teor de álcool;
- `Malic`: teor de ácido málico;
- `Ash`: teor de cinzas;
- `Alcalinity`: alcalinidade;
- `Magnesium`: teor de magnésio;
- `Phenols`: fenóis;
- `Flavanoids`: flavonóides;

Exemplo 6- Classificação de vinhos

- `Type`: tipo de vinho em uma de três classes (1, 2 ou 3);
- `Alcohol`: teor de álcool;
- `Malic`: teor de ácido málico;
- `Ash`: teor de cinzas;
- `Alcalinity`: alcalinidade;
- `Magnesium`: teor de magnésio;
- `Phenols`: fenóis;
- `Flavanoids`: flavonóides;
- `Nonflavanoids`: não flavonóides;

Exemplo 6- Classificação de vinhos

- `Type`: tipo de vinho em uma de três classes (1, 2 ou 3);
- `Alcohol`: teor de álcool;
- `Malic`: teor de ácido málico;
- `Ash`: teor de cinzas;
- `Alcalinity`: alcalinidade;
- `Magnesium`: teor de magnésio;
- `Phenols`: fenóis;
- `Flavanoids`: flavonóides;
- `Nonflavanoids`: não flavonóides;
- `Proanthocyanins`: proantocianinas;

Exemplo 6- Classificação de vinhos

- `Type`: tipo de vinho em uma de três classes (1, 2 ou 3);
- `Alcohol`: teor de álcool;
- `Malic`: teor de ácido málico;
- `Ash`: teor de cinzas;
- `Alcalinity`: alcalinidade;
- `Magnesium`: teor de magnésio;
- `Phenols`: fenóis;
- `Flavanoids`: flavonóides;
- `Nonflavanoids`: não flavonóides;
- `Proanthocyanins`: proantocianinas;
- `Color`: cor;

Exemplo 6- Classificação de vinhos

- `Type`: tipo de vinho em uma de três classes (1, 2 ou 3);
- `Alcohol`: teor de álcool;
- `Malic`: teor de ácido málico;
- `Ash`: teor de cinzas;
- `Alcalinity`: alcalinidade;
- `Magnesium`: teor de magnésio;
- `Phenols`: fenóis;
- `Flavanoids`: flavonóides;
- `Nonflavanoids`: não flavonóides;
- `Proanthocyanins`: proantocianinas;
- `Color`: cor;
- `Hue`: matiz;

Exemplo 6- Classificação de vinhos

- `Type`: tipo de vinho em uma de três classes (1, 2 ou 3);
- `Alcohol`: teor de álcool;
- `Malic`: teor de ácido málico;
- `Ash`: teor de cinzas;
- `Alcalinity`: alcalinidade;
- `Magnesium`: teor de magnésio;
- `Phenols`: fenóis;
- `Flavanoids`: flavonóides;
- `Nonflavanoids`: não flavonóides;
- `Proanthocyanins`: proantocianinas;
- `Color`: cor;
- `Hue`: matiz;
- `Dilution`: diluição;

Exemplo 6- Classificação de vinhos

- `Type`: tipo de vinho em uma de três classes (1, 2 ou 3);
- `Alcohol`: teor de álcool;
- `Malic`: teor de ácido málico;
- `Ash`: teor de cinzas;
- `Alcalinity`: alcalinidade;
- `Magnesium`: teor de magnésio;
- `Phenols`: fenóis;
- `Flavanoids`: flavonóides;
- `Nonflavanoids`: não flavonóides;
- `Proanthocyanins`: proantocianinas;
- `Color`: cor;
- `Hue`: matiz;
- `Dilution`: diluição;
- `Proline`: prolina.

Exemplo 6- Classificação de vinhos

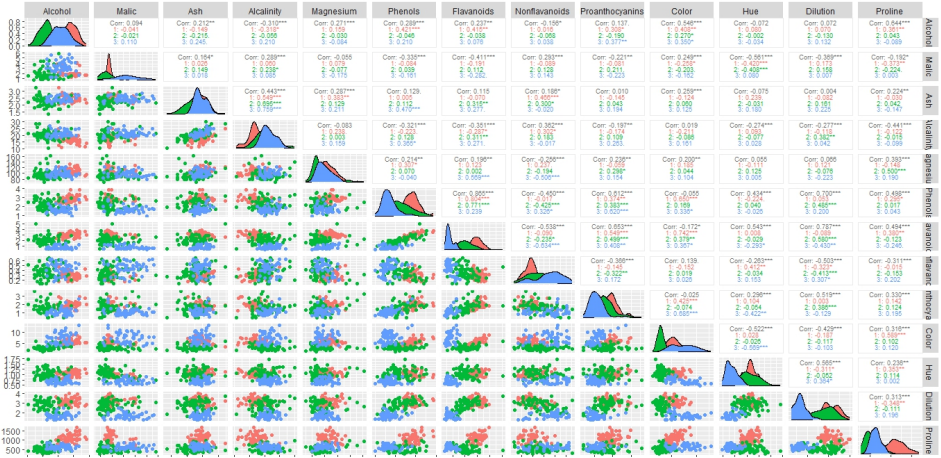


Figura 15: Dados de características de marcas de vinho

Análise discriminante quadrática

Análise discriminante quadrática

- Uma restrição forte na análise discriminante linear é a de matrizes de covariâncias iguais para as $k \geq 2$ populações:

$$\Sigma_1 = \Sigma_2 = ... = \Sigma_k$$

Análise discriminante quadrática

- Uma restrição forte na análise discriminante linear é a de matrizes de covariâncias iguais para as $k \geq 2$ populações:

$$\Sigma_1 = \Sigma_2 = ... = \Sigma_k$$

- Esta pressuposição pode não ser verificada na prática porque as variâncias e/ou correlações entre variáveis diferem entre os grupos.

Análise discriminante quadrática

- Uma restrição forte na análise discriminante linear é a de matrizes de covariâncias iguais para as $k \geq 2$ populações:

$$\Sigma_1 = \Sigma_2 = ... = \Sigma_k$$

- Esta pressuposição pode não ser verificada na prática porque as variâncias e/ou correlações entre variáveis diferem entre os grupos.

- A análise discriminante quadrática é adequada em situações desse tipo.

Análise discriminante quadrática

- Suponha $k \geq 2$ populações com distribuição normal multivariada.

Análise discriminante quadrática

- Suponha $k \geq 2$ populações com distribuição normal multivariada.

- Sejam $\boldsymbol{\mu}_1, \boldsymbol{\mu}_2, ..., \boldsymbol{\mu}_k$ os vetores de médias e $\Sigma_1, \Sigma_2, ..., \Sigma_k$ as matrizes de covariâncias de cada população.

Análise discriminante quadrática

- Suponha $k \geq 2$ populações com distribuição normal multivariada.
- Sejam $\boldsymbol{\mu}_1, \boldsymbol{\mu}_2, ..., \boldsymbol{\mu}_k$ os vetores de médias e $\Sigma_1, \Sigma_2, ..., \Sigma_k$ as matrizes de covariâncias de cada população.
- Adicionalmente, sejam $p_1, p_2, ..., p_k$ probabilidades a priori.

Análise discriminante quadrática

- Nesse contexto, a função discriminante quadrática, definida para a $i-$ésima população, é definida por:

$$Q_i(\boldsymbol{y}) = -\frac{1}{2}\ln|\Sigma_i| - \frac{1}{2}(\boldsymbol{y}-\boldsymbol{\mu}_i)'\Sigma_i^{-1}(\boldsymbol{y}-\boldsymbol{\mu}_i) + \log(p_i), \quad i = 1, 2, ..., k$$

Análise discriminante quadrática

- Nesse contexto, a função discriminante quadrática, definida para a $i-$ésima população, é definida por:

$$Q_i(\boldsymbol{y}) = -\frac{1}{2}\ln|\Sigma_i| - \frac{1}{2}(\boldsymbol{y}-\boldsymbol{\mu}_i)'\Sigma_i^{-1}(\boldsymbol{y}-\boldsymbol{\mu}_i) + \log(p_i), \quad i = 1, 2, ..., k$$

- Para fins de classificação, uma nova observação $\boldsymbol{y}_0$ deve ser alocada à população i tal que o valor calculado de $Q_i(\boldsymbol{y}_0)$ seja máximo $(i = 1, 2, ..., k)$.

Análise discriminante quadrática

- No caso particular de $k = 2$ populações, vamos classificar $\boldsymbol{y}_0$ em π_1 se:

$$Q_1(\boldsymbol{y}_0) > Q_2(\boldsymbol{y}_0).$$

Análise discriminante quadrática

- No caso particular de $k = 2$ populações, vamos classificar $\boldsymbol{y}_0$ em π_1 se:

$$Q_1(\boldsymbol{y}_0) > Q_2(\boldsymbol{y}_0).$$

- A fronteira de decisão é obtida resolvendo:

$$Q_1(\boldsymbol{y}_0) = Q_2(\boldsymbol{y}_0).$$

Análise discriminante quadrática

- No caso particular de $k = 2$ populações, vamos classificar $\boldsymbol{y}_0$ em π_1 se:

$$Q_1(\boldsymbol{y}_0) > Q_2(\boldsymbol{y}_0).$$

- A fronteira de decisão é obtida resolvendo:

$$Q_1(\boldsymbol{y}_0) = Q_2(\boldsymbol{y}_0).$$

- Após simplificações, aparece uma função quadrática em $\boldsymbol{y}$, justificando o nome da técnica.

Análise discriminante quadrática

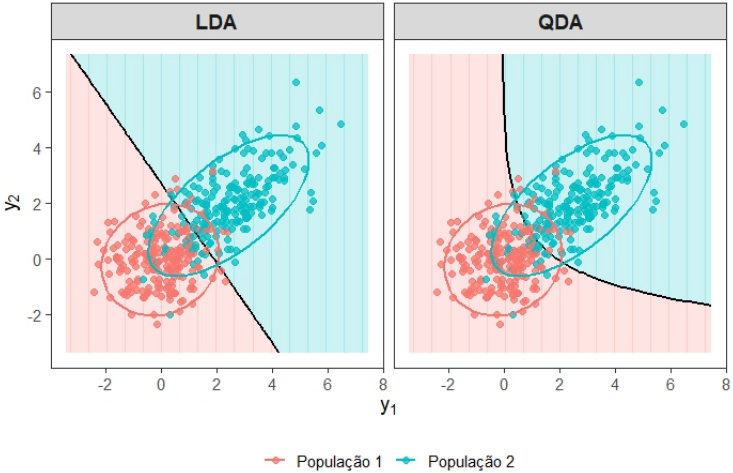


Figura 16: Comparação entre análise discriminante linear e quadrática.

Análise discriminante quadrática

- Como na prática $\boldsymbol{\mu}_k$ e Σ_k são desconhecidos, eles devem ser estimados, respectivamente, por:

$$\bar{\boldsymbol{y}}_k = \frac{1}{n_k}\sum_{i=1}^{n_k}\boldsymbol{y}_i \quad e \quad S_k = \sum_{i=1}^{n_k}(\boldsymbol{y}_i - \bar{\boldsymbol{y}}_k)(\boldsymbol{y}_i - \bar{\boldsymbol{y}}_k)',$$

em que n_k é o número de observações de π_k presentes na amostra.

Análise discriminante quadrática

- Na análise discriminante quadrática, o número de parâmetros a estimar é bastante superior ao da análise discriminante linear, devido às k matrizes de covariâncias distintas.

Análise discriminante quadrática

- Na análise discriminante quadrática, o número de parâmetros a estimar é bastante superior ao da análise discriminante linear, devido às k matrizes de covariâncias distintas.

- A análise discriminante linear tende a produzir resultados com variância substancialmente menor que a quadrática, sobretudo para pequenas amostras.

Análise discriminante quadrática

- Na análise discriminante quadrática, o número de parâmetros a estimar é bastante superior ao da análise discriminante linear, devido às k matrizes de covariâncias distintas.

- A análise discriminante linear tende a produzir resultados com variância substancialmente menor que a quadrática, sobretudo para pequenas amostras.

- Desta forma, a análise discriminante quadrática somente é recomendável se a quantidade de dados disponíveis for grande e as matrizes de covariâncias diferentes.

Diferenças entre LDA e QDA

Aspecto	LDA	QDA
Covariância	Igual para todas as populações	Diferente para cada população
Fronteira de decisão	Linear	Quadrática
Complexidade	Poucos parametros estimados	Muitos parâmetros estimados

Exemplo 7- Classificação de pacientes

Exemplo 7- Classificação de pacientes

- Considere duas populações:

Exemplo 7- Classificação de pacientes

- Considere duas populações:
  - π_1: indivíduos saudáveis;
  - π_2: indivíduos com determinado diagnóstico.

Exemplo 7- Classificação de pacientes

- Considere duas populações:
  - π_1: indivíduos saudáveis;
  - π_2: indivíduos com determinado diagnóstico.

- São observadas duas variáveis:

Exemplo 7- Classificação de pacientes

- Considere duas populações:
  - π_1: indivíduos saudáveis;
  - π_2: indivíduos com determinado diagnóstico.

- São observadas duas variáveis:
  - y_1: pressão arterial;
  - y_2: colesterol.

Exemplo 7- Classificação de pacientes

- Suponha que:

$$\boldsymbol{\mu}_1 = \begin{pmatrix} 120 \\ 180 \end{pmatrix}, \qquad \Sigma_1 = \begin{pmatrix} 25 & 10 \\ 10 & 20 \end{pmatrix}$$

$$\boldsymbol{\mu}_2 = \begin{pmatrix} 140 \\ 220 \end{pmatrix}, \qquad \Sigma_2 = \begin{pmatrix} 100 & 40 \\ 40 & 80 \end{pmatrix}$$

Exemplo 7- Classificação de pacientes

- Suponha que:

$$\boldsymbol{\mu}_1 = \begin{pmatrix} 120 \\ 180 \end{pmatrix}, \qquad \Sigma_1 = \begin{pmatrix} 25 & 10 \\ 10 & 20 \end{pmatrix}$$

$$\boldsymbol{\mu}_2 = \begin{pmatrix} 140 \\ 220 \end{pmatrix}, \qquad \Sigma_2 = \begin{pmatrix} 100 & 40 \\ 40 & 80 \end{pmatrix}$$

- Considere probabilidades a priori iguais ($p_1 = p_2 = 0.5$) e um novo indivíduo

$$\boldsymbol{y}_0 = \begin{pmatrix} 135 \\ 210 \end{pmatrix}$$

Exemplo 7- Classificação de pacientes

- Para classificar y_0, calculamos, para cada população,

$$Q_i(\boldsymbol{y}_0) = -\frac{1}{2}\ln|\Sigma_i| - \frac{1}{2}(\boldsymbol{y}_0 - \boldsymbol{\mu}_i)'\Sigma_i^{-1}(\boldsymbol{y}_0 - \boldsymbol{\mu}_i) + \ln(p_i).$$

Exemplo 7- Classificação de pacientes

- Para classificar y_0, calculamos, para cada população,

$$Q_i(\boldsymbol{y}_0) = -\frac{1}{2}\ln|\Sigma_i| - \frac{1}{2}(\boldsymbol{y}_0 - \boldsymbol{\mu}_i)'\Sigma_i^{-1}(\boldsymbol{y}_0 - \boldsymbol{\mu}_i) + \ln(p_i).$$

- Para a população π_1:

$$\boldsymbol{y}_0 - \mu_1 = \begin{pmatrix} 15 \\ 30 \end{pmatrix}, \qquad (\boldsymbol{y}_0 - \boldsymbol{\mu}_1)'\Sigma_1^{-1}(\boldsymbol{y}_0 - \boldsymbol{\mu}_1) = 51{,}43.$$

$$|\Sigma_1| = 400$$

$$Q_1(y_0) = -\frac{1}{2}\ln(400) - \frac{1}{2}(51{,}43) + \ln(0{,}5) = -29{,}40.$$

Exemplo 7- Classificação de pacientes

- Para a população π_2:

$$\boldsymbol{y}_0 - \mu_2 = \begin{pmatrix} -5 \\ -10 \end{pmatrix}, \qquad (\boldsymbol{y}_0 - \boldsymbol{\mu}_2)'\Sigma_2^{-1}(\boldsymbol{y}_0 - \boldsymbol{\mu}_2) = 1{,}29.$$

$$|\Sigma_2| = 6400$$

$$Q_2(\boldsymbol{y}_0) = -\frac{1}{2}\ln(6400) - \frac{1}{2}(1{,}29) + \ln(0{,}5) = -5{,}72.$$

Exemplo 7- Classificação de pacientes

- Para a população π_2:

$$\boldsymbol{y}_0 - \mu_2 = \begin{pmatrix} -5 \\ -10 \end{pmatrix}, \qquad (\boldsymbol{y}_0 - \boldsymbol{\mu}_2)'\Sigma_2^{-1}(\boldsymbol{y}_0 - \boldsymbol{\mu}_2) = 1{,}29.$$

$$|\Sigma_2| = 6400$$

$$Q_2(\boldsymbol{y}_0) = -\frac{1}{2}\ln(6400) - \frac{1}{2}(1{,}29) + \ln(0{,}5) = -5{,}72.$$

Exemplo 7- Classificação de pacientes

- Como

$$Q_2(\boldsymbol{y}_0) > Q_1(\boldsymbol{y}_0),$$

classificamos o indivíduo y_0 na população π_2.

Exemplo 7- Classificação de pacientes

- Como

$$Q_2(\boldsymbol{y}_0) > Q_1(\boldsymbol{y}_0),$$

classificamos o indivíduo y_0 na população π_2.

- O novo indivíduo apresenta valores de pressão arterial e colesterol mais próximos do padrão médio da população com diagnóstico.

Exemplo 7- Classificação de pacientes

- Além disso, a população π_2 possui maior variabilidade, o que torna menos surpreendente observar indivíduos relativamente distantes de sua média.

Exemplo 7- Classificação de pacientes

- Além disso, a população π_2 possui maior variabilidade, o que torna menos surpreendente observar indivíduos relativamente distantes de sua média.

- Por isso, a QDA não considera apenas a distância até os centroides.

Exemplo 7- Classificação de pacientes

- Além disso, a população π_2 possui maior variabilidade, o que torna menos surpreendente observar indivíduos relativamente distantes de sua média.

- Por isso, a QDA não considera apenas a distância até os centroides.

- Ela combina três componentes:

$$\text{posição do indivíduo} \quad + \quad \text{estrutura de covariância} \quad + \quad \text{probabilidades a priori.}$$

Performance preditiva

Performance preditiva

- A avaliação da performance dos métodos de classificação usualmente baseia-se na classificação de novos indivíduos, diferentes daqueles usados na obtenção da função de classificação.

Performance preditiva

- A avaliação da performance dos métodos de classificação usualmente baseia-se na classificação de novos indivíduos, diferentes daqueles usados na obtenção da função de classificação.

- Para isso, os seguintes procedimentos podem ser considerados:

Performance preditiva

- A avaliação da performance dos métodos de classificação usualmente baseia-se na classificação de novos indivíduos, diferentes daqueles usados na obtenção da função de classificação.

- Para isso, os seguintes procedimentos podem ser considerados:
  - Uso de uma amostra teste;

Performance preditiva

- A avaliação da performance dos métodos de classificação usualmente baseia-se na classificação de novos indivíduos, diferentes daqueles usados na obtenção da função de classificação.

- Para isso, os seguintes procedimentos podem ser considerados:
  - Uso de uma amostra teste;
  - Validação cruzada;

Performance preditiva

- A avaliação da performance dos métodos de classificação usualmente baseia-se na classificação de novos indivíduos, diferentes daqueles usados na obtenção da função de classificação.

- Para isso, os seguintes procedimentos podem ser considerados:
  - Uso de uma amostra teste;
  - Validação cruzada;
  - *Leave one out*.

Performance preditiva

- Uma vez classificadas as novas observações, uma tabela de dupla entrada pode ser construída cruzando as classes observadas e as classificações produzidas pela função (tabela de confusão).

Tabela 3: Tabela de Confusão

Classe Real \ Classe Prevista	**Positivo**	**Negativo**
Positivo	VP (Verdadeiro Positivo)	FN (Falso Negativo)
Negativo	FP (Falso Positivo)	VN (Verdadeiro Negativo)

Performance preditiva

- **Acurácia:** Desempenho global do classificador.

$$\text{Acurácia} = \frac{VP + VN}{VP + VN + FP + FN}$$

Performance preditiva

- **Acurácia:** Desempenho global do classificador.

$$\text{Acurácia} = \frac{VP + VN}{VP + VN + FP + FN}$$

- **Sensibilidade (Recall):** Capacidade de detectar corretamente os positivos.

$$\text{Sensibilidade} = \frac{VP}{VP + FN}$$

Performance preditiva

- **Acurácia:** Desempenho global do classificador.

$$\text{Acurácia} = \frac{VP + VN}{VP + VN + FP + FN}$$

- **Sensibilidade (Recall):** Capacidade de detectar corretamente os positivos.

$$\text{Sensibilidade} = \frac{VP}{VP + FN}$$

- **Especificidade:** Capacidade de identificar corretamente os negativos.

$$\text{Especificidade} = \frac{VN}{VN + FP}$$

Performance preditiva

- **Valor Preditivo Positivo (VPP):** Probabilidade de que uma observação classificada como positiva seja realmente positiva.

$$\text{VPP} = \frac{VP}{VP + FP}$$

Performance preditiva

- **Valor Preditivo Positivo (VPP):** Probabilidade de que uma observação classificada como positiva seja realmente positiva.

$$\text{VPP} = \frac{VP}{VP + FP}$$

- **Valor Preditivo Negativo (VPN):** Probabilidade de que uma observação classificada como negativa seja realmente negativa.

$$\text{VPN} = \frac{VN}{VN + FN}$$

Performance preditiva

- **Valor Preditivo Positivo (VPP):** Probabilidade de que uma observação classificada como positiva seja realmente positiva.

$$\text{VPP} = \frac{VP}{VP + FP}$$

- **Valor Preditivo Negativo (VPN):** Probabilidade de que uma observação classificada como negativa seja realmente negativa.

$$\text{VPN} = \frac{VN}{VN + FN}$$

- **F1-Score:** Média harmônica entre VPP e sensibilidade.

$$F_1 = \frac{2 \cdot \text{VPP} \cdot \text{Sensibilidade}}{\text{VPP} + \text{Sensibilidade}}$$

Exemplo 8- Classificação de sinais de sonar

Exemplo 8- Classificação de sinais de sonar

- Nesta aplicação vamos analisar dados de classificação de sinais de sonar disponíveis na base de dados `Sonar`, biblioteca `mlbench` do `R`.

Exemplo 8- Classificação de sinais de sonar

- Nesta aplicação vamos analisar dados de classificação de sinais de sonar disponíveis na base de dados `Sonar`, biblioteca `mlbench` do `R`.

- A base é composta por $n = 208$ sinais emitidos por um sonar, que podem ser classificados como `R`: refletido por uma rocha ou `M`: refletido por uma mina submarina.

Exemplo 8- Classificação de sinais de sonar

- Nesta aplicação vamos analisar dados de classificação de sinais de sonar disponíveis na base de dados `Sonar`, biblioteca `mlbench` do `R`.

- A base é composta por $n = 208$ sinais emitidos por um sonar, que podem ser classificados como `R`: refletido por uma rocha ou `M`: refletido por uma mina submarina.

- Os preditores correspondem a um conjunto de 60 variáveis numéricas, representando a energia observada em uma determinada frequência, integrada ao longo de um intervalo específico de tempo.

Exemplo 8- Classificação de sinais de sonar

- Nesta aplicação, para fins de ilustração, 10 desses preditores serão selecionados para análise.

Exemplo 8- Classificação de sinais de sonar

- Nesta aplicação, para fins de ilustração, 10 desses preditores serão selecionados para análise.

- Os dados serão divididos aleatoriamente em amostra de treinamento (ajuste), contendo 70% da base, e amostra teste (validação), com os demais 30%.

Exemplo 8- Classificação de sinais de sonar

- Nesta aplicação, para fins de ilustração, 10 desses preditores serão selecionados para análise.
- Os dados serão divididos aleatoriamente em amostra de treinamento (ajuste), contendo 70% da base, e amostra teste (validação), com os demais 30%.
- Serão ajustados e comparados os modelos:

Exemplo 8- Classificação de sinais de sonar

- Nesta aplicação, para fins de ilustração, 10 desses preditores serão selecionados para análise.
- Os dados serão divididos aleatoriamente em amostra de treinamento (ajuste), contendo 70% da base, e amostra teste (validação), com os demais 30%.
- Serão ajustados e comparados os modelos:
  - Análise discriminante linear;

Exemplo 8- Classificação de sinais de sonar

- Nesta aplicação, para fins de ilustração, 10 desses preditores serão selecionados para análise.
- Os dados serão divididos aleatoriamente em amostra de treinamento (ajuste), contendo 70% da base, e amostra teste (validação), com os demais 30%.
- Serão ajustados e comparados os modelos:
  - Análise discriminante linear;
  - Análise discriminante quadrática;

Exemplo 8- Classificação de sinais de sonar

- Nesta aplicação, para fins de ilustração, 10 desses preditores serão selecionados para análise.
- Os dados serão divididos aleatoriamente em amostra de treinamento (ajuste), contendo 70% da base, e amostra teste (validação), com os demais 30%.
- Serão ajustados e comparados os modelos:
  - Análise discriminante linear;
  - Análise discriminante quadrática;
  - Regressão logística.

Exemplo 8- Classificação de sinais de sonar

- Nesta aplicação, para fins de ilustração, 10 desses preditores serão selecionados para análise.
- Os dados serão divididos aleatoriamente em amostra de treinamento (ajuste), contendo 70% da base, e amostra teste (validação), com os demais 30%.
- Serão ajustados e comparados os modelos:
  - Análise discriminante linear;
  - Análise discriminante quadrática;
  - Regressão logística.
- Os códigos em R estão disponíveis na página da disciplina na UFPR Virtual.