CE319 - Estatística multivariada

Análise fatorial

Cesar Augusto Taconeli

20 de maio, 2026

O que vamos estudar neste módulo

O que vamos estudar neste módulo

- Neste módulo vamos estudar a análise fatorial, mais uma técnica multivariada de redução de dimensão.

O que vamos estudar neste módulo

- Neste módulo vamos estudar a análise fatorial, mais uma técnica multivariada de redução de dimensão.

- Serão abordados o modelo de análise fatorial e suas principais propriedades.

O que vamos estudar neste módulo

- Neste módulo vamos estudar a análise fatorial, mais uma técnica multivariada de redução de dimensão.
- Serão abordados o modelo de análise fatorial e suas principais propriedades.
- Tópicos como a definição do número de fatores, técnicas de rotação e interpretação dos resultados serão abordados.

O que vamos estudar neste módulo

- Neste módulo vamos estudar a análise fatorial, mais uma técnica multivariada de redução de dimensão.
- Serão abordados o modelo de análise fatorial e suas principais propriedades.
- Tópicos como a definição do número de fatores, técnicas de rotação e interpretação dos resultados serão abordados.
- O módulo encerra com exemplos ilustrativos e aplicações em R para entendimento da prática da técnica.

Introdução

Introdução

- O objetivo da análise fatorial é descrever as covariâncias entre as variáveis originais em termos de um menor número de variáveis subjacentes não observáveis (variáveis latentes), denominadas **fatores**.

Introdução

- O objetivo da análise fatorial é descrever as covariâncias entre as variáveis originais em termos de um menor número de variáveis subjacentes não observáveis (variáveis latentes), denominadas **fatores**.

- Embora usualmente se disponha de um grande número de variáveis sob estudo, é comum essas variáveis comporem subconjuntos de variáveis inter-correlacionadas.

Introdução

- O objetivo da análise fatorial é descrever as covariâncias entre as variáveis originais em termos de um menor número de variáveis subjacentes não observáveis (variáveis latentes), denominadas **fatores**.

- Embora usualmente se disponha de um grande número de variáveis sob estudo, é comum essas variáveis comporem subconjuntos de variáveis inter-correlacionadas.

- Na prática, podemos pensar que cada um desses subconjuntos esteja relacionado a um conceito abstrato, que não temos condições de medir diretamente. Esses conceitos são denominados **constructos**.

Introdução

- O objetivo da análise fatorial é descrever as covariâncias entre as variáveis originais em termos de um menor número de variáveis subjacentes não observáveis (variáveis latentes), denominadas **fatores**.

- Embora usualmente se disponha de um grande número de variáveis sob estudo, é comum essas variáveis comporem subconjuntos de variáveis inter-correlacionadas.

- Na prática, podemos pensar que cada um desses subconjuntos esteja relacionado a um conceito abstrato, que não temos condições de medir diretamente. Esses conceitos são denominados **constructos**.

- Uma das utilidades da análise fatorial é a identificação dos constructos presentes em conjuntos de dados.

Introdução

- Os constructos são identificados a partir da estrutura de correlações das variáveis.

Introdução

- Os constructos são identificados a partir da estrutura de correlações das variáveis.

- Variáveis com correlações altas indicam uma mesma dimensão latente (constructo).

Introdução

- Os constructos são identificados a partir da estrutura de correlações das variáveis.
- Variáveis com correlações altas indicam uma mesma dimensão latente (constructo).
- A redução das variáveis originais a um menor número de constructos caracteriza a análise fatorial como uma técnica de redução de dimensão.

Introdução

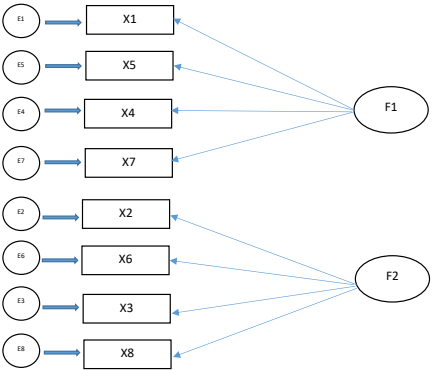


Figura 1: Relação variáveis-fatores em uma análise fatorial ortogonal com dois fatores comuns. Os termos E1 a E8 denotam erros.

Exemplos de constructos

- Numa pesquisa com pacientes submetidos a quimioterapia, imaginemos que bem-estar seja um constructo.

Exemplos de constructos

- Numa pesquisa com pacientes submetidos a quimioterapia, imaginemos que bem-estar seja um constructo.

- Não há como medir diretamente bem-estar. No entanto, ele pode estar associado a respostas objetivas a questões do tipo:

Exemplos de constructos

- Numa pesquisa com pacientes submetidos a quimioterapia, imaginemos que bem-estar seja um constructo.

- Não há como medir diretamente bem-estar. No entanto, ele pode estar associado a respostas objetivas a questões do tipo:
  - Com qual frequência sentiu dores ou desconfortos na última semana?

Exemplos de constructos

- Numa pesquisa com pacientes submetidos a quimioterapia, imaginemos que bem-estar seja um constructo.

- Não há como medir diretamente bem-estar. No entanto, ele pode estar associado a respostas objetivas a questões do tipo:
  - Com qual frequência sentiu dores ou desconfortos na última semana?
  - Notou queda de cabelo ou dermatite desde a última sessão?

Exemplos de constructos

- Numa pesquisa com pacientes submetidos a quimioterapia, imaginemos que bem-estar seja um constructo.

- Não há como medir diretamente bem-estar. No entanto, ele pode estar associado a respostas objetivas a questões do tipo:
  - Com qual frequência sentiu dores ou desconfortos na última semana?
  - Notou queda de cabelo ou dermatite desde a última sessão?
  - Qual o nível de perda de apetite nos últimos dias?

Exemplos de constructos

- Numa pesquisa com pacientes submetidos a quimioterapia, imaginemos que bem-estar seja um constructo.

- Não há como medir diretamente bem-estar. No entanto, ele pode estar associado a respostas objetivas a questões do tipo:
  - Com qual frequência sentiu dores ou desconfortos na última semana?
  - Notou queda de cabelo ou dermatite desde a última sessão?
  - Qual o nível de perda de apetite nos últimos dias?
  - Com qual frequência tem apresentado dificuldades no seu trabalho ou nas tarefas domésticas?

Exemplos de constructos

- Adicionalmente, na pesquisa com pacientes de quimioterapia, além de bem-estar outros constructos poderiam ser identificados, como:

Exemplos de constructos

- Adicionalmente, na pesquisa com pacientes de quimioterapia, além de bem-estar outros constructos poderiam ser identificados, como:
  - Suporte familiar;

Exemplos de constructos

- Adicionalmente, na pesquisa com pacientes de quimioterapia, além de bem-estar outros constructos poderiam ser identificados, como:
  - Suporte familiar;
  - Expectativa de cura;

Exemplos de constructos

- Adicionalmente, na pesquisa com pacientes de quimioterapia, além de bem-estar outros constructos poderiam ser identificados, como:
  - Suporte familiar;
  - Expectativa de cura;
  - Estabilidade emocional;

Exemplos de constructos

- Adicionalmente, na pesquisa com pacientes de quimioterapia, além de bem-estar outros constructos poderiam ser identificados, como:
  - Suporte familiar;
  - Expectativa de cura;
  - Estabilidade emocional;
  - Integração com equipe médica, dentre outros.

Exemplos de constructos

- Da mesma forma como bem-estar não pode ser medido diretamente, sendo possível avaliá-lo indiretamente com base em variáveis mensuráveis, o mesmo se aplica a outros conceitos abstratos como:

Exemplos de constructos

- Da mesma forma como bem-estar não pode ser medido diretamente, sendo possível avaliá-lo indiretamente com base em variáveis mensuráveis, o mesmo se aplica a outros conceitos abstratos como:
  - Satisfação;

Exemplos de constructos

- Da mesma forma como bem-estar não pode ser medido diretamente, sendo possível avaliá-lo indiretamente com base em variáveis mensuráveis, o mesmo se aplica a outros conceitos abstratos como:
  - Satisfação;
  - Qualidade de vida;

Exemplos de constructos

- Da mesma forma como bem-estar não pode ser medido diretamente, sendo possível avaliá-lo indiretamente com base em variáveis mensuráveis, o mesmo se aplica a outros conceitos abstratos como:
  - Satisfação;
  - Qualidade de vida;
  - Insegurança;

Exemplos de constructos

- Da mesma forma como bem-estar não pode ser medido diretamente, sendo possível avaliá-lo indiretamente com base em variáveis mensuráveis, o mesmo se aplica a outros conceitos abstratos como:
  - Satisfação;
  - Qualidade de vida;
  - Insegurança;
  - Felicidade;

Exemplos de constructos

- Da mesma forma como bem-estar não pode ser medido diretamente, sendo possível avaliá-lo indiretamente com base em variáveis mensuráveis, o mesmo se aplica a outros conceitos abstratos como:
  - Satisfação;
  - Qualidade de vida;
  - Insegurança;
  - Felicidade;
  - Conhecimento...

Análise fatorial vs análise de componentes principais

Tabela 1: Principais diferenças entre análise de componentes principais e análise fatorial

Aspecto	**Análise de componentes principais**	**Análise Fatorial**
Objetivo principal	Redução de dimensionalidade	Explicar covariâncias via fatores latentes
Natureza	Técnica algébrica	Modelo estatístico
Componentes/Fatores	Combinações lineares observadas	Variáveis latentes não observáveis
Interpretação	Nem sempre interpretável	Interpretável (constructos)
Uso típico	Compressão e visualização	Identificação de constructos

Análise fatorial

- Na sequência é apresentada a matriz de correlações para as notas dos alunos de um colégio em cinco disciplinas: Espanhol, Inglês, Química, Física e Matemática.

Tabela 2: Matriz de correlações

	Espanhol	Inglês	Química	Física	Matemática
Espanhol	1	0.90	0.05	0.05	0.10
Inglês	0.90	1	0.05	0.10	0.05
Química	0.05	0.05	1	0.95	0.85
Física	0.05	0.10	0.95	1	0.90
Matemática	0.10	0.05	0.85	0.90	1

Análise fatorial

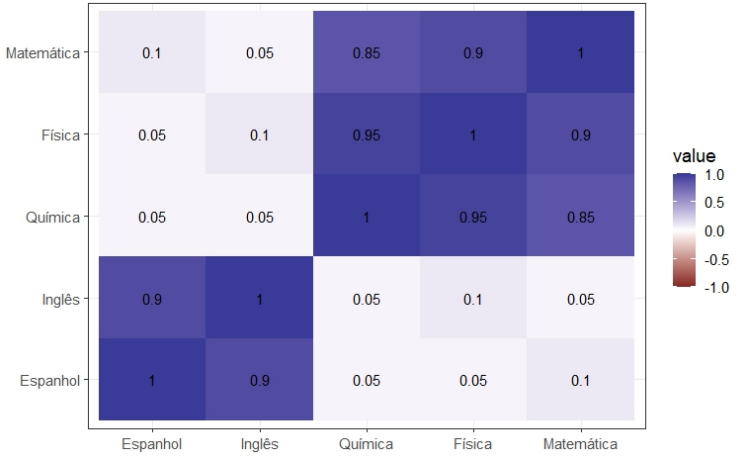


Figura 2: Gráfico de correlações

Análise fatorial

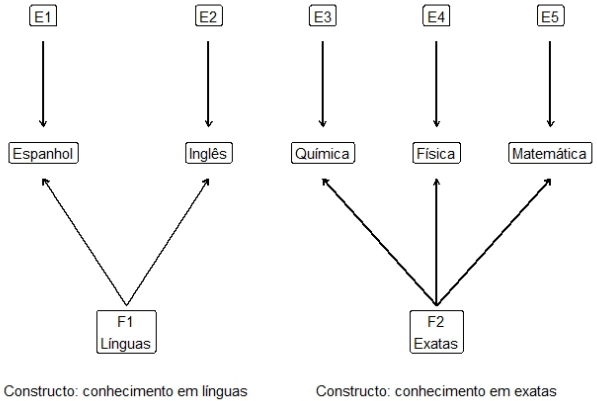


Figura 3: Ilustração dos fatores e constructos

Análise fatorial

- Com base nas correlações apresentadas, podemos **informalmente** identificar dois constructos:

Análise fatorial

- Com base nas correlações apresentadas, podemos **informalmente** identificar dois constructos:
  - **Constructo 1:** Conhecimento em línguas - associado aos desempenhos em Espanhol e Inglês, positivamente correlacionados;

Análise fatorial

- Com base nas correlações apresentadas, podemos **informalmente** identificar dois constructos:
  - **Constructo 1:** Conhecimento em línguas - associado aos desempenhos em Espanhol e Inglês, positivamente correlacionados;
  - **Constructo 2:** Conhecimento em ciências exatas - associado aos desempenhos em Química, Física e Matemática.

Análise fatorial

- Com base nas correlações apresentadas, podemos **informalmente** identificar dois constructos:
  - **Constructo 1:** Conhecimento em línguas - associado aos desempenhos em Espanhol e Inglês, positivamente correlacionados;
  - **Constructo 2:** Conhecimento em ciências exatas - associado aos desempenhos em Química, Física e Matemática.

- É importante reforçar que 'conhecimento' é algo que não se mede diretamente, mas que pode ser aferido com base em variáveis observáveis, como as notas obtidas nos exames.

Análise fatorial

- Há duas modalidades principais de análise fatorial.

Análise fatorial

- Há duas modalidades principais de análise fatorial.
  - **Análise fatorial exploratória:** quando os constructos não são conhecidos a priori, nem mesmo quantos constructos existem;

Análise fatorial

- Há duas modalidades principais de análise fatorial.
  - **Análise fatorial exploratória:** quando os constructos não são conhecidos a priori, nem mesmo quantos constructos existem;
  - **Análise fatorial confirmatória:** quando o número e a definição de constructos são estabelecidos a priori, e se deseja testar se os dados dão suporte a esses constructos.

Análise fatorial

- Há duas modalidades principais de análise fatorial.
  - **Análise fatorial exploratória:** quando os constructos não são conhecidos a priori, nem mesmo quantos constructos existem;
  - **Análise fatorial confirmatória:** quando o número e a definição de constructos são estabelecidos a priori, e se deseja testar se os dados dão suporte a esses constructos.

- Neste ponto do curso vamos tratar especificamente da análise fatorial exploratória.

Análise fatorial

- Situações inadequadas para análise fatorial:
  - Variáveis fracamente correlacionadas;

Análise fatorial

- Situações inadequadas para análise fatorial:
  - Variáveis fracamente correlacionadas;
  - Ausência de estrutura latente;

Análise fatorial

- Situações inadequadas para análise fatorial:
  - Variáveis fracamente correlacionadas;
  - Ausência de estrutura latente;
  - Variáveis redundantes/perfeitamente correlacionadas;

Análise fatorial

- Situações inadequadas para análise fatorial:
  - Variáveis fracamente correlacionadas;
  - Ausência de estrutura latente;
  - Variáveis redundantes/perfeitamente correlacionadas;
  - Amostra pequena;

Análise fatorial

- Situações inadequadas para análise fatorial:
  - Variáveis fracamente correlacionadas;
  - Ausência de estrutura latente;
  - Variáveis redundantes/perfeitamente correlacionadas;
  - Amostra pequena;
  - Variáveis medidas em escalas incompatíveis;

Análise fatorial

- Situações inadequadas para análise fatorial:
  - Variáveis fracamente correlacionadas;
  - Ausência de estrutura latente;
  - Variáveis redundantes/perfeitamente correlacionadas;
  - Amostra pequena;
  - Variáveis medidas em escalas incompatíveis;
  - Constructos pouco interpretáveis.

Situações inadequadas para análise fatorial

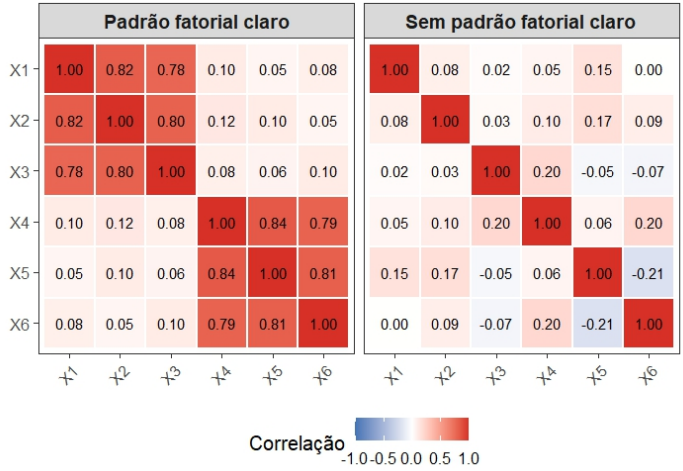


Figura 4: Variáveis com diferentes estruturas de correlações

Modelo de análise fatorial

Modelo de análise fatorial

- Os modelos de análise fatorial se subdividem em:

Modelo de análise fatorial

- Os modelos de análise fatorial se subdividem em:
  - **Modelo de análise fatorial ortogonal**- produz fatores comuns ortogonais (não correlacionados);

Modelo de análise fatorial

- Os modelos de análise fatorial se subdividem em:
  - **Modelo de análise fatorial ortogonal**- produz fatores comuns ortogonais (não correlacionados);
  - **Modelo de análise fatorial não ortogonal**- produz fatores comuns não ortogonais (correlacionados).

Modelo fatorial ortogonal

- Vamos considerar $\boldsymbol{Y}_1, \boldsymbol{Y}_2, ..., \boldsymbol{Y}_n$, onde $\boldsymbol{Y}_i' = (Y_{i1}, Y_{i2}, ..., Y_{ip})$ para $i = 1, 2, ..., n$, uma amostra aleatória de uma população com vetor de médias $\boldsymbol{\mu}' = (\mu_1, \mu_2, ..., \mu_p)$ e matriz de covariâncias $\boldsymbol{\Sigma}_{p \times p}$.

Modelo fatorial ortogonal

- Vamos considerar $\boldsymbol{Y}_1, \boldsymbol{Y}_2, ..., \boldsymbol{Y}_n$, onde $\boldsymbol{Y}_i' = (Y_{i1}, Y_{i2}, ..., Y_{ip})$ para $i = 1, 2, ..., n$, uma amostra aleatória de uma população com vetor de médias $\boldsymbol{\mu}' = (\mu_1, \mu_2, ..., \mu_p)$ e matriz de covariâncias $\boldsymbol{\Sigma}_{p \times p}$.
- Na análise fatorial, vamos expressar cada uma das p variáveis como combinação linear de $m < p$ *fatores comuns* $F_1, F_2, ..., F_m$ a menos de um termo correspondente ao erro $\epsilon_1, \epsilon_2, ..., \epsilon_p$:

Modelo fatorial ortogonal

- Vamos considerar $\boldsymbol{Y}_1, \boldsymbol{Y}_2, ..., \boldsymbol{Y}_n$, onde $\boldsymbol{Y}_i' = (Y_{i1}, Y_{i2}, ..., Y_{ip})$ para $i = 1, 2, ..., n$, uma amostra aleatória de uma população com vetor de médias $\boldsymbol{\mu}' = (\mu_1, \mu_2, ..., \mu_p)$ e matriz de covariâncias $\boldsymbol{\Sigma}_{p \times p}$.
- Na análise fatorial, vamos expressar cada uma das p variáveis como combinação linear de $m < p$ *fatores comuns* $F_1, F_2, ..., F_m$ a menos de um termo correspondente ao erro $\epsilon_1, \epsilon_2, ..., \epsilon_p$:

$$
\begin{aligned}
Y_1 - \mu_1 &= l_{11}F_1 + l_{12}F_2 + ... + l_{1m}F_m + \epsilon_1 \\
Y_2 - \mu_2 &= l_{21}F_1 + l_{22}F_2 + ... + l_{2m}F_m + \epsilon_2 \\
&\vdots \\
Y_p - \mu_p &= l_{p1}F_1 + l_{p2}F_2 + ... + l_{pm}F_m + \epsilon_p
\end{aligned}
$$

Modelo fatorial ortogonal

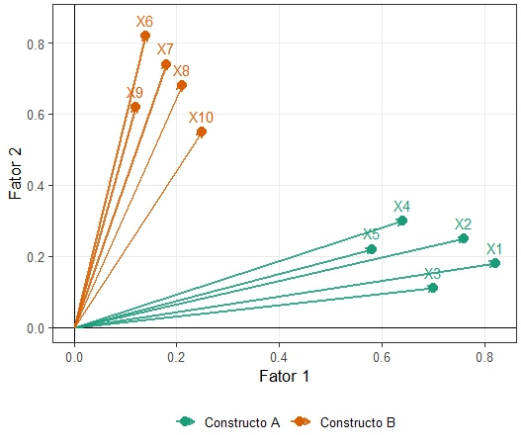


Figura 5: Ilustração de uma análise fatorial ortogonal com $p = 10$ variáveis e $m = 2$ fatores

Modelo fatorial ortogonal

- O modelo fatorial ortogonal pode ser representado na forma:

$$\boldsymbol{Y} - \boldsymbol{\mu} = \boldsymbol{LF} + \boldsymbol{\epsilon},$$

Modelo fatorial ortogonal

- O modelo fatorial ortogonal pode ser representado na forma:

$$\boldsymbol{Y} - \boldsymbol{\mu} = \boldsymbol{LF} + \boldsymbol{\epsilon},$$

sendo:

- $\boldsymbol{Y}' = (Y_1, Y_2, ..., Y_p)$ o vetor de variáveis aleatórias;

Modelo fatorial ortogonal

- O modelo fatorial ortogonal pode ser representado na forma:

$$\boldsymbol{Y} - \boldsymbol{\mu} = \boldsymbol{LF} + \boldsymbol{\epsilon},$$

sendo:

- $\boldsymbol{Y'} = (Y_1, Y_2, ..., Y_p)$ o vetor de variáveis aleatórias;
- $\boldsymbol{\mu'} = (\mu_1, \mu_2, ..., \mu_p)$ o vetor de médias;

Modelo fatorial ortogonal

- O modelo fatorial ortogonal pode ser representado na forma:

$$\boldsymbol{Y} - \boldsymbol{\mu} = \boldsymbol{LF} + \boldsymbol{\epsilon},$$

sendo:

- $\boldsymbol{Y}' = (Y_1, Y_2, ..., Y_p)$ o vetor de variáveis aleatórias;
- $\boldsymbol{\mu}' = (\mu_1, \mu_2, ..., \mu_p)$ o vetor de médias;
- $\boldsymbol{F}' = (F_1, F_2, ..., F_m)$ o vetor de fatores comuns;

Modelo fatorial ortogonal

- O modelo fatorial ortogonal pode ser representado na forma:

$$\boldsymbol{Y} - \boldsymbol{\mu} = \boldsymbol{LF} + \boldsymbol{\epsilon},$$

sendo:

- $\boldsymbol{Y}' = (Y_1, Y_2, ..., Y_p)$ o vetor de variáveis aleatórias;
- $\boldsymbol{\mu}' = (\mu_1, \mu_2, ..., \mu_p)$ o vetor de médias;
- $\boldsymbol{F}' = (F_1, F_2, ..., F_m)$ o vetor de fatores comuns;
- $\boldsymbol{\epsilon}' = (\epsilon_1, \epsilon_2, ..., \epsilon_p)$ os efeitos específicos (erros).

Modelo fatorial ortogonal

- E a matriz de cargas fatoriais:

$$\boldsymbol{L} = \begin{pmatrix} l_{11} & l_{12} & \dots & l_{1m} \\ l_{21} & l_{22} & \dots & l_{2m} \\ \vdots & \vdots & \ddots & \vdots \\ l_{p1} & l_{p2} & \dots & l_{pm} \end{pmatrix}$$

Suposições do modelo fatorial ortogonal

- As suposições inerentes ao modelo fatorial ortogonal são:

Suposições do modelo fatorial ortogonal

- As suposições inerentes ao modelo fatorial ortogonal são:

1. $E(\boldsymbol{F}) = \mathbf{0}$;

Suposições do modelo fatorial ortogonal

- As suposições inerentes ao modelo fatorial ortogonal são:

1. $E(\boldsymbol{F}) = \boldsymbol{0}$;
2. $Var(\boldsymbol{F}) = E(\boldsymbol{FF'}) = \boldsymbol{I}$;

Suposições do modelo fatorial ortogonal

- As suposições inerentes ao modelo fatorial ortogonal são:

1. $E(\boldsymbol{F}) = \boldsymbol{0}$;
2. $Var(\boldsymbol{F}) = E(\boldsymbol{FF'}) = \boldsymbol{I}$;
3. $E(\epsilon) = \boldsymbol{0}$;

Suposições do modelo fatorial ortogonal

4. $Var(\boldsymbol{\epsilon}) = E(\boldsymbol{\epsilon}\boldsymbol{\epsilon}') = \boldsymbol{\Psi}$,

com

$$\boldsymbol{\Psi} = \begin{pmatrix} \psi_1 & 0 & \dots & 0 \\ 0 & \psi_2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \psi_p \end{pmatrix}$$

Suposições do modelo fatorial ortogonal

4. $Var(\boldsymbol{\epsilon}) = E(\boldsymbol{\epsilon}\boldsymbol{\epsilon}') = \boldsymbol{\Psi}$,

com

$$\boldsymbol{\Psi} = \begin{pmatrix} \psi_1 & 0 & \dots & 0 \\ 0 & \psi_2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \psi_p \end{pmatrix}$$

5. $Cov(\boldsymbol{\epsilon}, \boldsymbol{F}) = E(\boldsymbol{\epsilon}\boldsymbol{F}') = \mathbf{0}$.

Propriedades do modelo fatorial ortogonal (baseadas na definição do modelo)

- $\text{Var}(\boldsymbol{Y}) = \boldsymbol{\Sigma} = \boldsymbol{L}\boldsymbol{L}' + \boldsymbol{\Psi}$;

Propriedades do modelo fatorial ortogonal (baseadas na definição do modelo)

- $\text{Var}(\boldsymbol{Y}) = \boldsymbol{\Sigma} = \boldsymbol{L}\boldsymbol{L}' + \boldsymbol{\Psi}$;

Prova:

$$\text{Var}(\boldsymbol{Y}) = \text{Var}(\boldsymbol{Y} - \boldsymbol{\mu}) = \text{Var}(\boldsymbol{L}\boldsymbol{F} + \epsilon) =$$

Propriedades do modelo fatorial ortogonal (baseadas na definição do modelo)

- $\text{Var}(\boldsymbol{Y}) = \boldsymbol{\Sigma} = \boldsymbol{LL'} + \boldsymbol{\Psi}$;

Prova:

$$\text{Var}(\boldsymbol{Y}) = \text{Var}(\boldsymbol{Y} - \boldsymbol{\mu}) = \text{Var}(\boldsymbol{LF} + \boldsymbol{\epsilon}) =$$

$$\boldsymbol{L}\text{Var}(\boldsymbol{F})\boldsymbol{L'} + \text{Var}(\boldsymbol{\epsilon}) = \boldsymbol{LIL'} + \psi = \boldsymbol{LL'} + \psi.$$

Propriedades do modelo fatorial ortogonal (baseadas na definição do modelo)

- $\text{Var}(\boldsymbol{Y}) = \boldsymbol{\Sigma} = \boldsymbol{LL'} + \boldsymbol{\Psi}$;

Prova:

$$\text{Var}(\boldsymbol{Y}) = \text{Var}(\boldsymbol{Y} - \boldsymbol{\mu}) = \text{Var}(\boldsymbol{LF} + \boldsymbol{\epsilon}) =$$

$$\boldsymbol{L}\text{Var}(\boldsymbol{F})\boldsymbol{L'} + \text{Var}(\boldsymbol{\epsilon}) = \boldsymbol{LIL'} + \psi = \boldsymbol{LL'} + \psi.$$

Propriedades do modelo fatorial ortogonal (baseadas na definição do modelo)

- $\text{Var}(Y_i) = l_{i1}^2 + l_{i2}^2 + ... + l_{im}^2 + \psi_i, \quad i = 1, 2, ..., p.$

Propriedades do modelo fatorial ortogonal (baseadas na definição do modelo)

- $\text{Var}(Y_i) = l_{i1}^2 + l_{i2}^2 + ... + l_{im}^2 + \psi_i, \quad i = 1, 2, ..., p.$

Prova:

$$\text{Var}(Y_i) = \text{Var}(Y_i - \mu_i) = \text{Var}(l_{i1}F_1 + l_{i2}F_2 + ... + l_{im}F_m + \epsilon_i) =$$

Propriedades do modelo fatorial ortogonal (baseadas na definição do modelo)

- $\text{Var}(Y_i) = l_{i1}^2 + l_{i2}^2 + ... + l_{im}^2 + \psi_i, \quad i = 1, 2, ..., p.$

Prova:

$$\text{Var}(Y_i) = \text{Var}(Y_i - \mu_i) = \text{Var}(l_{i1}F_1 + l_{i2}F_2 + ... + l_{im}F_m + \epsilon_i) =$$

$$l_{i1}^2\text{Var}(F_1) + l_{i2}^2\text{Var}(F_2) + ... + l_{im}^2\text{Var}(F_m) + \text{Var}(\epsilon_j) =$$

Propriedades do modelo fatorial ortogonal (baseadas na definição do modelo)

- $\text{Var}(Y_i) = l_{i1}^2 + l_{i2}^2 + ... + l_{im}^2 + \psi_i, \;\; i = 1, 2, ..., p.$

Prova:

$$\text{Var}(Y_i) = \text{Var}(Y_i - \mu_i) = \text{Var}(l_{i1}F_1 + l_{i2}F_2 + ... + l_{im}F_m + \epsilon_i) =$$

$$l_{i1}^2\text{Var}(F_1) + l_{i2}^2\text{Var}(F_2) + ... + l_{im}^2\text{Var}(F_m) + \text{Var}(\epsilon_j) =$$

$$l_{i1}^2 + l_{i2}^2 + ... + l_{im}^2 + \psi_i$$

Propriedades do modelo fatorial ortogonal (baseadas na definição do modelo)

- $\text{Cov}(\boldsymbol{Y}, \boldsymbol{F}) = \boldsymbol{L}$, de forma que $\text{Cov}(Y_i, F_j) = l_{ij}$.

Propriedades do modelo fatorial ortogonal (baseadas na definição do modelo)

- $\text{Cov}(\boldsymbol{Y}, \boldsymbol{F}) = \boldsymbol{L}$, de forma que $\text{Cov}(Y_i, F_j) = l_{ij}$.

Prova:

$$\text{Cov}(\boldsymbol{Y}, \boldsymbol{F}) = \text{Cov}(\boldsymbol{LF} + \boldsymbol{\epsilon}, \boldsymbol{F}) =$$

Propriedades do modelo fatorial ortogonal (baseadas na definição do modelo)

- $\text{Cov}(\boldsymbol{Y}, \boldsymbol{F}) = \boldsymbol{L}$, de forma que $\text{Cov}(Y_i, F_j) = l_{ij}$.

Prova:

$$\text{Cov}(\boldsymbol{Y}, \boldsymbol{F}) = \text{Cov}(\boldsymbol{LF} + \boldsymbol{\epsilon}, \boldsymbol{F}) =$$

$$\boldsymbol{L}\text{Cov}(\boldsymbol{F}, \boldsymbol{F}) + \text{Cov}(\boldsymbol{F}, \boldsymbol{\epsilon}) =$$

Propriedades do modelo fatorial ortogonal (baseadas na definição do modelo)

- $\text{Cov}(\boldsymbol{Y}, \boldsymbol{F}) = \boldsymbol{L}$, de forma que $\text{Cov}(Y_i, F_j) = l_{ij}$.

Prova:

$$\text{Cov}(\boldsymbol{Y}, \boldsymbol{F}) = \text{Cov}(\boldsymbol{LF} + \boldsymbol{\epsilon}, \boldsymbol{F}) =$$

$$\boldsymbol{L}\text{Cov}(\boldsymbol{F}, \boldsymbol{F}) + \text{Cov}(\boldsymbol{F}, \boldsymbol{\epsilon}) =$$

$$\boldsymbol{LI} + \boldsymbol{0} = \boldsymbol{L}$$

Propriedades do modelo fatorial ortogonal (baseadas na definição do modelo)

- $\text{Cor}(Y_i, F_j) = \frac{l_{ij}}{\sigma_i}$.

Propriedades do modelo fatorial ortogonal (baseadas na definição do modelo)

- $\text{Cor}(Y_i, F_j) = \frac{l_{ij}}{\sigma_i}$.

Prova:

$$\text{Cov}(Y_i, F_j) = \text{Cov}(l_{i1}F_1 + l_{i2}F_2 + ... + l_{im}F_m + \epsilon_i, F_j) =$$

Propriedades do modelo fatorial ortogonal (baseadas na definição do modelo)

- $\text{Cor}(Y_i, F_j) = \frac{l_{ij}}{\sigma_i}$.

Prova:

$$\text{Cov}(Y_i, F_j) = \text{Cov}(l_{i1}F_1 + l_{i2}F_2 + ... + l_{im}F_m + \epsilon_i, F_j) =$$

$$\text{Cov}(l_{ij}F_j, F_j) = l_{ij}\text{Cov}(F_j, F_j) = l_{ij}$$

Propriedades do modelo fatorial ortogonal (baseadas na definição do modelo)

- $\text{Cor}(Y_i, F_j) = \frac{l_{ij}}{\sigma_i}$.

Prova:

$$\text{Cov}(Y_i, F_j) = \text{Cov}(l_{i1}F_1 + l_{i2}F_2 + ... + l_{im}F_m + \epsilon_i, F_j) =$$

$$\text{Cov}(l_{ij}F_j, F_j) = l_{ij}\text{Cov}(F_j, F_j) = l_{ij}$$

$$\text{Cor}(Y_i, F_j) = \frac{\text{Cov}(Y_i, F_j)}{\sqrt{\text{Var}(Y_i)}\sqrt{\text{Var}(F_j)}} = \frac{l_{ij}}{\sigma_i}$$

Propriedades do modelo fatorial ortogonal

- **Nota:** Se as variáveis originais forem padronizadas a priori ($Z_i = \frac{Y_i - \mu_i}{\sigma_i}$, $i = 1, 2, ..., , p$) ainda valem as propriedades anteriores, destacando que $\text{Cor}(Y_i, F_j) = l_{ij}$.

Propriedades do modelo fatorial ortogonal

- Importante observar que sob o modelo fatorial ortogonal a variância de qualquer variável Y_i pode ser decomposta em dois componentes:

Propriedades do modelo fatorial ortogonal

- Importante observar que sob o modelo fatorial ortogonal a variância de qualquer variável Y_i pode ser decomposta em dois componentes:

$$\underbrace{\sigma_i^2}_{Var(Y_i)} = \underbrace{l_{i1}^2 + l_{i2}^2 + ... + l_{im}^2}_{Comunalidade} + \underbrace{\psi_i}_{Especificidade}$$

Propriedades do modelo fatorial ortogonal

- Importante observar que sob o modelo fatorial ortogonal a variância de qualquer variável Y_i pode ser decomposta em dois componentes:

$$\underbrace{\sigma_i^2}_{Var(Y_i)} = \underbrace{l_{i1}^2 + l_{i2}^2 + ... + l_{im}^2}_{Comunalidade} + \underbrace{\psi_i}_{Especificidade}$$

- Uma parte da variação de Y_i explicada pelos m fatores comuns, denominada **comunalidade**; outra parte da variação de Y_i não explicada pelos m fatores comuns, sendo específica da variável, denominada **especificidade**.

Propriedades do modelo fatorial ortogonal

- Importante observar que sob o modelo fatorial ortogonal a variância de qualquer variável Y_i pode ser decomposta em dois componentes:

$$\underbrace{\sigma_i^2}_{Var(Y_i)} = \underbrace{l_{i1}^2 + l_{i2}^2 + ... + l_{im}^2}_{Comunalidade} + \underbrace{\psi_i}_{Especificidade}$$

- Uma parte da variação de Y_i explicada pelos m fatores comuns, denominada **comunalidade**; outra parte da variação de Y_i não explicada pelos m fatores comuns, sendo específica da variável, denominada **especificidade**.
- Usando notações convencionais, $h_i^2 \sum_{j=1}^{m} l_{ij}^2 = l_{i1}^2 + l_{i2}^2 + ... + l_{im}^2$, de tal forma que:

$$\sigma_i^2 = h_i^2 + \psi_i, \qquad i = 1, 2, ..., p.$$

Propriedades do modelo fatorial ortogonal

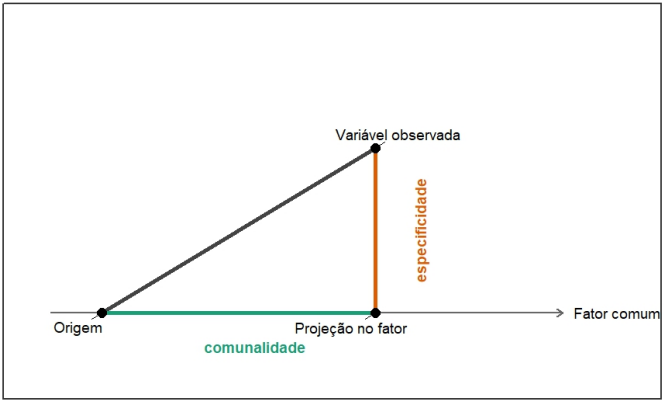


Figura 6: Representação geométrica da comunalidade e especificidade

Propriedades do modelo fatorial ortogonal

- A porcentagem da variação de Y_i explicada pelos m fatores comuns fica dada por:

$$100 \times \frac{h_i^2}{\sigma_i^2}\%$$

Propriedades do modelo fatorial ortogonal

- A porcentagem da variação de Y_i explicada pelos m fatores comuns fica dada por:

$$100 \times \frac{h_i^2}{\sigma_i^2}\%$$

- Se as variáveis forem padronizadas, então a porcentagem da variação de Y_i explicada pelos m fatores comuns será simplesmente $100 \times h_i^2\%$.

Propriedades do modelo fatorial ortogonal

- A porcentagem da variação de Y_i explicada pelos m fatores comuns fica dada por:

$$100 \times \frac{h_i^2}{\sigma_i^2}\%$$

- Se as variáveis forem padronizadas, então a porcentagem da variação de Y_i explicada pelos m fatores comuns será simplesmente $100 \times h_i^2\%$.

- A porcentagem da variação total explicada pelo fator j, por sua vez, é dada por:

$$100 \times \sum_{i=1}^{p} \frac{l_{ij}^2}{\sigma^2_{\text{Total}}}\%, \quad \sigma^2_{\text{Total}} = \sigma_1^2 + \sigma_2^2 + ...\sigma_p^2,$$

e, caso as variáveis forem padronizadas a priori, se resume a $100 \times \sum_{i=1}^{p} \frac{l_{ij}^2}{p}\%$.

Exercícios

- Resolva os exercícios 1 a 3 da primeira lista de exercícios, relativa a este módulo, disponibilizada na página da disciplina.

Determinação do número de fatores

Determinação do número de fatores

- Assim como no caso da análise de componentes principais, a determinação do número de fatores comuns é uma etapa importante da análise fatorial.

Determinação do número de fatores

- Assim como no caso da análise de componentes principais, a determinação do número de fatores comuns é uma etapa importante da análise fatorial.

- Um importante indicador para essa determinação é a porcentagem da variação total dos dados explicada pelos fatores comuns (algo como 70 a 80% costuma ser desejável, mas isso pode variar dependendo do problema).

Determinação do número de fatores

- Assim como no caso da análise de componentes principais, a determinação do número de fatores comuns é uma etapa importante da análise fatorial.

- Um importante indicador para essa determinação é a porcentagem da variação total dos dados explicada pelos fatores comuns (algo como 70 a 80% costuma ser desejável, mas isso pode variar dependendo do problema).

- Adicionalmente, os critérios baseados nos autovalores da matriz de correlações (ou covariâncias), como o critério de Kaiser, avaliação do screeplot, ou análise paralela, continuam válidos.

Determinação do número de fatores

- Além de critérios estatísticos, outros pontos devem ser considerados na determinação do número de fatores:

Determinação do número de fatores

- Além de critérios estatísticos, outros pontos devem ser considerados na determinação do número de fatores:
  - Interpretação prática dos resultados;

Determinação do número de fatores

- Além de critérios estatísticos, outros pontos devem ser considerados na determinação do número de fatores:
  - Interpretação prática dos resultados;
  - Busca de uma solução parcimoniosa;

Determinação do número de fatores

- Além de critérios estatísticos, outros pontos devem ser considerados na determinação do número de fatores:
  - Interpretação prática dos resultados;
  - Busca de uma solução parcimoniosa;
  - Possíveis indícios do número de fatores segundo a teoria da área;

Determinação do número de fatores

- Além de critérios estatísticos, outros pontos devem ser considerados na determinação do número de fatores:
  - Interpretação prática dos resultados;
  - Busca de uma solução parcimoniosa;
  - Possíveis indícios do número de fatores segundo a teoria da área;
  - Bom senso.

Métodos de estimação

Métodos de estimação

- Há diversos métodos disponíveis para estimação dos parâmetros de um modelo de análise fatorial, dentre os quais:

Métodos de estimação

- Há diversos métodos disponíveis para estimação dos parâmetros de um modelo de análise fatorial, dentre os quais:
  - Método dos componentes principais;

Métodos de estimação

- Há diversos métodos disponíveis para estimação dos parâmetros de um modelo de análise fatorial, dentre os quais:
  - Método dos componentes principais;
  - Método dos fatores principais;

Métodos de estimação

- Há diversos métodos disponíveis para estimação dos parâmetros de um modelo de análise fatorial, dentre os quais:
  - Método dos componentes principais;
  - Método dos fatores principais;
  - Máxima verossimilhança;

Métodos de estimação

- Há diversos métodos disponíveis para estimação dos parâmetros de um modelo de análise fatorial, dentre os quais:
  - Método dos componentes principais;
  - Método dos fatores principais;
  - Máxima verossimilhança;
  - Mínimos quadrados;

Métodos de estimação

- Há diversos métodos disponíveis para estimação dos parâmetros de um modelo de análise fatorial, dentre os quais:
  - Método dos componentes principais;
  - Método dos fatores principais;
  - Máxima verossimilhança;
  - Mínimos quadrados;
  - Mínimos quadrados ponderados.

Métodos de estimação- Método dos componentes principais

- Considere $\boldsymbol{y_1}, \boldsymbol{y_2}, \ldots, \boldsymbol{y_n}$ uma amostra aleatória da população sob estudo, com matriz de covariância amostral $\boldsymbol{S}$. Nesse caso, vamos procurar uma aproximação para $\boldsymbol{S}$ da forma:

$$\boldsymbol{S} \approx \hat{\boldsymbol{L}}\hat{\boldsymbol{L}}' + \hat{\boldsymbol{\Psi}}.$$

Métodos de estimação- Método dos componentes principais

- Considere $\boldsymbol{y_1}, \boldsymbol{y_2}, \ldots, \boldsymbol{y_n}$ uma amostra aleatória da população sob estudo, com matriz de covariância amostral $\boldsymbol{S}$. Nesse caso, vamos procurar uma aproximação para $\boldsymbol{S}$ da forma:

$$\boldsymbol{S} \approx \hat{\boldsymbol{L}}\hat{\boldsymbol{L}}' + \hat{\boldsymbol{\Psi}}.$$

- Uma maneira de fazer isso é por meio da decomposição espectral de $\boldsymbol{S}$:

$$\boldsymbol{S} = \boldsymbol{P}\boldsymbol{\Lambda}\boldsymbol{P}',$$

sendo $\boldsymbol{\Lambda}$ a matriz diagonal de autovalores e $\boldsymbol{P}$ a matriz ortogonal de autovetores de $\boldsymbol{S}$.

Métodos de estimação- Método dos componentes principais

- Podemos fatorar $\mathbf{\Lambda} = \mathbf{\Lambda}^{1/2}\mathbf{\Lambda}^{1/2}$, tal que:

$$\mathbf{\Lambda}^{1/2} = \begin{pmatrix} \sqrt{\lambda}_1 & 0 & \dots & 0 \\ 0 & \sqrt{\lambda}_2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \sqrt{\lambda}_p \end{pmatrix}$$

Métodos de estimação- Método dos componentes principais

- Podemos fatorar $\boldsymbol{\Lambda} = \boldsymbol{\Lambda}^{1/2}\boldsymbol{\Lambda}^{1/2}$, tal que:

$$\boldsymbol{\Lambda}^{1/2} = \begin{pmatrix} \sqrt{\lambda}_1 & 0 & \dots & 0 \\ 0 & \sqrt{\lambda}_2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \sqrt{\lambda}_p \end{pmatrix}$$

- Assim, $\boldsymbol{S}$ pode ser escrita na forma:

$$\boldsymbol{S} = (\boldsymbol{P}\boldsymbol{\Lambda}^{1/2})(\boldsymbol{P}\boldsymbol{\Lambda}^{1/2})'$$

Métodos de estimação- Método dos componentes principais

- Portanto, se considerarmos os p autovetores e autovalores, a matriz de covariâncias segundo o modelo de análise fatorial, pode ser fatorada da seguinte forma:

$$\boldsymbol{S} = \underbrace{(\boldsymbol{P}\boldsymbol{\Lambda}^{1/2})}_{\boldsymbol{L}}\underbrace{(\boldsymbol{P}\boldsymbol{\Lambda}^{1/2})'}_{\boldsymbol{L}'} + \underbrace{\mathbf{0}}_{\boldsymbol{\Psi}},$$

de tal maneira que a matriz de covariâncias fica reproduzida exatamente pelos p componentes principais.

Métodos de estimação- Método dos componentes principais

- Portanto, se considerarmos os p autovetores e autovalores, a matriz de covariâncias segundo o modelo de análise fatorial, pode ser fatorada da seguinte forma:

$$\boldsymbol{S} = \underbrace{(\boldsymbol{P}\boldsymbol{\Lambda}^{1/2})}_{\boldsymbol{L}}\underbrace{(\boldsymbol{P}\boldsymbol{\Lambda}^{1/2})'}_{\boldsymbol{L}'} + \underbrace{\boldsymbol{0}}_{\boldsymbol{\Psi}},$$

de tal maneira que a matriz de covariâncias fica reproduzida exatamente pelos p componentes principais.

- Se considerarmos apenas $m < p$ componentes principais, a igualdade não será verificada (teremos apenas uma aproximação), dando origem às especificidades.

Métodos de estimação- Método dos componentes principais

- Seja $\boldsymbol{S}$ a matriz de covariâncias amostral, com autovalores e autovetores $(\hat{\lambda}_1, \hat{\boldsymbol{e}}_1), (\hat{\lambda}_2, \hat{\boldsymbol{e}}_2), ..., (\hat{\lambda}_p, \hat{\boldsymbol{e}}_p)$, com $\hat{\lambda}_1 \geq \hat{\lambda}_2 \geq ... \geq \hat{\lambda}_p$.

Métodos de estimação- Método dos componentes principais

- Seja $\boldsymbol{S}$ a matriz de covariâncias amostral, com autovalores e autovetores $(\hat{\lambda}_1, \hat{\boldsymbol{e}}_1), (\hat{\lambda}_2, \hat{\boldsymbol{e}}_2), ..., (\hat{\lambda}_p, \hat{\boldsymbol{e}}_p)$, com $\hat{\lambda}_1 \geq \hat{\lambda}_2 \geq ... \geq \hat{\lambda}_p$.
- Considerando $m < p$ o número de fatores comuns, a matriz de cargas fatoriais, estimada pelo método dos componentes principais, fica dada por:

Métodos de estimação- Método dos componentes principais

- Seja $\boldsymbol{S}$ a matriz de covariâncias amostral, com autovalores e autovetores $(\hat{\lambda}_1, \hat{\boldsymbol{e}}_1), (\hat{\lambda}_2, \hat{\boldsymbol{e}}_2), ..., (\hat{\lambda}_p, \hat{\boldsymbol{e}}_p)$, com $\hat{\lambda}_1 \geq \hat{\lambda}_2 \geq ... \geq \hat{\lambda}_p$.
- Considerando $m < p$ o número de fatores comuns, a matriz de cargas fatoriais, estimada pelo método dos componentes principais, fica dada por:

$$\hat{\boldsymbol{L}} = \left[\sqrt{\hat{\lambda}_1}\hat{\boldsymbol{e}}_1 \vdots \sqrt{\hat{\lambda}_2}\hat{\boldsymbol{e}}_2 \vdots \cdots \vdots \sqrt{\hat{\lambda}_m}\hat{\boldsymbol{e}}_m \right] =$$

$$\begin{pmatrix} \sqrt{\lambda}_1 e_{11} & \sqrt{\lambda}_2 e_{21} & \dots & \sqrt{\lambda}_m e_{m1} \\ \sqrt{\lambda}_1 e_{12} & \sqrt{\lambda}_2 e_{22} & \dots & \sqrt{\lambda}_m e_{m2} \\ \vdots & \vdots & \ddots & \vdots \\ \sqrt{\lambda}_1 e_{1p} & \sqrt{\lambda}_2 e_{2p} & \dots & \sqrt{\lambda}_m e_{mp} \end{pmatrix}$$

Métodos de estimação- Método dos componentes principais

- As variâncias especificas ficam estimadas por $\hat{\boldsymbol{\Psi}} = \text{diag}(\boldsymbol{S} - \hat{\boldsymbol{L}}\hat{\boldsymbol{L}}')$, com:

$$\hat{\boldsymbol{\Psi}} = \begin{pmatrix} \hat{\psi}_1 & 0 & \dots & 0 \\ 0 & \hat{\psi}_2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \hat{\psi}_p \end{pmatrix},$$

Métodos de estimação- Método dos componentes principais

- As variâncias especificas ficam estimadas por $\hat{\boldsymbol{\Psi}} = \text{diag}(\boldsymbol{S} - \hat{\boldsymbol{L}}\hat{\boldsymbol{L}}')$, com:

$$\hat{\boldsymbol{\Psi}} = \begin{pmatrix} \hat{\psi}_1 & 0 & \dots & 0 \\ 0 & \hat{\psi}_2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \hat{\psi}_p \end{pmatrix},$$

sendo $\hat{\psi}_i = s_i^2 - \sum_{j=1}^{m} \hat{h}_i^2$ a especificidade correspondente à i-ésima variável (Y_i), e

$$\hat{h}_i^2 = \hat{l}_{i1}^2 + \hat{l}_{i2}^2 + ... + \hat{l}_{im}^2$$

a comunalidade.

Métodos de estimação- Método dos componentes principais

- Notas:

Métodos de estimação- Método dos componentes principais

- Notas:

1. A análise fatorial por componentes principais pode ser baseada na matriz de correlações ($\boldsymbol{R}$) ao invés da matriz de covariâncias ($\boldsymbol{S}$), para se contornar o problema de variáveis com diferentes escalas.

Métodos de estimação- Método dos componentes principais

- Notas:

1. A análise fatorial por componentes principais pode ser baseada na matriz de correlações ($\boldsymbol{R}$) ao invés da matriz de covariâncias ($\boldsymbol{S}$), para se contornar o problema de variáveis com diferentes escalas.

2. Para a solução via método ACP as cargas fatoriais de um particular fator não se alteram quando acrescentamos novos fatores à análise.

Métodos de estimação- Método dos componentes principais

- Notas:

1. A análise fatorial por componentes principais pode ser baseada na matriz de correlações ($\boldsymbol{R}$) ao invés da matriz de covariâncias ($\boldsymbol{S}$), para se contornar o problema de variáveis com diferentes escalas.

2. Para a solução via método ACP as cargas fatoriais de um particular fator não se alteram quando acrescentamos novos fatores à análise.

3. Os elementos da diagonal de $\boldsymbol{(\hat{L}\hat{L}' + \hat{\Psi})}$ são iguais aos correspondentes elementos de $\boldsymbol{S}$. Os demais elementos, no entanto, são apenas aproximações.

Métodos de estimação- Método dos fatores principais (ou eixos principais)

- No método dos componentes principais fatoramos $\boldsymbol{S}$ (ou $\boldsymbol{R}$).

Métodos de estimação- Método dos fatores principais (ou eixos principais)

- No método dos componentes principais fatoramos $\boldsymbol{S}$ (ou $\boldsymbol{R}$).
- Já no método de fatores principais fatoramos $\boldsymbol{S} - \hat{\boldsymbol{\Psi}}$ (ou $\boldsymbol{R} - \hat{\boldsymbol{\Psi}}$), ou seja, apenas a parte de $\boldsymbol{S}$ (ou $\boldsymbol{R}$) correspondente à variância comum.

Métodos de estimação- Método dos fatores principais (ou eixos principais)

- No método dos componentes principais fatoramos $\boldsymbol{S}$ (ou $\boldsymbol{R}$).
- Já no método de fatores principais fatoramos $\boldsymbol{S} - \hat{\boldsymbol{\Psi}}$ (ou $\boldsymbol{R} - \hat{\boldsymbol{\Psi}}$), ou seja, apenas a parte de $\boldsymbol{S}$ (ou $\boldsymbol{R}$) correspondente à variância comum.
- Para isso, devemos inicialmente encontrar uma estimativa inicial para $\boldsymbol{\Psi}$ ($\hat{\boldsymbol{\Psi}}$).

Métodos de estimação- Método dos fatores principais (ou eixos principais)

- No método dos componentes principais fatoramos $\boldsymbol{S}$ (ou $\boldsymbol{R}$).
- Já no método de fatores principais fatoramos $\boldsymbol{S} - \hat{\boldsymbol{\Psi}}$ (ou $\boldsymbol{R} - \hat{\boldsymbol{\Psi}}$), ou seja, apenas a parte de $\boldsymbol{S}$ (ou $\boldsymbol{R}$) correspondente à variância comum.
- Para isso, devemos inicialmente encontrar uma estimativa inicial para $\boldsymbol{\Psi}$ ($\hat{\boldsymbol{\Psi}}$).
- Então, determinamos $\hat{L}$ tal que:

$$\boldsymbol{S} - \hat{\boldsymbol{\Psi}} \approx \hat{\boldsymbol{L}}\hat{\boldsymbol{L}}', \text{ ou } \boldsymbol{R} - \hat{\boldsymbol{\Psi}} \approx \hat{\boldsymbol{L}}\hat{\boldsymbol{L}}',$$

usando os m primeiros autovetores e autovalores de $\boldsymbol{S} - \hat{\boldsymbol{\Psi}}$ (ou $\boldsymbol{R} - \hat{\boldsymbol{\Psi}}$).

Métodos de estimação- Método dos fatores principais (ou eixos principais)

- Uma vez que $\hat{\psi}_i = 1 - \hat{h}_i$, $i = 1, 2, ..., p$, temos:

$$\boldsymbol{S} - \hat{\boldsymbol{\Psi}} = \begin{pmatrix} \hat{h}_1^2 & s_{12} & \dots & s_{1p} \\ s_{21} & \hat{h}_2^2 & \dots & s_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ s_{p1} & s_{p2} & \dots & \hat{h}_p^2 \end{pmatrix}.$$

Métodos de estimação- Método dos fatores principais (ou eixos principais)

- Uma forma usual (mas não a única) de estimar $\hat{h}_i$ é por $\hat{h}_i = R_i^2$, em que R_i^2 é o quadrado do coeficiente de correlação múltipla de y_i nas outras p variáveis, calculado por:

$$R_i^2 = 1 - \frac{1}{r_{ii}}, \text{ para } \boldsymbol{R}, \text{ ou } s_{ii} - \frac{1}{s_{ii}}, \text{ para } \boldsymbol{S}, i = 1, 2, ..., p,$$

sendo r_{ii} e s_{ii} os elementos da diagonal de $\boldsymbol{R}^{-1}$ e $\boldsymbol{S}^{-1}$, respectivamente.

Métodos de estimação- Método dos fatores principais (ou eixos principais)

- Uma forma usual (mas não a única) de estimar $\hat{h}_i$ é por $\hat{h}_i = R_i^2$, em que R_i^2 é o quadrado do coeficiente de correlação múltipla de y_i nas outras p variáveis, calculado por:

$$R_i^2 = 1 - \frac{1}{r_{ii}}, \text{ para } \boldsymbol{R}, \text{ ou } s_{ii} - \frac{1}{s_{ii}}, \text{ para } \boldsymbol{S}, i = 1, 2, ..., p,$$

sendo r_{ii} e s_{ii} os elementos da diagonal de $\boldsymbol{R}^{-1}$ e $\boldsymbol{S}^{-1}$, respectivamente.

- Após estimadas as comunalidades, aplica-se o método das componentes principais em $\boldsymbol{S} - \hat{\boldsymbol{\Psi}}$ (ou $\boldsymbol{R} - \hat{\boldsymbol{\Psi}}$), extraindo-se a matriz de cargas fatoriais $\hat{\boldsymbol{L}}$.

Métodos de estimação- Método dos fatores principais (ou eixos principais)

- Uma forma usual (mas não a única) de estimar $\hat{h}_i$ é por $\hat{h}_i = R_i^2$, em que R_i^2 é o quadrado do coeficiente de correlação múltipla de y_i nas outras p variáveis, calculado por:

$$R_i^2 = 1 - \frac{1}{r_{ii}}, \text{ para } \boldsymbol{R}, \text{ ou } s_{ii} - \frac{1}{s_{ii}}, \text{ para } \boldsymbol{S}, i = 1, 2, ..., p,$$

sendo r_{ii} e s_{ii} os elementos da diagonal de $\boldsymbol{R}^{-1}$ e $\boldsymbol{S}^{-1}$, respectivamente.

- Após estimadas as comunalidades, aplica-se o método das componentes principais em $\boldsymbol{S} - \hat{\boldsymbol{\Psi}}$ (ou $\boldsymbol{R} - \hat{\boldsymbol{\Psi}}$), extraindo-se a matriz de cargas fatoriais $\hat{\boldsymbol{L}}$.

Nota - As matrizes $\boldsymbol{S} - \hat{\boldsymbol{\Psi}}$ (e $\boldsymbol{R} - \hat{\boldsymbol{\Psi}}$) não são, necessariamente, positivas definidas, podendo produzir autovalores negativos!

Métodos de estimação- Método dos fatores principais (ou eixos principais)

- O método dos fatores principais pode ser aplicado iterativamente, seguindo os passos:

Métodos de estimação- Método dos fatores principais (ou eixos principais)

- O método dos fatores principais pode ser aplicado iterativamente, seguindo os passos:

1. Defiinir a estimativa inicial das comunalidades;

Métodos de estimação- Método dos fatores principais (ou eixos principais)

- O método dos fatores principais pode ser aplicado iterativamente, seguindo os passos:

1. Defiinir a estimativa inicial das comunalidades;
2. Usar as estimativas disponíveis para as comunalidades para obter a matriz $\boldsymbol{S} - \hat{\boldsymbol{\Psi}}$ (ou $\boldsymbol{R} - \hat{\boldsymbol{\Psi}}$);

Métodos de estimação- Método dos fatores principais (ou eixos principais)

3. Aplicar a análise de componentes principais na matriz obtida no passo 2, para estimar as cargas fatoriais e extrair as comunalidades, por:

$$\hat{h}_j^2 = \sum_{i=1}^{m} \hat{l}_{ij}^2, \quad j = 1, 2, ..., p;$$

Métodos de estimação- Método dos fatores principais (ou eixos principais)

3. Aplicar a análise de componentes principais na matriz obtida no passo 2, para estimar as cargas fatoriais e extrair as comunalidades, por:

$$\hat{h}_j^2 = \sum_{i=1}^{m} \hat{l}_{ij}^2, \quad j = 1, 2, ..., p;$$

4. Usando as comunalidades obtidas no passo 3, repetir os passos 2 e 3 até que as comunalidades estimadas apresentem convergência.

Métodos de estimação- Método da máxima verossimilhança

- Se assumirmos que $\boldsymbol{Y_1}, \boldsymbol{Y_2}, ..., \boldsymbol{Y_n}$ constituem uma amostra aleatória de uma distribuição $N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$, então $\boldsymbol{L}, \boldsymbol{\Psi}$ podem ser estimados usando o método da máxima verossimilhança.

Métodos de estimação- Método da máxima verossimilhança

- Se assumirmos que $\boldsymbol{Y_1}, \boldsymbol{Y_2}, ..., \boldsymbol{Y_n}$ constituem uma amostra aleatória de uma distribuição $N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$, então $\boldsymbol{L}, \boldsymbol{\Psi}$ podem ser estimados usando o método da máxima verossimilhança.

- Para o modelo fatorial ortogonal $\boldsymbol{Y} - \boldsymbol{\mu} = \boldsymbol{LF} + \boldsymbol{\epsilon}$, a função de verossimilhança, assumindo normalidade, fica dada por:

$$L(\boldsymbol{\mu}, \boldsymbol{\Sigma}) = (2\pi)^{\frac{-np}{2}} |\boldsymbol{\Sigma}|^{-\frac{n}{2}} \times e^{-\frac{1}{2} tr\left[\boldsymbol{\Sigma}^{-1}\left(\sum_{j=1}^{n} (y_j - \bar{y})(y_j - \bar{y})' + n(\bar{y} - \mu)(\bar{y} - \mu)'\right)\right]}.$$

Métodos de estimação - Método da máxima verossimilhança

- $L(\mu, \mathbf{\Sigma})$ depende das matrizes de carregamentos $\boldsymbol{L}$ e de variâncias específicas $\mathbf{\Psi}$ através de $\mathbf{\Sigma} = \boldsymbol{L}\boldsymbol{L}' + \mathbf{\Psi}$.

Métodos de estimação - Método da máxima verossimilhança

- $L(\mu, \mathbf{\Sigma})$ depende das matrizes de carregamentos $\boldsymbol{L}$ e de variâncias específicas $\mathbf{\Psi}$ através de $\mathbf{\Sigma} = \boldsymbol{L}\boldsymbol{L}' + \mathbf{\Psi}$.

- A estimação por máxima verossimilhança se dá pela maximização de $L(\mu, \mathbf{\Sigma})$ com relação a $\mu, \boldsymbol{L}$ e $\mathbf{\Psi}$.

Métodos de estimação - Método da máxima verossimilhança

- $L(\mu, \mathbf{\Sigma})$ depende das matrizes de carregamentos $\boldsymbol{L}$ e de variâncias específicas $\mathbf{\Psi}$ através de $\mathbf{\Sigma} = \boldsymbol{L}\boldsymbol{L}' + \mathbf{\Psi}$.

- A estimação por máxima verossimilhança se dá pela maximização de $L(\mu, \mathbf{\Sigma})$ com relação a $\mu, \boldsymbol{L}$ e $\mathbf{\Psi}$.

- Como trataremos adiante, no entanto, não há solução única para $\boldsymbol{L}$, o que torna o modelo não identificável. Isso pode ser contornado impondo uma condição de unicidade:

$$\boldsymbol{L}\mathbf{\Psi}^{-1}\boldsymbol{L} \quad \text{é uma matriz diagonal}$$

Métodos de estimação - Método da máxima verossimilhança

- $L(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ depende das matrizes de carregamentos $\boldsymbol{L}$ e de variâncias específicas $\boldsymbol{\Psi}$ através de $\boldsymbol{\Sigma} = \boldsymbol{L}\boldsymbol{L}' + \boldsymbol{\Psi}$.

- A estimação por máxima verossimilhança se dá pela maximização de $L(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ com relação a $\boldsymbol{\mu}, \boldsymbol{L}$ e $\boldsymbol{\Psi}$.

- Como trataremos adiante, no entanto, não há solução única para $\boldsymbol{L}$, o que torna o modelo não identificável. Isso pode ser contornado impondo uma condição de unicidade:

$$\boldsymbol{L}\boldsymbol{\Psi}^{-1}\boldsymbol{L} \quad \text{é uma matriz diagonal}$$

- A maximização da função de verossimilhança somente é possível por meio de métodos numéricos, podendo eventualmente produzir problemas de convergência.

Exercícios

- Resolva os exercícios 4 e 5 da primeira lista de exercícios, relativa a este módulo, disponibilizada na página da disciplina.

Rotação dos fatores

Rotação dos fatores

- Numa análise fatorial ortogonal, se multiplicarmos a matriz de cargas $\boldsymbol{L}$ por uma matriz ortogonal $\boldsymbol{T}$ qualquer, a matriz de cargas transformadas:

$$\boldsymbol{L}^* = \boldsymbol{LT}, \text{ onde } \boldsymbol{TT}' = \boldsymbol{T}'\boldsymbol{T} = \boldsymbol{I}$$

satisfaz às suposições do modelo fatorial, fornecendo igual aproximação para a matriz de covariâncias:

$$\boldsymbol{\Sigma} \approx \boldsymbol{L}^*\boldsymbol{L}^{*'} + \boldsymbol{\Psi} = \boldsymbol{LTT}'\boldsymbol{L}' + \boldsymbol{\Psi} = \boldsymbol{LL}' + \boldsymbol{\Psi}$$

Rotação dos fatores

- Desta forma, não se tem solução única no ajuste de um modelo fatorial ortogonal, dispondo-se de soluções com desempenho equivalente para cada matriz $\boldsymbol{T}$.

Rotação dos fatores

- Desta forma, não se tem solução única no ajuste de um modelo fatorial ortogonal, dispondo-se de soluções com desempenho equivalente para cada matriz $\boldsymbol{T}$.

- O efeito de multiplicar a matriz de cargas fatoriais por uma matriz ortogonal é o de uma **rotação** rígida nos eixos definidos pelos fatores originais.

Rotação dos fatores

- Rotações são usadas na análise fatorial visando identificar uma estrutura de fatores mais simples, em que cada variável original seja fortemente correlacionada a um fator e pouco correlacionada com os demais.

Rotação dos fatores

- Rotações são usadas na análise fatorial visando identificar uma estrutura de fatores mais simples, em que cada variável original seja fortemente correlacionada a um fator e pouco correlacionada com os demais.

- Com isso se reduz possíveis ambiguidades, facilitando a interpretação dos resultados.

Rotação dos fatores

- Rotações são usadas na análise fatorial visando identificar uma estrutura de fatores mais simples, em que cada variável original seja fortemente correlacionada a um fator e pouco correlacionada com os demais.

- Com isso se reduz possíveis ambiguidades, facilitando a interpretação dos resultados.

- Embora maior ênfase seja dada às rotações ortogonais, vamos tratar também das rotações não ortogonais.

Tipos de rotação

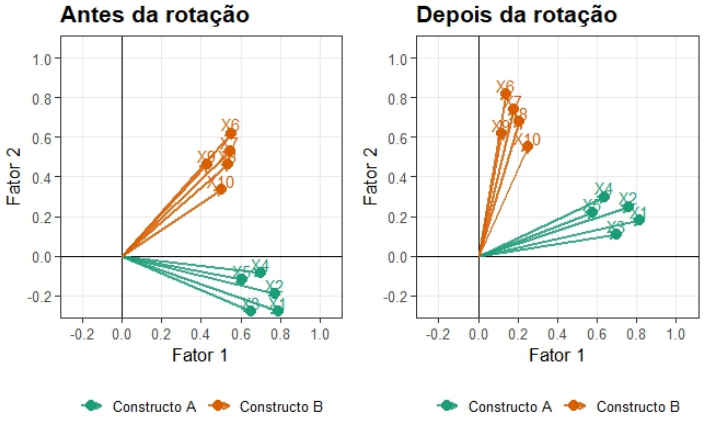


Figura 7: Ilustração de uma rotação ortogonal

Rotação ortogonal

- Uma forma simples, mas bastante limitada, de proceder a rotação, é através da inspeção gráfica das cargas fatoriais e determinação do ângulo θ associado à rotação.

Rotação ortogonal

- Uma forma simples, mas bastante limitada, de proceder a rotação, é através da inspeção gráfica das cargas fatoriais e determinação do ângulo θ associado à rotação.

- A matriz ortogonal responsável por uma rotação de ângulo θ, considerando dois fatores, é dada por:

$$\boldsymbol{T} = \begin{pmatrix} \cos\theta & -\sin\theta \\ \sin\theta & \cos\theta \end{pmatrix}$$

Rotação ortogonal varimax

- A rotação por inspeção visual é limitada ao caso de dois fatores, e a escolha do ângulo é subjetiva.

Rotação ortogonal varimax

- A rotação por inspeção visual é limitada ao caso de dois fatores, e a escolha do ângulo é subjetiva.

- Um dos crtérios mais usuais para rotação ortogonal dos fatores é a **rotação varimax**.

Rotação ortogonal varimax

- A rotação por inspeção visual é limitada ao caso de dois fatores, e a escolha do ângulo é subjetiva.

- Um dos crtérios mais usuais para rotação ortogonal dos fatores é a **rotação varimax**.

- O método de rotação varimax consiste na determinação da matriz ortogonal $\boldsymbol{T}$ que produza $\hat{\boldsymbol{L}}^* = \boldsymbol{T}'\hat{\boldsymbol{L}}$ tal que a variância das novas cargas fatoriais (escalonadas pelas comunalidades) seja máxima.

Rotação ortogonal varimax

- Sejam $\tilde{l}_{ij}^{*} = \hat{l}_{ij}^{*}/\hat{h}_i$ as cargas fatoriais escalonadas pelas raízes quadradas das respectivas comunalidades. Devemos escolher a transformação $\boldsymbol{T}$ que maximize:

$$V = \frac{1}{p}\sum_{j=1}^{m}\left[\sum_{i=1}^{p}\tilde{l}_{ij}^{*4} - \frac{\left(\sum_{i=1}^{p}\tilde{l}_{ij}^{*2}\right)^2}{p}\right]$$

que é proporcional à soma das variâncias das cargas fatoriais nos m fatores.

Rotação ortogonal varimax

- Sejam $\tilde{l}_{ij}^{*} = \hat{l}_{ij}^{*}/\hat{h}_i$ as cargas fatoriais escalonadas pelas raízes quadradas das respectivas comunalidades. Devemos escolher a transformação $\boldsymbol{T}$ que maximize:

$$V = \frac{1}{p}\sum_{j=1}^{m}\left[\sum_{i=1}^{p}\tilde{l}_{ij}^{*4} - \frac{\left(\sum_{i=1}^{p}\tilde{l}_{ij}^{*2}\right)^2}{p}\right]$$

que é proporcional à soma das variâncias das cargas fatoriais nos m fatores.

- O objetivo de escalonar as cargas fatoriais pelas comunalidades é atribuir às variáveis com menores comunalidades maior peso na determinação de uma estrutura rotacionada.

Rotação ortogonal varimax

- Sejam $\tilde{l}_{ij}^{*} = \hat{l}_{ij}^{*}/\hat{h}_i$ as cargas fatoriais escalonadas pelas raízes quadradas das respectivas comunalidades. Devemos escolher a transformação $\boldsymbol{T}$ que maximize:

$$V = \frac{1}{p}\sum_{j=1}^{m}\left[\sum_{i=1}^{p}\tilde{l}_{ij}^{*4} - \frac{\left(\sum_{i=1}^{p}\tilde{l}_{ij}^{*2}\right)^2}{p}\right]$$

que é proporcional à soma das variâncias das cargas fatoriais nos m fatores.

- O objetivo de escalonar as cargas fatoriais pelas comunalidades é atribuir às variáveis com menores comunalidades maior peso na determinação de uma estrutura rotacionada.

- Após a transformação $\boldsymbol{T}$ ser determinada, as cargas $\tilde{l}_{ij}^{*}$ são multiplicadas por $\hat{h}_i$ tal que as comunalidades originais sejam preservadas.

Rotações ortagonais

- Outros métodos de rotação ortogonal são:

Rotações ortagonais

- Outros métodos de rotação ortogonal são:
  - Quartimax;

Rotações ortagonais

- Outros métodos de rotação ortogonal são:
  - Quartimax;
  - Equamax;

Rotações ortagonais

- Outros métodos de rotação ortogonal são:
  - Quartimax;
  - Equamax;
  - Varimin;

Rotações ortagonais

- Outros métodos de rotação ortogonal são:
  - Quartimax;
  - Equamax;
  - Varimin;
  - Bifactor, dentre outros.

Rotações ortagonais

- Outros métodos de rotação ortogonal são:
  - Quartimax;
  - Equamax;
  - Varimin;
  - Bifactor, dentre outros.

- Para mais informações sobre rotações ortogonais e não ortogonais, consultar a documentação da função `fa` da biblioteca `psych`.

Exercícios

- Resolva o exercício 6 da primeira lista de exercícios, relativa a este módulo, disponibilizada na página da disciplina.

Rotações ortogonais vs rotações oblíquas

- Uma rotação ortogonal corresponde a uma rotação rígida do conjunto de fatores originais.

Rotações ortogonais vs rotações oblíquas

- Uma rotação ortogonal corresponde a uma rotação rígida do conjunto de fatores originais.

- Em contraposição, uma rotação oblíqua corresponde a uma rotação não rígida, em que o sistema de coordenadas é rotacionado de forma não perpendicular.

Rotações ortogonais vs rotações oblíquas

- Uma rotação ortogonal corresponde a uma rotação rígida do conjunto de fatores originais.
- Em contraposição, uma rotação oblíqua corresponde a uma rotação não rígida, em que o sistema de coordenadas é rotacionado de forma não perpendicular.
- Algumas consequências de uma rotação oblíqua:

Rotações ortogonais vs rotações oblíquas

- Uma rotação ortogonal corresponde a uma rotação rígida do conjunto de fatores originais.
- Em contraposição, uma rotação oblíqua corresponde a uma rotação não rígida, em que o sistema de coordenadas é rotacionado de forma não perpendicular.
- Algumas consequências de uma rotação oblíqua:
  - A produção de fatores não ortogonais (correlacionados);

Rotações ortogonais vs rotações oblíquas

- Uma rotação ortogonal corresponde a uma rotação rígida do conjunto de fatores originais.
- Em contraposição, uma rotação oblíqua corresponde a uma rotação não rígida, em que o sistema de coordenadas é rotacionado de forma não perpendicular.
- Algumas consequências de uma rotação oblíqua:
  - A produção de fatores não ortogonais (correlacionados);
  - A não preservação da matriz de covariâncias obtida pela solução original.

Rotações ortogonais vs rotações oblíquas

- Seja $\boldsymbol{T}_{(m \times m)}$ uma matriz não ortogonal e $\boldsymbol{L}^* = \boldsymbol{LT}$. Então:

$$\boldsymbol{L}^*(\boldsymbol{L}^*)' + \boldsymbol{\Psi} = (\boldsymbol{LT})(\boldsymbol{LT})' + \boldsymbol{\Psi} = \boldsymbol{LTT}'\boldsymbol{L}' + \boldsymbol{\Psi} \neq \boldsymbol{LL}' + \boldsymbol{\Psi}$$

Rotações ortogonais vs rotações oblíquas

- Seja $\boldsymbol{T}_{(m\times m)}$ uma matriz não ortogonal e $\boldsymbol{L}^* = \boldsymbol{LT}$. Então:

$$\boldsymbol{L}^*(\boldsymbol{L}^*)' + \boldsymbol{\Psi} = (\boldsymbol{LT})(\boldsymbol{LT})' + \boldsymbol{\Psi} = \boldsymbol{LTT}'\boldsymbol{L}' + \boldsymbol{\Psi} \neq \boldsymbol{LL}' + \boldsymbol{\Psi}$$

- Uma rotação oblíqua pode ser usada para verificar a proximidade da solução obtida à produzida por uma rotação ortogonal. Se as duas soluções forem similares, isso indica a ortogonalidade dos fatores comuns.

Rotações oblíquas

- Rotações oblíquas são apropriadas caso não seja razoável admitir que os fatores comuns produzidos por uma AF sejam não correlacionados.

Rotações oblíquas

- Rotações oblíquas são apropriadas caso não seja razoável admitir que os fatores comuns produzidos por uma AF sejam não correlacionados.

- Vários métodos estão implementados para execução de rotações oblíquas, dentre as quais as mais usuais são `promax` e `oblimin`.

Rotações oblíquas

- Rotações oblíquas são apropriadas caso não seja razoável admitir que os fatores comuns produzidos por uma AF sejam não correlacionados.

- Vários métodos estão implementados para execução de rotações oblíquas, dentre as quais as mais usuais são `promax` e `oblimin`.

- Como resultado de uma rotação oblíqua, temos as seguintes matrizes:

Rotações oblíquas

- Rotações oblíquas são apropriadas caso não seja razoável admitir que os fatores comuns produzidos por uma AF sejam não correlacionados.

- Vários métodos estão implementados para execução de rotações oblíquas, dentre as quais as mais usuais são `promax` e `oblimin`.

- Como resultado de uma rotação oblíqua, temos as seguintes matrizes:
  - `pattern matrix`: Contém as coordenadas das variáveis em relação aos eixos oblíquos;

Rotações oblíquas

- Rotações oblíquas são apropriadas caso não seja razoável admitir que os fatores comuns produzidos por uma AF sejam não correlacionados.

- Vários métodos estão implementados para execução de rotações oblíquas, dentre as quais as mais usuais são `promax` e `oblimin`.

- Como resultado de uma rotação oblíqua, temos as seguintes matrizes:
  - `pattern matrix`: Contém as coordenadas das variáveis em relação aos eixos oblíquos;
  - `structure matrix`: Contém as correlações entre os fatores rotacionados e as variáveis originais;

Rotações oblíquas

- Rotações oblíquas são apropriadas caso não seja razoável admitir que os fatores comuns produzidos por uma AF sejam não correlacionados.

- Vários métodos estão implementados para execução de rotações oblíquas, dentre as quais as mais usuais são `promax` e `oblimin`.

- Como resultado de uma rotação oblíqua, temos as seguintes matrizes:
  - `pattern matrix`: Contém as coordenadas das variáveis em relação aos eixos oblíquos;
  - `structure matrix`: Contém as correlações entre os fatores rotacionados e as variáveis originais;
  - `correlation matrix`: Contém as correlações entre os fatores comuns rotacionados.

Escores fatoriais

Escores fatoriais

- Na análise fatorial o objetivo principal é a estimação dos parâmetros do modelo (cargas fatoriais e variâncias específicas), de forma a derivar os fatores comuns e avaliar a qualidade do ajuste.

Escores fatoriais

- Na análise fatorial o objetivo principal é a estimação dos parâmetros do modelo (cargas fatoriais e variâncias específicas), de forma a derivar os fatores comuns e avaliar a qualidade do ajuste.

- Muitas vezes é de interesse também calcular escores baseados nos fatores comuns para os indivíduos sob estudo $\hat{\boldsymbol{F}}_i = (\hat{F}_{i1}, \hat{F}_{i2}, ..., \hat{F}_{im})', i = 1, 2, ..., n$.

Escores fatoriais

- Na análise fatorial o objetivo principal é a estimação dos parâmetros do modelo (cargas fatoriais e variâncias específicas), de forma a derivar os fatores comuns e avaliar a qualidade do ajuste.

- Muitas vezes é de interesse também calcular escores baseados nos fatores comuns para os indivíduos sob estudo $\hat{\boldsymbol{F}}_i = (\hat{F}_{i1}, \hat{F}_{i2}, ..., \hat{F}_{im})', i = 1, 2, ..., n$.

- Escores podem ser usados como índices, que permitem quantificar os constructos (satisfação, felicidade, ansiedade...) para cada indivíduo.

Escores fatoriais

- Na análise fatorial o objetivo principal é a estimação dos parâmetros do modelo (cargas fatoriais e variâncias específicas), de forma a derivar os fatores comuns e avaliar a qualidade do ajuste.

- Muitas vezes é de interesse também calcular escores baseados nos fatores comuns para os indivíduos sob estudo $\hat{\boldsymbol{F}}_i = (\hat{F}_{i1}, \hat{F}_{i2}, ..., \hat{F}_{im})', i = 1, 2, ..., n$.

- Escores podem ser usados como índices, que permitem quantificar os constructos (satisfação, felicidade, ansiedade...) para cada indivíduo.

- Os escores fatoriais podem ser aplicados em outras técnicas multivariadas, como variáveis dependentes (ou independentes) em modelos de regressão...

Escores fatoriais - Método dos mínimos quadrados ponderados (Método de Bartlett)

- Há diferentes métodos para predição dos escores fatoriais. Vamos destacar aqui o método de mínimos quadrados ponderados.

Escores fatoriais - Método dos mínimos quadrados ponderados (Método de Bartlett)

- Há diferentes métodos para predição dos escores fatoriais. Vamos destacar aqui o método de mínimos quadrados ponderados.

- Retomando o modelo fatorial original $\boldsymbol{Y} - \boldsymbol{\mu} = \boldsymbol{LF} + \boldsymbol{\epsilon}$, podemos expressar o vetor de erros $\boldsymbol{\epsilon} = (\epsilon_1, \epsilon_1, ..., \epsilon_p)$ por:

$$\boldsymbol{\epsilon} = \boldsymbol{y} - \boldsymbol{\mu} - \boldsymbol{LF},$$

com $\text{Var}(\epsilon_i) = \psi_i, i = 1, 2, ..., p$.

Escores fatoriais - Método dos mínimos quadrados ponderados (Método de Bartlett)

- O método de mínimos quadrados ponderados baseia-se na minimização da soma de quadrados dos erros ponderada pelo inverso das variâncias:

$$SQE = \sum_{i=1}^{n} \frac{\epsilon_i^2}{\psi_i} = (\boldsymbol{y} - \boldsymbol{\mu} - \boldsymbol{LF})' \boldsymbol{\Psi}^{-1} (\boldsymbol{y} - \boldsymbol{\mu} - \boldsymbol{LF})$$

.

Escores fatoriais - Método dos mínimos quadrados ponderados (Método de Bartlett)

- O método de mínimos quadrados ponderados baseia-se na minimização da soma de quadrados dos erros ponderada pelo inverso das variâncias:

$$SQE = \sum_{i=1}^{n} \frac{\epsilon_i^2}{\psi_i} = (\boldsymbol{y} - \boldsymbol{\mu} - \boldsymbol{LF})' \boldsymbol{\Psi}^{-1} (\boldsymbol{y} - \boldsymbol{\mu} - \boldsymbol{LF})$$

.

- Derivando-se SQE com relação a $\boldsymbol{F}$ e igualando a zero, obtém-se $\hat{\boldsymbol{F}}$, que minimiza SQE.

Escores fatoriais - Método dos mínimos quadrados ponderados (Método de Bartlett)

- O método de mínimos quadrados ponderados baseia-se na minimização da soma de quadrados dos erros ponderada pelo inverso das variâncias:

$$SQE = \sum_{i=1}^{n} \frac{\epsilon_i^2}{\psi_i} = (\boldsymbol{y} - \boldsymbol{\mu} - \boldsymbol{LF})'\boldsymbol{\Psi}^{-1}(\boldsymbol{y} - \boldsymbol{\mu} - \boldsymbol{LF})$$

.

- Derivando-se SQE com relação a $\boldsymbol{F}$ e igualando a zero, obtém-se $\hat{\boldsymbol{F}}$, que minimiza SQE.
- A solução fica dada por:

$$\hat{\boldsymbol{F}} = (\boldsymbol{L}'\boldsymbol{\Psi}\boldsymbol{L})^{-1}\boldsymbol{L}\boldsymbol{\Psi}^{-1}(\boldsymbol{y} - \boldsymbol{\mu}).$$

Escores fatoriais - Método dos mínimos quadrados ponderados (Método de Bartlett)

- Os escores fatoriais são obtidos, para o $i-$ésimo indivíduo, substituindo-se os parâmetros do modelo pelas respectivas estimativas:

$$\hat{\boldsymbol{F}}_i = (\hat{\boldsymbol{L}}'\hat{\boldsymbol{\Psi}}\hat{\boldsymbol{L}})^{-1}\hat{\boldsymbol{L}}\hat{\boldsymbol{\Psi}}^{-1}(\boldsymbol{y}_i - \bar{\boldsymbol{y}}), \quad i = 1, 2, ..., n.$$

Escores fatoriais - Método dos mínimos quadrados ponderados (Método de Bartlett)

- Os escores fatoriais são obtidos, para o $i-$ésimo indivíduo, substituindo-se os parâmetros do modelo pelas respectivas estimativas:

$$\hat{\boldsymbol{F}}_{\boldsymbol{i}} = (\hat{\boldsymbol{L}}'\hat{\boldsymbol{\Psi}}\hat{\boldsymbol{L}})^{-1}\hat{\boldsymbol{L}}\hat{\boldsymbol{\Psi}}^{-1}(\boldsymbol{y_i} - \bar{\boldsymbol{y}}), \quad i = 1, 2, ..., n.$$

- Se usarmos rotação, tal que $\hat{\boldsymbol{L}}^* = \hat{\boldsymbol{L}}\boldsymbol{T}$, então os novos escores ficam dados por $\hat{\boldsymbol{F}}_{\boldsymbol{i}}^* = \boldsymbol{T}'\hat{\boldsymbol{F}}_{\boldsymbol{i}}, i = 1, 2, ..., n.$

Escores fatoriais

- Outros métodos usados para obtenção dos escores fatoriais são:

Escores fatoriais

- Outros métodos usados para obtenção dos escores fatoriais são:
  - Método de Thurstone;

Escores fatoriais

- Outros métodos usados para obtenção dos escores fatoriais são:
  - Método de Thurstone;
  - Método de Anderson;

Escores fatoriais

- Outros métodos usados para obtenção dos escores fatoriais são:
  - Método de Thurstone;
  - Método de Anderson;
  - Método de Harman;

Escores fatoriais

- Outros métodos usados para obtenção dos escores fatoriais são:
  - Método de Thurstone;
  - Método de Anderson;
  - Método de Harman;
  - Método dos componentes, dentre outros.

Escores fatoriais

- Outros métodos usados para obtenção dos escores fatoriais são:
  - Método de Thurstone;
  - Método de Anderson;
  - Método de Harman;
  - Método dos componentes, dentre outros.

- Para mais informações sobre os métodos de obtenção de escores, consultar a documentação da função `factor.scores` da biblioteca `psych`.

Adequabilidade da análise fatorial

Adequabilidade da análise fatorial

- Existem diferentes critérios para avaliação da adequação do ajuste do modelo de análise fatorial.

Adequabilidade da análise fatorial

- Existem diferentes critérios para avaliação da adequação do ajuste do modelo de análise fatorial.

- Uma forma simples de se avaliar isso é pela comparação da matriz de covariâncias (ou correlações) amostral (S) e a matriz de covariâncias estimada pelo modelo ($\hat{\Sigma} = \boldsymbol{LL'}$).

Adequabilidade da análise fatorial

- Existem diferentes critérios para avaliação da adequação do ajuste do modelo de análise fatorial.

- Uma forma simples de se avaliar isso é pela comparação da matriz de covariâncias (ou correlações) amostral (S) e a matriz de covariâncias estimada pelo modelo ($\hat{\Sigma} = \boldsymbol{LL'}$).

- Pode-se proceder essa comparação calculando a matriz de covariâncias (correlações) residual:

$$S_{\text{Res}} = S - \hat{\Sigma}$$

Adequabilidade da análise fatorial

- Existem diferentes critérios para avaliação da adequação do ajuste do modelo de análise fatorial.
- Uma forma simples de se avaliar isso é pela comparação da matriz de covariâncias (ou correlações) amostral (S) e a matriz de covariâncias estimada pelo modelo ($\hat{\Sigma} = \boldsymbol{LL'}$).
- Pode-se proceder essa comparação calculando a matriz de covariâncias (correlações) residual:

$$S_{\text{Res}} = S - \hat{\Sigma}$$

- Se o modelo tiver bem ajustado, espera-se valores pequenos para os elementos de S_{Res}.

Raiz do quadrado médio residual

- Baseado na comparação das matrizes de covariâncias amostral e ajustada pelo modelo, podemos calcular um indicador de qualidade de ajuste denominado *raiz do quadrado médio residual*, calculado da seguinte forma:

$$\text{RQMR} = \sqrt{\frac{\sum_{i=1}^{p}\sum_{j>i}^{p}(s_{ij} - \hat{\sigma}_{ij})^2}{p(p-1)/2}},$$

em que $\hat{\sigma}_{ij}$ representa os elementos da matriz $\hat{\boldsymbol{\Sigma}} = \boldsymbol{LL'}$.

Raiz do quadrado médio residual

- Baseado na comparação das matrizes de covariâncias amostral e ajustada pelo modelo, podemos calcular um indicador de qualidade de ajuste denominado *raiz do quadrado médio residual*, calculado da seguinte forma:

$$\text{RQMR} = \sqrt{\frac{\sum_{i=1}^{p}\sum_{j>i}^{p}(s_{ij} - \hat{\sigma}_{ij})^2}{p(p-1)/2}},$$

em que $\hat{\sigma}_{ij}$ representa os elementos da matriz $\hat{\boldsymbol{\Sigma}} = \boldsymbol{LL'}$.

- O acréscimo no valor de RQMR produzido pela adição de fatores adicionais à análise pode ser mais um recurso para determinação do número de fatores (m).

Estatística de ajuste das correlações amostrais

- Podemos avaliar o quanto as correlações produzidas pelo modelo fatorial (r_{ij}^*) reproduzem as verdadeiras correlações amostrais (r_{ij}) por meio da seguinte estatística:

$$\text{fit} = \frac{\sum_{i=1}^{p} \sum_{j \neq i}^{p} r_{ij}^2 - \sum_{i=1}^{p} \sum_{j \neq i}^{p} r_{ij}^{*2}}{\sum_{j \neq i}^{p} r_{ij}^2}$$

Estatística de ajuste das correlações amostrais

- Podemos avaliar o quanto as correlações produzidas pelo modelo fatorial (r_{ij}^*) reproduzem as verdadeiras correlações amostrais (r_{ij}) por meio da seguinte estatística:

$$\text{fit} = \frac{\sum_{i=1}^{p} \sum_{j \neq i}^{p} r_{ij}^2 - \sum_{i=1}^{p} \sum_{j \neq i}^{p} r_{ij}^{*2}}{\sum_{j \neq i}^{p} r_{ij}^2}$$

- Quanto menor o valor da estatística `fit`, melhor a adequação do modelo.

Teste de esfericidade de Bartlett

- O teste de esfericidade de Bartlett permite testar a hipótese nula de ausência de correlação entre as variáveis, ou seja, que a matriz de correlações é diagonal.

Teste de esfericidade de Bartlett

- O teste de esfericidade de Bartlett permite testar a hipótese nula de ausência de correlação entre as variáveis, ou seja, que a matriz de correlações é diagonal.

- Neste caso, a análise fatorial somente será viável se a hipótese nula for rejeitada.

Teste de esfericidade de Bartlett

- O teste de esfericidade de Bartlett permite testar a hipótese nula de ausência de correlação entre as variáveis, ou seja, que a matriz de correlações é diagonal.
- Neste caso, a análise fatorial somente será viável se a hipótese nula for rejeitada.
- Seja R a matriz de correlações amostral. A estatística do teste de Bartlett é dada por:

$$\mathrm{X}^2 = -\left[(n-1) - \frac{2p+5}{6}\right] \log|\mathrm{R}|$$

Teste de esfericidade de Bartlett

- O teste de esfericidade de Bartlett permite testar a hipótese nula de ausência de correlação entre as variáveis, ou seja, que a matriz de correlações é diagonal.
- Neste caso, a análise fatorial somente será viável se a hipótese nula for rejeitada.
- Seja R a matriz de correlações amostral. A estatística do teste de Bartlett é dada por:

$$\mathrm{X}^2 = -\left[(n-1) - \frac{2p+5}{6}\right] \log|\mathrm{R}|$$

- A hipótese nula deverá ser rejeitada, para um nível de significância α, se $\mathrm{X}^2 > \chi^2_{\frac{p(p-1)}{2}}(1-\alpha)$.

Critério de Kaiser-Meyer-Olkin (KMO)

- O critério de Kaiser-Meyer-Olkin visa avaliar se há uma estrutura de dependência clara entre as variáveis.

Critério de Kaiser-Meyer-Olkin (KMO)

- O critério de Kaiser-Meyer-Olkin visa avaliar se há uma estrutura de dependência clara entre as variáveis.

- Baseia-se na comparação dos valores das correlações (r_{ij}) com as correspondentes correlações parciais (a_{ij}), que é a correlação entre as variáveis y_i e y_j ajustados os efeitos das demais variáveis.

Critério de Kaiser-Meyer-Olkin (KMO)

- O critério de Kaiser-Meyer-Olkin visa avaliar se há uma estrutura de dependência clara entre as variáveis.

- Baseia-se na comparação dos valores das correlações (r_{ij}) com as correspondentes correlações parciais (a_{ij}), que é a correlação entre as variáveis y_i e y_j ajustados os efeitos das demais variáveis.

- Neste caso, espera-se que os valores de a_{ij} sejam pequenos em relação aos correspondentes r_{ij}, indicando a interdependência existente no conjunto de variáveis.

Critério de Kaiser-Meyer-Olkin (KMO)

- A estatística KMO é definida por:

$$\text{KMO} = \frac{\sum_{i=1}^{p} \sum_{j \neq i}^{p} r_{ij}^2}{\sum_{i=1}^{p} \sum_{j \neq i}^{p} r_{ij}^2 + \sum_{i=1}^{p} \sum_{j \neq i}^{p} a_{ij}^2}$$

- Há diferentes sugestões de interpretação para o valor de KMO, dentre elas a apresentada na sequência:

Critério de Kaiser-Meyer-Olkin (KMO)

- A estatística KMO é definida por:

$$\text{KMO} = \frac{\sum_{i=1}^{p}\sum_{j\neq i}^{p} r_{ij}^2}{\sum_{i=1}^{p}\sum_{j\neq i}^{p} r_{ij}^2 + \sum_{i=1}^{p}\sum_{j\neq i}^{p} a_{ij}^2}$$

- Há diferentes sugestões de interpretação para o valor de KMO, dentre elas a apresentada na sequência:

Tabela 3: Sugestão de interpretação do KMO

KMO	Interpretação
0.80-1.00	Excelente
0.70-0.80	Ótimo
0.60-0.70	Bom
0.50-0.60	Regular
< 0.50	Insuficiente

Measure of sample adequacy (MSA)

- O MSA é um desmembramento do índice KMO que permite verificar a adequação do modelo para cada particular variável, sendo definida por:

$$\text{MSA}_i = \frac{\sum_{j \neq i}^{p} r_{ij}^2}{\sum_{j \neq i}^{p} r_{ij}^2 + \sum_{j \neq i}^{p} a_{ij}^2}, \qquad i = 1, 2, ..., p.$$

Measure of sample adequacy (MSA)

- O MSA é um desmembramento do índice KMO que permite verificar a adequação do modelo para cada particular variável, sendo definida por:

$$\text{MSA}_i = \frac{\sum_{j \neq i}^{p} r_{ij}^2}{\sum_{j \neq i}^{p} r_{ij}^2 + \sum_{j \neq i}^{p} a_{ij}^2}, \qquad i = 1, 2, ..., p.$$

- O objetivo da medida é verificar se uma variável é bem explicada pelas demais, sendo que valores de MSA próximos a zero indicam baixa explicação, enquanto valores próximos a 1 indicam boa explicação.

Measure of sample adequacy (MSA)

- O MSA é um desmembramento do índice KMO que permite verificar a adequação do modelo para cada particular variável, sendo definida por:

$$\text{MSA}_i = \frac{\sum_{j \neq i}^{p} r_{ij}^2}{\sum_{j \neq i}^{p} r_{ij}^2 + \sum_{j \neq i}^{p} a_{ij}^2}, \qquad i = 1, 2, ..., p.$$

- O objetivo da medida é verificar se uma variável é bem explicada pelas demais, sendo que valores de MSA próximos a zero indicam baixa explicação, enquanto valores próximos a 1 indicam boa explicação.

- A interpretação apresentada para o KMO pode se aplicar ao MSA para cada variável.

Exercícios

- Resolva os exercícios da segunda lista de exercícios, relativa a este módulo, disponibilizada na página da disciplina.

Roteiro da análise fatorial

Roteiro da análise fatorial

1. Padronizar as variáveis (se necessário);

Roteiro da análise fatorial

1. Padronizar as variáveis (se necessário);
2. Calcular matriz de correlações;

Roteiro da análise fatorial

1. Padronizar as variáveis (se necessário);
2. Calcular matriz de correlações;
3. Verificar adequação (KMO, teste de Bartlett);

Roteiro da análise fatorial

1. Padronizar as variáveis (se necessário);
2. Calcular matriz de correlações;
3. Verificar adequação (KMO, teste de Bartlett);
4. Determinar o número de fatores (screeplot, critério de Kaiser, análise paralela);

Roteiro da análise fatorial

1. Padronizar as variáveis (se necessário);
2. Calcular matriz de correlações;
3. Verificar adequação (KMO, teste de Bartlett);
4. Determinar o número de fatores (screeplot, critério de Kaiser, análise paralela);
5. Estimar cargas fatoriais (L);

Roteiro da análise fatorial

1. Padronizar as variáveis (se necessário);
2. Calcular matriz de correlações;
3. Verificar adequação (KMO, teste de Bartlett);
4. Determinar o número de fatores (screeplot, critério de Kaiser, análise paralela);
5. Estimar cargas fatoriais (L);
6. Rotacionar a solução (Varimax, Promax);

Roteiro da análise fatorial

1. Padronizar as variáveis (se necessário);
2. Calcular matriz de correlações;
3. Verificar adequação (KMO, teste de Bartlett);
4. Determinar o número de fatores (screeplot, critério de Kaiser, análise paralela);
5. Estimar cargas fatoriais (L);
6. Rotacionar a solução (Varimax, Promax);
7. Interpretar os fatores;

Roteiro da análise fatorial

1. Padronizar as variáveis (se necessário);
2. Calcular matriz de correlações;
3. Verificar adequação (KMO, teste de Bartlett);
4. Determinar o número de fatores (screeplot, critério de Kaiser, análise paralela);
5. Estimar cargas fatoriais (L);
6. Rotacionar a solução (Varimax, Promax);
7. Interpretar os fatores;
8. Avaliar comunalidades

Exemplo 1

Exemplo 1

- A título de ilustração, vamos supor que um conjunto de quatro variáveis (Y_1, Y_2, Y_3 e Y_4) apresentem a seguinte matriz de covariâncias:

$$\Sigma = \begin{bmatrix} 4.00 & 0.80 & 1.68 & 2.16 \\ 0.80 & 2.00 & 0.44 & 0.96 \\ 1.68 & 0.44 & 2.00 & 1.32 \\ 2.16 & 0.96 & 1.32 & 2.00 \end{bmatrix}$$

Exemplo 1

- Adicionalmente, considere a solução com $m = 2$ fatores, e as seguintes matrizes de cargas fatoriais e variâncias específicas:

$$\boldsymbol{L} = \begin{bmatrix} 1.60 & 0.40 \\ 0.20 & 1.20 \\ 1.00 & 0.20 \\ 1.20 & 0.60 \end{bmatrix} \quad \Psi = \begin{bmatrix} 1.28 & 0 & 0 & 0 \\ 0 & 0.52 & 0 & 0 \\ 0 & 0 & 0.96 & 0 \\ 0 & 0 & 0 & 0.20 \end{bmatrix}$$

Exemplo 1

- O modelo fatorial ortogonal fica definido da seguinte forma:

Exemplo 1

- O modelo fatorial ortogonal fica definido da seguinte forma:

$$Y_1 - \mu_1 = 1.60F_1 + 0.40F_2 + \epsilon_1, \quad \text{Var}(\epsilon_1) = 1.28$$

Exemplo 1

- O modelo fatorial ortogonal fica definido da seguinte forma:

$$Y_1 - \mu_1 = 1.60F_1 + 0.40F_2 + \epsilon_1, \quad \text{Var}(\epsilon_1) = 1.28$$

$$Y_2 - \mu_2 = 0.20F_1 + 1.20F_2 + \epsilon_2, \quad \text{Var}(\epsilon_2) = 0.52$$

Exemplo 1

- O modelo fatorial ortogonal fica definido da seguinte forma:

$$Y_1 - \mu_1 = 1.60F_1 + 0.40F_2 + \epsilon_1, \quad \text{Var}(\epsilon_1) = 1.28$$

$$Y_2 - \mu_2 = 0.20F_1 + 1.20F_2 + \epsilon_2, \quad \text{Var}(\epsilon_2) = 0.52$$

$$Y_3 - \mu_3 = 1.00F_1 + 0.20F_2 + \epsilon_3, \quad \text{Var}(\epsilon_3) = 0.96$$

Exemplo 1

- O modelo fatorial ortogonal fica definido da seguinte forma:

$$Y_1 - \mu_1 = 1.60F_1 + 0.40F_2 + \epsilon_1, \quad \text{Var}(\epsilon_1) = 1.28$$

$$Y_2 - \mu_2 = 0.20F_1 + 1.20F_2 + \epsilon_2, \quad \text{Var}(\epsilon_2) = 0.52$$

$$Y_3 - \mu_3 = 1.00F_1 + 0.20F_2 + \epsilon_3, \quad \text{Var}(\epsilon_3) = 0.96$$

$$Y_4 - \mu_4 = 1.20F_1 + 0.60F_2 + \epsilon_4, \quad \text{Var}(\epsilon_4) = 0.20$$

Exemplo 1

- A variância de Y_1 pode ser decomposta, segundo o modelo fatorial ortogonal, por:

$$\text{Var}(Y_1) = l_{11}^2 + l_{12}^2 + \psi_1 = (1.60^2 + 0.40^2) + 1.28 = 2.72 + 1.28 = 4.00$$

Exemplo 1

- A variância de Y_1 pode ser decomposta, segundo o modelo fatorial ortogonal, por:

$$\text{Var}(Y_1) = l_{11}^2 + l_{12}^2 + \psi_1 = (1.60^2 + 0.40^2) + 1.28 = 2.72 + 1.28 = 4.00$$

- Neste caso, a comunalidade de Y_1 é $h_1^2 = 2.72$, e a variância específica $\psi_1 = 1.28$.

Exemplo 1

- De maneira similar, as comunalidades de Y_2, Y_3 e Y_4 são, respectivamente:

Exemplo 1

- De maneira similar, as comunalidades de Y_2, Y_3 e Y_4 são, respectivamente:

$$h_2^2 = 0.20^2 + 1.20^2 = 1.48$$

Exemplo 1

- De maneira similar, as comunalidades de Y_2, Y_3 e Y_4 são, respectivamente:

$$h_2^2 = 0.20^2 + 1.20^2 = 1.48$$

$$h_3^2 = 1.00^2 + 0.20^2 = 1.04$$

Exemplo 1

- De maneira similar, as comunalidades de Y_2, Y_3 e Y_4 são, respectivamente:

$$h_2^2 = 0.20^2 + 1.20^2 = 1.48$$

$$h_3^2 = 1.00^2 + 0.20^2 = 1.04$$

$$h_4^2 = 1.20^2 + 0.60^2 = 1.80$$

Exemplo 1

- Além disso, apenas para fins de verificação, as variâncias específicas são:

Exemplo 1

- Além disso, apenas para fins de verificação, as variâncias específicas são:

$$\psi_2 = \sigma_2^2 - h_2^2 = 2.00 - 1.48 = 0.52$$

Exemplo 1

- Além disso, apenas para fins de verificação, as variâncias específicas são:

$$\psi_2 = \sigma_2^2 - h_2^2 = 2.00 - 1.48 = 0.52$$

$$\psi_3 = \sigma_3^2 - h_3^2 = 2.00 - 1.04 = 0.96$$

Exemplo 1

- Além disso, apenas para fins de verificação, as variâncias específicas são:

$$\psi_2 = \sigma_2^2 - h_2^2 = 2.00 - 1.48 = 0.52$$

$$\psi_3 = \sigma_3^2 - h_3^2 = 2.00 - 1.04 = 0.96$$

$$\psi_4 = \sigma_4^2 - h_4^2 = 2.00 - 1.80 = 0.20$$

Exemplo 1

- Podemos calcular a porcentagem da variância de Y_1 explicada pelos dois fatores comuns por:

$$100 \times \frac{l_{11}^2 + l_{12}^2}{\text{Var}(Y_1)} = 100 \times \frac{1.60^2 + 0.40^2}{4.00} = 100 \times \frac{2.72}{4.00} = 68\%$$

Exemplo 1

- Podemos calcular a porcentagem da variância de Y_1 explicada pelos dois fatores comuns por:

$$100 \times \frac{l_{11}^2 + l_{12}^2}{\text{Var}(Y_1)} = 100 \times \frac{1.60^2 + 0.40^2}{4.00} = 100 \times \frac{2.72}{4.00} = 68\%$$

- Consequentemente, 32% da variabilidade de Y_1 não é explicada pelos fatores comuns (variância específica).

Exemplo 1

- Procedendo de maneira similar, verificamos as seguintes explicações para as demais variáveis com base nos dois fatores comuns:

Exemplo 1

- Procedendo de maneira similar, verificamos as seguintes explicações para as demais variáveis com base nos dois fatores comuns:
  - Y_2 :

$$100 \times \frac{l_{21}^2 + l_{22}^2}{\text{Var}(Y_2)} = 100 \times \frac{0.20^2 + 1.20^2}{2.00} = 100 \times \frac{1.48}{2.00} = 74\%$$

Exemplo 1

- Procedendo de maneira similar, verificamos as seguintes explicações para as demais variáveis com base nos dois fatores comuns:
  - Y_2 :

$$100 \times \frac{l_{21}^2 + l_{22}^2}{\text{Var}(Y_2)} = 100 \times \frac{0.20^2 + 1.20^2}{2.00} = 100 \times \frac{1.48}{2.00} = 74\%$$

- Y_3 :

$$100 \times \frac{l_{31}^2 + l_{32}^2}{\text{Var}(Y_3)} = 100 \times \frac{1.00^2 + 0.20^2}{2.00} = 100 \times \frac{1.04}{2.00} = 52\%$$

Exemplo 1

- Y_4 :

$$100 \times \frac{l_{41}^2 + l_{42}^2}{\text{Var}(Y_4)} = 100 \times \frac{1.20^2 + 0.60^2}{2.00} = 100 \times \frac{1.80}{2.00} = 90\%$$

Exemplo 1

- Y_4 :

$$100 \times \frac{l_{41}^2 + l_{42}^2}{\text{Var}(Y_4)} = 100 \times \frac{1.20^2 + 0.60^2}{2.00} = 100 \times \frac{1.80}{2.00} = 90\%$$

- Adicionalmente, podemos calcular a porcentagem da variação total explicada pelo primeiro fator comum por:

$$100 \times \frac{l_{11}^2 + l_{21}^2 + l_{31}^2 + l_{41}^2}{\sigma^2_{\text{Total}}} = 100 \times \frac{1.60^2 + 0.20^2 + 1.00^2 + 1.20^2}{4 + 2 + 2 + 2} = 50.4\%$$

Exemplo 1

- De maneira análoga, para o segundo fator a porcentagem da variação total explicada é dada por:

$$100 \times \frac{l_{12}^2 + l_{22}^2 + l_{32}^2 + l_{42}^2}{\sigma^2_{\text{Total}}} = 100 \times \frac{0.40^2 + 1.20^2 + 0.20^2 + 0.60^2}{4 + 2 + 2 + 2} = 20.0\%$$

Exemplo 1

- De maneira análoga, para o segundo fator a porcentagem da variação total explicada é dada por:

$$100 \times \frac{l_{12}^2 + l_{22}^2 + l_{32}^2 + l_{42}^2}{\sigma^2_{\text{Total}}} = 100 \times \frac{0.40^2 + 1.20^2 + 0.20^2 + 0.60^2}{4 + 2 + 2 + 2} = 20.0\%$$

- Finalmente, a porcentagem da variância total explicada conjuntamente por F_1 e F_2 é dada por $50.4 + 20.0 = 70.4\%$.

Exemplo 2

Exemplo 2

Um estudo foi conduzido para avaliar as preferências de gênero cinematográfico para mulheres de certa faixa etária. Para isso, uma amostra de 15 participantes assistiram a diferentes filmes de quatro gêneros: suspense, ação, drama e comédia, e atribuíram notas de 0 a 100. As notas médias de cada participante por gênero dos filmes são apresentadas a seguir.

Exemplo 2

Tabela 4: Notas atribuídas pelas avaliadoras

Avaliadora	Suspense	Ação	Drama	Comédia
1	35	52	76	55
2	49	66	72	43
3	56	74	74	39
4	26	39	75	40
5	52	66	41	63
⋮	⋮	⋮	⋮	⋮
14	56	56	69	48
15	55	73	73	37

Exemplo 2

- A matriz de covariâncias é dada por:

$$S = \begin{pmatrix} 119.41 & 106.23 & -18.51 & 10.92 \\ 106.23 & 137.26 & -14.83 & -8.31 \\ -18.51 & -14.83 & 96.97 & -71.97 \\ 10.92 & -8.31 & -71.97 & 89.50 \end{pmatrix}$$

Exemplo 2

- A matriz de autovetores e os autovalores de S são apresentados na sequência:

$$P = \begin{pmatrix} -0.66 & -0.09 & 0.57 & 0.47 \\ -0.71 & 0.23 & -0.44 & -0.50 \\ 0.21 & -0.68 & 0.52 & -0.46 \\ -0.11 & 0.69 & 0.45 & -0.56 \end{pmatrix},$$

Exemplo 2

- A matriz de autovetores e os autovalores de S são apresentados na sequência:

$$P = \begin{pmatrix} -0.66 & -0.09 & 0.57 & 0.47 \\ -0.71 & 0.23 & -0.44 & -0.50 \\ 0.21 & -0.68 & 0.52 & -0.46 \\ -0.11 & 0.69 & 0.45 & -0.56 \end{pmatrix},$$

$$\boldsymbol{\lambda} = \begin{pmatrix} 240.28 & 162.08 & 27.68 & 13.09 \end{pmatrix}$$

Exemplo 2

- A matriz de autovetores e os autovalores de S são apresentados na sequência:

$$P = \begin{pmatrix} -0.66 & -0.09 & 0.57 & 0.47 \\ -0.71 & 0.23 & -0.44 & -0.50 \\ 0.21 & -0.68 & 0.52 & -0.46 \\ -0.11 & 0.69 & 0.45 & -0.56 \end{pmatrix},$$

$$\boldsymbol{\lambda} = \begin{pmatrix} 240.28 & 162.08 & 27.68 & 13.09 \end{pmatrix}$$

- Vamos considerar a solução com $m = 2$ fatores.

Exemplo 2

- Cargas fatoriais do primeiro fator:

$$\hat{\boldsymbol{l}}_{\mathbf{1}} = \begin{pmatrix} \sqrt{\hat{\lambda}_1}\hat{e}_{11} & \sqrt{\hat{\lambda}_1}\hat{e}_{12} & \sqrt{\hat{\lambda}_1}\hat{e}_{13} & \sqrt{\hat{\lambda}_1}\hat{e}_{14} \end{pmatrix} =$$

Exemplo 2

- Cargas fatoriais do primeiro fator:

$$\hat{\boldsymbol{l}}_{\mathbf{1}} = \left(\sqrt{\hat{\lambda}_1}\hat{e}_{11} \quad \sqrt{\hat{\lambda}_1}\hat{e}_{12} \quad \sqrt{\hat{\lambda}_1}\hat{e}_{13} \quad \sqrt{\hat{\lambda}_1}\hat{e}_{14} \right) =$$

$$\left(\sqrt{240.28} \times (-0.66) \quad \sqrt{240.28} \times (-0.70) \quad \sqrt{240.28} \times (0.21) \quad \sqrt{240.28} \times (-0.11) \right) =$$

Exemplo 2

- Cargas fatoriais do primeiro fator:

$$\hat{\boldsymbol{l}}_{\mathbf{1}} = \begin{pmatrix} \sqrt{\hat{\lambda}_1}\hat{e}_{11} & \sqrt{\hat{\lambda}_1}\hat{e}_{12} & \sqrt{\hat{\lambda}_1}\hat{e}_{13} & \sqrt{\hat{\lambda}_1}\hat{e}_{14} \end{pmatrix} =$$

$$\begin{pmatrix} \sqrt{240.28} \times (-0.66) & \sqrt{240.28} \times (-0.70) & \sqrt{240.28} \times (0.21) & \sqrt{240.28} \times (-0.11) \end{pmatrix} =$$

$$\begin{pmatrix} -10.23 & -10.85 & 3.25 & -1.70 \end{pmatrix}$$

Exemplo 2

- O primeiro fator atribui maiores cargas, e de mesmo sinal, para os gêneros `Suspense` e `Ação`.

Exemplo 2

- O primeiro fator atribui maiores cargas, e de mesmo sinal, para os gêneros `Suspense` e `Ação`.

- Este fator reflete a correlação positiva dos escores atribuídos aos filmes desses dois gêneros.

Exemplo 2

- O primeiro fator atribui maiores cargas, e de mesmo sinal, para os gêneros `Suspense` e `Ação`.
- Este fator reflete a correlação positiva dos escores atribuídos aos filmes desses dois gêneros.
- Os gêneros `Drama` e `Comédia` têm cargas relativamente menores neste fator, estando pouco correlacionados com ele.

Exemplo 2

- Cargas fatoriais do segundo fator:

$$\hat{\boldsymbol{l}}_{\boldsymbol{2}} = \begin{pmatrix} \sqrt{\hat{\lambda}_2}\hat{e}_{21} & \sqrt{\hat{\lambda}_2}\hat{e}_{22} & \sqrt{\hat{\lambda}_2}\hat{e}_{23} & \sqrt{\hat{\lambda}_2}\hat{e}_{24} \end{pmatrix} =$$

Exemplo 2

- Cargas fatoriais do segundo fator:

$$\hat{\boldsymbol{l}}_{\boldsymbol{2}} = \begin{pmatrix} \sqrt{\hat{\lambda}_2}\hat{e}_{21} & \sqrt{\hat{\lambda}_2}\hat{e}_{22} & \sqrt{\hat{\lambda}_2}\hat{e}_{23} & \sqrt{\hat{\lambda}_2}\hat{e}_{24} \end{pmatrix} =$$

$$\begin{pmatrix} \sqrt{162.08} \times (-0.09) & \sqrt{162.08} \times (-0.23) & \sqrt{162.08} \times (-0.68) & \sqrt{162.08} \times (0.69) \end{pmatrix} =$$

Exemplo 2

- Cargas fatoriais do segundo fator:

$$\hat{\boldsymbol{l}}_{\boldsymbol{2}} = \begin{pmatrix} \sqrt{\hat{\lambda}_2}\hat{e}_{21} & \sqrt{\hat{\lambda}_2}\hat{e}_{22} & \sqrt{\hat{\lambda}_2}\hat{e}_{23} & \sqrt{\hat{\lambda}_2}\hat{e}_{24} \end{pmatrix} =$$

$$\begin{pmatrix} \sqrt{162.08} \times (-0.09) & \sqrt{162.08} \times (-0.23) & \sqrt{162.08} \times (-0.68) & \sqrt{162.08} \times (0.69) \end{pmatrix} =$$

$$\begin{pmatrix} -1.15 & -2.93 & -8.65 & 8.78 \end{pmatrix}$$

Exemplo 2

- O segundo fator atribui maiores cargas, mas de sinais opostos, para os gêneros `Drama` e `Comédia`.

Exemplo 2

- O segundo fator atribui maiores cargas, mas de sinais opostos, para os gêneros `Drama` e `Comédia`.

- Este fator reflete a correlação negativa dos escores atribuídos aos filmes desses dois gêneros.

Exemplo 2

- O segundo fator atribui maiores cargas, mas de sinais opostos, para os gêneros `Drama` e `Comédia`.
- Este fator reflete a correlação negativa dos escores atribuídos aos filmes desses dois gêneros.
- Os gêneros `Suspense` e `Ação` têm cargas relativamente menores neste fator, estando pouco correlacionados com ele.

Exemplo 2

- Modelo fatorial ajustado:

Exemplo 2

- Modelo fatorial ajustado:

$$Y_1 - \mu_1 = -10.23F_1 - 1.15F_2 + \epsilon_1$$

Exemplo 2

- Modelo fatorial ajustado:

$$Y_1 - \mu_1 = -10.23F_1 - 1.15F_2 + \epsilon_1$$

$$Y_2 - \mu_2 = -10.85F_1 - 2.93F_2 + \epsilon_2$$

Exemplo 2

- Modelo fatorial ajustado:

$$Y_1 - \mu_1 = -10.23F_1 - 1.15F_2 + \epsilon_1$$

$$Y_2 - \mu_2 = -10.85F_1 - 2.93F_2 + \epsilon_2$$

$$Y_3 - \mu_3 = 3.25F_1 - 8.65F_2 + \epsilon_3$$

Exemplo 2

- Modelo fatorial ajustado:

$$Y_1 - \mu_1 = -10.23F_1 - 1.15F_2 + \epsilon_1$$

$$Y_2 - \mu_2 = -10.85F_1 - 2.93F_2 + \epsilon_2$$

$$Y_3 - \mu_3 = 3.25F_1 - 8.65F_2 + \epsilon_3$$

$$Y_4 - \mu_4 = -1.70F_1 + 8.78F_2 + \epsilon_4$$

Exemplo 2

- Matriz de covariâncias estimada pelo modelo de análise fatorial:

$$\hat{\boldsymbol{L}}\hat{\boldsymbol{L}}' = \begin{pmatrix} -10.23 & -1.15 \\ -10.85 & -2.93 \\ 3.25 & -8.65 \\ -1.70 & 8.78 \end{pmatrix} \times \begin{pmatrix} -10.23 & -1.15 \\ -10.85 & -2.93 \\ 3.25 & -8.65 \\ -1.70 & 8.78 \end{pmatrix}' = \begin{pmatrix} 105.97 & 114.36 & -23.30 & 7.44 \\ 114.36 & 126.31 & -9.92 & -6.90 \\ -23.30 & -9.92 & 85.38 & -81.47 \\ 7.44 & -6.90 & -81.47 & 79.98 \end{pmatrix}$$

Exemplo 2

- Cálculo das comunalidades:

Exemplo 2

- Cálculo das comunalidades:

$$\texttt{Supense:} \quad \hat{h}_1^2 = \hat{l}_{11}^2 + \hat{l}_{12}^2 = (-10.23)^2 + (-1.15)^2 = 105.97$$

Exemplo 2

- Cálculo das comunalidades:

$$\texttt{Supense:} \quad \hat{h}_1^2 = \hat{l}_{11}^2 + \hat{l}_{12}^2 = (-10.23)^2 + (-1.15)^2 = 105.97$$

$$\texttt{Ação:} \quad \hat{h}_2^2 = \hat{l}_{21}^2 + \hat{l}_{22}^2 = (-10.85)^2 + (-2.93)^2 = 126.31$$

Exemplo 2

- Cálculo das comunalidades:

$$\texttt{Supense:} \quad \hat{h}_1^2 = \hat{l}_{11}^2 + \hat{l}_{12}^2 = (-10.23)^2 + (-1.15)^2 = 105.97$$

$$\texttt{Ação:} \quad \hat{h}_2^2 = \hat{l}_{21}^2 + \hat{l}_{22}^2 = (-10.85)^2 + (-2.93)^2 = 126.31$$

$$\texttt{Drama:} \quad \hat{h}_3^2 = \hat{l}_{31}^2 + \hat{l}_{32}^2 = (3.25)^2 + (-8.65)^2 = 85.38$$

Exemplo 2

- Cálculo das comunalidades:

$$\texttt{Supense:} \quad \hat{h}_1^2 = \hat{l}_{11}^2 + \hat{l}_{12}^2 = (-10.23)^2 + (-1.15)^2 = 105.97$$

$$\texttt{Ação:} \quad \hat{h}_2^2 = \hat{l}_{21}^2 + \hat{l}_{22}^2 = (-10.85)^2 + (-2.93)^2 = 126.31$$

$$\texttt{Drama:} \quad \hat{h}_3^2 = \hat{l}_{31}^2 + \hat{l}_{32}^2 = (3.25)^2 + (-8.65)^2 = 85.38$$

$$\texttt{Comédia:} \quad \hat{h}_4^2 = \hat{l}_{41}^2 + \hat{l}_{42}^2 = (-1.70)^2 + (8.78)^2 = 79.97$$

Exemplo 2

- Cálculo das especificidades:

Exemplo 2

- Cálculo das especificidades:

$$\texttt{Supense:} \quad \hat{\psi}_1 = s_1^2 - \hat{h}_1^2 = 119.41 - 105.97 = 13.44$$

Exemplo 2

- Cálculo das especificidades:

$$\texttt{Supense:} \quad \hat{\psi}_1 = s_1^2 - \hat{h}_1^2 = 119.41 - 105.97 = 13.44$$

$$\texttt{Ação:} \quad \hat{\psi}_2 = s_2^2 - \hat{h}_2^2 = 137.26 - 126.31 = 10.95$$

Exemplo 2

- Cálculo das especificidades:

$$\texttt{Supense:}\quad \hat{\psi}_1 = s_1^2 - \hat{h}_1^2 = 119.41 - 105.97 = 13.44$$

$$\texttt{Ação:}\quad \hat{\psi}_2 = s_2^2 - \hat{h}_2^2 = 137.26 - 126.31 = 10.95$$

$$\texttt{Drama:}\quad \hat{\psi}_3 = s_3^2 - \hat{h}_3^2 = 96.97 - 85.38 = 11.95$$

Exemplo 2

- Cálculo das especificidades:

$$\texttt{Supense:}\quad \hat{\psi}_1 = s_1^2 - \hat{h}_1^2 = 119.41 - 105.97 = 13.44$$

$$\texttt{Ação:}\quad \hat{\psi}_2 = s_2^2 - \hat{h}_2^2 = 137.26 - 126.31 = 10.95$$

$$\texttt{Drama:}\quad \hat{\psi}_3 = s_3^2 - \hat{h}_3^2 = 96.97 - 85.38 = 11.95$$

$$\texttt{Comédia:}\quad \hat{\psi}_4 = s_4^2 - \hat{h}_4^2 = 89.50 - 79.97 = 9.53$$

Exemplo 2

- Porcentagens das variações das quatro variáveis originais explicadas pelos dois fatores comuns ($\bar{h}^2$):

Exemplo 2

- Porcentagens das variações das quatro variáveis originais explicadas pelos dois fatores comuns ($\bar{h}^2$):

$$\texttt{Supense:} \quad 100 \times \frac{\hat{l}_{11}^2 + \hat{l}_{12}^2}{s_1^2} = 100 \times \frac{(-10.23)^2 + (-1.15)^2}{119.41} = 100 \times \frac{105.97}{119.41} = 88.74\%$$

Exemplo 2

- Porcentagens das variações das quatro variáveis originais explicadas pelos dois fatores comuns ($\bar{h}^2$):

$$\texttt{Supense:} \quad 100 \times \frac{\hat{l}_{11}^2 + \hat{l}_{12}^2}{s_1^2} = 100 \times \frac{(-10.23)^2 + (-1.15)^2}{119.41} = 100 \times \frac{105.97}{119.41} = 88.74\%$$

$$\texttt{Ação:} \quad 100 \times \frac{\hat{l}_{21}^2 + \hat{l}_{22}^2}{s_2^2} = 100 \times \frac{(-10.85)^2 + (-2.93)^2}{137.26} = 100 \times \frac{126.31}{137.26} = 92.02\%$$

Exemplo 2

- Porcentagens das variações das quatro variáveis originais explicadas pelos dois fatores comuns ($\bar{h}^2$):

$$\texttt{Supense:}\quad 100 \times \frac{\hat{l}_{11}^2 + \hat{l}_{12}^2}{s_1^2} = 100 \times \frac{(-10.23)^2 + (-1.15)^2}{119.41} = 100 \times \frac{105.97}{119.41} = 88.74\%$$

$$\texttt{Ação:}\quad 100 \times \frac{\hat{l}_{21}^2 + \hat{l}_{22}^2}{s_2^2} = 100 \times \frac{(-10.85)^2 + (-2.93)^2}{137.26} = 100 \times \frac{126.31}{137.26} = 92.02\%$$

$$\texttt{Drama:}\quad 100 \times \frac{\hat{l}_{31}^2 + \hat{l}_{32}^2}{s_3^2} = 100 \times \frac{(3.25)^2 + (-8.65)^2}{96.97} = 100 \times \frac{85.38}{96.97} = 88.04\%$$

Exemplo 2

- Porcentagens das variações das quatro variáveis originais explicadas pelos dois fatores comuns ($\bar{h}^2$):

$$\texttt{Supense:}\quad 100 \times \frac{\hat{l}_{11}^2 + \hat{l}_{12}^2}{s_1^2} = 100 \times \frac{(-10.23)^2 + (-1.15)^2}{119.41} = 100 \times \frac{105.97}{119.41} = 88.74\%$$

$$\texttt{Ação:}\quad 100 \times \frac{\hat{l}_{21}^2 + \hat{l}_{22}^2}{s_2^2} = 100 \times \frac{(-10.85)^2 + (-2.93)^2}{137.26} = 100 \times \frac{126.31}{137.26} = 92.02\%$$

$$\texttt{Drama:}\quad 100 \times \frac{\hat{l}_{31}^2 + \hat{l}_{32}^2}{s_3^2} = 100 \times \frac{(3.25)^2 + (-8.65)^2}{96.97} = 100 \times \frac{85.38}{96.97} = 88.04\%$$

$$\texttt{Comédia:}\quad 100 \times \frac{\hat{l}_{41}^2 + \hat{l}_{42}^2}{s_4^2} = 100 \times \frac{(-1.70)^2 + (8.78)^2}{89.50} = 100 \times \frac{79.97}{89.50} = 89.35\%$$

Exemplo 2

- Porcentagens da variação total explicadas pelos dois fatores comuns:

Exemplo 2

- Porcentagens da variação total explicadas pelos dois fatores comuns:
  - Fator 1:

$$100 \times \frac{\hat{l}_{11}^2 + \hat{l}_{21}^2 + \hat{l}_{31}^2 + \hat{l}_{41}^2}{\text{tr}(S)} = 100 \times \frac{(-10.23)^2 + (-10.85)^2 + 3.25^2 + (-1.70^2)}{119.41 + 137.26 + 96.97 + 89.50} = 100 \times \frac{235.83}{443.14} = 53.22\%$$

Exemplo 2

- Porcentagens da variação total explicadas pelos dois fatores comuns:
  - Fator 1:

$$100 \times \frac{\hat{l}_{11}^2 + \hat{l}_{21}^2 + \hat{l}_{31}^2 + \hat{l}_{41}^2}{\text{tr}(S)} = 100 \times \frac{(-10.23)^2 + (-10.85)^2 + 3.25^2 + (-1.70^2)}{119.41 + 137.26 + 96.97 + 89.50} = 100 \times \frac{235.83}{443.14} = 53.22\%$$

- Fator 2:

$$100 \times \frac{\hat{l}_{12}^2 + \hat{l}_{22}^2 + \hat{l}_{32}^2 + \hat{l}_{42}^2}{\text{tr}(S)} = 100 \times \frac{(-1.15)^2 + (-2.93)^2 + (-8.65)^2 + 8.78^2}{119.41 + 137.26 + 96.97 + 89.50} = 100 \times \frac{161.82}{443.14} = 36.50\%$$

Exemplo 2

- Porcentagens da variação total explicadas pelos dois fatores comuns:
  - Fator 1:

$$100 \times \frac{\hat{l}_{11}^2 + \hat{l}_{21}^2 + \hat{l}_{31}^2 + \hat{l}_{41}^2}{\text{tr}(S)} = 100 \times \frac{(-10.23)^2 + (-10.85)^2 + 3.25^2 + (-1.70^2)}{119.41 + 137.26 + 96.97 + 89.50} = 100 \times \frac{235.83}{443.14} = 53.22\%$$

- Fator 2:

$$100 \times \frac{\hat{l}_{12}^2 + \hat{l}_{22}^2 + \hat{l}_{32}^2 + \hat{l}_{42}^2}{\text{tr}(S)} = 100 \times \frac{(-1.15)^2 + (-2.93)^2 + (-8.65)^2 + 8.78^2}{119.41 + 137.26 + 96.97 + 89.50} = 100 \times \frac{161.82}{443.14} = 36.50\%$$

- Logo, conjuntamente F_1 e F_2 explicam 53.22+36.50=89.72% da variação total dos dados originais.

Exemplo 2

- Matriz de variâncias específicas (especificidades):

Exemplo 2

- Matriz de variâncias específicas (especificidades):

$$\hat{\boldsymbol{\Psi}} = \text{diag}(S - \boldsymbol{LL'}) =$$

$$\text{diag}\left[\begin{pmatrix} 119.41 & 106.23 & -18.51 & 10.92 \\ 106.23 & 137.26 & -14.83 & -8.31 \\ -18.51 & -14.83 & 96.97 & -71.97 \\ 10.92 & -8.31 & -71.97 & 89.50 \end{pmatrix} - \begin{pmatrix} 105.97 & 114.36 & -23.30 & 7.44 \\ 114.36 & 126.31 & -9.92 & -6.90 \\ -23.30 & -9.92 & 85.38 & -81.47 \\ 7.44 & -6.90 & -81.47 & 79.98 \end{pmatrix}\right] =$$

$$\begin{pmatrix} 13.44 & 0 & 0 & 0 \\ 0 & 10.95 & 0 & 0 \\ 0 & 0 & 11.59 & 0 \\ 0 & 0 & 0 & 9.52 \end{pmatrix}$$

Exemplo 2

- Matriz de covariâncias residuais:

Exemplo 2

- Matriz de covariâncias residuais:

$$S_{Res} = S - \boldsymbol{LL'} = \begin{pmatrix} 119.41 & 106.23 & -18.51 & 10.92 \\ 106.23 & 137.26 & -14.83 & -8.31 \\ -18.51 & -14.83 & 96.97 & -71.97 \\ 10.92 & -8.31 & -71.97 & 89.50 \end{pmatrix} - \begin{pmatrix} 105.97 & 114.36 & -23.30 & 7.44 \\ 114.36 & 126.31 & -9.92 & -6.90 \\ -23.30 & -9.92 & 85.38 & -81.47 \\ 7.44 & -6.90 & -81.47 & 79.97 \end{pmatrix} =$$

$$\begin{pmatrix} 13.44 & -8.13 & 4.79 & 3.48 \\ -8.13 & 10.95 & -4.91 & -1.41 \\ 4.79 & -4.91 & 11.59 & 9.50 \\ 3.48 & -1.41 & 9.50 & 11.79 \end{pmatrix}$$

Exemplo 2

Tabela 5: Resumo da análise fatorial

Variável	Cargas fatoriais		Comunalidade(%)	Especificidade(%)
	Fator 1	Fator 2		
Suspense	-10.23	-1.15	88.74	11.26
Ação	-10.85	-2.93	92.02	7.98
Drama	+3.25	-8.65	88.04	11.96
Comédia	-1.70	+8.78	89.35	10.65
% Var. Explicada	53.22	36.50		
% Var. Acumulada	53.22	89.72		

Exemplo 2

Tabela 6: Soluções da análise fatorial com as cargas fatoriais rotacionadas

Variável	Não rotacionado		Rotação varimax		Rotação promax	
	Fator 1	Fator 2	Fator 1	Fator 2	Fator 1	Fator 2
Suspense	-10.23	-1.15	-10.30	+1.28	-10.25	+0.85
Ação	-10.85	-2.93	-11.30	-0.21	-11.38	-0.69
Drama	+3.25	-8.65	+1.20	-9.23	+0.64	-9.22
Comédia	-1.70	+8.78	+0.40	+8.92	+0.92	+8.98

Exemplo 2

- O fator 1 tem maior cargas numéricas, com mesmo sinal, para os gêneros suspense e ação.

Exemplo 2

- O fator 1 tem maior cargas numéricas, com mesmo sinal, para os gêneros suspense e ação.

- Desta forma, esse fator exprime o gosto conjunto por filmes desses dois gêneros.

Exemplo 2

- O fator 1 tem maior cargas numéricas, com mesmo sinal, para os gêneros suspense e ação.
- Desta forma, esse fator exprime o gosto conjunto por filmes desses dois gêneros.
- O fator 2 tem maiores cargas, de sinais opostos, para os gêneros drama e comédia.

Exemplo 2

- O fator 1 tem maior cargas numéricas, com mesmo sinal, para os gêneros suspense e ação.
- Desta forma, esse fator exprime o gosto conjunto por filmes desses dois gêneros.
- O fator 2 tem maiores cargas, de sinais opostos, para os gêneros drama e comédia.
- Esse fator se caracteriza pelos gostos contrastantes por filmes desses dois gêneros.

O que veremos no próximo módulo

O que veremos no próximo módulo

- No próximo módulo será abordada a técnica de análise discriminante.

O que veremos no próximo módulo

- No próximo módulo será abordada a técnica de análise discriminante.

- Serão discutidas duas de suas principais versões: as análises discriminante linear e quafrática.

O que veremos no próximo módulo

- No próximo módulo será abordada a técnica de análise discriminante.
- Serão discutidas duas de suas principais versões: as análises discriminante linear e quafrática.
- Problemas de classificação usando o fator de Bayes serão apresentados.

O que veremos no próximo módulo

- No próximo módulo será abordada a técnica de análise discriminante.
- Serão discutidas duas de suas principais versões: as análises discriminante linear e quafrática.
- Problemas de classificação usando o fator de Bayes serão apresentados.
- A aula finaliza com aplicações das técnicas usando o R.