# CE319 - Estatística multivariada

## Testes de hipóteses multivariados

Cesar Augusto Taconeli

18 de março, 2026

# Testes de hipóteses multivariados

# O que vamos estudar neste módulo

# O que vamos estudar neste módulo

- Testes de hipóteses e regiões de confiança para um vetor de médias.

# O que vamos estudar neste módulo

- Testes de hipóteses e regiões de confiança para um vetor de médias.

- Testes de hipóteses e regiões de confiança para dois vetores de médias.

# O que vamos estudar neste módulo

- Testes de hipóteses e regiões de confiança para um vetor de médias.
- Testes de hipóteses e regiões de confiança para dois vetores de médias.
- Análise de variância multivariada.

# O que vamos estudar neste módulo

- Testes de hipóteses e regiões de confiança para um vetor de médias.
- Testes de hipóteses e regiões de confiança para dois vetores de médias.
- Análise de variância multivariada.
- Comparação de matrizes de covariâncias.

# Introdução

# Estimação sob distribuição normal multivariada

- Uma vez assumido um modelo paramétrico, é de interesse usar dados amostrais para estimar os correspondentes parâmetros.

# Estimação sob distribuição normal multivariada

- Uma vez assumido um modelo paramétrico, é de interesse usar dados amostrais para estimar os correspondentes parâmetros.

- Vamos considerar $\boldsymbol{Y}_1, \boldsymbol{Y}_2, ..., \boldsymbol{Y}_n$ uma amostra aleatória de uma distribuição normal p-variada, com média $\boldsymbol{\mu}' = (\mu_1, \mu_2, ..., \mu_p)$ e matriz de covariâncias:

$$\Sigma = \begin{bmatrix} \sigma_{11} & \sigma_{12} & \cdots & \sigma_{1p} \\ \sigma_{12} & \sigma_{22} & \cdots & \sigma_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ \sigma_{1p} & \sigma_{2p} & \cdots & \sigma_{pp} \end{bmatrix}$$

# Estimação sob distribuição normal multivariada

- Uma vez assumido um modelo paramétrico, é de interesse usar dados amostrais para estimar os correspondentes parâmetros.

- Vamos considerar $\boldsymbol{Y}_1, \boldsymbol{Y}_2, ..., \boldsymbol{Y}_n$ uma amostra aleatória de uma distribuição normal p-variada, com média $\boldsymbol{\mu}' = (\mu_1, \mu_2, ..., \mu_p)$ e matriz de covariâncias:

$$\Sigma = \begin{bmatrix} \sigma_{11} & \sigma_{12} & \cdots & \sigma_{1p} \\ \sigma_{12} & \sigma_{22} & \cdots & \sigma_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ \sigma_{1p} & \sigma_{2p} & \cdots & \sigma_{pp} \end{bmatrix}$$

- **Nota**- Entenda-se por amostra aleatória que $\boldsymbol{Y}_1, \boldsymbol{Y}_2, ..., \boldsymbol{Y}_n$ são mutuamente independentes, com distribuição $N_p(\boldsymbol{\mu}, \Sigma)$.

# Estimação sob distribuição normal multivariada

- Considerando distribuição normal multivariada, a função de verossimilhança fica dada por:

$$L(\boldsymbol{\mu}, \Sigma) = \frac{1}{(2\pi)^{np/2}|\Sigma|^{n/2}} e^{-\sum_{i=1}^{n}(\boldsymbol{y_i}-\boldsymbol{\mu})\Sigma^{-1}(\boldsymbol{y_i}-\boldsymbol{\mu})/2}$$

# Estimação sob distribuição normal multivariada

- Considerando distribuição normal multivariada, a função de verossimilhança fica dada por:

$$L(\boldsymbol{\mu}, \Sigma) = \frac{1}{(2\pi)^{np/2}|\Sigma|^{n/2}} e^{-\sum_{i=1}^{n}(\boldsymbol{y_i}-\boldsymbol{\mu})\Sigma^{-1}(\boldsymbol{y_i}-\boldsymbol{\mu})/2}$$

- Os estimadores de máxima verossimilhança de $\boldsymbol{\mu}$ e $\Sigma$ (ou seja, $\boldsymbol{\mu}$ e $\Sigma$ tais que $L(\boldsymbol{\mu}, \Sigma)$ é maximizada) são dados por:

$$\hat{\boldsymbol{\mu}} = \bar{\boldsymbol{Y}} = \frac{1}{n}\sum_{i=1}^{n} \boldsymbol{Y}_i \qquad \hat{\boldsymbol{\Sigma}} = \frac{1}{n}\sum_{i=1}^{n} (\boldsymbol{Y_i} - \bar{\boldsymbol{Y}})(\boldsymbol{Y_i} - \bar{\boldsymbol{Y}})' = \frac{n-1}{n} S$$

# Estimação sob distribuição normal multivariada

- Vale sempre lembrar que os estimadores de máxima verossimilhança apresentam propriedades assintóticas desejáveis, como ausência de viés, eficiência, consistência...

# Estimação sob distribuição normal multivariada

- Vale sempre lembrar que os estimadores de máxima verossimilhança apresentam propriedades assintóticas desejáveis, como ausência de viés, eficiência, consistência...

- Adicionalmente, por produzirem os EMVs para $\boldsymbol{\mu}$ e $\Sigma$, $\bar{\boldsymbol{Y}}$ e $S$ são estatísticas suficientes, ou sejam, condensam toda informação amostral sobre $\boldsymbol{\mu}$ e $\Sigma$ contida nos dados.

# Estimação sob distribuição normal multivariada

- Vale sempre lembrar que os estimadores de máxima verossimilhança apresentam propriedades assintóticas desejáveis, como ausência de viés, eficiência, consistência...
- Adicionalmente, por produzirem os EMVs para $\boldsymbol{\mu}$ e $\Sigma$, $\bar{\boldsymbol{Y}}$ e $S$ são estatísticas suficientes, ou sejam, condensam toda informação amostral sobre $\boldsymbol{\mu}$ e $\Sigma$ contida nos dados.
- A suficiência de $\bar{\boldsymbol{Y}}$ e $S$ não é verificada para outras distribuições, o que requer cuidado quanto à aplicação de algumas técnicas multivariadas para dados não normais.

# Testes de hipóteses para vetores de médias

- No contexto multivariado temos um maior número de parâmetros a serem estimados e testados.

# Testes de hipóteses para vetores de médias

- No contexto multivariado temos um maior número de parâmetros a serem estimados e testados.

- Para uma distribuição normal $p$-variada, temos $p$ parâmetros que configuram a média e $p(p+1)/2$ parâmetros na matriz de covariâncias, totalizando $p(p+3)/2$ parâmetros.

# Testes de hipóteses para vetores de médias

- No contexto multivariado temos um maior número de parâmetros a serem estimados e testados.

- Para uma distribuição normal $p$-variada, temos $p$ parâmetros que configuram a média e $p(p+1)/2$ parâmetros na matriz de covariâncias, totalizando $p(p+3)/2$ parâmetros.

- Inicialmente, vamos restringir nossa atenção a testes de hipóteses para o vetor de médias, envolvendo, portanto, $p$ parâmetros $(\mu_1, \mu_2, ..., \mu_p)$.

# Testes de hipóteses para vetores de médias

- No contexto multivariado temos um maior número de parâmetros a serem estimados e testados.

- Para uma distribuição normal $p$-variada, temos $p$ parâmetros que configuram a média e $p(p+1)/2$ parâmetros na matriz de covariâncias, totalizando $p(p+3)/2$ parâmetros.

- Inicialmente, vamos restringir nossa atenção a testes de hipóteses para o vetor de médias, envolvendo, portanto, $p$ parâmetros $(\mu_1, \mu_2, ..., \mu_p)$.

- Neste caso, vamos estabelecer hipóteses e testar conjuntamente os $p$ parâmetros do vetor de médias.

# Testes de hipóteses multivariados

# Testes de hipóteses multivariados

- Por que testar conjuntamente (e não individualmente) os $p$ parâmetros?

# Testes de hipóteses multivariados

- Por que testar conjuntamente (e não individualmente) os $p$ parâmetros?
  - O uso de $p$ testes univariados, ao invés da aplicação de um único teste que considere conjuntamente os $p$ parâmetros, inflaciona a taxa do erro global, não preservando o nível de significância ($\alpha$) especificado;

# Testes de hipóteses multivariados

- Por que testar conjuntamente (e não individualmente) os $p$ parâmetros?
  - O uso de $p$ testes univariados, ao invés da aplicação de um único teste que considere conjuntamente os $p$ parâmetros, inflaciona a taxa do erro global, não preservando o nível de significância ($\alpha$) especificado;
  - Testes univariados não incorporam as correlações entre as variáveis;

# Testes de hipóteses multivariados

- Por que testar conjuntamente (e não individualmente) os $p$ parâmetros?
  - O uso de $p$ testes univariados, ao invés da aplicação de um único teste que considere conjuntamente os $p$ parâmetros, inflaciona a taxa do erro global, não preservando o nível de significância ($\alpha$) especificado;
  - Testes univariados não incorporam as correlações entre as variáveis;
  - Testes multivariados, em geral, são mais poderosos que múltiplos testes univariados;

# Testes de hipóteses multivariados

- Por que testar conjuntamente (e não individualmente) os $p$ parâmetros?
  - O uso de $p$ testes univariados, ao invés da aplicação de um único teste que considere conjuntamente os $p$ parâmetros, inflaciona a taxa do erro global, não preservando o nível de significância ($\alpha$) especificado;
  - Testes univariados não incorporam as correlações entre as variáveis;
  - Testes multivariados, em geral, são mais poderosos que múltiplos testes univariados;
  - A construção de testes multivariados pode ser mais informativa quanto à forma como as variáveis se conjugam na rejeição de hipóteses.

# Testes de hipóteses para vetores de médias

# Testes de hipóteses para vetores de médias

- No caso univariado, para se testar o par de hipóteses $H_0 : \mu = \mu_0$ vs $H_1 : \mu \neq \mu_0$, com base em $y_1, y_2, ..., y_n$ uma amostra aleatória de $Y \sim N(\mu, \sigma^2)$, consideramos a estatística teste:

$$t = \frac{\bar{y} - \mu_0}{s/\sqrt{n}}.$$

# Testes de hipóteses para vetores de médias

- No caso univariado, para se testar o par de hipóteses $H_0 : \mu = \mu_0$ vs $H_1 : \mu \neq \mu_0$, com base em $y_1, y_2, ..., y_n$ uma amostra aleatória de $Y \sim N(\mu, \sigma^2)$, consideramos a estatística teste:

$$t = \frac{\bar{y} - \mu_0}{s/\sqrt{n}}.$$

- Sob $H_0$, a estatística $t$ tem distribuição t-Student com n-1 graus de liberdade, de tal forma que rejeitamos $H_0$, para um nível de significância $\alpha$, se $|t| > |t_{n-1}(\alpha/2)|$.

# Teste de hipóteses para um vetor de médias

- A estatística do teste apresentada pode ser escrita na forma de uma distância quadrática:

$$t^2 = n(\bar{y} - \mu_0)(s^2)^{-1}(\bar{y} - \mu_0),$$

de tal forma que o teste equivalente rejeita $H_0$ se $t^2 > [t_{n-1}(\alpha/2)]^2$.

# Teste de hipóteses para um vetor de médias

- A estatística do teste apresentada pode ser escrita na forma de uma distância quadrática:

$$t^2 = n(\bar{y} - \mu_0)(s^2)^{-1}(\bar{y} - \mu_0),$$

de tal forma que o teste equivalente rejeita $H_0$ se $t^2 > [t_{n-1}(\alpha/2)]^2$.

- Generalizando para o caso p-dimensional, em que $\boldsymbol{\mu}_0' = (\mu_{10}, \mu_{20}, ..., \mu_{p0})$ é o vetor de médias postulado e $\bar{\boldsymbol{y}}$ e $S$ o vetor de médias e a matriz de covariâncias amostrais, a estatística do teste fica definida por:

$$T^2 = (\bar{\boldsymbol{y}} - \boldsymbol{\mu_0})' \left(\frac{\boldsymbol{S}}{\boldsymbol{n}}\right)^{-1} (\bar{\boldsymbol{y}} - \boldsymbol{\mu}_0) = n(\bar{\boldsymbol{y}} - \boldsymbol{\mu}_0)' S^{-1} (\bar{\boldsymbol{y}} - \boldsymbol{\mu}_0).$$

# Teste de hipóteses para um vetor de médias

- A estatística $T^2$ é chamada $T^2$ de Hotelling, e, sob a hipótese nula $H_0 : \boldsymbol{\mu} = \boldsymbol{\mu}_0$

$$T^2 \sim \frac{(n-1)p}{(n-p)} F_{p,n-p}.$$

# Teste de hipóteses para um vetor de médias

- A estatística $T^2$ é chamada $T^2$ de Hotelling, e, sob a hipótese nula $H_0 : \boldsymbol{\mu} = \boldsymbol{\mu}_0$

$$T^2 \sim \frac{(n-1)p}{(n-p)} F_{p,n-p}.$$

- Assim, para um nível de significância $\alpha$, devemos rejeitar a hipótese nula se

$$T^2 > \frac{(n-1)p}{(n-p)} F_{p,n-p}(\alpha).$$

# Região de confiança e intervalos simultâneos

- Uma região de confiança $100(1-\alpha)\%$ para a média de uma distribuição normal p-variada é o elipsoide determinado por todo $\boldsymbol{\mu} \in R^p$ tal que:

$$n(\bar{\boldsymbol{y}} - \boldsymbol{\mu})' S^{-1} (\bar{\boldsymbol{y}} - \boldsymbol{\mu}) \leq \frac{(n-1)p}{(n-p)} F_{p,n-p}(\alpha).$$

# Região de confiança e intervalos simultâneos

- Uma região de confiança $100(1-\alpha)\%$ para a média de uma distribuição normal p-variada é o elipsoide determinado por todo $\boldsymbol{\mu} \in R^p$ tal que:

$$n(\bar{\mathbf{y}} - \boldsymbol{\mu})' S^{-1} (\bar{\mathbf{y}} - \boldsymbol{\mu}) \leq \frac{(n-1)p}{(n-p)} F_{p,n-p}(\alpha).$$

- Para verificar se um particular vetor $\boldsymbol{\mu}_0 \in R^p$ pertence à região de confiança, basta ver se ele satisfaz a desigualdade apresentada.

# Região de confiança e intervalos simultâneos

- Uma região de confiança $100(1-\alpha)\%$ para a média de uma distribuição normal p-variada é o elipsoide determinado por todo $\boldsymbol{\mu} \in R^p$ tal que:

$$n(\bar{\boldsymbol{y}} - \boldsymbol{\mu})' S^{-1} (\bar{\boldsymbol{y}} - \boldsymbol{\mu}) \leq \frac{(n-1)p}{(n-p)} F_{p,n-p}(\alpha).$$

- Para verificar se um particular vetor $\boldsymbol{\mu}_0 \in R^p$ pertence à região de confiança, basta ver se ele satisfaz a desigualdade apresentada.

- No caso bidimensional essa elipsoide se resume a uma elipse.

# Região de confiança e intervalos simultâneos

- Como alternativa, podemos obter intervalos para componentes do vetor de médias ou mesmo para combinações lineares dos mesmos.

# Região de confiança e intervalos simultâneos

- Como alternativa, podemos obter intervalos para componentes do vetor de médias ou mesmo para combinações lineares dos mesmos.

- Um intervalo de confiança $100(1-\alpha)\%$ para $\mu_j$ tem limites:

$$\bar{y}_j \pm t_{n-1}(\alpha/2)\sqrt{\frac{s_{jj}}{n}}, \quad j = 1, 2, ..., p.$$

# Região de confiança e intervalos simultâneos

- Os intervalos obtidos dessa forma tem, **individualmente**, nível de confiança $100(1-\alpha)\%$.

# Região de confiança e intervalos simultâneos

- Os intervalos obtidos dessa forma tem, **individualmente**, nível de confiança $100(1-\alpha)\%$.

- No entanto, é comum avaliarmos, conjuntamente, dois ou mais intervalos de confiança (como, por exemplo, um intervalo para cada um dos p componentes do vetor de médias).

# Região de confiança e intervalos simultâneos

- Os intervalos obtidos dessa forma tem, **individualmente**, nível de confiança $100(1-\alpha)\%$.
- No entanto, é comum avaliarmos, conjuntamente, dois ou mais intervalos de confiança (como, por exemplo, um intervalo para cada um dos p componentes do vetor de médias).
- Neste caso, a construção de intervalos que tem, individualmente, nível de confiança $100(1-\alpha)\%$, não garante que, conjuntamente, eles tenham esse nível de confiança (na verdade o nível de confiança será inferior).

# Região de confiança e intervalos simultâneos

- Uma das formas de garantir que se tenha, conjuntamente, a confiança desejada, é usando a estatística do teste $T^2$ **de Hotelling** como base para a construção dos intervalos.

# Região de confiança e intervalos simultâneos

- Uma das formas de garantir que se tenha, conjuntamente, a confiança desejada, é usando a estatística do teste $T^2$ **de Hotelling** como base para a construção dos intervalos.

- Outra alternativa para a construção de intervalos de confiança simultâneos é o **método de Bonferroni**, segundo o qual garantimos $m$ intervalos com confiança conjunta mínima $100(1-\alpha)\%$ "corrigindo" o nível de confiança.

# Região de confiança e intervalos simultâneos

- Os intervalos de confiança simultâneos para os componentes do vetor de médias baseados na estatística $T^2$ de Hotelling são dados por:

# Região de confiança e intervalos simultâneos

- Os intervalos de confiança simultâneos para os componentes do vetor de médias baseados na estatística $T^2$ de Hotelling são dados por:

$$\bar{y}_1 - \sqrt{\frac{p(n-1)}{(n-p)}F_{p,n-p}(\alpha)}\sqrt{\frac{s_{11}}{n}} \leq \mu_1 \leq \bar{y}_1 + \sqrt{\frac{p(n-1)}{(n-p)}F_{p,n-p}(\alpha)}\sqrt{\frac{s_{11}}{n}}$$

$$\bar{y}_2 - \sqrt{\frac{p(n-1)}{(n-p)}F_{p,n-p}(\alpha)}\sqrt{\frac{s_{22}}{n}} \leq \mu_2 \leq \bar{y}_2 + \sqrt{\frac{p(n-1)}{(n-p)}F_{p,n-p}(\alpha)}\sqrt{\frac{s_{22}}{n}}$$

$$\vdots$$

$$\bar{y}_p - \sqrt{\frac{p(n-1)}{(n-p)}F_{p,n-p}(\alpha)}\sqrt{\frac{s_{pp}}{n}} \leq \mu_p \leq \bar{y}_p + \sqrt{\frac{p(n-1)}{(n-p)}F_{p,n-p}(\alpha)}\sqrt{\frac{s_{pp}}{n}}$$

# Região de confiança e intervalos simultâneos

- Os intervalos de confiança de Bonferroni para os $p$ parâmetros de média, com nível de confiança conjunto $100(1-\alpha)\%$ são dados por:

# Região de confiança e intervalos simultâneos

- Os intervalos de confiança de Bonferroni para os $p$ parâmetros de média, com nível de confiança conjunto $100(1-\alpha)\%$ são dados por:

$$\bar{y}_1 - t_{n-1}(\alpha/2p)\sqrt{\frac{s_{11}}{n}} \leq \mu_1 \leq \bar{y}_1 + t_{n-1}(\alpha/2p)\sqrt{\frac{s_{11}}{n}}$$

$$\bar{y}_2 - t_{n-1}(\alpha/2p)\sqrt{\frac{s_{22}}{n}} \leq \mu_2 \leq \bar{y}_2 + t_{n-1}(\alpha/2p)\sqrt{\frac{s_{22}}{n}}$$

$$\vdots$$

$$\bar{y}_p - t_{n-1}(\alpha/2p)\sqrt{\frac{s_{pp}}{n}} \leq \mu_p \leq \bar{y}_p + t_{n-1}(\alpha/2p)\sqrt{\frac{s_{pp}}{n}}$$

# Exemplo 1

# Exemplo 1

- Vamos analisar dados referentes aos teores de areia e argila em uma amostra de $n = 30$ parcelas em solo de capoeira nova na Amazônia.

# Exemplo 1

- Vamos analisar dados referentes aos teores de areia e argila em uma amostra de $n = 30$ parcelas em solo de capoeira nova na Amazônia.

- Vamos assumir que os dados seguem aproximadamente distribuição normal bivariada para a sequência da análise.

# Exemplo 1

**Tabela 1:** Quantidades de areia e argila em 30 amostras de solo

| Parcela | Areia | Argila | Parcela | Areia | Argila |
|---|---|---|---|---|---|
| 1 | 11 | 38 | 16 | 20 | 32 |
| 2 | 13 | 47 | 17 | 24 | 25 |
| 3 | 18 | 34 | 18 | 28 | 32 |
| 4 | 16 | 49 | 19 | 17 | 39 |
| 5 | 11 | 45 | 20 | 18 | 34 |
| 6 | 30 | 32 | 21 | 27 | 36 |
| 7 | 5 | 64 | 22 | 45 | 24 |
| 8 | 7 | 59 | 23 | 11 | 40 |
| 9 | 11 | 50 | 24 | 42 | 23 |
| 10 | 17 | 38 | 25 | 41 | 21 |
| 11 | 21 | 35 | 26 | 9 | 40 |
| 12 | 22 | 36 | 27 | 48 | 21 |
| 13 | 13 | 40 | 28 | 14 | 32 |
| 14 | 12 | 36 | 29 | 53 | 21 |
| 15 | 25 | 28 | 30 | 31 | 32 |

# Exemplo 1

- Estatísticas descritivas:

$$\bar{\boldsymbol{y}} = \begin{bmatrix} 22.0 \\ 36.1 \end{bmatrix} \quad S = \begin{bmatrix} 164.2069 & -109.8966 \\ -109.8966 & 110.5759 \end{bmatrix}$$

# Exemplo 1

a) Teste ao nível de significância de 5% se o solo de capoeira nova tem, em média, iguais teores de areia e argila de uma população de floresta, dados, respectivamente, por $\mu_{\text{areia}} = 14$ e $\mu_{\text{argila}} = 42$.

- Hipóteses:

$$H_0 : \boldsymbol{\mu} = \begin{bmatrix} 14 \\ 42 \end{bmatrix} \text{ vs } H_1 : \boldsymbol{\mu} \neq \begin{bmatrix} 14 \\ 42 \end{bmatrix}$$

# Exemplo 1

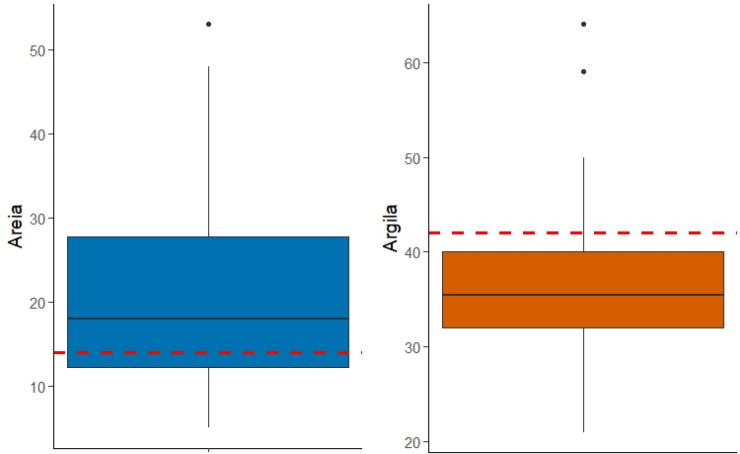



**Figura 1:** Boxplots das quantidades de areia e argila em 30 amostras de solo

# Exemplo 1

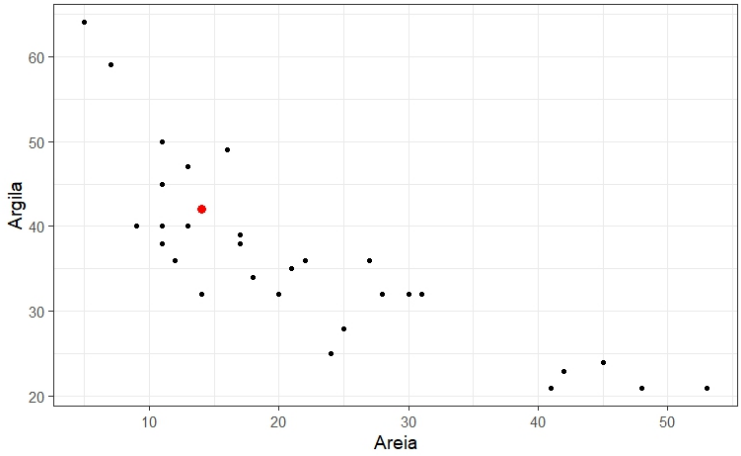



**Figura 2:** Quantidades de areia e argila em 30 amostras de solo

# Exemplo 1

- Estatística do teste:

$$T^2 = (\bar{\boldsymbol{Y}} - \boldsymbol{\mu_0})' \left(\frac{\boldsymbol{S}}{\boldsymbol{n}}\right)^{-1} (\bar{\boldsymbol{Y}} - \boldsymbol{\mu}_0) = n(\bar{\boldsymbol{Y}} - \boldsymbol{\mu}_0)' S^{-1} (\bar{\boldsymbol{Y}} - \boldsymbol{\mu}_0) =$$

$$T^2 = 30 \begin{bmatrix} 22 - 14 & 36.1 - 42 \end{bmatrix} \begin{bmatrix} 164.2069 & -109.8966 \\ -109.8966 & 110.5759 \end{bmatrix}^{-1} \begin{bmatrix} 22 - 14 \\ 36.1 - 42 \end{bmatrix} = 11.93$$

# Exemplo 1

- Regra de decisão:

O valor crítico para o teste, ao nível de significância de 5%, é dado por:

$$\frac{(n-1)p}{n-p} F p, n-p(1-\alpha) = \frac{29 \times 2}{30-2} \times 3.34 = 6.92$$

# Exemplo 1

- Regra de decisão:

O valor crítico para o teste, ao nível de significância de 5%, é dado por:

$$\frac{(n-1)p}{n-p} F p, n-p(1-\alpha) = \frac{29 \times 2}{30-2} \times 3.34 = 6.92$$

- Decisão: Como o valor calculado de $T^2$ excede o valor crítico ($T^2 = 11.93 > 6.92$), rejeitamos a hipótese $H_0$ ao nível de significância de 5%.

# Exemplo 1

- Regra de decisão:

O valor crítico para o teste, ao nível de significância de 5%, é dado por:

$$\frac{(n-1)p}{n-p} F p, n-p(1-\alpha) = \frac{29 \times 2}{30-2} \times 3.34 = 6.92$$

- Decisão: Como o valor calculado de $T^2$ excede o valor crítico ($T^2 = 11.93 > 6.92$), rejeitamos a hipótese $H_0$ ao nível de significância de 5%.

- Com isso, podemos concluir que o solo de capoeira nova difere significativamente nas médias de areia e argila da população de floresta.

# Exemplo 1

b) Obtenha a região de confiança (95%) para $\boldsymbol{\mu}$.

# Exemplo 1

b) Obtenha a região de confiança (95%) para $\boldsymbol{\mu}$.

A região de confiança (95%) para $\boldsymbol{\mu}$ é dada por todo vetor $\boldsymbol{\mu}' = (\mu_1, \mu_2)$ que satisfaz:

$$n(\bar{\boldsymbol{Y}} - \boldsymbol{\mu})' S^{-1} (\bar{\boldsymbol{Y}} - \boldsymbol{\mu}) \leq \frac{(n-1)p}{(n-p)} F_{p,n-p}(\alpha).$$

# Exemplo 1

b) Obtenha a região de confiança (95%) para $\boldsymbol{\mu}$.

A região de confiança (95%) para $\boldsymbol{\mu}$ é dada por todo vetor $\boldsymbol{\mu}' = (\mu_1, \mu_2)$ que satisfaz:

$$n(\bar{\boldsymbol{Y}} - \boldsymbol{\mu})' S^{-1} (\bar{\boldsymbol{Y}} - \boldsymbol{\mu}) \leq \frac{(n-1)p}{(n-p)} F_{p,n-p}(\alpha).$$

Ou seja,

$$30 \begin{bmatrix} 22 - \mu_1 & 36.1 - \mu_2 \end{bmatrix} \begin{bmatrix} 164.2069 & -109.8966 \\ -109.8966 & 110.5759 \end{bmatrix}^{-1} \begin{bmatrix} 22 - \mu_1 \\ 36.1 - \mu_2 \end{bmatrix} \leq 6.92$$

# Exemplo 1

- Obtenha os intervalos de confiança (95%) univariados para $\mu_1$ e $\mu_2$.

# Exemplo 1

- Obtenha os intervalos de confiança (95%) univariados para $\mu_1$ e $\mu_2$.

$$\text{IC}(\mu_1; 95\%) = \bar{y}_1 \pm t_{n-1}(\alpha/2)\sqrt{\frac{s_{11}}{n}} =$$

$$22 \pm 2.0452\sqrt{\frac{164.2069}{30}} = (17.2150; 26.7849)$$

# Exemplo 1

- Obtenha os intervalos de confiança (95%) univariados para $\mu_1$ e $\mu_2$.

$$IC(\mu_1; 95\%) = \bar{y}_1 \pm t_{n-1}(\alpha/2)\sqrt{\frac{s_{11}}{n}} =$$

$$22 \pm 2.0452\sqrt{\frac{164.2069}{30}} = (17.2150; 26.7849)$$

$$IC(\mu_2; 95\%) = \bar{y}_2 \pm t_{n-1}(\alpha/2)\sqrt{\frac{s_{22}}{n}} =$$

$$36.1 \pm 2.0452\sqrt{\frac{110.5759}{30}} = (32.1734; 40.0265)$$

# Exemplo 1

d) Obtenha os intervalos de confiança (95%) simultâneos para $\mu_1$ e $\mu_2$.

# Exemplo 1

d) Obtenha os intervalos de confiança (95%) simultâneos para $\mu_1$ e $\mu_2$.

$$IC(\mu_1; 95\%) = \left( \bar{y}_1 - \sqrt{\frac{p(n-1)}{(n-p)} F_{p,n-p}(\alpha)} \sqrt{\frac{s_{11}}{n}} \; ; \; \bar{y}_1 + \sqrt{\frac{p(n-1)}{(n-p)} F_{p,n-p}(\alpha)} \sqrt{\frac{s_{11}}{n}} \right) =$$

$$\left( 22 - \sqrt{\frac{2(30-1)}{(30-2)} 3.3404} \sqrt{\frac{164.2069}{30}} \; ; \; 22 + \sqrt{\frac{2(30-1)}{(30-2)} 3.3404} \sqrt{\frac{164.2069}{30}} \right) =$$

$$(15.8458; 28.1541)$$

# Exemplo 1

$$\text{IC}(\mu_2; 95\%) = \left( \bar{y}_2 - \sqrt{\frac{p(n-1)}{(n-p)} F_{p,n-p}(\alpha)} \sqrt{\frac{s_{22}}{n}} \;\; ; \;\; \bar{y}_2 + \sqrt{\frac{p(n-1)}{(n-p)} F_{p,n-p}(\alpha)} \sqrt{\frac{s_{22}}{n}} \right) =$$

$$\left( 36.1 - \sqrt{\frac{2(30-1)}{(30-2)} 3.3404} \sqrt{\frac{110.5759}{30}} \;\; ; \;\; 36.1 + \sqrt{\frac{2(30-1)}{(30-2)} 3.3404} \sqrt{\frac{110.5759}{30}} \right) =$$

$$(31.0499; 41.1501)$$

# Exemplo 1

e) Obtenha os intervalos de confiança (95%) com correção de Bonferroni para $\mu_1$ e $\mu_2$.

# Exemplo 1

e) Obtenha os intervalos de confiança (95%) com correção de Bonferroni para $\mu_1$ e $\mu_2$.

- Como $p = 2$, os intervalos deverão ser obtidos tomando $\alpha' = \alpha/2 = 0.025$. Desta forma, usaremos os quantis $\alpha'/2 = 0.0125$ $1 - \alpha'/2 = 0.9875$ da distribuição $t_{29}$ no cômputo dos limites de confiança ($t_{29;0.0125} = -2.3638$ e $t_{29;0.9875} = 2.3638$).

# Exemplo 1

e) Obtenha os intervalos de confiança (95%) com correção de Bonferroni para $\mu_1$ e $\mu_2$.

- Como $p = 2$, os intervalos deverão ser obtidos tomando $\alpha' = \alpha/2 = 0.025$. Desta forma, usaremos os quantis $\alpha'/2 = 0.0125$ $1 - \alpha'/2 = 0.9875$ da distribuição $t_{29}$ no cômputo dos limites de confiança ($t_{29;0.0125} = -2.3638$ e $t_{29;0.9875} = 2.3638$).

$$\text{IC}(\mu_1; 95\%) = 22 \pm 2.3638\sqrt{\frac{164.2069}{30}} = (16.4697; 27.5302)$$

$$\text{IC}(\mu_2; 95\%) = 36.1 \pm 2.3638\sqrt{\frac{110.5759}{30}} = (31.5618; 40.6381)$$

# Comparação de dois vetores de médias- caso pareado

# Comparação de dois vetores de médias- caso pareado

- Vamos abordar agora o caso em que temos duas populações (multivariadas) normalmente distribuídas e desejamos comparar suas médias.

# Comparação de dois vetores de médias- caso pareado

- Vamos abordar agora o caso em que temos duas populações (multivariadas) normalmente distribuídas e desejamos comparar suas médias.

- Uma vez mais, vamos estender a abordagem univariada para o caso multivariado.

# Comparação de dois vetores de médias- caso pareado

- Vamos abordar agora o caso em que temos duas populações (multivariadas) normalmente distribuídas e desejamos comparar suas médias.

- Uma vez mais, vamos estender a abordagem univariada para o caso multivariado.

- Vamos considerar, num primeiro momento, que dispomos de dados (grupos, amostras) pareados (ex: valores de uma variável verificados em pacientes antes e após administrar um tratamento).

# Comparação de dois vetores de médias- caso pareado

- Vamos abordar agora o caso em que temos duas populações (multivariadas) normalmente distribuídas e desejamos comparar suas médias.
- Uma vez mais, vamos estender a abordagem univariada para o caso multivariado.
- Vamos considerar, num primeiro momento, que dispomos de dados (grupos, amostras) pareados (ex: valores de uma variável verificados em pacientes antes e após administrar um tratamento).
- Vamos denotar por $y_{11}, y_{12}, ..., y_{1n}$ a primeira amostra (ex: respostas antes do tratamento) e $y_{21}, y_{22}, ..., y_{2n}$ a segunda (ex: respostas após o tratamento).

# Comparação de dois vetores de médias- caso pareado

- Como medida de efeito produzida pelo j-ésimo indivíduo, calculamos $d_j = y_{1j} - y_{2j}$, para $j = 1, 2, ..., n$.

# Comparação de dois vetores de médias- caso pareado

- Como medida de efeito produzida pelo j-ésimo indivíduo, calculamos $d_j = y_{1j} - y_{2j}$, para $j = 1, 2, ..., n$.

- Consideremos, $d_1, d_2, ..., d_n$ uma amostra de diferenças independentes com distribuição normal de média $\delta$ e variância $\sigma^2$. O teste fica definido pelo par de hipóteses $H_0 : \delta = \delta_0$ versus $H_1 : \delta \neq \delta_0$.

# Comparação de dois vetores de médias- caso pareado

- Como medida de efeito produzida pelo j-ésimo indivíduo, calculamos $d_j = y_{1j} - y_{2j}$, para $j = 1, 2, ..., n$.

- Consideremos, $d_1, d_2, ..., d_n$ uma amostra de diferenças independentes com distribuição normal de média $\delta$ e variância $\sigma^2$. O teste fica definido pelo par de hipóteses $H_0 : \delta = \delta_0$ versus $H_1 : \delta \neq \delta_0$.

- A estatística do teste, neste caso, é:

$$t = \frac{\bar{d} - \delta_0}{s_d/\sqrt{n}},$$

# Comparação de dois vetores de médias- caso pareado

- Como medida de efeito produzida pelo j-ésimo indivíduo, calculamos $d_j = y_{1j} - y_{2j}$, para $j = 1, 2, ..., n$.

- Consideremos, $d_1, d_2, ..., d_n$ uma amostra de diferenças independentes com distribuição normal de média $\delta$ e variância $\sigma^2$. O teste fica definido pelo par de hipóteses $H_0 : \delta = \delta_0$ versus $H_1 : \delta \neq \delta_0$.

- A estatística do teste, neste caso, é:

$$t = \frac{\bar{d} - \delta_0}{s_d/\sqrt{n}},$$

sendo

$$\bar{d} = \sum_{j=1}^{n} d_j; \;\; s_d^2 = \frac{1}{n-1} \sum_{j=1}^{n} (d_j - \bar{d})^2$$

# Comparação de dois vetores de médias- caso pareado

- Sob $H_0 : \delta = \delta_0$, $t \sim t_{n-1}$, de tal forma que rejeitamos $H_0$, para um nível de significância $\alpha$, se $|t| > |t_{n-1}(\alpha/2)|$.

# Comparação de dois vetores de médias- caso pareado

- Sob $H_0 : \delta = \delta_0$, $t \sim t_{n-1}$, de tal forma que rejeitamos $H_0$, para um nível de significância $\alpha$, se $|t| > |t_{n-1}(\alpha/2)|$.

- Adicionalmente, um intervalo de confiança $100(1-\alpha)\%$ para $\delta$ tem limites:

$$\bar{d} \pm t_{n-1}(\alpha/2)\frac{s_d}{\sqrt{n}}.$$

# Comparação de dois vetores de médias- caso pareado

- Para o caso multivariado (p variáveis), vamos denotar as duas amostras por $\boldsymbol{y_{11}}, \boldsymbol{y_{12}}, ..., \boldsymbol{y_{1n}}$ (em que $\boldsymbol{y'_{1j}} = (y_{1j1}, y_{1j2}, ..., y_{1jp})$) e $\boldsymbol{y_{21}}, \boldsymbol{y_{22}}, ..., \boldsymbol{y_{2n}}$, (em que $\boldsymbol{y'_{2j}} = (y_{2j1}, y_{2j2}, ..., y_{2jp})$), respectivamente.

# Comparação de dois vetores de médias- caso pareado

- Para o caso multivariado (p variáveis), vamos denotar as duas amostras por $\boldsymbol{y_{11}}, \boldsymbol{y_{12}}, ..., \boldsymbol{y_{1n}}$ (em que $\boldsymbol{y'_{1j}} = (y_{1j1}, y_{1j2}, ..., y_{1jp})$) e $\boldsymbol{y_{21}}, \boldsymbol{y_{22}}, ..., \boldsymbol{y_{2n}}$, (em que $\boldsymbol{y'_{2j}} = (y_{2j1}, y_{2j2}, ..., y_{2jp})$), respectivamente.

- Assim, para um particular indivíduo $j$, temos como medidas de efeito nas p variáveis as diferenças $d_{j1} = y_{1j1} - y_{2j1}$, $d_{j2} = y_{1j2} - y_{2j2}, \ldots$, $d_{jn} = y_{1jn} - y_{2jn}$. Assumimos, para $\boldsymbol{D}$ distribuição normal p-variada com $E(\boldsymbol{D}) = \boldsymbol{\delta}' = (\delta_1, \delta_2, ..., \delta_p)$ e $Cov(\boldsymbol{D}_j) = \Sigma_D$.

# Comparação de dois vetores de médias- caso pareado

- Para o caso multivariado (p variáveis), vamos denotar as duas amostras por $\boldsymbol{y_{11}}, \boldsymbol{y_{12}}, ..., \boldsymbol{y_{1n}}$ (em que $\boldsymbol{y'_{1j}} = (y_{1j1}, y_{1j2}, ..., y_{1jp})$) e $\boldsymbol{y_{21}}, \boldsymbol{y_{22}}, ..., \boldsymbol{y_{2n}}$, (em que $\boldsymbol{y'_{2j}} = (y_{2j1}, y_{2j2}, ..., y_{2jp})$), respectivamente.

- Assim, para um particular indivíduo $j$, temos como medidas de efeito nas p variáveis as diferenças $d_{j1} = y_{1j1} - y_{2j1}$, $d_{j2} = y_{1j2} - y_{2j2}, \ldots$, $d_{jn} = y_{1jn} - y_{2jn}$. Assumimos, para $\boldsymbol{D}$ distribuição normal p-variada com $E(\boldsymbol{D}) = \boldsymbol{\delta}' = (\delta_1, \delta_2, ..., \delta_p)$ e $Cov(\boldsymbol{D}_j) = \Sigma_D$.

- Desta forma, a inferência sobre o vetor $\boldsymbol{\delta}$ pode se basear na estatística $T^2$:

$$T^2 = n(\bar{\boldsymbol{d}} - \boldsymbol{\delta_0})' S_d^{-1} (\bar{\boldsymbol{d}} - \boldsymbol{\delta_0}),$$

que, sob $H_0$, tem distribuição $[(n-1)p/(n-p)]F_{p,n-p}$, sendo $\bar{\boldsymbol{D}}$ e $S_D$ o vetor de médias e a matriz de covariâncias amostrais do vetor de diferenças.

# Comparação de dois vetores de médias- caso pareado

- Nas condições apresentadas, para testar a hipótese $H_0 : \boldsymbol{\delta} = \mathbf{0}$ versus $H_1 : \boldsymbol{\delta} \neq \mathbf{0}$, rejeitamos $H_0$, para um nível de significância $\alpha$, se:

$$T^2 = n\bar{\boldsymbol{d}}'\boldsymbol{S}_{\boldsymbol{d}}^{-1}\bar{\boldsymbol{d}} > \frac{(n-1)p}{(n-p)}F_{p,n-p}(\alpha).$$

# Comparação de dois vetores de médias- caso pareado

- Nas condições apresentadas, para testar a hipótese $H_0 : \boldsymbol{\delta} = \mathbf{0}$ versus $H_1 : \boldsymbol{\delta} \neq \mathbf{0}$, rejeitamos $H_0$, para um nível de significância $\alpha$, se:

$$T^2 = n\bar{\boldsymbol{d}}'\boldsymbol{S}_{\boldsymbol{d}}^{-1}\bar{\boldsymbol{d}} > \frac{(n-1)p}{(n-p)}F_{p,n-p}(\alpha).$$

- Adicionalmente, intervalos de confiança simultâneos $T^2$ e de Bonferroni podem ser obtidos de forma semelhante à discutida anteriormente:

# Comparação de dois vetores de médias- caso pareado

- Nas condições apresentadas, para testar a hipótese $H_0 : \boldsymbol{\delta} = \mathbf{0}$ versus $H_1 : \boldsymbol{\delta} \neq \mathbf{0}$, rejeitamos $H_0$, para um nível de significância $\alpha$, se:

$$T^2 = n\bar{\boldsymbol{d}}'\boldsymbol{S}_{\boldsymbol{d}}^{-1}\bar{\boldsymbol{d}} > \frac{(n-1)p}{(n-p)}F_{p,n-p}(\alpha).$$

- Adicionalmente, intervalos de confiança simultâneos $T^2$ e de Bonferroni podem ser obtidos de forma semelhante à discutida anteriormente:

$$\bar{d}_j \pm \sqrt{\frac{(n-1)p}{(n-p)}F_{p,n-p}(\alpha)}\sqrt{\frac{s_{d_j}^2}{n}};$$

$$\bar{d}_j \pm t_{n-1}(\tfrac{\alpha}{2p})\sqrt{\frac{s_{d_j}^2}{n}}, j = 1, 2, ..., p.$$

# Exemplo 2

# Exemplo 2

- Os dados utilizados nesta aplicação referem-se a um estudo sobre o efeito de exercícios físicos intensos sobre o estresse oxidativo no plasma de mulheres da terceira idade.

# Exemplo 2

- Os dados utilizados nesta aplicação referem-se a um estudo sobre o efeito de exercícios físicos intensos sobre o estresse oxidativo no plasma de mulheres da terceira idade.

- Para isso, uma amostra de $n = 16$ mulheres foi avaliada antes e após tratamento, que consistia em submetê-las a 4 semanas de exercícios físicos intensos.

# Exemplo 2

- Os dados utilizados nesta aplicação referem-se a um estudo sobre o efeito de exercícios físicos intensos sobre o estresse oxidativo no plasma de mulheres da terceira idade.

- Para isso, uma amostra de $n = 16$ mulheres foi avaliada antes e após tratamento, que consistia em submetê-las a 4 semanas de exercícios físicos intensos.

- Foram registradas as quantidades de proteínas (g/dl) e peróxidos (nmol/g de proteína), antes e após o tratamento.

# Exemplo 2

**Tabela 2:** Quantidades sanguíneas de proteína e peróxido antes e após tratamento

| Paciente | Proteína (antes) | Peróxido (antes) | Proteína (depois) | Peróxido (depois) |
|---|---|---|---|---|
| 1 | 6.00 | 53.00 | 6.60 | 72.30 |
| 2 | 6.00 | 79.00 | 6.50 | 77.00 |
| 3 | 6.90 | 62.00 | 6.90 | 56.90 |
| 4 | 5.90 | 74.70 | 6.60 | 67.40 |
| 5 | 7.00 | 85.00 | 7.00 | 59.10 |
| 6 | 6.30 | 62.90 | 6.50 | 72.00 |
| 7 | 6.50 | 65.10 | 6.70 | 55.00 |
| 8 | 5.90 | 80.30 | 6.00 | 68.10 |
| 9 | 6.80 | 56.00 | 7.00 | 58.30 |
| 10 | 6.80 | 47.00 | 7.00 | 72.40 |
| 11 | 7.10 | 73.00 | 7.50 | 59.20 |
| 12 | 6.80 | 23.00 | 7.00 | 62.10 |
| 13 | 6.80 | 52.40 | 6.60 | 66.80 |
| 14 | 6.50 | 87.00 | 6.40 | 88.70 |
| 15 | 6.60 | 63.00 | 7.30 | 48.30 |
| 16 | 6.60 | 64.22 | 6.20 | 65.57 |

# Exemplo 2

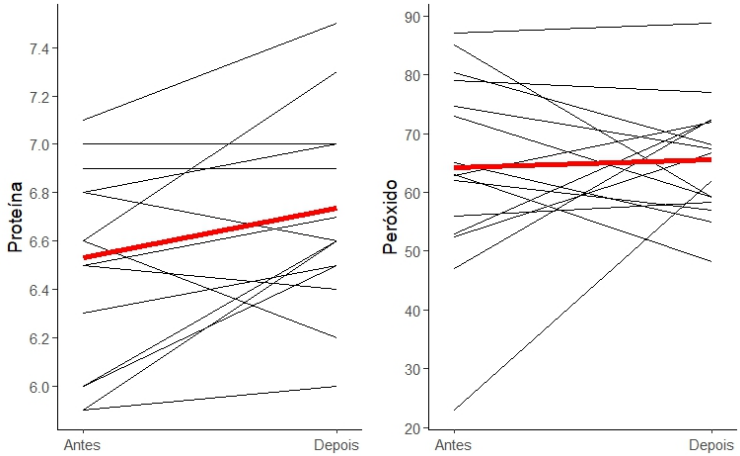



**Figura 3:** Quantidades sanguíneas de proteína e peróxido antes e após tratamento

# Exemplo 2

- Vetores de diferenças

$$\boldsymbol{d_1} = \begin{bmatrix} 6.60 \\ 72.30 \end{bmatrix} - \begin{bmatrix} 6.00 \\ 53.00 \end{bmatrix} = \begin{bmatrix} 0.60 \\ 19.30 \end{bmatrix}, \cdots, \boldsymbol{d_{16}} = \begin{bmatrix} 6.20 \\ 65.57 \end{bmatrix} - \begin{bmatrix} 6.60 \\ 64.22 \end{bmatrix} = \begin{bmatrix} -0.40 \\ 1.35 \end{bmatrix}$$

# Exemplo 2

- Vetores de diferenças

$$\boldsymbol{d_1} = \begin{bmatrix} 6.60 \\ 72.30 \end{bmatrix} - \begin{bmatrix} 6.00 \\ 53.00 \end{bmatrix} = \begin{bmatrix} 0.60 \\ 19.30 \end{bmatrix}, \cdots, \boldsymbol{d_{16}} = \begin{bmatrix} 6.20 \\ 65.57 \end{bmatrix} - \begin{bmatrix} 6.60 \\ 64.22 \end{bmatrix} = \begin{bmatrix} -0.40 \\ 1.35 \end{bmatrix}$$

- Estatísticas descritivas:

$$\bar{\boldsymbol{d}} = \begin{bmatrix} 0.2062 \\ 1.3469 \end{bmatrix} \quad S_d = \begin{bmatrix} 0.0993 & -0.4290 \\ -0.4290 & 281.9398 \end{bmatrix}$$

# Exemplo 2

a) Teste a hipótese de que os valores médios populacionais não foram alterados pelo exercício físico intenso.

- Hipóteses:

$$H_0 : \boldsymbol{\mu}_d = \delta_0 = \begin{bmatrix} 0 \\ 0 \end{bmatrix} \text{ vs } H_1 : \boldsymbol{\mu}_d \neq \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

# Exemplo 2

- Estatística do teste:

$$T^2 = n(\bar{\boldsymbol{d}} - \boldsymbol{\delta}_0)' S_d^{-1} (\bar{\boldsymbol{d}} - \boldsymbol{\delta}_0) =$$

$$T^2 = 16 \begin{bmatrix} 0.2062 & 1.3469 \end{bmatrix} \begin{bmatrix} 0.0993 & -0.4290 \\ -0.4290 & 281.9398 \end{bmatrix}^{-1} \begin{bmatrix} 0.2062 \\ 1.3469 \end{bmatrix} = 7.1409$$

# Exemplo 2

- Regra de decisão:

O valor crítico para o teste, ao nível de significância de 5%, é dado por:

$$\frac{(n-1)p}{n-p} F\, p, n-p(1-\alpha) = \frac{15 \times 2}{16-2} \times 3.7389 = 8.0119$$

# Exemplo 2

- Regra de decisão:

O valor crítico para o teste, ao nível de significância de 5%, é dado por:

$$\frac{(n-1)p}{n-p} F\, p, n-p(1-\alpha) = \frac{15 \times 2}{16-2} \times 3.7389 = 8.0119$$

- Decisão: Como o valor calculado de $T^2$ não excede o valor crítico ($T^2 = 7.1409 < 8.0119$), não há evidências para rejeitar a hipótese $H_0$ ao nível de significância de 5%.

# Exemplo 2

- Regra de decisão:

O valor crítico para o teste, ao nível de significância de 5%, é dado por:

$$\frac{(n-1)p}{n-p} F\,p, n-p(1-\alpha) = \frac{15 \times 2}{16-2} \times 3.7389 = 8.0119$$

- Decisão: Como o valor calculado de $T^2$ não excede o valor crítico ($T^2 = 7.1409 < 8.0119$), não há evidências para rejeitar a hipótese $H_0$ ao nível de significância de 5%.

- Assim, não temos evidências significativas de que haja efeito do exercício físico intenso sobre o estresse oxidativo.

# Exemplo 2

b) Obtenha a região de confiança (95%) para $\boldsymbol{\mu}_d$.

# Exemplo 2

b) Obtenha a região de confiança (95%) para $\boldsymbol{\mu}_d$.

A região de confiança (95%) para $\boldsymbol{\mu}_d$ é dada por todo vetor $\boldsymbol{\mu}_d = (\mu_{d1}, \mu_{d2})$ que satisfaz:

$$n(\bar{\boldsymbol{d}} - \boldsymbol{\mu_d})' S_d^{-1} (\bar{\boldsymbol{d}} - \boldsymbol{\mu_d}) \leq \frac{(n-1)p}{(n-p)} F_{p,n-p}(\alpha).$$

# Exemplo 2

b) Obtenha a região de confiança (95%) para $\boldsymbol{\mu}_d$.

A região de confiança (95%) para $\boldsymbol{\mu}_d$ é dada por todo vetor $\boldsymbol{\mu}_d = (\mu_{d1}, \mu_{d2})$ que satisfaz:

$$n(\bar{\boldsymbol{d}} - \boldsymbol{\mu_d})' S_d^{-1} (\bar{\boldsymbol{d}} - \boldsymbol{\mu_d}) \leq \frac{(n-1)p}{(n-p)} F_{p,n-p}(\alpha).$$

Ou seja,

$$\begin{bmatrix} 0.2062 - \mu_{d1} & 1.3469 - \mu_{d2} \end{bmatrix} \begin{bmatrix} 0.0993 & -0.4290 \\ -0.4290 & 281.9398 \end{bmatrix}^{-1} \begin{bmatrix} 0.2062 - \mu_{d1} \\ 1.3469 - \mu_{d2} \end{bmatrix} \leq 6.92$$

# Exemplo 2

- Obtenha os intervalos de confiança (95%) univariados para $\mu_{d1}$ e $\mu_{d2}$.

# Exemplo 2

- Obtenha os intervalos de confiança (95%) univariados para $\mu_{d1}$ e $\mu_{d2}$.

$$\text{IC}(\mu_{d1}; 95\%) = \bar{d}_1 \pm t_{n-1}(\alpha/2)\sqrt{\frac{s_{d11}}{n}} =$$

$$0.2062 \pm 2.1314\sqrt{\frac{0.0993}{16}} = (0.0383; 0.3741)$$

# Exemplo 2

- Obtenha os intervalos de confiança (95%) univariados para $\mu_{d1}$ e $\mu_{d2}$.

$$IC(\mu_{d1}; 95\%) = \bar{d}_1 \pm t_{n-1}(\alpha/2)\sqrt{\frac{s_{d11}}{n}} =$$

$$0.2062 \pm 2.1314\sqrt{\frac{0.0993}{16}} = (0.0383; 0.3741)$$

$$IC(\mu_{d2}; 95\%) = \bar{d}_2 \pm t_{n-1}(\alpha/2)\sqrt{\frac{s_{d22}}{n}} =$$

$$1.3469 \pm 2.1314\sqrt{\frac{281.9398}{16}} = (-7.6002; 10.2940)$$

# Exemplo 2

- Obtenha os intervalos de confiança (95%) simultâneos para $\mu_{d1}$ e $\mu_{d2}$.

# Exemplo 2

d) Obtenha os intervalos de confiança (95%) simultâneos para $\mu_{d1}$ e $\mu_{d2}$.

$$\text{IC}(\mu_{d1}; 95\%) = \left( \bar{d}_1 - \sqrt{\frac{p(n-1)}{(n-p)} F_{p,n-p}(\alpha)} \sqrt{\frac{s_{d11}}{n}} \;\; ; \;\; \bar{d}_1 + \sqrt{\frac{p(n-1)}{(n-p)} F_{p,n-p}(\alpha)} \sqrt{\frac{s_{d11}}{n}} \right) =$$

# Exemplo 2

d) Obtenha os intervalos de confiança (95%) simultâneos para $\mu_{d1}$ e $\mu_{d2}$.

$$\text{IC}(\mu_{d1}; 95\%) = \left( \bar{d}_1 - \sqrt{\frac{p(n-1)}{(n-p)} F_{p,n-p}(\alpha)} \sqrt{\frac{s_{d11}}{n}} \;\; ; \;\; \bar{d}_1 + \sqrt{\frac{p(n-1)}{(n-p)} F_{p,n-p}(\alpha)} \sqrt{\frac{s_{d11}}{n}} \right) =$$

$$\left( 0.2062 - \sqrt{\frac{2(16-1)}{(16-2)} 3.7389} \sqrt{\frac{0.0993}{16}} \;\; ; \;\; 0.2062 + \sqrt{\frac{2(16-1)}{(16-2)} 3.7389} \sqrt{\frac{0.0993}{16}} \right) =$$

$$(-0.0168; 0.4292)$$

# Exemplo 2

$$\text{IC}(\mu_{d2}; 95\%) = \left( \bar{d}_2 - \sqrt{\frac{p(n-1)}{(n-p)} F_{p,n-p}(\alpha)} \sqrt{\frac{s_{d22}}{n}} \;\; ; \;\; \bar{d}_2 + \sqrt{\frac{p(n-1)}{(n-p)} F_{p,n-p}(\alpha)} \sqrt{\frac{s_{d22}}{n}} \right) =$$

# Exemplo 2

$$\text{IC}(\mu_{d2}; 95\%) = \left( \bar{d}_2 - \sqrt{\frac{p(n-1)}{(n-p)} F_{p,n-p}(\alpha)} \sqrt{\frac{s_{d22}}{n}} \;\; ; \;\; \bar{d}_2 + \sqrt{\frac{p(n-1)}{(n-p)} F_{p,n-p}(\alpha)} \sqrt{\frac{s_{d22}}{n}} \right) =$$

$$\left( 1.3469 - \sqrt{\frac{2(16-1)}{(16-2)} 3.7389} \sqrt{\frac{281.9398}{16}} \;\; ; \;\; 1.3469 + \sqrt{\frac{2(16-1)}{(16-2)} 3.7389} \sqrt{\frac{281.9398}{16}} \right) =$$

$$(-10.5350; 13.2288)$$

# Exemplo 2

- Obtenha os intervalos de confiança (95%) com correção de Bonferroni para $\mu_{d1}$ e $\mu_{d2}$.

# Exemplo 2

- Obtenha os intervalos de confiança (95%) com correção de Bonferroni para $\mu_{d1}$ e $\mu_{d2}$.

  - Como $p = 2$, os intervalos deverão ser obtidos tomando $\alpha' = \alpha/2 = 0.025$. Desta forma, usaremos os quantis $\alpha'/2 = 0.0125$ $1 - \alpha'/2 = 0.9875$ da distribuição $t_{15}$ no cômputo dos limites de confiança ($t_{15}(0.0125) = -2.49$ e $t_{15}(0.9875) = 2.49$).

$$\text{IC}(\mu_{d1}; 95\%) = 0.2062 \pm 2.49\sqrt{\frac{0.0993}{16}} = (0.0100; 0.4024)$$

# Exemplo 2

- Obtenha os intervalos de confiança (95%) com correção de Bonferroni para $\mu_{d1}$ e $\mu_{d2}$.

  - Como $p = 2$, os intervalos deverão ser obtidos tomando $\alpha' = \alpha/2 = 0.025$. Desta forma, usaremos os quantis $\alpha'/2 = 0.0125$ $1 - \alpha'/2 = 0.9875$ da distribuição $t_{15}$ no cômputo dos limites de confiança ($t_{15}(0.0125) = -2.49$ e $t_{15}(0.9875) = 2.49$).

$$\text{IC}(\mu_{d1}; 95\%) = 0.2062 \pm 2.49\sqrt{\frac{0.0993}{16}} = (0.0100; 0.4024)$$

$$\text{IC}(\mu_{d2}; 95\%) = 1.3469 \pm 2.49\sqrt{\frac{281.9398}{16}} = (-9.1051; 11.7988)$$

# Comparação de dois vetores de médias- caso não pareado (com matrizes de covariâncias homogêneas)

# Comparação de dois vetores de médias- caso não pareado (com matrizes de covariâncias homogêneas)

- Já para o caso em que as amostras são independentes (não pareadas), considere:

# Comparação de dois vetores de médias- caso não pareado (com matrizes de covariâncias homogêneas)

- Já para o caso em que as amostras são independentes (não pareadas), considere:
  - $\boldsymbol{Y}_{11}, \boldsymbol{Y}_{12}, ..., \boldsymbol{Y}_{1n_1}$ uma amostra aleatória de uma normal p-variada com vetor de médias $\boldsymbol{\mu_1}$ e matriz de covariâncias $\Sigma_1$;

# Comparação de dois vetores de médias- caso não pareado (com matrizes de covariâncias homogêneas)

- Já para o caso em que as amostras são independentes (não pareadas), considere:
  - $\boldsymbol{Y}_{11}, \boldsymbol{Y}_{12}, ..., \boldsymbol{Y}_{1n_1}$ uma amostra aleatória de uma normal p-variada com vetor de médias $\boldsymbol{\mu_1}$ e matriz de covariâncias $\Sigma_1$;
  - $\boldsymbol{Y}_{21}, \boldsymbol{Y}_{22}, ..., \boldsymbol{Y}_{2n_2}$ uma amostra aleatória de uma normal p-variada com vetor de médias $\boldsymbol{\mu_2}$ e matriz de covariâncias $\Sigma_2$;

# Comparação de dois vetores de médias- caso não pareado (com matrizes de covariâncias homogêneas)

- Já para o caso em que as amostras são independentes (não pareadas), considere:
  - $\boldsymbol{Y}_{11}, \boldsymbol{Y}_{12}, ..., \boldsymbol{Y}_{1n_1}$ uma amostra aleatória de uma normal p-variada com vetor de médias $\boldsymbol{\mu_1}$ e matriz de covariâncias $\Sigma_1$;
  - $\boldsymbol{Y}_{21}, \boldsymbol{Y}_{22}, ..., \boldsymbol{Y}_{2n_2}$ uma amostra aleatória de uma normal p-variada com vetor de médias $\boldsymbol{\mu_2}$ e matriz de covariâncias $\Sigma_2$;
  - Assumimos que as populações de origem têm distribuição normal e que $\Sigma_1 = \Sigma_2$ (veremos adiante como testar essa suposição).

# Comparação de dois vetores de médias- caso não pareado (com matrizes de covariâncias homogêneas)

- Já para o caso em que as amostras são independentes (não pareadas), considere:
  - $\boldsymbol{Y}_{11}, \boldsymbol{Y}_{12}, ..., \boldsymbol{Y}_{1n_1}$ uma amostra aleatória de uma normal p-variada com vetor de médias $\boldsymbol{\mu_1}$ e matriz de covariâncias $\Sigma_1$;
  - $\boldsymbol{Y}_{21}, \boldsymbol{Y}_{22}, ..., \boldsymbol{Y}_{2n_2}$ uma amostra aleatória de uma normal p-variada com vetor de médias $\boldsymbol{\mu_2}$ e matriz de covariâncias $\Sigma_2$;
  - Assumimos que as populações de origem têm distribuição normal e que $\Sigma_1 = \Sigma_2$ (veremos adiante como testar essa suposição).

- Considere ainda $\bar{\boldsymbol{y}}_{\boldsymbol{1}}$ e $S_1$ o vetor de médias e a matriz de covariâncias amostrais da primeira amostra e $\bar{\boldsymbol{y}}_{\boldsymbol{2}}$ e $S_2$ os correspondentes da segunda.

# Comparação de dois vetores de médias- caso não pareado (com matrizes de covariâncias homogêneas)

- No cenário apresentado, podemos estimar $\Sigma = \Sigma_1 = \Sigma_2$ usando o estimador ponderado:

$$S_p = \frac{n_1-1}{n_1+n_2-2} S_1 + \frac{n_2-1}{n_1+n_2-2} S_2.$$

# Comparação de dois vetores de médias- caso não pareado (com matrizes de covariâncias homogêneas)

- No cenário apresentado, podemos estimar $\Sigma = \Sigma_1 = \Sigma_2$ usando o estimador ponderado:

$$S_p = \frac{n_1-1}{n_1+n_2-2} S_1 + \frac{n_2-1}{n_1+n_2-2} S_2.$$

- Nesse caso, a estatística:

$$T^2 = [(\bar{\boldsymbol{Y}}_1 - \bar{\boldsymbol{Y}}_2) - (\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2)]' \left[ \left( \frac{1}{n_1} + \frac{1}{n_2} \right) S_p \right]^{-1} [(\bar{\boldsymbol{Y}}_1 - \bar{\boldsymbol{Y}}_2) - (\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2)]$$

tem distribuição

$$\frac{(n_1+n_2-2)p}{(n_1+n_2-p-1)} F_{p,n_1+n_2-p-1}.$$

# Comparação de dois vetores de médias- caso não pareado (com matrizes de covariâncias homogêneas)

- Assim, para testar o par de hipóteses $H_0 : \boldsymbol{\mu}_1 - \boldsymbol{\mu}_2 = \boldsymbol{\delta}$ vs $H_1 : \boldsymbol{\mu}_1 - \boldsymbol{\mu}_2 \neq \boldsymbol{\delta}$, calculamos:

$$T^2 = [(\bar{\boldsymbol{y}}_1 - \bar{\boldsymbol{y}}_2) - \boldsymbol{\delta}]' \left[ \left( \frac{1}{n_1} + \frac{1}{n_2} \right) S_p \right]^{-1} [(\bar{\boldsymbol{y}}_1 - \bar{\boldsymbol{y}}_2) - \boldsymbol{\delta}],$$

# Comparação de dois vetores de médias- caso não pareado (com matrizes de covariâncias homogêneas)

- Assim, para testar o par de hipóteses $H_0 : \boldsymbol{\mu}_1 - \boldsymbol{\mu}_2 = \boldsymbol{\delta}$ vs $H_1 : \boldsymbol{\mu}_1 - \boldsymbol{\mu}_2 \neq \boldsymbol{\delta}$, calculamos:

$$T^2 = [(\bar{\boldsymbol{y}}_1 - \bar{\boldsymbol{y}}_2) - \boldsymbol{\delta}]' \left[ \left( \frac{1}{n_1} + \frac{1}{n_2} \right) S_p \right]^{-1} [(\bar{\boldsymbol{y}}_1 - \bar{\boldsymbol{y}}_2) - \boldsymbol{\delta}],$$

e rejeitamos $H_0$, a um nível de significância $\alpha$, se

$$T^2 > \frac{(n_1+n_2-2)p}{(n_1+n_2-p-1)} F_{p,n_1+n_2-p-1}(\alpha).$$

# Comparação de dois vetores de médias- caso não pareado (com matrizes de covariâncias homogêneas)

- Assim, para testar o par de hipóteses $H_0 : \boldsymbol{\mu}_1 - \boldsymbol{\mu}_2 = \boldsymbol{\delta}$ vs $H_1 : \boldsymbol{\mu}_1 - \boldsymbol{\mu}_2 \neq \boldsymbol{\delta}$, calculamos:

$$T^2 = [(\bar{\boldsymbol{y}}_1 - \bar{\boldsymbol{y}}_2) - \boldsymbol{\delta}]' \left[ \left( \frac{1}{n_1} + \frac{1}{n_2} \right) S_p \right]^{-1} [(\bar{\boldsymbol{y}}_1 - \bar{\boldsymbol{y}}_2) - \boldsymbol{\delta}],$$

e rejeitamos $H_0$, a um nível de significância $\alpha$, se

$$T^2 > \frac{(n_1+n_2-2)p}{(n_1+n_2-p-1)} F_{p,n_1+n_2-p-1}(\alpha).$$

- É usual, mas não obrigatório, considerar $\boldsymbol{\delta}$ o vetor de zeros de tamanho p.

# Comparação de dois vetores de médias- caso não pareado (com matrizes de covariâncias homogêneas)

- Intervalos de confiança simultâneos podem ser obtidos, uma vez mais, com base na estatística $T^2$ ou usando o método de Bonferroni.

# Comparação de dois vetores de médias- caso não pareado (com matrizes de covariâncias homogêneas)

- Intervalos de confiança simultâneos podem ser obtidos, uma vez mais, com base na estatística $T^2$ ou usando o método de Bonferroni.

- Seja $c^2 = \frac{(n_1+n_2-2)p}{(n_1+n_2-p-1)} F_{p,n_1+n_2-p-1}(\alpha)$. Então, para todo $\boldsymbol{a}$,

$$\boldsymbol{a'}(\bar{\boldsymbol{y}}_1 - \bar{\boldsymbol{y}}_2) \pm c\sqrt{\boldsymbol{a'}(\tfrac{1}{n_1} + \tfrac{1}{n_2})\boldsymbol{S}_p\boldsymbol{a}}$$

é um intervalo de $100(1-\alpha)\%$ de confiança para $\boldsymbol{a'}(\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2)$.

# Comparação de dois vetores de médias- caso não pareado (com matrizes de covariâncias homogêneas)

- Intervalos de confiança simultâneos podem ser obtidos, uma vez mais, com base na estatística $T^2$ ou usando o método de Bonferroni.

- Seja $c^2 = \frac{(n_1+n_2-2)p}{(n_1+n_2-p-1)} F_{p,n_1+n_2-p-1}(\alpha)$. Então, para todo $\boldsymbol{a}$,

$$\boldsymbol{a'}(\bar{\boldsymbol{y}}_1 - \bar{\boldsymbol{y}}_2) \pm c\sqrt{\boldsymbol{a'}(\tfrac{1}{n_1} + \tfrac{1}{n_2})\boldsymbol{S}_p\boldsymbol{a}}$$

é um intervalo de $100(1-\alpha)\%$ de confiança para $\boldsymbol{a'}(\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2)$.

- Em particular, para $\mu_{1j} - \mu_{2j}$ temos:

$$(\bar{y}_{1j} - \bar{y}_{2j}) \pm c\sqrt{(\tfrac{1}{n_1} + \tfrac{1}{n_2})S_{pjj}},\ j = 1, 2, ..., p.$$

# Comparação de dois vetores de médias- caso não pareado (com matrizes de covariâncias homogêneas)

- Já pelo método de Bonferroni, intervalos de confiança simultâneos para as diferenças $\mu_{1j} - \mu_{2j}$, $j = 1, 2, ..., p$ são dados por:

$$(\bar{y}_{1j} - \bar{y}_{2j}) \pm t_{n_1+n_2-2}(\tfrac{\alpha}{2p})\sqrt{(\tfrac{1}{n_1} + \tfrac{1}{n_2})s_{pjj}},\ j = 1, 2, ..., p.$$

# Exemplo 3

# Exemplo 3

- Dezenove alunos de uma turma de inglês foram aleatoriamente divididos em dois grupos.

# Exemplo 3

- Dezenove alunos de uma turma de inglês foram aleatoriamente divididos em dois grupos.

- O primeiro, com $n = 10$ alunos, foi submetido ao curso convencional (antigo), enquanto o segundo, com $n = 9$ alunos, a uma nova estratégia de ensino.

# Exemplo 3

- Dezenove alunos de uma turma de inglês foram aleatoriamente divididos em dois grupos.
- O primeiro, com $n = 10$ alunos, foi submetido ao curso convencional (antigo), enquanto o segundo, com $n = 9$ alunos, a uma nova estratégia de ensino.
- O objetivo é avaliar se os desempenhos dos alunos submetidos às duas estratégias em provas de gramática, audição e conversação, em média, diferem.

# Exemplo 3

- Dezenove alunos de uma turma de inglês foram aleatoriamente divididos em dois grupos.
- O primeiro, com $n = 10$ alunos, foi submetido ao curso convencional (antigo), enquanto o segundo, com $n = 9$ alunos, a uma nova estratégia de ensino.
- O objetivo é avaliar se os desempenhos dos alunos submetidos às duas estratégias em provas de gramática, audição e conversação, em média, diferem.
- Nesta aplicação, para fins de ilustração, vamos assumir igualdade para as matrizes de covariâncias populacionais.

# Exemplo 3

**Tabela 3:** Notas de alunos de curso de inglês em exames de gramática, audição e conversação segundo o tipo de curso (antigo ou novo)

| Alunos (Antigo) | Gramática | Audição | Conversação | Alunos (Novo) | Gramática | Audição | Conversação |
|---|---|---|---|---|---|---|---|
| 1 | 4.7 | 7.5 | 3.2 | 11 | 5.3 | 7.6 | 5.0 |
| 2 | 4.9 | 7.0 | 4.6 | 12 | 5.1 | 6.8 | 4.2 |
| 3 | 5.1 | 6.5 | 5.4 | 13 | 4.3 | 8.2 | 5.2 |
| 4 | 6.1 | 7.9 | 3.8 | 14 | 5.1 | 4.9 | 4.4 |
| 5 | 5.0 | 7.3 | 3.4 | 15 | 5.1 | 7.2 | 4.2 |
| 6 | 7.1 | 6.9 | 3.7 | 16 | 2.4 | 6.9 | 3.3 |
| 7 | 3.5 | 4.3 | 2.6 | 17 | 6.3 | 6.1 | 4.5 |
| 8 | 6.3 | 7.2 | 3.5 | 18 | 5.0 | 6.8 | 6.5 |
| 9 | 5.3 | 6.7 | 3.1 | 19 | 5.2 | 6.2 | 4.3 |
| 10 | 6.0 | 8.3 | 3.6 | | | | |

# Exemplo 3

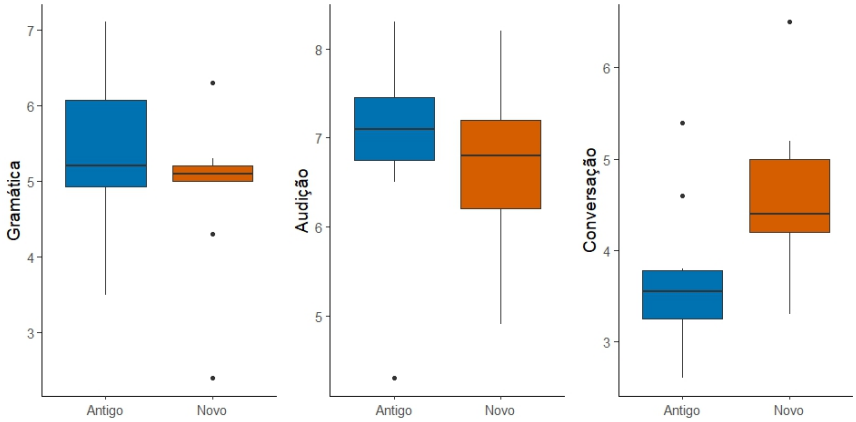



**Figura 4:** Notas de alunos de curso de inglês segundo o tipo de curso

# Exemplo 3

- Estatísticas descritivas:

$$\bar{\boldsymbol{y}}_{\boldsymbol{A}} = \begin{bmatrix} 5.40 \\ 6.96 \\ 3.69 \end{bmatrix} \quad S_A = \begin{bmatrix} 1.02 & 0.70 & 0.17 \\ 0.70 & 1.17 & 0.21 \\ 0.17 & 0.21 & 0.63 \end{bmatrix}$$

$$\bar{\boldsymbol{y}}_{\boldsymbol{N}} = \begin{bmatrix} 4.87 \\ 6.74 \\ 4.62 \end{bmatrix} \quad S_N = \begin{bmatrix} 1.12 & -0.28 & 0.35 \\ -0.28 & 0.90 & 0.19 \\ 0.35 & 0.19 & 0.78 \end{bmatrix}$$

# Exemplo 3

- Hipóteses:

$$H_0 : \begin{bmatrix} \mu_{A,\text{Gramática}} \\ \mu_{A,\text{Audição}} \\ \mu_{A,\text{Conversação}} \end{bmatrix} = \begin{bmatrix} \mu_{N,\text{Gramática}} \\ \mu_{N,\text{Audição}} \\ \mu_{N,\text{Conversação}} \end{bmatrix} \text{ vs } H_1 : \begin{bmatrix} \mu_{A,\text{Gramática}} \\ \mu_{A,\text{Audição}} \\ \mu_{A,\text{Conversação}} \end{bmatrix} \neq \begin{bmatrix} \mu_{N,\text{Gramática}} \\ \mu_{N,\text{Audição}} \\ \mu_{N,\text{Conversação}} \end{bmatrix}$$

# Exemplo 3

- Estatística do teste

# Exemplo 3

- Estatística do teste

Assumindo igualdade entre as matrizes de covariâncias populacionais, o primeiro passo é calcular a matriz de covariâncias amostral combinada:

$$S_p = \frac{(n_A - 1)S_A + (n_N - 1)S_N}{n_A + n_N - 2} =$$

$$\begin{bmatrix} 1.06 & 0.24 & 0.25 \\ 0.24 & 1.04 & 0.20 \\ 0.25 & 0.20 & 0.70 \end{bmatrix}$$

# Exemplo 3

$$T^2 = [(\bar{\boldsymbol{y}}_A - \bar{\boldsymbol{y}}_N)]' \left[\left(\tfrac{1}{n_A} + \tfrac{1}{n_N}\right) S_p\right]^{-1} [(\bar{\boldsymbol{y}}_A - \bar{\boldsymbol{y}}_N)] =$$

$$\begin{bmatrix} 0.53 & 0.22 & -0.93 \end{bmatrix} \left[\left(\frac{1}{10} + \frac{1}{9}\right) \begin{bmatrix} 1.06 & 0.24 & 0.25 \\ 0.24 & 1.04 & 0.20 \\ 0.25 & 0.20 & 0.70 \end{bmatrix}\right]^{-1} \begin{bmatrix} 0.53 \\ 0.22 \\ -0.93 \end{bmatrix} = 10.05$$

# Exemplo 3

- Regra de decisão- Devemos rejeitar a hipótese nula ($H_0$), ao nível de significância de 5%, se $T^2 > \frac{(10+9-2)3}{(10+9-3-1)} F_{3,10+9-3-1}(0.95) = 3.4 \times 3.287 = 11.18$

# Exemplo 3

- Regra de decisão- Devemos rejeitar a hipótese nula ($H_0$), ao nível de significância de 5%, se $T^2 > \frac{(10+9-2)3}{(10+9-3-1)} F_{3,10+9-3-1}(0.95) = 3.4 \times 3.287 = 11.18$

- Logo, como $T^2 = 10.05 < 11.18$, então não rejeitamos $H_0$ ao nível de significância de 5%.

# Exemplo 3

- Regra de decisão- Devemos rejeitar a hipótese nula ($H_0$), ao nível de significância de 5%, se $T^2 > \frac{(10+9-2)3}{(10+9-3-1)} F_{3,10+9-3-1}(0.95) = 3.4 \times 3.287 = 11.18$

- Logo, como $T^2 = 10.05 < 11.18$, então não rejeitamos $H_0$ ao nível de significância de 5%.

- Com isso, concluimos que os desempenhos dos alunos nas duas modalidades de ensino, no conjunto das três avaliações, em média não diferiram.

# Comparação de dois vetores de médias- caso não pareado (com matrizes de covariâncias não homogêneas)

# Comparação de dois vetores de médias- caso não pareado (com matrizes de covariâncias não homogêneas)

- No caso em que as matrizes de covariâncias são heterogêneas, a estatística do teste $T^2$ para o par de hipóteses $H_0 : \boldsymbol{\mu_1 - \mu_2 = \delta}$ vs $H_1 : \boldsymbol{\mu_1 - \mu_2 \neq \delta}$:

$$T^2 = (\bar{\boldsymbol{y}}_1 - \bar{\boldsymbol{y}}_2 - \boldsymbol{\delta})' \left( \frac{S_1}{n_1} + \frac{S_2}{n_2} \right)^{-1} (\bar{\boldsymbol{y}}_1 - \bar{\boldsymbol{y}}_2 - \boldsymbol{\delta})$$

# Comparação de dois vetores de médias- caso não pareado (com matrizes de covariâncias não homogêneas)

- No caso em que as matrizes de covariâncias são heterogêneas, a estatística do teste $T^2$ para o par de hipóteses $H_0 : \boldsymbol{\mu_1 - \mu_2 = \delta}$ vs $H_1 : \boldsymbol{\mu_1 - \mu_2 \neq \delta}$:

$$T^2 = (\bar{\boldsymbol{y}}_1 - \bar{\boldsymbol{y}}_2 - \boldsymbol{\delta})' \left( \frac{S_1}{n_1} + \frac{S_2}{n_2} \right)^{-1} (\bar{\boldsymbol{y}}_1 - \bar{\boldsymbol{y}}_2 - \boldsymbol{\delta})$$

- Neste caso, baseado na distribução assintótica de $T^2$, devemos rejeitar $H_0$, ao nível de significância $\alpha$, se $T^2 > \chi^2_p(1-\alpha)$, que é o quantil $1-\alpha$ da distribuição qui-quadrado com $p$ graus de liberdade.

# Comparação de dois vetores de médias- caso não pareado (com matrizes de covariâncias não homogêneas)

- No caso em que as matrizes de covariâncias são heterogêneas, a estatística do teste $T^2$ para o par de hipóteses $H_0 : \boldsymbol{\mu_1 - \mu_2 = \delta}$ vs $H_1 : \boldsymbol{\mu_1 - \mu_2 \neq \delta}$:

$$T^2 = (\bar{\boldsymbol{y}}_1 - \bar{\boldsymbol{y}}_2 - \boldsymbol{\delta})' \left( \frac{S_1}{n_1} + \frac{S_2}{n_2} \right)^{-1} (\bar{\boldsymbol{y}}_1 - \bar{\boldsymbol{y}}_2 - \boldsymbol{\delta})$$

- Neste caso, baseado na distribução assintótica de $T^2$, devemos rejeitar $H_0$, ao nível de significância $\alpha$, se $T^2 > \chi^2_p(1-\alpha)$, que é o quantil $1-\alpha$ da distribuição qui-quadrado com $p$ graus de liberdade.

- Melhores aproximações para o teste de comparação de vetor de médias, no caso de matrizes de covariâncias heterogêneas, estão disponíveis e podem ser verificados em Ferreira (2011).

# Comparação de dois vetores de médias- caso não pareado (com matrizes de covariâncias não homogêneas)

- Uma aproximação do teste de comparação de dois vetores de médias quando as matrizes de covariâncias não são homogêneas consiste em considerar a seguinte aproximação:

$$T^2 \sim \frac{\nu p}{\nu - p + 1} F_{p,\nu-p+1},$$

# Comparação de dois vetores de médias- caso não pareado (com matrizes de covariâncias não homogêneas)

- Uma aproximação do teste de comparação de dois vetores de médias quando as matrizes de covariâncias não são homogêneas consiste em considerar a seguinte aproximação:

$$T^2 \sim \frac{\nu p}{\nu - p + 1} F_{p,\nu-p+1},$$

onde

$$\nu = \sum_{i=1}^{2} \frac{1}{n_i} \left\{ \text{tr} \left[ \left( \frac{1}{n_i} S_i \left( \frac{1}{n_1} S_1 + \frac{1}{n_2} S_2 \right)^{-1} \right)^2 + \left( \text{tr} \left[ \frac{1}{n_i} S_i \left( \frac{1}{n_1} S_1 + \frac{1}{n_2} S_2 \right)^{-1} \right] \right)^2 \right] \right\}$$

# Comparação de dois vetores de médias- caso não pareado (com matrizes de covariâncias não homogêneas)

- Neste caso, a hipótese nula deverá ser rejeitada, ao nível de significância $\alpha$, se:

$$T^2 > \frac{\nu p}{\nu - p + 1} F_{p,\nu-p+1}(1-\alpha)$$

# Comparação de dois vetores de médias- caso não pareado (com matrizes de covariâncias não homogêneas)

- Neste caso, a hipótese nula deverá ser rejeitada, ao nível de significância $\alpha$, se:

$$T^2 > \frac{\nu p}{\nu - p + 1} F_{p,\nu-p+1}(1-\alpha)$$

- A função `TwoSamplesHT2` da biblioteca `MVTests` tem implementada esta aproximação, que em geral é preferível à aproximação com a $\chi^2$.

# Exemplo 4

# Exemplo 4

- Nesta aplicação, vamos testar a hipótese de igualdade dos vetores de médias das populações de pastagem e capoeira nova considerando as quantidades de cálcio (Ca), magnésio (Mg) e antimônio (SB).

# Exemplo 4

- Nesta aplicação, vamos testar a hipótese de igualdade dos vetores de médias das populações de pastagem e capoeira nova considerando as quantidades de cálcio (Ca), magnésio (Mg) e antimônio (SB).

- Os dados para $n = 13$ amostras de solo de pastagem e $n = 30$ amostras de capoeira nova são apresentados na sequência.

# Exemplo 4

- Nesta aplicação, vamos testar a hipótese de igualdade dos vetores de médias das populações de pastagem e capoeira nova considerando as quantidades de cálcio (Ca), magnésio (Mg) e antimônio (SB).

- Os dados para $n = 13$ amostras de solo de pastagem e $n = 30$ amostras de capoeira nova são apresentados na sequência.

- Neste caso, com base no resultado do teste da igualdade de matriz de covariâncias, vamos conduzir o teste **não assumindo** igualdade entre as matrizes para os dados de pastagem e capoeira nova.

# Exemplo 4

**Tabela 4:** Quantidades de cálcio, magnésio e antimônio em 13 amostras de solo de pastagem da Amazônia

| Parcela | Ca | Mg | SB |
|---|---|---|---|
| 1 | 2.3 | 1.7 | 4.1 |
| 2 | 2.5 | 2.5 | 5.1 |
| 3 | 1.8 | 2.1 | 4.1 |
| 4 | 3.4 | 2.5 | 6.1 |
| 5 | 1.8 | 1.1 | 3.0 |
| 6 | 3.7 | 1.4 | 5.2 |
| 7 | 1.4 | 0.7 | 2.2 |
| 8 | 1.5 | 0.6 | 2.2 |
| 9 | 2.8 | 2.2 | 5.1 |
| 10 | 1.4 | 0.8 | 2.3 |
| 11 | 1.8 | 0.6 | 2.5 |
| 12 | 1.9 | 1.7 | 3.7 |
| 13 | 2.8 | 0.8 | 3.7 |

# Exemplo 4

**Tabela 5:** Quantidades de cálcio, magnésio e antimônio em 30 amostras de solo de capoeira nova

| Parcela | Ca | Mg | SB | Parcela | Ca | Mg | SB |
|---|---|---|---|---|---|---|---|
| 1 | 3.1 | 2.1 | 5.3 | 16 | 5.2 | 1.9 | 7.3 |
| 2 | 4.1 | 2.4 | 6.8 | 17 | 5.0 | 2.5 | 7.7 |
| 3 | 8.3 | 2.6 | 11.1 | 18 | 7.8 | 2.2 | 10.3 |
| 4 | 5.2 | 2.3 | 7.7 | 19 | 6.2 | 1.8 | 8.2 |
| 5 | 8.5 | 4.1 | 12.8 | 20 | 4.4 | 2.1 | 6.6 |
| 6 | 4.2 | 2.5 | 6.9 | 21 | 7.6 | 2.1 | 10.0 |
| 7 | 10.5 | 4.8 | 15.5 | 22 | 5.4 | 3.6 | 9.2 |
| 8 | 6.9 | 3.1 | 10.4 | 23 | 4.9 | 2.1 | 7.2 |
| 9 | 3.4 | 1.6 | 5.3 | 24 | 10.4 | 4.8 | 15.5 |
| 10 | 2.6 | 1.8 | 4.5 | 25 | 7.1 | 2.2 | 9.5 |
| 11 | 5.1 | 2.2 | 7.4 | 26 | 7.9 | 3.1 | 11.2 |
| 12 | 7.3 | 1.7 | 9.2 | 27 | 7.0 | 2.3 | 9.6 |
| 13 | 5.7 | 1.2 | 7.0 | 28 | 5.0 | 2.5 | 7.6 |
| 14 | 8.5 | 3.6 | 12.3 | 29 | 2.9 | 1.2 | 4.4 |
| 15 | 7.3 | 2.2 | 9.6 | 30 | 6.4 | 2.6 | 9.1 |

# Exemplo 4

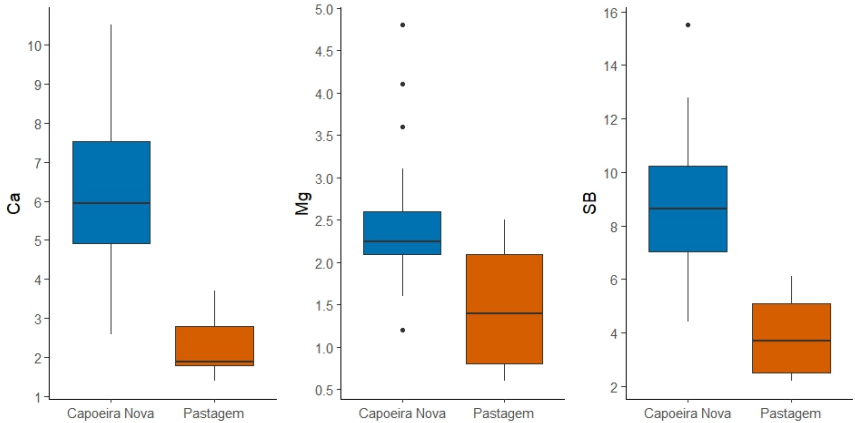



**Figura 5:** Composição das amostras segundo o tipo de solo

# Exemplo 4

- Estatísticas descritivas:

$$\bar{\boldsymbol{y}}_{\boldsymbol{P}} = \begin{bmatrix} 2.2384 \\ 1.4384 \\ 3.7923 \end{bmatrix} \quad S_P = \begin{bmatrix} 0.5692 & 0.2875 & 0.8628 \\ 0.2875 & 0.5242 & 0.8261 \\ 0.8628 & 0.8261 & 1.7107 \end{bmatrix}$$

$$\bar{\boldsymbol{y}}_{\boldsymbol{CN}} = \begin{bmatrix} 6.1300 \\ 2.5067 \\ 8.8400 \end{bmatrix} \quad S_{CN} = \begin{bmatrix} 4.2897 & 1.2994 & 5.6280 \\ 1.2994 & 0.8124 & 2.1242 \\ 5.6280 & 2.1242 & 7.8100 \end{bmatrix}$$

# Exemplo 4

- Hipóteses

$$H_0 : \begin{bmatrix} \mu_{P,Ca} \\ \mu_{P,Mg} \\ \mu_{P,SB} \end{bmatrix} = \begin{bmatrix} \mu_{CN,Ca} \\ \mu_{CN,Mg} \\ \mu_{CN,SB} \end{bmatrix} \text{ vs } H_1 : \begin{bmatrix} \mu_{P,Ca} \\ \mu_{P,Mg} \\ \mu_{P,SB} \end{bmatrix} \neq \begin{bmatrix} \mu_{CN,Ca} \\ \mu_{CN,Mg} \\ \mu_{CN,SB} \end{bmatrix}$$

# Exemplo 4

- Estatística do teste.

$$T^2 = (\bar{\boldsymbol{y}}_P - \bar{\boldsymbol{y}}_{CN})' \left( \frac{S_P}{n_P} + \frac{S_{CN}}{n_{CN}} \right)^{-1} (\bar{\boldsymbol{y}}_P - \bar{\boldsymbol{y}}_{CN}) =$$

$$\begin{bmatrix} -3.8915 & -1.0682 & -5.0477 \end{bmatrix} \begin{bmatrix} 3452.677 & 3498.362 & -3436.508 \\ 3498.362 & 3591.499 & -3498.130 \\ -3436.508 & -3498.130 & 3428.651 \end{bmatrix} \begin{bmatrix} -3.8915 \\ -1.0682 \\ -5.0477 \end{bmatrix} = 94.289$$

# Exemplo 4

- Vamos usar a aproximação com a distribuição $F$, mais adequada para pequenas ou médias amostras. Neste caso, $\nu = 38.29$, de tal forma que devemos rejeitar a hipótese nula se:

$$T^2 > \frac{\nu p}{\nu - p + 1} F_{p,\nu-p+1}(1-\alpha) = \frac{38.29 \times 3}{38.29 - 3 + 1} \times 2.86 = 9.05$$

# Exemplo 4

- Vamos usar a aproximação com a distribuição $F$, mais adequada para pequenas ou médias amostras. Neste caso, $\nu = 38.29$, de tal forma que devemos rejeitar a hipótese nula se:

$$T^2 > \frac{\nu p}{\nu - p + 1} F_{p,\nu-p+1}(1-\alpha) = \frac{38.29 \times 3}{38.29 - 3 + 1} \times 2.86 = 9.05$$

- Decisão: Como $T^2 = 94.289 >>> 9.05$, rejeitamos a hipótese nula ao nível de 5% de significância, e concluimos que as composições dos solos de pastagem e capoeira nova diferem, em média, quanto aos teores de Ca, Mg e SB.

# Comparação de g>2 vetores de médias- análise de variância multivariada (MANOVA)

# Comparação de g>2 vetores de médias

- Vamos considerar:

# Comparação de g>2 vetores de médias

- Vamos considerar:
  - $\boldsymbol{Y}_{11}, \boldsymbol{Y}_{12}, ..., \boldsymbol{Y}_{1n_1}$ uma amostra aleatória de uma normal p-variada com vetor de médias $\boldsymbol{\mu_1}$ e matriz de covariâncias $\Sigma_1$;

# Comparação de g>2 vetores de médias

- Vamos considerar:
  - $\boldsymbol{Y}_{11}, \boldsymbol{Y}_{12}, ..., \boldsymbol{Y}_{1n_1}$ uma amostra aleatória de uma normal p-variada com vetor de médias $\boldsymbol{\mu_1}$ e matriz de covariâncias $\Sigma_1$;
  - $\boldsymbol{Y}_{21}, \boldsymbol{Y}_{22}, ..., \boldsymbol{Y}_{2n_2}$ uma amostra aleatória de uma normal p-variada com vetor de médias $\boldsymbol{\mu_2}$ e matriz de covariâncias $\Sigma_2$...

# Comparação de g>2 vetores de médias

- Vamos considerar:
  - $\boldsymbol{Y}_{11}, \boldsymbol{Y}_{12}, ..., \boldsymbol{Y}_{1n_1}$ uma amostra aleatória de uma normal p-variada com vetor de médias $\boldsymbol{\mu_1}$ e matriz de covariâncias $\Sigma_1$;
  - $\boldsymbol{Y}_{21}, \boldsymbol{Y}_{22}, ..., \boldsymbol{Y}_{2n_2}$ uma amostra aleatória de uma normal p-variada com vetor de médias $\boldsymbol{\mu_2}$ e matriz de covariâncias $\Sigma_2$...
  - $\boldsymbol{Y}_{g1}, \boldsymbol{Y}_{g2}, ..., \boldsymbol{Y}_{gn_g}$ uma amostra aleatória de uma normal p-variada com vetor de médias $\boldsymbol{\mu_g}$ e matriz de covariâncias $\Sigma_g$.

# Comparação de g>2 vetores de médias

- Vamos considerar:
  - $\boldsymbol{Y}_{11}, \boldsymbol{Y}_{12}, ..., \boldsymbol{Y}_{1n_1}$ uma amostra aleatória de uma normal p-variada com vetor de médias $\boldsymbol{\mu_1}$ e matriz de covariâncias $\Sigma_1$;
  - $\boldsymbol{Y}_{21}, \boldsymbol{Y}_{22}, ..., \boldsymbol{Y}_{2n_2}$ uma amostra aleatória de uma normal p-variada com vetor de médias $\boldsymbol{\mu_2}$ e matriz de covariâncias $\Sigma_2$...
  - $\boldsymbol{Y}_{g1}, \boldsymbol{Y}_{g2}, ..., \boldsymbol{Y}_{gn_g}$ uma amostra aleatória de uma normal p-variada com vetor de médias $\boldsymbol{\mu_g}$ e matriz de covariâncias $\Sigma_g$.
  - Assumimos que as populações de origem têm distribuição normal e que $\Sigma_1 = \Sigma_2 = ... = \Sigma_g$ (veremos adiante como testar essa suposição).

# Comparação de g>2 vetores de médias

- Vamos considerar:
  - $\boldsymbol{Y}_{11}, \boldsymbol{Y}_{12}, ..., \boldsymbol{Y}_{1n_1}$ uma amostra aleatória de uma normal p-variada com vetor de médias $\boldsymbol{\mu_1}$ e matriz de covariâncias $\Sigma_1$;
  - $\boldsymbol{Y}_{21}, \boldsymbol{Y}_{22}, ..., \boldsymbol{Y}_{2n_2}$ uma amostra aleatória de uma normal p-variada com vetor de médias $\boldsymbol{\mu_2}$ e matriz de covariâncias $\Sigma_2$...
  - $\boldsymbol{Y}_{g1}, \boldsymbol{Y}_{g2}, ..., \boldsymbol{Y}_{gn_g}$ uma amostra aleatória de uma normal p-variada com vetor de médias $\boldsymbol{\mu_g}$ e matriz de covariâncias $\Sigma_g$.
  - Assumimos que as populações de origem têm distribuição normal e que $\Sigma_1 = \Sigma_2 = ... = \Sigma_g$ (veremos adiante como testar essa suposição).

- Considere ainda $\bar{\boldsymbol{y}}_{\boldsymbol{j}}$ e $S_j$ o vetor de médias e a matriz de covariâncias amostrais da j-ésima amostra, $j = 1, 2, ..., g$.

# Comparação de g>2 vetores de médias

- As hipóteses do teste são:

$$H_0 : \boldsymbol{\mu_1} = \boldsymbol{\mu_2} = ... = \boldsymbol{\mu_g}$$

versus a alternativa $H_1$ de que os $g$ vetores de médias não são idênticos.

# Comparação de g>2 vetores de médias

- As hipóteses do teste são:

$$H_0 : \boldsymbol{\mu_1} = \boldsymbol{\mu_2} = ... = \boldsymbol{\mu_g}$$

versus a alternativa $H_1$ de que os $g$ vetores de médias não são idênticos.

- Há diferentes testes aplicados à comparação dos $g$ vetores de médias, alguns apresentados na sequência.

# Teste de Wilks

- Considere as matrizes:

$$\mathrm{E} = \sum_{j=1}^{g} n_j(\bar{\boldsymbol{y}}_j - \bar{\boldsymbol{y}})(\bar{\boldsymbol{y}}_j - \bar{\boldsymbol{y}})' \text{ e } \mathrm{D} = \sum_{j=1}^{g}\sum_{i=1}^{n_j}(\boldsymbol{y}_{ji} - \bar{\boldsymbol{y}}_j)(\boldsymbol{y}_{ji} - \bar{\boldsymbol{y}}_j)',$$

com $\bar{\boldsymbol{y}} = (\sum_{j=1}^{g}\sum_{i=1}^{n_j}\boldsymbol{y}_{ji})/n$, $n = \sum_{j=1}^{g} n_j$.

# Teste de Wilks

- Considere as matrizes:

$$\mathrm{E} = \sum_{j=1}^{g} n_j(\bar{\boldsymbol{y}}_j - \bar{\boldsymbol{y}})(\bar{\boldsymbol{y}}_j - \bar{\boldsymbol{y}})' \text{ e } \mathrm{D} = \sum_{j=1}^{g}\sum_{i=1}^{n_j}(\boldsymbol{y}_{ji} - \bar{\boldsymbol{y}}_j)(\boldsymbol{y}_{ji} - \bar{\boldsymbol{y}}_j)',$$

com $\bar{\boldsymbol{y}} = (\sum_{j=1}^{g}\sum_{i=1}^{n_j}\boldsymbol{y}_{ji})/n$, $n = \sum_{j=1}^{g} n_j$.

- Observe que E corresponde à soma de quadrados **entre grupos**, enquanto D corresponde à soma de quadrados **dentro dos grupos** na análise de variância multivariada (MANOVA).

# Teste de Wilks

- Considere as matrizes:

$$\mathrm{E} = \sum_{j=1}^{g} n_j(\bar{\boldsymbol{y}}_j - \bar{\boldsymbol{y}})(\bar{\boldsymbol{y}}_j - \bar{\boldsymbol{y}})' \text{ e } \mathrm{D} = \sum_{j=1}^{g}\sum_{i=1}^{n_j}(\boldsymbol{y}_{ji} - \bar{\boldsymbol{y}}_j)(\boldsymbol{y}_{ji} - \bar{\boldsymbol{y}}_j)',$$

com $\bar{\boldsymbol{y}} = (\sum_{j=1}^{g}\sum_{i=1}^{n_j}\boldsymbol{y}_{ji})/n$, $n = \sum_{j=1}^{g} n_j$.

- Observe que E corresponde à soma de quadrados **entre grupos**, enquanto D corresponde à soma de quadrados **dentro dos grupos** na análise de variância multivariada (MANOVA).

- Estatística de Wilks:

$$\Lambda = \frac{|\mathrm{D}|}{|\mathrm{D}+\mathrm{E}|}$$

# Teste de Wilks

- Estatística do teste:

$$F = \left( \frac{1 - \Lambda^{1/b}}{\Lambda^{1/b}} \right) \left[ \frac{ab - c}{p(g-1)} \right],$$

# Teste de Wilks

- Estatística do teste:

$$F = \left( \frac{1 - \Lambda^{1/b}}{\Lambda^{1/b}} \right) \left[ \frac{ab - c}{p(g-1)} \right],$$

em que

$$a = n - g - \frac{p - g + 2}{2}$$

$$b = \sqrt{\frac{p^2(g-1)^2 - 4}{p^2 + (g-1)^2 - 5}},$$

se $p^2 + (g-1)^2 - 5 > 0$, e $b = 1$, caso contrário.

# Teste de Wilks

$$c = \frac{p(g-1)-2}{2}.$$

# Teste de Wilks

$$c = \frac{p(g-1)-2}{2}.$$

- Sob a hipótese nula ($H_0$), a estatística do teste tem distribuição $F_{p(g-1),ab-c}$. Desta forma, devemos rejeitar $H_0$, ao nível de significância $\alpha$, se:

$$F > F_{p(g-1),ab-c}(1-\alpha).$$

# Teste de Wilks

- Uma alternativa para o teste de Wilks, válida para grandes amostras, baseia-se na estatística:

$$\lambda = -\left(n - 1 - \frac{p+g}{2}\right) \ln \Lambda$$

# Teste de Wilks

- Uma alternativa para o teste de Wilks, válida para grandes amostras, baseia-se na estatística:

$$\lambda = -\left(n - 1 - \frac{p+g}{2}\right) \ln \Lambda$$

- Sob $H_0$, $\lambda \sim \chi^2_{p(g-1)}$, tal que a hipótese nula deverá ser rejeitada, ao nível de significância $\alpha$, se:

$$\lambda > \chi^2_{p(g-1)}(1-\alpha).$$

# Teste de Lawley e Hotteling

- Estatística de Lawley e Hotteling:

$$T = \text{tr}(\text{DE}^{-1})$$

# Teste de Lawley e Hotteling

- Estatística de Lawley e Hotteling:

$$T = \text{tr}(\text{DE}^{-1})$$

- Estatístics do teste:

$$L = \frac{2(su+1)}{s^2(2t+s+1)}T,$$

em que

$$s = \min(p, g-1), \quad t = \frac{|p-g-1|-1}{2} \text{ e } u = \frac{n-g-p-1}{2}.$$

# Teste de Lawley e Hotteling

- Sob a hipótese nula $H_0$, a estatística do teste tem aproximadamente distribuição $F_{s(2t+s+1),\, 2(su+1)}$, de forma que $H_0$ deverá ser rejeitada, ao nível de significância $\alpha$, se

$$L > F_{s(2t+s+1),\, 2(su+1)}(1-\alpha)$$

# Teste de Pillai

- Estatística de Pillai:

$$V = \text{tr}\left[\text{D}(\text{D}+\text{E})^{-\mathbf{1}}\right]$$

# Teste de Pillai

- Estatística de Pillai:

$$V = \text{tr}\left[\text{D}(\text{D}+\text{E})^{-\mathbf{1}}\right]$$

- Estatística do teste:

$$P = \left(\frac{2u+s+1}{2t+s+1}\right)\left(\frac{V}{s-V}\right)$$

# Teste de Pillai

- Sob a hipótese nula $H_0$, a estatística do teste tem aproximadamente distribuição $F_{s(2t+s+1),\, s(2u+s+1)}$, de forma que $H_0$ deverá ser rejeitada, ao nível de significância $\alpha$, se

$$P > F_{s(2t+s+1),\, s(2u+s+1)}(1-\alpha).$$

# Exemplo 5

# Exemplo 5

- Um experimento completamente casualizado com cinco repetições foi realizado com o objetivo de comparar os efeitos de quatro cultivares de feijão (A, B, C e D).

# Exemplo 5

- Um experimento completamente casualizado com cinco repetições foi realizado com o objetivo de comparar os efeitos de quatro cultivares de feijão (A, B, C e D).

- As variáveis consideradas foram as seguintes:

# Exemplo 5

- Um experimento completamente casualizado com cinco repetições foi realizado com o objetivo de comparar os efeitos de quatro cultivares de feijão (A, B, C e D).

- As variáveis consideradas foram as seguintes:
  - $Y_1$ : produtividade (em $kg/ha$);

# Exemplo 5

- Um experimento completamente casualizado com cinco repetições foi realizado com o objetivo de comparar os efeitos de quatro cultivares de feijão (A, B, C e D).

- As variáveis consideradas foram as seguintes:
  - $Y_1$ : produtividade (em $kg/ha$);
  - $Y_2$ : número médio de grãos por vagem.

# Exemplo 5

- Um experimento completamente casualizado com cinco repetições foi realizado com o objetivo de comparar os efeitos de quatro cultivares de feijão (A, B, C e D).

- As variáveis consideradas foram as seguintes:
  - $Y_1$ : produtividade (em $kg/ha$);
  - $Y_2$ : número médio de grãos por vagem.

- Vamos conduzir uma análise de variância multivariada para a comparação dos cultivares.

# Exemplo 5

- O objetivo é avaliar se há diferença nas médias de produtividade e grãos por vagem para os quatro cultivares.

# Exemplo 5

- O objetivo é avaliar se há diferença nas médias de produtividade e grãos por vagem para os quatro cultivares.

- A hipótese nula, neste caso, é definida por:

$$H_0 : \boldsymbol{\mu}_A = \boldsymbol{\mu}_B = \boldsymbol{\mu}_C = \boldsymbol{\mu}_D$$

versus a alternativa de que há diferenças entre os vetores de médias.

# Exemplo 5

- O objetivo é avaliar se há diferença nas médias de produtividade e grãos por vagem para os quatro cultivares.

- A hipótese nula, neste caso, é definida por:

$$H_0 : \boldsymbol{\mu}_A = \boldsymbol{\mu}_B = \boldsymbol{\mu}_C = \boldsymbol{\mu}_D$$

versus a alternativa de que há diferenças entre os vetores de médias.

- Vamos assumir igualdade para as matrizes de covariâncias populacionais.

# Exemplo 5

**Tabela 6:** Produtividade ($Y_1$) e número médio de grãos por vagem ($Y_2$) para quatro cultivares de feijão em experimento agrícola.

| Rep | Cultivares | | | | | | | |
|---|---|---|---|---|---|---|---|---|
| | A | | B | | C | | D | |
| | $Y_1$ | $Y_2$ | $Y_1$ | $Y_2$ | $Y_1$ | $Y_2$ | $Y_1$ | $Y_2$ |
| 1 | 1082 | 4.66 | 1163 | 5.52 | 1544 | 5.18 | 1644 | 5.45 |
| 2 | 1070 | 4.50 | 1100 | 5.30 | 1500 | 5.10 | 1600 | 5.18 |
| 3 | 1180 | 4.30 | 1200 | 5.42 | 1550 | 5.20 | 1680 | 5.18 |
| 4 | 1050 | 4.70 | 1190 | 5.62 | 1600 | 5.30 | 1700 | 5.40 |
| 5 | 1080 | 4.60 | 1170 | 5.70 | 1540 | 5.12 | 1704 | 5.50 |
| Total | 5462 | 22.76 | 5823 | 27.56 | 7734 | 25.90 | 8328 | 26.71 |

# Exemplo 5

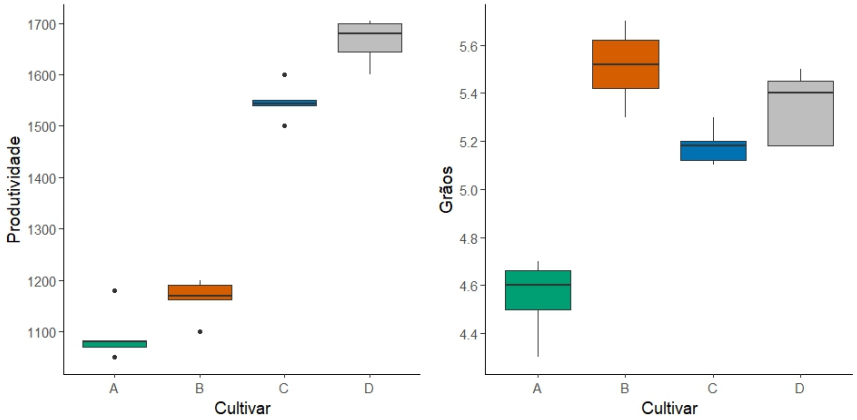



**Figura 6:** Boxplots dos resultados de experimento agrícola

# Exemplo 5

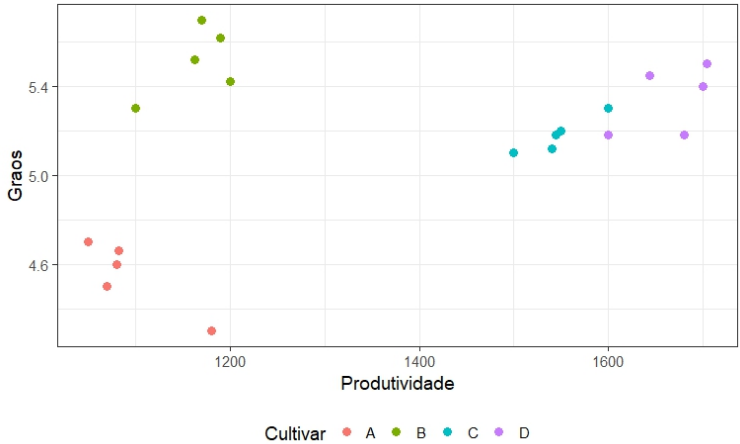



**Figura 7:** Resultados de experimento agrícola

# Exemplo 5

- Descritivas

$$\bar{\boldsymbol{y}}_A = \begin{bmatrix} 1092.4 \\ 4.552 \end{bmatrix} \quad \bar{\boldsymbol{y}}_B = \begin{bmatrix} 1164.6 \\ 5.512 \end{bmatrix} \quad \bar{\boldsymbol{y}}_C = \begin{bmatrix} 1546.8 \\ 5.180 \end{bmatrix} \quad \bar{\boldsymbol{y}}_D = \begin{bmatrix} 1665.6 \\ 5.342 \end{bmatrix} \quad \bar{\boldsymbol{y}} = \begin{bmatrix} 1367.0 \\ 5.146 \end{bmatrix}$$

# Exemplo 5

- Cálculo das matrizes E e D.

$$\mathrm{E} = \sum_{j=1}^{g} n_j(\bar{\boldsymbol{y}}_j - \bar{\boldsymbol{y}})(\bar{\boldsymbol{y}}_j - \bar{\boldsymbol{y}})' =$$

$$5 \times \left(\begin{bmatrix}1092.4\\4.552\end{bmatrix} - \begin{bmatrix}1367.0\\5.146\end{bmatrix}\right)\left(\begin{bmatrix}1092.4\\4.552\end{bmatrix} - \begin{bmatrix}1367.0\\5.146\end{bmatrix}\right)' + 5 \times \left(\begin{bmatrix}1164.6\\5.512\end{bmatrix} - \begin{bmatrix}1367.0\\5.146\end{bmatrix}\right)\left(\begin{bmatrix}1164.6\\5.512\end{bmatrix} - \begin{bmatrix}1367.0\\5.146\end{bmatrix}\right)' +$$

$$5 \times \left(\begin{bmatrix}1546.8\\5.180\end{bmatrix} - \begin{bmatrix}1367.0\\5.146\end{bmatrix}\right)\left(\begin{bmatrix}1546.8\\5.180\end{bmatrix} - \begin{bmatrix}1367.0\\5.146\end{bmatrix}\right)' + 5 \times \left(\begin{bmatrix}1665.6\\5.342\end{bmatrix} - \begin{bmatrix}1367.0\\5.146\end{bmatrix}\right)\left(\begin{bmatrix}1665.6\\5.342\end{bmatrix} - \begin{bmatrix}1367.0\\5.146\end{bmatrix}\right)' =$$

$$\begin{bmatrix}1189302.150 & 768.360\\768.360 & 2.632\end{bmatrix}$$

# Exemplo 5

$$\mathrm{D} = \sum_{j=1}^{g} \sum_{i=1}^{n_j} (\boldsymbol{y}_{ji} - \bar{\boldsymbol{y}}_j)(\boldsymbol{y}_{ji} - \bar{\boldsymbol{y}}_j)' =$$

$$\left(\begin{bmatrix}1082\\4.66\end{bmatrix} - \begin{bmatrix}1092.4\\4.552\end{bmatrix}\right)\left(\begin{bmatrix}1082\\4.66\end{bmatrix} - \begin{bmatrix}1092.4\\4.552\end{bmatrix}\right)' + \left(\begin{bmatrix}1070\\4.55\end{bmatrix} - \begin{bmatrix}1092.4\\4.552\end{bmatrix}\right)\left(\begin{bmatrix}1070\\4.55\end{bmatrix} - \begin{bmatrix}1092.4\\4.552\end{bmatrix}\right)' +$$

$$\left(\begin{bmatrix}1700\\5.40\end{bmatrix} - \begin{bmatrix}1665.6\\5.342\end{bmatrix}\right)\left(\begin{bmatrix}1700\\5.40\end{bmatrix} - \begin{bmatrix}1665.6\\5.342\end{bmatrix}\right)' + \left(\begin{bmatrix}1704\\5.50\end{bmatrix} - \begin{bmatrix}1665.6\\5.342\end{bmatrix}\right)\left(\begin{bmatrix}1704\\5.50\end{bmatrix} - \begin{bmatrix}1665.6\\5.342\end{bmatrix}\right)' =$$

$$\begin{bmatrix}29058.400 & 9.904\\ 9.904 & 0.319\end{bmatrix}$$

# Exemplo 5

- Estatística de Wilks:

$$\Lambda = \frac{|D|}{|D+E|} = \frac{9171.54}{2989687} = 0.00307$$

- Cálculo das constantes:

$$a = 20 - 4 - \frac{2-4+2}{2} = 16; \quad b = \sqrt{\frac{2^2(4-1)^2 - 4}{2^2 + (4-1)^2 - 5}} = 2$$

$$c = \frac{2(4-1)-2}{2} = 2$$

# Exemplo 5

- Estatística do teste de Wilks:

$$F = \left( \frac{1 - 0.00307^{1/2}}{0.00307^{1/2}} \right) \left[ \frac{16 \times 2 - 2}{2(4-1)} \right] = 326.73 \times 5 = 85.16$$

# Exemplo 5

- Estatística do teste de Wilks:

$$F = \left( \frac{1 - 0.00307^{1/2}}{0.00307^{1/2}} \right) \left[ \frac{16 \times 2 - 2}{2(4-1)} \right] = 326.73 \times 5 = 85.16$$

- Regra de decisão: Devemos rejeitar a hipótese nula de igualdade dos vetores de médias, ao nível de significância de 5%, se $F > F_{2(4-1),16\times2-2}(0.95) = 2.42$.

# Exemplo 5

- Conclusão: Como $F = 85.16$, rejeitamos a hipótese nula ao nível de 5% de significância e concluímos haver diferenças entre os vetores de médias.

# Exemplo 5

- Conclusão: Como $F = 85.16$, rejeitamos a hipótese nula ao nível de 5% de significância e concluímos haver diferenças entre os vetores de médias.

- A sequência da análise será realizada no R.

# Comparação de matrizes de covariâncias

# Comparação de matrizes de covariâncias

- Sejam $\Sigma_1, \Sigma_2, ..., \Sigma_g$ as matrizes de covariâncias de $g$ populações normais multivariadas.

# Comparação de matrizes de covariâncias

- Sejam $\Sigma_1, \Sigma_2, ..., \Sigma_g$ as matrizes de covariâncias de $g$ populações normais multivariadas.

- Vamos considerar a hipótese de igualdade dessas $g$ matrizes: $H_0 : \Sigma_1 = \Sigma_2 = ... = \Sigma_g = \Sigma$.

# Comparação de matrizes de covariâncias

- O teste da razão de verossimilhanças para a hipótese de igualdade das $g$ matrizes de covariâncias baseia-se nas $g$ matrizes de covariâncias amostrais e na matriz de covariâncias ponderada:

$$\Lambda = \prod_{l=1}^{g} \left( \frac{|S_l|}{|S_p|} \right)^{(n_l - 1)/2}$$

# Comparação de matrizes de covariâncias

- O teste da razão de verossimilhanças para a hipótese de igualdade das $g$ matrizes de covariâncias baseia-se nas $g$ matrizes de covariâncias amostrais e na matriz de covariâncias ponderada:

$$\Lambda = \prod_{l=1}^{g} \left( \frac{|S_l|}{|S_p|} \right)^{(n_l - 1)/2}$$

sendo

$$S_p = \frac{1}{\sum_{l=1}^{g} (n_l - 1)} \left\{ (n_1 - 1) S_1 + (n_2 - 1) S_2 + ... + (n_l - 1) S_g \right\}$$

# Comparação de matrizes de covariâncias

- A estatística de Box é dada por

$$M = -2 \ln \Lambda = \left[ \sum_{l=1}^{g} (n_l - 1) \right] \ln |S_p| - \sum_{l=1}^{g} [(n_l - 1) \ln |S_l|] .$$

# Comparação de matrizes de covariâncias

- A estatística de Box é dada por

$$M = -2 \ln \Lambda = \left[ \sum_{l=1}^{g} (n_l - 1) \right] \ln |S_p| - \sum_{l=1}^{g} \left[ (n_l - 1) \ln |S_l| \right].$$

- Sob a hipótese de igualdade, sob normalidade multivariada das $g$ populações, a estatística $C = (1 - u)M$, sendo:

$$u = \left[ \sum_{l=1}^{g} \frac{1}{(n_l - 1)} - \frac{1}{\sum_{l=1}^{g} (n_l - 1)} \right] \left[ \frac{2p^2 + 3p - 1}{6(p + 1)(g - 1)} \right]$$

tem distribuição aproximada $\chi^2$ com $\frac{1}{2} p(p + 1)(g - 1)$.

# Comparação de matrizes de covariâncias

- A estatística de Box é dada por

$$M = -2 \ln \Lambda = \left[ \sum_{l=1}^{g} (n_l - 1) \right] \ln |S_p| - \sum_{l=1}^{g} \left[ (n_l - 1) \ln |S_l| \right].$$

- Sob a hipótese de igualdade, sob normalidade multivariada das $g$ populações, a estatística $C = (1 - u)M$, sendo:

$$u = \left[ \sum_{l=1}^{g} \frac{1}{(n_l - 1)} - \frac{1}{\sum_{l=1}^{g} (n_l - 1)} \right] \left[ \frac{2p^2 + 3p - 1}{6(p + 1)(g - 1)} \right]$$

tem distribuição aproximada $\chi^2$ com $\frac{1}{2} p(p + 1)(g - 1)$.

- Assim, rejeitamos $H_0$, para um nível de significância $\alpha$, se $C > \chi^2_{p(p+1)(g-1)/2}(\alpha)$.

# Exemplo 6

# Exemplo 6

- Vamos testar a igualdade das matrizes de covariâncias para o exemplo usado na ilustração da MANOVA (comparação de cultivares).

# Exemplo 6

- Vamos testar a igualdade das matrizes de covariâncias para o exemplo usado na ilustração da MANOVA (comparação de cultivares).

- Neste caso, a hipótese nula é definida como:

$$H_0 : \Sigma_A = \Sigma_B = \Sigma_C = \Sigma_D$$

# Exemplo 6

- Matrizes de covariâncias amostrais:

$$S_A = \begin{bmatrix} 2258.800 & -7.226 \\ -7.226 & 0.025 \end{bmatrix} \quad S_B = \begin{bmatrix} 1525.800 & 3.546 \\ 3.546 & 0.025 \end{bmatrix}$$

$$S_C = \begin{bmatrix} 1271.200 & 2.650 \\ 2.650 & 0.006 \end{bmatrix} \quad S_D = \begin{bmatrix} 1908.800 & 3.506 \\ 3.506 & 0.023 \end{bmatrix}$$

# Exemplo 6

- Matriz de covariância ponderada:

$$S_P = \frac{1}{20-4}\left[(5-1)S_A + (5-1)S_B + (5-1)S_C + (5-1)S_D\right] =$$

$$S_P = \begin{bmatrix} 1816.150 & 0.619 \\ 0.619 & 0.020 \end{bmatrix}$$

# Exemplo 6

- Matriz de covariância ponderada:

$$S_P = \frac{1}{20-4}\left[(5-1)S_A + (5-1)S_B + (5-1)S_C + (5-1)S_D\right] =$$

$$S_P = \begin{bmatrix} 1816.150 & 0.619 \\ 0.619 & 0.020 \end{bmatrix}$$

- As variâncias generalizadas são dadas por:

$$|S_A| = 13.08; \;\; |S_B| = 25.75; \;\; |S_C| = 0.86; \;\; |S_D| = 31.84;$$

$$|S_P| = 35.92$$

# Exemplo 6

- Estatística M:

$$M = (20-4)\log(35.92) - [(5-1)\log(13.08) + (5-1)\log(25.75) + (5-1)\log(0.86) + (5-1)\log(31.84)] = 20.78$$

$$u = \left[\sum_{l=1}^{g} \frac{1}{(n_l - 1)} - \frac{1}{\sum_{l=1}^{g}(n_l - 1)}\right]\left[\frac{2p^2 + 3p - 1}{6(p+1)(g-1)}\right] =$$

$$(1 - 0.0625) \times 0.2407 = 0.2256$$

# Exemplo 6

- Estatística do teste:

$$C = (1 - u)M = (1 - 0.2256) \times 20.78 = 16.09$$

# Exemplo 6

- Estatística do teste:

$$C = (1 - u)M = (1 - 0.2256) \times 20.78 = 16.09$$

- Regra de decisão: Devemos rejeitar $H_0$ a um nível de significância 5% se $C > \chi^2_{2(2+1)(4-1)/2}(0.95) = 16.91$.

# Exemplo 6

- Estatística do teste:

$$C = (1 - u)M = (1 - 0.2256) \times 20.78 = 16.09$$

- Regra de decisão: Devemos rejeitar $H_0$ a um nível de significância 5% se $C > \chi^2_{2(2+1)(4-1)/2}(0.95) = 16.91$.

- Conclusão: Como $C = 16.09 < 16.91$, não rejeitamos a hipótese nula de igualdade das matrizes de covariâncias ao nível de 5% de significância.

# O que vamos estudar no próximo módulo

# O que vamos estudar no próximo módulo

- No próximo módulo vamos estudar a técnica de análise de componentes principais.

# O que vamos estudar no próximo módulo

- No próximo módulo vamos estudar a técnica de análise de componentes principais.

- Serão discutidos os principais objetivos e características da análise.

# O que vamos estudar no próximo módulo

- No próximo módulo vamos estudar a técnica de análise de componentes principais.
- Serão discutidos os principais objetivos e características da análise.
- A aplicação da análise de componentes principais em bases de dados servirá como ilustração da técnica em diferentes contextos.