

CE319 - Estatística multivariada

Análise exploratória

Cesar Augusto Taconeli

03 de março, 2026

Análise exploratória

O que vamos estudar neste módulo

O que vamos estudar neste módulo

- Como descrever dados multivariados usando medidas de centralidade, covariância e correlação.

O que vamos estudar neste módulo

- Como descrever dados multivariados usando medidas de centralidade, covariância e correlação.
- Cuidados na preparação dos dados para a análise.

O que vamos estudar neste módulo

- Como descrever dados multivariados usando medidas de centralidade, covariância e correlação.
- Cuidados na preparação dos dados para a análise.
- Métodos gráficos para visualização dos dados.

O que vamos estudar neste módulo

- Como descrever dados multivariados usando medidas de centralidade, covariância e correlação.
- Cuidados na preparação dos dados para a análise.
- Métodos gráficos para visualização dos dados.
- Os conceitos de dissimilaridade e distância.

Descrição de dados multivariados

Descrição de dados multivariados

- Disposição dos dados:

	Var 1	Var 2	...	Var j	...	Var p
Ind 1	y_{11}	y_{12}	...	y_{1j}	...	y_{1p}
Ind 2	y_{21}	y_{22}	...	y_{2j}	...	y_{2p}
⋮	⋮	⋮	...	⋮	...	⋮
Ind i	y_{i1}	y_{i2}	...	y_{ij}	...	y_{ip}
⋮	⋮	⋮	...	⋮	...	⋮
Ind n	y_{n1}	y_{n2}	...	y_{nj}	...	y_{np}

Descrição de dados multivariados

- Como ilustração, vamos considerar as cinco primeiras linha da base de dados *trees* do R, com dados de circunferência, altura e volume de madeira de cerejeiras pretas.

	Girth	Height	Volume
17	12.90	85.00	33.80
14	11.70	69.00	21.30
9	11.10	80.00	22.60
22	14.20	80.00	31.70
27	17.50	82.00	55.70

Vetor de médias

- Podemos calcular a média amostral separadamente para cada variável:

$$\bar{y}_j = \frac{1}{n} \sum_{i=1}^n y_{ij}, j = 1, 2, \dots, p.$$

Vetor de médias

- Podemos calcular a média amostral separadamente para cada variável:

$$\bar{y}_j = \frac{1}{n} \sum_{i=1}^n y_{ij}, j = 1, 2, \dots, p.$$

- O vetor de médias amostrais fica definido por:

$$\bar{\mathbf{y}} = \begin{bmatrix} \bar{y}_1 \\ \bar{y}_2 \\ \vdots \\ \bar{y}_p \end{bmatrix}.$$

Vetor de médias

- O vetor de médias é o centro de massa da nuvem de pontos no espaço p -dimensional.

Vetor de médias

- O vetor de médias é o centro de massa da nuvem de pontos no espaço p -dimensional.
- Matricialmente, temos $\bar{\mathbf{y}} = \frac{1}{n} \mathbf{Y}'\mathbf{1}$, sendo $\mathbf{Y}$ a matriz de dados e $\mathbf{1}$ o vetor de 1's de dimensão n .

Matriz de covariâncias

- A variância amostral para a j -ésima variável e a covariância amostral para as variáveis Y_j e Y_k são definidas, respectivamente, por:

Matriz de covariâncias

- A variância amostral para a j -ésima variável e a covariância amostral para as variáveis Y_j e Y_k são definidas, respectivamente, por:

$$s_j^2 = s_{jj} = \frac{1}{n-1} \sum_{i=1}^n (y_{ij} - \bar{y}_j)^2$$

Matriz de covariâncias

- A variância amostral para a j -ésima variável e a covariância amostral para as variáveis Y_j e Y_k são definidas, respectivamente, por:

$$s_j^2 = s_{jj} = \frac{1}{n-1} \sum_{i=1}^n (y_{ij} - \bar{y}_j)^2$$

$$s_{jk} = \frac{1}{n-1} \sum_{i=1}^n (y_{ij} - \bar{y}_j)(y_{ik} - \bar{y}_k)$$

Matriz de covariâncias

- A variância amostral para a j -ésima variável e a covariância amostral para as variáveis Y_j e Y_k são definidas, respectivamente, por:

$$s_j^2 = s_{jj} = \frac{1}{n-1} \sum_{i=1}^n (y_{ij} - \bar{y}_j)^2$$

$$s_{jk} = \frac{1}{n-1} \sum_{i=1}^n (y_{ij} - \bar{y}_j)(y_{ik} - \bar{y}_k)$$

- A matriz de covariâncias amostral (simétrica) fica definida por:

$$\mathbf{S} = \begin{bmatrix} s_{11} & s_{12} & \cdots & s_{1p} \\ s_{21} & s_{22} & \cdots & s_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ s_{p1} & s_{p2} & \cdots & s_{pp} \end{bmatrix},$$

Matriz de covariâncias

- Podemos expressar a matriz de covariâncias vetorialmente por:

$$\mathbf{S} = \frac{1}{n-1} \sum_{i=1}^n (\mathbf{y}_i - \bar{\mathbf{y}}) (\mathbf{y}_i - \bar{\mathbf{y}})' = \frac{1}{n-1} (\sum_{i=1}^n \mathbf{y}_i \mathbf{y}_i' - n \bar{\mathbf{y}} \bar{\mathbf{y}}')$$

Matriz de covariâncias

- Podemos expressar a matriz de covariâncias vetorialmente por:

$$\mathbf{S} = \frac{1}{n-1} \sum_{i=1}^n (\mathbf{y}_i - \bar{\mathbf{y}}) (\mathbf{y}_i - \bar{\mathbf{y}})' = \frac{1}{n-1} (\sum_{i=1}^n \mathbf{y}_i \mathbf{y}_i' - n \bar{\mathbf{y}} \bar{\mathbf{y}}')$$

- Interpretação prática:

Matriz de covariâncias

- Podemos expressar a matriz de covariâncias vetorialmente por:

$$\mathbf{S} = \frac{1}{n-1} \sum_{i=1}^n (\mathbf{y}_i - \bar{\mathbf{y}}) (\mathbf{y}_i - \bar{\mathbf{y}})' = \frac{1}{n-1} (\sum_{i=1}^n \mathbf{y}_i \mathbf{y}_i' - n \bar{\mathbf{y}} \bar{\mathbf{y}}')$$

- Interpretação prática:

- s_{jj} : dispersão individual (variância) de y_j ;

Matriz de covariâncias

- Podemos expressar a matriz de covariâncias vetorialmente por:

$$\mathbf{S} = \frac{1}{n-1} \sum_{i=1}^n (\mathbf{y}_i - \bar{\mathbf{y}}) (\mathbf{y}_i - \bar{\mathbf{y}})' = \frac{1}{n-1} (\sum_{i=1}^n \mathbf{y}_i \mathbf{y}_i' - n \bar{\mathbf{y}} \bar{\mathbf{y}}')$$

- Interpretação prática:

- s_{jj} : dispersão individual (variância) de y_j ;
- $s_{jk} > 0$: y_j e y_k “crescem juntos”;

Matriz de covariâncias

- Podemos expressar a matriz de covariâncias vetorialmente por:

$$\mathbf{S} = \frac{1}{n-1} \sum_{i=1}^n (\mathbf{y}_i - \bar{\mathbf{y}}) (\mathbf{y}_i - \bar{\mathbf{y}})' = \frac{1}{n-1} (\sum_{i=1}^n \mathbf{y}_i \mathbf{y}_i' - n \bar{\mathbf{y}} \bar{\mathbf{y}}')$$

- Interpretação prática:
 - s_{jj} : dispersão individual (variância) de y_j ;
 - $s_{jk} > 0$: y_j e y_k “crescem juntos”;
 - $s_{jk} < 0$: y_j e y_k tem “comportamentos opostos”;

Matriz de covariâncias

- Podemos expressar a matriz de covariâncias vetorialmente por:

$$\mathbf{S} = \frac{1}{n-1} \sum_{i=1}^n (\mathbf{y}_i - \bar{\mathbf{y}}) (\mathbf{y}_i - \bar{\mathbf{y}})' = \frac{1}{n-1} (\sum_{i=1}^n \mathbf{y}_i \mathbf{y}_i' - n \bar{\mathbf{y}} \bar{\mathbf{y}}')$$

- Interpretação prática:
 - s_{jj} : dispersão individual (variância) de y_j ;
 - $s_{jk} > 0$: y_j e y_k “crescem juntos”;
 - $s_{jk} < 0$: y_j e y_k tem “comportamentos opostos”;
 - $s_{jk} \approx 0$: y_j e y_k tem fraca associação linear.

Matriz de correlações

- O coeficiente de correlação amostral para Y_j e Y_k é dado por:

$$r_{jk} = \frac{s_{jk}}{\sqrt{s_{jj}}\sqrt{s_{kk}}} = \frac{\sum_{i=1}^n (x_{ij} - \bar{x}_j)(x_{ik} - \bar{x}_k)}{\sqrt{\sum_{i=1}^n (x_{ij} - \bar{x}_j)^2} \sqrt{\sum_{i=1}^n (x_{ik} - \bar{x}_k)^2}}$$

Matriz de correlações

- O coeficiente de correlação amostral para Y_j e Y_k é dado por:

$$r_{jk} = \frac{s_{jk}}{\sqrt{s_{jj}}\sqrt{s_{kk}}} = \frac{\sum_{i=1}^n (x_{ij} - \bar{x}_j)(x_{ik} - \bar{x}_k)}{\sqrt{\sum_{i=1}^n (x_{ij} - \bar{x}_j)^2} \sqrt{\sum_{i=1}^n (x_{ik} - \bar{x}_k)^2}}$$

- A matriz de correlações amostrais (simétrica) é determinada pelos coeficientes calculados para cada par de variáveis.

$$\mathbf{R} = \begin{bmatrix} 1 & r_{12} & \cdots & r_{1p} \\ r_{21} & 1 & \cdots & r_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ r_{p1} & r_{p2} & \cdots & 1 \end{bmatrix}.$$

Matriz de correlações

- Interpretação prática:

Matriz de correlações

- Interpretação prática:
 - $r_{jk} \approx 1$: relação linear crescente entre y_j e y_k ;

Matriz de correlações

- Interpretação prática:
 - $r_{jk} \approx 1$: relação linear crescente entre y_j e y_k ;
 - $r_{jk} \approx -1$: relação linear decrescente entre y_j e y_k ;

Matriz de correlações

- Interpretação prática:
 - $r_{jk} \approx 1$: relação linear crescente entre y_j e y_k ;
 - $r_{jk} \approx -1$: relação linear decrescente entre y_j e y_k ;
 - $r_{jk} \approx 0$: ausência de relação linear entre y_j e y_k .

Aplicação- Dados de cerejeiras pretas

- Vetor de médias:

Aplicação- Dados de cerejeiras pretas

- Vetor de médias:

$$\bar{y}_1 = \frac{12.9 + 11.7 + 11.1 + 14.2 + 17.5}{5} = 13.48$$

Aplicação- Dados de cerejeiras pretas

- Vetor de médias:

$$\bar{y}_1 = \frac{12.9 + 11.7 + 11.1 + 14.2 + 17.5}{5} = 13.48$$

$$\bar{y}_2 = \frac{85 + 69 + 80 + 80 + 82}{5} = 79.20$$

Aplicação- Dados de cerejeiras pretas

- Vetor de médias:

$$\bar{y}_1 = \frac{12.9 + 11.7 + 11.1 + 14.2 + 17.5}{5} = 13.48$$

$$\bar{y}_2 = \frac{85 + 69 + 80 + 80 + 82}{5} = 79.20$$

$$\bar{y}_3 = \frac{33.8 + 21.3 + 22.6 + 31.7 + 55.7}{5} = 33.02$$

Aplicação- Dados de cerejeiras pretas

- Vetor de médias:

$$\bar{y}_1 = \frac{12.9 + 11.7 + 11.1 + 14.2 + 17.5}{5} = 13.48$$

$$\bar{y}_2 = \frac{85 + 69 + 80 + 80 + 82}{5} = 79.20$$

$$\bar{y}_3 = \frac{33.8 + 21.3 + 22.6 + 31.7 + 55.7}{5} = 33.02$$

Aplicação- Dados de cerejeiras pretas

- Vetor de médias:

$$\bar{\mathbf{y}} = \begin{bmatrix} 13.48 \\ 79.20 \\ 33.02 \end{bmatrix}$$

Aplicação- Dados de cerejeiras

- Matriz de covariâncias:

Aplicação- Dados de cerejeiras

- Matriz de covariâncias:

$$s_{11} = s_1^2 = \frac{(12.9 - 13.48)^2 + (11.7 - 13.48)^2 + \dots + (17.5 - 13.48)^2}{5 - 1} = 6.462$$

Aplicação- Dados de cerejeiras

- Matriz de covariâncias:

$$s_{11} = s_1^2 = \frac{(12.9 - 13.48)^2 + (11.7 - 13.48)^2 + \dots + (17.5 - 13.48)^2}{5 - 1} = 6.462$$

$$s_{22} = s_2^2 = \frac{(85 - 79.2)^2 + (69 - 79.2)^2 + \dots + (82 - 79.2)^2}{5 - 1} = 36.700$$

Aplicação- Dados de cerejeiras

- Matriz de covariâncias:

$$s_{11} = s_1^2 = \frac{(12.9 - 13.48)^2 + (11.7 - 13.48)^2 + \dots + (17.5 - 13.48)^2}{5 - 1} = 6.462$$

$$s_{22} = s_2^2 = \frac{(85 - 79.2)^2 + (69 - 79.2)^2 + \dots + (82 - 79.2)^2}{5 - 1} = 36.700$$

$$s_{33} = s_3^2 = \frac{(33.8 - 33.02)^2 + (21.3 - 33.02)^2 + \dots + (55.7 - 33.02)^2}{5 - 1} = 190.667$$

Aplicação- Dados de cerejeiras

- Matriz de covariâncias:

Aplicação- Dados de cerejeiras

- Matriz de covariâncias:

$$s_{12} = \frac{(12.9 - 13.48)(85 - 79.2) + \dots + (17.5 - 13.48)(82 - 79.2)}{5 - 1} = 6.180$$

Aplicação- Dados de cerejeiras

- Matriz de covariâncias:

$$s_{12} = \frac{(12.9 - 13.48)(85 - 79.2) + \dots + (17.5 - 13.48)(82 - 79.2)}{5 - 1} = 6.180$$

$$s_{13} = \frac{(12.9 - 13.48)(33.8 - 33.02) + \dots + (17.5 - 13.48)(55.7 - 33.02)}{5 - 1} = 33.858$$

Aplicação- Dados de cerejeiras

- Matriz de covariâncias:

$$s_{12} = \frac{(12.9 - 13.48)(85 - 79.2) + \dots + (17.5 - 13.48)(82 - 79.2)}{5 - 1} = 6.180$$

$$s_{13} = \frac{(12.9 - 13.48)(33.8 - 33.02) + \dots + (17.5 - 13.48)(55.7 - 33.02)}{5 - 1} = 33.858$$

$$s_{23} = \frac{(85 - 79.2)(33.8 - 33.02) + \dots + (82 - 79.2)(55.7 - 33.02)}{5 - 1} = 44.545$$

Aplicação- Dados de cerejeiras

- Matriz de covariâncias:

$$\mathbf{S} = \begin{bmatrix} 6.462 & 6.180 & 33.858 \\ 6.180 & 36.700 & 44.545 \\ 33.858 & 44.545 & 190.667 \end{bmatrix}$$

Aplicação- Dados de cerejeiras

- Matriz de correlações:

Aplicação- Dados de cerejeiras

- Matriz de correlações:

$$r_{12} = \frac{6.180}{\sqrt{6.462}\sqrt{36.700}} = 0.401$$

Aplicação- Dados de cerejeiras

- Matriz de correlações:

$$r_{12} = \frac{6.180}{\sqrt{6.462}\sqrt{36.700}} = 0.401$$

$$r_{13} = \frac{33.858}{\sqrt{6.462}\sqrt{190.667}} = 0.965$$

Aplicação- Dados de cerejeiras

- Matriz de correlações:

$$r_{12} = \frac{6.180}{\sqrt{6.462}\sqrt{36.700}} = 0.401$$

$$r_{13} = \frac{33.858}{\sqrt{6.462}\sqrt{190.667}} = 0.965$$

$$r_{23} = \frac{44.545}{\sqrt{36.700}\sqrt{190.667}} = 0.532$$

Aplicação- Dados de cerejeiras

- Matriz de correlações:

$$\mathbf{R} = \begin{bmatrix} 1 & 0.401 & 0.965 \\ 0.401 & 1 & 0.532 \\ 0.965 & 0.532 & 1 \end{bmatrix}$$

Variância generalizada e variância total

Variância generalizada e variância total

- Em algumas situações, é de interesse exprimir a variação presente nos dados multivariados por meio de um único valor.

Variância generalizada e variância total

- Em algumas situações, é de interesse exprimir a variação presente nos dados multivariados por meio de um único valor.
- Uma das alternativas para isso é a **variância generalizada**, que é definida como o determinante da matriz de covariâncias amostral.

$$\text{Variância generalizada} = |\mathbf{S}|.$$

Variância generalizada e variância total

- Em algumas situações, é de interesse exprimir a variação presente nos dados multivariados por meio de um único valor.
- Uma das alternativas para isso é a **variância generalizada**, que é definida como o determinante da matriz de covariâncias amostral.

$$\text{Variância generalizada} = |\mathbf{S}|.$$

- Naturalmente, por resumir toda a variação em um único valor, parte da informação referente à variação dos dados se perde nesse resumo, originando possíveis distorções.

Variância generalizada e variância total

- Uma interpretação geométrica para a variância generalizada baseia-se em vetores de desvios do tipo $\mathbf{e}_j = \mathbf{y}_j - \bar{y}_j \mathbf{1}$, para $j = 1, 2, \dots, p$ (atente que estamos lidando com os vetores colunas) em que $\mathbf{1}$ é o vetor de 1's de dimensão n .

Variância generalizada e variância total

- Uma interpretação geométrica para a variância generalizada baseia-se em vetores de desvios do tipo $\mathbf{e}_j = \mathbf{y}_j - \bar{y}_j \mathbf{1}$, para $j = 1, 2, \dots, p$ (atente que estamos lidando com os vetores colunas) em que $\mathbf{1}$ é o vetor de 1's de dimensão n .
- A variância generalizada é proporcional ao quadrado do volume gerado pelos vetores $\mathbf{e}_1, \mathbf{e}_2, \dots, \mathbf{e}_p$, da seguinte forma:

$$|\mathbf{S}| = \frac{(\text{volume})^2}{(n-1)^p}.$$

Variância generalizada e variância total

- Uma interpretação geométrica para a variância generalizada baseia-se em vetores de desvios do tipo $\mathbf{e}_j = \mathbf{y}_j - \bar{y}_j \mathbf{1}$, para $j = 1, 2, \dots, p$ (atente que estamos lidando com os vetores colunas) em que $\mathbf{1}$ é o vetor de 1's de dimensão n .
- A variância generalizada é proporcional ao quadrado do volume gerado pelos vetores $\mathbf{e}_1, \mathbf{e}_2, \dots, \mathbf{e}_p$, da seguinte forma:

$$|\mathbf{S}| = \frac{(\text{volume})^2}{(n-1)^p}.$$

- Em particular, para o caso bivariado, temos:

$$|\mathbf{S}| = \frac{(\text{área})^2}{(n-1)^2},$$

em que a área em questão se refere ao paralelogramo originado por $\mathbf{e}_1$ e $\mathbf{e}_2$.

Variância generalizada e variância total

- A variância generalizada pode ser definida ainda a partir das variáveis originais padronizadas $(y_{ij} - \bar{y}_j)/s_{jj}$, contornando problema de diferentes escalas das variáveis. Como resultado da padronização, temos:

Variância generalizada das variáveis padronizadas = $|R|$.

Variância generalizada e variância total

- A variância generalizada pode ser definida ainda a partir das variáveis originais padronizadas $(y_{ij} - \bar{y}_j)/s_{jj}$, contornando problema de diferentes escalas das variáveis. Como resultado da padronização, temos:

Variância generalizada das variáveis padronizadas = $|\mathbf{R}|$.

- Algumas propriedades da variância generalizada:

Variância generalizada e variância total

- A variância generalizada pode ser definida ainda a partir das variáveis originais padronizadas $(y_{ij} - \bar{y}_j)/s_{jj}$, contornando problema de diferentes escalas das variáveis. Como resultado da padronização, temos:

Variância generalizada das variáveis padronizadas = $|\mathbf{R}|$.

- Algumas propriedades da variância generalizada:
 - Quanto maior a variância de uma variável, maior sua contribuição para a variância generalizada;

Variância generalizada e variância total

- A variância generalizada pode ser definida ainda a partir das variáveis originais padronizadas $(y_{ij} - \bar{y}_j)/s_{jj}$, contornando problema de diferentes escalas das variáveis. Como resultado da padronização, temos:

Variância generalizada das variáveis padronizadas = $|R|$.

- Algumas propriedades da variância generalizada:
 - Quanto maior a variância de uma variável, maior sua contribuição para a variância generalizada;
 - Quanto maior a correlação entre duas variáveis, menor a variância generalizada;

Variância generalizada e variância total

- A variância generalizada pode ser definida ainda a partir das variáveis originais padronizadas $(y_{ij} - \bar{y}_j)/s_{jj}$, contornando problema de diferentes escalas das variáveis. Como resultado da padronização, temos:

Variância generalizada das variáveis padronizadas = $|\mathbf{R}|$.

- Algumas propriedades da variância generalizada:
 - Quanto maior a variância de uma variável, maior sua contribuição para a variância generalizada;
 - Quanto maior a correlação entre duas variáveis, menor a variância generalizada;
 - Caso duas ou mais variáveis sejam perfeitamente correlacionadas a variância generalizada atingirá seu mínimo valor (zero);

Variância generalizada e variância total

- A variância generalizada pode ser definida ainda a partir das variáveis originais padronizadas $(y_{ij} - \bar{y}_j)/s_{jj}$, contornando problema de diferentes escalas das variáveis. Como resultado da padronização, temos:

Variância generalizada das variáveis padronizadas = $|R|$.

- Algumas propriedades da variância generalizada:
 - Quanto maior a variância de uma variável, maior sua contribuição para a variância generalizada;
 - Quanto maior a correlação entre duas variáveis, menor a variância generalizada;
 - Caso duas ou mais variáveis sejam perfeitamente correlacionadas a variância generalizada atingirá seu mínimo valor (zero);
 - A variância generalizada será máxima caso as variáveis tenham correlação nula.

Variância generalizada e variância total

- **Nota:** $|S|$ depende da escala, de forma que é recomendável sua análise (e possível comparação) após padronização dos dados.

Variância generalizada e variância total

- **Nota:** $|S|$ depende da escala, de forma que é recomendável sua análise (e possível comparação) após padronização dos dados.
- Uma das limitações da variância generalizada é o fato de diferentes estruturas de correlação produzirem, algumas vezes, igual variância generalizada.

Variância generalizada e variância total

- **Nota:** $|S|$ depende da escala, de forma que é recomendável sua análise (e possível comparação) após padronização dos dados.
- Uma das limitações da variância generalizada é o fato de diferentes estruturas de correlação produzirem, algumas vezes, igual variância generalizada.
- **Exemplo:** Calcular, para cada matriz de covariâncias, a variância generalizada e a correlação entre as variáveis.

$$\mathbf{S}_1 = \begin{pmatrix} 10 & 8 \\ 8 & 10 \end{pmatrix} \quad \mathbf{S}_2 = \begin{pmatrix} 10 & -8 \\ -8 & 10 \end{pmatrix} \quad \mathbf{S}_3 = \begin{pmatrix} 9 & 0 \\ 0 & 4 \end{pmatrix}$$

Variância generalizada e variância total

$$|S_1| = 10 \times 10 - 8 \times 8 = 100 - 64 = 36$$

Variância generalizada e variância total

$$|S_1| = 10 \times 10 - 8 \times 8 = 100 - 64 = 36$$

$$|S_2| = 10 \times 10 - (-8) \times (-8) = 100 - 64 = 36$$

Variância generalizada e variância total

$$|S_1| = 10 \times 10 - 8 \times 8 = 100 - 64 = 36$$

$$|S_2| = 10 \times 10 - (-8) \times (-8) = 100 - 64 = 36$$

$$|S_3| = 9 \times 4 - 0 \times 0 = 36$$

Variância generalizada e variância total

- Outra medida usada para resumir a variação total em um único valor é a **variância total**, definida por:

$$\text{Variância total} = \text{tr}(\mathbf{S}) = s_{11} + s_{22} + \dots + s_{pp}.$$

Variância generalizada e variância total

- Outra medida usada para resumir a variação total em um único valor é a **variância total**, definida por:

$$\text{Variância total} = \text{tr}(\mathbf{S}) = s_{11} + s_{22} + \dots + s_{pp}.$$

- Por se basear apenas na diagonal de $\mathbf{S}$, a variância total claramente ignora as correlações dos dados.

Aplicação- Dados de cerejeiras

- Variância generalizada:

$$|\mathbf{S}| = \begin{vmatrix} 6.462 & 6.180 & 33.858 \\ 6.180 & 36.700 & 44.545 \\ 33.858 & 44.545 & 190.667 \end{vmatrix} = 1683.254$$

Aplicação- Dados de cerejeiras

- Variância generalizada:

$$|\mathbf{S}| = \begin{vmatrix} 6.462 & 6.180 & 33.858 \\ 6.180 & 36.700 & 44.545 \\ 33.858 & 44.545 & 190.667 \end{vmatrix} = 1683.254$$

- Variância total:

$$\text{tr}(\mathbf{S}) = \text{tr} \begin{bmatrix} 6.462 & 6.180 & 33.858 \\ 6.180 & 36.700 & 44.545 \\ 33.858 & 44.545 & 190.667 \end{bmatrix} = 6.462 + 36.700 + 190.667 = 233.829$$

Preparação dos dados multivariados

Preparação dos dados multivariados

- Antes de aplicar técnicas multivariadas, é essencial avaliar a qualidade e a escala dos dados.

Preparação dos dados multivariados

- Antes de aplicar técnicas multivariadas, é essencial avaliar a qualidade e a escala dos dados.
- Problemas comuns:

Preparação dos dados multivariados

- Antes de aplicar técnicas multivariadas, é essencial avaliar a qualidade e a escala dos dados.
- Problemas comuns:
 - Dados ausentes (missing);

Preparação dos dados multivariados

- Antes de aplicar técnicas multivariadas, é essencial avaliar a qualidade e a escala dos dados.
- Problemas comuns:
 - Dados ausentes (missing);
 - Observações atípicas (outliers);

Preparação dos dados multivariados

- Antes de aplicar técnicas multivariadas, é essencial avaliar a qualidade e a escala dos dados.
- Problemas comuns:
 - Dados ausentes (missing);
 - Observações atípicas (outliers);
 - Variáveis com escalas diferentes;

Preparação dos dados multivariados

- Antes de aplicar técnicas multivariadas, é essencial avaliar a qualidade e a escala dos dados.
- Problemas comuns:
 - Dados ausentes (missing);
 - Observações atípicas (outliers);
 - Variáveis com escalas diferentes;
 - Distribuições assimétricas.

Dados ausentes

- Tipos de dados ausentes:

Dados ausentes

- Tipos de dados ausentes:
 - MCAR — Ausência completamente aleatória;

Dados ausentes

- Tipos de dados ausentes:
 - MCAR — Ausência completamente aleatória;
 - MAR — Observação ausente depende de outras variáveis, mas não do valor não observado;

Dados ausentes

- Tipos de dados ausentes:
 - MCAR — Ausência completamente aleatória;
 - MAR — Observação ausente depende de outras variáveis, mas não do valor não observado;
 - MNAR — Observação ausente depende (também) do próprio valor não observado.

Dados ausentes

- Tipos de dados ausentes:
 - MCAR — Ausência completamente aleatória;
 - MAR — Observação ausente depende de outras variáveis, mas não do valor não observado;
 - MNAR — Observação ausente depende (também) do próprio valor não observado.
- Impactos dos dados ausentes:

Dados ausentes

- Tipos de dados ausentes:
 - MCAR — Ausência completamente aleatória;
 - MAR — Observação ausente depende de outras variáveis, mas não do valor não observado;
 - MNAR — Observação ausente depende (também) do próprio valor não observado.
- Impactos dos dados ausentes:
 - Redução do tamanho amostral;

Dados ausentes

- Tipos de dados ausentes:
 - MCAR — Ausência completamente aleatória;
 - MAR — Observação ausente depende de outras variáveis, mas não do valor não observado;
 - MNAR — Observação ausente depende (também) do próprio valor não observado.
- Impactos dos dados ausentes:
 - Redução do tamanho amostral;
 - Viés nas estimativas;

Dados ausentes

- Tipos de dados ausentes:
 - MCAR — Ausência completamente aleatória;
 - MAR — Observação ausente depende de outras variáveis, mas não do valor não observado;
 - MNAR — Observação ausente depende (também) do próprio valor não observado.
- Impactos dos dados ausentes:
 - Redução do tamanho amostral;
 - Viés nas estimativas;
 - Limitação no uso de técnicas.

Tratamento de dados ausentes

- Principais estratégias:

Tratamento de dados ausentes

- Principais estratégias:
 - Remoção de casos (*listwise deletion*, *pairwise deletion*);

Tratamento de dados ausentes

- Principais estratégias:
 - Remoção de casos (*listwise deletion*, *pairwise deletion*);
 - Imputação simples (substituição pela média ou mediana);

Tratamento de dados ausentes

- Principais estratégias:
 - Remoção de casos (*listwise deletion*, *pairwise deletion*);
 - Imputação simples (substituição pela média ou mediana);
 - Imputação avançada (regressão, KNN, imputação múltipla)...

Tratamento de dados ausentes

- Principais estratégias:
 - Remoção de casos (*listwise deletion*, *pairwise deletion*);
 - Imputação simples (substituição pela média ou mediana);
 - Imputação avançada (regressão, KNN, imputação múltipla)...
- A escolha da estratégia depende do mecanismo de ausência.

Dados ausentes

- A Figura 1 apresenta os três mecanismos de perda de dados. Nos três casos, os valores observados (não observados) referem-se a y_2 .

Dados ausentes

- A Figura 1 apresenta os três mecanismos de perda de dados. Nos três casos, os valores observados (não observados) referem-se a y_2 .
- No mecanismo MCAR, as ausências para ocorrem de forma completamente aleatória com relação a ambas as variáveis;

Dados ausentes

- A Figura 1 apresenta os três mecanismos de perda de dados. Nos três casos, os valores observados (não observados) referem-se a y_2 .
- No mecanismo MCAR, as ausências para y_2 ocorrem de forma completamente aleatória com relação a ambas as variáveis;
- No mecanismo MAR, as ausências para y_2 dependem dos valores observados de y_1 , mas não estão relacionadas aos valores de y_2 .

Dados ausentes

- A Figura 1 apresenta os três mecanismos de perda de dados. Nos três casos, os valores observados (não observados) referem-se a y_2 .
- No mecanismo MCAR, as ausências para y_2 ocorrem de forma completamente aleatória com relação a ambas as variáveis;
- No mecanismo MAR, as ausências para y_2 dependem dos valores observados de y_1 , mas não estão relacionadas aos valores de y_2 .
- No mecanismo MNAR, as ausências para y_2 dependem também dos valores não observados de y_2 .

Dados ausentes




Figura 1: Mecanismos de dados ausentes

Outliers univariados

- Observações extremas com relação a uma variável.

Outliers univariados

- Observações extremas com relação a uma variável.
- Outliers univariados podem ser detectados com base no boxplot, z-score, intervalo interquartil. . .

Outliers univariados

- Observações extremas com relação a uma variável.
- Outliers univariados podem ser detectados com base no boxplot, z-score, intervalo interquartil. . .
- Critério clássico: $|z| > 3$.

Outliers multivariados

- Um indivíduo pode não ser extremo em nenhuma variável isolada, mas ser extremo no conjunto de variáveis.

Outliers multivariados

- Um indivíduo pode não ser extremo em nenhuma variável isolada, mas ser extremo no conjunto de variáveis.
- Medida clássica- Distância de Mahalanobis:

$$D_i^2 = (\mathbf{y}_i - \bar{\mathbf{y}})' S^{-1} (\mathbf{y}_i - \bar{\mathbf{y}}), \quad i = 1, 2, \dots, n$$

Outliers multivariados

- Um indivíduo pode não ser extremo em nenhuma variável isolada, mas ser extremo no conjunto de variáveis.
- Medida clássica- Distância de Mahalanobis:

$$D_i^2 = (\mathbf{y}_i - \bar{\mathbf{y}})' S^{-1} (\mathbf{y}_i - \bar{\mathbf{y}}), \quad i = 1, 2, \dots, n$$

- Os valores de D_i^2 podem ser comparados com os quantis de uma distribuição χ_p^2 para detecção de outliers (estudaremos adiante).

Outliers multivariados

- Outliers podem impactar fortemente medidas como médias, covariâncias e correlações, e consequentemente todas as análise baseadas nessas medidas.

Outliers multivariados

- Outliers podem impactar fortemente medidas como médias, covariâncias e correlações, e consequentemente todas as análise baseadas nessas medidas.
- Dependendo do tamanho da amostra e distribuição dos dados, outliers podem “dominar” a análise.

Outliers




Figura 2: Outlier univariado vs outlier multivariado

Outliers




Figura 3: Impacto de um outlier na correlação entre variáveis

Escalas e unidades

- Análises multivariadas usualmente contemplam variáveis com diferentes escalas (ex: altura (cm), peso (kg), renda (reais) . . .).

Escalas e unidades

- Análises multivariadas usualmente contemplam variáveis com diferentes escalas (ex: altura (cm), peso (kg), renda (reais) . . .).
- Como consequência, variáveis com maiores variâncias tendem a dominar as análises.

Escalas e unidades

- Análises multivariadas usualmente contemplam variáveis com diferentes escalas (ex: altura (cm), peso (kg), renda (reais) . . .).
- Como consequência, variáveis com maiores variâncias tendem a dominar as análises.
- A solução usual é padronizar as variáveis antes da análise.

Padronização (z-escore)

- O z-escore é calculado, para cada variável $j = 1, 2, \dots, p$, como:

$$z_{ij} = \frac{y_{ij} - \bar{y}_j}{s_{jj}}, \quad i = 1, 2, \dots, n.$$

Padronização (z-escore)

- O z-escore é calculado, para cada variável $j = 1, 2, \dots, p$, como:

$$z_{ij} = \frac{y_{ij} - \bar{y}_j}{s_{jj}}, \quad i = 1, 2, \dots, n.$$

- Propriedades:

Padronização (z-escore)

- O z-escore é calculado, para cada variável $j = 1, 2, \dots, p$, como:

$$z_{ij} = \frac{y_{ij} - \bar{y}_j}{s_{jj}}, \quad i = 1, 2, \dots, n.$$

- Propriedades:
 - Os z-escores têm média zero;

Padronização (z-escore)

- O z-escore é calculado, para cada variável $j = 1, 2, \dots, p$, como:

$$z_{ij} = \frac{y_{ij} - \bar{y}_j}{s_{jj}}, \quad i = 1, 2, \dots, n.$$

- Propriedades:
 - Os z-escores têm média zero;
 - Os z-escores têm variância igual a um;

Padronização (z-escore)

- O z-escore é calculado, para cada variável $j = 1, 2, \dots, p$, como:

$$z_{ij} = \frac{y_{ij} - \bar{y}_j}{s_{jj}}, \quad i = 1, 2, \dots, n.$$

- Propriedades:
 - Os z-escores têm média zero;
 - Os z-escores têm variância igual a um;
 - São adimensionais (livres de unidades de medida).

Outras formas de escalonamento

- Transformação min-max:

$$z_{ij} = \frac{y_{ij} - \min(y_j)}{\max(y_j) - \min(y_j)}, \quad i = 1, 2, \dots, n.$$

Outras formas de escalonamento

- Transformação min-max:

$$z_{ij} = \frac{y_{ij} - \min(y_j)}{\max(y_j) - \min(y_j)}, \quad i = 1, 2, \dots, n.$$

- Transformação robusta:

$$z_{ij} = \frac{y_{ij} - \text{mediana}(y_j)}{\text{IQR}(y_j)}, \quad i = 1, 2, \dots, n,$$

em que IQR representa a amplitude interquartis.

Escalas e unidades




Figura 4: Diferentes variáveis em suas escalas originais

Escalas e unidades




Figura 5: Variáveis padronizadas (z-escore)

Escalas e unidades




Figura 6: Variáveis padronizadas (transformação min-max)

Transformações

- As transformações de variáveis têm por objetivo:

Transformações

- As transformações de variáveis têm por objetivo:
 - Reduzir assimetria;

Transformações

- As transformações de variáveis têm por objetivo:
 - Reduzir assimetria;
 - Estabilizar variância;

Transformações

- As transformações de variáveis têm por objetivo:
 - Reduzir assimetria;
 - Estabilizar variância;
 - Linearizar relações.

Transformações

- As transformações de variáveis têm por objetivo:
 - Reduzir assimetria;
 - Estabilizar variância;
 - Linearizar relações.
- Como transformações mais comuns temos a logarítmica, raiz*-quadrada, além de famílias de transformações (como Box-Cox).

Transformações




Figura 7: Diferentes variáveis em suas escalas originais

Transformações




Figura 8: Variáveis transformadas para distribuição mais simétrica

Representação gráfica

Representação gráfica

- Algumas representações gráficas para dados multivariados:

Representação gráfica

- Algumas representações gráficas para dados multivariados:
 - Histograma;

Representação gráfica

- Algumas representações gráficas para dados multivariados:
 - Histograma;
 - Boxplot;

Representação gráfica

- Algumas representações gráficas para dados multivariados:
 - Histograma;
 - Boxplot;
 - Diagrama de dispersão (com ajustes de regressão não paramétrica);

Representação gráfica

- Algumas representações gráficas para dados multivariados:
 - Histograma;
 - Boxplot;
 - Diagrama de dispersão (com ajustes de regressão não paramétrica);
 - Correlograma;

Representação gráfica

- Algumas representações gráficas para dados multivariados:
 - Histograma;
 - Boxplot;
 - Diagrama de dispersão (com ajustes de regressão não paramétrica);
 - Correlograma;
 - Matrizes de gráficos;

Representação gráfica

- Algumas representações gráficas para dados multivariados:
 - Histograma;
 - Boxplot;
 - Diagrama de dispersão (com ajustes de regressão não paramétrica);
 - Correlograma;
 - Matrizes de gráficos;
 - Faces de Chernoff;

Representação gráfica

- Algumas representações gráficas para dados multivariados:
 - Histograma;
 - Boxplot;
 - Diagrama de dispersão (com ajustes de regressão não paramétrica);
 - Correlograma;
 - Matrizes de gráficos;
 - Faces de Chernoff;
 - Gráficos tridimensionais;

Representação gráfica

- Algumas representações gráficas para dados multivariados:
 - Histograma;
 - Boxplot;
 - Diagrama de dispersão (com ajustes de regressão não paramétrica);
 - Correlograma;
 - Matrizes de gráficos;
 - Faces de Chernoff;
 - Gráficos tridimensionais;
 - Gráfico de radar;

Representação gráfica

- Algumas representações gráficas para dados multivariados:
 - Histograma;
 - Boxplot;
 - Diagrama de dispersão (com ajustes de regressão não paramétrica);
 - Correlograma;
 - Matrizes de gráficos;
 - Faces de Chernoff;
 - Gráficos tridimensionais;
 - Gráfico de radar;
 - Heatmaps;

Representação gráfica

- Algumas representações gráficas para dados multivariados:
 - Histograma;
 - Boxplot;
 - Diagrama de dispersão (com ajustes de regressão não paramétrica);
 - Correlograma;
 - Matrizes de gráficos;
 - Faces de Chernoff;
 - Gráficos tridimensionais;
 - Gráfico de radar;
 - Heatmaps;
 - Dendrograma;

Representação gráfica

- Algumas representações gráficas para dados multivariados:
 - Histograma;
 - Boxplot;
 - Diagrama de dispersão (com ajustes de regressão não paramétrica);
 - Correlograma;
 - Matrizes de gráficos;
 - Faces de Chernoff;
 - Gráficos tridimensionais;
 - Gráfico de radar;
 - Heatmaps;
 - Dendrograma;
 - Alluvial plots;

Representação gráfica

- Algumas representações gráficas para dados multivariados:
 - Histograma;
 - Boxplot;
 - Diagrama de dispersão (com ajustes de regressão não paramétrica);
 - Correlograma;
 - Matrizes de gráficos;
 - Faces de Chernoff;
 - Gráficos tridimensionais;
 - Gráfico de radar;
 - Heatmaps;
 - Dendrograma;
 - Alluvial plots;
 - Biplots, dentre outros.

Distâncias e similaridades

Medidas de distância

- Boa parte das técnicas multivariadas baseiam-se no conceito de distância.

Medidas de distância

- Boa parte das técnicas multivariadas baseiam-se no conceito de distância.
- Em Estatística, usamos distâncias para medir quão semelhantes são dois indivíduos com relação aos valores observados para p variáveis.

Medidas de distância

- Boa parte das técnicas multivariadas baseiam-se no conceito de distância.
- Em Estatística, usamos distâncias para medir quão semelhantes são dois indivíduos com relação aos valores observados para p variáveis.
- Uma medida $d(P, Q)$ é definida distância entre dois pontos P e Q caso satisfaça às seguintes condições:

Medidas de distância

- Boa parte das técnicas multivariadas baseiam-se no conceito de distância.
- Em Estatística, usamos distâncias para medir quão semelhantes são dois indivíduos com relação aos valores observados para p variáveis.
- Uma medida $d(P, Q)$ é definida distância entre dois pontos P e Q caso satisfaça às seguintes condições:
 - $d(P, Q) = d(Q, P)$;

Medidas de distância

- Boa parte das técnicas multivariadas baseiam-se no conceito de distância.
- Em Estatística, usamos distâncias para medir quão semelhantes são dois indivíduos com relação aos valores observados para p variáveis.
- Uma medida $d(P, Q)$ é definida distância entre dois pontos P e Q caso satisfaça às seguintes condições:
 - $d(P, Q) = d(Q, P)$;
 - $d(P, Q) > 0$, se $P \neq Q$;

Medidas de distância

- Boa parte das técnicas multivariadas baseiam-se no conceito de distância.
- Em Estatística, usamos distâncias para medir quão semelhantes são dois indivíduos com relação aos valores observados para p variáveis.
- Uma medida $d(P, Q)$ é definida distância entre dois pontos P e Q caso satisfaça às seguintes condições:
 - $d(P, Q) = d(Q, P)$;
 - $d(P, Q) > 0$, se $P \neq Q$;
 - $d(P, Q) = 0$, se $P = Q$;

Medidas de distância

- Boa parte das técnicas multivariadas baseiam-se no conceito de distância.
- Em Estatística, usamos distâncias para medir quão semelhantes são dois indivíduos com relação aos valores observados para p variáveis.
- Uma medida $d(P, Q)$ é definida distância entre dois pontos P e Q caso satisfaça às seguintes condições:
 - $d(P, Q) = d(Q, P)$;
 - $d(P, Q) > 0$, se $P \neq Q$;
 - $d(P, Q) = 0$, se $P = Q$;
 - $d(P, Q) \leq d(P, R) + d(R, Q)$ (desigualdade triangular).

Medidas de distância

- Boa parte das técnicas multivariadas baseiam-se no conceito de distância.
- Em Estatística, usamos distâncias para medir quão semelhantes são dois indivíduos com relação aos valores observados para p variáveis.
- Uma medida $d(P, Q)$ é definida distância entre dois pontos P e Q caso satisfaça às seguintes condições:
 - $d(P, Q) = d(Q, P)$;
 - $d(P, Q) > 0$, se $P \neq Q$;
 - $d(P, Q) = 0$, se $P = Q$;
 - $d(P, Q) \leq d(P, R) + d(R, Q)$ (desigualdade triangular).
- Há uma grande variedade de medidas de distância. Algumas delas são discutidas na sequência.

Distância Euclidiana

- Considerando inicialmente o caso bidimensional ($p=2$), a distância Euclidiana entre dois pontos $\mathbf{x} = (x_1, x_2)$ e $\mathbf{y} = (y_1, y_2)$ é definida como:

$$d(\mathbf{x}, \mathbf{y}) = \sqrt{(x_1 - y_1)^2 + (x_2 - y_2)^2}.$$

Distância Euclidiana

- Considerando inicialmente o caso bidimensional ($p=2$), a distância Euclidiana entre dois pontos $\mathbf{x} = (x_1, x_2)$ e $\mathbf{y} = (y_1, y_2)$ é definida como:

$$d(\mathbf{x}, \mathbf{y}) = \sqrt{(x_1 - y_1)^2 + (x_2 - y_2)^2}.$$

- Como caso particular, a distância do ponto $\mathbf{x} = (x_1, x_2)$ à origem $O = (0, 0)$ fica dada por:

$$d(\mathbf{x}, O) = \sqrt{x_1^2 + x_2^2}$$

Distância Euclidiana

- Para o caso p -dimensional, a distância entre os pontos $\mathbf{x} = (x_1, x_2, \dots, x_p)$ e $\mathbf{y} = (y_1, y_2, \dots, y_p)$ é definida como:

$$d(\mathbf{x}, \mathbf{y}) = \sqrt{(x_1 - y_1)^2 + (x_2 - y_2)^2 + \dots + (x_p - y_p)^2}.$$

Distância Euclidiana

- Para o caso p -dimensional, a distância entre os pontos $\mathbf{x} = (x_1, x_2, \dots, x_p)$ e $\mathbf{y} = (y_1, y_2, \dots, y_p)$ é definida como:

$$d(\mathbf{x}, \mathbf{y}) = \sqrt{(x_1 - y_1)^2 + (x_2 - y_2)^2 + \dots + (x_p - y_p)^2}.$$

- Como caso particular, a distância do ponto $\mathbf{x} = (x_1, x_2, \dots, x_p)$ à origem $O = (0, 0, \dots, 0)$ fica dada por:

$$d(\mathbf{x}, O) = \sqrt{x_1^2 + x_2^2 + \dots + x_p^2}.$$

Medidas de distância

- A distância Euclidiana confere mesmos pesos às diferenças verificadas em cada uma das p dimensões.

Medidas de distância

- A distância Euclidiana confere mesmos pesos às diferenças verificadas em cada uma das p dimensões.
- Nas análises estatísticas em que as variáveis têm diferentes escalas, escalonar as variáveis e calcular as distâncias com base nessas novas variáveis pode ser recomendado.

Distância de Manhattan

- A distância de Manhattan é definida por:

$$d(\mathbf{x}, \mathbf{y}) = \sum_j^p |y_j - x_j|$$

Distância de Manhattan

- A distância de Manhattan é definida por:

$$d(\mathbf{x}, \mathbf{y}) = \sum_j^p |y_j - x_j|$$

- A distância de Manhattan pode ser útil em situações em que o deslocamento é restrito a direções ortogonais (como em GPS).

Distância de Manhattan

- A distância de Manhattan é definida por:

$$d(\mathbf{x}, \mathbf{y}) = \sum_j^p |y_j - x_j|$$

- A distância de Manhattan pode ser útil em situações em que o deslocamento é restrito a direções ortogonais (como em GPS).
- Em problemas com dados esparsos, em que a base de dados contém muitos zeros, a distância de Manhattan pode ser preferível à Euclidiana por amplificar menos as diferenças.

Distância de Chebyshev

- A distância de Chebyshev é definida por:

$$d(\mathbf{x}, \mathbf{y}) = \max_j |y_j - x_j|$$

Distância de Chebyshev

- A distância de Chebyshev é definida por:

$$d(\mathbf{x}, \mathbf{y}) = \max_j |y_j - x_j|$$

- A distância de Chebyshev pode ser usada quando o interesse reside apenas na maior distância dentre todas as variáveis (como a operação de dois servidores em que se tem interesse no processo em que os tempos de processamento foram mais díspares dentre todos).

Distância de Canberra

- A distância de Canberra é definida por:

$$d(\mathbf{x}, \mathbf{y}) = \sum_j^p \frac{|y_j - x_j|}{|x_j| + |y_j|}$$

Distância de Canberra

- A distância de Canberra é definida por:

$$d(\mathbf{x}, \mathbf{y}) = \sum_j^p \frac{|y_j - x_j|}{|x_j| + |y_j|}$$

- A distância de Canberra pode ser útil quando há uma mistura de dados com escalas muito variáveis, e prefere-se destacar diferenças relativas ao invés de absolutas.

Distância de Minkowski

- A distância de Minkowski é definida por:

$$d(\mathbf{x}, \mathbf{y}) = \left(\sum_j^p |y_j - x_j|^t \right)^{\frac{1}{t}},$$

para $t \geq 1$, tal que para $t = 1$ temos a distância de Manhattan, e para $t = 2$ a distância Euclidiana.

Distância de Minkowski

- A distância de Minkowski é definida por:

$$d(\mathbf{x}, \mathbf{y}) = \left(\sum_j^p |y_j - x_j|^t \right)^{\frac{1}{t}},$$

para $t \geq 1$, tal que para $t = 1$ temos a distância de Manhattan, e para $t = 2$ a distância Euclidiana.

- Por ser uma medida de distância mais geral, a calibragem do valor de t pode conferir maior sensibilidade em algumas aplicações como no reconhecimento de imagens.

Medidas de distância




Figura 9: Ilustração- medidas de distância

Aplicação- Dados de cerejeiras

- Distância Euclidiana (para as duas primeiras observações da base)

$$d(\mathbf{y}_1, \mathbf{y}_2) = \sqrt{(12.90 - 11.70)^2 + (85 - 69)^2 + (33.8 - 21.3)^2} = 20.34$$

Aplicação- Dados de cerejeiras

- Distância Euclidiana (para as duas primeiras observações da base)

$$d(\mathbf{y}_1, \mathbf{y}_2) = \sqrt{(12.90 - 11.70)^2 + (85 - 69)^2 + (33.8 - 21.3)^2} = 20.34$$

- Distância de Manhattan

$$d(\mathbf{y}_1, \mathbf{y}_2) = |12.90 - 11.70| + |85 - 69| + |33.8 - 21.3| = 29.70$$

Aplicação- Dados de cerejeiras

- Distância Euclidiana (para as duas primeiras observações da base)

$$d(\mathbf{y}_1, \mathbf{y}_2) = \sqrt{(12.90 - 11.70)^2 + (85 - 69)^2 + (33.8 - 21.3)^2} = 20.34$$

- Distância de Manhattan

$$d(\mathbf{y}_1, \mathbf{y}_2) = |12.90 - 11.70| + |85 - 69| + |33.8 - 21.3| = 29.70$$

- Distância de Chebyshev

$$d(\mathbf{y}_1, \mathbf{y}_2) = \max \{|12.90 - 11.70|, |85 - 69|, |33.8 - 21.3|\} = 16.00$$

Aplicação- Dados de cerejeiras

- Distância de Canberra

$$d(\mathbf{y}_1, \mathbf{y}_2) = \frac{|12.90 - 11.70|}{|12.90| + |11.70|} + \frac{|85 - 69|}{|85| + |69|} + \frac{|33.8 - 21.3|}{|33.8| + |21.3|} = 0.38$$

Aplicação- Dados de cerejeiras

- Distância de Canberra

$$d(\mathbf{y}_1, \mathbf{y}_2) = \frac{|12.90 - 11.70|}{|12.90| + |11.70|} + \frac{|85 - 69|}{|85| + |69|} + \frac{|33.8 - 21.3|}{|33.8| + |21.3|} = 0.38$$

- Distância de Minkowski (t=1.3)

$$d(\mathbf{y}_1, \mathbf{y}_2) = \left(|12.90 - 11.70|^{1.3} + |85 - 69|^{1.3} + |33.8 - 21.3|^{1.3} \right)^{\frac{1}{1.3}} = 24.71$$

Índices de similaridade

- Na análise de dados discotômicos (ex: presença/ausência de certo atributo, para p atributos avaliados), existem numerosos índices de similaridade aplicados a dois indivíduos quaisquer.

Índices de similaridade

- Na análise de dados discotômicos (ex: presença/ausência de certo atributo, para p atributos avaliados), existem numerosos índices de similaridade aplicados a dois indivíduos quaisquer.
- Em geral, tais índices assumem valor zero no caso de nenhuma similaridade, e valor 1 no caso de similaridade completa.

Índices de similaridade

- Na análise de dados discotômicos (ex: presença/ausência de certo atributo, para p atributos avaliados), existem numerosos índices de similaridade aplicados a dois indivíduos quaisquer.
- Em geral, tais índices assumem valor zero no caso de nenhuma similaridade, e valor 1 no caso de similaridade completa.
- Neste caso, a distância (dissimilaridade) entre dois indivíduos pode ser definida como o complemento da similaridade:

$$\text{Dissimilaridade} = 1 - \text{Similaridade}$$

Índices de similaridade

- Os índices de similaridade são calculados a partir das frequências de resultados coincidentes (e não coincidentes) para os p atributos:

Tabela 2: Tabela de concordâncias

Ind. 1	Ind. 2		Total
	Presente	Ausente	
Presente	a	b	$a+b$
Ausente	c	d	$c+d$
Total	$a+c$	$b+d$	p

Índices de similaridade

- Índice de empates simples

$$S(\mathbf{y}_1, \mathbf{y}_2) = \frac{a + d}{p}$$

Índices de similaridade

- Índice de empates simples

$$S(\mathbf{y}_1, \mathbf{y}_2) = \frac{a + d}{p}$$

- Índice de Jaccard

$$S(\mathbf{y}_1, \mathbf{y}_2) = \frac{a}{a + b + c}$$

Índices de similaridade

- Índice de empates simples

$$S(\mathbf{y}_1, \mathbf{y}_2) = \frac{a + d}{p}$$

- Índice de Jaccard

$$S(\mathbf{y}_1, \mathbf{y}_2) = \frac{a}{a + b + c}$$

Índices de similaridade

- Índice de Dice-Sorensen

$$S(\mathbf{y}_1, \mathbf{y}_2) = \frac{2a}{2a + b + c}$$

Índices de similaridade

- Índice de Dice-Sorensen

$$S(\mathbf{y}_1, \mathbf{y}_2) = \frac{2a}{2a + b + c}$$

- Índice de Ochiai

$$S(\mathbf{y}_1, \mathbf{y}_2) = \frac{a}{\sqrt{(a + b)(a + c)}}$$

Aplicação- sintomas de pacientes

Tabela 3: Dados de dez sintomas avaliados em dois pacientes

Sintoma	Paciente 1	Paciente 2
1	Ausente	Ausente
2	Presente	Presente
3	Presente	Ausente
4	Ausente	Ausente
5	Ausente	Ausente
6	Presente	Ausente
7	Presente	Presente
8	Presente	Ausente
9	Presente	Ausente
10	Ausente	Presente

Aplicação- sintomas de pacientes

Tabela 4: Tabela de concordâncias- sintomas dos pacientes

Pac. 1	Pac. 2		Total
	Presente	Ausente	
Presente	2	4	6
Ausente	1	3	4
Total	3	7	10

Aplicação- sintomas de pacientes

- Índice de empates simples

$$S(\text{Pac. 1, Pac. 2}) = \frac{2+3}{10} = 0.5$$

Aplicação- sintomas de pacientes

- Índice de empates simples

$$S(\text{Pac. 1, Pac. 2}) = \frac{2+3}{10} = 0.5$$

- Índice de Jaccard

$$S(\text{Pac. 1, Pac. 2}) = \frac{2}{2+4+1} = 0.29$$

Aplicação- sintomas de pacientes

- Índice de Dice-Sorensen

$$S(\text{Pac. 1, Pac. 2}) = \frac{2 \times 2}{2 \times 2 + 4 + 1} = 0.44$$

Aplicação- sintomas de pacientes

- Índice de Dice-Sorensen

$$S(\text{Pac. 1, Pac. 2}) = \frac{2 \times 2}{2 \times 2 + 4 + 1} = 0.44$$

- Índice de Ochiai

$$S(\text{Pac. 1, Pac. 2}) = \frac{2}{\sqrt{(2+4)(2+1)}} = 0.47$$

Distância de Mahalanobis

- A distância de Mahalanobis configura um caso mais geral, em que as variâncias e covariâncias são usadas no cálculo da distância.

Distância de Mahalanobis

- A distância de Mahalanobis configura um caso mais geral, em que as variâncias e covariâncias são usadas no cálculo da distância.
- A distância estatística de Mahalanobis entre $\mathbf{x}$ e $\mathbf{y}$ fica definida como:

$$d^2(\mathbf{x}, \mathbf{y}) = (\mathbf{x} - \mathbf{y})' \mathbf{S}^{-1} (\mathbf{x} - \mathbf{y}),$$

Distância de Mahalanobis

- A distância de Mahalanobis configura um caso mais geral, em que as variâncias e covariâncias são usadas no cálculo da distância.

- A distância estatística de Mahalanobis entre $\mathbf{x}$ e $\mathbf{y}$ fica definida como:

$$d^2(\mathbf{x}, \mathbf{y}) = (\mathbf{x} - \mathbf{y})' \mathbf{S}^{-1} (\mathbf{x} - \mathbf{y}),$$

- A distância de Mahalanobis é largamente aplicada, permitindo acomodar diferentes escalas e correlações entre as variáveis.

Distância de Mahalanobis

- Dada sua definição, a distância de Mahalanobis, ao incorporar a inversa da matriz de covariância, tem como efeitos:

Distância de Mahalanobis

- Dada sua definição, a distância de Mahalanobis, ao incorporar a inversa da matriz de covariância, tem como efeitos:
 - Padronizar todas as variáveis de forma que apresentem mesma variância;

Distância de Mahalanobis

- Dada sua definição, a distância de Mahalanobis, ao incorporar a inversa da matriz de covariância, tem como efeitos:
 - Padronizar todas as variáveis de forma que apresentem mesma variância;
 - Eliminar correlações.

Distância Euclidiana




Figura 10: Circunferência representando os pontos com mesma distância Euclidiana em relação a x_0 .

Distância de Mahalanobis




Figura 11: Elipse representando os pontos com mesma distância de Mahalanobis em relação a x_0 .

Exemplo

- Considere duas observações $\mathbf{x} = (1, 5)$ e $\mathbf{y} = (2, 12)$.

Exemplo

- Considere duas observações $\mathbf{x} = (1, 5)$ e $\mathbf{y} = (2, 12)$.
 - Calcule a distância Euclidiana entre os dois pontos;

Exemplo

- Considere duas observações $\mathbf{x} = (1, 5)$ e $\mathbf{y} = (2, 12)$.
 - Calcule a distância Euclidiana entre os dois pontos;
 - Calcule a distância de Mahalanobis entre os dois pontos, considerando:

Exemplo

- Considere duas observações $\mathbf{x} = (1, 5)$ e $\mathbf{y} = (2, 12)$.
 - Calcule a distância Euclidiana entre os dois pontos;
 - Calcule a distância de Mahalanobis entre os dois pontos, considerando:

$$\mathbf{S}_1 = \begin{pmatrix} 25 & 16 \\ 16 & 25 \end{pmatrix} \quad \mathbf{S}_2 = \begin{pmatrix} 25 & 4 \\ 4 & 16 \end{pmatrix}$$

Exemplo

- Distância Euclidiana:

$$d^2(\mathbf{x}, \mathbf{y}) = (1 - 2)^2 + (5 - 12)^2 = 50$$

Exemplo

- Distância Euclidiana:

$$d^2(\mathbf{x}, \mathbf{y}) = (1 - 2)^2 + (5 - 12)^2 = 50$$

- Distância de Mahalanobis (Caso 1):

$$d^2(\mathbf{x}, \mathbf{y}) = (1 - 2 \quad 5 - 12) \begin{pmatrix} 25 & 16 \\ 16 & 25 \end{pmatrix}^{-1} \begin{pmatrix} 1 - 2 \\ 5 - 12 \end{pmatrix} = 2.78$$

Exemplo

- Distância Euclidiana:

$$d^2(\mathbf{x}, \mathbf{y}) = (1 - 2)^2 + (5 - 12)^2 = 50$$

- Distância de Mahalanobis (Caso 1):

$$d^2(\mathbf{x}, \mathbf{y}) = (1 - 2 \quad 5 - 12) \begin{pmatrix} 25 & 16 \\ 16 & 25 \end{pmatrix}^{-1} \begin{pmatrix} 1 - 2 \\ 5 - 12 \end{pmatrix} = 2.78$$

- Distância de Mahalanobis (Caso 2):

$$d^2(\mathbf{x}, \mathbf{y}) = (1 - 2 \quad 5 - 12) \begin{pmatrix} 25 & 4 \\ 4 & 16 \end{pmatrix}^{-1} \begin{pmatrix} 1 - 2 \\ 5 - 12 \end{pmatrix} = 3.08$$

Matriz de distâncias

- A **matriz de distâncias** é a representação matricial das distâncias avaliadas para cada par de observações amostrais.

$$\mathbf{D} = \begin{bmatrix} d_{11} & d_{12} & \cdots & d_{1n} \\ d_{21} & d_{22} & \cdots & d_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ d_{n1} & d_{n2} & \cdots & d_{nn} \end{bmatrix},$$

em que $d_{ij} = d_{ji}$ é a distância calculada para os indivíduos i e j e $d_{ii} = 0$, $i = 1, 2, \dots, n$.

Matriz de distâncias

- A **matriz de distâncias** é a representação matricial das distâncias avaliadas para cada par de observações amostrais.

$$\mathbf{D} = \begin{bmatrix} d_{11} & d_{12} & \cdots & d_{1n} \\ d_{21} & d_{22} & \cdots & d_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ d_{n1} & d_{n2} & \cdots & d_{nn} \end{bmatrix},$$

em que $d_{ij} = d_{ji}$ é a distância calculada para os indivíduos i e j e $d_{ii} = 0$, $i = 1, 2, \dots, n$.

- A visualização das distâncias num gráfico do tipo “mapa de calor” permite uma avaliação conjunta das distâncias calculadas duas a duas (exercício).

Distâncias




Figura 12: Ilustração- distâncias

Aplicação- Dados de cerejeiras

- A matriz de distâncias Euclidianas fica dada por:

$$\mathbf{D} = \begin{bmatrix} 0 & 20.34 & 12.40 & 5.57 & 22.58 \\ 20.34 & 0 & 11.09 & 15.34 & 37.23 \\ 12.40 & 11.09 & 0 & 9.71 & 33.77 \\ 5.57 & 15.34 & 9.71 & 0 & 24.30 \\ 22.58 & 37.23 & 33.77 & 24.30 & 0 \end{bmatrix}.$$

Exemplo- Desempenho de atletas de decatlo

Exemplo- Desempenho de atletas de decatlo

- Para fins de ilustração, vamos considerar dados referentes ao desempenho de atletas de decatlo nos jogos olímpicos do Rio de Janeiro, 2016.

Exemplo- Desempenho de atletas de decatlo

- Para fins de ilustração, vamos considerar dados referentes ao desempenho de atletas de decatlo nos jogos olímpicos do Rio de Janeiro, 2016.
- Os dados estão disponíveis na base `dec` disponível na biblioteca `combinedevents` do R e referem-se ao desempenho dos 23 atletas da prova de decatlo nos jogos olímpicos do Rio de Janeiro, 2016.

Exemplo- Desempenho de atletas de decatlo

- Para fins de ilustração, vamos considerar dados referentes ao desempenho de atletas de decatlo nos jogos olímpicos do Rio de Janeiro, 2016.
- Os dados estão disponíveis na base `dec` disponível na biblioteca `combinedevents` do R e referem-se ao desempenho dos 23 atletas da prova de decatlo nos jogos olímpicos do Rio de Janeiro, 2016.
- As dez variáveis a serem analisadas referem-se aos desempenhos dos atletas em cada prova que compõe o decatlo.

Exemplo- Desempenho de atletas de decatlo

- As variáveis para a análise são as seguintes:

Exemplo- Desempenho de atletas de decatlo

- As variáveis para a análise são as seguintes:
 - `athlete`: nome do atleta (apenas para identificação);

Exemplo- Desempenho de atletas de decatlo

- As variáveis para a análise são as seguintes:
 - athlete: nome do atleta (apenas para identificação);
 - 100m_p: pontuação na corrida de 100 metros;

Exemplo- Desempenho de atletas de decatlo

- As variáveis para a análise são as seguintes:
 - athlete: nome do atleta (apenas para identificação);
 - 100m_p: pontuação na corrida de 100 metros;
 - LJ_p: pontuação no salto em distância;

Exemplo- Desempenho de atletas de decatlo

- As variáveis para a análise são as seguintes:
 - athlete: nome do atleta (apenas para identificação);
 - 100m_p: pontuação na corrida de 100 metros;
 - LJ_p: pontuação no salto em distância;
 - SP_p: pontuação no arremesso de peso;

Exemplo- Desempenho de atletas de decatlo

- As variáveis para a análise são as seguintes:
 - athlete: nome do atleta (apenas para identificação);
 - 100m_p: pontuação na corrida de 100 metros;
 - LJ_p: pontuação no salto em distância;
 - SP_p: pontuação no arremesso de peso;
 - HJ_p: pontuação no salto em altura;

Exemplo- Desempenho de atletas de decatlo

- As variáveis para a análise são as seguintes:
 - athlete: nome do atleta (apenas para identificação);
 - 100m_p: pontuação na corrida de 100 metros;
 - LJ_p: pontuação no salto em distância;
 - SP_p: pontuação no arremesso de peso;
 - HJ_p: pontuação no salto em altura;
 - 400m_p: pontuação na corrida de 400 metros;

Exemplo- Desempenho de atletas de decatlo

- As variáveis para a análise são as seguintes:
 - athlete: nome do atleta (apenas para identificação);
 - 100m_p: pontuação na corrida de 100 metros;
 - LJ_p: pontuação no salto em distância;
 - SP_p: pontuação no arremesso de peso;
 - HJ_p: pontuação no salto em altura;
 - 400m_p: pontuação na corrida de 400 metros;
 - 110mH_p: pontuação na corrida de 110 metros com barreiras;

Exemplo- Desempenho de atletas de decatlo

- As variáveis para a análise são as seguintes:
 - athlete: nome do atleta (apenas para identificação);
 - 100m_p: pontuação na corrida de 100 metros;
 - LJ_p: pontuação no salto em distância;
 - SP_p: pontuação no arremesso de peso;
 - HJ_p: pontuação no salto em altura;
 - 400m_p: pontuação na corrida de 400 metros;
 - 110mH_p: pontuação na corrida de 110 metros com barreiras;
 - DT_p: pontuação no arremesso de disco;

Exemplo- Desempenho de atletas de decatlo

- As variáveis para a análise são as seguintes:
 - athlete: nome do atleta (apenas para identificação);
 - 100m_p: pontuação na corrida de 100 metros;
 - LJ_p: pontuação no salto em distância;
 - SP_p: pontuação no arremesso de peso;
 - HJ_p: pontuação no salto em altura;
 - 400m_p: pontuação na corrida de 400 metros;
 - 110mH_p: pontuação na corrida de 110 metros com barreiras;
 - DT_p: pontuação no arremesso de disco;
 - PV_p: pontuação no salto com vara;

Exemplo- Desempenho de atletas de decatlo

- As variáveis para a análise são as seguintes:
 - athlete: nome do atleta (apenas para identificação);
 - 100m_p: pontuação na corrida de 100 metros;
 - LJ_p: pontuação no salto em distância;
 - SP_p: pontuação no arremesso de peso;
 - HJ_p: pontuação no salto em altura;
 - 400m_p: pontuação na corrida de 400 metros;
 - 110mH_p: pontuação na corrida de 110 metros com barreiras;
 - DT_p: pontuação no arremesso de disco;
 - PV_p: pontuação no salto com vara;
 - JT_p: pontuação no arremesso de dardo;

Exemplo- Desempenho de atletas de decatlo

- As variáveis para a análise são as seguintes:
 - athlete: nome do atleta (apenas para identificação);
 - 100m_p: pontuação na corrida de 100 metros;
 - LJ_p: pontuação no salto em distância;
 - SP_p: pontuação no arremesso de peso;
 - HJ_p: pontuação no salto em altura;
 - 400m_p: pontuação na corrida de 400 metros;
 - 110mH_p: pontuação na corrida de 110 metros com barreiras;
 - DT_p: pontuação no arremesso de disco;
 - PV_p: pontuação no salto com vara;
 - JT_p: pontuação no arremesso de dardo;
 - 1500m_p: pontuação na corrida de 1500 metros.

Exemplo- Desempenho de atletas de decatlo

- O que queremos descobrir aqui?

Exemplo- Desempenho de atletas de decatlo

- O que queremos descobrir aqui?
 - Há atletas especialistas?

Exemplo- Desempenho de atletas de decatlo

- O que queremos descobrir aqui?
 - Há atletas especialistas?
 - Existem provas redundantes?

Exemplo- Desempenho de atletas de decatlo

- O que queremos descobrir aqui?
 - Há atletas especialistas?
 - Existem provas redundantes?
 - Há atletas com desempenhos similares?

Exemplo- Desempenho de atletas de decatlo

- O que queremos descobrir aqui?
 - Há atletas especialistas?
 - Existem provas redundantes?
 - Há atletas com desempenhos similares?
 - Quais atletas “dominam” o ranking?

O que vamos estudar no próximo módulo

O que vamos estudar no próximo módulo

- Vetores aleatórios e suas propriedades.

O que vamos estudar no próximo módulo

- Vetores aleatórios e suas propriedades.
- A distribuição normal multivariada.

O que vamos estudar no próximo módulo

- Vetores aleatórios e suas propriedades.
- A distribuição normal multivariada.
- Como verificar a suposição de normalidade multivariada.

O que vamos estudar no próximo módulo

- Vetores aleatórios e suas propriedades.
- A distribuição normal multivariada.
- Como verificar a suposição de normalidade multivariada.
- Como detectar outliers em dados multivariados.