

CE319 - Estatística multivariada

Distribuições multivariadas

Cesar Augusto Taconeli

12 de março, 2026

Distribuições multivariadas

O que vamos estudar neste módulo

O que vamos estudar neste módulo

- Vetores aleatórios e suas propriedades.

O que vamos estudar neste módulo

- Vetores aleatórios e suas propriedades.
- A distribuição normal multivariada.

O que vamos estudar neste módulo

- Vetores aleatórios e suas propriedades.
- A distribuição normal multivariada.
- Como verificar a suposição de normalidade multivariada.

O que vamos estudar neste módulo

- Vetores aleatórios e suas propriedades.
- A distribuição normal multivariada.
- Como verificar a suposição de normalidade multivariada.
- Como detectar outliers em dados multivariados.

Introdução

Introdução

- Numa análise multivariada, dispõe-se, em geral, de uma amostra de n indivíduos em $p \geq 2$ variáveis aleatórias.

Introdução

- Numa análise multivariada, dispõe-se, em geral, de uma amostra de n indivíduos em $p \geq 2$ variáveis aleatórias.
- O uso de técnicas multivariadas permite concluir simultaneamente sobre as p variáveis.

Introdução

- Numa análise multivariada, dispõe-se, em geral, de uma amostra de n indivíduos em $p \geq 2$ variáveis aleatórias.
- O uso de técnicas multivariadas permite concluir simultaneamente sobre as p variáveis.
- Alguns métodos multivariados consistem de generalizações de procedimentos univariados utilizados com finalidades semelhantes.

Disposição dos dados em uma análise multivariada

- Vamos denotar por y_{ij} o valor da variável j verificado no indivíduo i , $i = 1, 2, \dots, n$; $j = 1, 2, \dots, p$.

Disposição dos dados em uma análise multivariada

- Vamos denotar por y_{ij} o valor da variável j verificado no indivíduo i , $i = 1, 2, \dots, n$; $j = 1, 2, \dots, p$.
- A disposição usual dos dados é na forma convencional, entrando com os indivíduos nas linhas e as variáveis nas colunas.

	Var 1	Var 2	...	Var j	...	Var p
Ind 1	y_{11}	y_{12}	...	y_{1j}	...	y_{1p}
Ind 2	y_{21}	y_{22}	...	y_{2j}	...	y_{2p}
⋮	⋮	⋮	...	⋮	...	⋮
Ind i	y_{i1}	y_{i2}	...	y_{ij}	...	y_{ip}
⋮	⋮	⋮	...	⋮	...	⋮
Ind n	y_{n1}	y_{n2}	...	y_{nj}	...	y_{np}

Representação matricial dos dados

- A matriz dos dados tem dimensão $n \times p$, apresentando nas linhas os n indivíduos e nas colunas as p variáveis.

$$\mathbf{Y} = \begin{bmatrix} y_{11} & y_{12} & \cdots & y_{1j} & \cdots & y_{1p} \\ y_{21} & y_{22} & \cdots & y_{2j} & \cdots & y_{2p} \\ \vdots & \vdots & \cdots & \vdots & \cdots & \vdots \\ y_{i1} & y_{i2} & \cdots & y_{ij} & \cdots & y_{ip} \\ \vdots & \vdots & \cdots & \vdots & \ddots & \vdots \\ y_{n1} & y_{n2} & \cdots & y_{nj} & \cdots & y_{np} \end{bmatrix}$$

Vetores aleatórios

Vetores aleatórios (ou variáveis aleatórias multidimensionais)

- Um vetor aleatório de dimensão p é um vetor em que cada um de seus p componentes é uma variável aleatória:

$$\mathbf{Y} = (Y_1, Y_2, \dots, Y_p)'$$

.

Vetores aleatórios (ou variáveis aleatórias multidimensionais)

- A título de ilustração, numa avaliação educacional o vetor aleatório poderia ser composto pelas notas de cada estudante em diferentes disciplinas:

$$\mathbf{Y}_i = (\text{Matemática}_i, \text{Português}_i, \dots, \text{Ciências Naturais}_i)', \quad i = 1, 2, \dots, n.$$

Vetores aleatórios (ou variáveis aleatórias multidimensionais)

- A título de ilustração, numa avaliação educacional o vetor aleatório poderia ser composto pelas notas de cada estudante em diferentes disciplinas:

$$\mathbf{Y}_i = (\text{Matemática}_i, \text{Português}_i, \dots, \text{Ciências Naturais}_i)', \quad i = 1, 2, \dots, n.$$

- Num experimento agrícola, o vetor aleatório poderia ser composto por diferentes variáveis de produção avaliadas em cada planta.

$$\mathbf{Y}_i = (\text{Número de galhos}_i, \text{Altura}_i, \dots, \text{Biomassa}_i)', \quad i = 1, 2, \dots, n.$$

Vetores aleatórios

- A função distribuição de probabilidade conjunta de $\mathbf{Y}$ é definida como:

$$F(\mathbf{y}) = P(Y_1 \leq y_1, Y_2 \leq y_2, \dots, Y_p \leq y_p),$$

para $(\mathbf{y} \in R^p)$.

Vetores aleatórios

- Se $\mathbf{Y}$ for contínuo, então a função densidade de probabilidade conjunta de $f(\mathbf{y})$ fica definida por:

$$f(\mathbf{y}) = \frac{\partial F(\mathbf{y})}{\partial y_1 \partial y_2 \dots \partial y_p},$$

Vetores aleatórios

- Se $\mathbf{Y}$ for contínuo, então a função densidade de probabilidade conjunta de $f(\mathbf{y})$ fica definida por:

$$f(\mathbf{y}) = \frac{\partial F(\mathbf{y})}{\partial y_1 \partial y_2 \dots \partial y_p},$$

satisfazendo

$$\int_{-\infty}^{\infty} \dots \int_{-\infty}^{\infty} f(y_1, y_2, \dots, y_p) dy_1 dy_2 \dots dy_p = 1$$

Vetores aleatórios

- Se $\mathbf{Y}$ for contínuo, então a função densidade de probabilidade conjunta de $f(\mathbf{y})$ fica definida por:

$$f(\mathbf{y}) = \frac{\partial F(\mathbf{y})}{\partial y_1 \partial y_2 \dots \partial y_p},$$

satisfazendo

$$\int_{-\infty}^{\infty} \dots \int_{-\infty}^{\infty} f(y_1, y_2, \dots, y_p) dy_1 dy_2 \dots dy_p = 1$$

e

$$f(y_1, y_2, \dots, y_p) \geq 0,$$

para qualquer conjunto de valores $y_1, y_2, \dots, y_p$.

Vetores aleatórios

- Se $\mathbf{Y}$ for discreto, sua distribuição pode ser caracterizada pela função de probabilidades conjunta:

$$f(\mathbf{y}) = f(y_1, y_2, \dots, y_p) = P(Y_1 = y_1, Y_2 = y_2, \dots, Y_p = y_p)$$

Vetores aleatórios




Figura 1: Ilustração de função densidade de probabilidade bivariada (caso contínuo)

Vetores aleatórios




Figura 2: Ilustração de função de probabilidade bivariada (caso discreto)

Vetores aleatórios

- Cada elemento de $\mathbf{Y} = (Y_1, Y_2, \dots, Y_p)'$ é uma variável aleatória $Y_i, i = 1, 2, \dots, p$ com distribuição marginal dada pela função densidade de probabilidade $f(y_i)$:

$$f(y_i) = \int_{y_1} \dots \int_{y_p} f(\mathbf{y}) dy_1 \dots dy_p$$

$j \neq i$ $j \neq i$

Vetores aleatórios

- Cada elemento de $\mathbf{Y} = (Y_1, Y_2, \dots, Y_p)'$ é uma variável aleatória $Y_i, i = 1, 2, \dots, p$ com distribuição marginal dada pela função densidade de probabilidade $f(y_i)$:

$$f(y_i) = \int_{y_1} \dots \int_{y_p} f(\mathbf{y}) dy_1 \dots dy_p$$

$j \neq i$ $j \neq i$

- Se $Y_1, Y_2, \dots, Y_p$ forem independentes, então:

$$f(y_1, y_2, \dots, y_p) = \prod_{i=1}^p f(y_i) = f(y_1)f(y_2)\dots f(y_p).$$

Vetores aleatórios

- A média e a variância de Y_i , ficam definidas como:

Vetores aleatórios

- A média e a variância de Y_i , ficam definidas como:

$$\mu_i = E(Y_i) = \int_{-\infty}^{\infty} y_i f(y_i) dy_i$$

Vetores aleatórios

- A média e a variância de Y_i , ficam definidas como:

$$\mu_i = E(Y_i) = \int_{-\infty}^{\infty} y_i f(y_i) dy_i$$

$$\sigma_i^2 = \text{Var}(Y_i) = E((Y_i - \mu_i)^2) = \int_{-\infty}^{\infty} (y_i - \mu_i)^2 f(y_i) dy_i$$

para $i = 1, 2, \dots, p$.

Vetores aleatórios

- A média e a variância de Y_i , ficam definidas como:

$$\mu_i = E(Y_i) = \int_{-\infty}^{\infty} y_i f(y_i) dy_i$$

$$\sigma_i^2 = \text{Var}(Y_i) = E((Y_i - \mu_i)^2) = \int_{-\infty}^{\infty} (y_i - \mu_i)^2 f(y_i) dy_i$$

para $i = 1, 2, \dots, p$.

- Para duas variáveis aleatórias Y_i e Y_j , a covariância é definida por:

$$\sigma_{ij} = \text{Var}(Y_i, Y_j) = E((Y_i - \mu_i)(Y_j - \mu_j)) = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} (y_i - \mu_i)(y_j - \mu_j) f(y_i, y_j) dy_i dy_j$$

Vetores aleatórios:

- Se Y_i e Y_j forem independentes, então $\text{Cov}(Y_i, Y_j) = 0$.

Vetores aleatórios:

- Se Y_i e Y_j forem independentes, então $\text{Cov}(Y_i, Y_j) = 0$.
- O coeficiente de correlação de Y_i e Y_j é definido como:

$$\rho_{ij} = \frac{\sigma_{ij}}{\sqrt{\sigma_i^2} \sqrt{\sigma_j^2}},$$

sendo uma medida de associação linear adimensional, tal que $-1 \leq \rho \leq 1$.

Vetores aleatórios:

- Se Y_i e Y_j forem independentes, então $\text{Cov}(Y_i, Y_j) = 0$.

- O coeficiente de correlação de Y_i e Y_j é definido como:

$$\rho_{ij} = \frac{\sigma_{ij}}{\sqrt{\sigma_i^2} \sqrt{\sigma_j^2}},$$

sendo uma medida de associação linear adimensional, tal que $-1 \leq \rho \leq 1$.

- Todos os resultados equivalentes para o caso discreto são obtidos substituindo adequadamente as integrais por somatórios.

Vetores aleatórios

- A esperança matemática de um vetor aleatório $\mathbf{Y} = (Y_1, Y_2, \dots, Y_p)'$ é definida pelo vetor de mesma dimensão em que cada elemento corresponde à esperança matemática da respectiva variável.

$$E(\mathbf{Y}) = E \begin{bmatrix} Y_1 \\ Y_2 \\ \vdots \\ Y_p \end{bmatrix} = \begin{bmatrix} E(Y_1) \\ E(Y_2) \\ \vdots \\ E(Y_p) \end{bmatrix} = \begin{bmatrix} \mu_1 \\ \mu_2 \\ \vdots \\ \mu_p \end{bmatrix} = \boldsymbol{\mu}$$

Vetores aleatórios

- A matriz de variâncias e covariâncias de um vetor aleatório $\mathbf{Y} = (Y_1, Y_2, \dots, Y_p)'$ é definida pela matriz $p \times p$ dada por:

$$\text{Var}(\mathbf{Y}) = E(\mathbf{Y} - \boldsymbol{\mu})(\mathbf{Y} - \boldsymbol{\mu})' =$$

$$\begin{bmatrix} E(Y_1 - \mu_1)^2 & \cdots & E(Y_1 - \mu_1)(Y_p - \mu_p) \\ E(Y_1 - \mu_1)(Y_2 - \mu_2) & \cdots & E(Y_2 - \mu_2)(Y_p - \mu_p) \\ \vdots & \ddots & \vdots \\ E(Y_1 - \mu_1)(Y_p - \mu_p) & \cdots & E(Y_p - \mu_p)^2 \end{bmatrix}$$

Vetores aleatórios

- É usual denotar a matriz de covariâncias por:

$$\Sigma = \begin{bmatrix} \sigma_{11} & \sigma_{12} & \cdots & \sigma_{1p} \\ \sigma_{12} & \sigma_{22} & \cdots & \sigma_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ \sigma_{1p} & \sigma_{2p} & \cdots & \sigma_{pp} \end{bmatrix}$$

Vetores aleatórios

- De maneira semelhante, a matriz de correlações do vetor aleatório $\mathbf{Y}$ fica dada por:

$$\rho = \text{Cor}(\mathbf{Y}) = \begin{bmatrix} 1 & \rho_{12} & \cdots & \rho_{1p} \\ \rho_{12} & 1 & \cdots & \rho_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ \rho_{1p} & \rho_{2p} & \cdots & 1 \end{bmatrix}$$

Vetores aleatórios

- De maneira semelhante, a matriz de correlações do vetor aleatório $\mathbf{Y}$ fica dada por:

$$\rho = \text{Cor}(\mathbf{Y}) = \begin{bmatrix} 1 & \rho_{12} & \cdots & \rho_{1p} \\ \rho_{12} & 1 & \cdots & \rho_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ \rho_{1p} & \rho_{2p} & \cdots & 1 \end{bmatrix}$$

- A matriz de correlações pode ser determinada facilmente a partir da matriz de covariâncias por:

$$\rho = (\mathbf{V}^{1/2})^{-1} \mathbf{\Sigma} (\mathbf{V}^{1/2})^{-1},$$

sendo $\mathbf{V}^{1/2}$ a matriz diagonal com elementos $\sqrt{\sigma_{11}}, \sqrt{\sigma_{22}}, \dots, \sqrt{\sigma_{pp}}$.

Propriedades da média e da variância de vetores aleatórios:

Sejam $\mathbf{A}$ e $\mathbf{B}$ matrizes e $\mathbf{c}$ um vetor de constantes (todos com dimensões compatíveis às operações apresentadas). Sejam $\mathbf{X}$ e $\mathbf{Y}$ vetores aleatórios.

Propriedades da média e da variância de vetores aleatórios:

Sejam $\mathbf{A}$ e $\mathbf{B}$ matrizes e $\mathbf{c}$ um vetor de constantes (todos com dimensões compatíveis às operações apresentadas). Sejam $\mathbf{X}$ e $\mathbf{Y}$ vetores aleatórios.

- $E(\mathbf{X} + \mathbf{Y}) = E(\mathbf{X}) + E(\mathbf{Y});$

Propriedades da média e da variância de vetores aleatórios:

Sejam $\mathbf{A}$ e $\mathbf{B}$ matrizes e $\mathbf{c}$ um vetor de constantes (todos com dimensões compatíveis às operações apresentadas). Sejam $\mathbf{X}$ e $\mathbf{Y}$ vetores aleatórios.

- $E(\mathbf{X} + \mathbf{Y}) = E(\mathbf{X}) + E(\mathbf{Y});$
- $E(\mathbf{A}\mathbf{Y}\mathbf{B}) = \mathbf{A}E(\mathbf{Y})\mathbf{B};$

Propriedades da média e da variância de vetores aleatórios:

Sejam $\mathbf{A}$ e $\mathbf{B}$ matrizes e $\mathbf{c}$ um vetor de constantes (todos com dimensões compatíveis às operações apresentadas). Sejam $\mathbf{X}$ e $\mathbf{Y}$ vetores aleatórios.

- $E(\mathbf{X} + \mathbf{Y}) = E(\mathbf{X}) + E(\mathbf{Y})$;
- $E(\mathbf{A}\mathbf{Y}\mathbf{B}) = \mathbf{A}E(\mathbf{Y})\mathbf{B}$;
- $E(\mathbf{A}\mathbf{Y} + \mathbf{c}) = \mathbf{A}E(\mathbf{Y}) + \mathbf{c}$;

Propriedades da média e da variância de vetores aleatórios:

Sejam $\mathbf{A}$ e $\mathbf{B}$ matrizes e $\mathbf{c}$ um vetor de constantes (todos com dimensões compatíveis às operações apresentadas). Sejam $\mathbf{X}$ e $\mathbf{Y}$ vetores aleatórios.

- $E(\mathbf{X} + \mathbf{Y}) = E(\mathbf{X}) + E(\mathbf{Y})$;
- $E(\mathbf{A}\mathbf{Y}\mathbf{B}) = \mathbf{A}E(\mathbf{Y})\mathbf{B}$;
- $E(\mathbf{A}\mathbf{Y} + \mathbf{c}) = \mathbf{A}E(\mathbf{Y}) + \mathbf{c}$;
- $\text{Var}(\mathbf{Y}) = E(\mathbf{Y}\mathbf{Y}') - \mu_{\mathbf{Y}}\mu_{\mathbf{Y}}'$;

Propriedades da média e da variância de vetores aleatórios:

Sejam $\mathbf{A}$ e $\mathbf{B}$ matrizes e $\mathbf{c}$ um vetor de constantes (todos com dimensões compatíveis às operações apresentadas). Sejam $\mathbf{X}$ e $\mathbf{Y}$ vetores aleatórios.

- $E(\mathbf{X} + \mathbf{Y}) = E(\mathbf{X}) + E(\mathbf{Y})$;
- $E(\mathbf{A}\mathbf{Y}\mathbf{B}) = \mathbf{A}E(\mathbf{Y})\mathbf{B}$;
- $E(\mathbf{A}\mathbf{Y} + \mathbf{c}) = \mathbf{A}E(\mathbf{Y}) + \mathbf{c}$;
- $\text{Var}(\mathbf{Y}) = E(\mathbf{Y}\mathbf{Y}') - \mu_{\mathbf{Y}}\mu_{\mathbf{Y}}'$;
- $\text{Var}(\mathbf{c}'\mathbf{Y}) = \mathbf{c}'\text{Var}(\mathbf{Y})\mathbf{c}$;

Propriedades da média e da variância de vetores aleatórios:

Sejam $\mathbf{A}$ e $\mathbf{B}$ matrizes e $\mathbf{c}$ um vetor de constantes (todos com dimensões compatíveis às operações apresentadas). Sejam $\mathbf{X}$ e $\mathbf{Y}$ vetores aleatórios.

- $E(\mathbf{X} + \mathbf{Y}) = E(\mathbf{X}) + E(\mathbf{Y})$;
- $E(\mathbf{A}\mathbf{Y}\mathbf{B}) = \mathbf{A}E(\mathbf{Y})\mathbf{B}$;
- $E(\mathbf{A}\mathbf{Y} + \mathbf{c}) = \mathbf{A}E(\mathbf{Y}) + \mathbf{c}$;
- $\text{Var}(\mathbf{Y}) = E(\mathbf{Y}\mathbf{Y}') - \mu_{\mathbf{Y}}\mu_{\mathbf{Y}}'$;
- $\text{Var}(\mathbf{c}'\mathbf{Y}) = \mathbf{c}'\text{Var}(\mathbf{Y})\mathbf{c}$;
- $\text{Var}(\mathbf{A}'\mathbf{Y} + \mathbf{c}) = \mathbf{A}\text{Var}(\mathbf{Y})\mathbf{A}'$.

Exemplo de ilustração

Exemplo de ilustração

- Considere os vetores aleatórios:

$$\mathbf{X} = \begin{pmatrix} X_1 \\ X_2 \end{pmatrix} \quad \mathbf{Y} = \begin{pmatrix} Y_1 \\ Y_2 \end{pmatrix}$$

Exemplo de ilustração

- Considere os vetores aleatórios:

$$\mathbf{X} = \begin{pmatrix} X_1 \\ X_2 \end{pmatrix} \quad \mathbf{Y} = \begin{pmatrix} Y_1 \\ Y_2 \end{pmatrix}$$

- Suponha que:

$$E(\mathbf{X}) = \begin{pmatrix} 1 \\ 2 \end{pmatrix} \quad E(\mathbf{Y}) = \begin{pmatrix} 3 \\ -1 \end{pmatrix}$$

$$\text{Var}(\mathbf{Y}) = \Sigma = \begin{pmatrix} 2 & 1 \\ 1 & 3 \end{pmatrix}$$

Exemplo de ilustração

- Considere ainda:

$$A = \begin{pmatrix} 1 & 2 \\ 0 & -1 \end{pmatrix} \quad B = \begin{pmatrix} 2 & 0 \\ 1 & 1 \end{pmatrix} \quad c = \begin{pmatrix} 1 \\ -2 \end{pmatrix}$$

Linearidade da esperança

$$E(\mathbf{X} + \mathbf{Y}) = E(\mathbf{X}) + E(\mathbf{Y})$$

Linearidade da esperança

$$E(\mathbf{X} + \mathbf{Y}) = E(\mathbf{X}) + E(\mathbf{Y})$$

$$E(\mathbf{X} + \mathbf{Y}) = \begin{pmatrix} 1 \\ 2 \end{pmatrix} + \begin{pmatrix} 3 \\ -1 \end{pmatrix} = \begin{pmatrix} 4 \\ 1 \end{pmatrix}$$

Esperança de transformação linear

$$E(A\mathbf{Y} + c) = AE(\mathbf{Y}) + c.$$

Esperança de transformação linear

$$E(A\mathbf{Y} + c) = AE(\mathbf{Y}) + c.$$

- Primeiro, calculamos:

$$AE(\mathbf{Y}) = \begin{pmatrix} 1 & 2 \\ 0 & -1 \end{pmatrix} \begin{pmatrix} 3 \\ -1 \end{pmatrix} = \begin{pmatrix} 1 \\ 1 \end{pmatrix}$$

Esperança de transformação linear

$$E(A\mathbf{Y} + c) = AE(\mathbf{Y}) + c.$$

- Primeiro, calculamos:

$$AE(\mathbf{Y}) = \begin{pmatrix} 1 & 2 \\ 0 & -1 \end{pmatrix} \begin{pmatrix} 3 \\ -1 \end{pmatrix} = \begin{pmatrix} 1 \\ 1 \end{pmatrix}$$

- Somando o vetor constante:

$$E(A\mathbf{Y} + c) = \begin{pmatrix} 1 \\ 1 \end{pmatrix} + \begin{pmatrix} 1 \\ -2 \end{pmatrix} = \begin{pmatrix} 2 \\ -1 \end{pmatrix}$$

Identidade da covariância

$$\text{Var}(\mathbf{Y}) = \text{E}(\mathbf{Y}\mathbf{Y}') - \mu\mu', \quad \mu = \text{E}(\mathbf{Y})$$

Identidade da covariância

$$\text{Var}(\mathbf{Y}) = \text{E}(\mathbf{Y}\mathbf{Y}') - \mu\mu', \quad \mu = \text{E}(\mathbf{Y})$$

- Temos:

$$\mu = \begin{pmatrix} 3 \\ -1 \end{pmatrix}$$

Identidade da covariância

$$\text{Var}(\mathbf{Y}) = \text{E}(\mathbf{Y}\mathbf{Y}') - \mu\mu', \quad \mu = \text{E}(\mathbf{Y})$$

- Temos:

$$\mu = \begin{pmatrix} 3 \\ -1 \end{pmatrix}$$

- Logo,

$$\mu\mu' = \begin{pmatrix} 3 \\ -1 \end{pmatrix} (3, -1) = \begin{pmatrix} 9 & -3 \\ -3 & 1 \end{pmatrix}$$

Identidade da covariância

- Portanto,

$$E(\mathbf{Y}\mathbf{Y}') = \Sigma + \mu\mu' = \begin{pmatrix} 2 & 1 \\ 1 & 3 \end{pmatrix} + \begin{pmatrix} 9 & -3 \\ -3 & 1 \end{pmatrix} = \begin{pmatrix} 11 & -2 \\ -2 & 4 \end{pmatrix}$$

Variância de combinação linear

- Para

$$\mathbf{Z} = \mathbf{c}'\mathbf{Y}$$

vale:

$$\text{Var}(\mathbf{Z}) = \mathbf{c}'\Sigma\mathbf{c}$$

Variância de combinação linear

- Para

$$\mathbf{Z} = \mathbf{c}'\mathbf{Y}$$

vale:

$$\text{Var}(\mathbf{Z}) = \mathbf{c}'\Sigma\mathbf{c}$$

- Primeiro:

$$\Sigma\mathbf{c} = \begin{pmatrix} 2 & 1 \\ 1 & 3 \end{pmatrix} \begin{pmatrix} 1 \\ -2 \end{pmatrix} = \begin{pmatrix} 0 \\ -5 \end{pmatrix}$$

Variância de combinação linear

$$c' \Sigma c = (1, -2) \begin{pmatrix} 0 \\ -5 \end{pmatrix} = 10$$

Logo,

$$\text{Var}(c' \mathbf{Y}) = 10$$

Covariância após transformação linear

- Para

$$\mathbf{W} = \mathbf{A}\mathbf{Y} + \mathbf{c}$$

vale:

$$\text{Var}(\mathbf{W}) = \mathbf{A}\Sigma\mathbf{A}'$$

Covariância após transformação linear

- Para

$$\mathbf{W} = \mathbf{A}\mathbf{Y} + \mathbf{c}$$

vale:

$$\text{Var}(\mathbf{W}) = \mathbf{A}\Sigma\mathbf{A}'$$

- Calculamos:

$$\mathbf{A}\Sigma = \begin{pmatrix} 1 & 2 \\ 0 & -1 \end{pmatrix} \begin{pmatrix} 2 & 1 \\ 1 & 3 \end{pmatrix} = \begin{pmatrix} 4 & 7 \\ -1 & -3 \end{pmatrix}$$

Covariância após transformação linear

- A transposta de A é:

$$A' = \begin{pmatrix} 1 & 0 \\ 2 & -1 \end{pmatrix}$$

Covariância após transformação linear

- A transposta de A é:

$$A' = \begin{pmatrix} 1 & 0 \\ 2 & -1 \end{pmatrix}$$

- Logo:

$$A\Sigma A' = \begin{pmatrix} 4 & 7 \\ -1 & -3 \end{pmatrix} \begin{pmatrix} 1 & 0 \\ 2 & -1 \end{pmatrix} = \begin{pmatrix} 18 & -7 \\ -7 & 3 \end{pmatrix}$$

Covariância após transformação linear

- A transposta de A é:

$$A' = \begin{pmatrix} 1 & 0 \\ 2 & -1 \end{pmatrix}$$

- Logo:

$$A\Sigma A' = \begin{pmatrix} 4 & 7 \\ -1 & -3 \end{pmatrix} \begin{pmatrix} 1 & 0 \\ 2 & -1 \end{pmatrix} = \begin{pmatrix} 18 & -7 \\ -7 & 3 \end{pmatrix}$$

- Portanto,

$$\text{Var}(A\mathbf{Y} + c) = \begin{pmatrix} 18 & -7 \\ -7 & 3 \end{pmatrix}$$

Combinação linear com duas matrizes

- Para

$$\mathbf{U} = \mathbf{A}\mathbf{X} + \mathbf{B}\mathbf{Y} + c$$

vale:

$$E(\mathbf{U}) = \mathbf{A}E(\mathbf{X}) + \mathbf{B}E(\mathbf{Y}) + c$$

Combinação linear com duas matrizes

- Para

$$\mathbf{U} = \mathbf{A}\mathbf{X} + \mathbf{B}\mathbf{Y} + c$$

vale:

$$E(\mathbf{U}) = \mathbf{A}E(\mathbf{X}) + \mathbf{B}E(\mathbf{Y}) + c$$

- Calculamos:

$$\mathbf{A}E(\mathbf{X}) = \begin{pmatrix} 1 & 2 \\ 0 & -1 \end{pmatrix} \begin{pmatrix} 1 \\ 2 \end{pmatrix} = \begin{pmatrix} 5 \\ -2 \end{pmatrix}$$

Combinação linear com duas matrizes

$$B E(\mathbf{Y}) = \begin{pmatrix} 2 & 0 \\ 1 & 1 \end{pmatrix} \begin{pmatrix} 3 \\ -1 \end{pmatrix} = \begin{pmatrix} 6 \\ 2 \end{pmatrix}$$

Combinação linear com duas matrizes

$$B E(\mathbf{Y}) = \begin{pmatrix} 2 & 0 \\ 1 & 1 \end{pmatrix} \begin{pmatrix} 3 \\ -1 \end{pmatrix} = \begin{pmatrix} 6 \\ 2 \end{pmatrix}$$

- Somando todos os termos:

$$E(\mathbf{U}) = \begin{pmatrix} 5 \\ -2 \end{pmatrix} + \begin{pmatrix} 6 \\ 2 \end{pmatrix} + \begin{pmatrix} 1 \\ -2 \end{pmatrix} = \begin{pmatrix} 12 \\ -2 \end{pmatrix}$$

Distribuição Normal multivariada

Distribuição Normal multivariada

- A distribuição normal multivariada é uma generalização da distribuição normal univariada, para o caso p -dimensional.

Distribuição Normal multivariada

- A distribuição normal multivariada é uma generalização da distribuição normal univariada, para o caso p -dimensional.
- Diversas técnicas multivariadas baseiam-se na distribuição normal multivariada e em suas propriedades.

Distribuição Normal multivariada

- A distribuição normal multivariada é uma generalização da distribuição normal univariada, para o caso p -dimensional.
- Diversas técnicas multivariadas baseiam-se na distribuição normal multivariada e em suas propriedades.
- Configura um modelo probabilístico adequado em diferentes problemas.

Distribuição Normal multivariada

- Caso univariado: Uma variável aleatória Y tem distribuição normal univariada com média μ e variância σ^2 , o que denotamos por $Y \sim \text{Normal}(\mu, \sigma^2)$, se sua função densidade de probabilidade é dada por:

$$f(y) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left\{ -\frac{1}{2} \left[\frac{y-\mu}{\sigma} \right]^2 \right\}, -\infty < y < \infty$$

Distribuição Normal multivariada

- Caso univariado: Uma variável aleatória Y tem distribuição normal univariada com média μ e variância σ^2 , o que denotamos por $Y \sim \text{Normal}(\mu, \sigma^2)$, se sua função densidade de probabilidade é dada por:

$$f(y) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left\{ -\frac{1}{2} \left[\frac{y-\mu}{\sigma} \right]^2 \right\}, -\infty < y < \infty$$

- Observe o termo presente no expoente, que pode ser escrito como:

$$\left(\frac{y-\mu}{\sigma} \right)^2 = (y - \mu)(\sigma^2)^{-1}(y - \mu)$$

Distribuição Normal multivariada

- Considere agora $\mathbf{Y}$ um vetor aleatório p -dimensional, com vetor de médias $\boldsymbol{\mu}$ e matriz de covariâncias $\boldsymbol{\Sigma}$.

Distribuição Normal multivariada

- Considere agora $\mathbf{Y}$ um vetor aleatório p -dimensional, com vetor de médias $\boldsymbol{\mu}$ e matriz de covariâncias $\boldsymbol{\Sigma}$.
- Assumindo que $\boldsymbol{\Sigma}$ é uma matriz $p \times p$ positiva definida, a seguinte expressão define o quadrado da distância generalizada (ou distância de Mahalanobis) entre $\mathbf{y}$ e $\boldsymbol{\mu}$:

$$(\mathbf{y} - \boldsymbol{\mu})' \boldsymbol{\Sigma}^{-1} (\mathbf{y} - \boldsymbol{\mu})$$

Distribuição Normal multivariada

- Considere agora $\mathbf{Y}$ um vetor aleatório p -dimensional, com vetor de médias $\boldsymbol{\mu}$ e matriz de covariâncias $\boldsymbol{\Sigma}$.
- Assumindo que $\boldsymbol{\Sigma}$ é uma matriz $p \times p$ positiva definida, a seguinte expressão define o quadrado da distância generalizada (ou distância de Mahalanobis) entre $\mathbf{y}$ e $\boldsymbol{\mu}$:

$$(\mathbf{y} - \boldsymbol{\mu})' \boldsymbol{\Sigma}^{-1} (\mathbf{y} - \boldsymbol{\mu})$$

- A distância de Mahalanobis mede quão longe $\mathbf{y}$ está da média, levando em conta as covariâncias.

Distribuição Normal multivariada

- A distribuição normal multivariada é obtida substituindo o expoente original pela distância generalizada, para o caso p-dimensional, e usando como constante de normalização $(2\pi)^{p/2} |\mathbf{\Sigma}|^{-1/2}$.

Distribuição Normal multivariada

- A distribuição normal multivariada é obtida substituindo o expoente original pela distância generalizada, para o caso p-dimensional, e usando como constante de normalização $(2\pi)^{p/2}|\mathbf{\Sigma}|^{-1/2}$.
- Um vetor aleatório p-dimensional $\mathbf{Y}' = (Y_1, Y_2, \dots, Y_p)$ tem distribuição normal p-variada, com vetor de médias $\boldsymbol{\mu}$ e matriz de covariâncias $\mathbf{\Sigma}$ se a função densidade de probabilidade conjunta for dada por:

$$f(\mathbf{y}) = \frac{1}{(2\pi)^{p/2}|\mathbf{\Sigma}|^{1/2}} e^{-(\mathbf{y}-\boldsymbol{\mu})'\mathbf{\Sigma}^{-1}(\mathbf{y}-\boldsymbol{\mu})/2},$$

para $-\infty < y_i < \infty, i = 1, 2, \dots, p$.

Distribuição Normal multivariada

- A distribuição normal multivariada é obtida substituindo o expoente original pela distância generalizada, para o caso p-dimensional, e usando como constante de normalização $(2\pi)^{p/2}|\mathbf{\Sigma}|^{-1/2}$.
- Um vetor aleatório p-dimensional $\mathbf{Y}' = (Y_1, Y_2, \dots, Y_p)$ tem distribuição normal p-variada, com vetor de médias $\boldsymbol{\mu}$ e matriz de covariâncias $\mathbf{\Sigma}$ se a função densidade de probabilidade conjunta for dada por:

$$f(\mathbf{y}) = \frac{1}{(2\pi)^{p/2}|\mathbf{\Sigma}|^{1/2}} e^{-(\mathbf{y}-\boldsymbol{\mu})'\mathbf{\Sigma}^{-1}(\mathbf{y}-\boldsymbol{\mu})/2},$$

para $-\infty < y_i < \infty, i = 1, 2, \dots, p$.

- Vamos denotar a normalidade multivariada na forma $\mathbf{Y} \sim \text{Normal}_p(\boldsymbol{\mu}, \mathbf{\Sigma})$.

Distribuição Normal bivariada

- Como caso particular da distribuição normal multivariada temos a normal bivariada ($p=2$).

Distribuição Normal bivariada

- Como caso particular da distribuição normal multivariada temos a normal bivariada ($p=2$).
- Seja (Y_1, Y_2) um vetor aleatório com distribuição normal de média $\boldsymbol{\mu} = (\mu_1, \mu_2)$ e matriz de covariâncias:

$$\boldsymbol{\Sigma} = \begin{bmatrix} \sigma_{11} & \sigma_{12} \\ \sigma_{21} & \sigma_{22} \end{bmatrix}.$$

Distribuição Normal bivariada

- Como caso particular da distribuição normal multivariada temos a normal bivariada ($p=2$).
- Seja (Y_1, Y_2) um vetor aleatório com distribuição normal de média $\boldsymbol{\mu} = (\mu_1, \mu_2)$ e matriz de covariâncias:

$$\boldsymbol{\Sigma} = \begin{bmatrix} \sigma_{11} & \sigma_{12} \\ \sigma_{21} & \sigma_{22} \end{bmatrix}.$$

- A função densidade de probabilidade de (Y_1, Y_2) fica dada por:

$$f(y_1, y_2) = \frac{1}{2\pi\sqrt{\sigma_{11}\sigma_{22}(1-\rho_{12}^2)}} \times \exp \left\{ -\frac{1}{2(1-\rho_{12}^2)} \left[\left(\frac{y_1-\mu_1}{\sqrt{\sigma_{11}}} \right)^2 + \left(\frac{y_2-\mu_2}{\sqrt{\sigma_{22}}} \right)^2 - 2\rho_{12} \left(\frac{y_1-\mu_1}{\sqrt{\sigma_{11}}} \right) \left(\frac{y_2-\mu_2}{\sqrt{\sigma_{22}}} \right) \right] \right\}$$

Distribuição Normal bivariada




Figura 3: Distribuição normal bivariada para diferentes correlações

Distribuição Normal bivariada




Figura 4: Curvas de nível da distribuição normal bivariada para diferentes correlações

Distribuição Normal multivariada

- Se $Y_1, Y_2, \dots, Y_p$ forem independentes, então $f(\mathbf{y}) = f(y_1)f(y_2)\dots f(y_p)$, tal que $Y_i \sim \text{Normal}(\mu_i, \sigma_i^2)$.

Distribuição Normal multivariada

- Se $Y_1, Y_2, \dots, Y_p$ forem independentes, então $f(\mathbf{y}) = f(y_1)f(y_2)\dots f(y_p)$, tal que $Y_i \sim \text{Normal}(\mu_i, \sigma_i^2)$.
- Contornos da normal multivariada - para um valor c fixado, são elipsoides que compreendem todo $\mathbf{y} \in R_p$ tal que $(\mathbf{y} - \boldsymbol{\mu})' \boldsymbol{\Sigma}^{-1} (\mathbf{y} - \boldsymbol{\mu}) = c^2$.

Distribuição Normal multivariada

- Se $Y_1, Y_2, \dots, Y_p$ forem independentes, então $f(\mathbf{y}) = f(y_1)f(y_2)\dots f(y_p)$, tal que $Y_i \sim \text{Normal}(\mu_i, \sigma_i^2)$.
- Contornos da normal multivariada - para um valor c fixado, são elipsoides que compreendem todo $\mathbf{y} \in R_p$ tal que $(\mathbf{y} - \boldsymbol{\mu})' \boldsymbol{\Sigma}^{-1} (\mathbf{y} - \boldsymbol{\mu}) = c^2$.
- Os elipsoides (contornos) gerados tem centro em $\boldsymbol{\mu}$ e a direção dada pelos autovetores de $\boldsymbol{\Sigma}$, com eixos $\pm c \sqrt{\lambda_i} \mathbf{e}_i$.

Distribuição Normal multivariada

- Se $Y_1, Y_2, \dots, Y_p$ forem independentes, então $f(\mathbf{y}) = f(y_1)f(y_2)\dots f(y_p)$, tal que $Y_i \sim \text{Normal}(\mu_i, \sigma_i^2)$.
- Contornos da normal multivariada - para um valor c fixado, são elipsoides que compreendem todo $\mathbf{y} \in R_p$ tal que $(\mathbf{y} - \boldsymbol{\mu})' \boldsymbol{\Sigma}^{-1} (\mathbf{y} - \boldsymbol{\mu}) = c^2$.
- Os elipsoides (contornos) gerados tem centro em $\boldsymbol{\mu}$ e a direção dada pelos autovetores de $\boldsymbol{\Sigma}$, com eixos $\pm c \sqrt{\lambda_i} \mathbf{e}_i$.
- O elipsoide sólido de $\mathbf{y}$ satisfazendo:

$$(\mathbf{y} - \boldsymbol{\mu})' \boldsymbol{\Sigma}^{-1} (\mathbf{y} - \boldsymbol{\mu}) \leq \chi_p^2(\alpha),$$

onde $\chi_p^2(\alpha)$ é o quantil $1 - \alpha$ de uma distribuição χ_p^2 , delimita $1 - \alpha$ de probabilidade.

Propriedades da distribuição normal multivariada

- Seja $\mathbf{Y} \sim N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$. Valem as propriedades:

Propriedades da distribuição normal multivariada

- Seja $\mathbf{Y} \sim N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$. Valem as propriedades:
- ① Qualquer combinação linear das variáveis que compõem $\mathbf{Y}$ tem distribuição normal univariada.

Propriedades da distribuição normal multivariada

- Seja $\mathbf{Y} \sim N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$. Valem as propriedades:
- ① Qualquer combinação linear das variáveis que compõem $\mathbf{Y}$ tem distribuição normal univariada.
- Mais especificamente, se $\mathbf{a}' = (a_1, a_2, \dots, a_p)$ é um vetor de constantes, então

$$\mathbf{a}'\mathbf{Y} = a_1 Y_1 + a_2 Y_2 + \dots + a_p Y_p \sim N(\mathbf{a}'\boldsymbol{\mu}, \mathbf{a}'\boldsymbol{\Sigma}\mathbf{a}),$$

Propriedades da distribuição normal multivariada

- ② Se $\mathbf{A}$ é uma matriz $q \times p$ de constantes, então $\mathbf{A}\mathbf{Y}$ tem distribuição normal multivariada.

Propriedades da distribuição normal multivariada

- ② Se $\mathbf{A}$ é uma matriz $q \times p$ de constantes, então $\mathbf{AY}$ tem distribuição normal multivariada.
- Mais especificamente, considerando:

$$\mathbf{A} = \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1p} \\ a_{21} & a_{22} & \cdots & a_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ a_{q1} & a_{q2} & \cdots & a_{qp} \end{bmatrix},$$

então $\mathbf{AY} \sim N_q(\mathbf{A}\boldsymbol{\mu}, \mathbf{A}\boldsymbol{\Sigma}\mathbf{A}')$.

Propriedades da distribuição normal multivariada

- 3 As partições de $\mathbf{Y}$ são normalmente distribuídas com respectivos vetores de médias e matrizes de covariâncias.

Propriedades da distribuição normal multivariada

- 3 As partições de $\mathbf{Y}$ são normalmente distribuídas com respectivos vetores de médias e matrizes de covariâncias.

$$\mathbf{Y} = \begin{pmatrix} \mathbf{Y}_1 \\ \mathbf{Y}_2 \end{pmatrix} \quad \boldsymbol{\mu} = \begin{pmatrix} \boldsymbol{\mu}_1 \\ \boldsymbol{\mu}_2 \end{pmatrix} \quad \boldsymbol{\Sigma} = \begin{pmatrix} \boldsymbol{\Sigma}_{11} & \boldsymbol{\Sigma}_{12} \\ \boldsymbol{\Sigma}_{21} & \boldsymbol{\Sigma}_{22} \end{pmatrix}$$

então $\mathbf{Y}_1 \sim N_q(\boldsymbol{\mu}_1, \boldsymbol{\Sigma}_{11})$ e $\mathbf{Y}_2 \sim N_{p-q}(\boldsymbol{\mu}_2, \boldsymbol{\Sigma}_{22})$.

Propriedades da distribuição normal multivariada

- Como caso particular da propriedade anterior, se $\mathbf{Y} \sim N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$, então $Y_i \sim N(\mu_i, \sigma_{ii}), i = 1, 2, \dots, p$, ou seja, a normalidade multivariada implica em marginais com distribuição normal univariada.

Propriedades da distribuição normal multivariada




Figura 5: Distribuição conjunta e densidades marginais

Propriedades da distribuição normal multivariada

- ④ Equivalência de covariância zero e independência para variáveis com distribuição normal.

Propriedades da distribuição normal multivariada

- ④ Equivalência de covariância zero e independência para variáveis com distribuição normal.
- Se $\mathbf{Y}_1$ e $\mathbf{Y}_2$ são vetores aleatórios com distribuição normal e $\text{Cov}(\mathbf{Y}_1, \mathbf{Y}_2) = \mathbf{\Sigma}_{12} = \mathbf{0}$, então $\mathbf{Y}_1$ e $\mathbf{Y}_2$ são independentes.

Propriedades da distribuição normal multivariada

- ④ Equivalência de covariância zero e independência para variáveis com distribuição normal.
- Se $\mathbf{Y}_1$ e $\mathbf{Y}_2$ são vetores aleatórios com distribuição normal e $\text{Cov}(\mathbf{Y}_1, \mathbf{Y}_2) = \mathbf{\Sigma}_{12} = \mathbf{0}$, então $\mathbf{Y}_1$ e $\mathbf{Y}_2$ são independentes.
- No caso bivariado, Y_1 e Y_2 são independentes se $\text{Cov}(Y_1, Y_2) = \sigma_{12} = 0$.

Propriedades da distribuição normal multivariada

- ④ Equivalência de covariância zero e independência para variáveis com distribuição normal.
- Se $\mathbf{Y}_1$ e $\mathbf{Y}_2$ são vetores aleatórios com distribuição normal e $\text{Cov}(\mathbf{Y}_1, \mathbf{Y}_2) = \mathbf{\Sigma}_{12} = \mathbf{0}$, então $\mathbf{Y}_1$ e $\mathbf{Y}_2$ são independentes.
- No caso bivariado, Y_1 e Y_2 são independentes se $\text{Cov}(Y_1, Y_2) = \sigma_{12} = 0$.
- Importante destacar que a condição de independência apresentada *não vale* para variáveis sem distribuição normal.

Propriedades da distribuição normal multivariada

5 Se $\mathbf{Y} \sim N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$, então:

Propriedades da distribuição normal multivariada

5 Se $\mathbf{Y} \sim N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$, então:

- $(\mathbf{y} - \boldsymbol{\mu})' \boldsymbol{\Sigma}^{-1} (\mathbf{y} - \boldsymbol{\mu})$ tem distribuição qui-quadrado com p graus de liberdade χ_p^2 ;

Propriedades da distribuição normal multivariada

5 Se $\mathbf{Y} \sim N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$, então:

- $(\mathbf{y} - \boldsymbol{\mu})' \boldsymbol{\Sigma}^{-1} (\mathbf{y} - \boldsymbol{\mu})$ tem distribuição qui-quadrado com p graus de liberdade χ_p^2 ;

- O elipsoide sólido de $\mathbf{y}$ definido por:

$$\mathbf{y} : (\mathbf{y} - \boldsymbol{\mu})' \boldsymbol{\Sigma} (\mathbf{y} - \boldsymbol{\mu}) \leq \chi_p^2(\alpha),$$

onde $\chi_p^2(\alpha)$ é o quantil superior α , delimita $100 \times (1 - \alpha)\%$ de probabilidade.

Propriedades da distribuição normal multivariada

6 Considere a partição $\mathbf{Y} = (\mathbf{Y}_1 \ \mathbf{Y}_2)'$, tal que:

$$\boldsymbol{\mu} = \begin{pmatrix} \mu_1 \\ \mu_2 \end{pmatrix} \quad \boldsymbol{\Sigma} = \begin{pmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{pmatrix}$$

Propriedades da distribuição normal multivariada

- 6 Considere a partição $\mathbf{Y} = (\mathbf{Y}_1 \ \mathbf{Y}_2)'$, tal que:

$$\boldsymbol{\mu} = \begin{pmatrix} \mu_1 \\ \mu_2 \end{pmatrix} \quad \boldsymbol{\Sigma} = \begin{pmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{pmatrix}$$

- Neste caso, a distribuição condicional de $\mathbf{Y}_1 | \mathbf{Y}_2 = \mathbf{y}_2$ é normal multivariada, bem como a distribuição de $\mathbf{Y}_2 | \mathbf{Y}_1 = \mathbf{y}_1$.

Propriedades da distribuição normal multivariada

- A distribuição condicional de $\mathbf{Y}_1 | \mathbf{Y}_2 = \mathbf{y}_2$ é normal multivariada com:

Propriedades da distribuição normal multivariada

- A distribuição condicional de $\mathbf{Y}_1 | \mathbf{Y}_2 = \mathbf{y}_2$ é normal multivariada com:

$$\mu_{\mathbf{Y}_1 | \mathbf{Y}_2} = \mu_1 + \Sigma_{12} \Sigma_{22}^{-1} (\mathbf{y}_2 - \mu_2)$$

Propriedades da distribuição normal multivariada

- A distribuição condicional de $\mathbf{Y}_1 | \mathbf{Y}_2 = \mathbf{y}_2$ é normal multivariada com:

$$\mu_{\mathbf{Y}_1 | \mathbf{Y}_2} = \mu_1 + \Sigma_{12} \Sigma_{22}^{-1} (\mathbf{y}_2 - \mu_2)$$

$$\Sigma_{\mathbf{Y}_1 | \mathbf{Y}_2} = \Sigma_{11} - \Sigma_{12} \Sigma_{22}^{-1} \Sigma_{21}$$

Propriedades da distribuição normal multivariada

- Em particular, para o caso bivariado $Y = (Y_1 \ Y_2)'$ temos que $Y_1|Y_2 = y_2$ tem distribuição normal univariada com média e variância dadas por:

Propriedades da distribuição normal multivariada

- Em particular, para o caso bivariado $Y = (Y_1 \ Y_2)'$ temos que $Y_1|Y_2 = y_2$ tem distribuição normal univariada com média e variância dadas por:

$$\mu_{Y_1|Y_2} = \mu_1 + \frac{\sigma_{12}}{\sigma_{22}}(y_2 - \mu_2)$$

Propriedades da distribuição normal multivariada

- Em particular, para o caso bivariado $Y = (Y_1 \ Y_2)'$ temos que $Y_1|Y_2 = y_2$ tem distribuição normal univariada com média e variância dadas por:

$$\mu_{Y_1|Y_2} = \mu_1 + \frac{\sigma_{12}}{\sigma_{22}}(y_2 - \mu_2)$$

$$\sigma_{Y_1|Y_2}^2 = \sigma_{11} - \frac{\sigma_{12}^2}{\sigma_{22}}$$

Exemplos de ilustração

Exemplo de ilustração

- Seja $\mathbf{Y} = (Y_1, Y_2)'$ um vetor aleatório com distribuição:

$$\mathbf{Y} \sim \text{Normal} \left(\mu = \begin{bmatrix} 0 \\ 0 \end{bmatrix}, \Sigma = \begin{bmatrix} 2 & 1 \\ 1 & 3 \end{bmatrix} \right)$$

Exemplo de ilustração

- Considere:

$$\left(c = \begin{bmatrix} 1 \\ -2 \end{bmatrix}, A = \begin{bmatrix} 1 & 0 \\ 2 & -1 \end{bmatrix} \right)$$

Exemplo de ilustração

- Considere:

$$\left(c = \begin{bmatrix} 1 \\ -2 \end{bmatrix}, A = \begin{bmatrix} 1 & 0 \\ 2 & -1 \end{bmatrix} \right)$$

- Qual a distribuição de $W = AY + c$?

Exemplo de ilustração

- Inicialmente:

$$E(W) = E(AY + c) = AE(Y) + c =$$

$$\begin{bmatrix} 1 & 0 \\ 2 & -1 \end{bmatrix} \times \begin{bmatrix} 0 \\ 0 \end{bmatrix} + \begin{bmatrix} 1 \\ -2 \end{bmatrix} = \begin{bmatrix} 1 \\ -2 \end{bmatrix}$$

Exemplo de ilustração

- Adicionalmente:

$$\text{Var}(W) = \text{Var}(AY + c) = A\text{Var}(Y)A' =$$

$$\begin{bmatrix} 1 & 2 \\ 0 & -1 \end{bmatrix} \times \begin{bmatrix} 2 & 1 \\ 1 & 3 \end{bmatrix} \times \begin{bmatrix} 1 & 0 \\ 2 & -1 \end{bmatrix} = \begin{bmatrix} 18 & -7 \\ -7 & 3 \end{bmatrix}$$

Exemplo de ilustração

- Adicionalmente:

$$\text{Var}(W) = \text{Var}(AY + c) = A\text{Var}(Y)A' =$$

$$\begin{bmatrix} 1 & 2 \\ 0 & -1 \end{bmatrix} \times \begin{bmatrix} 2 & 1 \\ 1 & 3 \end{bmatrix} \times \begin{bmatrix} 1 & 0 \\ 2 & -1 \end{bmatrix} = \begin{bmatrix} 18 & -7 \\ -7 & 3 \end{bmatrix}$$

- Logo,

$$W \sim \text{Normal} \left(\mu = \begin{bmatrix} 1 \\ -2 \end{bmatrix}, \Sigma = \begin{bmatrix} 18 & -7 \\ -7 & 3 \end{bmatrix} \right)$$

Exemplo de ilustração




Figura 6: Ilustração- transformação linear

Exemplo de ilustração

- Seja $\mathbf{Y} = (Y_1, Y_2, Y_3)'$ um vetor aleatório com distribuição:

$$\mathbf{Y} \sim \text{Normal} \left(\mu = \begin{bmatrix} 5 \\ 2 \\ 1 \end{bmatrix}, \Sigma = \begin{bmatrix} 1 & 0.8 & 1.5 \\ 0.8 & 2 & -0.2 \\ 1.5 & -0.2 & 4 \end{bmatrix} \right)$$

Exemplo de ilustração

- Com base no apresentado, identifique:

Exemplo de ilustração

- Com base no apresentado, identifique:
- a) As distribuições marginais de Y_1 e Y_3 .

Exemplo de ilustração

- Com base no apresentado, identifique:
 - a) As distribuições marginais de Y_1 e Y_3 .

$$Y_1 \sim \text{Normal}(\mu = 5, \sigma^2 = 1) \text{ e } Y_3 \sim \text{Normal}(\mu = 1, \sigma^2 = 4)$$

Exemplo de ilustração

- Com base no apresentado, identifique:

a) As distribuições marginais de Y_1 e Y_3 .

$$Y_1 \sim \text{Normal}(\mu = 5, \sigma^2 = 1) \text{ e } Y_3 \sim \text{Normal}(\mu = 1, \sigma^2 = 4)$$

b) A distribuição conjunta de Y_1 e Y_2 .

Exemplo de ilustração

- Com base no apresentado, identifique:

a) As distribuições marginais de Y_1 e Y_3 .

$$Y_1 \sim \text{Normal}(\mu = 5, \sigma^2 = 1) \text{ e } Y_3 \sim \text{Normal}(\mu = 1, \sigma^2 = 4)$$

b) A distribuição conjunta de Y_1 e Y_2 .

$$\begin{bmatrix} Y_1 \\ Y_2 \end{bmatrix} \sim \text{Normal} \left(\mu = \begin{bmatrix} 5 \\ 2 \end{bmatrix}, \Sigma = \begin{bmatrix} 1 & 0.8 \\ 0.8 & 2 \end{bmatrix} \right)$$

Exemplo de ilustração

- e) O elipsóide sólido baseado na distribuição de $\mathbf{Y} = (Y_1, Y_2, Y_3)'$ que delimita 95% de probabilidade em torno da média.

Exemplo de ilustração

- e) O elipsóide sólido baseado na distribuição de $\mathbf{Y} = (Y_1, Y_2, Y_3)'$ que delimita 95% de probabilidade em torno da média.

$$\mathbf{y} : (\mathbf{y} - \boldsymbol{\mu})' \boldsymbol{\Sigma}^{-1} (\mathbf{y} - \boldsymbol{\mu}) \leq \chi_p^2(\alpha).$$

Exemplo de ilustração

- e) O elipsóide sólido baseado na distribuição de $\mathbf{Y} = (Y_1, Y_2, Y_3)'$ que delimita 95% de probabilidade em torno da média.

$$\mathbf{y} : (\mathbf{y} - \boldsymbol{\mu})' \boldsymbol{\Sigma}^{-1} (\mathbf{y} - \boldsymbol{\mu}) \leq \chi_p^2(\alpha).$$

$$\boldsymbol{\Sigma}^{-1} = \begin{bmatrix} 1 & 0.8 & 1.5 \\ 0.8 & 2 & -0.2 \\ 1.5 & -0.2 & 4 \end{bmatrix}^{-1} = \begin{bmatrix} 18.95 & -8.33 & -7.53 \\ -8.33 & 4.17 & 3.33 \\ -7.53 & 3.33 & 3.24 \end{bmatrix}$$

Exemplo de ilustração

- e) O elipsóide sólido baseado na distribuição de $\mathbf{Y} = (Y_1, Y_2, Y_3)'$ que delimita 95% de probabilidade em torno da média.

$$\mathbf{y} : (\mathbf{y} - \boldsymbol{\mu})' \boldsymbol{\Sigma}^{-1} (\mathbf{y} - \boldsymbol{\mu}) \leq \chi_p^2(\alpha).$$

$$\boldsymbol{\Sigma}^{-1} = \begin{bmatrix} 1 & 0.8 & 1.5 \\ 0.8 & 2 & -0.2 \\ 1.5 & -0.2 & 4 \end{bmatrix}^{-1} = \begin{bmatrix} 18.95 & -8.33 & -7.53 \\ -8.33 & 4.17 & 3.33 \\ -7.53 & 3.33 & 3.24 \end{bmatrix}$$

$$\chi_3^2(0.95) = 7.814$$

Exemplo de ilustração

- Logo, o elipsóide de 95% de probabilidade é composto por todo $\mathbf{y}$ tal que:

$$\begin{bmatrix} y_1 - 5 \\ y_2 - 2 \\ y_3 - 1 \end{bmatrix}' \times \begin{bmatrix} 18.95 & -8.33 & -7.53 \\ -8.33 & 4.17 & 3.33 \\ -7.53 & 3.33 & 3.24 \end{bmatrix} \times \begin{bmatrix} y_1 - 5 \\ y_2 - 2 \\ y_3 - 1 \end{bmatrix} \leq 7.814$$

Exemplo de ilustração

- d) Verifique se os seguintes pontos pertencem ao elipsóide sólido que delimita 95% de probabilidade em torno da média.

Exemplo de ilustração

- d) Verifique se os seguintes pontos pertencem ao elipsóide sólido que delimita 95% de probabilidade em torno da média.
- e) $\mathbf{y}' = (6, 3, 2)$

Exemplo de ilustração

- d) Verifique se os seguintes pontos pertencem ao elipsóide sólido que delimita 95% de probabilidade em torno da média.
- e) $\mathbf{y}' = (6, 3, 2)$

$$\begin{bmatrix} 6 - 5 \\ 3 - 2 \\ 2 - 1 \end{bmatrix}' \times \begin{bmatrix} 18.95 & -8.33 & -7.53 \\ -8.33 & 4.17 & 3.33 \\ -7.53 & 3.33 & 3.24 \end{bmatrix} \times \begin{bmatrix} 6 - 5 \\ 3 - 2 \\ 2 - 1 \end{bmatrix} = 1.3 \leq 7.814$$

Exemplo de ilustração

- d) Verifique se os seguintes pontos pertencem ao elipsóide sólido que delimita 95% de probabilidade em torno da média.
- e) $\mathbf{y}' = (6, 3, 2)$

$$\begin{bmatrix} 6 - 5 \\ 3 - 2 \\ 2 - 1 \end{bmatrix}' \times \begin{bmatrix} 18.95 & -8.33 & -7.53 \\ -8.33 & 4.17 & 3.33 \\ -7.53 & 3.33 & 3.24 \end{bmatrix} \times \begin{bmatrix} 6 - 5 \\ 3 - 2 \\ 2 - 1 \end{bmatrix} = 1.3 \leq 7.814$$

Logo, $\mathbf{y}' = (6, 3, 2)$ pertence ao elipsóide de 95%.

Exemplo de ilustração

ii) $\mathbf{y}' = (5, 3, 3)$

Exemplo de ilustração

ii) $\mathbf{y}' = (5, 3, 3)$

$$\begin{bmatrix} 5 - 5 \\ 3 - 2 \\ 3 - 1 \end{bmatrix}' \times \begin{bmatrix} 18.95 & -8.33 & -7.53 \\ -8.33 & 4.17 & 3.33 \\ -7.53 & 3.33 & 3.24 \end{bmatrix} \times \begin{bmatrix} 5 - 5 \\ 3 - 2 \\ 3 - 1 \end{bmatrix} = 30.45 > 7.814$$

Exemplo de ilustração

ii) $\mathbf{y}' = (5, 3, 3)$

$$\begin{bmatrix} 5 - 5 \\ 3 - 2 \\ 3 - 1 \end{bmatrix}' \times \begin{bmatrix} 18.95 & -8.33 & -7.53 \\ -8.33 & 4.17 & 3.33 \\ -7.53 & 3.33 & 3.24 \end{bmatrix} \times \begin{bmatrix} 5 - 5 \\ 3 - 2 \\ 3 - 1 \end{bmatrix} = 30.45 > 7.814$$

Logo, $\mathbf{y}' = (5, 3, 3)$ não pertence ao elipsóide de 95%.

Exemplo de ilustração

- e) A distribuição de $Z = 2Y_1 + 3Y_2 - Y_3$.

Exemplo de ilustração

e) A distribuição de $Z = 2Y_1 + 3Y_2 - Y_3$.

Seja $c = [2 \ 3 \ -1]'$.

Exemplo de ilustração

e) A distribuição de $Z = 2Y_1 + 3Y_2 - Y_3$.

Seja $c = [2 \ 3 \ -1]'$.

$$E(Z) = c'\mu = \begin{bmatrix} 2 & 3 & -1 \end{bmatrix} \times \begin{bmatrix} 5 \\ 2 \\ 1 \end{bmatrix} = 15$$

Exemplo de ilustração

$$\text{Var}(Z) = c' \Sigma c = \begin{bmatrix} 2 & 3 & -1 \end{bmatrix} \times \begin{bmatrix} 1 & 0.8 & 1.5 \\ 0.8 & 2 & -0.2 \\ 1.5 & -0.2 & 4 \end{bmatrix} \times \begin{bmatrix} 2 \\ 3 \\ -1 \end{bmatrix} = 30.8$$

Exemplo de ilustração

$$\text{Var}(Z) = c'\Sigma c = \begin{bmatrix} 2 & 3 & -1 \end{bmatrix} \times \begin{bmatrix} 1 & 0.8 & 1.5 \\ 0.8 & 2 & -0.2 \\ 1.5 & -0.2 & 4 \end{bmatrix} \times \begin{bmatrix} 2 \\ 3 \\ -1 \end{bmatrix} = 30.8$$

Logo,

$$Z \sim \text{Normal}(\mu = 15, \sigma^2 = 30.8)$$

Exemplo de ilustração

- ① A distribuição conjunta de $Z_1 = 0.5Y_1 + Y_2 + 2Y_3$ e $Z_2 = -0.25Y_1 - 0.25Y_2 + 0.5Y_3$.

Exemplo de ilustração

① A distribuição conjunta de $Z_1 = 0.5Y_1 + Y_2 + 2Y_3$ e $Z_2 = -0.25Y_1 - 0.25Y_2 + 0.5Y_3$.

Seja $Z' = [Z_1 \ Z_2]$ e

$$A = \begin{bmatrix} 0.5 & 1 & 2 \\ -0.25 & -0.25 & 0.5 \end{bmatrix}$$

Exemplo de ilustração

❶ A distribuição conjunta de $Z_1 = 0.5Y_1 + Y_2 + 2Y_3$ e $Z_2 = -0.25Y_1 - 0.25Y_2 + 0.5Y_3$.

Seja $Z' = [Z_1 \ Z_2]$ e

$$A = \begin{bmatrix} 0.5 & 1 & 2 \\ -0.25 & -0.25 & 0.5 \end{bmatrix}$$

$$E(Z) = A\mu = \begin{bmatrix} 0.5 & 1 & 2 \\ -0.25 & -0.25 & 0.5 \end{bmatrix} \times \begin{bmatrix} 5 \\ 2 \\ 1 \end{bmatrix} = \begin{bmatrix} 6.5 \\ -1.25 \end{bmatrix}$$

Exemplo de ilustração

$$\text{Var}(Z) = A\Sigma A' = \begin{bmatrix} 0.5 & 1 & 2 \\ -0.25 & -0.25 & 0.5 \end{bmatrix} \times \begin{bmatrix} 1 & 0.8 & 1.5 \\ 0.8 & 2 & -0.2 \\ 1.5 & -0.2 & 4 \end{bmatrix} \times \begin{bmatrix} 0.5 & -0.25 \\ 1 & -0.25 \\ 2 & 0.5 \end{bmatrix} = \begin{bmatrix} 19.16 & 2.62 \\ 2.62 & 0.96 \end{bmatrix}$$

Exemplo de ilustração

$$\text{Var}(Z) = A\Sigma A' = \begin{bmatrix} 0.5 & 1 & 2 \\ -0.25 & -0.25 & 0.5 \end{bmatrix} \times \begin{bmatrix} 1 & 0.8 & 1.5 \\ 0.8 & 2 & -0.2 \\ 1.5 & -0.2 & 4 \end{bmatrix} \times \begin{bmatrix} 0.5 & -0.25 \\ 1 & -0.25 \\ 2 & 0.5 \end{bmatrix} = \begin{bmatrix} 19.16 & 2.62 \\ 2.62 & 0.96 \end{bmatrix}$$

Logo,

$$Z \sim \text{Normal} \left(\mu = \begin{bmatrix} 6.5 \\ -1.25 \end{bmatrix}, \Sigma = \begin{bmatrix} 19.16 & 2.62 \\ 2.62 & 0.96 \end{bmatrix} \right)$$

Exemplo de ilustração

- g) A distribuição condicional de $Y_1|Y_3 = 2$.

Exemplo de ilustração

g) A distribuição condicional de $Y_1|Y_3 = 2$.

- Neste caso, $Y_1|Y_3 = 2$ tem distribuição normal com média e variância dadas por:

$$\mu_{Y_1|Y_3} = \mu_1 + \frac{\sigma_{13}}{\sigma_{33}}(y_3 - \mu_3) =$$

$$5 + \frac{1.5}{4}(2 - 1) = 5.375$$

Exemplo de ilustração

g) A distribuição condicional de $Y_1|Y_3 = 2$.

- Neste caso, $Y_1|Y_3 = 2$ tem distribuição normal com média e variância dadas por:

$$\mu_{Y_1|Y_3} = \mu_1 + \frac{\sigma_{13}}{\sigma_{33}}(y_3 - \mu_3) =$$

$$5 + \frac{1.5}{4}(2 - 1) = 5.375$$

$$\sigma_{Y_1|Y_3}^2 = \sigma_{11} - \frac{\sigma_{13}^2}{\sigma_{33}} =$$

$$1 - \frac{1.5^2}{4} = 0.4375$$

Verificação da normalidade multivariada

Verificação da normalidade multivariada

- Uma vez que parte dos métodos de análise multivariada requer a suposição de normalidade (multivariada) dos dados, precisamos de métodos para verificar tal suposição.

Verificação da normalidade multivariada

- Uma vez que parte dos métodos de análise multivariada requer a suposição de normalidade (multivariada) dos dados, precisamos de métodos para verificar tal suposição.
- Embora, como dito anteriormente, normalidade para as distribuições marginais não implique em normalidade para a conjunta, o contrário é necessariamente válido.

Verificação da normalidade multivariada

- Uma vez que parte dos métodos de análise multivariada requer a suposição de normalidade (multivariada) dos dados, precisamos de métodos para verificar tal suposição.
- Embora, como dito anteriormente, normalidade para as distribuições marginais não implique em normalidade para a conjunta, o contrário é necessariamente válido.
- Dessa forma, analisar a normalidade univariada (e eventualmente bivariada) para as p variáveis pode fornecer indicativos favoráveis (ou definitivamente contrários) à suposição de normalidade multivariada.

Verificando a suposição de normalidade multivariada

- Alguns recursos para verificar normalidade (caso univariado):

Verificando a suposição de normalidade multivariada

- Alguns recursos para verificar normalidade (caso univariado):
- Gráficos:

Verificando a suposição de normalidade multivariada

- Alguns recursos para verificar normalidade (caso univariado):
- Gráficos:
 - Histograma com curva de densidade não paramétrica;

Verificando a suposição de normalidade multivariada

- Alguns recursos para verificar normalidade (caso univariado):
- Gráficos:
 - Histograma com curva de densidade não paramétrica;
 - Boxplot;

Verificando a suposição de normalidade multivariada

- Alguns recursos para verificar normalidade (caso univariado):
- Gráficos:
 - Histograma com curva de densidade não paramétrica;
 - Boxplot;
 - Gráfico quantil-quantil.

Verificando a suposição de normalidade multivariada

- Alguns recursos para verificar normalidade (caso univariado):
- Gráficos:
 - Histograma com curva de densidade não paramétrica;
 - Boxplot;
 - Gráfico quantil-quantil.
- Testes:

Verificando a suposição de normalidade multivariada

- Alguns recursos para verificar normalidade (caso univariado):
- Gráficos:
 - Histograma com curva de densidade não paramétrica;
 - Boxplot;
 - Gráfico quantil-quantil.
- Testes:
 - Shapiro Wilks;

Verificando a suposição de normalidade multivariada

- Alguns recursos para verificar normalidade (caso univariado):
- Gráficos:
 - Histograma com curva de densidade não paramétrica;
 - Boxplot;
 - Gráfico quantil-quantil.
- Testes:
 - Shapiro Wilks;
 - Anderson Darling;

Verificando a suposição de normalidade multivariada

- Alguns recursos para verificar normalidade (caso univariado):
- Gráficos:
 - Histograma com curva de densidade não paramétrica;
 - Boxplot;
 - Gráfico quantil-quantil.
- Testes:
 - Shapiro Wilks;
 - Anderson Darling;
 - Lilliefors. . .

Verificando a suposição de normalidade multivariada

- Um procedimento para verificação de normalidade multivariada pode ser estabelecido a partir da medida de distância generalizada:

$$d_i^2 = (\mathbf{y}_i - \bar{\mathbf{y}})' \mathbf{S}^{-1} (\mathbf{y}_i - \bar{\mathbf{y}}), \quad i = 1, 2, \dots, n.$$

Verificando a suposição de normalidade multivariada

- Um procedimento para verificação de normalidade multivariada pode ser estabelecido a partir da medida de distância generalizada:

$$d_i^2 = (\mathbf{y}_i - \bar{\mathbf{y}})' \mathbf{S}^{-1} (\mathbf{y}_i - \bar{\mathbf{y}}), \quad i = 1, 2, \dots, n.$$

- Para n e $n - p$ grandes, é usual comparar os quantis das distâncias quadráticas com os quantis de uma distribuição χ_p^2 .

Verificando a suposição de normalidade multivariada

- Um procedimento para verificação de normalidade multivariada pode ser estabelecido a partir da medida de distância generalizada:

$$d_i^2 = (\mathbf{y}_i - \bar{\mathbf{y}})' \mathbf{S}^{-1} (\mathbf{y}_i - \bar{\mathbf{y}}), \quad i = 1, 2, \dots, n.$$

- Para n e $n - p$ grandes, é usual comparar os quantis das distâncias quadráticas com os quantis de uma distribuição χ_p^2 .
- No caso de aderência satisfatória, tem-se um indicativo de normalidade multivariada.

Verificando a suposição de normalidade multivariada

- A verificação da normalidade multivariada com base nas distâncias quadráticas se dá da seguinte forma:

Verificando a suposição de normalidade multivariada

- A verificação da normalidade multivariada com base nas distâncias quadráticas se dá da seguinte forma:
 - Ordenar as n distâncias quadráticas de forma crescente: $d_{(1)}^2 \leq d_{(2)}^2 \leq \dots \leq d_{(n)}^2$;

Verificando a suposição de normalidade multivariada

- A verificação da normalidade multivariada com base nas distâncias quadráticas se dá da seguinte forma:
 - Ordenar as n distâncias quadráticas de forma crescente: $d_{(1)}^2 \leq d_{(2)}^2 \leq \dots \leq d_{(n)}^2$;
 - Obter os quantis $(i - 1/2)/n$ da distribuição χ_p^2 , para $i = 1, 2, \dots, n$. Vamos denotá-los por $q_{(1)}, q_{(2)}, \dots, q_{(p)}$.

Verificando a suposição de normalidade multivariada

- A verificação da normalidade multivariada com base nas distâncias quadráticas se dá da seguinte forma:
 - Ordenar as n distâncias quadráticas de forma crescente: $d_{(1)}^2 \leq d_{(2)}^2 \leq \dots \leq d_{(n)}^2$;
 - Obter os quantis $(i - 1/2)/n$ da distribuição χ_p^2 , para $i = 1, 2, \dots, n$. Vamos denotá-los por $q_{(1)}, q_{(2)}, \dots, q_{(p)}$.
 - Plotar a dispersão dos pontos $(d_{(1)}^2, q_{(1)}), (d_{(2)}^2, q_{(2)}), \dots, (d_{(n)}^2, q_{(n)})$.

Verificando a suposição de normalidade multivariada

- A verificação da normalidade multivariada com base nas distâncias quadráticas se dá da seguinte forma:
 - Ordenar as n distâncias quadráticas de forma crescente: $d_{(1)}^2 \leq d_{(2)}^2 \leq \dots \leq d_{(n)}^2$;
 - Obter os quantis $(i - 1/2)/n$ da distribuição χ_p^2 , para $i = 1, 2, \dots, n$. Vamos denotá-los por $q_{(1)}, q_{(2)}, \dots, q_{(p)}$.
 - Plotar a dispersão dos pontos $(d_{(1)}^2, q_{(1)}), (d_{(2)}^2, q_{(2)}), \dots, (d_{(n)}^2, q_{(n)})$.
- Quanto mais os pontos estiverem dispersos próximos à reta identidade, mais forte o indicativo de normalidade multivariada.

Verificando a suposição de normalidade multivariada

- A verificação da normalidade multivariada com base nas distâncias quadráticas se dá da seguinte forma:
 - Ordenar as n distâncias quadráticas de forma crescente: $d_{(1)}^2 \leq d_{(2)}^2 \leq \dots \leq d_{(n)}^2$;
 - Obter os quantis $(i - 1/2)/n$ da distribuição χ_p^2 , para $i = 1, 2, \dots, n$. Vamos denotá-los por $q_{(1)}, q_{(2)}, \dots, q_{(p)}$.
 - Plotar a dispersão dos pontos $(d_{(1)}^2, q_{(1)}), (d_{(2)}^2, q_{(2)}), \dots, (d_{(n)}^2, q_{(n)})$.
- Quanto mais os pontos estiverem dispersos próximos à reta identidade, mais forte o indicativo de normalidade multivariada.
- **Nota** - Para amostras pequenas, Ferreira (2008) apresenta uma modificação desse procedimento, baseado nos quantis de uma distribuição beta e com resultados mais satisfatórios (p. 157-158).

Verificando a suposição de normalidade multivariada

- Um procedimento confirmatório disponível para a checagem da normalidade multivariada é a versão multivariada do teste de Shapiro-Wilks.

Verificando a suposição de normalidade multivariada

- Um procedimento confirmatório disponível para a checagem da normalidade multivariada é a versão multivariada do teste de Shapiro-Wilks.
- A hipótese nula desse teste é a hipótese de normalidade multivariada, contra a hipótese alternativa de não normalidade.

Verificando a suposição de normalidade multivariada

- Um procedimento confirmatório disponível para a checagem da normalidade multivariada é a versão multivariada do teste de Shapiro-Wilks.
- A hipótese nula desse teste é a hipótese de normalidade multivariada, contra a hipótese alternativa de não normalidade.
- A distribuição da estatística do teste, sob a hipótese nula, não pode ser obtida analiticamente, mas determinada via simulação.

Verificando a suposição de normalidade multivariada

- Um procedimento confirmatório disponível para a checagem da normalidade multivariada é a versão multivariada do teste de Shapiro-Wilks.
- A hipótese nula desse teste é a hipótese de normalidade multivariada, contra a hipótese alternativa de não normalidade.
- A distribuição da estatística do teste, sob a hipótese nula, não pode ser obtida analiticamente, mas determinada via simulação.
- No R, pacotes *mvShapiroTest* e *mvnormtest*.

Verificando a suposição de normalidade multivariada

- Caso a suposição de normalidade não seja atendida, deve-se considerar como alternativas:

Verificando a suposição de normalidade multivariada

- Caso a suposição de normalidade não seja atendida, deve-se considerar como alternativas:
 - Utilizar métodos baseados em outras distribuições de probabilidades, ou métodos não paramétricos;

Verificando a suposição de normalidade multivariada

- Caso a suposição de normalidade não seja atendida, deve-se considerar como alternativas:
 - Utilizar métodos baseados em outras distribuições de probabilidades, ou métodos não paramétricos;
 - Transformar os dados (ex: transformação de Box-Cox);

Verificando a suposição de normalidade multivariada

- Caso a suposição de normalidade não seja atendida, deve-se considerar como alternativas:
 - Utilizar métodos baseados em outras distribuições de probabilidades, ou métodos não paramétricos;
 - Transformar os dados (ex: transformação de Box-Cox);
 - Categorizar os dados;

Verificando a suposição de normalidade multivariada

- Caso a suposição de normalidade não seja atendida, deve-se considerar como alternativas:
 - Utilizar métodos baseados em outras distribuições de probabilidades, ou métodos não paramétricos;
 - Transformar os dados (ex: transformação de Box-Cox);
 - Categorizar os dados;
 - Investigar a presença de outliers.

Verificação de outliers multivariados

Verificando a existência de outliers

- Outliers são resultados extremos que devem ser identificados e examinados com cautela, verificando possível impacto nos resultados das análises.

Verificando a existência de outliers

- Outliers são resultados extremos que devem ser identificados e examinados com cautela, verificando possível impacto nos resultados das análises.
- No contexto univariado, gráficos (histograma, boxplot, gráfico quanti-quantil), além de regras empíricas (como pontos afastados a mais de três desvios padrões da média) são ferramentas auxiliares na identificação de outliers.

Verificando a existência de outliers

- Outliers são resultados extremos que devem ser identificados e examinados com cautela, verificando possível impacto nos resultados das análises.
- No contexto univariado, gráficos (histograma, boxplot, gráfico quanti-quantil), além de regras empíricas (como pontos afastados a mais de três desvios padrões da média) são ferramentas auxiliares na identificação de outliers.
- Já no contexto multivariado, identificar outliers é uma tarefa mais complicada.

Verificando a existência de outliers

- Outliers são resultados extremos que devem ser identificados e examinados com cautela, verificando possível impacto nos resultados das análises.
- No contexto univariado, gráficos (histograma, boxplot, gráfico quanti-quantil), além de regras empíricas (como pontos afastados a mais de três desvios padrões da média) são ferramentas auxiliares na identificação de outliers.
- Já no contexto multivariado, identificar outliers é uma tarefa mais complicada.
- Gráficos de dispersão bi e tridimensionais e matrizes de gráficos de dispersão podem ajudar.

Verificando a existência de outliers




Figura 7: Representação de outliers (caso bivariado)

Verificando a existência de outliers

- Uma vez mais, o conceito de distância pode ser aplicado aqui como recurso para identificação de outliers.

Verificando a existência de outliers

- Uma vez mais, o conceito de distância pode ser aplicado aqui como recurso para identificação de outliers.
- Nesse caso, calculamos $d_i^2 = (\mathbf{y}_i - \bar{\mathbf{y}})' \mathbf{S}^{-1} (\mathbf{y}_i - \bar{\mathbf{y}})$, $i = 1, 2, \dots, n$ e comparamos os valores obtidos com o quantil superior α da distribuição χ_p^2 .

Verificando a existência de outliers

- Uma vez mais, o conceito de distância pode ser aplicado aqui como recurso para identificação de outliers.
- Nesse caso, calculamos $d_i^2 = (\mathbf{y}_i - \bar{\mathbf{y}})' \mathbf{S}^{-1} (\mathbf{y}_i - \bar{\mathbf{y}})$, $i = 1, 2, \dots, n$ e comparamos os valores obtidos com o quantil superior α da distribuição χ_p^2 .
- Em geral consideramos um valor pequeno para α (como 1%, ou 0,5%), tendo em mente que, mesmo sob normalidade multivariada, valores extremos naturalmente ocorrem.

O que vamos estudar no próximo módulo

O que vamos estudar no próximo módulo

- Testes de hipóteses e regiões de confiança para um vetor de médias.

O que vamos estudar no próximo módulo

- Testes de hipóteses e regiões de confiança para um vetor de médias.
- Testes de hipóteses e regiões de confiança para dois vetores de médias.

O que vamos estudar no próximo módulo

- Testes de hipóteses e regiões de confiança para um vetor de médias.
- Testes de hipóteses e regiões de confiança para dois vetores de médias.
- Análise de variância multivariada.

O que vamos estudar no próximo módulo

- Testes de hipóteses e regiões de confiança para um vetor de médias.
- Testes de hipóteses e regiões de confiança para dois vetores de médias.
- Análise de variância multivariada.
- Comparação de matrizes de covariâncias.