

CE319 - Estatística multivariada

Introdução

Cesar Augusto Taconeli

03 de março, 2026

Introdução à Estatística Multivariada

O que vamos estudar neste módulo

O que vamos estudar neste módulo

- Neste módulo vamos apresentar o contexto e a relevância da Estatística Multivariada.

O que vamos estudar neste módulo

- Neste módulo vamos apresentar o contexto e a relevância da Estatística Multivariada.
- Técnicas multivariadas de visualização de dados, redução de dimensão, classificação e agrupamentos, além de métodos inferenciais, são brevemente introduzidos.

O que vamos estudar neste módulo

- Neste módulo vamos apresentar o contexto e a relevância da Estatística Multivariada.
- Técnicas multivariadas de visualização de dados, redução de dimensão, classificação e agrupamentos, além de métodos inferenciais, são brevemente introduzidos.
- Uma aplicação em dados de características nutricionais de sanduíches servem de ilustração.

Análise Estatística Multivariada

Análise Estatística Multivariada

- Nos últimos anos, temos observado aumento exponencial na produção e disponibilidade de dados e informação.

Análise Estatística Multivariada

- Nos últimos anos, temos observado aumento exponencial na produção e disponibilidade de dados e informação.
- Esse fenômeno tem como consequência a demanda por recursos computacionais e técnicas estatística para a análise desses dados.

Análise Estatística Multivariada

- Nos últimos anos, temos observado aumento exponencial na produção e disponibilidade de dados e informação.
- Esse fenômeno tem como consequência a demanda por recursos computacionais e técnicas estatística para a análise desses dados.
- A **Estatística Multivariada** compreende um conjunto de métodos aplicados à análise conjunta de múltiplas variáveis aleatórias.

Análise Estatística Multivariada

- Nos últimos anos, temos observado aumento exponencial na produção e disponibilidade de dados e informação.
- Esse fenômeno tem como consequência a demanda por recursos computacionais e técnicas estatística para a análise desses dados.
- A **Estatística Multivariada** compreende um conjunto de métodos aplicados à análise conjunta de múltiplas variáveis aleatórias.
- Técnicas multivariadas podem ser aplicadas com finalidades diversas, sendo algumas delas brevemente ilustradas na sequência.

Principais objetivos da Estatística Multivariada

- Dentre os principais propósitos da Estatística Multivariada, podemos destacar:

Principais objetivos da Estatística Multivariada

- Dentre os principais propósitos da Estatística Multivariada, podemos destacar:
 - Visualização e resumo de dados multivariados;

Principais objetivos da Estatística Multivariada

- Dentre os principais propósitos da Estatística Multivariada, podemos destacar:
 - Visualização e resumo de dados multivariados;
 - Redução da dimensão ou simplificação dos dados;

Principais objetivos da Estatística Multivariada

- Dentre os principais propósitos da Estatística Multivariada, podemos destacar:
 - Visualização e resumo de dados multivariados;
 - Redução da dimensão ou simplificação dos dados;
 - Identificação de padrões e agrupamento de indivíduos semelhantes;

Principais objetivos da Estatística Multivariada

- Dentre os principais propósitos da Estatística Multivariada, podemos destacar:
 - Visualização e resumo de dados multivariados;
 - Redução da dimensão ou simplificação dos dados;
 - Identificação de padrões e agrupamento de indivíduos semelhantes;
 - Classificação e discriminação (em grupos previamente definidos);

Principais objetivos da Estatística Multivariada

- Dentre os principais propósitos da Estatística Multivariada, podemos destacar:
 - Visualização e resumo de dados multivariados;
 - Redução da dimensão ou simplificação dos dados;
 - Identificação de padrões e agrupamento de indivíduos semelhantes;
 - Classificação e discriminação (em grupos previamente definidos);
 - Inferência estatística multivariada.

Exemplo de ilustração

Exemplo de ilustração

- Informações nutricionais de 20 sanduíches comercializados por uma grande rede de fast-food (McDonald's).

Exemplo de ilustração

- Informações nutricionais de 20 sanduíches comercializados por uma grande rede de fast-food (McDonald's).
- Além do nome comercial do sanduíche, as seguintes variáveis serão consideradas:

Exemplo de ilustração

- Informações nutricionais de 20 sanduíches comercializados por uma grande rede de fast-food (McDonald's).
- Além do nome comercial do sanduíche, as seguintes variáveis serão consideradas:
 - Carboidratos (g);

Exemplo de ilustração

- Informações nutricionais de 20 sanduíches comercializados por uma grande rede de fast-food (McDonald's).
- Além do nome comercial do sanduíche, as seguintes variáveis serão consideradas:
 - Carboidratos (g);
 - Proteínas (g);

Exemplo de ilustração

- Informações nutricionais de 20 sanduíches comercializados por uma grande rede de fast-food (McDonald's).
- Além do nome comercial do sanduíche, as seguintes variáveis serão consideradas:
 - Carboidratos (g);
 - Proteínas (g);
 - Fibras (g);

Exemplo de ilustração

- Informações nutricionais de 20 sanduíches comercializados por uma grande rede de fast-food (McDonald's).
- Além do nome comercial do sanduíche, as seguintes variáveis serão consideradas:
 - Carboidratos (g);
 - Proteínas (g);
 - Fibras (g);
 - Sódio (mg).

Exemplo de ilustração

- Informações nutricionais de 20 sanduíches comercializados por uma grande rede de fast-food (McDonald's).
- Além do nome comercial do sanduíche, as seguintes variáveis serão consideradas:
 - Carboidratos (g);
 - Proteínas (g);
 - Fibras (g);
 - Sódio (mg).
- Variáveis adicionais serão oportunamente apresentadas.

Exemplo de ilustração

Tabela 1: Informações nutricionais de 20 sanduiches do McDonald's

Sanduiche	Carboidratos	Proteinas	Fibra	Sódio
Big Mac	45	27	5,4	1047
Big Tasty	41	41	4,6	1345
Quarterão	33	30	2,6	1072
McNífico Bacon	34	32	3,8	1099
Cheddar McMelt	30	28	2,4	819
McFish	37	15	2,2	511
McChicken	36	17	3,4	718
Duplo Salada	32	22	3,2	764
Extra Chicken	35	13	3,5	662
Chicken Supreme Grill	30	29	3,1	1164
Chicken Supreme Crispy	37	19	3,6	1096
Cheeseburger	32	16	2,2	715
Hamburger	31	14	2,2	517
ClubHouse	48	49	3,6	1368
ClubHouse com Crispy	60	33	4,4	1680
McDuplo	31	22	2,2	680
Duplo Quarterão	33	50	2,6	1273
Egg Cheese Bacon	27	17	1,6	660
4-Formaggi Carne	49	55	3,6	1832
4-Formaggi Frango	61	39	4,4	2143

Visualização dos dados

Visualização dos dados

- A visualização de dados multivariados requer o uso adequado de gráficos, tabelas e outras formas de visualização.

Visualização dos dados

- A visualização de dados multivariados requer o uso adequado de gráficos, tabelas e outras formas de visualização.
- Gráficos multi-dimensionais, dinâmicos e interativos podem ser úteis para reconhecimento de padrões nos dados.

Aplicações

- **Área:** Epidemiologia/Saúde pública.

Aplicações

- **Área:** Epidemiologia/Saúde pública.
 - Pacientes acompanhados em um estudo clínico.

Aplicações

- **Área:** Epidemiologia/Saúde pública.
 - Pacientes acompanhados em um estudo clínico.
 - Variáveis: idade, pressão arterial, colesterol, IMC, glicemia.

Aplicações

- **Área:** Epidemiologia/Saúde pública.
 - Pacientes acompanhados em um estudo clínico.
 - Variáveis: idade, pressão arterial, colesterol, IMC, glicemia.
 - Objetivo: usar gráficos de dispersão ou pairs plots para identificar padrões de risco cardiovascular.

Aplicações

- **Área:** Epidemiologia/Saúde pública.
 - Pacientes acompanhados em um estudo clínico.
 - Variáveis: idade, pressão arterial, colesterol, IMC, glicemia.
 - Objetivo: usar gráficos de dispersão ou pairs plots para identificar padrões de risco cardiovascular.

- **Área:** Marketing/Comportamento do consumidor.

Aplicações

- **Área:** Epidemiologia/Saúde pública.
 - Pacientes acompanhados em um estudo clínico.
 - Variáveis: idade, pressão arterial, colesterol, IMC, glicemia.
 - Objetivo: usar gráficos de dispersão ou pairs plots para identificar padrões de risco cardiovascular.
- **Área:** Marketing/Comportamento do consumidor.
 - Base de clientes de uma rede varejista.

Aplicações

- **Área:** Epidemiologia/Saúde pública.
 - Pacientes acompanhados em um estudo clínico.
 - Variáveis: idade, pressão arterial, colesterol, IMC, glicemia.
 - Objetivo: usar gráficos de dispersão ou pairs plots para identificar padrões de risco cardiovascular.
- **Área:** Marketing/Comportamento do consumidor.
 - Base de clientes de uma rede varejista.
 - Variáveis: renda, idade, frequência de compra, gasto médio, número de produtos comprados.

Aplicações

- **Área:** Epidemiologia/Saúde pública.
 - Pacientes acompanhados em um estudo clínico.
 - Variáveis: idade, pressão arterial, colesterol, IMC, glicemia.
 - Objetivo: usar gráficos de dispersão ou pairs plots para identificar padrões de risco cardiovascular.
- **Área:** Marketing/Comportamento do consumidor.
 - Base de clientes de uma rede varejista.
 - Variáveis: renda, idade, frequência de compra, gasto médio, número de produtos comprados.
 - Objetivo: visualizar relações entre hábitos de consumo e perfil socioeconômico.

Visualização dos dados




Figura 1: Distribuições univariadas

Visualização dos dados




Figura 2: Gráficos de dispersão

Visualização dos dados




Figura 3: Representação das quatro variáveis

Redução da dimensão ou simplificação dos dados

Redução da dimensão ou simplificação dos dados

- Técnicas de redução de dimensão tem por objetivo a análise conjunta das variáveis originais em um número menor de dimensões.

Redução da dimensão ou simplificação dos dados

- Técnicas de redução de dimensão tem por objetivo a análise conjunta das variáveis originais em um número menor de dimensões.
- O objetivo é simplificar os dados reduzindo a dimensão do problema, mas conservando ao máximo a informação original dos dados.

Redução da dimensão ou simplificação dos dados

- Técnicas de redução de dimensão tem por objetivo a análise conjunta das variáveis originais em um número menor de dimensões.
- O objetivo é simplificar os dados reduzindo a dimensão do problema, mas conservando ao máximo a informação original dos dados.
- Os resultados produzidos permitem extrair informações sobre a estrutura de correlações dos dados, bem como produzir índices que combinam os valores das variáveis originais.

Redução da dimensão ou simplificação dos dados

- Técnicas de redução de dimensão tem por objetivo a análise conjunta das variáveis originais em um número menor de dimensões.
- O objetivo é simplificar os dados reduzindo a dimensão do problema, mas conservando ao máximo a informação original dos dados.
- Os resultados produzidos permitem extrair informações sobre a estrutura de correlações dos dados, bem como produzir índices que combinam os valores das variáveis originais.
- Técnicas como análise de componentes principais, análise fatorial e análise de correspondência se destacam com esse objetivo.

Aplicações

- **Área:** Genômica.

Aplicações

- **Área:** Genômica.
 - Estudo de expressão gênica em pacientes.

Aplicações

- **Área:** Genômica.
 - Estudo de expressão gênica em pacientes.
 - Variáveis: milhares de genes medidos simultaneamente.

Aplicações

- **Área:** Genômica.
 - Estudo de expressão gênica em pacientes.
 - Variáveis: milhares de genes medidos simultaneamente.
 - Objetivo: usar PCA para reduzir milhares de variáveis a poucos componentes que resumem os padrões biológicos.

Aplicações

- **Área:** Genômica.
 - Estudo de expressão gênica em pacientes.
 - Variáveis: milhares de genes medidos simultaneamente.
 - Objetivo: usar PCA para reduzir milhares de variáveis a poucos componentes que resumem os padrões biológicos.

- **Área:** Economia.

Aplicações

- **Área:** Genômica.
 - Estudo de expressão gênica em pacientes.
 - Variáveis: milhares de genes medidos simultaneamente.
 - Objetivo: usar PCA para reduzir milhares de variáveis a poucos componentes que resumem os padrões biológicos.
- **Área:** Economia.
 - Avaliação de desenvolvimento socioeconômico de municípios.

Aplicações

- **Área:** Genômica.
 - Estudo de expressão gênica em pacientes.
 - Variáveis: milhares de genes medidos simultaneamente.
 - Objetivo: usar PCA para reduzir milhares de variáveis a poucos componentes que resumem os padrões biológicos.
- **Área:** Economia.
 - Avaliação de desenvolvimento socioeconômico de municípios.
 - Variáveis: renda média, escolaridade, mortalidade infantil, emprego formal, acesso a saneamento.

Aplicações

- **Área:** Genômica.
 - Estudo de expressão gênica em pacientes.
 - Variáveis: milhares de genes medidos simultaneamente.
 - Objetivo: usar PCA para reduzir milhares de variáveis a poucos componentes que resumem os padrões biológicos.
- **Área:** Economia.
 - Avaliação de desenvolvimento socioeconômico de municípios.
 - Variáveis: renda média, escolaridade, mortalidade infantil, emprego formal, acesso a saneamento.
 - Objetivo: construir índices sintéticos de desenvolvimento usando componentes principais.

Exemplo de ilustração




Figura 4: Correlograma- informações nutricionais

Exemplo de ilustração

- Podemos observar que as quatro variáveis (informações nutricionais) estão positivamente correlacionadas.

Exemplo de ilustração

- Podemos observar que as quatro variáveis (informações nutricionais) estão positivamente correlacionadas.
- Desta forma, um índice (por exemplo, uma combinação linear) que atribuisse pesos aproximadamente semelhantes às quatro variáveis permitiria medir o “consumo global” (solução com uma dimensão).

Exemplo de ilustração

- Podemos observar que as quatro variáveis (informações nutricionais) estão positivamente correlacionadas.
- Desta forma, um índice (por exemplo, uma combinação linear) que atribuisse pesos aproximadamente semelhantes às quatro variáveis permitiria medir o “consumo global” (solução com uma dimensão).
- Por outro lado, a quantidade de fibras apresenta menores correlações com as demais variáveis.

Exemplo de ilustração

- Podemos observar que as quatro variáveis (informações nutricionais) estão positivamente correlacionadas.
- Desta forma, um índice (por exemplo, uma combinação linear) que atribuisse pesos aproximadamente semelhantes às quatro variáveis permitiria medir o “consumo global” (solução com uma dimensão).
- Por outro lado, a quantidade de fibras apresenta menores correlações com as demais variáveis.
- Como alternativa, poderíamos pensar num índice conjunto de proteínas, carboidratos e sódio, e outro que refletisse predominantemente a quantidade de fibras (solução com duas dimensões).

Identificação de padrões e agrupamento de indivíduos semelhantes

Identificação de padrões e agrupamento de indivíduos semelhantes

- Técnicas de agrupamento tem por finalidade a identificação de grupos de indivíduos com valores semelhantes para o conjunto de variáveis.

Identificação de padrões e agrupamento de indivíduos semelhantes

- Técnicas de agrupamento tem por finalidade a identificação de grupos de indivíduos com valores semelhantes para o conjunto de variáveis.
- Com base nos grupos formados, podemos caracterizar padrões distintos para indivíduos de diferentes grupos.

Identificação de padrões e agrupamento de indivíduos semelhantes

- Técnicas de agrupamento tem por finalidade a identificação de grupos de indivíduos com valores semelhantes para o conjunto de variáveis.
- Com base nos grupos formados, podemos caracterizar padrões distintos para indivíduos de diferentes grupos.
- Se o problema envolve tomada de decisão, uma vez caracterizados os grupos diferentes estratégias podem ser definidas para lidar com cada grupo.

Identificação de padrões e agrupamento de indivíduos semelhantes

- Técnicas de agrupamento tem por finalidade a identificação de grupos de indivíduos com valores semelhantes para o conjunto de variáveis.
- Com base nos grupos formados, podemos caracterizar padrões distintos para indivíduos de diferentes grupos.
- Se o problema envolve tomada de decisão, uma vez caracterizados os grupos diferentes estratégias podem ser definidas para lidar com cada grupo.
- Dentre as principais técnicas de agrupamento, destacam-se os métodos aglomerativos, K-means e baseados em modelos.

Aplicações

- **Área:** Ecologia.

Aplicações

- **Área:** Ecologia.
 - Estudo de comunidades vegetais em diferentes áreas.

Aplicações

- **Área:** Ecologia.
 - Estudo de comunidades vegetais em diferentes áreas.
 - Variáveis: abundância de espécies, altura média da vegetação, umidade do solo.

Aplicações

- **Área:** Ecologia.
 - Estudo de comunidades vegetais em diferentes áreas.
 - Variáveis: abundância de espécies, altura média da vegetação, umidade do solo.
 - Objetivo: identificar tipos de ecossistemas semelhantes.

Aplicações

- **Área:** Ecologia.
 - Estudo de comunidades vegetais em diferentes áreas.
 - Variáveis: abundância de espécies, altura média da vegetação, umidade do solo.
 - Objetivo: identificar tipos de ecossistemas semelhantes.

- **Área:** Marketing.

Aplicações

- **Área:** Ecologia.
 - Estudo de comunidades vegetais em diferentes áreas.
 - Variáveis: abundância de espécies, altura média da vegetação, umidade do solo.
 - Objetivo: identificar tipos de ecossistemas semelhantes.

- **Área:** Marketing.
 - Base de consumidores de um e-commerce.

Aplicações

- **Área:** Ecologia.
 - Estudo de comunidades vegetais em diferentes áreas.
 - Variáveis: abundância de espécies, altura média da vegetação, umidade do solo.
 - Objetivo: identificar tipos de ecossistemas semelhantes.

- **Área:** Marketing.
 - Base de consumidores de um e-commerce.
 - Variáveis: valor gasto, frequência de compra, tempo desde última compra.

Aplicações

- **Área:** Ecologia.
 - Estudo de comunidades vegetais em diferentes áreas.
 - Variáveis: abundância de espécies, altura média da vegetação, umidade do solo.
 - Objetivo: identificar tipos de ecossistemas semelhantes.

- **Área:** Marketing.
 - Base de consumidores de um e-commerce.
 - Variáveis: valor gasto, frequência de compra, tempo desde última compra.
 - Objetivo: segmentar clientes em perfis de consumo.

Exemplo de ilustração




Figura 5: Dispersão- Proteína versus carboidratos

Exemplo de ilustração





Figura 6: Dispersão- Sódio versus fibra



Exemplo de ilustração




Figura 8: Resultado da análise de agrupamentos- 4 grupos

Exemplo de ilustração

- Os gráficos de dispersão evidenciam sanduíches com diferentes características quanto aos valores das quatro variáveis analisadas.

Exemplo de ilustração

- Os gráficos de dispersão evidenciam sanduíches com diferentes características quanto aos valores das quatro variáveis analisadas.
- Os dendrogramas permitem avaliar os agrupamentos formados para diferentes números de grupos.

Exemplo de ilustração

- Os gráficos de dispersão evidenciam sanduíches com diferentes características quanto aos valores das quatro variáveis analisadas.
- Os dendrogramas permitem avaliar os agrupamentos formados para diferentes números de grupos.
- Como sugestão, é apresentada a solução para quatro grupos.

Exemplo de ilustração

- Os gráficos de dispersão evidenciam sanduíches com diferentes características quanto aos valores das quatro variáveis analisadas.
- Os dendrogramas permitem avaliar os agrupamentos formados para diferentes números de grupos.
- Como sugestão, é apresentada a solução para quatro grupos.
- Analisando conjuntamente o dendrograma com quatro grupos e os gráficos de dispersão, podemos caracterizar cada grupo segundo os valores das quatro variáveis.

Classificação e discriminação

Classificação e discriminação

- Técnicas de classificação e discriminação têm por objetivo identificar regras (funções) baseadas nos valores das variáveis originais que permitam classificar (discriminar) os indivíduos em classes (pré-estabelecidas).

Classificação e discriminação

- Técnicas de classificação e discriminação têm por objetivo identificar regras (funções) baseadas nos valores das variáveis originais que permitam classificar (discriminar) os indivíduos em classes (pré-estabelecidas).
- Os métodos multivariados usados com essa finalidade tem como concorrentes técnicas baseadas em modelos de regressão (ex: regressão logística) e de aprendizado de máquina (ex: support vector machines).

Classificação e discriminação

- Técnicas de classificação e discriminação têm por objetivo identificar regras (funções) baseadas nos valores das variáveis originais que permitam classificar (discriminar) os indivíduos em classes (pré-estabelecidas).
- Os métodos multivariados usados com essa finalidade tem como concorrentes técnicas baseadas em modelos de regressão (ex: regressão logística) e de aprendizado de máquina (ex: support vector machines).
- Dentre as técnicas multivariadas mais usuais para fins de classificação, destacam-se a análise discriminante linear e quadrática.

Aplicações

- **Área:** Finanças.

Aplicações

- **Área:** Finanças.
 - Clientes classificados como adimplentes ou inadimplentes.

Aplicações

- **Área:** Finanças.
 - Clientes classificados como adimplentes ou inadimplentes.
 - Variáveis: renda, histórico de crédito, número de empréstimos, idade.

Aplicações

- **Área:** Finanças.
 - Clientes classificados como adimplentes ou inadimplentes.
 - Variáveis: renda, histórico de crédito, número de empréstimos, idade.
 - Objetivo: prever risco de crédito.

Aplicações

- **Área:** Finanças.
 - Clientes classificados como adimplentes ou inadimplentes.
 - Variáveis: renda, histórico de crédito, número de empréstimos, idade.
 - Objetivo: prever risco de crédito.

- **Área:** Agricultura.

Aplicações

- **Área:** Finanças.
 - Clientes classificados como adimplentes ou inadimplentes.
 - Variáveis: renda, histórico de crédito, número de empréstimos, idade.
 - Objetivo: prever risco de crédito.

- **Área:** Agricultura.
 - Grãos classificados em variedades diferentes.

Aplicações

- **Área:** Finanças.
 - Clientes classificados como adimplentes ou inadimplentes.
 - Variáveis: renda, histórico de crédito, número de empréstimos, idade.
 - Objetivo: prever risco de crédito.

- **Área:** Agricultura.
 - Grãos classificados em variedades diferentes.
 - Variáveis: comprimento, largura, massa, teor de proteína.

Aplicações

- **Área:** Finanças.
 - Clientes classificados como adimplentes ou inadimplentes.
 - Variáveis: renda, histórico de crédito, número de empréstimos, idade.
 - Objetivo: prever risco de crédito.

- **Área:** Agricultura.
 - Grãos classificados em variedades diferentes.
 - Variáveis: comprimento, largura, massa, teor de proteína.
 - Objetivo: classificar automaticamente a variedade do grão.

Exemplo de ilustração

- Nesta aplicação, os sanduíches foram divididos em dois grupos: com quantidade de calorias acima ou abaixo da mediana.

Exemplo de ilustração

- Nesta aplicação, os sanduíches foram divididos em dois grupos: com quantidade de calorias acima ou abaixo da mediana.
- O objetivo aqui é usar as variáveis originais para discriminar (classificar) os sanduíches com total calórico acima ou abaixo da mediana.

Exemplo de ilustração

- Nesta aplicação, os sanduíches foram divididos em dois grupos: com quantidade de calorias acima ou abaixo da mediana.
- O objetivo aqui é usar as variáveis originais para discriminar (classificar) os sanduíches com total calórico acima ou abaixo da mediana.
- Para fins de ilustração, uma função discriminante linear é apresentada considerando as quantidades de carboidratos e proteínas.

Exemplo de ilustração

- Nesta aplicação, os sanduíches foram divididos em dois grupos: com quantidade de calorias acima ou abaixo da mediana.
- O objetivo aqui é usar as variáveis originais para discriminar (classificar) os sanduíches com total calórico acima ou abaixo da mediana.
- Para fins de ilustração, uma função discriminante linear é apresentada considerando as quantidades de carboidratos e proteínas.
- Observe que a reta apresentada é capaz de discriminar completamente os sanduíches dos dois grupos.

Exemplo de ilustração




Figura 9: Dispersão- Proteínas versus carboidratos por consumo calórico

Exemplo de ilustração




Figura 10: Dispersão- Sódio versus fibra por consumo calórico

Exemplo de ilustração




Figura 11: Ilustração - função discriminante

Inferência estatística multivariada

Inferência estatística multivariada

- Os problemas usuais de inferência estatística (testes de hipóteses, intervalos de confiança) se estendem para o caso em que dispomos de $p \geq 2$ variáveis.

Inferência estatística multivariada

- Os problemas usuais de inferência estatística (testes de hipóteses, intervalos de confiança) se estendem para o caso em que dispomos de $p \geq 2$ variáveis.
- O objetivo é produzir inferências para uma ou mais populações sob estudo levando em conta as p variáveis conjuntamente.

Inferência estatística multivariada

- Os problemas usuais de inferência estatística (testes de hipóteses, intervalos de confiança) se estendem para o caso em que dispomos de $p \geq 2$ variáveis.
- O objetivo é produzir inferências para uma ou mais populações sob estudo levando em conta as p variáveis conjuntamente.
- Neste caso, deve-se incorporar à análise as correlações inerentes às variáveis.

Aplicações

- **Área:** Educação.

Aplicações

- **Área:** Educação.
 - Comparar métodos de ensino.

Aplicações

- **Área:** Educação.
 - Comparar métodos de ensino.
 - Variáveis: notas em matemática, leitura e ciências.

Aplicações

- **Área:** Educação.
 - Comparar métodos de ensino.
 - Variáveis: notas em matemática, leitura e ciências.
 - Objetivo: testar se há diferença multivariada no desempenho dos alunos.

Aplicações

- **Área:** Educação.
 - Comparar métodos de ensino.
 - Variáveis: notas em matemática, leitura e ciências.
 - Objetivo: testar se há diferença multivariada no desempenho dos alunos.

- **Área:** Farmacologia.

Aplicações

- **Área:** Educação.
 - Comparar métodos de ensino.
 - Variáveis: notas em matemática, leitura e ciências.
 - Objetivo: testar se há diferença multivariada no desempenho dos alunos.

- **Área:** Farmacologia.
 - Avaliar efeito de um medicamento.

Aplicações

- **Área:** Educação.
 - Comparar métodos de ensino.
 - Variáveis: notas em matemática, leitura e ciências.
 - Objetivo: testar se há diferença multivariada no desempenho dos alunos.

- **Área:** Farmacologia.
 - Avaliar efeito de um medicamento.
 - Variáveis: pressão arterial, frequência cardíaca, nível de colesterol.

Aplicações

- **Área:** Educação.
 - Comparar métodos de ensino.
 - Variáveis: notas em matemática, leitura e ciências.
 - Objetivo: testar se há diferença multivariada no desempenho dos alunos.

- **Área:** Farmacologia.
 - Avaliar efeito de um medicamento.
 - Variáveis: pressão arterial, frequência cardíaca, nível de colesterol.
 - Objetivo: verificar se o tratamento altera simultaneamente vários indicadores fisiológicos.

Exemplo de ilustração

- A título de ilustração, consideramos aqui dois grupos de sanduíches: com ou sem bacon em seu preparo.

Exemplo de ilustração

- A título de ilustração, consideramos aqui dois grupos de sanduíches: com ou sem bacon em seu preparo.
- Neste caso, como objetivo sugerimos a comparação das quantidades médias de carboidratos, proteínas, fibras e sódio nos sanduíches com e sem bacon.

Exemplo de ilustração

- A título de ilustração, consideramos aqui dois grupos de sanduíches: com ou sem bacon em seu preparo.
- Neste caso, como objetivo sugerimos a comparação das quantidades médias de carboidratos, proteínas, fibras e sódio nos sanduíches com e sem bacon.
- No contexto multivariado, estamos interessados em investigar se essas quantidades diferem conjuntamente (para as quatro variáveis), e não separadamente para cada uma delas.

Exemplo de ilustração

- A título de ilustração, consideramos aqui dois grupos de sanduíches: com ou sem bacon em seu preparo.
- Neste caso, como objetivo sugerimos a comparação das quantidades médias de carboidratos, proteínas, fibras e sódio nos sanduíches com e sem bacon.
- No contexto multivariado, estamos interessados em investigar se essas quantidades diferem conjuntamente (para as quatro variáveis), e não separadamente para cada uma delas.
- Caso a diferença multivariada seja comprovada, pode-se proceder com análises univariadas para identificar quais variáveis são responsáveis pela diferença.

Exemplo de ilustração




Figura 12: Boxplots segundo uso de bacon como ingrediente

Exemplo de ilustração

- Aparentemente, sanduíches que tem bacon no seu preparo diferem dos sanduiches sem bacon no conjunto de nutrientes avaliados.

Exemplo de ilustração

- Aparentemente, sanduíches que tem bacon no seu preparo diferem dos sanduiches sem bacon no conjunto de nutrientes avaliados.
- Ao analisar individualmente os quatro nutrientes, percebe-se maiores quantidades, para todos eles, nos sanduíches que tem bacon no preparo.

Conclusão

Conclusão

- Ao final da disciplina você será capaz de:

Conclusão

- Ao final da disciplina você será capaz de:
 - Produzir visualizações e resumos de dados multivariados;

Conclusão

- Ao final da disciplina você será capaz de:
 - Produzir visualizações e resumos de dados multivariados;
 - Aplicar técnicas de redução de dimensão para simplificação dos dados;

Conclusão

- Ao final da disciplina você será capaz de:
 - Produzir visualizações e resumos de dados multivariados;
 - Aplicar técnicas de redução de dimensão para simplificação dos dados;
 - Identificar padrões e agrupar dados indivíduos com base ;

Conclusão

- Ao final da disciplina você será capaz de:
 - Produzir visualizações e resumos de dados multivariados;
 - Aplicar técnicas de redução de dimensão para simplificação dos dados;
 - Identificar padrões e agrupar dados indivíduos com base ;
 - Classificar e discriminar dados multivariados em em grupos previamente definidos;

Conclusão

- Ao final da disciplina você será capaz de:
 - Produzir visualizações e resumos de dados multivariados;
 - Aplicar técnicas de redução de dimensão para simplificação dos dados;
 - Identificar padrões e agrupar dados indivíduos com base ;
 - Classificar e discriminar dados multivariados em em grupos previamente definidos;
 - Produzir inferências (testar hipóteses, construir intervalos de confiança) para múltiplas variáveis.

O que vamos estudar no próximo módulo

O que vamos estudar no próximo módulo

- Como descrever dados multivariados usando medidas de centralidade, covariância e correlação.

O que vamos estudar no próximo módulo

- Como descrever dados multivariados usando medidas de centralidade, covariância e correlação.
- Cuidados na preparação dos dados para a análise.

O que vamos estudar no próximo módulo

- Como descrever dados multivariados usando medidas de centralidade, covariância e correlação.
- Cuidados na preparação dos dados para a análise.
- Métodos gráficos para visualização dos dados.

O que vamos estudar no próximo módulo

- Como descrever dados multivariados usando medidas de centralidade, covariância e correlação.
- Cuidados na preparação dos dados para a análise.
- Métodos gráficos para visualização dos dados.
- Os conceitos de dissimilaridade e distância.