Análise de Séries Temporais: Impactos Climáticos, Genômica e Ciclos Epidemiológicos

Eduardo Demetrio

20/06/2026

Questão 1

1.1 Introdução e Preparação dos Dados

Nesta análise, investigamos como as variações no preço do suco de laranja concentrado congelado são influenciadas por ondas de frio (FDD) na Flórida.

```
library(astsa)

# Importação dos dados brutos
df_juice <- read.csv("http://leg.ufpr.br/~lucambio/CE017/20251S/FrozenJuice.csv")

# Processamento das variáveis principais
# Cálculo do preço real (deflacionado pelo PPI)
preco_real <- df_juice$price / df_juice$ppi

# Cálculo da variação percentual logarítmica
var_preco <- 100 * diff(log(preco_real))

# Graus-dia de congelamento (FDD)
fdd_clima <- df_juice$fdd

# Conversão para objetos de série temporal (TS)
ts_preco <- ts(preco_real, start = c(1950, 1), frequency = 12)
ts_var <- ts(var_preco, start = c(1950, 2), frequency = 12)
ts_fdd <- ts(fdd_clima, start = c(1950, 1), frequency = 12)
```

1.2 Exploração Visual das Séries

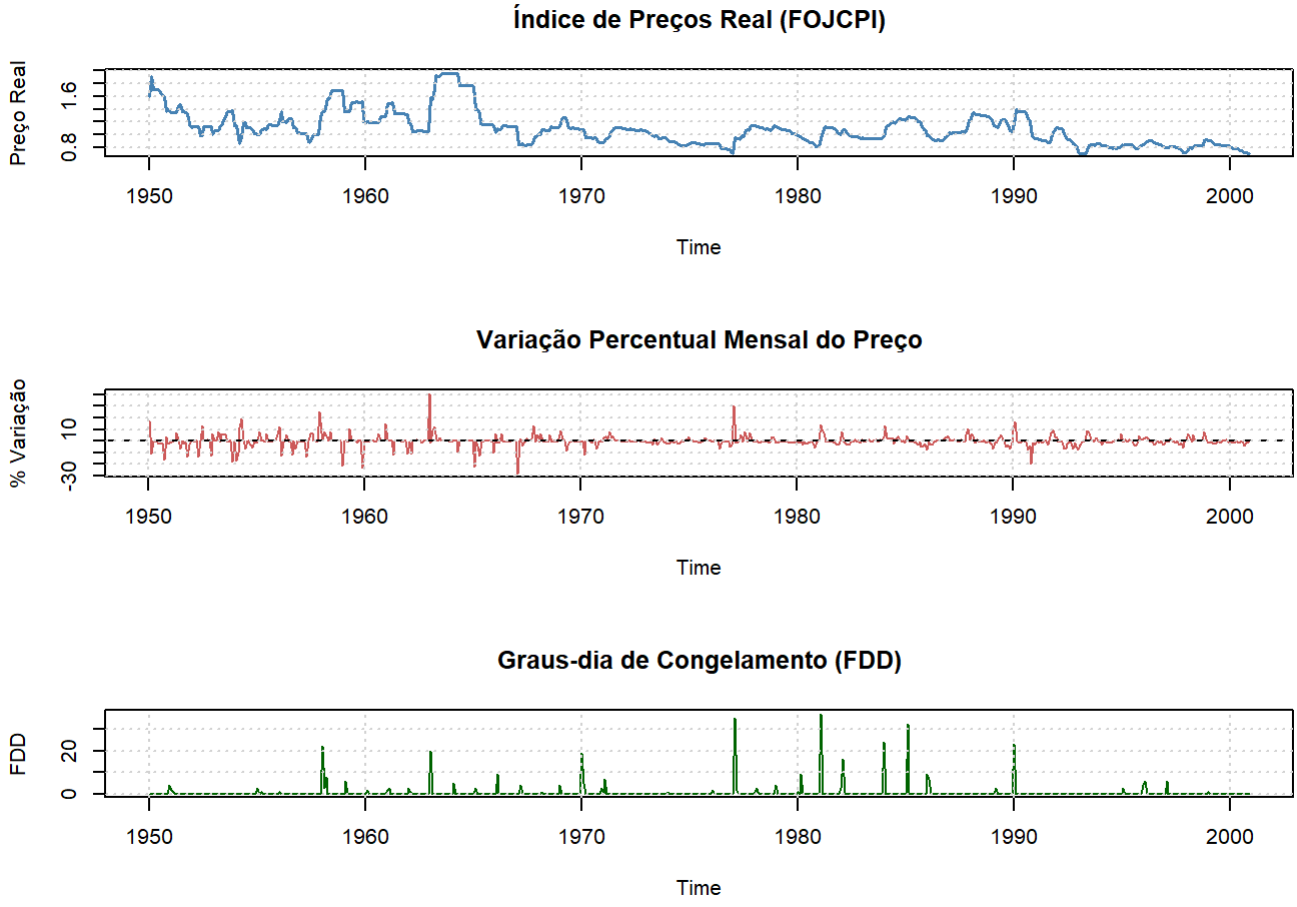
Abaixo, apresentamos o comportamento histórico das três variáveis de interesse entre 1950 e 2000.

```
par(mfrow = c(3, 1))

plot(ts_preco, col = "steelblue", lwd = 1.5, ylab = "Preço Real",
     main = "Índice de Preços Real (FOJCPI)")
grid()

plot(ts_var, col = "indianred", lwd = 1, ylab = "% Variação",
     main = "Variação Percentual Mensal do Preço")
abline(h = 0, lty = 2)
grid()

plot(ts_fdd, col = "darkgreen", lwd = 1, ylab = "FDD",
     main = "Graus-dia de Congelamento (FDD)")
grid()
```



1.3 Modelagem de Regressão Defasada

Ajustamos um modelo de regressão linear onde a variação do preço hoje é explicada pelo congelamento ocorrido no mês atual e nos 6 meses anteriores.

```
# Alinhamento temporal das séries e suas defasagens
dataset <- ts.intersect(
  Variacao = ts_var,
  FDD_Lag0 = ts_fdd,
  FDD_Lag1 = lag(ts_fdd, -1),
  FDD_Lag2 = lag(ts_fdd, -2),
  FDD_Lag3 = lag(ts_fdd, -3),
  FDD_Lag4 = lag(ts_fdd, -4),
  FDD_Lag5 = lag(ts_fdd, -5),
  FDD_Lag6 = lag(ts_fdd, -6)
)

# Ajuste do modelo de regressão
modelo_final <- lm(Variacao ~ FDD_Lag0 + FDD_Lag1 + FDD_Lag2 + FDD_Lag3 +
                   FDD_Lag4 + FDD_Lag5 + FDD_Lag6, data = dataset)

# Sumário estatístico
summary(modelo_final)
```

```
##
## Call:
## lm(formula = Variacao ~ FDD_Lag0 + FDD_Lag1 + FDD_Lag2 + FDD_Lag3 +
##     FDD_Lag4 + FDD_Lag5 + FDD_Lag6, data = dataset)
##
## Residuals:
##     Min      1Q  Median      3Q     Max
## -27.710  -0.948   0.235   0.992  32.285
##
## Coefficients:
##             Estimate Std. Error t value Pr(>|t|)
## (Intercept) -0.69296    0.21556  -3.215  0.00138 **
## FDD_Lag0     0.47143    0.05775   8.163 1.94e-15 ***
## FDD_Lag1     0.14502    0.05773   2.512  0.01227 *
## FDD_Lag2     0.05836    0.05770   1.011  0.31222
## FDD_Lag3     0.07417    0.05771   1.285  0.19923
## FDD_Lag4     0.03630    0.05770   0.629  0.52950
## FDD_Lag5     0.04876    0.05773   0.845  0.39872
## FDD_Lag6     0.05025    0.05775   0.870  0.38462
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 4.734 on 598 degrees of freedom
## Multiple R-squared:  0.1135, Adjusted R-squared:  0.1032
## F-statistic: 10.94 on 7 and 598 DF,  p-value: 4.902e-13
```

1.4 Resultados e Impactos Futuros

A tabela abaixo resume o impacto estimado de um evento de congelamento no preço do suco ao longo do tempo (horizonte de 6 meses)

```
resumo <- summary(modelo_final)$coefficients
tabela_impactos <- data.frame(
  Horizonte = paste0("Mês ", 0:6),
  Impacto_Percentual = round(resumo[2:8, 1], 4),
  Erro_Padrao = round(resumo[2:8, 2], 4),
  Significancia_P = round(resumo[2:8, 4], 4)
)

knitr::kable(tabela_impactos, align = "c")
```

	Horizonte	Impacto_Percentual	Erro_Padrao	Significancia_P
FDD_Lag0	Mês 0	0.4714	0.0578	0.0000
FDD_Lag1	Mês 1	0.1450	0.0577	0.0123
FDD_Lag2	Mês 2	0.0584	0.0577	0.3122
FDD_Lag3	Mês 3	0.0742	0.0577	0.1992
FDD_Lag4	Mês 4	0.0363	0.0577	0.5295
FDD_Lag5	Mês 5	0.0488	0.0577	0.3987
FDD_Lag6	Mês 6	0.0502	0.0578	0.3846

Conclusão:

Os coeficientes representam a magnitude do aumento de preço esperado para cada unidade de FDD. Valores de p-valor baixos indicam meses onde o congelamento tem impacto estatisticamente significativo na oferta e, consequentemente, no preço futuro.

Questão 2

2.1 Contexto e Dados Genômicos

O vírus Epstein-Barr (EBV) e o Herpesvírus Saimiri (HVS) compartilham o gene BNRF1, mas apresentam variações em suas sequências de nucleotídeos. Nesta análise, utilizamos a série temporal `bnrf1hvs` do pacote `astsa`.

```
# Carregamento da sequência do Herpesvírus Saimiri
data("bnrf1hvs")
seq_hvs <- bnrf1hvs

# Mapeamento: 1=A, 2=C, 3=G, 4=T
# Criando um indicador para Citosina (C) para análise de periodicidade
c_indicador <- ifelse(seq_hvs == 2, 1, 0)
```

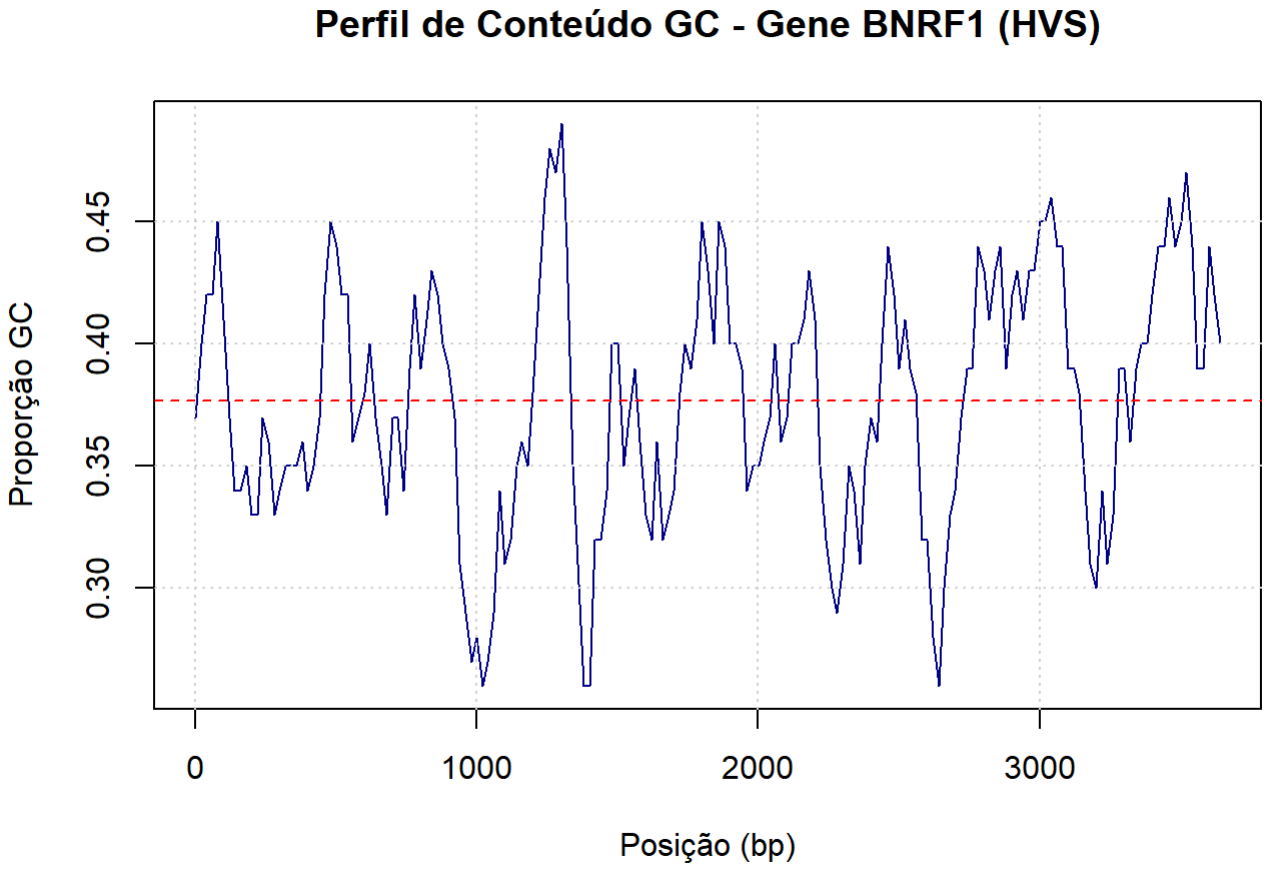
2.2 Análise de Janela Móvel (Sliding Window)

Para entender a distribuição do conteúdo GC (Guanina e Citosina) ao longo do gene, aplicamos uma média móvel. Regiões com alto teor de GC frequentemente possuem funções biológicas distintas.

```
# Configuração da janela: 100 bp com salto de 20 bp
janela <- 100
salto <- 20
posicoes <- seq(1, length(seq_hvs) - janela, by = salto)

# Cálculo do conteúdo GC local
conteudo_gc <- sapply(posicoes, function(p) {
  sub_seq <- seq_hvs[p:(p + janela)]
  sum(sub_seq == 2 | sub_seq == 3) / janela
})

# Visualização da variação ao longo do gene
plot(posicoes, conteudo_gc, type = "l", col = "darkblue",
     main = "Perfil de Conteúdo GC - Gene BNRF1 (HVS)",
     xlab = "Posição (bp)", ylab = "Proporção GC")
abline(h = mean(conteudo_gc), col = "red", lty = 2)
grid()
```

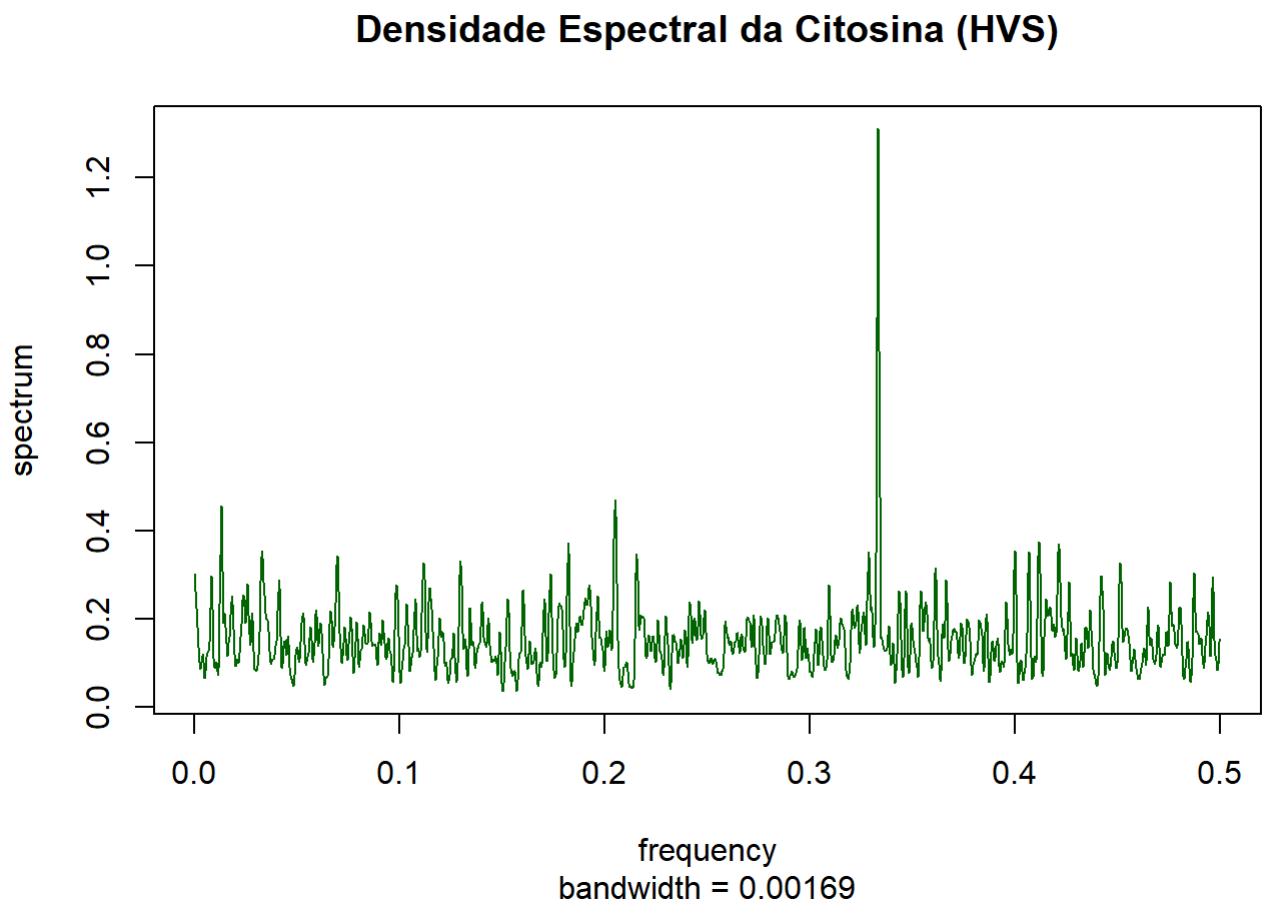


2.3 Decomposição Espectral da Sequência

A análise espectral permite identificar se existe uma periodicidade latente na sequência, como o ciclo de 3 pares de base comum em regiões codificantes.

```
# Cálculo do periodograma suavizado
espectro_dna <- mvspec(c_indicador, spans = c(5, 5), plot = FALSE)

# Plotagem do espectro
plot(espectro_dna, main = "Densidade Espectral da Citosina (HVS)",
     col = "darkgreen", log = "no")
```



Questão 3: Decomposição Espectral (Casos de Rubéola)

Esta análise visa identificar padrões periódicos na série temporal de casos de rubéola em Copenhague utilizando a densidade espectral.

3.1 Carregamento e Visualização

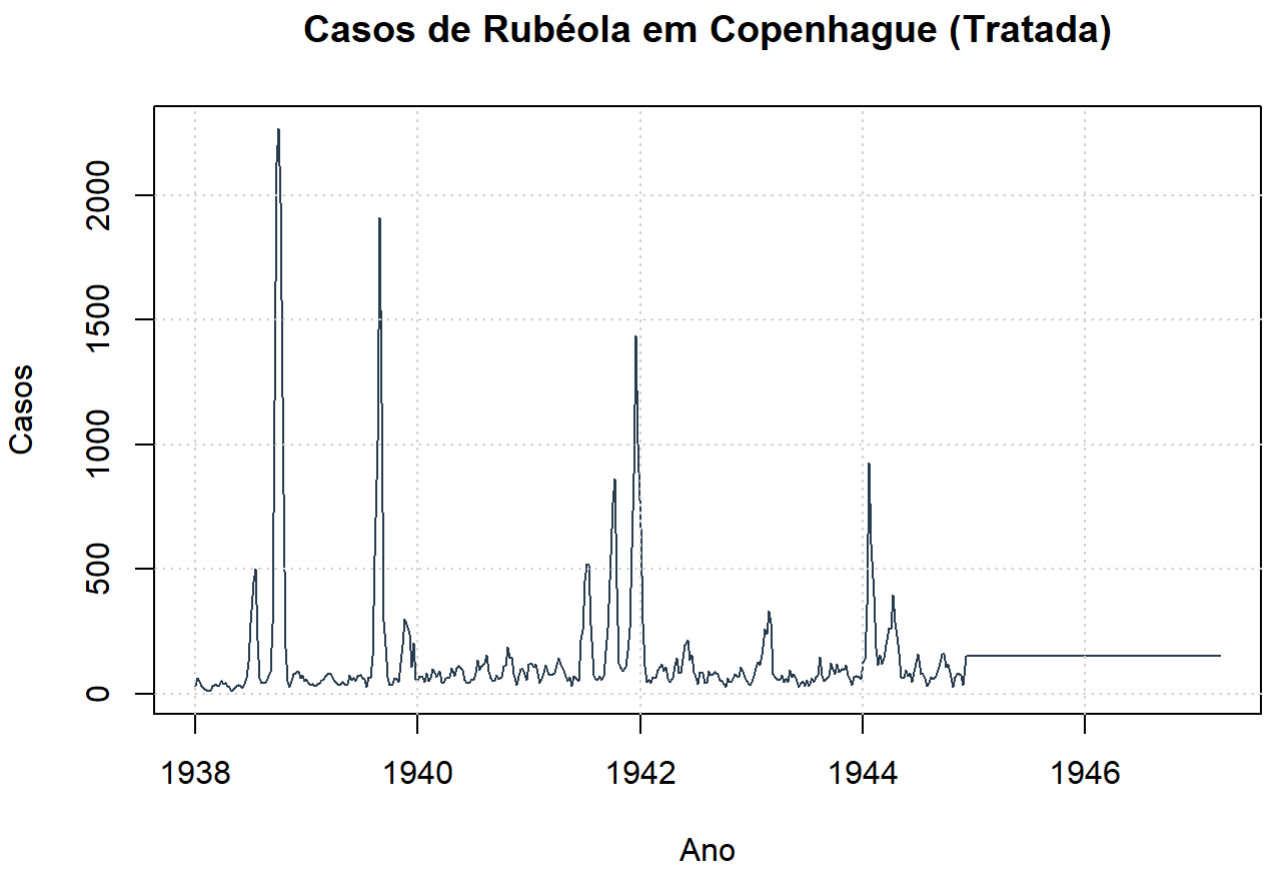
```
library(ggplot2)
library(astsa)

# Leitura dos dados
dados <- read.csv("https://math.mcmaster.ca/~bolker/eeid/2010/Ecology/Copenhagen.csv")

# Criando a série temporal
rubella_ts <- ts(dados$Rubella, start = dados$Date.3[1], frequency = 52)

# TRATAMENTO: Removendo valores NA para permitir o cálculo do espectro
# Substituímos NAs pela média da série para não interromper a continuidade
rubella_ts[is.na(rubella_ts)] <- mean(rubella_ts, na.rm = TRUE)

# Gráfico da série tratada
plot(rubella_ts, main = "Casos de Rubéola em Copenhague (Tratada)",
     ylab = "Casos", xlab = "Ano", col = "#2c3e50")
grid()
```

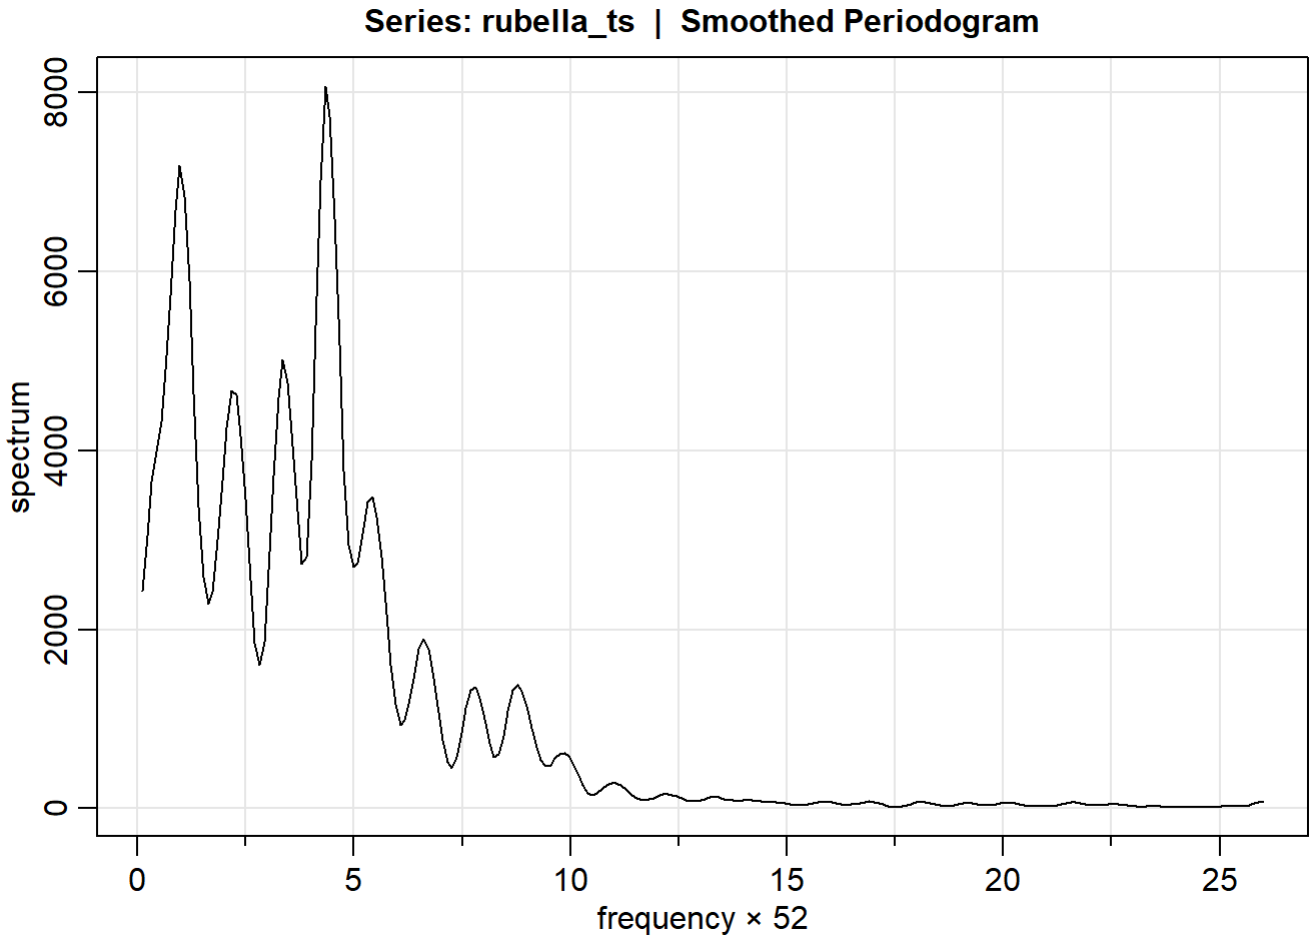


3.2 Cálculo do Espectro

Calculamos o periodograma para identificar as frequências dominantes. Utilizaremos uma suavização (spans) para obter uma estimativa mais consistente da densidade espectral.

```
# Agora o mvspec funcionará sem o erro de valores em falta
espectro <- mvspec(rubella_ts, spans = c(5, 5), taper = 0.1, log = "no")
```

```
## Bandwidth: 0.687 | Degrees of Freedom: 11.36 | split taper: 10%
```




```
# Identificando a frequência de pico
frequencia_pico <- espectro$freq[which.max(espectro$spec)]
periodo_pico <- 1 / frequencia_pico

cat("Frequência dominante:", frequencia_pico, "\n")
```

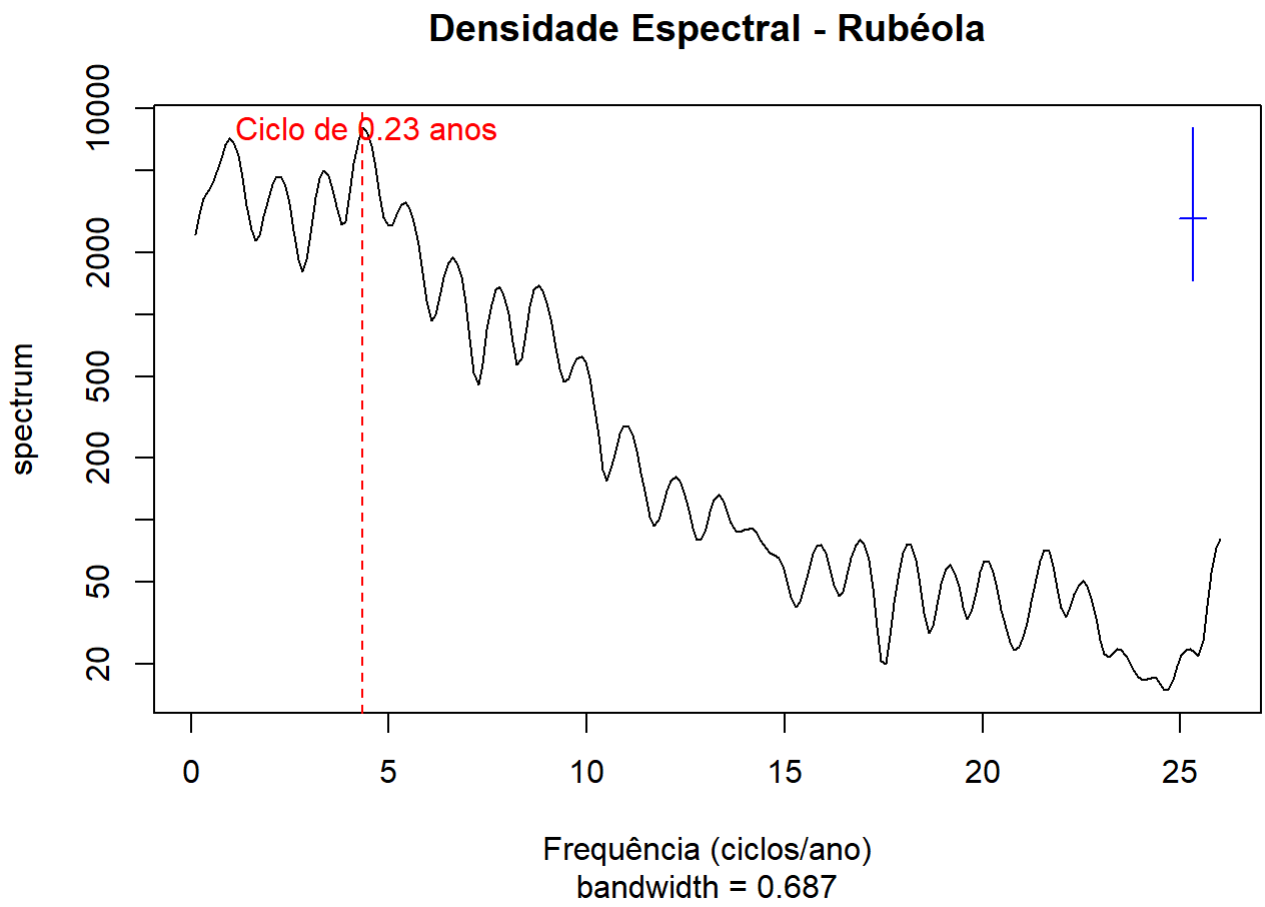
```
## Frequência dominante: 4.333333
```

```
cat("Período correspondente (em anos):", periodo_pico, "\n")
```

```
## Período correspondente (em anos): 0.2307692
```

3.3 Identificação de Padrões Periódicos

```
# Plotando o espectro com destaque para o pico principal
plot(espectro, main = "Densidade Espectral - Rubéola", xlab = "Frequência (ciclos/ano)")
abline(v = frequencia_pico, col = "red", lty = 2)
text(frequencia_pico + 0.1, max(espectro$spec),
     labels = paste("Ciclo de", round(periodo_pico, 2), "anos"), col = "red")
```


Densidade Espectral - Rubéola
Ciclo de 0.23 anos
spectrum
10000
2000
500
200
50
20
0
5
10
15
20
25
Frequência (ciclos/ano)
bandwidth = 0.687